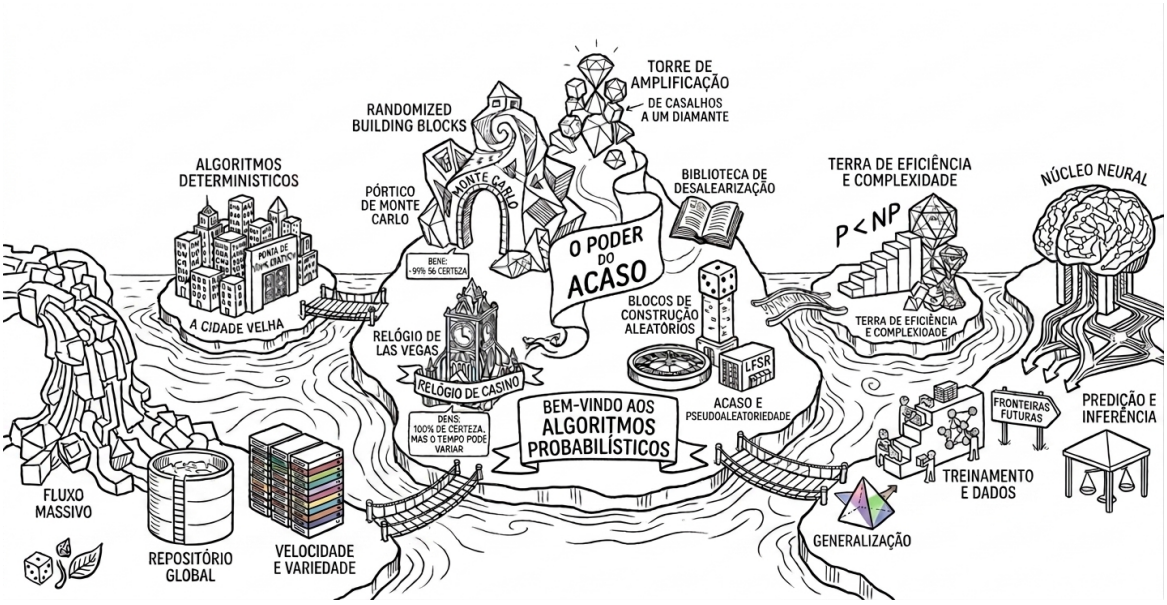
NOTAS DE AULA

ALGORITMOS PROBABILÍSTICOS



MCZA035-17 ALGORITMO PROBABILÍSTICOS (Q3 2026)

PROF.: JAIR DONADELLI

http://professor.ufabc.edu.br/~jair.donadelli/algprob

Sumário

1 Noções de probabilidade **7**
- 1.1 Convenções notacionais . . . 9
- 1.2 Probabilidade discreta . . . 10
- 1.3 Probabilidade condicional . . . 13
  - 1.3.1 Independência de eventos . . . 16
  - 1.3.2 Teste de identidade polinomial . . . 17
  - 1.3.3 Continuidade de uma medida de probabilidade . 23
- 1.4 Um gerador de números aleatórios . . . 24
- 1.5 Verificação do produto de matrizes . . . 27
- 1.6 Exercícios . . . 27

2 Variáveis aleatórias discretas **29**
- 2.1 Distribuição . . . 30
- 2.2 Valor esperado de uma variável aleatória discreta . . . 33
- 2.3 Propriedades da esperança . . . 44
  - 2.3.1 Esperança de funções de variáveis aleatórias . . . 49
- 2.4 Variáveis contínuas, a Uniforme e simulação . . . 50
  - 2.4.1 A distribuição uniforme (contínua) . . . 52
- 2.5 Exercícios . . . 55

3 *Quicksort* probabilístico **59**
- 3.1 Dominação estocástica . . . 61
  - 3.1.1 Acoplamento . . . 63
  - 3.1.2 Dominação estocástica na análise do QS . . . 65
- 3.2 Análise do *quicksort* probabilístico . . . 67
- 3.3 Esperança condicional . . . 70
- 3.4 Desigualdade de Markov . . . 72
- 3.5 Desigualdade de Chebyshev . . . 75
- 3.6 Exercícios . . . 76

4 Desigualdades de Chernoff–Hoeffding **87**
- 4.1 O método de Chernoff . . . 87
  - 4.1.1 Momentos e função geradora de momentos . . . 88
- 4.2 Soma de variáveis aleatórias uniformes . . . 90

4.3 A desigualdade de Hoeffding . . . 92
4.3.1 A desigualdade de Hoeffding . . . 95
4.4 Soma de variáveis aleatórias Bernoulli não identicamente distribuídas . . . 96
4.5 Soma de variáveis aleatórias geométricas . . . 101
4.6 Amplificação em algoritmos de Monte Carlo . . . 102
4.7 *Quicksort* . . . 105
4.8 Exercícios . . . 108

5 *Skip*, *Treap* e *Streaming* 111
5.1 *Skip list* . . . 111
5.1.1 O tempo de uma busca . . . 115
5.2 *Treap* . . . 120
5.3 *Streaming* . . . 125
5.3.1 O truque da média . . . 130
5.3.2 O truque da mediana . . . 131
5.3.3 Espaço . . . 131
5.4 Exercícios . . . 133

6 *Hashing* 135
6.1 Tabelas de espalhamento . . . 136
6.1.1 O paradoxo dos aniversários e um limiar para colisões . . . 140
6.1.2 Variância do número de colisões e do tamanho de uma lista . . . 142
6.2 *Hashing* universal . . . 144
6.2.1 *Hashing* perfeito . . . 147
6.2.2 *Count-Min sketch* . . . 149
6.2.3 Filtro de Bloom . . . 151
6.3 Exercícios . . . 156

7 *Hashing* 2-universal 159
7.0.1 Corte grande em grafos . . . 163
7.0.2 Lema de misturabilidade do *hashing* 2-universal . . . 167
7.1 Impressões digitais e verificação de igualdade . . . 171
7.1.1 Famílias quase universais e o protocolo geral . . . 172
7.1.2 Impressão digital por resto módulo um primo aleatório . . . 173
7.1.3 Impressão digital por avaliação de polinômio . . . 173
7.1.4 Comparação e um exemplo numérico . . . 174
7.2 Exercícios . . . 176

8 Teste de Identidade de Polinômios 179
8.1 Emparelhamentos Perfeitos em Grafos Bipartidos . . . 179
8.2 Representação de Polinômios . . . 181

8.3 O Lema de Schwartz–Zippel 182
8.4 Emparelhamentos Perfeitos via Teste de Identidade de Polinômios 184

A Sobre convergência de séries **187**
A.1 Sequências e séries 187

B Desigualdades **189**

C Resolução dos exercícios **191**

Referências Bibliográficas **211**

Notação

1. $\mathbb{N} = \{0, 1, 2, \dots\}$ denota o conjunto dos números naturais; $\mathbb{Z}$ denota o conjunto dos números inteiros e $\mathbb{Z}_+ = \{1, 2, \dots\}$ os inteiros positivos; $\mathbb{R}$ denota o conjunto dos números reais.

2. ":=" tem o significado de "é definido igual a".

3. O conjunto de todos os subconjuntos de B com cardinalidade k é denotado $\binom{B}{k}$.

   O conjunto de todos os subconjuntos de B, ou seja, o ***conjunto das partes*** de B, é denotado por 2^B.

   Se A e B são conjuntos então B^A é o c***onjunto de todas as funções de*** A ***em*** B.

   $\overline{A}$ para o ***complemento*** $\Omega \setminus A$.

4. ln é a função logaritmo natural, ou seja, logaritmo na base e $= 2{,}71\dots$. Em base a, usamos $\log_a$ e omitimos a no caso $a = 2$.

5. Usamos $\sum_{i \geqslant 1}$ com o mesmo significado de $\sum_{i=1}^{\infty}$ para séries.

   Também, usamos $\bigcup_{i \geqslant 1}$ tanto quanto $\bigcup_{i=1}^{\infty}$ para operações sobre conjuntos.

Disclaimer

Estas notas podem conter erro, esteja atento e leia-as criticamente.

O objetivo destas notas é, além de apresentar o conteúdo das aulas, complementá-los. Não só, mas principalmente, muitas dos detalhes técnicos e dos cálculos de probabilidades são rascunhados em sala e detalhados aqui.

1
Noções de probabilidade

Intuitivamente, uma medida de probabilidade é uma forma quantitativa de expressar a chance de ocorrência de eventos associados a um experimento aleatório, cujos resultados não podem ser previamente determinados. A teoria da probabilidade é a área da matemática dedicada à modelagem e ao estudo rigoroso desses fenômenos sob condições de incerteza.

Uma medida de probabilidade $\mathbb{P}$ é definida sobre uma família $\mathcal{E}$ de subconjuntos de Ω, os eventos aleatórios, que deve satisfazer:

(i) $\Omega \in \mathcal{E}$;

(ii) se $A \in \mathcal{E}$ então $\overline{A} \in \mathcal{E}$;

(iii) se $A_i \in \mathcal{E}$ para todo $i \geqslant 1$, então $\bigcup_{i \geqslant 1} A_i \in \mathcal{E}$.

Uma família de subconjuntos que satisfaz essas propriedades é chamada de ***σ-álgebra de subconjuntos de Ω***.

Um ***espaço de probabilidade***, ou um modelo probabilístico, é uma terna $(\Omega, \mathcal{E}, \mathbb{P})$ tal que Ω é um conjunto não vazio, chamado ***espaço amostral***; $\mathcal{E}$ é uma σ-álgebra de subconjuntos de Ω; e $\mathbb{P} \colon \mathcal{E} \to [0,1]$ é uma ***medida de probabilidade***, que atribui a cada evento aleatório um número real satisfazendo

Neste texto, usaremos os termos *espaço de probabilidade* e *modelo probabilístico* de maneira intercambiável, sem distinção.

Não-negatividade $\mathbb{P}(A) \geqslant 0$ para todo $A \in \mathcal{E}$.
Normalização $\mathbb{P}(\Omega) = 1$.
Aditividade enumerável se $\{ A_i \in \mathcal{E} \colon i \geqslant 1 \}$ é um conjunto enumerável de eventos mutuamente exclusivos, então

$$\mathbb{P}\left(\bigcup_{i=1}^{\infty} A_i \right) = \sum_{i=1}^{\infty} \mathbb{P}(A_i).$$

O lado esquerdo dessa igualdade não depende de uma enumeração particular dos conjuntos A_i e o mesmo vale para o lado direito.

Proposição 1.1: Propriedades de $\mathbb{P}$

Para uma medida de probabilidade $\mathbb{P}$ sobre um espaço de eventos $\mathcal{E}$ do espaço amostral Ω valem as seguintes propriedades.

1. A probabilidade do ***evento impossível*** é
$$\mathbb{P}(\varnothing)=0.$$
2. ***Aditividade finita:*** se $A_1, A_2, \ldots, A_n \in \mathcal{E}$ são eventos mutuamente exclusivos então
$$\mathbb{P}\left(\bigcup_{i=1}^{n} A_i\right)=\sum_{i=1}^{n}\mathbb{P}(A_i). \tag{1.1}$$
3. ***A probabilidade do complemento*** é
$$\mathbb{P}(\overline{A})=1-\mathbb{P}(A)$$
para todo evento $A \in \mathcal{E}$.
4. ***Monotonicidade***: se $A \subseteq B$, então $\mathbb{P}(A) \leqslant \mathbb{P}(B)$. Também, $\mathbb{P}(B \setminus A)=\mathbb{P}(B)-\mathbb{P}(A)$.
5. ***Regra da adição***: Para quaisquer A, B
$$\mathbb{P}(A \cup B)=\mathbb{P}(A)+\mathbb{P}(B)-\mathbb{P}(A \cap B).$$
6. ***Subaditividade***: Se $A_1, A_2, \ldots, A_n$ são eventos, então
$$\mathbb{P}\left(\bigcup_{i=1}^{n} A_i\right) \leqslant \sum_{i=1}^{n}\mathbb{P}(A_i). \tag{1.2}$$

Demonstração. Fazendo $A_1 = \Omega$ e $A_i = \varnothing$ para todo $i \geqslant 2$ temos, pela aditividade enumerável, que

$$\mathbb{P}(\Omega) = \mathbb{P}(\Omega \cup \varnothing \cup \varnothing \cup \cdots \cup \varnothing \cup \cdots) = \mathbb{P}(\Omega) + \sum_{i=2}^{\infty}\mathbb{P}(\varnothing)$$

portanto, pela não-negatividade, resta que $\mathbb{P}(\varnothing) = 0$. Agora, definindo $A_i = \varnothing$ para todo $i > n$

$$\mathbb{P}\left(\bigcup_{i=1}^{n} A_i\right) = \mathbb{P}\left(\bigcup_{i=1}^{\infty} A_i\right) = \sum_{i=1}^{\infty}\mathbb{P}(A_i) = \sum_{i=1}^{n}\mathbb{P}(A_i) + \sum_{i>n}\mathbb{P}(\varnothing) = \sum_{i=1}^{n}\mathbb{P}(A_i)$$

que é o resultado afirmado no item 2.

A probabilidade do complemento segue do item anterior e da normalização. Os detalhes ficam a cargo do leitor.

Para monotonicidade, consideremos A e B eventos tais que $A \subseteq B$. Usamos que B pode ser escrito como a união disjunta $A \cup (B \setminus A)$,

donde $\mathbb{P}(B) = \mathbb{P}(A) + \mathbb{P}(B \setminus A)$ e como $\mathbb{P}(\overline{A} \cap B) \geqslant 0$ temos $\mathbb{P}(B) \geqslant \mathbb{P}(A)$. Notemos que, como consequência imediata, temos $\mathbb{P}(A) \leqslant 1$ para todo evento A.

Finalmente, a união $A \cup B$ pode ser escrita como duas uniões disjuntas $(A \setminus B) \cup (B \setminus A) \cup (A \cap B)$ donde concluímos que

$$\mathbb{P}(A \cup B) = \mathbb{P}(A \setminus B) + \mathbb{P}(B \setminus A) + \mathbb{P}(A \cap B). \tag{1.3}$$

Agora, A pode ser escrito como a união disjunta $(A \setminus B) \cup (A \cap B)$ e, analogamente, $B = (B \setminus A) \cup (A \cap B)$, portanto $\mathbb{P}(A) = \mathbb{P}(A \setminus B) + \mathbb{P}(A \cap B)$ assim como $\mathbb{P}(B) = \mathbb{P}(B \setminus A) + \mathbb{P}(A \cap B)$. Isolando $\mathbb{P}(A \setminus B)$ e $\mathbb{P}(B \setminus A)$ nessas duas igualdades e substituindo na equação (1.3) prova a regra da adição. □

1.1 *Convenções notacionais*

Sejam A uma descrição de um evento aleatório e A_Ω o subconjunto que o representa em $(\Omega, \mathcal{E}, \mathbb{P})$. Denotamos por $\mathbb{P}[A]$ a probabilidade do evento descrito por A, isto é, $\mathbb{P}[A] \coloneqq \mathbb{P}(A_\Omega)$. Caso haja a necessidade de evidenciar o espaço amostral escreveremos

$$\mathop{\mathbb{P}}_{\Omega}[A] \quad \text{ou} \quad \mathop{\mathbb{P}}_{\omega \in \Omega}[\text{ocorre } A] \quad \text{ou} \quad \mathop{\mathbb{P}}_{\omega \in \Omega}[\omega \in A] \tag{1.4}$$

com o mesmo sentido, o de $\mathbb{P}(A_\Omega)$.

Por exemplo, no caso em que uma moeda equilibrada é lançada até sair coroa, o evento caracterizado por "o número de lançamentos é par" é definido em $(\Omega, \mathcal{E}, \mathbb{P})$ por $A_\Omega \coloneqq \{(c_1, \ldots, c_i) : i \text{ é par}\}$ e $\mathbb{P}\big[\text{número par de lançamentos}\big]$ denota o mesmo que $\mathbb{P}(A_\Omega)$.

Quando Ω é finito e a menos que seja dada explicitamente outra medida, então a notação na equação (1.4) significa que estamos assumindo a medida de ***probabilidade uniforme***: $\mathbb{P}(\omega) = 1/|\Omega|$ para todo $\omega \in \Omega$. Por exemplo, seja $p(x)$ um polinômio não nulo e Ω um conjunto finito de números. A probabilidade de que o sorteio de um elemento de Ω, todos com a mesma probabilidade de ocorrência, resulte numa raiz do polinômio é descrita por

$$\mathop{\mathbb{P}}_{x \in_R \Omega}[p(x) = 0]$$

que é a probabilidade do evento $R = \{\omega \in \Omega : p(\omega) = 0\}$.

Nos algoritmos assumiremos a possibilidade de se fazer escolhas aleatórias, ou seja, assumiremos que os algoritmos dispõem da instrução

$$a \xleftarrow{R} \Omega$$

chamada de atribuição por uma ***escolha aleatória uniforme*** em Ω (finito), o que significa que a assume qualquer um dos elementos de Ω

com igual probabilidade, a saber $1 / |\Omega|$. Por exemplo, a partir de uma fonte de bits aleatórios, a instrução

$$a \xleftarrow{R} \{0,1\}$$

denota o fato de que a é uma variável do algoritmo e que após a execução da atribuição $\xleftarrow{R}$ o valor da variável a é um elemento qualquer de $\{0,1\}$ com probabilidade $1/2$.

Notação	***Eventos***	***Conjunto***
Ω	espaço amostral, evento certo	universo
$\varnothing$	evento impossível	vazio
$\{\omega\}$	evento elementar	conjunto unitário
A	evento	subconjunto
A	ocorre A	$\omega \in A$
$\overline{A}$	não ocorre A	$\omega \notin A$ (complemento)
$A \cap B$	ocorre A e B	$\omega \in A \cap B$ (intersecção)
$A \cup B$	ocorre A ou B	$\omega \in A \cup B$ (união)
$A \setminus B$	ocorre A e não ocorre B	$\omega \in A$ e $\omega \notin B$ (diferença)
$A \triangle B$	ocorre A ou B, não ambos	$\omega \in A \cup B$ e $\omega \notin A \cap B$ (diferença simétrica)
$A \subseteq B$	se ocorre A, então ocorre B	$\omega \in A \Rightarrow \omega \in B$ (inclusão)

Tabela 1.1: pequeno dicionário de termos da probabilidade.

1.2 *Probabilidade discreta*

Um ***modelo probabilístico discreto***, ou ***espaço de probabilidade discreto***, é um espaço $(\Omega, \mathcal{E}, \mathbb{P})$ em que Ω é enumerável (finito ou infinito) e $\mathcal{E} = 2^{\Omega}$.

Se A é conjunto, 2^A denota o conjunto das partes de A.

Nesse caso, todo experimento tem seu modelo probabilístico especificado quando estabelecemos

1. um espaço amostral enumerável Ω;
2. uma função $p : \Omega \to [0,1]$ tal que $\sum_{\omega\in\Omega} p(\omega) = 1$, chamada ***função massa de probabilidade***.

De fato, dado (Ω, p) como acima, podemos definir uma função $\mathbb{P}$ em 2^{Ω} tomando

$$\mathbb{P}(A) := \sum_{\omega\in A} p(\omega), \qquad A \subseteq \Omega. \tag{1.5}$$

Essa soma está bem definida e $0 \leqslant \mathbb{P}(A) \leqslant 1$ para todo $A \subseteq \Omega$. Claramente, $\mathbb{P}(\Omega) = \sum_{\omega} \mathbb{P}(\{\omega\}) = 1$. Além disso, se A_i para $i \geqslant 1$ são eventos mutuamente exclusivos, então

$$\mathbb{P}\left(\bigcup_{i=1}^{\infty} A_i\right) = \sum_{i=1}^{\infty} \mathbb{P}(A_i)$$

segue da convergência absoluta e da exclusão mútua. Portanto, $\mathbb{P}$ é uma medida de probabilidade sobre 2^Ω.

Assim, em um espaço de probabilidade discreto, a função massa de probabilidade determina completamente a medida de probabilidade.

Convencionamos a notação

$$\mathbb{P}(\omega) \coloneqq \mathbb{P}(\{\omega\})$$

para os eventos elementares.

Exemplo 1.1: Moeda equilibrada

Uma moeda equilibrada é lançada repetidamente até sair coroa. No espaço amostral definimos a função massa de probabilidade

$$p((c_1, c_2, \ldots, c_i)) = \begin{cases} 2^{-i} & \text{para } c_j = \text{Ca se } j < i \text{ e } c_i = \text{Co}, \\ 0 & \text{nos outros casos.} \end{cases}$$

Ω e p definem um modelo probabilístico discreto para o experimento.

Monty Hall

Vejamos um modelo probabilístico para o problema de Monty Hall: o apresentador Monty Hall mostra três portas a um espectador que concorre ao prêmio escondido atrás das portas.

Monty Hall é o nome do apresentador de um concurso televisivo que era exibido na década de 1970, nos Estados Unidos, chamado *Let's Make a Deal*.

O protocolo é o seguinte: Monty Hall escolhe, ao acaso, uma das portas para esconder um carro; nas outras duas esconde um bode em cada. Na primeira etapa o concorrente escolhe uma porta ao acaso (que ainda não é aberta); em seguida Monty Hall abre uma das outras duas portas que o concorrente não escolheu, sabendo que ela esconde um bode e escolhendo ao acaso se houver mais de uma possibilidade. Com duas portas fechadas apenas e sabendo que o carro está atrás de uma delas, o apresentador oferece ao concorrente a oportunidade de trocar de porta. O concorrente tem que decidir se permanece com a porta que escolheu no início do jogo ou se muda para a outra porta que ainda está fechada. Feita a escolha, o apresentador abre a porta escolhida e o concorrente leva o prêmio escondido pela porta. Qual é a estratégia que maximiza a chance de ganhar o carro?

O experimento consiste das seguintes três etapas

1. o apresentador esconde o carro atrás de uma das portas escolhida com probabilidade 1/3;
2. com probabilidade 1/3, uma porta é escolhida pelo jogador;
3. o apresentador revela, dentre as duas que o jogador não escolheu, aquela que não esconde o carro. Se houver duas possibilidades então o apresentador escolhe uma delas com probabilidade 1/2.

Um espaço amostral fica definido pelas ternas (e_1, e_2, e_3) em que e_i é a porta escolhida no passo i descrito acima e, se as portas estão numeradas por 1,2 e 3, então definimos um modelo probabilístico discreto com Ω dado por

$$\big\{(1,2,3),(1,3,2),(2,1,3),(2,3,1),(3,1,2),(3,2,1),$$
$$(1,1,2),(1,1,3),(2,2,1),(2,2,3),(3,3,1),(3,3,2)\big\}.$$

e probabilidades de acordo com o diagrama de árvore mostrado na Figura 1.1 abaixo; um caminho seguido pelo jogador numa rodada do jogo corresponde a um caminho na árvore, a partir da raiz (o ponto mais alto) até uma folha (um dos pontos mais baixos). A primeira ramificação corresponde a escolha de porta para esconder o carro, as segundas ramificações correspondem a escolha do jogador e as terceiras ramificações correspondem a escolha de porta para abrir feita pelo apresentador. Os eventos que interessam, a saber "o jogador

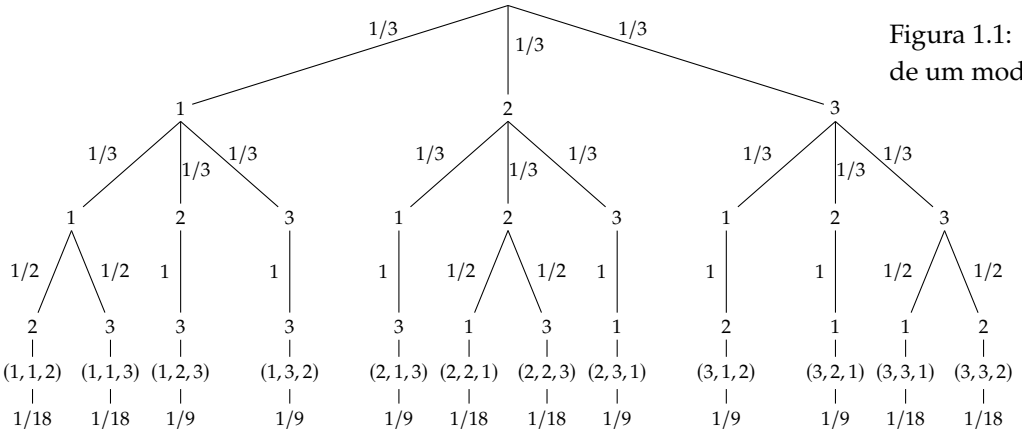


Figura 1.1: diagrama de árvore de um modelo para Monty Hall.

vence trocando de porta" e "o jogador vence não trocando de porta", são complementares e denotados por A e $\overline{A}$ respectivamente, de modo que $A = \{\,(1,2,3),(1,3,2),(2,1,3),(2,3,1),(3,1,2),(3,2,1)\,\}$ e $\overline{A}$ é dada pelas ternas restantes de Ω. O jogador ganha o carro trocando de porta com probabilidade

$$\mathbb{P}(A) = \mathbb{P}(\{\,(1,2,3),(1,3,2),(2,1,3),(2,3,1),(3,1,2),(3,2,1)\,\}) = \frac{2}{3}$$

portanto, ganha sem trocar de porta com probabilidade $1 - 2/3 = 1/3$, que corresponde à probabilidade de ter escolhido a porta certa já na primeira oportunidade de escolha. Portanto, a melhor estratégia é trocar de porta quando é oferecida essa oportunidade pois isso dobra a probabilidade de ganhar o carro.

1.3 *Probabilidade condicional*

Em um espaço de probabilidade discreto definido por Ω e $\mathbb{P}$, a probabilidade de ocorrência do evento A condicionada à ocorrência o evento E, ou como dizemos a ***probabilidade condicional*** de A dado E, em que $\mathbb{P}(E) \neq 0$, é definida por

$$\mathbb{P}(A \mid E) := \frac{\mathbb{P}(A \cap E)}{\mathbb{P}(E)} \tag{1.6}$$

e $\mathbb{P}(A \mid E)$ é lido como a ***probabilidade de A dado E***.

Por exemplo, se Ω é finito com medida de probabilidade uniforme e $E \neq \varnothing$ então

$$\mathbb{P}(A \mid E) = \frac{\mathbb{P}(A \cap E)}{\mathbb{P}(E)} = \frac{|A \cap E|}{|E|} \tag{1.7}$$

Ideia importante

Considere um espaço de probabilidade $(\Omega, \mathcal{E}, \mathbb{P})$ e um evento com probabilidade positiva $E \in \mathcal{E}$.
$\mathbb{P}_E(A) := \mathbb{P}(A \mid E)$ é uma medida de probabilidade para os eventos em $\mathcal{E}$ (i.e, satisfaz os axiomas de probabilidade).
Também, $(E, \{A \cap E : \quad A \in \mathcal{E}\}, \mathbb{P}_E)$ é um espaço de probabilidade.

Regra do produto: A igualdade, que decorre da definição,

$$\mathbb{P}(A \cap B) = \mathbb{P}(A \mid B) \cdot \mathbb{P}(B)$$

é consequência direta da definição de probabilidade condicional e é conhecida como ***teorema da multiplicação*** ou ***regra do produto***.

Essa regra é facilmente estendida para calcular $\mathbb{P}(A \cap B \cap C)$:

$$\begin{aligned}\mathbb{P}(A \cap B \cap C) &= \mathbb{P}(A) \cdot \mathbb{P}(B \cap C \mid A) \\ &= \mathbb{P}(A) \cdot \mathbb{Q}(B \cap C) \\ &= \mathbb{P}(A) \cdot \mathbb{Q}(B) \cdot \mathbb{Q}(C \mid B)\end{aligned}$$

onde $\mathbb{Q}$ é a medida $\mathbb{P}(\cdot \mid A)$. Mas

$$\mathbb{Q}(C \mid B) = \frac{\mathbb{P}(B \cap C \mid A)}{\mathbb{P}(B \mid A)} = \frac{\frac{\mathbb{P}(A \cap B \cap C)}{\mathbb{P}(A)}}{\frac{\mathbb{P}(A \cap B)}{\mathbb{P}(A)}} = \mathbb{P}(C \mid A \cap B)$$

assim

$$\mathbb{P}(A \cap B \cap C) = \mathbb{P}(A) \cdot \mathbb{P}(B \mid A) \cdot \mathbb{P}(C \mid A \cap B) \tag{1.8}$$

(identifique o uso dessa regra no modelo probabilístico para o problema de Monty Hall, página 11).

Um caso geral desse teorema é dado abaixo, cuja prova é exercício.

Teorema 1.1: Teorema da multiplicação

Sejam $A_1, A_2, \ldots, A_n$ eventos de um modelo probabilístico. Prove que

$$\begin{aligned}\mathbb{P}(A_1 \cap \cdots \cap A_n) = &\mathbb{P}(A_1) \cdot \mathbb{P}(A_2 \mid A_1) \cdot \\ &\mathbb{P}(A_3 \mid A_2 \cap A_1) \cdots \\ &\mathbb{P}(A_n \mid A_{n-1} \cap A_{n-2} \cap \cdots \cap A_1)\end{aligned} \tag{1.9}$$

sempre que as probabilidades condicionais estão definidas (veja que é suficiente pedir que $\mathbb{P}(A_1 \cap \cdots \cap A_{n-1}) > 0$).

A Lei da Probabilidade Total: Se E e A são eventos, com $0 < \mathbb{P}(E) < 1$, então o evento A ocorre se e somente se ocorre (A e E) ou (A e $\overline{E}$), e esses eventos entre parênteses são disjuntos; mais que isso $\{A \cap E, A \cap \overline{E}\}$ é uma partição de A, portanto,

$$\begin{aligned}\mathbb{P}(A) &= \mathbb{P}\Big((A \cap E) \cup (A \cap \overline{E})\Big) \\ &= \mathbb{P}(A \cap E) + \mathbb{P}(A \cap \overline{E}) &(1.10)\\ &= \mathbb{P}(A \mid E)\,\mathbb{P}(E) + \mathbb{P}(A \mid \overline{E})\,\mathbb{P}(\overline{E}). &(1.11)\end{aligned}$$

No problema de Monty Hall se o convidado fica com a porta que escolheu inicialmente, então a probabilidade de ganhar um carro é $1/3$, que é a probabilidade dele ter escolhido a porta certa logo de início. Agora, vamos supor que o convidado troca de porta. Nesse caso, denotamos por A o evento "ganha o carro" e por E o evento "a porta escolhida na primeira etapa esconde o carro". Claramente, $\mathbb{P}(A \mid E) = 0$ e $\mathbb{P}(E) = 1/3$. Se a primeira escolha não era a correta então o convidado ganha o carro, ou seja, $\mathbb{P}(A \mid \overline{E}) = 1$. Com isso temos por (1.11)

$$\mathbb{P}(A) = \mathbb{P}(A \mid E)\,\mathbb{P}(E) + \mathbb{P}(A \mid \overline{E})\,\mathbb{P}(\overline{E}) = 0\frac{1}{3} + 1\frac{2}{3} = \frac{2}{3}$$

portanto, é melhor trocar de porta.

O caso geral dessa igualdade é conhecido como o teorema da probabilidade total. Segue da dedução acima e usando indução em n que se $\{E_1, E_2, \ldots, E_n\}$ é um conjunto de eventos que particionam o espaço amostral Ω com $\mathbb{P}(E_i) > 0$ para todo $i \geqslant 1$, então vale

$$\mathbb{P}(A) = \sum_{i=1}^{n} \mathbb{P}(A \cap E_i) = \sum_{i=1}^{n} \mathbb{P}(A \mid E_i)\mathbb{P}(E_i) \tag{1.12}$$

para qualquer evento A. Deixamos a prova por conta do leitor do resultado abaixo considerando partições enumeráveis.

Teorema 1.2: Lei da probabilidade total

Seja $\{ E_i : \quad i \geqslant 1 \}$ uma partição (enumerável) do espaço amostral Ω com $\mathbb{P}(E_i) > 0$ para todo i. Então

$$\mathbb{P}(A) = \sum_{i=1}^{\infty} \mathbb{P}(A \cap E_i) = \sum_{i=1}^{\infty} \mathbb{P}(A \mid E_i)\, \mathbb{P}(E_i) \tag{1.13}$$

para qualquer evento A.

Demonstração. Os conjuntos $A \cap E_i$ são disjuntos dois a dois e da união deles resulta A, logo a primeira igualdade em (1.13) segue de $\mathbb{P}$ ser medida de probabilidade. A segunda igualdade segue de $\mathbb{P}(A \cap E_i) = \mathbb{P}(A \mid E_i)\mathbb{P}(E_i)$ para todo i. □

Exemplo 1.2

As seguradoras de automóveis classificam motoristas em *mais propensos a acidentes* e *menos propensos a acidentes*. Com isso estimam que os mais propensos são 30% da população e que esses se envolvem em acidente no período de um ano com probabilidade 0,4, enquanto que os menos propensos a acidentes se envolvem em acidente no período de um ano com probabilidade 0,2. Denotemos por A^+ o evento definido pelos motoristas mais propensos a acidentes. Então a probabilidade de um novo segurado se envolver em acidente em um ano é

$$\begin{aligned} \mathbb{P}(A_1) &= \mathbb{P}(A_1 \mid A^+)\, \mathbb{P}\left(A^+\right) + \mathbb{P}(A_1 \mid \overline{A^+})\, \mathbb{P}(\overline{A^+}) \\ &= 0{,}4 \cdot 0{,}3 + 0{,}2 \cdot 0{,}7 = 0{,}26 \end{aligned}$$

e se um novo segurado se envolve em acidente nesse prazo, a probabilidade dele ser propenso a acidentes é

$$\begin{aligned} \mathbb{P}(A^+ \mid A_1) &= \frac{\mathbb{P}(A_1 \cap A^+)}{\mathbb{P}(A_1)} = \frac{\mathbb{P}(A_1 \mid A^+)\, \mathbb{P}(A^+)}{\mathbb{P}(A_1)} \\ &= \frac{0{,}4 \cdot 0{,}3}{0{,}26} = \frac{6}{13}. \end{aligned}$$

Portanto, a probabilidade de ser propenso a acidente dado que se envolve em acidente em um ano é 0,46, aproximadamente. Dado que o motorista não se envolve em acidente em um ano, a probabilidade de ser propenso a acidente é $\mathbb{P}(A^+ \mid \overline{A_1}) \approx 0{,}24$.(Ross, 2010)

1.3.1 *Independência de eventos*

Se um dado é lançado duas vezes, então temos

$$\mathbb{P}\left[\text{ a soma é } 7 \;\middle|\; \text{o primeiro resultado é } 4\ \right] = \frac{1}{6} = \mathbb{P}[\text{ a soma é } 7\,]$$

entretanto

$$\mathbb{P}\left[\text{ a soma é } 12 \;\middle|\; \text{o primeiro resultado é } 4\ \right] = 0 \neq \mathbb{P}[\text{ a soma é } 12\,].$$

O condicionamento de ocorrência de um evento A à ocorrência de B pode afetar ou não a probabilidade de ocorrência de A.

Definição 1.1: Independência

Definimos que o evento A é independente do evento B se

$$\mathbb{P}(A \cap B) = \mathbb{P}(A)\,\mathbb{P}(B)$$

Notemos que se A é independente de B então B é independente de A de modo que dizemos A e B são ***eventos independentes***.

É imediato da Definição 1.1 o seguinte fato.

Proposição 1.2

Todo evento A de um modelo probabilístico é independente do evento certo Ω e do evento impossível $\varnothing$. □

Se os eventos têm probabilidade não nula então decorre da definição acima que a independência de A e B equivale a

$$\mathbb{P}(\,A \mid B\,) = \mathbb{P}(A) \quad \text{e} \quad \mathbb{P}(\,B \mid A\,) = \mathbb{P}(B).$$

Por exemplo, de

$$\mathbb{P}\left[\text{ a soma é } 7 \;\middle|\; \text{o primeiro resultado é } 4\ \right] = \mathbb{P}[\text{ a soma é } 7\,]$$

temos que "a soma é 7" é um evento independente de "o primeiro resultado é 4" se o experimento é lançar um dado duas vezes.

Exemplo 1.3: 2 lançamentos de uma moeda

Considere

$$\Omega = \{\,\mathrm{CaCa}, \mathrm{CaCo}, \mathrm{CoCa}, \mathrm{CoCo}\,\},$$

onde todos os resultados têm probabilidade 1/4.
Considere os eventos

$$A = [\text{o primeiro lançamento é cara}] = \{\,\mathrm{CaCa}, \mathrm{CaCo}\,\},$$

B=[os dois lançamentos são iguais]=[CaCa, CoCo].

Intuitivamente, pode parecer que os eventos são dependentes. De fato, saber que os dois lançamentos são iguais restringe os resultados possíveis a $\{\,\mathrm{CaCa}, \mathrm{CoCo}\,\}$. Assim, parece que essa informação deveria afetar a probabilidade de o primeiro lançamento ser cara. Entretanto,

$$\mathbb{P}(A)=\frac{1}{2} \qquad \text{e} \qquad \mathbb{P}(B)=\frac{1}{2}.$$

Além disso, $A \cap B = \{\,\mathrm{CaCa}\,\}$, de modo que

$$\mathbb{P}(A \cap B)=\frac{1}{4}.$$

Portanto, $\mathbb{P}(A \cap B)=\mathbb{P}(A)\mathbb{P}(B)$. Logo, A e B são independentes.
Equivalentemente,

$$\mathbb{P}(A \mid B)=\frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)}=\frac{1/4}{1/2}=\frac{1}{2}=\mathbb{P}(A).$$

Assim, embora a ocorrência de B elimine metade dos resultados possíveis, ela não altera a probabilidade de A. Esse exemplo ilustra que a independência não significa que dois eventos não tenham qualquer relação ou que a ocorrência de um não forneça nenhuma informação sobre o experimento. O que importa é se a ocorrência de um evento altera ou não a probabilidade do outro. Embora saber que os dois lançamentos são iguais forneça informação sobre os resultados possíveis, essa informação não altera a probabilidade de o primeiro lançamento ser cara.

Uma família enumerável de eventos $\mathcal{E} = \{\,E_n : n \in I\,\}$ é dita ***mutuamente independente*** se para todo subconjunto finito $J \subseteq I$ vale que

$$\mathbb{P}\left(\bigcap_{\ell \in J} E_\ell\right) = \prod_{\ell \in J} \mathbb{P}(E_\ell). \tag{1.14}$$

Para $k \geqslant 2$ fixo, dizemos que a coleção $\mathcal{E}$ é ***k-a-k independente*** se todo subconjunto de índices $J \subseteq I$ com $|J| \leqslant k$ define uma subcoleção de eventos mutuamente independentes.

1.3.2 *Teste de identidade polinomial*

Nosso primeiro exemplo de um algoritmo aleatorizado é um teste de identidade entre polinômios: dados dois polinômios p e q sobre x,

decidir de modo eficiente se eles são idênticos.

Há muitas questões a serem esclarecidas nessa formulação do problema: o que significam "eficiente", "dado um polinômio" e "idênticos"? Por ora, deixemos de lado tais questões e vamos ver como decidir, se dado um polinômio f por uma "caixa preta", da qual a função polinomial $p(x)$ pode ser avaliada em qualquer número x, o polinômio dado f é identicamente nulo. Um algoritmo que resolve esse problema também resolve o problema original, basta tomarmos $f(x) = p(x) - q(x)$.

Fato 1. Esse problema aparentemente simples pode ser generalizado para polinômios em várias variáveis. Um algoritmo determinístico eficiente para o caso multivariado tem consequências profundas em Teoria da Computação, especificamente, em Complexidade Computacional.

Um algoritmo para esse problema funciona do seguinte modo: dado $f(x)$ de grau no máximo d, escolhemos aleatoriamente $a \in \{1, 2, \ldots, 4d\}$ e avaliamos $f(a)$; se $f(a) = 0$, então respondemos *sim*, caso contrário respondemos *não*. A resposta *sim* significa que $f(x)$ é o polinômio nulo e a resposta *não* significa que $f(x)$ não é o polinômio nulo. Esse algoritmo pode responder errado dependendo de f e da escolha aleatória a e devemos tentar garantir que a probabilidade de ocorrer o erro seja pequena.

Se o polinômio f é nulo então a resposta está sempre certa. Suponhamos que f não é nulo. Nesse caso, se a escolha aleatória a for uma raiz do polinômio então $f(a) = 0$ e a resposta *sim* dada pelo algoritmo está errada e se a escolha aleatória a não for uma raiz do polinômio então $f(a) \neq 0$ e a resposta a resposta *sim* dada pelo algoritmo está correta. Em resumo, uma resposta *não* dada pelo algoritmo está correta e uma resposta *sim* pode estar errada. O algoritmo descrito abaixo resume essa estratégia.

Algoritmo 1.1: Teste de identidade entre polinômios

Instância: d inteiro positivo e f polinômio de grau no máximo d.
Resposta: *não* se f não é nulo, senão *sim* com probabilidade de erro no máximo 1/4.

1 $a \xleftarrow{R} \{1, 2, \ldots, 4d\}$;
2 **se** $f(a)=0$ **então responda** *sim*.
3 **senão responda** *não*.

Para determinar um limitante para a probabilidade do algoritmo responder errado, seja f um polinômio não nulo e de grau no máximo

d e consideremos o evento E formado pelas raízes de f que pertencem ao espaço amostral $\Omega = \{1, 2, \ldots, 4d\}$. Então $|E| \leqslant \text{grau}(f) \leqslant d$ pois f tem no máximo grau(f) raízes distintas pelo teorema fundamental da álgebra. O algoritmo erra se a escolha aleatória resulta num elemento de E, portanto,

$$\mathbb{P}[\text{ erro }] \leqslant \frac{1}{4}.$$

Podemos fazer essa probabilidade arbitrariamente pequena ao custo de mais computação. Intuitivamente, como no caso dos lançamentos de moedas, imagine tal algoritmo sendo executado k vezes com a mesma entrada.

Basta uma rodada responder *não* para que a resposta definitiva seja *não*. Se todas as rodadas respondem *sim*, qual a probabilidade de todas estarem erradas?

$$\mathbb{P}\left[\text{ erro em } k \text{ rodadas independentes }\right] \leqslant \left(\frac{1}{4}\right)^k.$$

Se $k = 10$ a probabilidade de erro é a probabilidade de 10 respostas *sim*, ou seja, no máximo $(1/4)^{10} < 10^{-6}$ (em metros é menos que o diâmetro do fio da teia de uma aranha), valor desprezível na prática.

Ideia importante

Assumimos que os sorteios realizados durante a execução de um algoritmo são independentes. Além disso, sorteios realizados em diferentes execuções do mesmo algoritmo são independentes entre si.

Algoritmos Monte Carlo Algoritmos aleatorizados com tempo de execução que depende somente da entrada e não dos sorteios e que podem responder errado, são conhecidos na literatura como algoritmos ***Monte Carlo***. O teste de identidade polinomial é um algoritmo que pode errar, no entanto, somos capazes de delimitar a probabilidade de tal solução incorreta ocorrer.

Observamos uma propriedade útil de um algoritmo Monte Carlo: se o algoritmo for executado repetidamente com escolhas aleatórias independentes a cada vez, a probabilidade de falha pode se tornar arbitrariamente pequena, às custas do tempo de execução.

Observação 1 (*erros de hardware*). Para um base de comparação, sem a intenção de ser rigoroso, *hardware* apresentam falhas no processamento, transmissão e armazenamento de informação.Estudos da IBM realizados na década de 1990 indicaram que os efeitos de radiação cósmica podem produzir soft errors em memórias semicondutoras. Uma estimativa frequentemente associada aos estudos da IBM é de

T. J. O'Gorman et. al. (1996). *Field testing for cosmic ray soft errors in semiconductor memories*. IBM J. Res. Dev., 40(1):41–50.

aproximadamente um erro induzido por raios cósmicos para cada 256 MB de memória por mês. Essa taxa corresponde, aproximadamente, a $\approx 1{,}4 \times 10^{-15}$ por byte-segundo.

Schroeder, Pinheiro e Weber (2009), em um estudo de larga escala realizado em uma grande frota de servidores do Google, analisaram erros de DRAM durante aproximadamente 2,5 anos. Os autores encontraram taxas de erro muito superiores às previstas por estudos laboratoriais anteriores, da ordem de 25.000 a 70.000 erros por bilhão de horas de dispositivo por Mbit, além de observarem que os erros registrados eram predominantemente associados a falhas permanentes (*hard errors*), e não a *soft errors* causados por radiação[1].

Bianca Schroeder et. al. (2009). *DRAM errors in the wild: A large-scale field study*. Proceedings of the Eleventh International Joint Conference on Measurement and Modeling of Computer Systems, SIGMETRICS '09, pages 193–204.

[1] Assim, esses resultados não devem ser interpretados diretamente como uma taxa de erros induzidos por raios cósmicos.

Como ilustração da grande variabilidade das taxas de erro reportadas na literatura, taxas de 120 a 81.000 FIT por Mbit foram posteriormente compiladas em trabalhos sobre confiabilidade de hardware. Como 1 FIT corresponde a uma falha por 10^9 horas, essas taxas correspondem aproximadamente a um erro a cada 950 anos e a cada 1,4 anos, respectivamente, para cada Mbit de memória. Para uma máquina com 4 GiB de DRAM, essas taxas corresponderiam, respectivamente, a aproximadamente 3 e 2.000 erros por mês, supondo uma taxa constante e proporcional à quantidade de memória.

Nightingale et al. (2011), em um estudo da Microsoft envolvendo aproximadamente 950.000 computadores, encontraram uma probabilidade de aproximadamente 1/2700 de uma primeira falha classificada como DRAM one-bit flip entre as máquinas com pelo menos cinco dias de tempo acumulado de CPU (TACT). Para máquinas com pelo menos 30 dias de TACT, essa probabilidade era de aproximadamente 1/1700. Esses valores representam probabilidades de falha observada no sistema, e não uma taxa de erro por bit ou por unidade de tempo.

Edmund B. Nightingale et. al. (2011). *Cycles, cells and platters: An empirical analysisof hardware failures on a million consumer PCs*. Proceedings of the Sixth Conference on Computer Systems, EuroSys '11, pages 343–356.

Amplificação

Para ***problemas de decisão*** — problemas computacionais para os quais a resposta para uma instância é "sim" ou "não"), — existem dois tipos de algoritmos Monte Carlo:

- com ***erro unilateral*** (*one-sided error*), se a probabilidade de errar for zero para pelo menos uma das respostas possíveis;
- com ***erro bilateral*** (*two-sided error*), se houver uma probabilidade não nula de ele errar tanto quando responde "sim" quanto quando responde "não".

Para algoritmos Monte Carlo de erro unilateral, com probabilidade de erro $\leqslant \varepsilon$, para $\varepsilon \in (0,1)$, podemos usar a estratégia de repetições independentes para atingir um limiar $\delta \in (0,1)$ para a probabilidade de erro.

Se A é um algoritmo Monte Carlo que erra apenas nas respostas "sim", então em t rodadas do algoritmo com a mesma entrada o erro só se dá *se todas as t respostas forem* "sim". A probabilidade de erro será no máximo δ para todo t tal que $\varepsilon^t \leqslant \delta$, portanto, para todo

$$t \geqslant \frac{\ln(1/\delta)}{\ln(1/\varepsilon)}.$$

Para A que erra apenas nas respostas "não" o resultado é análogo.

Proposição 1.3: Amplificação unilateral

Dados um limiar $\delta \in (0,1)$ e um algoritmo Monte Carlo A de erro unilateral limitado por ε, com $\lceil \ln(1/\delta)/\ln(1/\varepsilon) \rceil$ ou mais repetições de A temos um algoritmo Monte Carlo de erro (unilateral) no máximo δ. □

Assim, dado conhecido um algoritmo probabilístico A de erro unilateral ε, com $O(\ln(1/\delta))$ repetições baixamos o erro para $< \delta$.

No caso de erro bilateral nenhuma das duas respostas é definitiva, a estratégia é repetir o algoritmo t vezes e devolver a resposta de maior ocorrência.

Proposição 1.4: Amplificação bilateral

Seja $\varepsilon < 1/2$ fixo. Dados um limiar $\delta \in (0,1)$ e um algoritmo Monte Carlo A de erro bilateral no máximo ε, um número $O(\ln(1/\delta))$ de repetições independentes de A fornece um algoritmo Monte Carlo de erro bilateral no máximo δ. A constante implícita depende de ε.

Demonstração. Se $\varepsilon = 0$, o próprio A já tem erro $0 \leqslant \delta$ e nada há a fazer. Suponha, então, $0 < \varepsilon < \frac{1}{2}$.

O algoritmo amplificado executa A independentemente $t = 2k+1$ vezes e retorna a resposta majoritária, que é bem definida por ser t ímpar. Ao final da prova escolhemos k em função de δ e de ε.

Seja S o número dessas t execuções que produzem a resposta correta. Cada execução está correta com probabilidade $p \geqslant 1-\varepsilon > \frac{1}{2}$, independentemente das demais, de modo que

$$\mathbb{P}[\, X = i \,] = \binom{t}{i} p^i (1-p)^{t-i}$$

que é não crescente em p, e portanto basta tratar o pior caso $p = 1-\varepsilon$; suporemos isso daqui em diante. Escrevendo

$$p = 1-\varepsilon = \frac{1}{2} + q, \qquad \text{onde } q := \frac{1}{2} - \varepsilon \in \left(0, \tfrac{1}{2}\right),$$

temos $1 - p = \frac{1}{2} - q = \varepsilon$ e

$$\mathbb{P}[\, S = i \,] = \binom{2k+1}{i} \left(\frac{1}{2} + q\right)^{i} \left(\frac{1}{2} - q\right)^{2k+1-i}.$$

Como t é ímpar, não há empates: o algoritmo amplificado erra exatamente quando a resposta correta é minoritária, isto é, quando $S \leqslant k$. Sua probabilidade de erro é, pois,

$$\mathbb{P}[\, S \leqslant k \,] = \sum_{i=0}^{k} \binom{2k+1}{i} \left(\frac{1}{2} + q\right)^{i} \left(\frac{1}{2} - q\right)^{2k+1-i}.$$

Estimamos os dois fatores separadamente. Para $i \leqslant k$ vale $2k + 1 - i \geqslant k + 1$ e, como $\frac{1}{2} + q > \frac{1}{2} - q$, trocar um fator $\left(\frac{1}{2} - q\right)$ por $\left(\frac{1}{2} + q\right)$ só pode aumentar o produto; aplicando essa troca $k - i$ vezes,

$$\left(\frac{1}{2} + q\right)^{i} \left(\frac{1}{2} - q\right)^{2k+1-i} \leqslant \left(\frac{1}{2} + q\right)^{k} \left(\frac{1}{2} - q\right)^{k+1}.$$

Quanto aos coeficientes binomiais, a identidade

$$\binom{2k+1}{i} = \binom{2k+1}{2k+1-i}$$

estabelece uma bijeção entre os índices $0, \ldots, k$ e os índices $k+1, \ldots, 2k+1$ que preserva o valor do coeficiente. Como esses dois conjuntos particionam $\{\, 0, 1, \ldots, 2k+1 \,\}$, cada um deles responde por metade da soma total, e o Teorema Binomial dá

$$\sum_{i=0}^{k} \binom{2k+1}{i} = \frac{1}{2} \sum_{i=0}^{2k+1} \binom{2k+1}{i} = \frac{2^{2k+1}}{2} = 2^{2k}.$$

Combinando as duas estimativas e usando $\frac{1}{2} - q = \varepsilon$,

$$\mathbb{P}[\, S \leqslant k \,] \leqslant 2^{2k} \left(\frac{1}{2} + q\right)^{k} \left(\frac{1}{2} - q\right)^{k+1} = \varepsilon \left[4 \left(\frac{1}{2} + q\right)\left(\frac{1}{2} - q\right)\right]^{k} = \varepsilon \left(1 - 4q^2\right)^{k} \leqslant \left(1 - 4q^2\right)^{k}.$$

Escreva

$$\alpha := 1 - 4q^2 = 1 - 4\left(\frac{1}{2} - \varepsilon\right)^{2}.$$

De $0 < q < \frac{1}{2}$ segue $0 < \alpha < 1$, e o que provamos é que a probabilidade de o algoritmo amplificado produzir uma resposta incorreta é no máximo $\alpha^k = \alpha^{(t-1)/2}$. Essa cota é no máximo δ sempre que

$$k \geqslant \frac{\ln(1/\delta)}{\ln(1/\alpha)},$$

de modo que basta tomar

$$k = \left\lceil \frac{\ln(1/\delta)}{\ln(1/\alpha)} \right\rceil, \qquad t = 2k + 1.$$

Sendo ε fixo, $\ln(1/\alpha)$ é uma constante positiva e, consequentemente, $t = O(\ln(1/\delta))$. □

Uma abordagem alternativa é dada na Seção 4.6.

1.3.3 *Continuidade de uma medida de probabilidade*

Uma sequência qualquer $(A_n : n \geqslant 1)$ de eventos em um espaço de probabilidade $(\Omega, \mathcal{E}, \mathbb{P})$ é dita ***monótona*** se vale um dos casos

crescente: $A_1 \subseteq A_2 \subseteq \cdots \subseteq A_n \subseteq A_{n+1} \subseteq \cdots$ e definimos

$$\lim_{n\to\infty} A_n := \bigcup_{n=1}^{\infty} A_n.$$

decrescente: $A_1 \supseteq A_2 \supseteq \cdots \supseteq A_n \supseteq A_{n+1} \supseteq \cdots$ e definimos

$$\lim_{n\to\infty} A_n := \bigcap_{n=1}^{\infty} A_n.$$

Se $(A_n : n \geqslant 1)$ é uma sequência crescente, então o limite pode ser escrito como uma união de eventos disjuntos $A_1 \cup (A_2 \setminus A_1) \cup (A_3 \setminus A_2) \cup \cdots$ de modo que se tomamos $A_0 := \varnothing$ então

$$\mathbb{P}\Big(\lim_{n\to\infty} A_n\Big) = \lim_{n\to\infty} \sum_{i=1}^{n} \mathbb{P}(A_i \setminus A_{i-1}) = \lim_{n\to\infty} \sum_{i=1}^{n} (\mathbb{P}(A_i) - \mathbb{P}(A_{i-1})) = \lim_{n\to\infty} \mathbb{P}(A_n).$$

No caso em que $(A_n : n \geqslant 1)$ é decrescente tomamos os complementos e temos que $(\overline{A_n} : n \geqslant 1)$ é crescente, portanto,

$$\mathbb{P}\Big(\lim_{n\to\infty} \overline{A_n}\Big) = \mathbb{P}\left(\bigcup_{n=1}^{\infty} \overline{A_n}\right) = \mathbb{P}\left(\overline{\bigcap_{n=1}^{\infty} A_n}\right) = \mathbb{P}\Big(\overline{\lim_{n\to\infty} A_n}\Big) = 1 - \mathbb{P}\Big(\lim_{n\to\infty} A_n\Big)$$

por outro lado

$$\mathbb{P}\Big(\lim_{n\to\infty} \overline{A_n}\Big) = \lim_{n\to\infty} \mathbb{P}\Big(\overline{A_n}\Big) = \lim_{n\to\infty} (1 - \mathbb{P}(A_n)) = 1 - \lim_{n\to\infty} \mathbb{P}(A_n)$$

portanto

$$\lim_{n\to\infty} \mathbb{P}(A_n) = \mathbb{P}\Big(\lim_{n\to\infty} A_n\Big).$$

Em resumo, se $(A_n : n \geqslant 1)$, é uma sequência monótona de eventos então

$$\mathbb{P}\Big(\lim_{n\to\infty} A_n\Big) = \lim_{n\to\infty} \mathbb{P}(A_n). \tag{1.15}$$

A propriedade (1.15) é chamada de ***continuidade da medida de probabilidade***.

Consideremos novamente o exemplo do lançamento de uma moeda equilibrada até sair coroa

$$\Omega = \{\,(\mathrm{Co}), (\mathrm{Ca}, \mathrm{Co}), \ldots, (\mathrm{Ca}, \mathrm{Ca}, \ldots)\,\}$$

munido da função massa de probabilidade $p((c_1, c_2, \ldots, c_n)) = 2^{-n}$ para a sequência que termina em coroa após n lançamentos.

Definimos o evento A_n definido por "não sai coroa até o n-ésimo lançamento". Esse evento ocorre com probabilidade

$$1 - \mathbb{P}(\overline{A_n}) = 1 - \sum_{i=1}^{n} \left(\frac{1}{2}\right)^i = 1 - \frac{1/2 - (1/2)^{n+1}}{1/2} = \left(\frac{1}{2}\right)^n.$$

Intuitivamente, "nunca sair coroa" tem probabilidade $\lim_{n\to\infty} 2^{-n} = 0$. Essa passagem ao limite, $\mathbb{P}(\lim_{n\to\infty} A_n) = \lim_{n\to\infty} \mathbb{P}(A_n)$, é garantida pela continuidade.

A sequência $(A_n : n \geqslant 1)$ é monótona pois $A_n \supseteq A_{n-1}$ para todo $n > 1$, portanto,

$$\mathbb{P}((\mathrm{Ca}, \mathrm{Ca}, \ldots)) = \mathbb{P}\left(\lim_{n\to\infty} A_n\right) = \lim_{n\to\infty} \mathbb{P}(A_n) = 0.$$

Ideia importante

A interpretação correta desse fato é que "sair cara para sempre" é um resultado possível, mas tem probabilidade zero. Isso porque, nesse caso, o espaço amostral não é discreto: o resultado $(\mathrm{Ca}, \mathrm{Ca}, \ldots)$ é um elemento do espaço amostral, mas o conjunto que contém apenas esse resultado tem probabilidade zero. Em contraste, *se o espaço amostral é discreto e todo resultado elementar tem probabilidade positiva*, então

$$\mathbb{P}(A) = 0 \Rightarrow A = \varnothing.$$

De fato, se $A \neq \varnothing$, existe algum resultado elementar $\omega \in A$ e, pela monotonicidade da probabilidade, $\mathbb{P}(A) \geqslant \mathbb{P}(\omega) > 0$. *Nesse contexto, portanto, um evento de probabilidade zero é necessariamente impossível.*

1.4 Um gerador de números aleatórios

Dada uma fonte que gera bits aleatórios de modo uniforme e independente, como projetar um algoritmo que recebe um inteiro positivo M e devolve uma escolha aleatória em $\{0, 1, \ldots, M-1\}$?

Se M é uma potência de 2, digamos que $M = 2^k$, então a resposta é simples: basta sortearmos $k = \log M$ bits aleatórios $d_0, d_1, \ldots d_{k-1} \in \{0, 1\}$ que o resultado é o número $\sum_{i=0}^{k-1} d_i 2^i$ no domínio desejado com probabilidade $1/M$.

No caso em que M não é potência de 2, digamos que $2^{k-1} < M < 2^k$ (o que significa que precisamos de $k = \lceil \log M \rceil$ bits aleatórios), usamos o mesmo processo descrito no parágrafo anterior com a exceção de que se o resultado for maior ou igual a M, o processo é reiniciado e é repetido até que um número entre 0 e $M-1$ seja obtido.

Algoritmo 1.2: Gerador de números aleatórios

Instância: inteiro positivo $M \geqslant 2$.
Resposta: uma escolha uniforme em $\{0, 1, \ldots, M-1\}$.

```
1 repita
2     para cada i ∈ {0, ..., ⌈log M⌉ − 1} faça d_i ←R {0,1};
3     N ← Σ_i d_i 2^i;
4 até que N < M;
5 responda N.
```

O resultado das escolhas aleatórias na linha 2 do Algoritmo 1.2, digamos que seja a sequência $d_{k-1}d_{k-2}\ldots d_0$, é um evento que tem probabilidade $\mathbb{P}^{(k)}(d_{k-1}d_{k-2}\ldots d_0) = (1/2)^k$.

Essa sequência é a representação binária do número $\sum_{i=0}^{k-1} d_i 2^i$ que pertence ao conjunto $\{0, 1, \ldots, 2^k - 1\}$.

O ALGORITMO TERMINA?

Isto é, eventualmente a condição $N < M$ na linha 4 é satisfeita?

Fixamos uma instância M com

$$2^{k-1} < M \leqslant 2^k \quad \text{e} \quad k = \lceil \log M \rceil.$$

A probabilidade com que uma rodada do laço da linha 1 resulte em um inteiro N que pertença ao conjunto $\overline{A} = \{M, \ldots, 2^k - 1\}$ é

$$\mathbb{P}(\overline{A}) = \frac{2^k - M}{2^k} = 1 - \frac{M}{2^k} < 1 - \frac{2^{k-1}}{2^k} = \frac{1}{2},$$

pois $M > 2^{k-1}$.

Para todo $n \geqslant 1$,

A_n é o evento "o algoritmo leva mais que n rodadas para terminar".

Tal evento ocorre se nas n primeiras tentativas do laço na linha 1 ocorre um sorteio em $\overline{A}$ e daí pra diante pode ocorrer qualquer um dos dois casos, A ou $\overline{A}$, logo, pela independência da ocorrência dos eventos $\overline{A}$ em cada rodada do laço

$$\mathbb{P}(A_n) = \left(1 - \frac{M}{2^k}\right)^n$$

portanto,

$$\mathbb{P}(A_n) < \left(\frac{1}{2}\right)^n.$$

Os eventos A_n formam uma sequência decrescente $A_n \supset A_{n+1}$ e $\lim_{n\to\infty} A_n = \bigcap_{n\geqslant 1} A_n$ é o evento "o algoritmo não termina", cuja

probabilidade é, por continuidade (equação (1.15) na página 23),

$$\begin{aligned}\mathbb{P}\big[\text{ o algoritmo não termina }\big] &= \mathbb{P}\left(\bigcap_{n\geqslant 1} A_n\right)\\ &= \lim_{n\to\infty} \mathbb{P}(\,A_n\,)\\ &= \lim_{n\to\infty} \left(1-\frac{M}{2^k}\right)^n\\ &= 0.\end{aligned} \tag{1.16}$$

Consequentemente, $\mathbb{P}\big[\text{ o algoritmo termina }\big] = 1$. O algoritmo termina *quase certamente*.

SE TERMINA, QUÃO RÁPIDO TERMINA?

A aleatoriedade influencia na duração das rodadas, isto é, no número de rodadas do laço da linha 1 necessárias para que ele termine.

O algoritmo não apenas termina quase certamente, como, de fato, termina em poucas rodadas com alta probabilidade. De $M > 2^{k-1}$ temos $\mathbb{P}(\overline{A}\,) < 1/2$, portanto, em n rodadas do laço todos os inteiros sorteados pertencem a $\overline{A}$ com probabilidade menor que 2^{-n}. A probabilidade de não terminar em, por exemplo, 4 rodadas é menor que 0,07, em 10 rodadas é menor que 0,00098.

SE O ALGORITMO TERMINA, RESPONDE CERTO?

Por exemplo, se $M = 7$ então $k = 3$. Com três bits $d_2d_1d_0$ temos as representações binárias dos naturais de 0 a 7. O laço da linha 1 gera qualquer um desses números com a mesma probabilidade, a saber $1/2^3 = 1/8$. Porém o algoritmo só termina se o sorteio for diferente de 7, isto é, não ocorre o evento $d_2d_1d_0 = 111$. Dado que esse evento não ocorre, qual a probabilidade do algoritmo responder 4?

Seja N a resposta do algoritmo. Usando probabilidade condicional $\mathbb{P}[\ N = 4 \mid N \neq 7\ ] = (1/8)\,/\,(7/8) = 1/7$ e, de fato, o algoritmo escolhe qualquer número em $\{\,0,\ldots,6\,\}$ com probabilidade $1/7$.

No caso geral, definimos o evento $A = \{\,0,1,\ldots,M-1\,\}$ e para qualquer $t \in A$ a probabilidade da resposta N do algoritmo ser t dado que $N \in A$ é

$$\mathop{\mathbb{P}}_{N\in_{\mathrm{R}}\{0,\ldots,2^k-1\}}[\ N = t \mid N \in A\ ] = \frac{\mathbb{P}(\,\{\,t\,\}\cap A\,)}{\mathbb{P}(\,A\,)} = \frac{(1/2)^k}{M/2^k} = \frac{1}{M}.$$

Portanto, se o algoritmo termina, ou seja, dado que o sorteio N satisfaça $N < M$, então ele responde com um número entre 0 e $M-1$ de modo uniforme.

Diferente do algoritmo para identidade polinomial, o Algoritmo 1.2 não responde errado. Em contrapartida, o tempo de execução depende dos sorteios.

Algoritmos Las Vegas O algoritmo gerador de números aleatórios sempre fornece a solução correta. A única variação de uma execução para outra é o seu tempo de execução. Chamamos esse tipo de algoritmo de ***algoritmo Las Vegas***. Um algoritmo Las Vegas é, por definição, um algoritmo Monte Carlo com probabilidade de erro igual a 0 cujo tempo de execução é uma variável aleatória (nosso próximo tema). Em geral, deseja-se que esses algoritmos tenham tempo de execução esperado pequeno e que a probabilidade de uma execução demorar muito seja pequena.

Dizemos que um algoritmo Las Vegas é um algoritmo ***Las Vegas eficiente*** se, para qualquer entrada, seu *tempo de execução esperado*[2] for delimitado por uma função polinomial do tamanho da entrada.

[2] A esperança da variável aleatória para o tempo de execução

Dizemos que um algoritmo Monte Carlo é um algoritmo ***Monte Carlo eficiente*** se, para qualquer entrada, seu tempo de execução no pior caso for delimitado por uma função polinomial do tamanho da entrada.

1.5 *Verificação do produto de matrizes, princípio da decisão adiada e desaleatorização*

`na proxima rodada`

1.6 *Exercícios*

Exercício 1. Há três urnas e em cada urna um par de bolas. Na primeira urna há um par de bolas brancas, na segunda um par de bolas pretas e na terceira um par com uma bola de cada cor. Uma urna é escolhida uniformemente e, sem olhar para o interior da urna, uma bola é escolhida uniformemente é retirada. A bola retirada é branca. Qual a probabilidade da bola que ficou sozinha na urna ser preta?

Exercício 2. Considere a seguinte proposta de algoritmo que recebe um inteiro positivo $M > 0$ e devolve um inteiro escolhido aleatoriamente em $\{0, 1, \ldots, M-1\}$:

Instância: inteiro positivo M.

Resposta: uma escolha aleatória em $\{0, 1, \ldots, M-1\}$.

1 seja k o número de bits de M;
2 $(d_0, d_1, \ldots, d_{k-1}) \xleftarrow{R} \{0,1\}^k$;
3 $N \leftarrow \sum_i d_i 2^i$;
4 **responda** N mod M.

Prove que as respostas não são equiprováveis quando M não é potência de 2.

Exercício 3. Agora, considere o seguinte gerador de números aleatórios adaptado do anterior.

Instância: inteiros positivos M e t.

Resposta: uma escolha aleatória em $\{0, 1, \ldots, M-1\}$.

```
1 seja k o número de bits de M;
2 (d_0, d_1, ..., d_{k+t-1}) ←R {0,1}^{k+t};
3 N ← Σ_i d_i 2^i;
4 responda N mod M.
```

No caso $t = 0$ a probabilidade da resposta não é uniforme (como vimos acima). Prove que

$$\sum_{n=0}^{M-1} \left| \mathbb{P}[\, N = n \,] - \frac{1}{M} \right| \leqslant \frac{1}{2^{t-1}}.$$

Isso mostra que, à medida que t cresce, a distribuição de $N \bmod M$ converge exponencialmente rápido para a distribuição uniforme em $\{0, \ldots, M-1\}$, o que justifica usar valores modestos de t (por exemplo $t = O(\log(1/\delta))$) para obter uma amostragem "quase uniforme" com erro estatístico δ arbitrariamente pequeno.

Exercício 4. Prove que no seguinte algoritmo a probabilidade p_n do laço executar pelo menos n vezes, para todo $n \geqslant 2$, é maior que 0 e, mais que isso, essa probabilidade é maior que 0 no limite, ou seja, $\lim p_n > 0$ quando $n \to \infty$ (pode ser útil a desigualdade $1 - x \geqslant \exp(-2x)$ para $x \in [0, 1/2]$).

```
1 j ← 0;
2 repita
3 |   j ← j + 1;
4 |   para cada i ∈ {1, 2, ..., j} faça d_i ←R {0,1};
5 até que d_i = 1 para todo i.
```

2
Variáveis aleatórias discretas

As variáveis aleatórias são funções que descrevem grandezas observáveis em fenômenos aleatórios, como o tempo de execução de um algoritmo aleatorizado, o número de comparações realizadas por um procedimento de busca, ou o tamanho de uma estrutura de dados gerada aleatoriamente. No Algoritmo 1.2, o número de rodadas do laço é uma variável aleatória. Note que execuções diferentes do algoritmo, mesmo que com a entrada M fixa, a quantidade de rodadas do laço pode ser diferente.

Definição 2.1: Variável aleatória discreta

Se $(\Omega, \mathcal{A}, \mathbb{P})$ é um espaço de probabilidade, então uma função

$$X : \Omega \to \mathbb{R}$$

é uma ***variável aleatória discreta*** se sua imagem, que denotamos por $X(\Omega)$, é enumerável.
Em particular, se Ω é enumerável, então qualquer função $X : \Omega \to \mathbb{R}$ é uma ***variável aleatória discreta***.

A definição mais geral para v.a. discreta é: existe um enumerável S tal que $\mathbb{P}[\, X \in S \,] = 1$ Note que isso permite $\omega \in \Omega$ tal que $X(\omega) \notin S$, desde que $\mathbb{P}(\, \omega \,) = 0$. Entretanto, neste texto, não será preciso toda essa generalidade. Quase sempre trabalharemos com Ω enumerável.

Usaremos, quase sempre, as letras maiúsculas finais do alfabeto, como X, Y, Z, W, para denotar variáveis aleatórias.

Exemplo 2.1: Variável aleatória indicadora

Para qualquer evento A de um espaço de probabilidade $(\Omega, \mathcal{A}, \mathbb{P})$, definimos a variável aleatória $\mathbb{1}_A : \Omega \to \{\, 0, 1 \,\}$ por

$$\mathbb{1}_A(\omega) := \begin{cases} 1, & \text{se } \omega \in A \\ 0, & \text{caso contrário,} \end{cases}$$

e que chamamos de ***variável aleatória indicadora*** da ocorrência do evento A.

Proposição 2.1: Variável aleatória como soma de indicadoras

Toda variável aleatória discreta pode ser escrita como uma combinação linear de variáveis indicadoras.

Demonstração. Seja X uma variável aleatória discreta e seja $\{x_1, x_2, \dots\} \subseteq \mathbb{R}$ o conjunto dos valores que X pode assumir. Para cada i, considere a variável aleatória $\mathbb{1}_{A_i}$ indicadora do evento $A_i = [X = x_i]$.

Como X assume, necessariamente, um dos valores x_i, para todo $\omega \in \Omega$, existe um único i tal que $X(\omega) = x_i$. Consequentemente,

$$\sum_{i=1}^{\infty} x_i \mathbb{1}_{A_i}(\omega) = X(\omega).$$

Logo,

$$X = \sum_{i=1}^{\infty} x_i \mathbb{1}_{A_i} = \sum_{i} x_i \mathbb{1}_{[X=x_i]}.$$

No caso em que X assume apenas um número finito de valores, a soma é finita; no caso enumerável, trata-se de uma soma enumerável (série). □

Proposição 2.2

Se X é uma variável aleatória que assume valores nos inteiros positivos, então

$$X = \sum_{k=1}^{\infty} \mathbb{1}_{[X \geqslant k]}. \tag{2.1}$$

Demonstração. Para cada $\omega \in \Omega$, existe um único $m = X(\omega) \in \mathbb{Z}_+$. Então, dado $k \geqslant 1$

$$\mathbb{1}_{[X \geqslant k]}(\omega) = \begin{cases} 1, & \text{se } k \leqslant m, \\ 0, & \text{se } k > m. \end{cases}$$

Logo,

$$\sum_{k=1}^{\infty} \mathbb{1}_{[X \geqslant k]}(\omega) = \underbrace{1 + \cdots + 1}_{m \text{ termos}} = m = X(\omega).$$

Como vale para todo $\omega \in \Omega$, concluímos (2.1) □

2.1 Distribuição

Se X é uma v.a. discreta. Para $a \in X(\Omega)$, $[X = a]$ denota o evento

$$[X = a] := \{\, \omega \in \Omega \colon X(\omega) = a \,\}$$

que ocorre com probabilidade

$$\mathbb{P}_X(a) \coloneqq \mathbb{P}[X = a].$$

A função $a \mapsto \mathbb{P}_X(a)$ é chamada ***lei***, ou ***distribuição***, de X: trata-se de uma medida de probabilidade em $(X(\Omega), 2^{X(\Omega)})$.

Analogamente, $[X \leqslant a]$ denota o evento $\{\omega \in \Omega : X(\omega) \leqslant a\}$.

Para a v.a. indicadora, como no Exemplo 2.1 acima, temos

$$[\mathbb{1}_A \leqslant t] = \begin{cases} \varnothing, & \text{se } t < 0 \\ \overline{A}, & \text{se } 0 \leqslant t < 1 \\ \Omega, & \text{se } t \geqslant 1 \end{cases}$$

Ainda, a notação $[X \in A]$ é usada para o evento dado pela pré-imagem de A, i.e.,

$$[X \in A] = X^{-1}(A) = \{\omega \in \Omega : X(\omega) \in A\},$$

para todo $A \subseteq X(\Omega)$.

Por exemplo, as pré-imagens $\mathbb{1}_A^{-1}(B)$ são $\varnothing$, A, $\overline{A}$ e Ω nos casos, respectivamente, $\{0,1\} \cap B = \varnothing$, $\{0,1\} \cap B = \{1\}$, $\{0,1\} \cap B = \{0\}$ e $\{0,1\} \cap B = \{0,1\}$ para todo $B \subseteq \mathbb{R}$.

Experimentos aleatórios com apenas duas possibilidades de resultado, *sucesso* ou *fracasso*, recebem o nome de ***ensaio de Bernoulli***. Modelamos um ensaio de Bernoulli por uma variável aleatória $X : \Omega \to \mathbb{R}$, com $X(\Omega) \in \{0,1\}$ e 0 representa *fracasso* e 1 representa *sucesso*.

Exemplo 2.2: Distribuição de Bernoulli

Se X é uma variável aleatória com imagem $\{0,1\}$ e lei

$$\mathbb{P}_X(1) = p \quad \text{e} \quad \mathbb{P}_X(0) = 1 - p$$

então dizemos que X tem ***distribuição de Bernoulli*** com parâmetro p, onde $p \in [0,1]$ é a probabilidade de sucesso, e usamos

$$X \sim \text{Bernoulli}(p)$$

para indicar esse fato.

Em n ensaios de Bernoulli idênticos e independentes, uma resposta específica $(b_1, b_2, \ldots, b_n)$ com exatamente $t \in \{0, \ldots, n\}$ sucessos e $n - t$ fracassos ocorre com probabilidade $p^t(1-p)^{n-t}$. A quantidade de sequências de respostas distintas com exatamente t sucessos é $\binom{n}{t}$, assim a probabilidade de exatamente t sucessos é

$$\binom{n}{t} p^t (1-p)^{n-t}.$$

Exemplo 2.3: Distribuição binomial

Se X é a quantidade de sucessos em n ensaios de Bernoulli, idênticos e independentes, então

$$\mathbb{P}_X(t) := \binom{n}{t} p^t (1-p)^{n-t}, \quad t \in \{0, 1, \ldots, n\}$$

chamada ***distribuição binomial*** com parâmetros n e p. Nesse caso, escrevemos

$$X \sim \text{Binomial}(n, p).$$

Se $X_1, \ldots, X_n \sim \text{Bernoulli}(p)$ são variáveis aleatórias mutuamente independentes, então

$$X = \sum_{i=1}^{n} X_i \sim \text{Binomial}(n, p).$$

Exemplo 2.4: Distribuição geométrica

Uma variável geométrica conta o número de realizações de ensaios de Bernoulli independentes e identicamente distribuídos realizados até, e incluindo, o primeiro sucesso.
Se X é uma variável aleatória geométrica, então para $X = t$ é necessário que nas primeiras $t-1$ iterações ocorra fracasso e na t-ésima iteração ocorra sucesso. Como os ensaios são independentes, a lei de X é

$$\mathbb{P}_X(t) := (1-p)^{t-1} p, \quad t \in \{1, 2, \ldots\}$$

e dizemos que X tem ***distribuição geométrica*** com parâmetro p, o que denotamos por $X \sim \text{Geom}(p)$.
Em alguns textos a distribuição geométrica conta o número de fracassos antes do primeiro sucesso. Nesse caso a variável aleatória $Y = X - 1$ assume valores em $\{0, 1, 2, \ldots\}$ e tem distribuição $\mathbb{P}_Y(t) = \mathbb{P}_X(t+1)$.

Independência

As variáveis aleatórias discretas X e Y definidas em Ω são ***independentes*** se para quaisquer $A, B \subset \mathbb{R}$

$$\mathbb{P}([X \in A] \cap [Y \in B]) = \mathbb{P}[X \in A] \cdot \mathbb{P}[Y \in B].$$

Considerando as leis $\mathbb{P}_{(X,Y)}$ do vetor aleatório (X, Y), $\mathbb{P}_X$ de X e $\mathbb{P}_Y$ de Y temos que independência como definido acima é equivalente a

1. $\mathbb{P}_{(X,Y)}(A \times B) = \mathbb{P}_X(A) \cdot \mathbb{P}_Y(B)$;

2. $[X = a]$ e $[Y = b]$ são independentes, para quaisquer $a \in X(\Omega)$ e $b \in Y(\Omega)$;

3. $\mathbb{P}_{(X,Y)}((a,b)) = \mathbb{P}_X(a) \cdot \mathbb{P}_Y(b)$, para quaisquer $a \in X(\Omega)$ e $b \in Y(\Omega)$;

4. $\mathbb{P}([X \leqslant a] \cap [Y \leqslant b]) = \mathbb{P}[X \leqslant a] \cdot \mathbb{P}[Y \leqslant b]$ para quaisquer $a, b \in \mathbb{R}$.

Mais geralmente, as variáveis aleatórias $X_1, X_2, \ldots, X_n$ são ***mutuamente independentes*** se para quaisquer subconjuntos $A_1, \ldots, A_n \subseteq \mathbb{R}$

$$\mathbb{P}\left(\bigcap_{i=1}^{n} [X_i \in A_i]\right) = \mathbb{P}_{\mathbf{X}}(A_1 \times \cdots \times A_n) = \prod_{i=1}^{n} \mathbb{P}_{X_i}(A_i) = \prod_{i=1}^{n} \mathbb{P}[X_i \in A_i].$$

Equivalentemente,

$$\mathbb{P}_{\mathbf{X}}(A_1 \times \cdots \times A_n) = \prod_{i=1}^{n} \mathbb{P}_{X_i}(A_i)$$

em que $\mathbf{X} = (X_1, X_2, \ldots, X_n)$.

2.2 *Valor esperado de uma variável aleatória discreta*

O ***valor esperado*** ou, ainda, ***esperança*** da variável aleatória X é, ingenuamente, a média dos valores que X assume, ponderada pela probabilidade de assumir tais valores.

Uma variável aleatória X é chamada de ***simples*** se pode ser escrita como combinação linear finita de funções indicadoras de eventos, ou seja, existem valores $x_1, \ldots, x_k \in \mathbb{R}$ e eventos $A_1, \ldots, A_k$ tais que

$$X = \sum_{i=1}^{k} x_i \mathbb{1}_{A_i}.$$

Podem existir muitas maneiras de escrever uma variável aleatória simples como combinação linear de indicadoras. Descrevemos a seguir uma ***forma canônica***: sejam $x_1, \ldots, x_m$ os valores ***distintos*** assumidos por X e $B_i = [X = x_i]$. Os B_i são eventos não vazios, disjuntos dois a dois, e formam uma partição de Ω; a ***representação canônica*** é

$$X = \sum_{i=1}^{m} x_i \mathbb{1}_{B_i}.$$

Queremos que a esperança seja linear e que $\mathbb{E}\mathbb{1}_A = \mathbb{P}(A)$. Sobre a representação canônica, isso força a seguinte definição.

Definição 2.2: Esperança de uma variável simples

Se X é uma variável aleatória simples, com valores distintos $x_1, \dots, x_m$ e $B_i = [X = x_i]$, então

$$\mathbb{E}X := \sum_{i=1}^{m} x_i \, \mathbb{P}(B_i) = \sum_{i=1}^{m} x_i \, \mathbb{P}[X = x_i].$$

Vamos verificar que essa definição é compatível com as outras representações de X. É isso que fazem os resultados a seguir. Primeiro tratamos as representações por partições, que é o que precisamos para a linearidade.

Proposição 2.3: Boa definição via refinamento comum

Sejam $\{A_i\}_{i=1}^{n}$ e $\{B_j\}_{j=1}^{m}$ partições finitas de Ω em eventos (possivelmente vazios) e suponha

$$X = \sum_{i=1}^{n} x_i \, \mathbb{1}_{A_i} = \sum_{j=1}^{m} a_j \, \mathbb{1}_{B_j}.$$

Então

$$\sum_{i=1}^{n} x_i \, \mathbb{P}(A_i) = \sum_{j=1}^{m} a_j \, \mathbb{P}(B_j).$$

Demonstração. Seja $C_{ij} = A_i \cap B_j$. Estes conjuntos são disjuntos dois a dois e

$$A_i = \bigdot\bigcup_{j} C_{ij}, \qquad B_j = \bigdot\bigcup_{i} C_{ij},$$

logo, por aditividade finita de $\mathbb{P}$,

$$\mathbb{P}(A_i) = \sum_{j} \mathbb{P}(C_{ij}), \qquad \mathbb{P}(B_j) = \sum_{i} \mathbb{P}(C_{ij}). \tag{2.2}$$

Afirmamos que $x_i \, \mathbb{P}(C_{ij}) = a_j \, \mathbb{P}(C_{ij})$ para todo par (i, j). Se $C_{ij} = \varnothing$, ambos os lados são nulos. Caso contrário, tome $\omega \in C_{ij}$: como as famílias são partições, $\mathbb{1}_{A_k}(\omega) = 1$ apenas para $k = i$ e $\mathbb{1}_{B_l}(\omega) = 1$ apenas para $l = j$, de modo que $x_i = X(\omega) = a_j$. Combinando com (2.2),

$$\sum_{i} x_i \mathbb{P}(A_i) = \sum_{i,j} x_i \mathbb{P}(C_{ij}) = \sum_{i,j} a_j \mathbb{P}(C_{ij}) = \sum_{j} a_j \mathbb{P}(B_j). \qquad \square$$

Corolário 2.1: Qualquer partição calcula $\mathbb{E}X$

Se $X = \sum_{j=1}^{m} a_j \mathbb{1}_{A_j}$ com $\{A_j\}$ partição finita de Ω em eventos, então $\mathbb{E}X = \sum_{j=1}^{m} a_j \, \mathbb{P}(A_j)$.

Demonstração. A representação canônica é uma representação por partição. Aplique a Proposição 2.3 a ela e à representação dada. □

Proposição 2.4: Linearidade

Se X e Y são variáveis aleatórias simples e $a, b \in \mathbb{R}$, então $aX + bY$ é simples e

$$\mathbb{E}(aX + bY) = a\,\mathbb{E}X + b\,\mathbb{E}Y.$$

Demonstração. Sejam $X = \sum_{i=1}^{n} x_i \mathbb{1}_{B_i}$ e $Y = \sum_{j=1}^{m} y_j \mathbb{1}_{C_j}$ as representações canônicas. A família $\{ B_i \cap C_j \}$ é uma partição de Ω em eventos e, para $\omega \in B_i \cap C_j$, $(aX + bY)(\omega) = ax_i + by_j$. Logo

$$aX + bY = \sum_{i=1}^{n} \sum_{j=1}^{m} (ax_i + by_j)\, \mathbb{1}_{B_i \cap C_j},$$

o que mostra que $aX + bY$ é simples. Esta é uma representação por partição de $aX + bY$, talvez não canônica (os valores $ax_i + by_j$ podem se repetir). Pelo Corolário 2.1,

$$\mathbb{E}(aX + bY) = \sum_{i,j} (ax_i + by_j)\, \mathbb{P}\big(B_i \cap C_j\big).$$

Por aditividade finita, $\sum_j \mathbb{P}\big(B_i \cap C_j\big) = \mathbb{P}(B_i)$ e $\sum_i \mathbb{P}\big(B_i \cap C_j\big) = \mathbb{P}\big(C_j\big)$, donde

$$\mathbb{E}(aX + bY) = a \sum_{i=1}^{n} x_i \mathbb{P}(B_i) + b \sum_{j=1}^{m} y_j \mathbb{P}\big(C_j\big) = a\,\mathbb{E}X + b\,\mathbb{E}Y. \qquad \square$$

Corolário 2.2: Linearidade finita

Se $X_1, \ldots, X_n$ são variáveis aleatórias simples e $a_1, \ldots, a_n \in \mathbb{R}$, então $\sum_{i=1}^{n} a_i X_i$ é simples e

$$\mathbb{E}\left(\sum_{i=1}^{n} a_i X_i \right) = \sum_{i=1}^{n} a_i\, \mathbb{E}(X_i).$$

Demonstração. Indução em n: o caso $n = 1$ é trivial, e o passo segue da Proposição 2.4 aplicada a $\sum_{i<n} a_i X_i$ e X_n. □

Corolário 2.3: Indicadoras arbitrárias

Se $A_1, \ldots, A_k$ são eventos quaisquer (não necessariamente disjuntos) e $c_1, \ldots, c_k \in \mathbb{R}$, então

$$\mathbb{E}\left(\sum_{l=1}^{k} c_l\, \mathbb{1}_{A_l} \right) = \sum_{l=1}^{k} c_l\, \mathbb{P}(A_l).$$

Em particular, o valor de $\mathbb{E}X$ não depende de qual representação de X como combinação linear finita de indicadoras é usada.

Demonstração. Como $\mathbb{1}_A = 1 \cdot \mathbb{1}_A + 0 \cdot \mathbb{1}_{\overline{A}}$ é uma representação por partição, o Corolário 2.1 dá $\mathbb{E}\mathbb{1}_A = \mathbb{P}(A)$. O resultado segue do Corolário 2.2. □

Observação 2. Reagrupando a soma da Definição 2.2, e *supondo* Ω *enumerável*, temos

$$\mathbb{E}X = \sum_{i=1}^{m} x_i \, \mathbb{P}(B_i) = \sum_{\omega \in \Omega} X(\omega) \, \mathbb{P}(\omega),$$

a média dos valores de X ponderada pela probabilidade de cada ponto. Em um espaço geral (por exemplo, $[0,1]$ com a medida de Lebesgue) vale $\mathbb{P}(\{\omega\}) = 0$ e a soma sobre Ω não faz sentido; a fórmula correta é $\mathbb{E}X = \sum_x x \, \mathbb{P}(X = x)$.

Exemplo 2.5: Média pode ser pouco representativa

Consideremos um jogo de azar no qual em cada aposta pagamos R$10,00 e, ou ganhamos R$1.000g.010,00 com probabilidade $p \in (0,1)$ ou não ganhamos nada, ou seja, perdemos os R$10,00 que já foram pagos, com probabilidade $1-p$. Se Y é o ganho líquido em uma aposta, então a esperança do ganho por aposta é $\mathbb{E}Y = 10^6 p - 10(1-p) = 1.000.010p - 10$.
Se $p = 1/100$ então a probabilidade de ganhar o valor alto é muito pequeno quando comparado com a probabilidade de perder 10 reais, mas o prêmio é tão grande que o ganho esperado por aposta ainda é positivo: $\mathbb{E}Y = 9.990{,}10$.
Apesar do ganho esperado por aposta ser positivo, a probabilidade de efetivamente ganhar o prêmio é de apenas 1%: em 99% das vezes o jogador simplesmente perde os R$ 10,00 investidos. A esperança, portanto, não descreve o que tipicamente acontece a quem joga, apenas uma média que só se manifestaria após repetições muito numerosas do jogo.

Exemplo 2.6

Se $X \in_R \{1,2,3,4,5,6\}$ é o resultado de um lançamento de um dado, então

$$\mathbb{E}X = 1\frac{1}{6} + 2\frac{1}{6} + 3\frac{1}{6} + 4\frac{1}{6} + 5\frac{1}{6} + 6\frac{1}{6} = \frac{7}{2}$$

e se Y é o resultado de outro lançamento de dado, qual é a es-

perança da soma $X+Y$ dos pontos nos dois lançamentos do dado?

$$\mathbb{E}(X+Y)=\mathbb{E}(X)+\mathbb{E}(Y)=7$$

pela linearidade da esperança é 7.
Assumindo que os lançamentos são independentes, a esperança do produto é

$$\mathbb{E}(X\cdot Y)=\mathbb{E}(X)\cdot\mathbb{E}(Y)=\frac{49}{4}.$$

A distribuição do produto $X\cdot Y$ é mostrada na Tabela 2.1 abaixo.

$X\cdot Y$	1	2	3	4	5	6	8	9	10	12	15	16	18	20	24	25	30	36
$\mathbb{P}_{X\cdot Y}$	$\frac{1}{36}$	$\frac{2}{36}$	$\frac{2}{36}$	$\frac{3}{36}$	$\frac{2}{36}$	$\frac{4}{36}$	$\frac{2}{36}$	$\frac{1}{36}$	$\frac{2}{36}$	$\frac{4}{36}$	$\frac{2}{36}$	$\frac{1}{36}$	$\frac{2}{36}$	$\frac{2}{36}$	$\frac{2}{36}$	$\frac{1}{36}$	$\frac{2}{36}$	$\frac{1}{36}$

Tabela 2.1: distribuição do produto de dois dados.

Exemplo 2.7: Esperança da distribuição de Bernoulli

Se $X\sim\text{Bernoulli}(p)$, então podemos considerar o evento dado por $A=\{\omega\in\Omega\colon X(\omega)=1\}$, de forma que $X=\mathbb{1}_A$. Dessa forma,

$$\mathbb{E}X=\mathbb{P}_X(1)=\mathbb{P}(A)=p.$$

Exemplo 2.8: Esperança da distribuição binomial

Se $X\sim\text{Binomial}(n,p)$, então

$$X=\sum_{i=1}^{n}X_i\sim\text{Binomial}(n,p)$$

com $X_i\sim\text{Bernoulli}(p)$ e, pela linearidade da esperança (Corol. 2.2),

$$\mathbb{E}X=\mathbb{E}\left(\sum_{i=1}^{n}X_i\right)=\sum_{i=1}^{n}\mathbb{E}(X_i)=np.$$

Uma variável aleatória geométrica tem imagem enumerável infinita $\{1,2,\dots\}$ e gostaríamos de estender, de modo natural, a definição de valor esperado de uma variável simples, ou seja, se X tem valores $\{x_1,x_2,\dots\}\subseteq\mathbb{R}$ queremos

$$\mathbb{E}X=\sum_{n\geqslant 1}x_n\,\mathbb{P}[X=x_n]. \tag{2.3}$$

Exemplo 2.9: Rearranjos podem convergir para somas distintas

Desde o século XIX sabe-se que rearranjos da série harmônica alternada

$$\sum_{i=1}^{\infty} \frac{(-1)^{i+1}}{i}$$

podem resultar em limites diferentes. Por exemplo,

$$1-\frac{1}{2}+\frac{1}{3}-\cdots+\frac{(-1)^{n+1}}{n}+\cdots=\ln(2)$$

enquanto que, no rearranjo atribuído a Laurent,

$$1-\frac{1}{2}-\frac{1}{4}+\frac{1}{3}-\frac{1}{6}-\frac{1}{8}+\cdots+\frac{1}{2k-1}-\frac{1}{2(2k-1)}-\frac{1}{4k}+\cdots=\frac{\ln(2)}{2}.$$

Seja X a variável aleatória que assume os valores (distintos)

$$x_i := (-1)^{i+1}\, i, \quad i=1,2,\ldots, \quad \mathbb{P}[\,X=x_i\,]=\frac{6}{(\pi i)^2}.$$

Então $x_i\,\mathbb{P}[\,X=x_i\,]=\frac{6}{\pi^2}\frac{(-1)^{i+1}}{i}$ e, para uma enumeração σ dos valores,

$$\sum_{i=1}^{\infty} x_{\sigma(i)}=\mathbb{P}\left[\,X=x_{\sigma(i)}\,\right] \begin{cases} \frac{6}{\pi^2}\ln(2) & \text{se } \sigma \text{ é a permutação identidade} \\ \frac{3}{\pi^2}\ln(2) & \text{se } \sigma \text{ é a permutação de Laurent} \end{cases}, \quad (2.4)$$

Note que $\sum_i x_i^+\,\mathbb{P}[\,X=x_i\,]=\sum_i x_i^-\,\mathbb{P}[\,X=x_i\,]=\infty$ (os termos de cada sinal são da ordem de $1/i$). Portanto, X não tem um valor esperado bem definido.

Para que (2.3) defina um número real, é necessário que o valor da soma não dependa da ordem dos termos. O índice n não carrega nenhuma ordem imposta pela estrutura do problema: os eventos $\{\,X=x_n\,\}$ formam um conjunto enumerável, não uma sequência canonicamente ordenada (a ordem em que escrevemos $x_1, x_2, \ldots$ é apenas uma escolha arbitrária de enumeração). Assim, para que (2.3) defina uma esperança finita, é necessário que a série seja ***incondicionalmente convergente***, isto é, que qualquer reordenação de seus termos convirja sempre para a mesma soma.

Um teorema atribuído a Riemann (veja em Rudin, 1976, teorema 3.54) estabelece que, se $\sum_n a_n$ converge e $\sum_{i\geqslant 1}|a_i| = \infty$, então, para qualquer $S \in \mathbb{R} \cup \{-\infty, +\infty\}$, existe uma permutação σ dos inteiros positivos tal que $\sum_{i\geqslant 1} a_{\sigma(i)} = S$. Se a série nem converge na ordem original, também não é incondicionalmente convergente. Por outro lado, séries com $\sum_{i\geqslant 1}|a_i| < \infty$ convergem para a mesma soma em qualquer ordem (Rudin, 1976, teorema 3.55). Portanto,

a série é incondicionalmente convergente, se e só se $\sum_{i\geqslant 1}|a_i| < \infty$.

e nesse caso dizemos que a série ***converge absolutamente***.

Se $(a_n : n \geqslant 1)$ uma sequência de números reais com $a_n \geqslant 0$ para todo n, então a soma parcial $\sum_{n=1}^{m} a_n$ é crescente e, portanto, sempre tende a um limite S, possivelmente infinito, $S \in [0, \infty]$. Assim, tal série

- ***converge*** para um número real (finito), caso em que escrevemos $\sum_{n\geqslant 1} a_n < \infty$; ou
- ***converge para*** ∞ e escrevemos $\sum_{n\geqslant 1} a_n = \infty$.

Em ambos os casos, o valor da série não se altera se a ordem dos termos for modificada.

No caso geral, onde $a_n \in \mathbb{R}$, definimos $a^+ := \max\{a, 0\}$ e $a^- := \max\{-a, 0\}$ e

$$S^+ := \sum_{n\,:\,a_n\geqslant 0} {a_n}^+ \quad \text{e} \quad S^- := \sum_{n\,:\,a_n<0} {a_n}^-. \tag{2.5}$$

Há três casos.

- Se $S^+ < \infty$ e $S^- < \infty$, então a série converge absolutamente e $S = S^+ - S^-$, em qualquer ordem.
- Se exatamente um entre S^+ e S^- é infinito, então $S = +\infty$ (se $S^+ = \infty$) ou $S = -\infty$ (se $S^- = \infty$), independentemente da ordem de somação.
- Se $S^+ = S^- = \infty$, a soma não está bem definida: pode depender da ordem dos termos, e diferentes rearranjos podem levar a valores distintos.

Em particular, para X discreta com imagem $\{x_1, x_2, \ldots\}$, eventos $B_i = [X = x_i]$ as somas

$$\mathbb{E}\big(X^+\big) := \sum_i x_i^+ \,\mathbb{P}(B_i) \in [0, \infty], \qquad \mathbb{E}(X^-) := \sum_i x_i^- \,\mathbb{P}(B_i) \in [0, \infty]$$

estão sempre bem definidas, independentemente da enumeração escolhida.

Definição 2.3: Esperança matemática de uma v.a. discreta

Seja X uma variável aleatória discreta com imagem $\{x_1, x_2, \dots\}$ (valores distintos) e $B_i = [X = x_i]$.

Se **não** ocorrer $\mathbb{E}(X^+) = \mathbb{E}(X^-) = \infty$, então dizemos que $\mathbb{E}X$ está ***definida*** e nesse caso

$$\mathbb{E}X := \mathbb{E}\big(X^+\big) - \mathbb{E}(X^-) \in [-\infty, \infty].$$

Dizemos que X tem ***esperança finita*** ou que X é ***integrável***, se $\mathbb{E}(X^+) < \infty$ e $\mathbb{E}(X^-) < \infty$, o que equivale a

$$\sum_i |x_i|\, \mathbb{P}[X = x_i] < \infty,$$

e, nesse caso, $\mathbb{E}X$ é finita e, como a série converge absolutamente,

$$\mathbb{E}X = \sum_i x_i\, \mathbb{P}[X = x_i] \tag{2.6}$$

em qualquer ordem de somação.

Quando X é simples, esta definição coincide com a Definição 2.2, pois a soma é finita e os sinais se separam termo a termo.

Cabe perguntar se o valor de $\mathbb{E}X$ também independe da *representação* de X, isto é, se qualquer outra decomposição enumerável de Ω em que X seja constante leva ao mesmo resultado. A resposta é sim, e é o análogo, para o caso enumerável, da Proposição 2.3.

Proposição 2.5: Independência da partição

Sejam $\{A_i\}_i$ e $\{B_j\}_j$ partições enumeráveis de Ω em eventos (possivelmente vazios) tais que

$$X = \sum_i x_i \mathbb{1}_{A_i} = \sum_j b_j \mathbb{1}_{B_j}.$$

(a) Se $x_i, b_j \geqslant 0$ para todos i, j, então

$$\sum_i x_i \mathbb{P}(A_i) = \sum_j b_j \mathbb{P}\big(B_j\big)$$

em $[0, \infty]$.

(b) Se $\sum_i |x_i| \mathbb{P}(A_i) < \infty$, então

$$\sum_j |b_j| \mathbb{P}\big(B_j\big) < \infty \quad \text{e} \quad \sum_i x_i\, \mathbb{P}(A_i) = \sum_j b_j\, \mathbb{P}\big(B_j\big).$$

Demonstração. Seja $C_{ij} = A_i \cap B_j$. Para i e j fixos, $A_i = \dot{\bigcup}_j C_{ij}$ e $B_j = \dot{\bigcup}_i C_{ij}$ são uniões disjuntas *enumeráveis*, de modo que, pela aditividade enumerável de $\mathbb{P}$ (e não apenas a finita),

$$\mathbb{P}(A_i) = \sum_j \mathbb{P}(C_{ij}), \qquad \mathbb{P}(B_j) = \sum_i \mathbb{P}(C_{ij}).$$

Além disso, $x_i \mathbb{P}(C_{ij}) = b_j \mathbb{P}(C_{ij})$ para todo par (i,j): se $C_{ij} = \varnothing$ ambos os lados são nulos; caso contrário, avaliando $X(\omega)$ nas duas representações para $\omega \in C_{ij}$, obtemos $x_i = b_j$. O mesmo vale com módulos.

(a) Se todos os termos são não negativos, então a soma dupla $\sum_{i,j} x_i \mathbb{P}(C_{ij}) \in [0,\infty]$ pode ser calculada em qualquer ordem (Tonelli para séries, s.5 no apêndice). Somando primeiro em j obtemos $\sum_i x_i \mathbb{P}(A_i)$; como $x_i \mathbb{P}(C_{ij}) = b_j \mathbb{P}(C_{ij})$, somando primeiro em i obtemos $\sum_j b_j \mathbb{P}(B_j)$.

(b) Aplicando (a) a $|x_i|$ e $|b_j|$ (que também representam $|X|$), temos

$$\sum_j |b_j| \mathbb{P}(B_j) = \sum_{i,j} |b_j| \mathbb{P}(C_{ij}) = \sum_{i,j} |x_i| \mathbb{P}(C_{ij}) = \sum_i |x_i| \mathbb{P}(A_i) < \infty.$$

Logo a família $\{ x_i \mathbb{P}(C_{ij}) \}_{i,j}$ é absolutamente somável e Fubini para séries permite somar em qualquer ordem, com o mesmo argumento de (a). □

Corolário 2.4: Qualquer partição calcula $\mathbb{E}X$

Se $X = \sum_j b_j \mathbb{1}_{B_j}$, com $\{B_j\}$ uma partição enumerável de Ω em eventos, então

(a) se $b_j \geqslant 0$ para todo j,

$$\mathbb{E}X = \sum_j b_j \mathbb{P}(B_j)$$

em $[0,\infty]$;

(b) se $\sum_j |b_j| \mathbb{P}(B_j) < \infty$, então X é integrável e

$$\mathbb{E}X = \sum_j b_j \mathbb{P}(B_j).$$

Em particular, $\mathbb{E}X^+ = \sum_j b_j^+ \mathbb{P}(B_j)$ e $\mathbb{E}X^- = \sum_j b_j^- \mathbb{P}(B_j)$ para qualquer partição em que X seja constante em cada elemento.

Demonstração. A partição canônica $[X = x_i]$ é uma partição enumerável em que $X = \sum_i x_i \mathbb{1}_{[X=x_i]}$. Aplique a Proposição 2.5 a ela e à partição dada. Para $X^\pm$, observe que $X^\pm = \sum_j b_j^\pm \mathbb{1}_{B_j}$ com coeficientes não negativos e aplique (a). □

Observação 3. A Proposição 2.5 expõe um ingrediente que a definição usual $\mathbb{E}X := \sum_i x_i \mathbb{P}[\, X = x_i \,]$, apresentada sem passar pela construção via indicadoras, deixa implícito. A definição pela partição canônica já está bem posta apenas com convergência absoluta. Já a *compatibilidade com outras representações* depende também da aditividade enumerável de $\mathbb{P}$, algo que não era necessário no caso de variáveis simples, onde bastava aditividade finita.

Para *coberturas* enumeráveis não disjuntas $X = \sum_i y_i \mathbb{1}_{C_i}$ a igualdade $\mathbb{E}X = \sum_i y_i \mathbb{P}(\, C_i \,)$ exige a hipótese adicional $\sum_i |y_i| \mathbb{P}(\, C_i \,) < \infty$ (sem ela pode falhar, mesmo com convergência pontual) e é adiada para depois da integral geral, onde a troca entre esperança e série é justificada.

Analogamente à Observação 2, se Ω é enumerável e X é integrável, então podemos rearranjar a série de $\mathbb{E}X$. Os passos abaixo são justificados porque

$$\sum_t \sum_\omega |t| \, \mathbb{1}_{[X(\omega)=t]} \mathbb{P}(\, \omega \,) = \sum_t |t| \, \mathbb{P}[\, X = t \,] < \infty$$

(Tonelli para séries), o que torna a família absolutamente somável e autoriza Fubini na quarta igualdade:

$$\begin{aligned}
\mathbb{E}X &= \sum_t t \, \mathbb{P}[\, X = t \,] \\
&= \sum_t t \sum_{\omega:\, X(\omega)=t} \mathbb{P}(\, \omega \,) \\
&= \sum_t t \left(\sum_\omega \mathbb{1}_{[X(\omega)=t]} \, \mathbb{P}(\, \omega \,) \right) \\
&= \sum_\omega \left(\sum_t t \, \mathbb{1}_{[X(\omega)=t]} \right) \mathbb{P}(\, \omega \,) \\
&= \sum_\omega X(\omega) \, \mathbb{P}(\, \omega \,).
\end{aligned}$$

Portanto, com $B_i = [X = x_i]$,

$$\sum_i x_i \, \mathbb{P}(\, B_i \,) = \sum_\omega X(\omega) \, \mathbb{P}(\, \omega \,), \tag{2.7}$$

e a série do lado direito também converge absolutamente.

Ideia importante

A esperança de uma variável aleatória depende apenas da sua distribuição, ou seja, se X e Y têm a mesma distribuição, então $\mathbb{E}Y = \mathbb{E}X$. De fato, a Definição 2.3 usa apenas os valores x_i e as probabilidades $\mathbb{P}[\, X = x_i \,]$.

Em particular, a esperança pode ser vista como uma propriedade da distribuição de X, não do espaço amostral subjacente.

Exemplo 2.10: Esperança da distribuição geométrica

Seja $X \sim \text{Geom}(p)$ com $p \in (0,1)$. Lembremos que

$$\mathbb{P}_X(t) = (1-p)^{t-1}p, \quad t \in \{1,2,\dots\}$$

portanto,

$$\mathbb{E}X = \sum_{t \geqslant 1} t(1-p)^{t-1}p$$

e pelo teste da razão a série converge absolutamente. Assim, usando s.6c, do apêndice,

$$\mathbb{E}X = p\sum_{t \geqslant 1} t(1-p)^{t-1} = p \cdot \frac{1}{(1-(1-p))^2} = \frac{1}{p}. \quad (2.8)$$

Análise do Algoritmo 1.2

Dado $M \geqslant 2$, tome $k = \lceil \log_2 M \rceil$ e seja X o número de rodadas do laço `repita`. Então $X \sim \text{Geom}(p)$ para $p = \mathbb{P}[N < M] = \frac{M}{2^k} > 1/2$. A esperança é

$$\mathbb{E}X = \frac{1}{p} < 2.$$

Vimos no Exemplo 2.5 que o valor esperado pode ser pouco representativo, mas aqui sabemos mais. Usando o Exercício 8, no final deste capítulo, temos que a probabilidade de ocorrerem mais que 5 vezes o número esperado de rodadas do `repita`

$$\mathbb{P}\left[X > \tfrac{5}{p}\right] = (1-p)^{\frac{5}{p}} < \left(\frac{1}{2}\right)^{10} = 0.0009765625$$

O tempo de execução das instruções dentro do laço é $O(k) = O(\ln M)$. Assim, se a variável aleatória T é o tempo de execução do algoritmo, então com entrada M

$$\mathbb{E}T(M) = \mathbb{E}(X) \cdot O(k) = \frac{1}{p} \cdot O(\ln M) = O(\ln M).$$

Exemplo 2.11: Distribuição binomial negativa

Há dois entendimento para variável com ***distribuição binomial negativa***.
(1) X conta o número *total* de tentativas de Bernoulli, independentes e idênticas, com parâmetro p até o r-ésimo sucesso.

Nesse caso

$$X = G_1 + \cdots + G_r$$

com $G_i \sim \text{Geom}(p)$ e sua distribuição é

$$\mathbb{P}_X(t) = \binom{t-1}{r-1} p^r (1-p)^{t-r}, \quad t = r, r+1, \ldots$$

Nesse caso, $\mathbb{E}X = r/p$, por linearidade.
(2) Y conta o número de *fracassos* antes do r-ésimo sucesso.
Nesse caso, em função de (1), $Y = X - r$ e tem distribuição

$$\mathbb{P}_Y(t) = \binom{t+r-1}{t} (1-p)^t p^r, \qquad t = 0, 1, 2, \ldots$$

Notemos que o caso $r = 1$ é a lei da distribuição geométrica.
Denotamos por $\text{BN}(r, p)$ no caso 2, que chamamos de distribuição binomial negativa com parâmetros $r \in \mathbb{Z}_+$ e $p \in (0, 1)$.
Nesse caso, $\mathbb{E}Y = \frac{r}{p} - r$, por linearidade.

2.3 *Propriedades da esperança*

A seguir veremos propriedades importantes para a média das variáveis aleatórias discretas a valores reais. Começamos por um lema técnico com os fatos sobre $\mathbb{E}|X|$, comparação e igualdade quase certa que serão usados adiante. Todas as variáveis são discretas e usamos a Definição 2.3 e o Corolário 2.4.

Lema 2.1: Ferramentas básicas

Sejam Z, W, X, Y variáveis aleatórias discretas.

(a) Sejam z_i os valores distintos de Z. Para a v.a. $|Z|$ vale

$$\mathbb{E}|Z| = \mathbb{E}Z^+ + \mathbb{E}Z^- = \sum_i |z_i| \, \mathbb{P}[Z = z_i] \in [0, \infty].$$

Em particular, Z é integrável se, e só se, $\mathbb{E}|Z| < \infty$.

(b) (***Monotonicidade em*** $[0, \infty]$) Se $0 \leqslant Z \leqslant W$, então $\mathbb{E}Z \leqslant \mathbb{E}W$.

(c) (***Domínio***) Se $|Z| \leqslant W$ e W é integrável, então Z é integrável e $\mathbb{E}|Z| \leq \mathbb{E}W$.

(d) (***Igualdade quase certa***) Se $\mathbb{P}[X = Y] = 1$, então, para todo $t \in \mathbb{R}$, vale $\mathbb{P}[X = t] = \mathbb{P}[Y = t]$.

Logo X e Y têm a mesma esperança (definida ou não, finita ou não).

Demonstração. (a) Escreva $|Z| = \sum_i |z_i| \mathbb{1}_{[Z=z_i]}$, uma representação por partição enumerável com coeficientes não negativos. Pelo Corolário 2.4(a), $\mathbb{E}|Z| = \sum_i |z_i| \mathbb{P}[\, Z = z_i \,]$. Como $|z_i| = z_i^+ + z_i^-$ e os termos são não negativos, a série se separa em $\sum_i z_i^+ \mathbb{P}[\, Z = z_i \,] + \sum_i z_i^- \mathbb{P}[\, Z = z_i \,] = \mathbb{E}Z^+ + \mathbb{E}Z^-$.

(b) Sejam $A_i = [Z = z_i]$ e $B_j = [W = w_j]$ as partições canônicas e $C_{ij} = A_i \cap B_j$. Se $C_{ij} \neq \varnothing$, tomando $\omega \in C_{ij}$ obtemos $z_i = Z(\omega) \leqslant W(\omega) = w_j$; se $C_{ij} = \varnothing$ vale $z_i \mathbb{P}(C_{ij}) = 0 = w_j \mathbb{P}(C_{ij})$. Logo $z_i \mathbb{P}(C_{ij}) \leqslant w_j \mathbb{P}(C_{ij})$ para todo par (i, j). Por aditividade enumerável e Tonelli para séries (termos não negativos),

$$\mathbb{E}Z = \sum_i z_i \mathbb{P}(A_i) = \sum_{i,j} z_i \mathbb{P}(C_{ij}) \leq \sum_{i,j} w_j \mathbb{P}(C_{ij}) = \sum_j w_j \mathbb{P}(B_j) = \mathbb{E}W.$$

(c) Como $0 \leqslant |Z| \leqslant W$, o item (b) dá $\mathbb{E}|Z| \leqslant \mathbb{E}W < \infty$, e o item (a) mostra que Z é integrável.

(d) Como $\mathbb{P}[\, X \neq Y \,] = 0$, $\mathbb{P}[\, X = t \,] = \mathbb{P}([X = t] \cap [X = Y]) = \mathbb{P}([Y = t] \cap [X = Y]) = \mathbb{P}[\, Y = t \,]$. A Definição 2.3 depende de X apenas por seus valores e essas probabilidades. □

Teorema 2.1: Linearidade da esperança

Se X e Y são variáveis aleatórias integráveis e $a, b \in \mathbb{R}$, então $aX + bY$ é integrável e sua esperança satisfaz

$$\mathbb{E}(aX + bY) = a\,\mathbb{E}X + b\,\mathbb{E}Y.$$

Demonstração. Sejam S_X e S_Y conjuntos enumeráveis que contêm os valores de X e Y. Para $(x, y) \in S_X \times S_Y$, seja $D_{xy} = [X = x] \cap [Y = y]$. A família $\{ D_{xy} \}$ é uma partição enumerável de Ω em eventos (possivelmente vazios) e, por aditividade enumerável,

$$\sum_{y \in S_Y} \mathbb{P}(D_{xy}) = \mathbb{P}[\, X = x \,], \qquad \sum_{x \in S_X} \mathbb{P}(D_{xy}) = \mathbb{P}[\, Y = y \,]. \tag{2.9}$$

Em cada D_{xy} a variável $Z = aX + bY$ vale $ax + by$, ou seja,

$$Z = \sum_{x,y} (ax + by)\, \mathbb{1}_{D_{xy}}.$$

Em particular, Z é discreta (seus valores estão no conjunto enumerável $\{ ax + by \}$). Os valores $ax + by$ podem se repetir, então esta não é a partição canônica de Z, e o Corolário 2.4 é o que permite usá-la.

Como $|ax + by| \leqslant |a||x| + |b||y|$, por Tonelli para séries e por (2.9),

$$\begin{aligned} \sum_{x,y} |ax + by| \mathbb{P}(D_{xy}) &\leqslant |a| \sum_x |x| \sum_y \mathbb{P}(D_{xy}) + |b| \sum_y |y| \sum_x \mathbb{P}(D_{xy}) \\ &= |a|\,\mathbb{E}|X| + |b|\,\mathbb{E}|Y| < \infty. \end{aligned}$$

Pelo Corolário 2.4(b), Z é integrável e $\mathbb{E}Z = \sum_{x,y}(ax+by)\mathbb{P}(D_{xy})$.

Pela estimativa acima, as famílias $\{x\mathbb{P}(D_{xy})\}$ e $\{y\mathbb{P}(D_{xy})\}$ são absolutamente somáveis (suas somas de módulos valem $\mathbb{E}|X|$ e $\mathbb{E}|Y|$). Portanto podemos separar a soma e, por Fubini para séries, somar primeiro em y (ou em x):

$$\begin{aligned}\mathbb{E}Z &= a\sum_x x\sum_y \mathbb{P}(D_{xy}) + b\sum_y y\sum_x \mathbb{P}(D_{xy}) \\ &= a\sum_x x\,\mathbb{P}[X=x] + b\sum_y y\,\mathbb{P}[Y=y] = a\,\mathbb{E}X + b\,\mathbb{E}Y,\end{aligned}$$

onde usamos (2.9). □

Teorema 2.2: Monotonicidade da esperança

Se X e Y são integráveis tais que $X \leqslant Y$ então $\mathbb{E}X \leqslant \mathbb{E}Y$.

Demonstração. Se $X \leqslant Y$ então $Y - X \geqslant 0$, logo $\mathbb{E}(Y-X) \geqslant 0$. Da linearidade da esperança $\mathbb{E}Y - \mathbb{E}X \geqslant 0$ donde segue o teorema. □

Corolário 2.5: Consequências da linearidade e monotonicidade

As seguintes propriedades decorrem dos teoremas acima.

1. Se $X=c$ então $\mathbb{E}X=c$, para qualquer $c\in\mathbb{R}$.
2. Se $\mathbb{E}X$ é integrável, então $\mathbb{E}(aX+b)=a\,\mathbb{E}X+b$.
3. Se $\mathbb{P}[a\leqslant X\leqslant b]=1$, então X é integrável e $a\leqslant\mathbb{E}X\leqslant b$.
4. Se X é integrável então $X\cdot\mathbb{1}_A$ é integrável para todo evento A.
5. Se $\mathbb{E}X$ está definida então $|\mathbb{E}X|\leqslant\mathbb{E}|X|$.

Demonstração. Vamos demonstrar apenas os três últimos itens, os outros ficam para verificação do leitor.

3. Seja $E = [a \leqslant X \leqslant b]$, com $\mathbb{P}(E)=1$, e $X' = X\mathbb{1}_E + a\mathbb{1}_{\overline{E}}$. Então $a \leqslant X' \leqslant b$ em todo ponto e $\mathbb{P}[X'=X] \geqslant \mathbb{P}(E) = 1$. Como $|X'| \leqslant \max\{|a|,|b|\}$, que é constante e portanto integrável, o Lema 2.1(c) mostra que X' é integrável, e o Teorema 2.2 (com as constantes a e b) dá $a \leqslant \mathbb{E}X' \leqslant b$. Pelo Lema 2.1(d), $\mathbb{E}X = \mathbb{E}X'$ (e X é integrável pois X e X' têm a mesma distribuição).

4. Temos $|X\mathbb{1}_A| = |X|\mathbb{1}_A \leqslant |X|$ e $|X|$ é integrável pelo Lema 2.1(a). O Lema 2.1(c) dá a integrabilidade de $X\mathbb{1}_A$.

5. Pelo Lema 2.1(a), $\mathbb{E}|X| = \mathbb{E}X^+ + \mathbb{E}X^-$. Se X não é integrável, como $\mathbb{E}X$ está definida, um entre $\mathbb{E}X^+$ e $\mathbb{E}X^-$ é infinito, logo $\mathbb{E}|X| =$

$\infty \geqslant |\mathbb{E}X|$. Se X é integrável, $|X|$ também é, e de $-|X| \leqslant X \leqslant |X|$ o Teorema 2.2 dá $-\mathbb{E}|X| \leqslant \mathbb{E}X \leqslant \mathbb{E}|X|$, isto é, $|\mathbb{E}X| \leqslant \mathbb{E}|X|$. □

O item 2 vale também quando $\mathbb{E}X = \pm\infty$ (com $a \neq 0$; para $a = 0$ é preciso a convenção $0 \cdot \infty = 0$), mas a prova exige um argumento separado com $\mathbb{E}X^{\pm}$, pois os teoremas acima são enunciados para variáveis integráveis. Para $a < 0$ os papéis de X^+ e X^- se trocam.

Proposição 2.6

Se X assume valores inteiros e não negativos, então $\mathbb{E}X$ está bem definida e

$$\mathbb{E}X = \sum_{n=0}^{\infty} \mathbb{P}[\, X > n \,].$$

Demonstração. Se X assume valores não negativos, $\mathbb{E}X = \mathbb{E}X^+ \in [0, \infty]$ e que $\mathbb{E}X$ está definida. Rearranjando os termos (Tonelli para séries), a esperança é

$$\begin{aligned}
\sum_{t=0}^{\infty} t\, \mathbb{P}_X(t) = &\mathbb{P}_X(1) + \mathbb{P}_X(2) + \mathbb{P}_X(3) + \mathbb{P}_X(4) + \cdots \\
&+ \mathbb{P}_X(2) + \mathbb{P}_X(3) + \mathbb{P}_X(4) + \cdots \\
&+ \mathbb{P}_X(3) + \mathbb{P}_X(4) + \cdots \\
&+ \mathbb{P}_X(4) + \cdots \\
&\vdots \\
= &\sum_{n=0}^{\infty} \sum_{t=n+1}^{\infty} \mathbb{P}_X(t).
\end{aligned}$$

Por aditividade enumerável, como $[X > n] = \dot{\bigcup}_{t>n} [X = t]$, temos $\sum_{t>n} \mathbb{P}[\, X = t \,] = \mathbb{P}[\, X > n \,]$, o que conclui a prova. □

Proposição 2.7: Condição de integrabilidade

Uma variável aleatória X é integrável se, e somente se,

$$\sum_{n=1}^{\infty} \mathbb{P}[\, |X| \geqslant n \,] < +\infty.$$

Demonstração. Seja $Y = |X| \geq 0$. Pelo Lema 2.1(a), X é integrável se, e somente se, $\mathbb{E}Y < \infty$. Como Y é discreta, $\lfloor Y \rfloor$ também é, com valores inteiros e não negativos, e $0 \leqslant \lfloor Y \rfloor \leqslant Y \leqslant \lfloor Y \rfloor + 1$.

Pelo Lema 2.1(b) (monotonicidade em $[0, \infty]$), $\mathbb{E}\lfloor Y \rfloor \leqslant \mathbb{E}Y \leqslant \mathbb{E}\lfloor Y \rfloor + 1$. Além disso, $\mathbb{E}\lfloor Y \rfloor + 1 = \mathbb{E}\lfloor Y \rfloor + 1$ em $[0, \infty]$: se $\lfloor Y \rfloor = \sum_i w_i \mathbb{1}_{A_i}$ é a representação canônica, o Corolário 2.4(a) e a separação

de séries de termos não negativos dão $\mathbb{E}\lfloor Y\rfloor + 1 = \sum_i (w_i + 1)\mathbb{P}(A_i) = \mathbb{E}\lfloor Y\rfloor + \sum_i \mathbb{P}(A_i) = \mathbb{E}\lfloor Y\rfloor + 1$. Logo

$$\mathbb{E}\lfloor Y\rfloor \leqslant \mathbb{E}Y \leqslant \mathbb{E}\lfloor Y\rfloor + 1. \tag{2.10}$$

Para $n \in \mathbb{Z}$, como $\lfloor Y\rfloor$ é o maior inteiro $\leqslant Y$, temos $n \leqslant Y \iff n \leqslant \lfloor Y\rfloor$, isto é, $[Y \geqslant n] = [\lfloor Y\rfloor \geqslant n]$. Pela Proposição 2.6, e como $[\lfloor Y\rfloor > n] = [\lfloor Y\rfloor \geqslant n+1]$,

$$\mathbb{E}\lfloor Y\rfloor = \sum_{n\geqslant 0} \mathbb{P}[\,\lfloor Y\rfloor \geqslant n+1\,] = \sum_{n\geqslant 1} \mathbb{P}[\,\lfloor Y\rfloor \geqslant n\,] = \sum_{n\geqslant 1} \mathbb{P}[\,Y \geqslant n\,].$$

Substituindo em (2.10),

$$\sum_{n\geqslant 1} \mathbb{P}[\,|X| \geqslant n\,] \leqslant \mathbb{E}|X| \leqslant \sum_{n\geqslant 1} \mathbb{P}[\,|X| \geqslant n\,] + 1,$$

em $[0,\infty]$. Portanto $\mathbb{E}|X| < \infty$ se, e só se, $\sum_{n\geqslant 1} \mathbb{P}(\,|X| \geqslant n\,) < \infty$. □

Teorema 2.3: Produto de variáveis aleatórias independentes

Sejam

$$X : \Omega \to S \quad \text{e} \quad Y : \Omega \to R$$

variáveis aleatórias discretas independentes (S e R enumeráveis) e sejam

$$f : S \to \mathbb{R} \quad \text{e} \quad g : R \to \mathbb{R}$$

funções tais que $f(X)$ e $g(Y)$ são integráveis. Então $f(X)\cdot g(Y)$ é integrável e

$$\mathbb{E}(\,f(X)\cdot g(Y)\,) = \mathbb{E}(\,f(X)\,)\,\mathbb{E}(\,g(Y)\,).$$

Demonstração. Seja $D_{xy} = [X = x] \cap [Y = y]$, partição enumerável de Ω em que $f(X)g(Y)$ vale $f(x)g(y)$. Pela independência, $\mathbb{P}(D_{xy}) = \mathbb{P}[\,X = x\,]\mathbb{P}[\,Y = y\,]$. Aplicando o Corolário 2.4(a) a $|f(X)g(Y)|$ e Tonelli para séries,

$$\mathbb{E}|f(X)g(Y)| = \sum_{x,y} |f(x)||g(y)|\mathbb{P}[\,X = x\,]\mathbb{P}[\,Y = y\,]$$

$$= \left(\sum_x |f(x)|\mathbb{P}[\,X = x\,]\right)\left(\sum_y |g(y)|\mathbb{P}[\,Y = y\,]\right) = \mathbb{E}|f(X)|\,\mathbb{E}|g(Y)| < \infty,$$

onde a última igualdade usa o mesmo corolário na partição $[X = x]$ (em que $|f(X)|$ é constante), e analogamente para Y. Logo $f(X)g(Y)$ é integrável, o Corolário 2.4(b) dá

$$\mathbb{E}(\,f(X)g(Y)\,) = \sum_{x,y} f(x)g(y)\mathbb{P}[\,X = x\,]\mathbb{P}[\,Y = y\,]$$

e, como a família é absolutamente somável, Fubini para séries dá

$$\mathbb{E}f(X)g(Y) = \left(\sum_x f(x)\mathbb{P}[\,X = x\,]\right)\left(\sum_y g(y)\mathbb{P}[\,Y = y\,]\right) = \mathbb{E}(\,f(X)\,)\,\mathbb{E}(\,g(Y)\,).$$

□

Corolário 2.6

Se X e Y são discretas independentes e integráveis, então XY é integrável e

$$\mathbb{E}(\,XY\,)=\mathbb{E}(\,X\,)\,\mathbb{E}(\,Y\,). \tag{2.11}$$

Demonstração. Tome f e g como a identidade no teorema. □

Observação 4. O Teorema 2.2, da monotonicidade, ainda vale com as hipóteses de $\mathbb{E}X$ e $\mathbb{E}Y$ definidos. Basta, por exemplo, $\mathbb{E}X^- < \infty$ ou $\mathbb{E}Y^+ < \infty$ para que ambas estejam definidas.

Se X é integrável, $\mathbb{E}Y$ está definida e $a, b \in \mathbb{R}$, então $\mathbb{E}aX + bY$ está definida e $\mathbb{E}aX + bY = a\,\mathbb{E}X + b\,\mathbb{E}Y$ (com $0 \cdot \infty = 0$). Em geral, $aX + bY$ é integrável se, e só se, bY o é.

2.3.1 *Esperança de funções de variáveis aleatórias*

Seja $X\colon \Omega \to S$, com $S \subset \mathbb{R}$ enumerável. A lei de X é a medida de probabilidade $\mathbb{P}_X$ em $(S, 2^S)$ dada por $\mathbb{P}_X(\,A\,) = \mathbb{P}[\,X \in A\,]$. Em particular, $(S, \mathbb{P}_X)$ é um espaço de probabilidade discreto.

Toda $f\colon S \to \mathbb{R}$ é uma variável aleatória em $(S, \mathbb{P}_X)$, discreta pois $f(S)$ é enumerável. Sua lei é a medida imagem (*pushforward*) de $\mathbb{P}_X$ por f, classicamente denotado $\mathbb{P}_X \circ f^{-1}$:

$$(\mathbb{P}_X \circ f^{-1})(\{\,y\,\}) = \mathbb{P}_X[\,f = y\,] \quad \text{para } y \in f(S).$$

Por outro lado, $f(X)$ é variável aleatória em $(\Omega, \mathbb{P})$ e

$$\mathbb{P}[\,f(X) = y\,] = \mathbb{P}\big[\,X \in f^{-1}(y)\,\big] = \mathbb{P}_X(f^{-1}(y)) = (\mathbb{P}_X \circ f^{-1})(\{\,y\,\}).$$

Portanto, ***f em $(S, \mathbb{P}_X)$ e $f(X)$ em $(\Omega, \mathbb{P})$ têm a mesma lei***. Como a esperança depende apenas da lei, $\mathbb{E}f(X)$ pode ser calculada em $(S, \mathbb{P}_X)$.

Proposição 2.8: Mudança de espaço

Para toda $f\colon \quad S \to \mathbb{R}$, a esperança $\mathbb{E}_S[\,f\,]$ está definida se, e somente se, $\mathbb{E}_\Omega[\,f(X)\,]$ está, e nesse caso

$$\mathbb{E}_S[\,f\,] = \mathbb{E}_\Omega[\,f(X)\,].$$

Além disso, f é integrável em $(S, \mathbb{P}_X)$ se, e somente se, $f(X)$ é integrável em $(\Omega, \mathbb{P})$.

Demonstração. Se $g\colon S \to \mathbb{R}$ é qualquer função, o mesmo cálculo que mostra que f e $f(X)$ têm a mesma lei dá $\mathbb{P}_X[\, g = y \,] = \mathbb{P}[\, g(X) = y \,]$ para todo $y \in \mathbb{R}$, com ambos os lados nulos se $y \notin g(S)$. Logo, as somas $\sum_y y^{\pm}\, \mathbb{P}_E(\, X\,)g = y$ e $\sum_y y^{\pm}\, \mathbb{P}[\, g(X) = y \,]$ têm os mesmos termos não nulos, e portanto

$$\mathbb{E}_S\,[g^{\pm}] \;=\; \mathbb{E}_\Omega\,(g(X))^{\pm} \quad \text{em } [0,\infty],$$

onde usamos $g^{\pm}(X) = (g(X))^{\pm}$. Tomando $g = f$, como "$\mathbb{E}$ está definida" e o valor $\mathbb{E}f = \mathbb{E}f^{+} - \mathbb{E}f^{-}$ dependem só desses dois números, seguem a equivalência e a igualdade. Tomando $g = |f|$, obtemos $\mathbb{E}_S\,[|f|] \;=\; \mathbb{E}_\Omega\,[|f(X)|]$, o que dá a equivalência de integrabilidade. □

Teorema 2.4: Lei do Estatístico Inconsciente (LOTUS)

Seja $f\colon S \to \mathbb{R}$.

(a) Se $f \geq 0$, então $\mathbb{E}f(X) = \sum_{s\in S} f(s)\,\mathbb{P}[\, X = s \,]$ em $[0,\infty]$.

(b) Se $\mathbb{E}f(X)$ está definida, então a série $\sum_s f(s)\,\mathbb{P}[\, X = s \,]$ está definida e $\mathbb{E}f(X) = \sum_s f(s)\,\mathbb{P}[\, X = s \,]$. Se $f(X)$ é integrável, a série converge absolutamente.

Demonstração. (a) Seja $A_y = \{\, s \in S\colon f(s) = y \,\}$, $y \in f(S)$, a partição canônica de f em $(S, \mathbb{P}_X)$, que é um espaço de probabilidade, e a $\{\,\{\, s \,\}\,\}_{s\in S}$ a partição fina, com $\mathbb{P}_X(\{s\}) = \mathbb{P}[\, X = s \,]$. Pela Proposição 2.8 e pela definição de $\mathbb{E}$ em $(S, \mathbb{P}_X)$, $\mathbb{E}f(X) = \mathbb{E}_S f = \sum_y y\, \mathbb{P}_X(A_y)$. Como $f = \sum_s f(s)\mathbb{1}_{\{s\}}$ e todos os coeficientes são não negativos, o item (a) da Proposição 2.5, aplicada a $(S, \mathbb{P}_X)$, dá $\sum_y y\, \mathbb{P}_X(A_y) = \sum_s f(s)\mathbb{P}_X(\{s\})$.

(b) Aplique (a) a f^{+} e f^{-}, usando $f^{\pm}(X) = (f(X))^{\pm}$: $\mathbb{E}(\,(f(X))^{\pm}\,) = \sum_s f^{\pm}(s)\mathbb{P}[\, X = s \,]$. Como $\mathbb{E}f(X)$ está definida, não são ambas infinitas, e subtraindo obtém-se a igualdade. Se $f(X)$ é integrável, então $\mathbb{E}|f(X)| = \mathbb{E}(f(X))^{+} + \mathbb{E}(f(X))^{-} < \infty$ (Lema 2.1(a)) e, por (a) aplicado a $|f|$, temos $\sum_s |f(s)|\mathbb{P}[\, X = s \,] < \infty$. □

Observação 5. A Proposição 2.8 não exige integrabilidade: é uma igualdade de somas de termos não negativos. A LOTUS compara duas partições de S, a grossa $\{\, A_y \,\}$ e a fina $\{\,\{\, s \,\}\,\}$. A igualdade das duas somas é a independência da partição (Proposição 2.5), e a convergência absoluta dá o valor finito. Para $f \geq 0$, não é preciso hipótese alguma.

O termo "Lei do Estatístico Inconsciente" foi cunhado por Sheldon Ross em seu famoso livro "A First Course in Probability" (1976). A piada interna da comunidade acadêmica é que mudar o parâmetro de x para $f(x)$ dentro do somatório ou da integral parece tão óbvio e natural que as pessoas fazem isso mecanicamente, como se fosse uma mera definição, quando na verdade trata-se de um teorema que exige demonstração.

2.4 *Variáveis contínuas, a Uniforme e simulação*

Até aqui, toda variável aleatória X que consideramos era discreta, sua distribuição estava concentrada em um conjunto enumerável e

$\mathbb{P}[\, X \in B \,] = \sum_{x \in B} \mathbb{P}[\, X = x \,]$. Isso não cobre situações básicas, como "sortear um ponto ao acaso em $[0,1]$", em que cada valor individual deve ter probabilidade zero e, ainda assim, o valor sorteado existe. Além disso, "sortear um ponto ao acaso em $[0,1]$" pode ser uma ferramenta para tratar casos discretos (em Acoplamento, por exemplo, na Seção 3.1.1).

Seja X uma variável aleatória real com ***distribuição acumulada*** $F_X(x) = \mathbb{P}[\, X \leqslant x \,]$.

Uma função $F\colon \mathbb{R} \to [0,1]$ é a função de distribuição de alguma variável aleatória se, e somente se, satisfaz:

(i) **Monotonicidade** $x \leqslant y \implies F(x) \leqslant F(y)$;

(ii) **Continuidade à direita** $\lim_{y \to x^+} F(y) = F(x)$ para todo $x \in \mathbb{R}$;

(iii) **Limites nos extremos** $\lim_{x \to -\infty} F(x) = 0$ e $\lim_{x \to +\infty} F(x) = 1$.

A necessidade dessas três condições, quando $F(x) = \mathbb{P}[\, X \leqslant x \,]$ para alguma variável aleatória X, decorre dos axiomas de probabilidade: (i) de $[X \leqslant x] \subseteq [X \leqslant y]$ para $x \leqslant y$; (ii) e (iii) da continuidade da probabilidade, aplicada às sequências de eventos $[X \leqslant y_n] \downarrow [X \leqslant x]$ quando $y_n \downarrow x$, $[X \leqslant x_n] \downarrow \varnothing$ quando $x_n \to -\infty$, e $[X \leqslant x_n] \uparrow \Omega$ quando $x_n \to +\infty$.

A suficiência é o conteúdo da Proposição 2.10: dada F satisfazendo (i)–(iii), a variável $X := F^{-1}(U)$, com $U \sim \mathrm{U}(0,1)$, tem função de distribuição F. Ou seja, as três condições *caracterizam* as funções de distribuição: toda F que as satisfaz é realizada por alguma variável aleatória.

Vale notar que não se exige continuidade de F: os saltos de F correspondem aos átomos de X (como no Exemplo 2.12), e são no máximo enumeráveis, por F ser monótona e limitada.

Dizemos que X (ou sua distribuição) é ***absolutamente contínua*** se existe uma função contínua por partes[1] $f_X\colon \mathbb{R} \to [0,\infty)$ tal que

$$F_X(x) = \int_{-\infty}^{x} f_X(t)\,\mathrm{d}t \qquad \text{para todo } x \in \mathbb{R}. \tag{2.12}$$

A função f_X é chamada de ***densidade*** de X.

[1] Uma função $f\colon \mathbb{R} \to \mathbb{R}$ é ***contínua por partes*** se, em cada intervalo limitado, ela é contínua exceto em um número finito de pontos, nos quais existem os limites laterais (finitos). De fato, basta ser Borel-mensurável.

A densidade *não* é uma probabilidade, $f(x)$ pode ser maior que 1. Sua interpretação é local: para h pequeno, $\mathbb{P}[\, x < X \leqslant x + h \,] \approx f(x)\,h$. Além disso, como $\mathbb{P}[\, X = x \,] = 0$ para todo x, alterar o valor de f em um número finito de pontos não muda a distribuição de X.

Proposição 2.9

Seja X absolutamente contínua com densidade $f = f_X$. Então

(a) $\displaystyle\int_{-\infty}^{\infty} f(x)\,\mathrm{d}x = 1$;

(b) $\mathbb{P}[\, X=x \,]=0$ para todo $x\in\mathbb{R}$; em particular, F_X é contínua

$$\mathbb{P}[\, a<X<b \,]=\mathbb{P}[\, a\leqslant X\leqslant b \,]=\mathbb{P}[\, a<X\leqslant b \,]=\int_a^b f(x)\,\mathrm{d}x$$

para quaisquer $a<b$;

(c) $F'_X(x)=f(x)$ em todo ponto x onde f é contínua.

Demonstração. Exercício. □

Como no caso discreto, esperanças se calculam integrando contra a distribuição; agora, contra a densidade. Se g é contínua por partes e $\int_{-\infty}^{\infty} |g(x)|\,\mathrm{d}F_X(x) < \infty$, então

$$\mathbb{E}(\, g(X)\,) \coloneqq \int_{-\infty}^{\infty} g(x)\,\mathrm{d}F_X(x). \tag{2.13}$$

em que a integral é de Riemann–Stieltjes (imprópria). A definição vale para X discreta com g contínua. Quando X é absolutamente contínua com densidade f_X, vale $\mathrm{d}F_X(x) = f_X(x)\,\mathrm{d}x$, e portanto

$$\mathbb{E}(\, g(X)\,) = \int_{-\infty}^{\infty} g(x)\, f_X(x)\,\mathrm{d}x. \tag{2.14}$$

Em particular, $\mathbb{E}(\, X\,) = \int x f_X(x)\,\mathrm{d}x$.

2.4.1 *A distribuição uniforme (contínua)*

Sejam $a < b$. Dizemos que X tem distribuição ***uniforme em*** $[a,b]$, e escrevemos $X \sim \mathrm{U}(a,b)$, se X é absolutamente contínua com densidade

$$f(x) = \frac{1}{b-a}\,\mathbb{1}_{[a,b]}(x)$$

e função de distribuição acumulada

$$F(x) = \begin{cases} 0, & x < a, \\ \dfrac{x-a}{b-a}, & a \le x \le b, \\ 1, & x > b. \end{cases}$$

Para $[c,d] \subseteq [a,b]$,

$$\mathbb{P}(c \le X \le d) = \frac{d-c}{b-a},$$

ou seja, a probabilidade de um intervalo é proporcional ao seu comprimento.

Se $X \sim \mathrm{U}(a,b)$, então

$$\mathbb{E}X = \int_a^b \frac{x}{b-a}\,dx = \frac{a+b}{2}, \qquad \mathbb{E}(\, X^2\,) = \int_a^b \frac{x^2}{b-a}\,dx = \frac{a^2+ab+b^2}{3}.$$

A uniforme em $[0,1]$ é o "***gerador básico de aleatoriedade***", no sentido da proposição a seguir.

Proposição 2.10: Transformação integral da probabilidade

Seja F uma função de distribuição qualquer e defina

$$F^{-1}(u) := \inf\{\, x \in \mathbb{R} : F(x) \geqslant u \,\}$$

para $u \in (0,1)$.
Se $U \sim \mathrm{U}(0,1)$, então $F^{-1}(U)$ tem função de distribuição F.

Demonstração. *F^{-1} está bem definida.* Fixe $u \in (0,1)$. Pelas condições (iii) — limites nos extremos —, existe b com $F(b) \geqslant u$ (pois $F(x) \to 1$) e existe a com $F(a) < u$ (pois $F(x) \to 0$); pela monotonicidade (i), $F(x) < u$ para todo $x \leqslant a$. Logo o conjunto

$$A_u := \{\, x \in \mathbb{R} : F(x) \geq u \,\}$$

é não vazio (contém b) e limitado inferiormente (por a), e portanto $F^{-1}(u) = \inf A_u$ é um número real bem definido.

Afirmação: para todo $x \in \mathbb{R}$ e $u \in (0,1)$,

$$F^{-1}(u) \leqslant x \iff u \leqslant F(x). \tag{2.15}$$

($\Leftarrow$) Se $u \leqslant F(x)$, então $x \in A_u$, logo $F^{-1}(u) = \inf A_u \leqslant x$.

($\Rightarrow$) Suponha $F^{-1}(u) \leqslant x$. Por definição de ínfimo, existe uma sequência $(x_n)_n \subseteq A_u$ com $x_n \downarrow F^{-1}(u)$ (tome, por exemplo, $x_n \in A_u \cap (F^{-1}(u), F^{-1}(u) + 1/n]$, que é não vazio pela definição de ínfimo). Como $x_n \in A_u$, temos $F(x_n) \geqslant u$ para todo n. Além disso, $x_n \to F^{-1}(u)$ com $x_n \geqslant F^{-1}(u)$, de modo que, pela continuidade à direita (ii), $F(x_n) \to F(F^{-1}(u))$. Logo $F(F^{-1}(u)) \geqslant u$, isto é, $F^{-1}(u) \in A_u$ (o ínfimo é, de fato, mínimo). Como $F^{-1}(u) \leqslant x$ e F é não decrescente (i), segue $F(x) \geqslant F(F^{-1}(u)) \geqslant u$, *o que prova a afirmação.*

Conclusão. Seja $U \sim \mathrm{U}(0,1)$, que toma valores em $(0,1)$ com probabilidade 1. Para todo $x \in \mathbb{R}$, usando (2.15) com $u = U$,

$$\mathbb{P}\left[\, F^{-1}(U) \leqslant x \,\right] = \mathbb{P}[\, U \leqslant F(x) \,] = F(x),$$

em que a última igualdade usa que $F(x) \in [0,1]$ e que $\mathbb{P}[\, U \leqslant t \,] = t$ para $t \in [0,1]$. Logo $F^{-1}(U)$ tem função de distribuição F. □

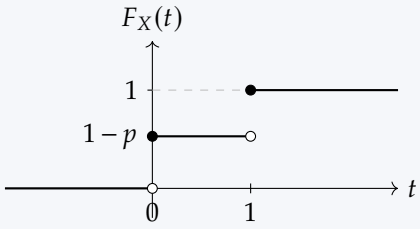
Assim, ***qualquer distribuição pode ser simulada a partir de uma variável uniforme***, o que será explorado nos algoritmos probabilísticos.

Exemplo 2.12: Simulação de uma Bernoulli

Seja $X \sim \text{Bernoulli}(p)$, de modo que

$$F_X(x) = \begin{cases} 0, & x < 0 \\ 1-p, & 0 \leqslant x < 1 \\ 1, & x \geqslant 1. \end{cases}$$

A função tem um salto de tamanho $1-p$ em $x=0$ e de tamanho p em $x=1$.



O cálculo de F_X^{-1}, via ínfimo, dá

$$F_X^{-1}(u) = \inf\{\, x : F_X(x) \geqslant u \,\} = \begin{cases} 0, & u \leqslant 1-p \\ 1, & u > 1-p \end{cases}$$

Dado $U \sim \text{U}(0,1)$, a v.a. $X' = F_X^{-1}(U) = \mathbb{1}_{[U>1-p]}$ tem a mesma distribuição de X, pela Proposição 2.10.

Note que $1-U \sim \text{U}(0,1)$ e que $\mathbb{P}[\, U \leqslant p \,] = p$, de modo que a variável $X' := \mathbb{1}_{[U \leqslant p]}$ também tem distribuição Bernoulli(p), Por isso, costuma-se escrever de forma simétrica que U nos dá

$$X' = \mathbb{1}_{[U \leqslant p]}$$

que é exatamente como qualquer implementação sorteia ω uniformemente, compara com p e gera uma Bernoulli:

```
if random() <= p:
    return 1
else:
    return 0
```

Por exemplo, para simular um dado justo, $X \in \{1,2,3,4,5,6\}$ com

distribuição uniforme (discreta). A função de distribuição F_X é

$$F_X(x) = \sum_{k=1}^{6} \frac{1}{6} \mathbb{1}_{[k \leqslant x]} = \begin{cases} 0, & x < 1 \\ 1/6, & 1 \leqslant x < 2 \\ 2/6, & 2 \leqslant x < 3 \\ 3/6, & 3 \leqslant x < 4 \\ 4/6, & 4 \leqslant x < 5 \\ 5/6, & 5 \leqslant x < 6 \\ 1, & x \geqslant 6 \end{cases}$$

Ela é constante por partes, com saltos de tamanho $1/6$ em cada inteiro de 1 a 6. Não é bijetora, então não existe inversa de F_X no sentido clássico.

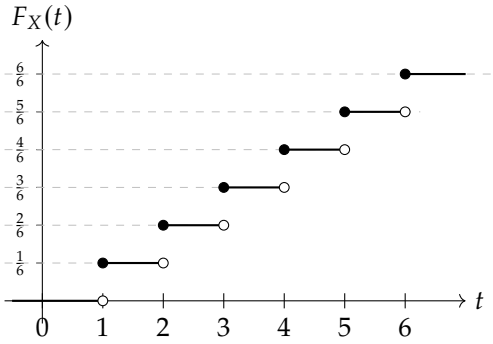


Figura 2.1: FDA de $X(\omega) = \omega$ no lançamento de um dado equilibrado.

Para $u \in (0,1)$, $F_X^{-1}(u) = \inf\{\, x \colon F_X(x) \geqslant u \,\}$ é, por definição, o menor valor x cuja "escada" F_X já atingiu ou ultrapassou o nível u. Como F só cresce nos pontos $1, \ldots, 6$, o resultado é sempre um desses inteiros (veja Figura 2.1):

$$F^{-1}(u) = k \quad \text{sempre que} \quad \frac{k-1}{6} < u \leqslant \frac{k}{6}, \quad k = 1, \ldots, 6.$$

Dado $U \sim \mathrm{U}(0,1)$, devolva

$$X' = F_X^{-1}(U) = \lceil 6U \rceil,$$

que é, exatamente, k quando U cai no intervalo $\left(\frac{k-1}{6}, \frac{k}{6}\right]$. Pela proposição, X' tem função de distribuição F_X, ou seja, X' é um dado justo.

2.5 *Exercícios*

Exercício 5. Sejam $X = \sum_{k=1}^{n} x_k \mathbb{1}_{A_k}$ e $Y = \sum_{\ell=1}^{m} y_\ell \mathbb{1}_{B_\ell}$ duas variáveis aleatórias simples de $(\Omega, \mathbb{P})$. Verifique que valem as seguintes identidades

1. para quaisquer $a, b \in \mathbb{R}$

$$aX + bY = \sum_{k=1}^{n}\sum_{\ell=1}^{m}(ax_k + by_\ell)\mathbb{1}_{A_k \cap B_\ell};$$

2.

$$X \cdot Y = \sum_{k=1}^{n}\sum_{\ell=1}^{m}(x_k \cdot y_\ell)\mathbb{1}_{A_k \cap B_\ell}.$$

Exercício 6 (***desigualdade de Jensen***). Sejam X uma variável aleatória integrável, $I \subseteq \mathbb{R}$ um intervalo tal que $\mathbb{P}[\, X \in I \,] = 1$ e $f : I \to \mathbb{R}$ uma função convexa em I, então $\mathbb{E}(\, f(X)\,)$ está definida e

$$\mathbb{E}(\, f(X)\,) \geqslant f(\mathbb{E}X). \tag{2.16}$$

$f : [a, b] \to \mathbb{R}$ é dita convexa se para quaisquer $x, y \in [a, b]$ e para todo $t \in [0, 1]$, tem-se que o segmento de reta que une x e y fica acima do gráfico de f entre x e y, isto é, $f(tx + (1-t)y) \leqslant tf(x) + (1-t)f(y)$

Exercício 7. Conclua do teorema acima que $\mathbb{E}|\, X\,| \;\geqslant\; |\,\mathbb{E}X\,|$ e que $\mathbb{E}(\, X^2\,) \geqslant (\mathbb{E}X)^2$.

Exercício 8. Mostre que se Z tem distribuição geométrica com parâmetro p então $\mathbb{P}[\, Z > n - 1\,] = (1-p)^{n-1}$ para todo $n \geqslant 1$.

Exercício 9. Este exercício fornece uma maneira de derivar um algoritmo Las Vegas a partir de um algoritmo Monte Carlo.

Considere um algoritmo Monte Carlo A para um problema computacional Π cujo tempo de execução esperado é de no máximo $T(n)$ em qualquer instância de tamanho n e que produz uma solução correta com probabilidade $\gamma(n)$. Suponha ainda que, dada uma solução para Π, possamos verificar sua corretude no tempo $t(n)$. Mostre como obter um algoritmo Las Vegas que sempre fornece uma resposta correta para Π e roda em um tempo esperado de no máximo $(T(n) + t(n))/\gamma(n)$.

Exercício 10 (*linearidade da esperança, o caso de séries*). Prove que se $X_1, X_2, \ldots$ são variáveis aleatórias sobre Ω enumerável e $\sum_{i\geqslant 1}\mathbb{E}|X_i|$ converge, então $\mathbb{E}\sum_{i\geqslant 1} X_i = \sum_{i\geqslant 1}\mathbb{E}X_i$.

Exercício 11. Verifique que a hipótese de convergência é necessária no Exercício 10. Para tal, considere o espaço de probabilidade $(\mathbb{N}, \mathbb{P})$ com $\mathbb{P}(\, n\,) = 2^{-n}$ e as variáveis aleatórias

$$X_n(j) := \begin{cases} 2^n, & \text{se } j = n, \\ -2^{n+1}, & \text{se } j = n+1, \\ 0, & \text{caso contrário.} \end{cases}$$

1. Mostre que $\mathbb{E}X_n = 0$ para todo $n \geqslant 1$.
2. Tome $X = \sum_{n\geqslant 1} X_n$. Determine $X(1), X(2), X(3), \ldots$.
3. Usando o item anterior determine $\mathbb{E}X = \sum_{n\geqslant 1} X(n)\mathbb{P}(\, n\,)$.

Conclua que $\mathbb{E}\sum_n X_n \neq \sum_n \mathbb{E}X_n$.

Exercício 12. Considere uma moeda que resulta em cara com probabilidade $1/5$ e coroa com probabilidade $4/5$. Justifique que a probabilidade de sair menos que k coroas em $2k$ lançamentos (independentes) é

$$\sum_{i=0}^{k-1} \binom{2k}{i} (4/5)^i (1/5)^{2k-i} < (1/5)^{2k} 4^k \sum_{i=0}^{k-1} \binom{2k}{i}.$$

Prove que a probabilidade de sair menos que k coroas em $2k$ lançamentos dessa moeda é menor que $(4/5)^{2k}$ (dica: teorema do binômio de Newton para o somatório na equação acima).

3
Quicksort probabilístico

O *quicksort* é um algoritmo recursivo de ordenação que, grosso modo, funciona da seguinte maneira: dada uma sequência S de números, dos quais o primeiro é chamado de *pivô*, o *quicksort*(S) compara o pivô com cada outro elemento de S e rearranja a sequência, os elementos menores que o pivô formam a subsequência S_{E} (alocados à esquerda do pivô no vetor) e os demais, que não o pivô, formam a subsequência S_{D} (alocados à direita do pivô no vetor); o algoritmo devolve a sequência $(quicksort(S_{\text{E}}), \text{pivo}, quicksort(S_{\text{D}}))$ ordenada recursivamente.

O *quicksort* foi inventado por Charles A. R. Hoare por volta de 1960 e sabemos que é muito rápido em geral, mas é lento em algumas raras instâncias. É um algoritmo que ordena os números em função dos resultados das comparações entre elementos da entrada e, nesse tipo de algoritmo, medimos a eficiência do algoritmo contando o número de comparações realizadas para ordenar a sequência. O algoritmo *quicksort* executa $O(n \ln n)$ comparações em média e $O(n^2)$ comparações no pior caso para ordenar sequências de tamanho n. A Figura 3.1 abaixo ilustra exemplos de melhor caso e de pior caso da árvore de recursão para uma sequência de tamanho 6.

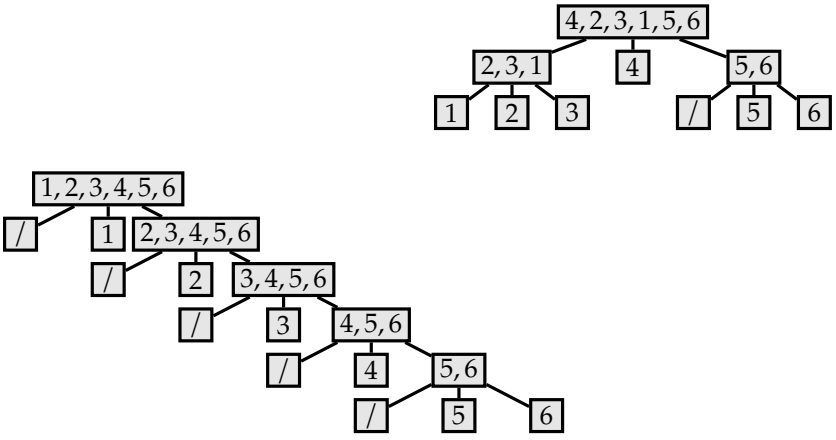


Figura 3.1: em cima à direita temos uma árvore de recursão do *quicksort* onde o pivô é a mediana da sequência. A outra árvore, abaixo e à esquerda, é o caso onde o pivô é sempre o menor elemento da sequência.

É sabido que para garantir $O(n \ln n)$ comparações numa execução é suficiente garantir que as subsequências geradas no pivotamento tenham sempre uma fração aproximadamente constante do tamanho da sequência que as origina. Por exemplo, se S_E (ou S_D) sempre tem 10% do tamanho de S então o número de comparações executadas pelo *quicksort* numa instância de tamanho n, que denotamos $T(n)$, é o número de comparações executadas em S_E mais o número de comparações executadas em S_D mais as $O(n)$ comparações executadas no particionamento que cria essas subsequências

$$T(n) = T(0{,}1n) + T(0{,}9n) + O(n)$$

cuja solução é uma função em $O(n \ln n)$. Não há nada de especial na escolha de 10%. De fato, se uma proporção for mantida no particionamento, digamos que a menor parte tem uma fração α da entrada, então a recorrência $t(n) \leqslant t(\lfloor \alpha n \rfloor) + t(\lfloor (1-\alpha)n \rfloor) + cn$ para constantes $\alpha, c > 0$ tem solução $O(n \ln n)$ (Cormen et al., 2009).

Na versão probabilística do *quicksort* a aleatoriedade é usada para descaracterizar o pior caso no sentido de que, sorteando o pivô como qualquer elemento da sequência, com grande chance evitamos os 10% menores e os 10% maiores elementos do vetor de modo que na maior parte do tempo os particionamentos garantem pelo menos uma fração constante da sequência original no menor lado.

Algoritmo 3.1: *Quicksort* aleatorizado.

Instância: uma sequência numérica $S=(x_1, x_2, \ldots, x_n)$.
Resposta: os elementos de S em ordem crescente.

```
1  se |S|⩽50 então
2  |   ordene S na força bruta ;
3  |   responda a sequência ordenada.
4  senão z ←R S;
5  para cada y∈S, y≠z faça
6  |   se y<z então insira y em S_E;
7  |   senão insira y em S_D;
8  ordene recursivamente a subsequência S_E;
9  ordene recursivamente a subsequência S_D;
10 responda (S_E, z, S_D).
```

Sedgewick (1977) analisou matematicamente a sobrecarga das chamadas recursivas do *quicksort* em vetores muito pequenos. Ele provou que interromper a recursão para subsequências com tamanho $\leqslant n_0$ e aplicar o *insertion sort* reduz significativamente o tempo total de execução. Nos resultados originais da década de 1970, a constante ideal encontrada para n_0 situava-se na faixa de 10 a 25 elementos (com

20 a 25 sendo o ponto ideal nos modelos computacionais analisados na época). Em arquiteturas modernas e linguagens atuais, esse limite costuma variar entre 10 e 15 devido ao comportamento de cache e otimizações de instrução do processador. Aqui, por conveniência, usamos 50.

Para simplificar a análise assumimos que na instância os elementos de S são distintos. Mostraremos que, com essa estratégia, o número de comparações entre elementos de S é $O(n \ln n)$ com alta probabilidade.

A análise desse algoritmo é um detalhamento da seguinte ideia: consideremos um elemento x de uma instância S para o algoritmo. Sejam $S_0 \coloneqq S$ e $S_1, S_2, \ldots, S_M$ as subsequências a que x pertence após cada particionamento durante uma execução. O i-ésimo particionamento é *bom* se o pivô não está entre os 10% menores nem entre os 10% maiores elementos de S_i, o que supomos, neste parágrafo, ocorrer com probabilidade exatamente $4/5$ e independente dos outros particionamentos, de modo que $|S_i|/10 \leqslant |S_{i+1}| \leqslant 9|S_i|/10$ e portanto x passa por no máximo $\log_{10/9}(n)$ particionamentos bons. Agora, a variável aleatória $M = M(x)$ não deve ser muito maior que $2\log_{10/9}(n)$ pois pelo Exercício 12, página 57, a probabilidade de ocorrerem menos que $\log_{10/9}(n)$ particionamentos bons em $2\log_{10/9}(n)$ particionamentos é menor que

$$\left(\frac{4}{5}\right)^{2\log_{10/9}(n)} < \left(\frac{9}{10}\right)^{2\log_{10/9}(n)} = \frac{1}{n^2}.$$

A cada particionamento o elemento não-pivô x é comparado uma única vez, com o pivô sorteado. Assim, o número total de comparações numa execução é a soma para todo x do número de particionamentos pelos quais x passa. Portanto, uma execução realiza mais que $2n\log_{10/9}(n)$ comparações somente se existe um x que passa por mais que $2\log_{10/9}(n)$ particionamentos o que ocorre com probabilidade no máximo $n(1/n^2) = 1/n$. Portanto, com alta probabilidade, o *quicksort* realiza $O(n \ln n)$ comparações.

As ordenações "na força bruta" das subsequências disjuntas com até 50 elementos também fazem comparações, mas são $O(1)$ comparações em cada uma e isso soma $O(n)$, o que não altera o resultado.

3.1 Dominação estocástica

Em muitas análises de algoritmos probabilísticos a distribuição exata de uma variável aleatória é complicada, mas sabemos que ela é "pelo menos tão grande quanto" (ou "no máximo tão grande quanto") uma variável cuja distribuição conhecemos bem. Por exemplo, no *quicksort* aleatorizado a probabilidade de um particionamento ser um sucesso muda a cada passo, mas sabemos que ela nunca é menor que uma constante p. A *dominação estocástica* formaliza essa comparação.

Intuitivamente, a dominação estocástica captura a ideia de que uma variável "tende a assumir valores maiores" do que a outra. Para variáveis aleatórias reais, ela é definida em termos de probabilidades de cauda, ou equivalentemente em termos de funções de distribuição acumulada.

Definição 3.1: Dominação estocástica

Sejam X e Y variáveis aleatórias reais (não necessariamente definidas no mesmo espaço de probabilidade). Dizemos que X ***domina estocasticamente*** Y, e escrevemos $X \succeq Y$, se

$$\mathbb{P}[\,X > t\,] \geqslant \mathbb{P}[\,Y > t\,]$$

para todo $t \in \mathbb{R}$.

Observemos que a definição compara apenas as *distribuições*; nada é dito sobre a relação entre os valores de X e Y numa mesma realização do experimento. Na verdade, X e Y podem até ser independentes, e nesse caso pode ocorrer $X < Y$ com probabilidade positiva, mesmo com $X \succeq Y$.

Por exemplo, se $X \sim \text{Bernoulli}(p)$ e $Y \sim \text{Bernoulli}(q)$ com $p \geqslant q$. Para $t < 0$ as duas probabilidades $\mathbb{P}[\,X > t\,] = \mathbb{P}[\,Y > t\,]$ valem 1; para $0 \leqslant t < 1$ temos $\mathbb{P}[\,X > t\,] = p \geqslant q = \mathbb{P}[\,Y > t\,]$; para $t \geqslant 1$ ambas valem 0. Logo $X \succeq Y$.

Exemplo 3.1: Quando Poisson $\succeq$ Bernoulli

Seja X uma variável aleatória discreta representando a contagem de eventos e $\lambda \in (0, \infty)$.
Dizemos que X segue uma ***distribuição de Poisson*** com parâmetro de taxa λ, denotado por $X \sim \text{Poisson}(\lambda)$, se tem lei

$$\mathbb{P}_X(\,k\,) = \frac{\lambda^k e^{-\lambda}}{k!}, \quad k \in \{\,0, 1, \dots\,\}.$$

Sejam $X \sim \text{Poisson}(\lambda)$ e $Y \sim \text{Bernoulli}(p)$ ($p \in (0,1)$).

- Para $t < 0$, $\mathbb{P}[\,X > t\,] = \mathbb{P}[\,Y > t\,] = 1$.
- Para $0 \leqslant t < 1$, $\mathbb{P}[\,X > t\,] = \mathbb{P}[\,X \geqslant 1\,] = 1 - \mathrm{e}^{-\lambda}$ e $\mathbb{P}[\,Y > t\,] = p$.
- Para $t \geqslant 1$, $\mathbb{P}[\,X > t\,] \geqslant 0 = \mathbb{P}[\,Y > t\,]$.

Assim, $\mathbb{P}[\,X > t\,] \geqslant \mathbb{P}[\,Y > t\,]$ se e somente se

$$1 - \mathrm{e}^{-\lambda} \geqslant p \Leftrightarrow \lambda \geqslant -\ln(1-p)$$

logo, $X \succeq Y$ se, e somente se, $\lambda \geqslant \ln\big((1-p)^{-1}\big)$.

Escrevemos $X \overset{d}{=} Y$ para denotar que

$$\mathbb{P}[\, X \leqslant t \,] = \mathbb{P}[\, Y \leqslant t \,]$$

para todo $t \in \mathbb{R}$, e dizemos que as variáveis aleatórias X e Y são ***iguais em distribuição***.

Exemplo 3.2: Dominação entre geométricas

Sejam $0 < q \leqslant p < 1$. Se $Y \sim \text{Geom}(q)$ e $X \sim \text{Geom}(p)$, então $\mathbb{P}[\, Y > j \,] = (1-q)^j \geqslant (1-p)^j = \mathbb{P}[\, X > j \,]$. Portanto, $Y \geq X$, ou seja, um sucesso mais provável chega mais cedo.

3.1.1 *Acoplamento*

Para comparar duas variáveis aleatórias, podemos colocá-las no mesmo experimento aleatório, de modo que possamos observar diretamente quando elas diferem. Um acoplamento cria uma dependência entre elas sem alterar suas distribuições individuais.

Suponha que $X \sim \text{Bernoulli}(p)$ e $Y \sim \text{Bernoulli}(q)$, com $p \geqslant q$. Podemos gerar (veja Exemplo 2.12) uma única variável $U \sim \text{U}[0,1]$ e definir

$$X' := \mathbb{1}_{[U \leqslant p]}, \qquad Y' := \mathbb{1}_{[U \leqslant q]}.$$

Assim, $X' \sim \text{Bernoulli}(p)$ e $Y' \sim \text{Bernoulli}(q)$ no mesmo espaço de probabilidade, como desejado. Ademais, temos algo interessante: $Y'(\omega) \leqslant X'(\omega)$ para todo ω, pois $[U \leqslant q] \subseteq [U \leqslant p]$. Em outras palavras, o par (Y', X') nunca assume o valor $(1, 0)$.

Note que $Y' \leqslant X'$ é uma propriedade do par construído, e não de X e Y (que podem ser, por exemplo, independentes). O que se conclui sobre X e Y é que, para toda função h não decrescente, $\mathbb{E}(\, h(Y)\,) \leqslant \mathbb{E}(\, h(X)\,)$, pois esses valores *dependem apenas das distribuições* de X e Y.

A caracterização a seguir é a que mais usamos na prática: dominação estocástica equivale a poder construir, num mesmo espaço de probabilidade, variáveis X' e Y' com as mesmas distribuições de X e Y, respectivamente, tais que $Y' \leqslant X'$ com probabilidade 1.[1] Construir duas variáveis com distribuições dadas num mesmo espaço de probabilidade é chamado de ***acoplamento***.

Teorema 3.1: teorema de Strassen para ordem estocástica na reta

Para variáveis aleatórias reais X e Y, vale $X \geq Y$ se, e somente se, existem variáveis aleatórias $X' \overset{d}{=} X$ e $Y' \overset{d}{=} Y$ definidas num mesmo espaço de probabilidade tais que $Y' \leqslant X'$ com probabilidade 1.

[1] Se $Y' \leqslant X'$ vale fora de um conjunto N com $\mathbb{P}(\, N\,) = 0$, defina $X'' := X' \mathbb{1}_{\overline{N}}$ e $Y'' := Y' \mathbb{1}_{\overline{N}}$, isto é, ambas valem 0 em N. Como N tem probabilidade zero, X'' e Y'' têm as mesmas distribuições de X' e Y', e agora $Y'' \leqslant X''$ vale para todo ω: em N por serem ambas nulas, e fora de N porque nada mudou. Assim, exigir $Y' \leqslant X'$ com probabilidade 1 ou para todo ω dá o mesmo resultado.

Demonstração. ($\Rightarrow$) Sejam $F_X(t) = \mathbb{P}[\, X \leqslant t \,]$ e $F_Y(t) = \mathbb{P}[\, Y \leqslant t \,]$ as funções de distribuição de X e Y. Para uma função de distribuição F qualquer e $u \in (0,1)$, seja

$$F^{-1}(u) := \inf\{\, t : F(t) \geqslant u \,\}$$

a função quantil (finita para $u \in (0,1)$).

Se $U \sim \mathrm{U}(0,1)$, então $F^{-1}(U)$ tem função de distribuição F, pela Proposição 2.10.

Da hipótese $X \geq Y$ temos $F_X(t) \leqslant F_Y(t)$ para todo t. Assim, se $F_X(t) \geqslant u$ então $F_Y(t) \geqslant u$, isto é, $\{\, t : F_X(t) \geqslant u \,\} \subseteq \{\, t : F_Y(t) \geqslant u \,\}$, e o ínfimo do conjunto menor é o maior: $F_X^{-1}(u) \geqslant F_Y^{-1}(u)$ para todo $u \in (0,1)$. Tomando $X' = F_X^{-1}(U)$ e $Y' = F_Y^{-1}(U)$, com o *mesmo* U, temos $X' \stackrel{d}{=} X$, $Y' \stackrel{d}{=} Y$ e $Y' \leqslant X'$ sempre que $U \in (0,1)$, isto é, com probabilidade 1.

($\Leftarrow$) Se $Y' \leqslant X'$ com probabilidade 1, então, para todo t, o evento $[Y' > t]$ está contido em $[X' > t]$ a menos de um conjunto de probabilidade zero, logo

$$\mathbb{P}[\, Y > t \,] = \mathbb{P}[\, Y' > t \,] \leqslant \mathbb{P}[\, X' > t \,] = \mathbb{P}[\, X > t \,].$$

Portanto $\mathbb{P}[\, X > t \,] \geqslant \mathbb{P}[\, Y > t \,]$ para todo t, isto é, $X \geq Y$. □

Corolário 3.1

Se $X \geq Y$, então $\mathbb{E}Y \leqslant \mathbb{E}X$ (quando as esperanças existem) e, mais geralmente, $\mathbb{E}f(Y) \leqslant \mathbb{E}f(X)$ para toda função f não decrescente. Além disso, $\mathbb{P}[\, X \leqslant k \,] \leqslant \mathbb{P}[\, Y \leqslant k \,]$ para todo k.

Demonstração. Tome o acoplamento $Y' \leqslant X'$. Como f é não decrescente, $f(Y') \leqslant f(X')$ e a monotonicidade da esperança dá o resultado. A última afirmação é o complementar da definição. □

O corolário é o que justifica, nas análises, passar de uma variável complicada para uma variável simples. Basta que a simples esteja do lado correto da desigualdade.

Exemplo 3.3: Dominação entre Binomiais

Se $X \sim \text{Binomial}(m,p)$ e $Y \sim \text{Binomial}(m,q)$ com $1 \geqslant p \geqslant q \geqslant 0$, então $X \geq Y$.
Sejam $U_1, \ldots, U_m$ independentes e uniformes em $[0,1]$ e defina

$$B_i = \mathbb{1}_{[U_i \leqslant p]} \quad \text{e} \quad C_i = \mathbb{1}_{[U_i \leqslant q]}, \qquad i = 1, \ldots, m.$$

Como as U_i são independentes, $B_1, \ldots, B_m$ são independentes com distribuição Bernoulli(p), e $C_1, \ldots, C_m$ são independentes

com distribuição Bernoulli(q). Portanto

$$X' := \sum_{i=1}^{m} B_i \sim \text{Binomial}(m,p) \quad \text{e} \quad Y' := \sum_{i=1}^{m} C_i \sim \text{Binomial}(m,q),$$

isto é, $X' \stackrel{d}{=} X$ e $Y' \stackrel{d}{=} Y$. (Note que B_i e C_i não são independentes, pois usam o mesmo U_i; isso é o que se deseja e não afeta as distribuições de X' e Y'.)
Como $q \leqslant p$, vale $[U_i \leqslant q] \subseteq [U_i \leqslant p]$, logo $C_i \leqslant B_i$ para todo i e todo ω. Somando, $Y' \leqslant X'$. Pelo Teorema, $X \geq Y$.

3.1.2 *Dominação estocástica na análise do QS*

Como dito acima, a ideia é estimar quão longa é a cadeia de subsequências $S, S'_1, S'_2, \ldots, S'_M$ obtidas por particionamento e que contêm um elemento fixo, mas arbitrário x. Se cada particionamento fosse um sucesso com probabilidade p fixa, independentemente do histórico de particionamentos, então estaríamos no caso de estimar quantos particionamentos até ocorrer um sucesso, que sabemos se tratar de uma variável geométrica de média $1/p$. Como o número de sucessos é limitado, digamos que por ℓ, então queremos estimar o número de particionamentos até ocorrer o $(\ell+1)$-ésimo sucesso em uma sequência de experimentos independentes de Bernoulli com parâmetro p, uma binomial negativa de parâmetros $\ell+1$, p (cf. 2.11).

Entretanto, assumindo que sucesso resulta em não escolher o pivô entre os 10% menores nem entre os 10% maiores, se a subsequência tem 100 elementos, então a probabilidade de sucesso é 0,8, mas se a subsequência tem 51 elementos, então a probabilidade de sucesso é $(\lfloor 0{,}9 \cdot 51 \rfloor - \lceil 0{,}1 \cdot 51 \rceil)/51 \approx 0{,}765$ devido aos arredondamentos. As tentativas *não* são independentes, e a probabilidade de sucesso de cada uma depende do que aconteceu antes. O que sabemos é apenas que, dado qualquer histórico, a probabilidade de sucesso é *pelo menos* uma constante $\alpha \in (0,1)$.

Lema 3.1

Sejam $Z_1, Z_2, \ldots$ variáveis com valores em $\{0,1\}$ tais que, para todo i e todo histórico $(z_1, \ldots, z_{i-1})$ de probabilidade positiva,

$$\mathbb{P}[\, Z_i = 1 \mid Z_1 = z_1, \ldots, Z_{i-1} = z_{i-1} \,] \geqslant \alpha.$$

Então

(a) o número de sucessos em m tentativas, $\sum_{i=1}^{m} Z_i$, domina estocasticamente uma Binomial(m, α);

(b) o número de tentativas até o r-ésimo sucesso é dominado estocasticamente por uma binomial negativa de parâmetros (r, α). Em particular, o número esperado de tentativas até o r-ésimo sucesso é no máximo r/α.

Demonstração. Para todo $i \geqslant 1$ tome

$$U_i \sim \mathrm{U}(0,1), \quad Y_i = \mathbb{1}_{[U_i \leqslant \alpha]}, \quad Z_i = \mathbb{1}_{[U_i \leqslant p_i]}$$

em que $U_1, U_2, \ldots$ são independentes e $p_i \geqslant \alpha$ é a probabilidade condicional de sucesso na i-ésima tentativa dado o histórico $Z_1, \ldots, Z_{i-1}$.

Como U_i é independente de $U_1, \ldots, U_{i-1}$ e p_i é função dessas variáveis, $\mathbb{P}[\, Z_i = 1 \mid U_1, \ldots, U_{i-1} \,] = p_i$; assim, por indução, $(Z_i)_i$ tem a distribuição conjunta exigida. Além disso, $Y_i \sim \text{Bernoulli}(\alpha)$ e $Y_1, Y_2, \ldots$ são independentes, pois cada Y_i é função só de U_i.

Como $\alpha \leqslant p_i$, vale a inclusão de eventos $[U_i \leqslant \alpha] \subseteq [U_i \leqslant p_i]$, isto é, $Y_i = 1 \Rightarrow Z_i = 1$. Logo $Y_i \leqslant Z_i$ com probabilidade 1 (não apenas em distribuição)[2].

[2] é o mesmo U_i usado nas duas variáveis que torna essa comparação possível.

(a) Da desigualdade pontual acima,

$$\sum_{i=1}^{m} Z_i \geqslant \sum_{i=1}^{m} Y_i.$$

Ademais, as Y_i são independentes com $\mathbb{P}[\, Y_i = 1 \,] = \alpha$, de modo que $\sum_{i \leqslant m} Y_i \sim \text{Binomial}(m, \alpha)$.

(b) Seja τ_Z (resp. τ_Y) o instante do r-ésimo sucesso da sequência $(Z_i)_i$ (resp. $(Y_i)_i$). Como $Y_i \leqslant Z_i$ para todo i, todo sucesso de $(Y_i)_i$ é também sucesso de $(Z_i)_i$, logo o r-ésimo sucesso em $(Z_i)_i$ ocorre no máximo no instante do r-ésimo sucesso em $(Y_i)_i$. Portanto $\tau_Z \leqslant \tau_Y$. Como τ_Y é a soma de r geométricas independentes de parâmetro α, $\mathbb{E}\tau_Z \leqslant \mathbb{E}\tau_Y = r/\alpha$. □

Fixado um elemento x, os particionamentos de que ele participa formam uma sequência de tentativas cuja probabilidade de sucesso depende do tamanho corrente da subsequência de x, e portanto do passado. Dado qualquer histórico, essa probabilidade é pelo menos α (com α a constante da análise). O lema acima permite, então, trocar essa sequência por tentativas independentes de parâmetro α: o número de particionamentos até o $(\ell + 1)$-ésimo sucesso tem esperança no máximo $(\ell + 1)/\alpha$. Disso podemos deduzir o número esperado de comparações pelas quais passa x sem precisar da distribuição exata do número de particionamentos.

3.2 *Análise do quicksort probabilístico*

O particionamento (ou pivotamento) de S nas linhas 4, 5, 6 e 7 do algoritmo acima é considerado um *sucesso* se $\min\{|S_E|, |S_D|\} \geqslant (1/10)|S|$, caso contrário, dizemos que o particionamento foi um fracasso. Um sucesso significa que o pivô não está entre os 10% maiores elementos da sequência particionada e nem está entre os 10% menores elementos da sequência particionada.

Para pivô de posto[3] r temos $|S_E| = r - 1$ e $|S_D| = |S| - r$. O número de postos para bons pivôs é, então, $\lfloor 0{,}9\,|S|\rfloor - \lceil 0{,}1\,|S|\rceil$. Como $\lfloor 0{,}9\,|S|\rfloor > 0{,}9\,|S| - 1$ e $\lceil 0{,}1\,|S|\rceil < 0{,}1\,|S| + 1$, o número de pivôs bons é maior que $0{,}8\,|S| - 2$, portanto, $p > 0{,}8 - 2/|S| \geqslant 0{,}76$ para $|S| > 50$. Por outro lado, $\lfloor 0{,}9\,|S|\rfloor - \lceil 0{,}1\,|S|\rceil \leqslant 0{,}8|S|$, portanto

$$0{,}76 < p \leqslant 0{,}8.$$

[3] ***posto*** é a posição do elemento na sequência ordenada.

Consideremos uma execução do *quicksort* com entrada $S = (x_1, x_2, \ldots, x_n)$. Fixado $i \in \{1, 2, \ldots, n\}$, seja X_i o número de comparações entre o elemento x_i da entrada e algum pivô durante toda uma execução do algoritmo. Em cada particionamento x_i é comparado uma única vez (com o pivô) e se x_i é escolhido pivô então: (1) cada elemento da subsequência da qual x_i pertence é comparado com ele e tais comparações são contabilizadas pelos outros elementos e (2) a partir daí x_i nunca mais participará de um particionamento e nunca mais será comparado com outro elemento de S.

Exercício 13. Mostre que x_i participa de no máximo $\lfloor \log_{10/9} n \rfloor$ particionamentos com sucesso.

Fixemos x_i e escrevamos $\ell := \lfloor \log_{10/9} n \rfloor$. O tamanho da subsequência que contém x_i muda a cada particionamento, e com ele a probabilidade de sucesso. Seja s_k o tamanho da subsequência que contém x_i imediatamente antes do k-ésimo particionamento.

Lembremos que toda subsequência com no máximo 50 elementos é ordenada por força bruta; assim, enquanto x_i participa de particionamentos, a subsequência que o contém tem mais de 50 elementos.

Suponha conhecido tudo o que aconteceu nos $k - 1$ primeiros particionamentos de x_i (tamanhos das subsequências e pivôs sorteados). Isso determina s_k. Dado s_k, o pivô é escolhido uniformemente entre os s_k postos, e portanto a probabilidade de o k-ésimo particionamento ser um sucesso depende apenas de s_k. Como $s_k > 50$ (pois o k-ésimo particionamento é real), ela é maior que 0,76.

O Lema 3.1, porém, pede essa cota sabendo apenas quais dos $k - 1$ primeiros particionamentos foram sucessos ou fracassos, o que é menos informação. Ela continua valendo: vários históricos completos são compatíveis com a mesma sequência de sucessos e fracassos, e a pro-

babilidade de sucesso no k-ésimo particionamento, sabendo só essa sequência, é uma média ponderada das probabilidades correspondentes a esses históricos. Como todas são maiores que 0,76, a média também é.

Para que a análise não dependa do instante em que x_i deixa de participar de particionamentos (por ter sido escolhido pivô ou por ter caído no caso base), imaginamos que, a partir daí, x_i continua participando de particionamentos *fictícios*, cada um deles com sucesso com probabilidade 0,76 *independentemente* do passado. Assim, para cada x_i está definida uma sequência infinita de particionamentos (os reais, seguidos dos fictícios), cada um com probabilidade condicional de sucesso pelo menos 0,76 dados os resultados (sucesso ou fracasso) dos particionamentos anteriores (que é exatamente a hipótese do Lema 3.1).

Seja M_i o número de particionamentos reais de que x_i participa, e seja τ_i o instante do $(\ell+1)$-ésimo sucesso na sequência completada.

Pelo Exercício, os M_i primeiros particionamentos da sequência completada, que são os reais, contêm no máximo ℓ sucessos. Logo o $(\ell+1)$-ésimo sucesso, no instante τ_i, não está entre eles, assim $\tau_i > M_i$.

Pelo Lema 3.1(b), com $\alpha = 0{,}76$ e $r = \ell+1$,

$$\mathbb{E}\tau_i \leqslant \frac{\ell+1}{0{,}76} < \frac{10}{7}(\ell+1) \leqslant 2\ell,$$

onde a última desigualdade vale porque $\ell \geqslant 37 \geqslant 3$ para $n > 50$.

Em cada particionamento de que participa sem ser o pivô, x_i é comparado uma única vez com o pivô; portanto o número X_i de comparações de x_i com pivôs satisfaz $X_i \leqslant M_i \leqslant \tau_i$. Pela monotonicidade da esperança,

$$\mathbb{E}X_i \leqslant \mathbb{E}\tau_i < 2\ell.$$

O número total de comparações com pivôs durante toda a execução é $T := \sum_{i=1}^{n} X_i$ e, pela linearidade da esperança, $\mathbb{E}T < 2n\ell$. Em resumo,

$$\mathbb{E}X_i < 2\lfloor \log_{\frac{10}{9}} n \rfloor \quad \text{e} \quad \mathbb{E}T < 2n\lfloor \log_{\frac{10}{9}} n \rfloor. \tag{3.1}$$

Além disso, as subsequências disjuntas ordenadas na força-bruta na linha 2 fazem, cada uma, $O(1)$ comparações, contribuindo no total com $O(n)$ comparações que, somadas às $O(n \ln n)$ de (3.1), totalizam $O(n \ln n)$ comparações.

Lema 3.2: O número esperado de comparações do QS

O número esperado de comparações entre elementos de uma sequência com n elementos numa execução do *quicksort* aleatorizado é $O(n \ln n)$. □

Da disciplina Análise de Algoritmos sabemos que todo algoritmo de ordenação baseado em comparação realiza $\Omega(n \ln n)$ comparações para ordenar n elementos, ou seja, em esperança o *quicksort* aleatorizado é o melhor possível (Cormen et al., 2009). Porém, saber que um algoritmo é bom em média não nos garante que ele é bom quase sempre. Vamos mostrar que com alta probabilidade o desempenho do algoritmo está próximo da média.

Teorema 3.2

O número de comparações numa execução do quicksort aleatorizado com uma entrada de tamanho n é $O(n \ln n)$ com probabilidade $1 - O(n^{-33})$.

Demonstração. Definimos

$$\begin{aligned} \ell &\coloneqq \lfloor \log_{10/9} n \rfloor \\ L &\coloneqq 12\lfloor \log_{\frac{10}{9}} n \rfloor = 12\ell \\ F &\coloneqq L - \ell = 11\ell. \end{aligned}$$

Consideramos o evento $[X_i > L]$ que, segundo (3.1), diz que o elemento x_i foi comparado a um pivô mais do que seis vezes o valor esperado.

Como $X_i \leqslant M_i$, o evento $[X_i > L]$ implica que x_i participa de mais que L particionamentos reais (não fictícios); em particular, os primeiros L particionamentos de sua sequência completa são todos reais. Pelo Exercício 13, x_i tem no máximo ℓ sucessos reais ao longo de toda a execução, logo, nesse evento, há no máximo ℓ sucessos entre os primeiros L particionamentos da sequência completada.

Tomemos $Z_k^{(i)}$ o indicador de sucesso do k-ésimo particionamento de x_i e W_i o número de sucessos entre esses L particionamentos, isto é, $W_i = \sum_{k \le L} Z_k^{(i)}$. Então

$$[X_i > L] \subseteq [W_i \leqslant \ell].$$

Pelo Lema 3.1(a), com $\alpha = 0{,}76$ e $m = L$ tentativas, W_i domina estocasticamente uma Binomial$(L, 0{,}76)$, portanto

$$\begin{aligned} \mathbb{P}[\, X_i > L \,] \leqslant \mathbb{P}[\, W_i \leqslant \ell \,] \leqslant \mathbb{P}[\, \text{Binomial}(L, 0{,}76) \leqslant \ell \,] \\ = \sum_{j=F}^{L} \binom{L}{j} (0{,}24)^j (0{,}76)^{L-j}. \end{aligned}$$

Usando o limitante usual para o coeficiente binomial (veja (d.2)), para $j \geqslant F$,

$$\binom{L}{j}(0{,}24)^j(0{,}76)^{L-j} \leqslant \left(\frac{\mathrm{e}L}{j} \cdot \frac{0{,}24}{0{,}76}\right)^j (0{,}76)^L \leqslant \left(\frac{\mathrm{e}L}{F} \cdot \frac{0{,}24}{0{,}76}\right)^j (0{,}76)^L.$$

Como $L/F = 12/11$ e $0{,}24/0{,}76 = 6/19$,

$$\mathrm{e} \cdot \frac{L}{F} \cdot \frac{0{,}24}{0{,}76} = \mathrm{e} \cdot \frac{12}{11} \cdot \frac{6}{19} = \frac{72\,\mathrm{e}}{209} < 0{,}9365 < 1.$$

Logo, para $c = \frac{72\mathrm{e}}{209}$

$$\begin{aligned}\mathbb{P}[\, X_i > L \,] &\leqslant (0{,}76)^L \sum_{j \geqslant F} c^j = (0{,}76)^L \, \frac{c^F}{1-c} \\ &= \frac{209}{209 - 72\mathrm{e}} \, (0{,}76)^{12\ell} \, c^{11\ell} < 16 \left((0{,}76)^{12} c^{11} \right)^{\ell}\end{aligned}$$

portanto, $\mathbb{P}[\, X_i > L \,] < 16\,(0{,}019)^{\ell}$.

Convertendo para potência de n, com $\ell > \log_{10/9}(n) - 1$,

$$(0{,}019)^{\ell} < (0{,}019)^{-1} (0{,}019)^{\log_{10/9}(n)} < 53 n^{\log_{10/9}(0{,}019)} < 53 n^{-37},$$

portanto $ProbEX_i > L < 848\, n^{-37} < n^{-34}$.

A probabilidade de existir i com $X_i > L$ é

$$\mathbb{P}\left(\bigcup_{i=1}^{n} [X_i > L] \right) < n \cdot n^{-34} = n^{-33},$$

logo, com probabilidade $1 - O(n^{-33})$, vale $X_i \leqslant 12 \lfloor \log_{10/9} n \rfloor$ para todo i, e nessa probabilidade o *quicksort* aleatorizado executa $O(n \ln n)$ comparações, incluídas as $O(n)$ comparações "força bruta" feitas na linha 2 do algoritmo. □

3.3 *Esperança condicional*

Sejam $(\Omega, \mathbb{P})$ um espaço de probabilidade discreto, A um evento desse espaço com probabilidade positiva e X uma variável aleatória real e integrável (ou apenas não negativa). A ocorrência de A implica uma nova medida $\mathbb{P}_A$ em Ω e temos uma nova lei, condicionada a A, para a variável X. A ***esperança condicional*** da variável X dado A é o valor médio de X com respeito à lei condicional

$$\mathbb{E}(\, X \mid A \,) = \sum_r r \mathbb{P}[\, X = r \mid A \,] = \sum_r r \mathbb{P}_A[X = r] = \sum_r r \mathbb{P}_{X|A}(r). \tag{3.2}$$

Por ser uma média de uma variável aleatória com respeito a uma distribuição, a esperança condicional usufrui das mesmas propriedades da esperança: se X e Y são integráveis, A um evento de probabilidade positiva, B um evento qualquer e $a, b \in \mathbb{R}$, então

1. $\mathbb{E}(\, c \mid A \,) = c$.
2. $\mathbb{E}(\, 1_B \mid A \,) = \mathbb{P}(\, B \mid A \,)$.

3. Se $X \leqslant Y$ então $\mathbb{E}(\ X \mid A\ ) \leqslant \mathbb{E}(\ Y \mid A\ )$.

4. $\mathbb{E}(\ aX + bY \mid A\ ) = a\,\mathbb{E}(\ X \mid A\ ) + b\,\mathbb{E}(\ Y \mid A\ )$.

5. Se X e A são independentes então $\mathbb{E}(\ X \mid A\ ) = \mathbb{E}X$. Ademais, $\mathbb{E}(\ XY \mid A\ ) = \mathbb{E}(\ X \mid A\ ) \cdot \mathbb{E}(\ Y \mid A\ )$ nem sempre decorre da independência global de X e Y, mas vale caso X e Y são independentes sob a distribuição condicionada[4] a A.

[4] $\mathbb{P}_A([X = x] \cap [Y = y]) = \mathbb{P}_A[X = x]\mathbb{P}_A[Y = y]$ para todos x, y

Sobre o último item acima, considere X e Y independentes, cada um com distribuição Bernoulli(1/2). A distribuição conjunta é uniforme sobre os 4 pares possíveis

$$\mathbb{P}[\,(X,Y) = (x,y)\,] = \frac{1}{4}, \quad (\forall x, y \in \{\,0,1\,\}).$$

Agora defina o evento $A \coloneqq \{\ X = Y\ \}$, ou seja, A ocorre quando X e Y são iguais. Temos

$$\mathbb{P}(\ A\ ) = \mathbb{P}(\ \{\ (0,0),(1,1)\ \}\ ) = \frac{1}{2}$$

logo $\mathbb{E}(\ X \mid A\ ) = 1/2$, $\mathbb{E}(\ Y \mid A\ ) = 1/2$ e $\mathbb{E}(\ XY \mid A\ ) = 1/2$. Nesse caso, globalmente, X e Y são independentes mas, ao condicionar em A eles se tornam dependentes. Isso mostra que a fatoração $\mathbb{E}(\ XY \mid A\ ) = \mathbb{E}(\ X \mid A\ ) \cdot \mathbb{E}(\ Y \mid A\ )$ não vale em geral, apesar de X e Y serem independentes globalmente, $1/2 \neq 1/4$ e o item 5 exige independência sob a lei condicionada a A (que aqui falha, já que A força $X = Y$).

Exemplo 3.4: Esperança da distribuição geométrica

Seja X o número de tentativas de Bernoulli até o primeiro sucesso, com probabilidade de sucesso p. Condicionando no primeiro resultado, seja A o evento "sucesso",

- A ocorre na primeira tentativa, então $X{=}1$;
- $\overline{A}$ ocorre na primeira tentativa, nesse caso, já gastamos 1 tentativa, então $X{=}1+Y$, com $Y{\sim}\text{Geom}(p)$ (o processo recomeça do zero). Portanto,

Assim,

$$\begin{aligned}\mathbb{E}(X) &= \sum_x x\mathbb{P}[X=x] \\ &= \sum_x x\left(\mathbb{P}[X=x \mid A]\mathbb{P}(A) + \mathbb{P}\left[X=x \,\middle|\, \overline{A}\right]\mathbb{P}\left(\overline{A}\right)\right) \\ &= \left(\sum_x x\mathbb{P}_A[X=x]\right)\mathbb{P}(A) + \left(\sum_x x\mathbb{P}_{\overline{A}}[X=x]\right)\mathbb{P}\left(\overline{A}\right) \\ &= \mathbb{E}(X \mid A)\mathbb{P}(A) + \mathbb{E}\left(X \,\middle|\, \overline{A}\right)\mathbb{P}(\overline{A})\end{aligned}$$

Agora, $\mathbb{E}(X \mid A)=1$ e $\mathbb{E}\left(X \,\middle|\, \overline{A}\right)=\mathbb{E}(Y)+1=\mathbb{E}(X)+1$, portanto $\mathbb{E}(X)=1\cdot p+(\mathbb{E}(X)+1)(1-p)$ e resolvendo para $\mathbb{E}X$

$$\mathbb{E}(X)=\frac{1}{p}.$$

Teorema 3.3: Lei de esperança total

Se Y é uma variável aleatória integrável, então

$$\mathbb{E}Y=\sum_{x\in S_X}\mathbb{E}(Y \mid X=x)\mathbb{P}[X=x]. \tag{3.3}$$

Demonstração. Seja Y uma variável aleatória integrável. Então,

$$\begin{aligned}\mathbb{E}Y &= \sum_{y\in S_Y} y\mathbb{P}[Y=y] \\ &= \sum_{y\in S_Y} y\left(\sum_{x\in S_X}\mathbb{P}([Y=y]\cap[X=x])\right) \\ &= \sum_{y\in S_Y}\sum_{x\in S_X} y\mathbb{P}[Y=y \mid X=x]\mathbb{P}[X=x] \\ &= \sum_{x\in S_X}\sum_{y\in S_Y} y\mathbb{P}[Y=y \mid X=x]\mathbb{P}[X=x] \\ &= \sum_{x\in S_X}\mathbb{E}(Y \mid X=x)\mathbb{P}[X=x]\end{aligned}$$

em que a troca das ordens de soma é pelo teorema de Tonelli–Fubini para séries (s.5). □

3.4 *Desigualdade de Markov*

A ***desigualdade de Markov*** tem um enunciado simples e a vantagem de valer em situações bem gerais, sem muitas hipóteses sobre a variá-

Andrey Markov (1856–1922) foi um matemático russo conhecido principalmente por suas contribuições no que foi posteriormente conhecido como Cadeias de Markov. Seu filho Andrey Markov Jr (1903–1979) ficou conhecido pelas contribuições em Teoria da Computação.

vel aleatória, o que a torna amplamente aplicável. Por outro lado, ela pode fornecer limitantes fracos que, às vezes, são pouco úteis.

Teorema 3.4: Desigualdade de Markov

Se X é uma variável aleatória integrável,

$$\mathbb{P}[\,|X| \geqslant t\,] \leqslant \frac{\mathbb{E}|X|}{t} \tag{3.4}$$

para todo $t > 0$. Em particular, se X assume valores não negativos,

$$\mathbb{P}[\,X \geqslant t\,] \leqslant \frac{\mathbb{E}X}{t} \tag{3.5}$$

para todo $t > 0$.

Demonstração. De X integrável $|X|$ também é integrável. Ademais, $|X| \geqslant |X| \cdot \mathbb{1}_{|X| \geqslant t}$, para todo $t > 0$, logo a desigualdade de Markov segue da monotonicidade da esperança

$$\mathbb{E}(|X|) \geqslant \mathbb{E}(|X|\mathbb{1}_{|X|\geqslant t}) \geqslant \mathbb{E}(t\mathbb{1}_{|X|\geqslant t}) = \\ = t\,\mathbb{E}(\mathbb{1}_{[|X|\geqslant t]}) = t\,\mathbb{P}[\,|X| \geqslant t\,]. \qquad \square$$

Há casos onde essa desigualdade é justa, como mostra o seguinte exemplo. Seja X uma variável aleatória que assume o valor 0 com probabilidade 99/100 e assume o valor 10 com probabilidade 1/100. Então $\mathbb{E}X = 1/10$ e

$$\mathbb{P}[\,X \geqslant 10\,] \leqslant \frac{1/10}{10} = \frac{1}{100}$$

que é exatamente a probabilidade do evento $[X \geqslant 10]$.

Análise do QS usando a desigualdade de Markov

Vejamos uma prova alternativa de que em uma execução do *quicksort* probabilístico o número esperado de comparações entre elementos de uma instância com n elementos é $O(n \ln n)$ com alta probabilidade. *Nesta seção, para ilustrar a robustez do método de Markov mesmo no pior caso de recursão, consideramos a variante do algoritmo cujo caso base é $|S| \leqslant 2$ (isto é, a recursão prossegue para toda subsequência com 3 ou mais elementos).*

Para pivô de posto r temos $|S_{\text{E}}| = r - 1$ e $|S_{\text{D}}| = |S| - r$. O número de postos para bons pivôs é $\lfloor 0{,}9\,|S| \rfloor - \lceil 0{,}1\,|S| \rceil$. Diferentemente do caso $|S| > 50$, aqui não há uma cota inferior próxima de 0,8: o pior caso ocorre no menor tamanho recursivo, $|S| = 3$, onde há um único posto bom (o do meio) entre três, dando assim,

$$\frac{1}{3} \leqslant p \leqslant \frac{4}{5}.$$

Consideremos um elemento x de uma instância S para o algoritmo 3.1 e $S_0 = S, S_1, S_2, \ldots, S_M$ as subsequências a que x pertence após cada particionamento durante uma execução.

Sorteando um pivô o i-ésimo particionamento é *bom* se $|S_i|/10 \leqslant |S_{i+1}| \leqslant 9|S_i|/10$ o que ocorre com probabilidade $0{,}33 < p \leqslant 0{,}8$.

Fixado $|S_i| = k$, o particionamento cai em um de dois casos, dependendo do pivô sorteado: se for *sucesso* (o que ocorre com probabilidade p), então, por definição, $|S_{i+1}| \leqslant 9k/10$; caso contrário (*fracasso*, com probabilidade $1 - p$), não há garantia melhor que a trivial $|S_{i+1}| \leqslant |S_i| = k$. Tomando a esperança condicional em cada um desses dois casos e combinando-as segundo suas probabilidades,

$$\mathbb{E}(\,|S_{i+1}| \mid |S_i| = k\,) \leqslant \underbrace{p \cdot \frac{9k}{10}}_{\text{sucesso}} + \underbrace{(1-p)\cdot k}_{\text{fracasso}} = \left(1 - \frac{p}{10}\right)k,$$

onde a última igualdade é apenas a fatoração de k nos dois termos. Como $1 - p/10$ é *decrescente* em p, o maior valor possível dessa cota e, portanto, o pior caso, ocorre no menor p garantido. Com $p \geqslant 1/3$

$$\left(1 - \frac{p}{10}\right)k \leqslant \left(1 - \frac{1}{30}\right)k = \frac{29}{30}\,k.$$

Agora, podemos usar a lei de esperança total para escrever

$$\begin{aligned}
\mathbb{E}|S_{i+1}| &= \sum_k \mathbb{E}(\;|S_{i+1}| \;\mid\; |S_i| = k\;)\,\mathbb{P}[\,|S_i| = k\,] \\
&\leqslant \sum_k \frac{29}{30}\,k\,\mathbb{P}[\,|S_i| = k\,] \\
&= \frac{29}{30}\sum_k k\,\mathbb{P}[\,|S_i| = k\,] \\
&= \frac{29}{30}\,\mathbb{E}|S_i|
\end{aligned}$$

iterando essa desigualdade, partindo de $|S_0| = |S| = n$, concluímos

$$\mathbb{E}|S_M| < \left(\frac{29}{30}\right)^M n.$$

Queremos escolher M de modo que essa cota seja pequena o bastante para, somada sobre os n elementos da instância, ainda dar uma probabilidade de falha que tende a zero. Para isso, tomando $M := a \log_{30/29} n$, para uma constante $a > 0$ a ser escolhida,

$$\left(\frac{29}{30}\right)^M n = \left(\frac{29}{30}\right)^{a \log_{30/29} n} n = \left(\frac{30}{29}\right)^{-a \log_{30/29} n} n = n^{-a} \cdot n = n^{1-a}.$$

Assim, $\mathbb{E}|S_M| < n^{1-a}$. Para que essa probabilidade, somada sobre os n elementos da instância, ainda tenda a zero; por isso fixamos, desde já, $a \geqslant 3$.

Pela desigualdade de Markov, aplicada à variável aleatória (não negativa) $|S_M|$ com $t = 2$ (o limiar do caso base)

$$\mathbb{P}[\,|S_M| > 2\,] \leqslant \frac{\mathbb{E}|S_M|}{2} < \frac{n^{1-a}}{2},$$

ou seja, a probabilidade de que o elemento fixado x ainda esteja participando de particionamentos após $M = a \log_{30/29} n$ passos é menor que $n^{1-a}/2$.

Pela união desse evento sobre os n elementos de S, a probabilidade de que *exista* algum $x \in S$ que passe por mais que $a \log_{30/29} n$ particionamentos é

$$< n \cdot \frac{n^{1-a}}{2} = \frac{n^{2-a}}{2}$$

ou seja, o número de comparações efetuadas pelo *quicksort* é $O(n \ln n)$ com probabilidade pelo menos

$$1 - \frac{n^{2-a}}{2} \overset{(a=3)}{\geqslant} 1 - \frac{1}{2n}.$$

3.5 *Desigualdade de Chebyshev*

A próxima desigualdade é conhecida por ***desigualdade de Chebyshev***, também conhecida por ***desigualdade de Bienaymé–Chebyshev*** . Da equação (3.5) obtemos a desigualdade de Chebyshev

$$\mathbb{P}[\,|X| \geqslant t\,] = \mathbb{P}\big[\,X^2 \geqslant t^2\,\big] \leqslant \frac{\mathbb{E}(X^2)}{t^2} \tag{3.6}$$

que é mais conhecida na forma enunciada a seguir.

Pafnuty Lvovich Chebyshev (1821–1894) foi um matemático russo conhecido por suas contribuição à Probabilidade, dentre seus alunos vários são matemáticos reconhecidos e um deles foi Andrey Markov. Irénée-Jules Bienaymé (1796–1878) foi um estatístico francês, contribuiu para a Probabilidades e o desenvolvimento da Estatística e suas aplicações.

Teorema 3.5: desigualdade de Chebyshev

Para toda constante $t>0$ e toda variável aleatória X com quadrado integrável temos

$$\mathbb{P}[\,|X - \mathbb{E}X| \geqslant t\,] \leqslant \frac{\mathrm{Var}(X)}{t^2}. \tag{3.7}$$

Demonstração. Segue da desigualdade (3.6) com a variável aleatória $X - \mathbb{E}X$. □

A desigualdade (3.7) pode ser justa como no seguinte exemplo. Seja X uma variável aleatória que assume o valor 0 com probabilidade $q \in (0,1)$ e os valores 1 e -1 com probabilidade $p/2$ cada, com $p = 1 - q$. A esperança de X é 0 e a variância é p. A probabilidade do evento $[|X| \geqslant 1]$ é p de modo que

$$p = \mathbb{P}[\,|X - 0| \geqslant 1\,] \leqslant \frac{\mathrm{Var}(X)}{1^2} = p.$$

Quando a variância está definida mas não é finita, a desigualdade de Chebyshev não é útil. Por exemplo se X tem lei $\mathbb{P}_X(z) = c/z^3$, para $c > 0$ constante e $k \in \mathbb{Z}^+$, então $\mathbb{E}(X) = c\pi^2/6$ (veja (s.8)) e $\mathbb{E}(X^2) = +\infty$. Com $\mathrm{Var}(X) = \infty$, a desigualdade de Chebyshev não dá informação, enquanto que pela desigualdade de Markov obtemos $\mathbb{P}[X \geqslant t] \leqslant c\pi^2/6t$.

Tomando o ***desvio padrão*** $\sigma_X = \sqrt{\mathrm{Var}(X)}$ e trocando t por $t\,\sigma_X > 0$ na desigualdade de Chebyshev, obtemos

$$\mathbb{P}[\,|X - \mathbb{E}X| \geqslant t\,\sigma_X\,] \leqslant \frac{1}{t^2}$$

e com $t\,\mathbb{E}X > 0$, obtemos

$$\mathbb{P}[\,|X - \mathbb{E}X| \geqslant t\mathbb{E}X\,] \leqslant \frac{\mathrm{Var}(X)}{t^2(\mathbb{E}X)^2} \leqslant \frac{\mathbb{E}(X^2)}{t^2(\mathbb{E}X)^2} \tag{3.8}$$

onde a segunda desigualdade segue do fato de

$$\frac{\mathrm{Var}(X)}{(\mathbb{E}X)^2} = \frac{\mathbb{E}(X^2)}{(\mathbb{E}X)^2} - 1. \tag{3.9}$$

Análise do QS usando a desigualdade de Chebyshev

Uma terceira estratégia para mostrar que T concentra em torno de sua média é aplicar a desigualdade de Chebyshev diretamente ao total T, em vez de tratar cada X_i separadamente e somar as probabilidades de falha. Isso requer conhecer (ou estimar) $\mathrm{Var}(T)$.

É um resultado conhecido na literatura (citado na seção 5.2.2, pág. 120 de Knuth, 1998, como consequência do exerc. 6.2.2-8) que a variância do número de comparações do *quicksort* aleatorizado satisfaz (Iliopoulos e Penman, 2010)

$$\mathrm{Var}(T) = \left(7 - \frac{2\pi^2}{3}\right)n^2 + O(n\log n) \approx 0{,}4203\,n^2.$$

Pela desigualdade de Chebyshev, para qualquer $t > 0$,

$$\mathbb{P}[\,|T - \mathbb{E}T| \geqslant t\,] \leqslant \frac{\mathrm{Var}(T)}{t^2}.$$

Tomando $t = c\,n\log n$ para uma constante $c > 0$, e usando $\mathbb{E}T = O(n\log n)$,

$$\mathbb{P}\left[\,T > \mathbb{E}T + c\,n\log n\,\right] \leqslant \frac{0{,}4203\,n^2}{c^2n^2\log^2 n} = \frac{0{,}4203}{c^2\log^2 n} \xrightarrow[n\to\infty]{} 0.$$

Ou seja, $T = O(n\log n)$ com probabilidade $1 - o(1)$.

3.6 *Exercícios*

Exercício 14. Em um treino, paraquedistas formam, de início, um grupo de n paraquedistas enfileirados nas posições $1, 2, \ldots, n$ dentro de um avião. Em cada etapa do treinamento, um paraquedista é

escolhido e seu grupo é dividido em dois grupos. A escolha é uniformemente ao acaso. O paraquedista escolhido cumprimenta todos os paraquedistas do seu grupo e salta do avião. A divisão do grupo em e dois é assim: um novo grupo formado pelos paraquedistas que se encontravam a esquerda daquele que pulou e o outro grupo formado pelos paraquedistas a direita.

O procedimento é repetido para cada um dos grupos restantes até que todos os grupos tenham um único paraquedista; esses últimos paraquedistas saltam, então, um a um. A ordem relativa dos paraquedistas dentro de cada grupo é sempre preservada.

Observe que, a partir do momento em que dois paraquedistas pertencem a grupos distintos, eles não se cumprimentam mais.

Prove que os paraquedistas das posições i e j, com $j > i$, se cumprimentam com probabilidade $2/(j - i + 1)$.

Exercício 15. Assuma que as instâncias para o *quicksort* padrão, sem sorteios, são as permutações de $(1, 2, \ldots, n)$. Demonstre que o o número médio de comparações para ordenar essa instâncias é $O(n \ln n)$ (dica: o exercício dos parquedistas).

Exercício 16. Considere o *quicksort* aleatorizado (Algoritmo 3.1) executando sobre uma sequência de n elementos distintos, mas com o limiar do caso base alterado de 50 para 100 elementos (ou seja, sequências com até 100 elementos são ordenadas na força bruta).

(a) Refaça o cálculo que leva à desigualdade $0{,}76 < p < 0{,}8$ feito no texto, obtendo os novos limitantes para a probabilidade p de um particionamento ser *bom* quando $|S| > 100$.

(b) Explique por que a mudança do limiar não altera a ordem de grandeza $O(n \ln n)$ do número esperado de comparações, mas pode alterar a constante multiplicativa na cota $\mathbb{E}T < 2n\lceil \log_{10/9} n \rceil$ de (3.1).

Exercício 17. No Lema 3.1, a hipótese é que a probabilidade *condicional* de sucesso, dado qualquer histórico, é pelo menos α. Considere a seguinte variante do particionamento do *quicksort*: suponha que, em vez de sortear o pivô uniformemente, o algoritmo sorteia o pivô de modo que a probabilidade de sucesso no i-ésimo particionamento de uma dada subsequência de x seja *exatamente* 0,7 se o particionamento anterior de x foi um sucesso, e 0,9 se foi um fracasso (mas sempre pelo menos 0,7).

(a) Verifique que as hipóteses do Lema 3.1 continuam satisfeitas com $\alpha = 0{,}7$, mesmo essa sequência de tentativas não sendo i.i.d.

(b) Usando o item (b) do lema, dê um limitante superior para o nú-

mero esperado de particionamentos necessários para x acumular $L+1 = 29$ sucessos.

(c) Explique, em uma frase, por que seria *errado* aplicar diretamente a fórmula da esperança de uma binomial negativa $BN(L{+}1, 0{,}7)$ para calcular exatamente (e não apenas limitar superiormente) o número esperado de particionamentos nesse cenário.

Exercício 18. Em uma execução do *quicksort* aleatorizado sobre uma entrada de tamanho n, seja T o número total de comparações entre elementos realizadas pelo algoritmo. Vimos em (3.1) que $\mathbb{E}T < 2n\lceil \log_{10/9} n \rceil$.

(a) Usando a desigualdade de Markov (Teorema 3.4), mostre que, para qualquer constante $c > 1$,

$$\mathbb{P}\Big[\, T \geqslant c \cdot 2n\lceil \log_{10/9} n \rceil \,\Big] \leqslant \frac{1}{c}.$$

(b) Em particular, tome $c = 100$. Conclua que a probabilidade de o *quicksort* realizar mais que $200\, n\lceil \log_{10/9} n \rceil$ comparações é no máximo 1%.

(c) Compare o limitante obtido no item anterior com o limitante do Teorema que afirma que T é $O(n \ln n)$ com probabilidade $1 - O(n^{-29})$. Qual dos dois resultados é mais forte para n grande? A desigualdade de Markov, sozinha, seria suficiente para provar esse teorema mais forte? Justifique.

(d) Explique, em termos gerais (sem repetir a conta), por que a desigualdade de Markov aplicada diretamente a T fornece um limitante muito mais fraco do que a análise feita no Teorema 3.2 via $\mathbb{P}[\, X_i > L \,]$ para cada elemento x_i individualmente, seguida de união de eventos. (Dica: pense em quantos "graus de liberdade", ou quantas variáveis aleatórias diferentes, cada abordagem usa.)

Exercício 19. Seja $Y \sim \text{Geom}(1/2)$. Mostre que $X \geq Y$ se, e só se, $\mathbb{P}[\, X > j \,] \geqslant 2^{-j}$ para todo inteiro $j \geqslant 0$, para toda X com valores nos naturais positivos.

Exercício 20. Mostre que a dominação estocástica é transitiva e que $Y \geq X$ e $X \geq Y$ implicam que $X \overset{d}{=} Y$.

Exercício 21. Considere, para cada elemento x_i da instância, a variável W_i igual ao número de particionamentos bem sucedidos entre os $L = 12\ell$ primeiros particionamentos sofridos por x_i, de modo que $\mathbb{E}(\, W_i \,) = \mu = L\alpha$ e $\text{Var}(\, W_i \,) \leqslant L\alpha(1-\alpha) = O(\ell)$.

O objetivo deste exercício é mostrar que, se tentarmos substituir a desigualdade de Chernoff por uma aplicação *ingênua* da desigualdade de Chebyshev a cada W_i individualmente, o argumento "por elemento + união de eventos" deixa de funcionar.

(a) Usando a desigualdade de Chebyshev (Teorema 3.5) com $t = \mu - \ell = O(\ell)$, mostre que

$$\mathbb{P}[\, W_i \leqslant \ell \,] \leqslant \frac{\mathrm{Var}(\, W_i \,)}{t^2} = O\left(\frac{1}{\ell}\right) = O\left(\frac{1}{\log n}\right).$$

(b) Aplicando a união de eventos sobre os n elementos $x_1, \ldots, x_n$ da instância, mostre que o limitante obtido no item (a) fornece apenas

$$\mathbb{P}[\, \exists i : \; W_i \leqslant \ell \,] \leqslant n \cdot O\left(\frac{1}{\log n}\right),$$

e explique por que essa cota é *inútil* (isto é, por que ela não tende a 0 quando $n \to \infty$).

(c) Compare a ordem de grandeza do desvio $t = \mu - \ell$ com a do desvio-padrão $\sqrt{\mathrm{Var}(\, W_i \,)}$ nesse regime. Explique, em termos gerais, por que o fato de ambos serem da mesma ordem ($t = \Theta(\ell)$ e o desvio-padrão $\Theta(\sqrt{\ell})$) faz com que o quadrado no denominador de Chebyshev não seja suficiente para compensar o fator n introduzido pela união de eventos.

(d) Conclua explicando por que, nesse argumento "por elemento + união", é necessário usar um limitante de cauda exponencial (como o de Chernoff) em vez de um limitante polinomial como o de Chebyshev.

Exercício 22 (*Seleção do k-ésimo menor elemento*). Dada uma sequência A de n números inteiros distintos e um inteiro k com $1 \leqslant k \leqslant n$, queremos encontrar o k-ésimo menor elemento de A.

Aquecimento

(a) Descreva uma solução simples para o problema, com tempo $O(n \log n)$ com alta probabilidade.

(b) Usando o particionamento do *quicksort*, o que se pode dizer se o pivô escolhido tem posto k?

(c) Dependendo da relação entre k e o posto r do pivô, existem três casos. Para cada um, diga onde está o k-ésimo menor elemento de A e qual deve ser o *novo* valor de k caso seja necessário continuar a busca em uma subsequência.

Projeto do algoritmo

(d) Com base no item anterior, escreva o pseudocódigo de um algoritmo recursivo QuickSelect(A, k) que escolhe um pivô *uniformemente ao acaso*. Deixe claros o caso base e o que é devolvido quando o pivô tem posto k.

(e) Prove, por indução forte no tamanho de A, que QuickSelect(A, k) devolve de fato o k-ésimo menor elemento de A, para todo k válido. Verifique que o novo valor de k em cada chamada recursiva é válido para a subsequência recebida.

(f) Quantas comparações são feitas na construção das subsequências à esquerda A_{E} e à direita A_{D} em uma chamada com uma sequência de tamanho m? Conclua que o número total de comparações é, no máximo, a soma dos tamanhos dos vetores recebidos em todas as chamadas recursivas.

Análise do pior caso

(g) Mostre que, para todo n, existem um valor de k e uma sequência de pivôs sorteados para os quais o algoritmo faz $\Theta(n^2)$ comparações. Por que isso não contradiz uma análise de tempo *esperado* linear? (Dica: qual é a probabilidade dessa sequência de pivôs?)

Análise do tempo esperado

Chame de chamada 0 a chamada inicial, com $|A| = n$. Seja Z_i o número de elementos do vetor recebido pela chamada i, com $Z_0 = n$. (Se o algoritmo já terminou antes da chamada i, defina $Z_i = 0$.) Como cada chamada descarta ao menos o pivô, $Z_i \leqslant \max\{n - i, 0\}$; em particular, $Z_i = 0$ para todo $i \geqslant n$.

(h) *Pivôs bons e ruins.* Dizemos que ocorre o evento "ruim" B na primeira partição (a da chamada 0) se $r < \lceil n/4 \rceil$ ou $r > \lceil 3n/4 \rceil$, em que r é o posto do pivô. Como r é uniforme em $\{1, \ldots, n\}$, mostre que

$$\mathbb{P}(B) \leqslant \frac{1}{2}.$$

(i) Mostre que, qualquer que seja k, $Z_1 \in \{0, r-1, n-r\}$. Conclua que $\mathbb{E}(Z_1 \mid B) \leqslant n$ (que garantia trivial você usa aqui?) e que $\mathbb{E}\left(Z_1 \,\middle|\, \overline{B}\right) \leqslant 3n/4$. Em que situação $Z_1 = 0$? (Se um evento condicionante tem probabilidade zero, o termo correspondente é simplesmente omitido.)

(j) Use a lei da esperança total para concluir que

$$\mathbb{E}Z_1 \leqslant \frac{n}{4}\mathbb{P}(B) + \frac{3n}{4} \leqslant \frac{7}{8}n.$$

(Dica: use $\mathbb{P}\left(\overline{B}\right) = 1 - \mathbb{P}(B)$; o resultado é crescente em $\mathbb{P}(B)$.)

(k) *Partições seguintes.* O vetor da chamada i resulta da partição feita pela chamada $i-1$, que recebe Z_{i-1} elementos, número que já é aleatório. Justifique que

$$\mathbb{E}(\ Z_i \mid Z_{i-1} = m\ ) \leqslant \frac{7}{8}\, m$$

e, usando novamente a lei da esperança total,

$$\mathbb{E}Z_i = \sum_{m=0}^{n} \mathbb{P}[\ Z_{i-1} = m\ ] \cdot \mathbb{E}(\ Z_i \mid Z_{i-1} = m\ ) \leqslant \frac{7}{8}\, \mathbb{E}Z_{i-1}.$$

(Dica: o pivô da chamada $i-1$ é sorteado uniformemente e independentemente de tudo o que aconteceu antes, e o argumento de (h)–(j) vale com m no lugar de n, qualquer que seja o passado e o valor de k. Saber apenas que $Z_{i-1} = m$ é saber menos que o passado completo: a probabilidade condicional correspondente é uma média ponderada de valores $\leqslant 7m/8$. Termos com $\mathbb{P}[\ Z_{i-1} = m\ ] = 0$ são omitidos da soma.)

(l) Conclua que para todo $i \geqslant 0$

$$\mathbb{E}Z_i \leqslant \left(\frac{7}{8}\right)^i n.$$

(m) Usando os itens (f) e (l), a linearidade da esperança (a soma é finita, pois $Z_i = 0$ para $i \geqslant n$) e a fórmula da soma de uma série geométrica finita, demonstre:

Para toda sequência A com n elementos distintos e todo $k \in \{1, \ldots, n\}$, QuickSelect(A, k) realiza menos de $8n$ comparações em esperança:

$$\mathbb{E}[\text{comparações}] \leqslant \mathbb{E}\Big[\sum_{i=0}^{n-1} Z_i\Big] = \sum_{i=0}^{n-1} \mathbb{E}Z_i \leqslant \sum_{i=0}^{n-1} \left(\tfrac{7}{8}\right)^i n = 8n\left(1 - \left(\tfrac{7}{8}\right)^n\right) < 8n.$$

(n) O que a desigualdade de Markov garante sobre a probabilidade do algoritmo fazer mais de $80n$ comparações?

Por fim, mas não finalmente

(o) A constante $7/8$ veio de escolher a faixa "$r \in [\lceil n/4\rceil, \lceil 3n/4\rceil]$" como pivô bom. Refaça a análise com a faixa $[\lceil n/3\rceil, \lceil 2n/3\rceil]$. Qual constante você obtém no lugar de $7/8$ e qual é a nova cota para o número esperado de comparações?

Alta probabilidade

Seja T o número de comparações feitas por QuickSelect(A, k). Até aqui limitamos $\mathbb{E}T$. Vamos agora limitar a cauda de T.

(p) *Da esperança à cauda.* Fixe uma constante $a > 1$ e defina

$$M := \lceil a \log_{8/7} n \rceil.$$

Usando o item (l), mostre que

$$\mathbb{E}Z_M \leqslant \left(\frac{7}{8}\right)^M n \leqslant n^{1-a}.$$

(q) *Markov.* A variável Z_M é não negativa. Use a desigualdade de Markov com limiar 1 para mostrar

$$\mathbb{P}[\, Z_M \geqslant 1 \,] \leqslant \mathbb{E}Z_M \leqslant n^{1-a}.$$

O que significa o evento $[Z_M = 0]$ em termos da execução do QuickSelect? Por que, ao contrário da análise da altura do *quicksort*, aqui não é preciso usar a desigualdade de união sobre os n elementos de A?

(r) *Escolha de a.* Explique por que, para a cota do item anterior tender a 0 quando $n \to \infty$, basta $a > 1$. Mais precisamente, $a = 1 + c$ dá probabilidade de falha $\leqslant n^{-c}$, isto é, probabilidade de sucesso $1 - O(n^{-c})$. Compare com o *quicksort*, onde a união sobre n elementos multiplica a cota por n e obriga a escolher a maior. Conclua que, com $a = 2$,

$$\mathbb{P}[\, Z_M = 0 \,] \geqslant 1 - \frac{1}{n}.$$

(s) *Do tamanho ao número de comparações.* No evento $[Z_M = 0]$, argumente que o QuickSelect faz no máximo M chamadas recursivas (as chamadas $0, \ldots, M-1$) e que, como a chamada i faz menos de $Z_i \leqslant n$ comparações,

$$T \leqslant \sum_{i=0}^{M-1} Z_i \leqslant Mn = O(n \log n) \quad \text{com probabilidade pelo menos } 1 - n^{1-a}.$$

Agora compare com a cota em esperança do item (m):

(i) Que cota para T a desigualdade de Markov, aplicada diretamente a $\mathbb{E}T < 8n$, garante com probabilidade de falha $1/n$? Por que ela é muito pior que $O(n \log n)$?

(ii) Use o evento complementar de $[Z_M = 0]$ e o fato de que sempre $T \leqslant n^2$ para mostrar que, com $a \geqslant 2$, $\mathbb{E}T = O(n \log n)$.

Conclua que a cota $O(n)$ em esperança e a cota $O(n \log n)$ com alta probabilidade são afirmações diferentes, e que nenhuma substitui a outra.

(t) *Para refletir (desafio).* Usando a desigualdade de Markov, a cota em esperança dá $\mathbb{P}[\, T \geqslant 16n \,] \leqslant \frac{1}{2}$. Mostre que não se pode esperar nada muito melhor com c constante: para todo c existe $\delta_c > 0$ tal que, para n suficientemente grande,

$$\mathbb{P}[\, T \geqslant cn \,] \geqslant \delta_c,$$

e portanto nenhuma cota do tipo "$T \leqslant cn$ com probabilidade $\geqslant 1 - 1/n$" pode valer. (Dica: tome $k = \lceil n/2 \rceil$ e $\eta = 1/(8c)$. Considere o evento em que, nas primeiras $\lfloor 1/(4\eta) \rfloor$ chamadas, o pivô tem posto entre os $\eta\,|\text{vetor}|$ menores. Mostre que, então, k continua dentro da parte direita, o vetor mantém tamanho pelo menos $3n/4$ e cada chamada faz $\Omega(n)$ comparações. Qual é a probabilidade desse evento?)

Observação. Essa cauda é uma propriedade do QuickSelect aleatorizado, e não uma limitação de Markov: algoritmos com escolha mais cuidadosa do pivô (amostragem de Floyd–Rivest, ou mediana das medianas) obtêm $O(n)$ também com alta probabilidade.

Variância do número de comparações do QS

Seja C_n o número de comparações do *quicksort* ao ordenar n elementos distintos, com pivô escolhido uniformemente. Seja $U_n \sim \mathrm{U}\{\, 0, \ldots, n-1 \,\}$. Então, em distribuição,

$$C_n \overset{d}{=} C_{U_n} + C'_{n-1-U_n} + n - 1, \tag{3.10}$$

onde, para cada k, C'_k é uma cópia independente de C_k (duas execuções físicas distintas do algoritmo) e independente de U_n. Escrevemos

$$\mu_n \coloneqq \mathbb{E}(\, C_n \,), \qquad s_n \coloneqq \mathbb{E}(\, C_n^2 \,), \qquad v_n \coloneqq \mathrm{Var}(\, C_n \,) = s_n - \mu_n^2,$$

com $C_0 = C_1 = 0$, e

$$H_n \coloneqq \sum_{j=1}^{n} \frac{1}{j}, \qquad H_n^{(2)} \coloneqq \sum_{j=1}^{n} \frac{1}{j^2}.$$

Condicionando em $U_n = k$ em (3.10),

$$\mu_n = n - 1 + \frac{1}{n} \sum_{k=0}^{n-1} (\mu_k + \mu_{n-1-k}) = n - 1 + \frac{2}{n} \sum_{k=0}^{n-1} \mu_k.$$

Multiplicando por n e subtraindo a mesma identidade para $n-1$,

$$\begin{aligned} n\mu_n - (n-1)\mu_{n-1} &= 2(n-1) + 2\mu_{n-1} \\ \Longrightarrow \frac{\mu_n}{n+1} &= \frac{\mu_{n-1}}{n} + \frac{2(n-1)}{n(n+1)} = \frac{\mu_{n-1}}{n} + \frac{4}{n+1} - \frac{2}{n}. \end{aligned}$$

Somando de 1 a n (com $\mu_0 = 0$):

$$\frac{\mu_n}{n+1} = 4(H_{n+1} - 1) - 2H_n = 2H_n + \frac{4}{n+1} - 4,$$

e portanto

$$\mu_n = 2(n+1)H_n - 4n. \tag{3.11}$$

Condicionando em $U_n = k$ e usando a independência,

$$\mathbb{E}\Big((C_k + C'_{n-1-k} + n - 1)^2 \Big) = s_k + s_{n-1-k} + 2\mu_k\mu_{n-1-k} + 2(n-1)(\mu_k + \mu_{n-1-k}) + (n-1)^2.$$

Fazendo a média sobre k e multiplicando por n, com $T_n := \sum_{k=0}^{n-1} \mu_k\mu_{n-1-k}$ e $P_n := \sum_{k=0}^{n-1} \mu_k$,

$$n\, s_n = 2\sum_{k=0}^{n-1} s_k + 2T_n + 4(n-1)P_n + n(n-1)^2, \qquad \forall n \geqslant 1. \tag{3.12}$$

Funções geradoras. Seja

$$L = L(z) := -\ln(1-z) = \sum_{m\geq 1} \frac{1}{m} z^m$$

e sejam $\mu(z) = \sum_n \mu_n z^n$ e $M(z) = \sum_n s_n z^n$.

Da recorrência $n\mu_n = n(n-1) + 2P_n$ e de $\sum_{n\geq 1} n(n-1)z^{n-1} = 2z/(1-z)^3$,

$$\mu'(z) = \frac{2z}{(1-z)^3} + \frac{2\mu(z)}{1-z} \iff$$

$$\big((1-z)^2\mu\big)' = \frac{2z}{1-z} = 2\left(\frac{1}{1-z} - 1\right);$$

Integrando de 0 a z,

$$\mu(z) = \frac{2\,(L-z)}{(1-z)^2}. \tag{3.13}$$

A função geradora de (3.12): multiplicando (3.12) por z^{n-1} e somando em $n \geqslant 1$:

- $\sum_{n\geq 1} n s_n z^{n-1} = M'$;
- $\sum_{n\geq 1} \big(2\sum_{k<n} s_k\big) z^{n-1} = \dfrac{2M}{1-z}$;
- $\sum_{n\geq 1} 2T_n z^{n-1} = 2\mu(z)^2$ (produto de séries);
- como $\sum_{n\geq 1} P_n z^{n-1} = B(z) := \dfrac{\mu}{1-z} = \dfrac{2(L-z)}{(1-z)^3}$, temos $\sum_{n\geq 1} 4(n-1)P_n z^{n-1} = 4zB'(z)$, e

$$B'(z) = \frac{2z + 6(L-z)}{(1-z)^4} \implies 4zB'(z) = \frac{24zL - 16z^2}{(1-z)^4};$$

- $\sum_{n\geq 1} n(n-1)^2 z^{n-1} = \sum n(n-1)(n-2)z^{n-1} + \sum n(n-1)z^{n-1} = \dfrac{6z^2}{(1-z)^4} + \dfrac{2z}{(1-z)^3} = \dfrac{4z^2+2z}{(1-z)^4}$.

Logo

$$M' = \frac{2M}{1-z} + 2\mu^2 + F, \qquad F(z) := \frac{24zL - 12z^2 + 2z}{(1-z)^4}.$$

Multiplicando por $(1-z)^2$,

$$\big((1-z)^2 M\big)' = (1-z)^2\,(2\mu^2 + F) = \frac{8L^2 + 8zL - 4z^2 + 2z}{(1-z)^2},$$

pois $(1-z)^2 \cdot 2\mu^2 = 8(L-z)^2/(1-z)^2$. Como $M(0) = 0$,

$$(1-z)^2 M(z) = \int_0^z \frac{8L(t)^2 + 8tL(t) - 4t^2 + 2t}{(1-t)^2}\,\mathrm{d}t.$$

Usando $L' = 1/(1-t)$ e integração por partes, obtêm-se as primitivas

$$\int_0^z \frac{L^2}{(1-t)^2}\,\mathrm{d}t = \frac{L^2 - 2L + 2}{1-z} - 2,$$
$$\int_0^z \frac{L}{(1-t)^2}\,\mathrm{d}t = \frac{L-1}{1-z} + 1, \qquad \int_0^z \frac{L}{1-t}\,\mathrm{d}t = \frac{L^2}{2},$$
$$\int_0^z \frac{-4t^2+2t}{(1-t)^2}\,\mathrm{d}t = -\frac{2}{1-z} + 2 + 6L - 4z,$$

onde a última usa $-4t^2 + 2t = -2 + 6(1-t) - 4(1-t)^2$ e $t\,L/(1-t)^2 = L/(1-t)^2 - L/(1-t)$. Somando com os pesos 8, 8 e 1,

$$M(z) = \frac{8L^2 - 8L + 6}{(1-z)^3} + \frac{-4L^2 + 6L - 4z - 6}{(1-z)^2}. \tag{3.14}$$

Lema 3.1. *Para $r \geqslant 0$ inteiro,*

$$[z^n]\frac{1}{(1-z)^{r+1}} = \binom{n+r}{r},$$
$$[z^n]\frac{L}{(1-z)^{r+1}} = \binom{n+r}{r}\big(H_{n+r} - H_r\big),$$
$$[z^n]\frac{L^2}{(1-z)^{r+1}} = \binom{n+r}{r}\Big[\big(H_{n+r} - H_r\big)^2 - \big(H^{(2)}_{n+r} - H^{(2)}_r\big)\Big].$$

Demonstração. Para $\alpha > 0$, $(1-z)^{-\alpha} = \mathrm{e}^{\alpha L}$ e

$$[z^n](1-z)^{-\alpha} = \Gamma(n+\alpha)/(\Gamma(\alpha)\,n!).$$

Derivando j vezes em α obtém-se $L^j(1-z)^{-\alpha}$ do lado esquerdo. Do lado direito,

$$\partial_\alpha \ln\frac{\Gamma(n+\alpha)}{\Gamma(\alpha)} = \psi(n+\alpha) - \psi(\alpha)$$

e

$$\partial^2_\alpha \ln\frac{\Gamma(n+\alpha)}{\Gamma(\alpha)} = \psi'(n+\alpha) - \psi'(\alpha).$$

Em $\alpha = r+1$, $\psi(n+r+1) - \psi(r+1) = H_{n+r} - H_r$ e $\psi'(n+r+1) - \psi'(r+1) = -(H^{(2)}_{n+r} - H^{(2)}_r)$. Basta aplicar $\partial^2_\alpha e^f = (f'^2 + f'')e^f$ com $f = \ln \frac{\Gamma(n+\alpha)}{\Gamma(\alpha)}$. □

Fixe

$$p := n+1, \quad a := H_{n+1} \quad \text{e} \quad a_2 := H^{(2)}_{n+1}.$$

Aplicando o lema a (3.14) (com $r = 2$ nos termos em $(1-z)^{-3}$ e $r = 1$ nos termos em $(1-z)^{-2}$, e lembrando $H_2 = \frac{3}{2}$, $H^{(2)}_2 = \frac{5}{4}$, $H_{n+2} = a + \frac{1}{p+1}$), os seis blocos de $[z^n]M(z)$ são:

$$\begin{aligned}
\frac{8L^2}{(1-z)^3} &\mapsto 4p(p+1)\big(a^2 - 3a - a_2 + \tfrac{7}{2}\big) + 8pa - 12p,\\
\frac{-8L}{(1-z)^3} &\mapsto -4p(p+1)a + 6p(p+1) - 4p,\\
\frac{6}{(1-z)^3} &\mapsto 3p(p+1),\\
\frac{-4L^2}{(1-z)^2} &\mapsto -4pa^2 + 8pa - 8p + 4pa_2,\\
\frac{6L}{(1-z)^2} &\mapsto 6pa - 6p,\\
\frac{-4z-6}{(1-z)^2} &\mapsto -10p + 4.
\end{aligned}$$

Somando,

$$s_n = 4p^2a^2 - 4p^2a_2 - 16p^2a + 6pa + 23p^2 - 17p + 4. \tag{3.15}$$

A variância. Por (3.11), como $H_n = a - \frac{1}{p}$, temos $\mu_n = 2pa - 4p + 2$, e então

$$\mu_n^2 = 4p^2a^2 - 16p^2a + 8pa + 16p^2 - 16p + 4.$$

Subtraindo de (3.15) (os termos em a^2 e em p^2a cancelam):

$$v_n = s_n - \mu_n^2 = 7p^2 - p - 4p^2a_2 - 2pa.$$

Voltando a n, com $a_2 = H^{(2)}_n + \frac{1}{(n+1)^2}$ e $a = H_n + \frac{1}{n+1}$:

$$\operatorname{Var}(C_n) = 7n^2 + 13n - 4(n+1)^2H^{(2)}_n - 2(n+1)H_n. \tag{3.16}$$

Como $H^{(2)}_n = \zeta(2) - \sum_{j>n} j^{-2}$ e $\frac{1}{n+1} < \sum_{j>n} j^{-2} < \frac{1}{n}$, temos $H^{(2)}_n = \frac{\pi^2}{6} - \frac{1}{n} + O(n^{-2})$. Logo

$$-4(n+1)^2H^{(2)}_n = -\frac{2\pi^2}{3}(n+1)^2 + 4n + O(1),$$

e, com $H_n = \ln n + \gamma + O(1/n)$,

$$\operatorname{Var}(C_n) = \Big(7 - \frac{2\pi^2}{3}\Big)n^2 - 2n\ln n + O(n).$$

4
Desigualdades de Chernoff–Hoeffding

As desigualdades de Chernoff formam uma classe de desigualdades derivadas da desigualdade de Markov e de limitantes para a função geradora de momentos. Essa técnica foi introduzida por Bernstein (1924), que desenvolveu limitantes para a soma de variáveis aleatórias com variâncias finitas. Chernoff (1952) derivou limitantes para soma de variáveis aleatórias independentes

> "Devo mencionar que Cramér (1938) havia obtido resultados muito mais elegantes e gerais sobre grandes desvios. Descobri isso depois de derivar meus próprios resultados. No entanto, Cramér exigia uma condição que não era satisfeita pelas variáveis aleatórias de valores inteiros no meu problema. Shannon havia publicado um artigo usando o Teorema Central do Limite como uma aproximação para grandes desvios e foi criticado por isso. Meu artigo permitiu que ele modificasse seus resultados e gerou muita publicidade na literatura de ciência da computação para o que ficou conhecido como o limitante de Chernoff, que, na verdade, era o resultado de Rubin." Herman Chernoff, (Chernoff, 2014).

Sergei N. Bernstein, 1880–1968 foi um matemático soviético. Em 1917, sugeriu a primeira base axiomática da teoria de probabilidade. Conhecido também por resolver o décimo nono problema de Hilbert sobre a solução analítica de equações diferenciais elípticas.

Por fim, Hoeffding (1994) introduziu uma desigualdade para soma de variáveis aleatórias independentes e limitadas.

4.1 O método de Chernoff

Se X é uma variável aleatória, $f\colon \mathbb{R} \to \mathbb{R}_+$ uma função estritamente crescente e $t \in \mathbb{R}$, então vale $[X \geqslant t] = [f(X) \geqslant f(t)]$ e, pela desigualdade de Markov, deduzimos

$$\mathbb{P}[\, X \geqslant t \,] = \mathbb{P}[\, f(X) \geqslant f(t) \,] \leqslant \frac{\mathbb{E} f(X)}{f(t)}$$

donde derivamos, anteriormente, a desigualdade de Chebyshev usando $f(x) = x^2$. Agora, neste contexto, tomamos a função $f(x) = \exp(sx)$ para algum parâmetro $s \in \mathbb{R}$ e temos que

- se $s > 0$, então $[X \geqslant t] = [sX \geqslant st] = [\exp(sX) \geqslant \exp(st)]$, logo

$$\mathbb{P}[\, X \geqslant t \,] = \mathbb{P}\left[\, \mathrm{e}^{sX} \geqslant \mathrm{e}^{st} \,\right] \leqslant \frac{\mathbb{E}\mathrm{e}^{sX}}{\mathrm{e}^{st}}, \tag{4.1}$$

- se $s < 0$, então $[X \leqslant t] = [sX \geqslant st] = [\exp(sX) \geqslant \exp(st)]$, logo

$$\mathbb{P}[\, X \leqslant t \,] = \mathbb{P}\left[\, \mathrm{e}^{sX} \geqslant \mathrm{e}^{st} \,\right] \leqslant \frac{\mathbb{E}\mathrm{e}^{sX}}{\mathrm{e}^{st}}. \tag{4.2}$$

A esperança $M_X(s) := \mathbb{E}\mathrm{e}^{sX}$ é a ***função geradora de momentos*** (FGM) de X, que estudamos com mais cuidado na Seção 4.1.1; aqui basta saber que ela está definida para os $s \in \mathbb{R}$ em que a esperança é finita. As desigualdades (4.1) e (4.2) valem para todo s (do sinal indicado) em que a FGM de X é finita, e, quando ela diverge, o lado direito vale $+\infty$ e a desigualdade é trivial. Obtemos delas o seguinte resultado.

Teorema 4.1: método de Chernoff–Cramér

Se X é uma variável aleatória e $t \in \mathbb{R}$, então

$$\mathbb{P}[\, X \geqslant t \,] \leqslant \inf_{s>0} \frac{\mathbb{E}\mathrm{e}^{sX}}{\mathrm{e}^{st}} \tag{4.3}$$

$$\mathbb{P}[\, X \leqslant t \,] \leqslant \inf_{s<0} \frac{\mathbb{E}\mathrm{e}^{sX}}{\mathrm{e}^{st}}. \tag{4.4}$$

O método de Chernoff–Cramér consiste em estimar o lado direito dessas desigualdades e é especialmente útil no caso de variáveis aleatórias que podem ser escritas como soma de variáveis aleatórias independentes, pois nesse caso a FGM da soma é o produto das FGMs.

4.1.1 *Momentos e função geradora de momentos*

Dado um inteiro positivo k, definimos o momento de ordem k, ou o ***k-ésimo momento*** da variável aleatória $X : \Omega \to \mathbb{R}$, como a esperança de X^k

$$\mathbb{E}X^k = \sum_r r^k \, \mathbb{P}_X(r)$$

quando está definida. De $|x|^k \leqslant |x|^{k+1} + 1$ para todo $x \in \mathbb{R}$, temos que se o momento de ordem $k+1$ é finito então o de ordem k também é finito. Ainda, usando a desigualdade de Markov, podemos provar facilmente que, dado um inteiro positivo k, vale

$$\mathbb{P}[\,|X| \geqslant t\,] = \mathbb{P}\Big[\,|X|^k \geqslant t^k\,\Big] \leqslant \frac{\mathbb{E}|X|^k}{t^k} \tag{4.5}$$

para toda constante $t > 0$, sempre que $|X|^k$ é integrável.

Se X tem esperança finita, definimos o ***k-ésimo momento central*** por $\mathbb{E}(X - \mathbb{E}X)^k$. Em particular, a ***variância*** de uma variável aleatória integrável é o segundo momento central dessa variável

$$\mathrm{Var}(X) := \mathbb{E}(X - \mathbb{E}X)^2 = \mathbb{E}X^2 - (\mathbb{E}X)^2. \tag{4.6}$$

A ***função geradora de momentos*** (FGM) de uma variável aleatória real X é

$$M_X(s) := \mathbb{E}e^{sX}, \qquad s \in \mathbb{R}, \tag{4.7}$$

definida nos valores de s para os quais a esperança é finita. Sempre vale $M_X(0) = 1$. Se a função está definida em algum intervalo $(-x_0, x_0)$ com $x_0 > 0$, então a variável aleatória X tem todos os seus momentos finitos e, usando a série de Taylor em torno de 0, vale que

$$M_X(s) = \sum_{k=0}^{\infty} \frac{s^k}{k!} \mathbb{E}X^k \tag{4.8}$$

para todo $s \in (-x_0, x_0)$ (ver Billingsley, 1995, Seção 21).

O nome vem do fato de que, expandindo e^{sX} em série de Taylor e trocando soma com esperança (quando isso é válido),

$$M_X(s) = \mathbb{E}\sum_{k=0}^{\infty} \frac{(sX)^k}{k!} = \sum_{k=0}^{\infty} \frac{\mathbb{E}X^k}{k!} s^k,$$

ou seja, os *momentos* $\mathbb{E}X^k$ aparecem como os coeficientes de Taylor de M_X em $s = 0$ (a menos do fatorial). Equivalentemente, $\mathbb{E}X^k = M_X^{(k)}(0)$, a k-ésima derivada de M_X avaliada em $s = 0$. Em particular, $M_X'(0) = \mathbb{E}X$ e $M_X''(0) = \mathbb{E}X^2$.

A FGM pode não estar definida para todo s: para variáveis com cauda muito pesada[1], $M_X(s)$ pode divergir para todo $s \neq 0$. Felizmente, nas aplicações deste capítulo a FGM está definida em um intervalo em torno de 0: para variáveis limitadas, como as indicadoras, em todo $\mathbb{R}$; para a geométrica, em $s < \ln 2$ (Exemplo 4.2 e Seção 4.5).

[1] por exemplo, distribuições com densidade proporcional a $|x|^{-3}$ para $|x| \geqslant 1$

A propriedade central que torna a FGM valiosa em nossas aplicações é que ela transforma *soma de variáveis independentes* em *produto de* FGMs. Se $X_1, \ldots, X_n$ são independentes,

$$M_{X_1+\cdots+X_n}(s) = \mathbb{E}e^{s(X_1+\cdots+X_n)} = \mathbb{E}\prod_{i=1}^{n} e^{sX_i} = \prod_{i=1}^{n} \mathbb{E}e^{sX_i} = \prod_{i=1}^{n} M_{X_i}(s),$$

onde a penúltima igualdade usa a independência (a esperança do produto é o produto das esperanças).

Exemplo 4.1: FGM da binomial

Se $X \sim \text{Binomial}(n, p)$, então $X = \sum_i X_i$ com X_i independentes e distribuição de Bernoulli(p), e

$$M_{X_i}(s) = \mathbb{E}e^{sX_i} = p\,e^s + 1 - p,$$

logo

$$M_X(s) = (p\,e^s + 1 - p)^n$$

para todo $s \in \mathbb{R}$.

Exemplo 4.2: FGM da geométrica

Se $X \sim \text{Geom}(p)$, então

$$M_X(s) = \sum_{k=1}^{\infty} \mathrm{e}^{sk} p(1-p)^{k-1} = p\,\mathrm{e}^{s} \sum_{k=1}^{\infty} (\mathrm{e}^{s}(1-p))^{k-1} = \frac{p\,\mathrm{e}^{s}}{1-\mathrm{e}^{s}(1-p)} \tag{4.9}$$

sempre que $\mathrm{e}^{s}(1-p) < 1$, ou seja, $s < -\ln(1-p)$. Em particular, $\mathbb{E}X = M_X'(0) = 1/p$.

4.2 *Soma de variáveis aleatórias uniformes*

Antes do caso geral, vejamos duas somas em que as contas são particularmente simples.

Soma de variáveis aleatórias de Rademacher

Uma variável aleatória tem ***distribuição de Rademacher*** se assume os valores $\{-1, 1\}$ com probabilidade uniforme.

Teorema 4.2: Chernoff para variáveis Rademacher

Se $X = \sum_{i=1}^{n} X_i$ com $X_1, \ldots, X_n \in_{\mathrm{R}} \{-1, 1\}$ independentes e $t > 0$, então

$$\mathbb{P}[\,|X| \geqslant t\,] \leqslant 2\exp\left(\frac{-t^2}{2n}\right). \tag{4.10}$$

Demonstração. Seja X uma variável aleatória como no enunciado. Pela independência das X_i, para todo $s \in \mathbb{R}$,

$$\mathbb{E}\mathrm{e}^{sX} = \prod_{i=1}^{n} \mathbb{E}\mathrm{e}^{sX_i} = \prod_{i=1}^{n} \frac{\mathrm{e}^{s} + \mathrm{e}^{-s}}{2} = (\cosh s)^n.$$

Pela série de Taylor do cosseno hiperbólico e pelo fato de que $(2i)! \geqslant 2^i\, i!$ para todo inteiro $i \geqslant 0$ (segue facilmente por indução em i),

$\cosh(s)$ é a função cosseno hiperbólico.

$$\cosh s = \sum_{i=0}^{\infty} \frac{s^{2i}}{(2i)!} \leqslant \sum_{i=0}^{\infty} \frac{(s^2/2)^i}{i!} = \mathrm{e}^{s^2/2},$$

logo $\mathbb{E}\mathrm{e}^{sX} \leqslant \mathrm{e}^{s^2 n/2}$. Para $s > 0$, a desigualdade de Markov aplicada à variável não negativa e^{sX} dá

$$\mathbb{P}[\,X \geqslant t\,] = \mathbb{P}\left[\,\mathrm{e}^{sX} \geqslant \mathrm{e}^{st}\,\right] \leqslant \mathrm{e}^{-st}\,\mathbb{E}\mathrm{e}^{sX} \leqslant \exp\left(\frac{s^2 n}{2} - st\right).$$

O mínimo do lado direito, entre os $s > 0$, é atingido em $s = t/n$ (positivo, pois $t > 0$), de modo que

$$\mathbb{P}[\, X \geqslant t \,] \leqslant \mathrm{e}^{-t^2/2n}. \tag{4.11}$$

Como $-X$ tem a mesma distribuição de X (as $-X_i$ também são independentes e uniformes em $\{-1, 1\}$), $\mathbb{P}[\, -X \geqslant t \,] = \mathbb{P}[\, X \geqslant t \,]$ e, pela subaditividade (equação (1.2)),

$$\mathbb{P}[\, |X| \geqslant t \,] \leqslant 2\,\mathrm{e}^{-t^2/2n}$$

para todo $t > 0$. □

Soma de variáveis aleatórias de Bernoulli

Sejam $X_1, \ldots, X_n \in_{\mathrm{R}} \{-1, 1\}$ independentes. Então $Y_i := (X_i + 1)/2 \in_{\mathrm{R}} \{0, 1\}$ são independentes e $Y := \sum_i Y_i \sim \text{Binomial}(n, 1/2)$, com $\sum_i X_i = 2Y - n$. Aplicando o Teorema 4.2 com parâmetro $2t$, para todo $t > 0$,

$$\mathbb{P}[\, |Y - n/2| \geqslant t \,] = \mathbb{P}[\, |2Y - n| \geqslant 2t \,] \leqslant 2\exp\left(-\frac{(2t)^2}{2n}\right).$$

Do mesmo modo, a cota unilateral (4.11), também com parâmetro $2t$, dá $\mathbb{P}[\, Y - n/2 \geqslant t \,] = \mathbb{P}[\, 2Y - n \geqslant 2t \,] \leqslant \mathrm{e}^{-(2t)^2/2n} = \mathrm{e}^{-2t^2/n}$. Disso concluímos o seguinte resultado.

Teorema 4.3: Chernoff para v.a. binomial padrão

Se $X \sim \text{Binomial}(n, 1/2)$, então $\mathbb{E}X = n/2$ e, para todo $t > 0$,

$$\mathbb{P}[\, X - \mathbb{E}X \geqslant t \,] \leqslant \mathrm{e}^{-2t^2/n} \quad \text{e} \quad \mathbb{P}[\, X - \mathbb{E}X \leqslant -t \,] \leqslant \mathrm{e}^{-2t^2/n}, \tag{4.12}$$

e, portanto,

$$\mathbb{P}[\, |X - \mathbb{E}X| \geqslant t \,] \leqslant 2\exp\left(\frac{-2t^2}{n}\right). \tag{4.13}$$

A demonstração é a discussão que precede o enunciado: a primeira desigualdade é a cota unilateral (4.11) aplicada com parâmetro $2t$, a segunda segue da primeira porque $n - X$ também tem distribuição $\text{Binomial}(n, 1/2)$, e a terceira, da subaditividade.

Exemplo 4.3: Markov, Chebyshev e Chernoff no lançamento de moedas

Consideremos S_n a quantidade de caras no lançamento de n moedas equilibradas. O número esperado de caras é $n/2$,

portanto, pela desigualdade de Markov,

$$\mathbb{P}\left[\, S_n \geqslant \frac{3}{4}n \,\right] \leqslant \frac{n/2}{3n/4} = \frac{2}{3}.$$

Usando a desigualdade de Chebyshev, com $\operatorname{Var}(S)_n = n \cdot \frac{1}{4} = \frac{n}{4}$ (as n moedas são independentes),

$$\mathbb{P}\left[\, \left| S_n - \frac{n}{2} \right| \geqslant \frac{n}{4} \,\right] \leqslant \frac{n/4}{(n/4)^2} = \frac{4}{n},$$

em particular, $\mathbb{P}[\, S_n \geqslant 3n/4 \,] \leqslant 4/n$. Pela versão unilateral da desigualdade de Chernoff (4.12), com $t = n/4$,

$$\mathbb{P}\left[\, S_n \geqslant \frac{3n}{4} \,\right] = \mathbb{P}\left[\, S_n - \frac{n}{2} \geqslant \frac{n}{4} \,\right] \leqslant \mathrm{e}^{-2(n/4)^2/n} = \mathrm{e}^{-n/8}.$$

Em resumo, os limitantes superiores para a probabilidade de $S_n \geqslant 1{,}5\,\mathbb{E}S_n$ são

	Markov	Chebyshev	Chernoff
$\mathbb{P}[\, S_n \geqslant 3n/4 \,]$	$\leqslant 2/3$	$\leqslant 4/n$	$\leqslant \mathrm{e}^{-n/8}$

Embora a desigualdade de Chernoff seja muito mais poderosa, essas desigualdades assumem hipóteses diferentes: Markov só exige que a variável seja não negativa; Chebyshev, para uma soma, usa que as variâncias se somam (basta independência dois a dois); Chernoff usa a independência das X_i em conjunto.

4.3 *A desigualdade de Hoeffding*

O logaritmo da FGM,

$$K_X(s) := \ln M_X(s),$$

é chamado de ***função geradora de cumulantes***. Sob a transformação logarítmica, a propriedade de produto vira soma:

$$K_{X_1+\cdots+X_n}(s) = \sum_{i=1}^{n} K_{X_i}(s),$$

uma *soma* de n termos, mais simples de analisar que um produto de n fatores. Suas derivadas em $s = 0$ são os *cumulantes* de X: $K'_X(0) = \mathbb{E}X$ (o primeiro cumulante, igual ao primeiro momento) e $K''_X(0) = \operatorname{Var}(X)$ (o segundo cumulante, que já não coincide com o segundo momento bruto, mas com a variância, justamente por causa da centralização implícita que o logaritmo introduz). É essa função, aplicada a $Z = X - \mathbb{E}X$, que aparece na prova do Lema de Hoeffding: $f(s) = K_{X-\mu}(s)$.

Combinando a FGM com a desigualdade de Markov aplicada a e^{sX}, como em (4.1), e escolhendo $s > 0$ para minimizar o lado direito, obtemos a cota mais forte possível por esse método. É o que faremos na prova do Teorema 4.4, com $s = 4t/n$. Diferentes escolhas de X e de s dão origem às várias variantes de "cotas de Chernoff" encontradas na literatura. A que provamos aqui (Lema de Hoeffding mais essa otimização) é uma das mais simples e vale para variáveis limitadas em $[0,1]$.

Antes de enunciar o lema, vale explicar duas escolhas técnicas que tornam sua demonstração simples.

A primeira é trabalhar com o *logaritmo* da função geradora de momentos, $f(s) := \ln \mathbb{E}e^{sZ}$, em vez de $\mathbb{E}e^{sZ}$ diretamente. A função $\mathbb{E}e^{sZ}$ mistura somas e exponenciais de forma que suas derivadas de ordem superior ficam cada vez mais complicadas (a regra do produto se acumula a cada derivação). Tomando o logaritmo antes de derivar, essas derivadas assumem uma forma fechada e reconhecível: no caso de uma Bernoulli, a segunda derivada de f sai na forma $q_s(1-q_s)$, um produto do tipo "$p(1-p)$", fácil de limitar. Além disso, como ln é crescente, provar uma cota para $f(s)$ é equivalente a provar a mesma cota, exponenciada, para $\mathbb{E}e^{sZ}$, de modo que nada se perde ao passar para o logaritmo.

A segunda escolha é aplicar essa construção à variável *centralizada* $Z = X - \mu$, e não a X diretamente. Como $\mathbb{E}X - \mu = 0$, a variável Z tem média zero. Isso faz com que a expansão de Taylor de f em torno de $s = 0$ comece direto no termo quadrático: $f(0) = 0$ (pois $\mathbb{E}e^0 = 1$) e $f'(0) = \mathbb{E}Z = 0$[2], sem o termo linear, sobra apenas

$$f(s) = \frac{f''(\xi)}{2}\, s^2$$

para algum ξ entre 0 e s (teorema de Taylor com resto de Lagrange), e basta então limitar f'' uniformemente para obter uma cota do tipo $f(s) \leqslant cs^2$, válida para *todo* s, e não apenas para s pequeno, como daria uma expansão assintótica comum. Se não tivéssemos centralizado, $f'(0) = \mathbb{E}X = \mu \neq 0$ em geral, e um termo linear indesejado apareceria na cota final.

[2] Em geral, $\frac{\mathrm{d}}{\mathrm{d}s}\mathbb{E}e^{sZ}\big|_{s=0} = \mathbb{E}Z$; após compor com o logaritmo, $f'(0) = \mathbb{E}Z$ também, pois $\mathbb{E}e^0 = 1$.

Lema 4.1: Lema de Hoeffding

Seja X uma variável aleatória com valores em $[0,1]$ e $\mu := \mathbb{E}X$. Para todo $s \in \mathbb{R}$,

$$\mathbb{E}e^{s(X-\mu)} \leqslant \exp\left(\frac{s^2}{8}\right).$$

Demonstração. Se $\mu \in \{0,1\}$, então $X = \mu$ com probabilidade 1 e o resultado é trivial; suponha $0 < \mu < 1$.

Redução ao caso Bernoulli. Para $x \in [0,1]$, a convexidade de $x \mapsto \mathrm{e}^{sx}$ dá $\mathrm{e}^{sx} \leqslant (1-x) + x\,\mathrm{e}^{s}$ (a corda entre $x=0$ e $x=1$). Tomando a esperança,

$$\mathbb{E}\mathrm{e}^{sX} \leqslant 1 + \mu(\mathrm{e}^{s} - 1),$$

que vale com igualdade quando $X \in \{0,1\}$. Logo $\mathbb{E}\mathrm{e}^{s(X-\mu)} \leqslant \mathrm{e}^{f(s)}$, onde $f(s) := -s\mu + \ln(1 + \mu(\mathrm{e}^{s}-1))$.

Usando Taylor. Temos $f(0)=0$, $f'(s) = -\mu + q_s$ com $q_s := \mu\mathrm{e}^{s}/(1-\mu+\mu\mathrm{e}^{s}) \in (0,1)$, logo $f'(0)=0$ e, como $q_s' = q_s(1-q_s)$,

$$f''(s) = q_s(1-q_s) \leqslant \frac{1}{4} \qquad \text{para todo } s.$$

Pelo teorema de Taylor com resto, existe ξ entre 0 e s tal que

$$\begin{aligned} f(s) &= f(0) + f'(0)\,s + \frac{f''(\xi)}{2}\,s^2 \\ &= \frac{f''(\xi)}{2}\,s^2 \leqslant \frac{1/4}{2}\,s^2 = \frac{s^2}{8}. \end{aligned}$$

Portanto $\mathbb{E}\mathrm{e}^{s(X-\mu)} \leqslant \mathrm{e}^{f(s)} \leqslant \mathrm{e}^{s^2/8}$. □

Corolário 4.1: Lema de Hoeffding

Seja X uma variável aleatória com $\mathbb{E}X=0$ e $X \in [a,b]$. Então

$$\mathbb{E}\mathrm{e}^{\lambda X} \leqslant \exp\left(\frac{\lambda^2 (b-a)^2}{8}\right) \qquad \text{para todo } \lambda \in \mathbb{R}.$$

Demonstração. Se $a=b$, então $X=0$ quase certamente e a desigualdade vale com igualdade ($1 \leqslant 1$). Suponha $a<b$ e defina

$$Y := \frac{X-a}{b-a} \in [0,1], \qquad \mu := \mathbb{E}Y = \frac{-a}{b-a},$$

onde usamos $\mathbb{E}X = 0$. Então $a = -(b-a)\mu$, e portanto

$$X = a + (b-a)Y = (b-a)(Y-\mu).$$

Aplicando o Lema 4.1 a Y com $s := \lambda(b-a)$,

$$\mathbb{E}\mathrm{e}^{\lambda X} = \mathbb{E}\mathrm{e}^{s(Y-\mu)} \leqslant \exp\left(\frac{s^2}{8}\right) = \exp\left(\frac{\lambda^2(b-a)^2}{8}\right).$$ □

Teorema 4.4: Desigualdade de Chernoff–Hoeffding

Sejam $X_1, \ldots, X_n$ independentes, com valores em $[0,1]$,

$S := X_1 + \cdots + X_n$ e $\mu := \mathbb{E}S$. Para todo $t > 0$,

$$\mathbb{P}[\, S \geqslant \mu + t \,] \leqslant \mathrm{e}^{-2t^2/n},$$

e

$$\mathbb{P}[\, S \leqslant \mu - t \,] \leqslant \mathrm{e}^{-2t^2/n}$$

e, portanto,

$$\mathbb{P}[\, |\, S - \mu \,| \geqslant t \,] \leqslant 2\exp\left(-\frac{2t^2}{n}\right).$$

Demonstração. Para $s > 0$, pela desigualdade de Markov (3.5) aplicada à variável não negativa $\mathrm{e}^{s(S-\mu)}$,

$$\mathbb{P}[\, S - \mu \geqslant t \,] = \mathbb{P}\left[\, \mathrm{e}^{s(S-\mu)} \geqslant \mathrm{e}^{st} \,\right] \leqslant \mathrm{e}^{-st}\, \mathbb{E}\mathrm{e}^{s(S-\mu)} = \mathrm{e}^{-st} \prod_{i=1}^{n} \mathbb{E}\mathrm{e}^{s(X_i - \mathbb{E}X_i)} \leqslant \mathrm{e}^{-st}\mathrm{e}^{\left(ns^2/8\right)},$$

usando a independência dos X_i e o Lema 4.1 em cada fator. Otimizando em s, o mínimo de $-st + ns^2/8$ ocorre em $s = 4t/n$, dando o valor $-2t^2/n$, o que prova a primeira desigualdade. Para a segunda, aplicamos a primeira às variáveis $1 - X_i \in [0,1]$, independentes, com soma $n - S$ e esperança $n - \mu$: $\mathbb{P}[\, S \leqslant \mu - t \,] = \mathbb{P}[\, n - S \geqslant (n-\mu) + t \,] \leqslant \mathrm{e}^{-2t^2/n}$. A cota bilateral segue da subaditividade. □

Observação 6. Os resultados da Seção 4.2 são casos particulares. Para $X_i \in_{\mathrm{R}} \{\, 0, 1 \,\}$ (Binomial$(n, 1/2)$), o Teorema dá exatamente (4.12). Para Rademacher, $X = \sum_i X_i = 2S - n$ com $S = \sum_i (X_i + 1)/2$ e $\mu = n/2$, logo $\mathbb{P}[\, X \geqslant t \,] = \mathbb{P}[\, S \geqslant \mu + t/2 \,] \leqslant \mathrm{e}^{-t^2/2n}$, que é (4.11).

4.3.1 *A desigualdade de Hoeffding*

A desigualdade de Hoeffding permite que X_i siga qualquer distribuição, desde que seu valor seja limitado quase certamente.

Teorema 4.5: Desigualdade de Hoeffding

Sejam $X_1, \ldots, X_n$ variáveis aleatórias independentes e $a_1, \ldots, a_n, b_1, \ldots, b_n \in \mathbb{R}$ tais que $a_i \leqslant b_i$ e $\mu_i := \mathbb{E}X_i$ para todo i. Sejam, também, $X = \sum_{i=1}^n X_i$ e $\mu := \mathbb{E}X = \sum_{i=1}^n \mu_i$.
Se $X_i \in [a_i, b_i]$ com probabilidade 1, então, para todo $t \geqslant 0$,

$$\mathbb{P}[\, |\, X - \mu \,| \geqslant t \,] \leqslant 2\exp\left(-\frac{2t^2}{\sum_{i=1}^n (b_i - a_i)^2}\right),$$

e

$$\mathbb{P}[\, X - \mu \geqslant t \,] \leqslant \mathrm{e}^{-2t^2/\sum_i (b_i - a_i)^2},$$

e

$$\mathbb{P}[\, X - \mu \leqslant -t \,] \leqslant \mathrm{e}^{-2t^2/\sum_i (b_i - a_i)^2}.$$

Demonstração. Seja $D := \sum_{i=1}^n (b_i - a_i)^2$. Se $D = 0$, então $X = \mu$ com probabilidade 1 e não há o que provar; suponha $D > 0$. Podemos supor $\mu_i = 0$ para todo i: caso contrário, substituímos X_i por $X_i - \mu_i$, que tem média zero e está em $[a_i - \mu_i, b_i - \mu_i]$, intervalo de mesmo comprimento. Basta, então, provar que $\mathbb{P}[\, X \geqslant t \,] \leqslant \exp(-2t^2/D)$: a cota para $\mathbb{P}[\, X \leqslant -t \,]$ segue aplicando-a às variáveis $-X_i \in [-b_i, -a_i]$, e a cota bilateral, pela subaditividade.

Para $\lambda > 0$, pela desigualdade de Markov e pela independência,

$$\mathbb{P}[\, X \geqslant t \,] = \mathbb{P}\left[\, \mathrm{e}^{\lambda X} \geqslant \mathrm{e}^{\lambda t} \,\right] \leqslant \frac{\mathbb{E}\mathrm{e}^{\lambda X}}{\mathrm{e}^{\lambda t}} = \mathrm{e}^{-\lambda t} \prod_{i=1}^{n} \mathbb{E}\mathrm{e}^{\lambda X_i},$$

e o Corolário 4.1 aplicado a cada fator dá $\mathbb{E}\mathrm{e}^{\lambda X_i} \leqslant \exp(\lambda^2 (b_i - a_i)^2/8)$. Logo

$$\mathbb{P}[\, X \geqslant t \,] \leqslant \exp\left(-\lambda t + \frac{\lambda^2 D}{8}\right).$$

Tomando $\lambda = 4t/D$ (que é positivo, se $t > 0$; o caso $t = 0$ é trivial), o expoente vale $-4t^2/D + 2t^2/D = -2t^2/D$. □

4.4 *Soma de variáveis aleatórias Bernoulli não identicamente distribuídas*

O Teorema 4.4 já dá a cota aditiva para qualquer soma de variáveis em $[0, 1]$. Para variáveis de Bernoulli com probabilidades p_i distintas obtemos, com as mesmas ideias, mais: a cota exata em função de $\hat{p}$ e a cota ***multiplicativa***, bem melhor quando $\mathbb{E}X$ é pequeno, que é a usada nas aplicações a algoritmos.

A estratégia do método da função geradora de momentos (método de Chernoff: desigualdade de Markov aplicada a e^{sX}) pode ser usada na soma de variáveis aleatórias que são independentes mas não têm, necessariamente, a mesma distribuição. Sejam $X_i \sim \text{Bernoulli}(p_i)$, $1 \leqslant i \leqslant n$, independentes, $X = \sum_i X_i$ e

$$\hat{p} := \frac{1}{n} \sum_{i=1}^{n} p_i \quad \text{e} \quad \hat{q} := 1 - \hat{p}, \tag{4.14}$$

de modo que $\mathbb{E}X = n\hat{p}$. Se $\hat{p} \in \{0, 1\}$, então X é constante com probabilidade 1 e tudo o que segue é trivial; supomos $0 < \hat{p} < 1$.

Pela independência e pela desigualdade entre as médias aritmética e geométrica, para todo $s \in \mathbb{R}$,

$$\mathbb{E}e^{sX} = \prod_{i=1}^{n} \mathbb{E}e^{sX_i} = \prod_{i=1}^{n} (p_i e^s + (1-p_i)) \leqslant \left(\frac{1}{n} \sum_{i=1}^{n} (p_i e^s + (1-p_i)) \right)^n = (\hat{p}\, e^s + \hat{q})^n.$$

Para $s > 0$ e $t \geqslant 0$, a desigualdade de Markov aplicada à variável não negativa e^{sX} dá

$$\begin{aligned} \mathbb{P}[\, X \geqslant (\hat{p}+t)n \,] &= \mathbb{P}\left[\, e^{sX} \geqslant e^{s(\hat{p}+t)n} \,\right] \\ &\leqslant \frac{\mathbb{E}e^{sX}}{e^{s(\hat{p}+t)n}} \\ &\leqslant \left(\frac{\hat{p}\, e^s + \hat{q}}{e^{s(\hat{p}+t)}} \right)^n. \end{aligned} \tag{4.15}$$

Para $0 < t < \hat{q}$, minimizamos o lado direito em s, isto é, a função

$$g(s) = \frac{\hat{p}\, e^s + \hat{q}}{e^{s(\hat{p}+t)}} = \hat{p}\, e^{s(\hat{q}-t)} + \hat{q}\, e^{-s(\hat{p}+t)}.$$

Como g é soma de exponenciais, é convexa, e portanto um ponto crítico é mínimo global. A derivada é

$$g'(s) = \hat{p}(\hat{q}-t)\, e^{s(\hat{q}-t)} - \hat{q}(\hat{p}+t)\, e^{-s(\hat{p}+t)},$$

e $g'(s) = 0$ equivale, multiplicando por $e^{s(\hat{p}+t)}$, a $\hat{p}(\hat{q}-t)\, e^s = \hat{q}(\hat{p}+t)$, isto é,

$$s^* = \ln\left(\frac{\hat{q}(\hat{p}+t)}{\hat{p}(\hat{q}-t)} \right).$$

Esse ponto é positivo, pois $\hat{q}(\hat{p}+t) - \hat{p}(\hat{q}-t) = t(\hat{p}+\hat{q}) = t > 0$, de modo que s^* serve para a desigualdade (4.15).

Lema 4.2

Se X é a soma das variáveis aleatórias independentes $X_i \sim \text{Bernoulli}(p_i)$, $1 \leqslant i \leqslant n$, $\hat{p} = \frac{1}{n}\sum_{i=1}^{n} p_i \in (0,1)$ e $\hat{q} = 1-\hat{p}$, então

$$\mathbb{P}[\, X \geqslant (\hat{p}+t)n \,] \leqslant \left(\left(\frac{\hat{p}}{\hat{p}+t} \right)^{\hat{p}+t} \left(\frac{\hat{q}}{\hat{q}-t} \right)^{\hat{q}-t} \right)^n \qquad (0 \leqslant t < \hat{q}).$$

Demonstração. Para $t = 0$ o lado direito é 1 e não há o que provar. Para $0 < t < \hat{q}$, substituímos $s = s^*$ em (4.15). Com $e^{s^*} = \hat{q}(\hat{p}+t)/(\hat{p}(\hat{q}-t))$,

$$\hat{p}\, e^{s^*} + \hat{q} = \frac{\hat{q}(\hat{p}+t)}{\hat{q}-t} + \hat{q} = \frac{\hat{q}}{\hat{q}-t}, \qquad e^{-s^*(\hat{p}+t)} = \left(\frac{\hat{p}(\hat{q}-t)}{\hat{q}(\hat{p}+t)} \right)^{\hat{p}+t},$$

logo

$$g(s^*) = \frac{\hat{q}}{\hat{q}-t} \cdot \left(\frac{\hat{p}}{\hat{p}+t}\right)^{\hat{p}+t} \left(\frac{\hat{q}-t}{\hat{q}}\right)^{\hat{p}+t} = \left(\frac{\hat{p}}{\hat{p}+t}\right)^{\hat{p}+t} \left(\frac{\hat{q}}{\hat{q}-t}\right)^{1-\hat{p}-t},$$

e $1-\hat{p}-t = \hat{q}-t$. □

Cota aditiva Reescrevendo o lado direito do Lema 4.2,

$$\mathbb{P}[\, X \geqslant (\hat{p}+t)n \,] \leqslant \exp(-f(t) \cdot n), \tag{4.16}$$

onde, para $-\hat{p} < t < \hat{q}$,

$$f(t) = (\hat{p}+t) \ln \frac{\hat{p}+t}{\hat{p}} + (\hat{q}-t) \ln \frac{\hat{q}-t}{\hat{q}}.$$

Vamos estudar essa função f. Sua primeira e segunda derivadas são

$$f'(t) = \ln\left(\frac{(\hat{p}+t)\hat{q}}{\hat{p}(\hat{q}-t)}\right) \quad \text{e} \quad f''(t) = \frac{1}{\hat{p}+t} + \frac{1}{\hat{q}-t} = \frac{1}{(\hat{p}+t)(\hat{q}-t)},$$

de modo que $f(0) = f'(0) = 0$. Para $0 \leqslant t < \hat{q}$, o denominador de f'' é o produto de dois reais positivos que somam 1, logo é no máximo $1/4$ e $f''(t) \geqslant 4$. Pela fórmula de Taylor com resto, com $a = 0$, existe $\xi \in (0, t)$ tal que

$$f(t) = f(0) + f'(0)\, t + \frac{f''(\xi)}{2}\, t^2 = \frac{f''(\xi)}{2}\, t^2 \geqslant 2t^2.$$

Substituindo em (4.16),

$$\mathbb{P}[\, X \geqslant (\hat{p}+t)n \,] \leqslant \exp\Big(-2t^2 n\Big) \qquad (0 \leqslant t < \hat{q}).$$

Essa cota vale para todo $t \geqslant 0$. Se $t > \hat{q}$, o evento é vazio, pois $(\hat{p} + t)n > n$. Se $t = \hat{q}$, o evento está contido em $[X \geqslant (\hat{p}+t')n]$ para todo $t' < \hat{q}$, e basta fazer $t' \to \hat{q}$.

Para a cauda inferior, as variáveis $Y_i := 1 - X_i \sim \text{Bernoulli}(1-p_i)$ são independentes, com média amostral $\hat{q}$, e $\sum_i Y_i = n - X$. Portanto, pela cota anterior aplicada a (Y_i), para todo $t \geqslant 0$,

$$\mathbb{P}[\, X \leqslant (\hat{p}-t)n \,] = \mathbb{P}\left[\, \sum_i Y_i \geqslant (\hat{q}+t)n \,\right] \leqslant \exp\Big(-2t^2 n\Big).$$

Em particular, pelo Lema 4.2 aplicado a (Y_i),

$$\mathbb{P}[\, X \leqslant (\hat{p}-t)n \,] \leqslant \exp(-f(-t) \cdot n) \qquad (0 \leqslant t < \hat{p}), \tag{4.17}$$

pois o expoente associado a (Y_i) é $(\hat{q}+t) \ln \frac{\hat{q}+t}{\hat{q}} + (\hat{p}-t) \ln \frac{\hat{p}-t}{\hat{p}} = f(-t)$.

Corolário 4.2

Com as hipóteses do Lema 4.2, $\mathbb{E}X = n\hat{p}$ e

$$\mathbb{P}[\,|X - \mathbb{E}X| \geqslant tn\,] \leqslant 2\exp\left(-2t^2 n\right), \quad \text{para todo } t \geqslant 0.$$

□

Esse corolário também segue do Teorema 4.4 (com tn no lugar de t). A demonstração acima é uma segunda prova, que mostra a cota aditiva como consequência da cota exata do Lema e deixa disponível a função f, usada abaixo na cota inferior multiplicativa.

Cota multiplicativa Fazendo $s = \ln(1+\varepsilon)$ e $t = \varepsilon\hat{p}$, para todo $\varepsilon > 0$, em (4.15), ao invés de tomarmos o ótimo como acima, obtemos uma desigualdade mais fraca, mas que pode ser mais fácil de aplicar. Com essa escolha, $\hat{p}\,\mathrm{e}^s + \hat{q} = 1 + \varepsilon\hat{p}$ e $\mathrm{e}^{s(\hat{p}+t)} = (1+\varepsilon)^{(1+\varepsilon)\hat{p}}$, logo, usando $1 + x \leqslant \mathrm{e}^x$,

$$\mathbb{P}[\,X \geqslant (1+\varepsilon)\mathbb{E}X\,] \leqslant \left(\frac{1+\varepsilon\hat{p}}{(1+\varepsilon)^{(1+\varepsilon)\hat{p}}}\right)^n \leqslant \left(\frac{\mathrm{e}^{\varepsilon}}{(1+\varepsilon)^{(1+\varepsilon)}}\right)^{\mathbb{E}X}, \tag{4.18}$$

pois $n\hat{p} = \sum_i p_i = \mathbb{E}X$ e $(1+\varepsilon)\mathbb{E}X = (\hat{p} + \varepsilon\hat{p})n$.

Exercício 23. Deduza que, para todo $\varepsilon \in (0,1)$, vale

$$\mathbb{P}[\,X \leqslant (1-\varepsilon)\mathbb{E}X\,] \leqslant \left(\frac{\mathrm{e}^{-\varepsilon}}{(1-\varepsilon)^{1-\varepsilon}}\right)^{\mathbb{E}X}.$$

(Dica: repita o argumento acima com $s < 0$, escolhendo $s = \ln(1-\varepsilon)$, e use $1 + x \leqslant \mathrm{e}^x$ em cada fator de $\mathbb{E}\mathrm{e}^{sX} = \prod_i (1 + p_i(\mathrm{e}^s - 1))$.)

Lema 4.3

Sejam $p_i \in [0,1]$ e $X_i \sim \text{Bernoulli}(p_i)$, para $1 \leqslant i \leqslant n$, variáveis aleatórias independentes. Se $X = \sum_{i=1}^n X_i$, então

$$\begin{aligned}
&\mathbb{P}[\,X \geqslant (1+\varepsilon)\mathbb{E}X\,] \leqslant \left(\frac{\mathrm{e}^{\varepsilon}}{(1+\varepsilon)^{1+\varepsilon}}\right)^{\mathbb{E}X} && \text{para todo } \varepsilon > 0, \text{ e} \\
&\mathbb{P}[\,X \leqslant (1-\varepsilon)\mathbb{E}X\,] \leqslant \left(\frac{\mathrm{e}^{-\varepsilon}}{(1-\varepsilon)^{1-\varepsilon}}\right)^{\mathbb{E}X} && \text{para todo } \varepsilon \in (0,1).
\end{aligned} \tag{4.19}$$

Demonstração. A primeira desigualdade é (4.18) e a segunda é o Exercício 23. □

A seguir vamos trabalhar os limitantes dos lemas acima para obtermos desigualdades mais fáceis de serem usadas. Usamos a seguinte desigualdade, cuja demonstração está no final desta seção.

Proposição 4.1

Para todo $x>0$, $(1+x)\ln(1+x)-x \geqslant \dfrac{3x^2}{6+2x}=\dfrac{x^2}{2(1+x/3)}$.

Como o limitante superior de (4.19) é igual a $\exp(-((1+\varepsilon)\ln(1+\varepsilon)-\varepsilon)\mathbb{E}X)$, a proposição dá

$$\mathbb{P}[\, X \geqslant (1+\varepsilon)\mathbb{E}X \,] \leqslant \exp\left(-\frac{\varepsilon^2\,\mathbb{E}X}{2(1+\varepsilon/3)}\right) \leqslant \exp\left(-\frac{\varepsilon^2\,\mathbb{E}X}{3}\right), \qquad (4.20)$$

em que a segunda desigualdade vale se $2(1+\varepsilon/3) \leqslant 3$, isto é, se $\varepsilon \leqslant 3/2$. Em particular, vale para $0<\varepsilon\leqslant 1$.

Para o limitante inferior, seja $h(x) := f(-x\hat{p})$, com $0 \leqslant x < 1$. Então $h(0)=0$, $h'(x)=-\hat{p}\,f'(-x\hat{p})$, $h'(0)=0$ e

$$h''(x)=\hat{p}^2 f''(-x\hat{p})=\frac{\hat{p}^2}{(\hat{p}-x\hat{p})(\hat{q}+x\hat{p})}=\frac{\hat{p}}{(1-x)(\hat{q}+\hat{p}x)} \geqslant \frac{\hat{p}}{1-x} \geqslant \hat{p},$$

pois $\hat{q}+\hat{p}x \leqslant \hat{q}+\hat{p}=1$. Portanto, pela fórmula de Taylor com resto, $h(x) \geqslant \hat{p}x^2/2$. Por (4.17) com $t=\varepsilon\hat{p}<\hat{p}$,

$$\begin{aligned}\mathbb{P}[\, X \leqslant (1-\varepsilon)\mathbb{E}X \,] &= \mathbb{P}[\, X \leqslant (\hat{p}-\varepsilon\hat{p})n \,] \\ &\leqslant \exp(-h(\varepsilon)\cdot n) \leqslant \exp\left(-\frac{\hat{p}\,\varepsilon^2 n}{2}\right) = \exp\left(-\frac{\varepsilon^2\,\mathbb{E}X}{2}\right)\end{aligned}$$

para todo $\varepsilon \in (0,1)$.

Reunindo os resultados acima, a partir do Corolário 4.2, de (4.20) e do limitante anterior, escrevemos o teorema a seguir.

Teorema 4.6: Chernoff para somas de Bernoulli

Se $X_i \sim \text{Bernoulli}(p_i)$ são independentes com $p_i \in [0,1]$ e $X=\sum_{i=1}^n X_i$, então

1. para todo $t>0$,

$$\mathbb{P}[\,|X-\mathbb{E}X|\geqslant t\,] \leqslant 2\exp\left(\frac{-2t^2}{n}\right); \qquad (4.21)$$

2. para todo $0<\varepsilon\leqslant 1$,

$$\mathbb{P}[\, X \geqslant (1+\varepsilon)\mathbb{E}X \,] \leqslant \exp\left(-\frac{\varepsilon^2\,\mathbb{E}X}{3}\right); \qquad (4.22)$$

3. para todo $0<\varepsilon<1$,

$$\mathbb{P}[\, X \leqslant (1-\varepsilon)\mathbb{E}X \,] \leqslant \exp\left(-\frac{\varepsilon^2\,\mathbb{E}X}{2}\right). \qquad (4.23)$$

Além disso, para todo $\varepsilon > 0$,

$$\mathbb{P}[\, X \geqslant (1+\varepsilon)\mathbb{E}X \,] \leqslant \exp\left(-\frac{\varepsilon^2 \mathbb{E}X}{(2+\varepsilon)}\right).$$

O item 1 é o Corolário 4.2 com t/n no lugar de t. Os casos $\hat{p} \in \{0, 1\}$, excluídos acima, são triviais, pois X é constante. A última afirmação segue de (4.20), já que $2(1+\varepsilon/3) \leqslant 2+\varepsilon$.

Observação 7. Na prática podemos ter apenas uma estimativa $0 < \alpha \leqslant \mathbb{E}X \leqslant \beta$ para a esperança. Então, para todo $t \in (0,1)$,

$$\mathbb{P}[\, X \geqslant (1+t)\beta \,] \leqslant \exp\left(-\frac{t^2\beta}{3}\right) \quad \text{e} \quad \mathbb{P}[\, X \leqslant (1-t)\alpha \,] \leqslant \exp\left(-\frac{t^2\alpha}{2}\right).$$

Para a primeira, acrescentamos a X novas variáveis de Bernoulli independentes ($k = \lceil \beta - \mathbb{E}X \rceil$ variáveis, cada uma com probabilidade $(\beta - \mathbb{E}X)/k$), de modo que a esperança total seja exatamente β, obtendo $X' \geqslant X$ com $\mathbb{E}X' = \beta$; então $\mathbb{P}[\, X \geqslant (1+t)\beta \,] \leqslant \mathbb{P}[\, X' \geqslant (1+t)\mathbb{E}X' \,]$ e basta usar o item 2 do Teorema. Para a segunda, tomamos $c = \alpha/\mathbb{E}X \leqslant 1$ e $B_i \sim \text{Bernoulli}(c)$ independentes entre si e das X_i; então $X_i' = X_i B_i \sim \text{Bernoulli}(cp_i)$ são independentes, $X'' = \sum_i X_i' \leqslant X$ e $\mathbb{E}X'' = \alpha$, logo $\mathbb{P}[\, X \leqslant (1-t)\alpha \,] \leqslant \mathbb{P}[\, X'' \leqslant (1-t)\mathbb{E}X'' \,]$ e basta usar o item 3.

Demonstração da Proposição 4.1. Seja $\varphi(x) = (1+x)\ln(1+x) - x - \dfrac{3x^2}{6+2x}$, para $x \geqslant 0$. Então $\varphi(0) = 0$,

$$\varphi'(x) = \ln(1+x) - \frac{3x(6+x)}{2(3+x)^2}, \qquad \varphi''(x) = \frac{1}{1+x} - \frac{27}{(3+x)^3},$$

e $\varphi'(0) = 0$. Como $(3+x)^3 = 27 + 27x + 9x^2 + x^3 \geqslant 27(1+x)$, temos $\varphi''(x) \geqslant 0$. Logo φ' é não decrescente, $\varphi' \geqslant \varphi'(0) = 0$, e portanto φ é não decrescente, $\varphi \geqslant \varphi(0) = 0$. □

4.5 *Soma de variáveis aleatórias geométricas*

Vamos derivar uma desigualdade do tipo Chernoff para soma de variáveis aleatórias com distribuição geométrica. Diferentemente das seções anteriores, essas variáveis são ilimitadas, e a FGM só é finita para $s < \ln 2$ (Exemplo 4.2); como o método só usa $s > 0$, basta trabalhar com $0 < s < \ln 2$.

Sejam $X_i \sim \text{Geom}(1/2)$, para $1 \leqslant i \leqslant n$, variáveis aleatórias independentes, e $X := \sum_{i=1}^n X_i$. Pelo Exemplo 4.2 com $p = 1/2$, $\mathbb{E}X = 2n$ e, para $0 < s < \ln 2$,

$$\mathbb{E}e^{sX} = \prod_{i=1}^n \mathbb{E}e^{sX_i} = \left(\frac{e^s}{2 - e^s}\right)^n.$$

Usando a desigualdade (4.1) com $t = (2+a)n$, para qualquer $a > 0$, temos

$$\mathbb{P}[\, X \geqslant (2+a)n \,] \leqslant \mathrm{e}^{-s(2+a)n}\left(\frac{\mathrm{e}^s}{2-\mathrm{e}^s}\right)^n = \left(\frac{\mathrm{e}^{-(1+a)s}}{2-\mathrm{e}^s}\right)^n.$$

Minimizamos o logaritmo da base, $-(1+a)s - \ln(2-\mathrm{e}^s)$, que é convexo em s (sua segunda derivada é $2\mathrm{e}^s/(2-\mathrm{e}^s)^2 > 0$). Seu ponto crítico satisfaz $-(1+a) + \mathrm{e}^s/(2-\mathrm{e}^s) = 0$, isto é, $\mathrm{e}^s = 2(1+a)/(2+a) = 1 + a/(2+a) \in (1,2)$, logo $s = \ln(1 + a/(2+a)) \in (0, \ln 2)$ é o mínimo, e nele, para todo $a > 0$

$$\mathbb{P}[\, X \geqslant (2+a)n \,] \leqslant \left(\left(1+\frac{a}{2}\right)\left(1-\frac{a}{2+2a}\right)^{1+a}\right)^n. \tag{4.24}$$

Usando que $1 - x \leqslant \exp(-x)$, para todo x,

$$\left(1-\frac{a}{2+2a}\right)^{1+a} \leqslant \mathrm{e}^{-a/2},$$

e que $1 + a/2 \leqslant \exp(a/4)$ para $a \geqslant 6$ (a função $\varphi(a) = a/4 - \ln(1+a/2)$ é não decrescente para $a \geqslant 2$, pois $\varphi'(a) = 1/4 - 1/(2+a) \geqslant 0$, e $\varphi(6) = 3/2 - \ln 4 > 0$),

$$\left(1+\frac{a}{2}\right)^n \leqslant \mathrm{e}^{an/4}.$$

Finalmente, para todo $a \geqslant 6$ vale que $\mathbb{P}[\, X \geqslant (2+a)n \,] \leqslant \exp(-an/4)$. Como $(2+a)n = (1+a/2)\mathbb{E}X$, fazendo $t = a/2$ obtemos o teorema a seguir.

Teorema 4.7: Chernoff para a geométrica de parâmetro $1/2$

Sejam $X_1, \ldots, X_n$ variáveis aleatórias independentes com distribuição Geom(1/2) em $\{1, 2, \ldots\}$, de modo que $\mathbb{E}X_i = 2$, e seja $X = \sum_{i=1}^n X_i$, com $\mathbb{E}X = 2n$. Então, para todo $t \geqslant 3$,

$$\mathbb{P}[\, X \geqslant 2(1+t)\, n \,] = \mathbb{P}[\, X \geqslant (1+t)\mathbb{E}X \,] \leqslant \exp\left(-\frac{tn}{2}\right). \tag{4.25}$$

□

A cota exata (4.24) vale para todo $a > 0$; o enunciado simplificado exige $t \geqslant 3$ apenas por causa da passagem $1 + a/2 \leqslant \exp(a/4)$.

4.6 *Amplificação de probabilidade em algoritmos de Monte Carlo*

Um algoritmo de Monte Carlo A tem erro bilateral no máximo $\varepsilon < 1/2$ se, para toda entrada w,

$$\mathbb{P}\big[\, A \text{ responde errado } \big] \leqslant \varepsilon < \frac{1}{2},$$

isto é, A pode responder *sim* quando a resposta correta é *não* e vice-versa. Queremos, dado $\delta \in (0,1)$, um algoritmo com erro menor que δ.

Dada a entrada w, executamos k vezes o algoritmo A sobre w, cada uma com sorteios novos e independentes das anteriores, e respondemos a resposta que aparecer mais vezes (em caso de empate, qualquer uma).

Teorema 4.8: Amplificação por maioria

Se A tem erro bilateral no máximo $\varepsilon < 1/2$, então, para toda entrada w e todo $k \geqslant 1$, em k rodadas independentes

$$\mathbb{P}\big[\text{ resposta errada }\big] \leqslant \exp\left(-\frac{k\,(1-2\varepsilon)^2}{2}\right). \tag{4.26}$$

Em particular, para todo $\delta \in (0,1)$, se

$$k > \frac{2}{(1-2\varepsilon)^2}\,\ln\frac{1}{\delta}, \tag{4.27}$$

então k rodadas de A erra com probabilidade menor que δ.

Demonstração. Fixe w e seja Z_j o indicador de que a j-ésima execução erra. As Z_j são independentes (sorteios novos a cada execução), com $Z_j \sim \text{Bernoulli}(q)$ e $q := \mathbb{P}[\,A(w) \text{ erra}\,] \leqslant \varepsilon$. Seja $Z = \sum_{j=1}^{k} Z_j$ o número de execuções erradas, de modo que $\mu := \mathbb{E}Z = qk$.

Se menos da metade das execuções erra, isto é, se $Z < k/2$, então a resposta correta aparece mais de $k/2$ vezes e vence a votação. Portanto,

$$[A(w)\ k \text{ em rodadas, erra}] \subseteq [Z \geqslant k/2].$$

Escreva $k/2 = \mu + t$, com

$$t = \frac{k}{2} - qk = k\left(\frac{1}{2} - q\right) \geqslant k\left(\frac{1}{2} - \varepsilon\right) > 0.$$

Pela desigualdade de Chernoff–Hoeffding (Teorema 4.4), com as variáveis $Z_j \in [0,1]$,

$$\mathbb{P}[\,Z \geqslant \mu + t\,] \leqslant \exp\left(-\frac{2t^2}{k}\right) \leqslant \exp\left(-2k\left(\frac{1}{2}-\varepsilon\right)^2\right) = \exp\left(-\frac{k(1-2\varepsilon)^2}{2}\right),$$

em que a segunda desigualdade usa $t \geqslant k(1/2-\varepsilon)$. Isso prova (4.26). Se vale (4.27), então o expoente é menor que $-\ln(1/\delta)$, e o erro é menor que δ. □

Duas observações sobre o enunciado. Primeiro, o número de repetições é $k = O(\ln(1/\delta))$ quando ε é uma constante menor que $1/2$: o

erro decai *exponencialmente* em k, e o custo cresce só com o *logaritmo* do erro desejado. O tempo total é k vezes o tempo de A. Segundo, a folga $\gamma := 1/2 - \varepsilon$ em relação a $1/2$ é essencial: o número de repetições é proporcional a $1/\gamma^2$, de modo que $\varepsilon = 1/2 - 1/\mathrm{poly}(n)$ ainda pode ser amplificado com um número polinomial de repetições, enquanto com $\varepsilon = 1/2$ (o algoritmo não é melhor que uma moeda) não há como amplificar.

Exemplo 4.4: Monte Carlo com erro $1/3$

Com $\varepsilon = 1/3$ temos $(1-2\varepsilon)^2 = 1/9$, e (4.27) pede $k > 18\ln(1/\delta)$.

- Para $\delta = 2^{-100}$, $18\ln(2^{100}) \approx 1247{,}7$, então $k = 1248$ repetições bastam.
- Para $\delta = n^{-c}$, o número de repetições é $k > 18\,c\ln n$, isto é, $O(\log n)$. Assim, um algoritmo com erro $1/3$ vira um algoritmo com erro $1/\mathrm{poly}(n)$ ao custo de um fator $O(\log n)$ no tempo. ◊

A cota exata. Quando ε é pequeno, a cota (4.26) desperdiça muito, pois a desigualdade de Hoeffding não distingue erros pequenos de erros próximos de $1/2$. A cota exata do Lema 4.2 (cuja prova é a mesma do método de Chernoff, sem as simplificações) dá mais. Com $\hat{p} = q$, $n = k$ e $t = 1/2 - q$, temos $\hat{p} + t = \hat{q} - t = 1/2$ e

$$\mathbb{P}[\, Z \geqslant k/2 \,] \leqslant \left(\left(\frac{q}{1/2} \right)^{1/2} \left(\frac{1-q}{1/2} \right)^{1/2} \right)^{k} = (4q(1-q))^{k/2} \leqslant (4\varepsilon(1-\varepsilon))^{k/2},$$

pois $q \mapsto 4q(1-q)$ é crescente em $[0, 1/2]$ e $q \leqslant \varepsilon$ (para $q = 0$ o erro é nulo). Como $4\varepsilon(1-\varepsilon) = 1 - (1-2\varepsilon)^2 \leqslant \exp(-(1-2\varepsilon)^2)$, essa cota implica (4.26), e dá o número de repetições

$$k > \frac{2\ln(1/\delta)}{\ln(1/(4\varepsilon(1-\varepsilon)))}.$$

Por exemplo, com $\varepsilon = 1/3$ a base é $8/9$ e $k > 16{,}98\ln(1/\delta)$ (em vez de 18); com $\varepsilon = 0{,}01$, a cota exata pede $k > 0{,}62\ln(1/\delta)$, contra $2{,}08\ln(1/\delta)$ de (4.27).

Observação 8.

- A votação só usa que a resposta correta é única. Para problemas com mais de duas respostas possíveis vale o mesmo argumento: se $Z < k/2$, a resposta correta aparece mais de $k/2$ vezes e é a mais frequente.
- Se o algoritmo devolve um *número* $\tilde{x}$ com $\mathbb{P}[\, |\tilde{x} - x| \leqslant \eta \,] \geqslant 1 - \varepsilon$, devolva a *mediana* das k execuções. Se menos da metade das execuções está fora de $[x - \eta, x + \eta]$, a mediana está dentro, e a análise é a

mesma, com o mesmo número de repetições. É o chamado "truque da mediana".

- Em termos de classes de complexidade, o teorema mostra que a constante $1/3$ na definição de BPP é arbitrária: qualquer constante em $(0, 1/2)$ define a mesma classe, e o erro pode ser reduzido até $2^{-\mathrm{poly}(n)}$.

4.7 Quicksort

Vimos duas estratégias de que o *quicksort* aleatorizado executa $O(n \ln n)$ comparações com alta probabilidade, usando propriedades de distribuições conhecidas e usando desigualdades para desvios da média (Markov e Chebyshev). Nessas últimas provas a probabilidade de falha obtida é fraca: apenas $O(1/n)$ com a desigualdade de Markov, que é a melhor delas. Nesta seção obtemos uma cota de falha muito mais forte — polinomialmente pequena em qualquer grau desejado — usando a desigualdade de Chernoff.

Preliminares. Relembramos a montagem já estabelecida. Um particionamento de S é um *sucesso* se $\min\{|S_E|, |S_D|\} \geqslant |S|/10$; a probabilidade de sucesso é $p > 0{,}76$, qualquer que seja o histórico anterior. um elemento fixo x_i participa de no máximo $\ell := \lfloor \log_{10/9} n \rfloor$ particionamentos; temos $\log_{10/9} n \approx 9{,}49 \ln n$, logo $\ell < 10 \ln n$.

A sequência de particionamentos de x_i é completada com particionamentos *fictícios* após o fim de sua participação real, cada um com sucesso de probabilidade exatamente 0,76, independentemente do passado. Isso produz uma sequência infinita em que, a cada posição, a probabilidade condicional de sucesso é sempre pelo menos 0,76.

Como antes, se M_i denota o número de particionamentos reais de que x_i participa, vale $X_i \leqslant M_i$, pois x_i é comparado com o pivô uma única vez por particionamento real do qual participa sem ser o pivô.

Dominação estocástica. Fixe uma constante $c > 10$, a ser escolhida mais adiante, e defina

$$L := c \ln n$$

(mais precisamente $\lceil c \ln n \rceil$, o que altera apenas constantes aditivas que são irrelevantes na análise). Seja B o número de sucessos entre os L primeiros particionamentos da sequência completada de x_i. Pelo Lema 3.1(a), com $\alpha = 0{,}76$ e $m = L$ tentativas,

$$B \geq \mathrm{Binomial}(L, 0{,}76).$$

Denotando por $F := L - B$ o número de *fracassos* entre esses L particionamentos, para todo t,

$$\begin{aligned}\mathbb{P}[\, F \geqslant t \,] = \mathbb{P}[\, B \leqslant L - t \,] &\leqslant \mathbb{P}[\, \text{Binomial}(L, 0{,}76) \leqslant L - t \,] \\ &= \mathbb{P}[\, \text{Binomial}(L, 0{,}24) \geqslant t \,].\end{aligned}$$

Tome $G \sim \text{Binomial}(L, 0{,}24)$, o número de fracassos de uma binomial com parâmetro de sucesso 0,76 (ou 0,24, trocando os papéis). Note que $\mathbb{E}G = 0{,}24\, L = 0{,}24\, c\, \ln n$.

O evento "muitos particionamentos". Suponha $M_i > L$. Então os L primeiros particionamentos da sequência completada de x_i são todos *reais* (pois x_i ainda não saiu do processo), e, pelo Exercício 13, contêm no máximo $\ell < 10 \ln n$ sucessos. Logo, supondo $c > 10$, o número de fracassos é

$$F = L - B \geqslant L - \ell > c \ln n - 10 \ln n = (c - 10) \ln n.$$

Combinando essa implicação com a dominação estocástica da seção anterior, obtemos a cadeia

$$\mathbb{P}[\, M_i > L \,] \;\leqslant\; \mathbb{P}[\, F \geqslant (c - 10) \ln n \,] \;\leqslant\; \mathbb{P}[\, G \geqslant (c - 10) \ln n \,],$$

onde o primeiro "$\leqslant$" é a implicação determinística recém-obtida e o segundo vem da dominação estocástica de B.

Cota de Chernoff. Usamos a seguinte forma da desigualdade de Chernoff para a cauda superior de uma soma de Bernoulli independentes.

Teorema 4.9: Desigualdade de Chernoff

Se G é soma de variáveis de Bernoulli independentes, $\mu = \mathbb{E}G$ e $\delta > 0$, então

$$\mathbb{P}[\, G \geqslant (1+\delta)\mu \,] \leqslant \exp\left(\frac{-\delta^2 \mu}{2+\delta}\right).$$

No nosso caso, $G \sim \text{Binomial}(L, 0{,}24)$ é soma de L Bernoulli independentes, com $\mu = 0{,}24\, c\, \ln n$. Queremos aplicar o teorema com $(1+\delta)\mu = (c - 10) \ln n$, isto é,

$$1 + \delta = \frac{c - 10}{0{,}24\, c}, \qquad \delta = \frac{0{,}76\, c - 10}{0{,}24\, c}.$$

Para que $\delta > 0$ (hipótese do teorema), precisamos $c > 10/0{,}76 \approx 13{,}16$; assumimos isso daqui em diante (condição mais restritiva que $c > 10$, já suposta acima).

Substituindo $\mu = 0{,}24\,c\ln n$ e o δ no limitantes exponencial do teorema,

$$\delta^2\mu = \frac{(0{,}76\,c-10)^2}{(0{,}24\,c)^2}\cdot 0{,}24\,c\,\ln n = \frac{(0{,}76\,c-10)^2}{0{,}24\,c}\,\ln n,$$

e

$$2+\delta = \frac{2\cdot 0{,}24\,c + (0{,}76\,c-10)}{0{,}24\,c} = \frac{1{,}24\,c-10}{0{,}24\,c}.$$

Dividindo,

$$\frac{\delta^2\mu}{2+\delta} = \frac{(0{,}76\,c-10)^2}{0{,}24\,c}\cdot\frac{0{,}24\,c}{1{,}24\,c-10}\,\ln n = \frac{(0{,}76\,c-10)^2}{1{,}24\,c-10}\,\ln n.$$

Definindo

$$b \coloneqq \frac{(0{,}76\,c-10)^2}{1{,}24\,c-10}$$

a desigualdade de Chernoff dá

$$\mathbb{P}[\,G \geqslant (c-10)\ln n\,] \leqslant n^{-b)},$$

e, pela cadeia de implicações da seção anterior,

$$\mathbb{P}[\,M_i > c\ln n\,] \leqslant n^{-b} \qquad \text{para cada } i.$$

Observação 9 (Dependência de δ, μ, b em c). Note que $\delta = \delta(c)$ satura: quando $c \to \infty$, temos $\delta(c) \to 19/6$. Também, $2+\delta \to 31/6$, logo para $b = b(c)$

$$\frac{\delta^2\mu}{(2+\delta)\ln n} \sim \frac{(19/6)^2}{31/6}\cdot 0{,}24\,c = \frac{361}{186}\cdot 0{,}24\,c \approx 0{,}4658\,c \xrightarrow[c\to\infty]{} \infty.$$

Alguns valores, para ilustrar o crescimento:

$$b(20)\approx 1{,}83, \quad b(30)\approx 6{,}02, \quad b(50)\approx 15{,}08, \quad b(100)\approx 38{,}21.$$

Pela união sobre os n elementos de S,

$$\mathbb{P}[\,\exists\, i : M_i > c\ln n\,] \leqslant n\cdot n^{-b} = n^{1-b}.$$

Em particular, $\mathbb{P}[\,\exists\, i : M_i > 30\ln n\,] \leqslant n\cdot n^{-b} < n^5$.

Dado qualquer $a > 0$ desejado para o expoente final da probabilidade de falha, basta escolher c de modo que $b(c) \geqslant a+1$. Escrevendo $K \coloneqq a+1$ e expandindo $b(c) = K$,

$$(0{,}76\,c-10)^2 = K\,(1{,}24\,c-10) \iff 0{,}5776\,c^2 - (15{,}2+1{,}24K)\,c + (100+10K) = 0,$$

cuja raiz positiva relevante (a maior das duas) é

$$c = \frac{(15{,}2+1{,}24K) + \sqrt{(15{,}2+1{,}24K)^2 - 4\cdot 0{,}5776\,(100+10K)}}{2\cdot 0{,}5776}.$$

Como $b(c) \to \infty$ quando $c \to \infty$, essa equação sempre admite solução real para qualquer $K > 0$, isto é, para qualquer $a > 0$ desejado. Por exemplo, $a = 6$ (logo $K = 7$) dá $c \approx 32{,}2$; conferindo, $b(32{,}2) \approx 7{,}00 = K$, como esperado. Com essa escolha,

$$\mathbb{P}[\, \exists\, i : M_i > c \ln n \,] < n^{-a}.$$

Concluindo, fixada a constante c (e, portanto, a) como acima, com probabilidade pelo menos $1 - n^{-a}$ vale $X_i \leqslant M_i \leqslant c \ln n$ para todo $i \in \{1, \ldots, n\}$. Como cada comparação com um pivô é contabilizada uma única vez, pelo elemento não-pivô envolvido,

$$T = \sum_{i=1}^{n} X_i \leqslant c \cdot n \cdot \ln n = O(n \ln n).$$

Somando as $O(n)$ comparações realizadas pela ordenação por força bruta nas folhas da recursão, concluímos que o número total de comparações do *quicksort* aleatorizado é

$$T = O(n \ln n) \qquad \text{com probabilidade } 1 - O(n^{-a}),$$

onde $a > 0$ é uma constante que pode ser escolhida livremente, ao custo de uma constante multiplicativa maior (via c) escondida no $O(n \ln n)$.

4.8 Exercícios

Exercício 24. Reescreva a prova do Teorema 4.8 usando, no lugar do Teorema 4.4, o item 2 do Teorema 4.6 (cota multiplicativa) com $\mathbb{E}Z \leqslant \varepsilon k$. Que cota você obtém, e por que ela é pior quando ε está próximo de $1/2$?

Exercício 25. Seja X uma variável aleatória com $\mathrm{Var}(\, X \,) = 0$ (em particular, quadrado integrável). Prove que $\mathbb{P}[\, X = \mathbb{E}X \,] = 1$. (*Dica*: use a desigualdade de Chebyshev para mostrar que $\mathbb{P}[\, |X - \mathbb{E}X| \geqslant 1/k \,] = 0$ para todo inteiro $k \geqslant 1$, e a subaditividade para a união enumerável sobre k.)

Exercício 26. Seja X uma variável aleatória quadrado integrável com $\mathrm{Var}(\, X \,) > 0$. Calcule a esperança e a variância da variável aleatória

$$Y \coloneqq \frac{X - \mathbb{E}X}{\sqrt{\mathrm{Var}(\, X \,)}}.$$

Exercício 27. Prove que, se X e Y são variáveis aleatórias simples e $M_X(s) = M_Y(s)$ para todo $s \in \mathbb{R}$, então X e Y têm a mesma distribuição.

(*Dica*: sejam $a_1 < \cdots < a_m$ os valores possíveis de X ou de Y e $c_j = \mathbb{P}\big[\, X = a_j \,\big] - \mathbb{P}\big[\, Y = a_j \,\big]$. Então $\sum_{j=1}^{m} c_j \mathrm{e}^{a_j s} = 0$ para todo s. Se algum $c_j \neq 0$, tome o maior j com essa propriedade, divida por $\mathrm{e}^{a_j s}$ e faça $s \to \infty$.)

Observação. O resultado vale, mais geralmente, para variáveis cuja FGM é finita em algum intervalo $(-x_0, x_0)$ com $x_0 > 0$ (veja, por exemplo, Billingsley 1995); essa hipótese não pode ser retirada: se X tem densidade $\frac{1}{2}|x|^{-3}$ em $|x| \geqslant 1$, então X e $2X$ têm FGM igual a $+\infty$ para todo $s \neq 0$, mas distribuições diferentes.

Exercício 28. Prove que se $X_1, \ldots, X_n$ são variáveis aleatórias independentes com distribuição de Rademacher e $t \in (0,1)$, então

$$\mathbb{P}\left[\, \frac{1}{n}\sum_{i=1}^{n} X_i \geqslant t \,\right] \leqslant \exp\!\Big(-\frac{n}{2}\big((1+t)\ln(1+t) + (1-t)\ln(1-t)\big)\Big). \quad (4.28)$$

(*Dica*: para $s > 0$, aplique a desigualdade de Markov a $\mathrm{e}^{s\sum_i X_i}$ e use $\mathbb{E}\mathrm{e}^{sX_i} = \cosh s$ para obter $\mathbb{P}[\, \sum_i X_i \geqslant nt \,] \leqslant (\cosh(s)\,\mathrm{e}^{-st})^n$. Depois minimize $f(s) = \cosh(s)\,\mathrm{e}^{-st}$ em $s > 0$ usando técnicas de Cálculo Diferencial: mostre que o ponto crítico satisfaz $\tanh s = t$ e que então $\cosh s = (1-t^2)^{-1/2}$.)

Exercício 29. Seja $g(t) = (1+t)\ln(1+t) + (1-t)\ln(1-t)$ para $t \in [0,1)$. Mostre que $g(t) \geqslant t^2$ (dica: $g(0) = g'(0) = 0$ e $g''(t) = 2/(1-t^2)$) e conclua que o lado direito de (4.28) é no máximo $\mathrm{e}^{-nt^2/2}$. Compare com o Teorema 4.2.

Exercício 30. Dizemos que X é uma (ε, δ)-aproximação para a quantidade V se $\mathbb{P}[\, |X - V| \leqslant \varepsilon V \,] \geqslant 1 - \delta$. Sejam $X_1, \ldots, X_m$ variáveis aleatórias independentes com valores em $[0,1]$ e $\mathbb{E}X_i = \mu > 0$ para todo i. Denotemos por $\overline{X}_m$ a média amostral, $\overline{X}_m = (1/m)\sum_{i=1}^{m} X_i$. Prove que, para $0 < \varepsilon \leqslant 1$, se $m \geqslant 3\ln(2/\delta)/(\varepsilon^2\mu)$ então

$$\mathbb{P}[\, \big|\overline{X}_m - \mu\big| \geqslant \varepsilon\mu \,] \leqslant \delta \quad (4.29)$$

e conclua, passando ao evento complementar, que a média amostral é uma (ε, δ)-aproximação para μ.

Exercício 31. (Karp e Luby, 1983) Suponha que sejam dados conjuntos finitos $S_1, S_2, \ldots, S_n$ com cardinalidades conhecidas e tais que seja possível sortear elementos uniformemente de cada S_i e testar em tempo constante se $x \in S_i$. O algoritmo a seguir estima a cardinalidade da união desses conjuntos. Defina $\mathrm{cob}(x) := |\{i : x \in S_i\}|$ e $s := \sum_{i=1}^{n} |S_i|$.

Instância: conjuntos $S_1, S_2, \ldots, S_n$.
Resposta: uma estimativa para $\left|S_1 \cup S_2 \cup \cdots \cup S_n\right|$.

1 escolha $T \in_{\mathcal{D}} \{S_1, S_2, \ldots, S_n\}$ de acordo com a lei $\mathcal{D}(S_i) = |S_i|/s$
2 $x \leftarrow_{\mathrm{R}} T$
3 compute $\mathrm{cob}(x)$
4 $X \leftarrow \dfrac{s}{\mathrm{cob}(x)}$
5 **responda** X.

Algoritmo 1: Algoritmo de Karp–Luby

Prove que $\mathbb{E}X = \left|\bigcup_{i=1}^{n} S_i\right|$ e que $\mathrm{Var}(X) \leqslant (n-1)\mathbb{E}(X)^2$.

Exercício 32. Sejam $X_1, X_2, \ldots, X_m$ as respostas de m rodadas independentes do Algoritmo 1 com a mesma entrada, $\overline{X}_m$ a média amostral dessas rodadas e $V = \left|\bigcup_{i=1}^{n} S_i\right|$. Seja $0 < \varepsilon \leqslant 1$.

(a) Prove que, se $n \geqslant 3$ e $m \geqslant (9/2)(n-1)(1/\varepsilon^2)\ln(2/\delta)$, então $\overline{X}_m$ é uma (ε, δ)-aproximação para V. *Dica:* aplique o Exercício 1 às variáveis X_i/s e use que $s \leqslant nV$.

(b) Usando a desigualdade de Chebyshev e o exercício anterior, prove que se $m \geqslant (n-1)/(\varepsilon^2\delta)$ então $\overline{X}_m$ é uma (ε, δ)-aproximação para V. Note que essa cota vale para todo $n \geqslant 2$, mas depende de $1/\delta$ e não de $\ln(1/\delta)$.

Exercício 33 (***Truque da mediana***). Para recuperar a dependência logarítmica em δ no Exercício 32 item (b), proceda assim:

(a) Tome $m_0 = \lceil 4(n-1)/\varepsilon^2 \rceil$ e mostre, por (b) com $\delta = 1/4$, que a média de m_0 rodadas é uma $(\varepsilon, 1/4)$-aproximação para V.

(b) Repita o procedimento de (i) de forma independente k vezes, obtendo $Y_1, \ldots, Y_k$, e seja Y a mediana desses valores. Chame Y_j de *ruim* se $|Y_j - V| > \varepsilon V$ e seja N o número de Y_j ruins. Mostre que $N < k/2$ implica $|Y - V| \leqslant \varepsilon V$.

(c) Use o limitante de Chernoff (cauda superior, com $\mathbb{E}N \leqslant k/4$) para mostrar que $\mathbb{P}[N \geqslant k/2] \leqslant e^{-k/12}$ e conclua que, para $k \geqslant 12\ln(1/\delta)$, Y é uma (ε, δ)-aproximação para V usando $O\big((n/\varepsilon^2)\ln(1/\delta)\big)$ rodadas do Algoritmo 1.

5
Skip Treap & Streaming
Estruturas de dados aleatorizadas

5.1 Skip list

Uma ***skip list*** (Pugh, 1989) é uma estrutura de dados para representar conjuntos dinâmicos que usa aleatoriedade para obter, em tempo esperado, desempenho comparável ao de uma árvore de busca balanceada[1], com a vantagem de ser mais simples de implementar e de manter.

[1] Uma árvore binária balanceada é uma árvore com raiz r cujas subárvores esquerda e direita satisfazem algum critério de balanceamento como, por exemplo, a diferença entre as alturas ser de no máximo 1. Um critério bom garante que a altura da árvore é logarítmica no número de elementos, o que faz uma busca ser rápida. Em contrapartida, toda alteração exige o esforço de recompor o balanceamento.

Numa *skip list* mantemos um conjunto S de n elementos distintos de um universo U dotado de ordem total. Os elementos de S são mantidos em uma lista ligada ordenada, a ***lista do nível*** 0, denotada S_0 ($S_0 = S$). Dada a lista S_i do nível $i \geqslant 0$, a ***lista do nível*** $i+1$, denotada S_{i+1}, é um subconjunto aleatório de S_i no qual cada elemento de S_i é escolhido com probabilidade $1/2$, com as escolhas independentes. A lista S_{i+1} é ordenada e cada elemento seu tem um apontador para a sua cópia imediatamente abaixo, no nível S_i. No último nível, digamos H (é uma variável aleatória) temos $S_H = \varnothing$. A estrutura tem os níveis $0, 1, \ldots, H$, dos quais só o último é vazio.

Além dos elementos de S mantemos dois sentinelas em cada nível, $-\infty$ no começo e $+\infty$ no fim de cada lista (inclusive da vazia S_H), que não pertencem a U. Todas as listas são duplamente ligadas. Um apontador topo aponta para o sentinela $-\infty$ do nível H. A Figura 5.1 descreve um exemplo.

As operações de dicionário são descritas a seguir.

busca: Dado $x \in U$, a busca devolve um apontador para o maior elemento de S_0 menor ou igual a x. Assim, devolve o próprio x se $x \in S$; caso contrário, devolve o antecessor de x caso x estivesse em S, e o próximo elemento de S_0 é o menor elemento maior que x. A busca começa em topo. Em cada nível, enquanto o próximo elemento da lista é menor ou igual a x, a busca avança por ele;

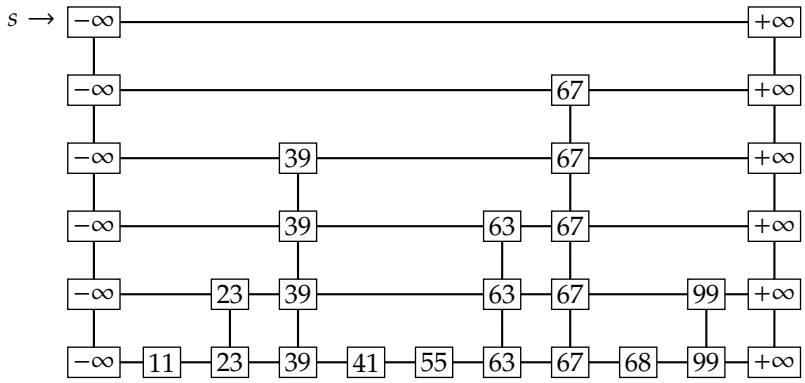


Figura 5.1: exemplo de uma *skip list* com 6 níveis que representa o conjunto $\{11, 23, 39, 41, 55, 63, 67, 68, 99\}$.

quando o próximo é maior que x, ela desce um nível pela cópia abaixo, e termina quando não é possível descer, isto é, no nível 0. O último nó visitado em cada nível i é o maior elemento de S_i menor ou igual a x. A Figura 5.2 destaca um exemplo na estrutura da Figura 5.1;

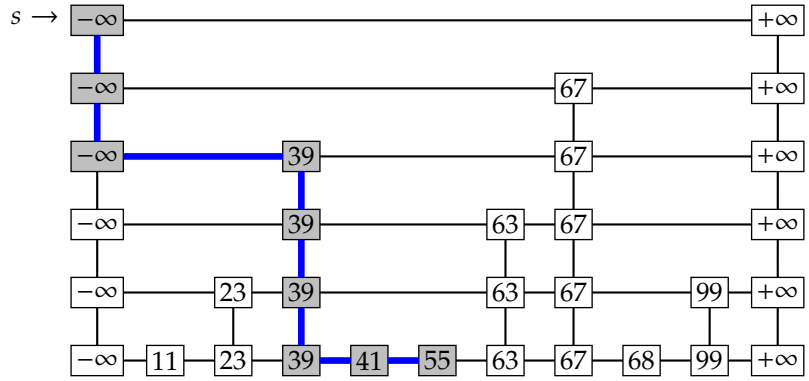


Figura 5.2: O caminho da busca por 55 na *skip list* da Figura 5.1.

inserção: Dado $x \in U$, a inserção coloca x no lugar apropriado da estrutura caso ele não esteja. Supondo $x \notin S$, uma busca por x determina, para cada nível i, o último nó a_i visitado nele, que é o antecessor de x nesse nível; esses nós são guardados durante a busca. Inserimos x em S_0 logo depois de a_0. Em seguida jogamos uma moeda: se der cara, inserimos uma cópia de x no nível 1 logo depois de a_1, ligada à cópia de baixo, e jogamos outra moeda para decidir se há inclusão no nível 2, e assim sucessivamente até sair coroa. Se a replicação chega a um nível que ainda não existe, criamos esses níveis (com sentinelas) e mais um nível vazio no topo, de modo que o último nível continue vazio; assim, H (o índice do último nível) pode aumentar numa inserção;

remoção: Dado $x \in s$, uma busca por x passa por todas as cópias de x, da mais alta, no nível $h(x)$, até a do nível 0. Cada cópia é retirada

de sua lista usando os apontadores para o elemento anterior e o seguinte, que é o motivo de as listas serem duplamente ligadas. Depois, eliminamos os níveis do topo que ficaram vazios; se x era o único elemento dos r níveis mais altos não vazios, então H diminui de r.

Em cada uma das operações, o custo é proporcional ao comprimento do caminho percorrido pela busca, que tem as H descidas mais os passos horizontais. Essas quantidades são variáveis aleatórias, e dependem da estrutura sorteada.

Como $\mathbb{E}|S_i| = n/2^i$ fica abaixo de 1 quando $i > \log_2 n$, esperamos que $H \approx \log_2 n$ e que nos níveis mais altos os nós sejam muito esparsos, de modo que uma busca caminha pouco na horizontal em cada um dos níveis mais altos e, no total, a quantidade de passos de uma busca seja de ordem logarítmica no tamanho do conjunto.

Observemos que sortear as listas nível a nível, ou jogar moedas a cada inserção, produz a mesma distribuição de alturas e que a remoção de um elemento não afeta as alturas dos demais. Por isso, nas análises seguintes supomos que a sequência de operações não depende dos sorteios feitos pela estrutura. Vamos estudar essa estrutura de dados e, para isso, começamos definindo alguns parâmetros importantes.

A ***altura de x***, para todo $x \in S$, é denotada por $h(x)$ e é o número de sorteios realizados na inserção de x. Assim, $h(x) \sim \text{Geom}(1/2)$. Além disso, $h(x)$ também é o número de cópias de x:

$$x \in S_i \text{ se, e somente se, } i < h(x).$$

A ***altura da skip list*** S é

$$H \coloneqq \max_{x \in S} h(x)$$

com $S_H = \varnothing$. No exemplo da Figura 5.1, $h(11) = 1$ e $h(67) = 5 = H$.

De $h(x) \sim \text{Geom}(1/2)$ temos

$$\mathbb{P}[\, h(x) = t \,] = 2^{-t} = \mathbb{P}[\, h(x) > t \,] \tag{5.1}$$

para todo inteiro $t \geqslant 1$. Como $x \in S_i$ equivale a $h(x) > i$ e as alturas são independentes,

$$|S_i| \sim \text{Binomial}(n, 2^{-i}).$$

Podemos calcular a esperança de H, que é uma variável aleatória inteira positiva, pela Proposição 2.6

$$\begin{aligned} \mathbb{E}H &= \sum_{i \geqslant 0} \mathbb{P}[\, H > i \,] \\ &= \sum_{i=0}^{m} \mathbb{P}[\, H > i \,] + \sum_{i > m} \mathbb{P}[\, H > i \,], \qquad m \coloneqq \lfloor \log_2 n \rfloor. \end{aligned} \tag{5.2}$$

No primeiro somatório limitamos, trivialmente, cada termo por $\mathbb{P}[\,H > i\,] \leqslant 1$. No segundo, usamos a subaditividade e a equação (5.1), para obtermos

$$\mathbb{P}[\,H > i\,] \leqslant \mathbb{P}\left[\bigcup_{x\in S}[h(x) > i]\right] \leqslant \sum_{x\in S}\mathbb{P}[\,h(x) > i\,] = n\,2^{-i},$$

para cada i. Agora, $\sum_{i>m} 2^{-i} = 2 - \sum_{i\leqslant m} 2^{-i} = 2 - (2 - 2^{-m}) = 2^{-m}$, e juntando as estimativas

$$\mathbb{E}H \leqslant m + 1 + n\sum_{i>m} 2^{-i} = m + 1 + n\,2^{-m} < m + 3, \tag{5.3}$$

em que a última desigualdade vale porque $m > \log_2 n - 1$ implica $2^m > n/2$, isto é, $n\,2^{-m} < 2$. Ou seja, como intuímos alguns parágrafos acima, de fato a estrutura tem altura esperada logarítmica no número de elementos de S (como numa árvore balanceada de busca)

$$\mathbb{E}H < \log_2 n + 3.$$

Mais que isso, a altura é logarítmica no número de elementos de S com alta probabilidade.

Como $h(x)$ é inteira, para $\alpha \in \mathbb{R}_+$ vale $h(x) > \alpha$ se e somente se $h(x) > \lfloor\alpha\rfloor$, logo

$$\mathbb{P}\big[\,h(x) > 2\log_2(n) + 1\,\big] = 2^{-\lfloor 2\log_2(n)+1\rfloor} < 2^{-2\log_2(n)} = n^{-2}$$

(pois $\lfloor\alpha\rfloor + 1 > \alpha$) e, pela subaditividade,

$$\mathbb{P}\left[\bigcup_{x\in S}[h(x) > 2\log_2 n + 1]\right] \leqslant \sum_{x\in S}\mathbb{P}\big[\,h(x) > 2\log_2 n + 1\,\big] < n\cdot\frac{1}{n^2} = \frac{1}{n}, \tag{5.4}$$

ou seja, $H \leqslant 2\log_2 n + 1$ com alta probabilidade. Note que, nas contas acima, só usamos a distribuição *marginal* de cada $h(x)$, e não a independência das alturas.

Proposição 5.1: A altura é logarítmica com alta probabilidade

Se S é uma *skip list* para um conjunto com n elementos então a altura $H = H(S)$ satisfaz

$$\mathbb{E}H < \log_2 n + 3 \qquad \text{e} \qquad \mathbb{P}\big[\,H > 2\log_2 n + 1\,\big] < \frac{1}{n}.$$

O tamanho da estrutura

Seja $N := 2(H+1) + \sum_{i=0}^{H} |S_i|$ o número de nós na *skip list* (cada nível tem dois sentinelas). Como todo $x \in S$ tem $h(x)$ cópias,

$$\sum_{i=0}^{H} |S_i| = \sum_{x \in S} h(x).$$

Da linearidade da esperança, da igualdade acima e de $\mathbb{E}h(x) = 2$,

$$\mathbb{E}N = 2\,\mathbb{E}H + 2 + \sum_{x \in S} \mathbb{E}(\, h(x)\,) = 2n + 2\,\mathbb{E}H + 2 \tag{5.5}$$

e como $\mathbb{E}H < \log_2 n + 3$, temos $\mathbb{E}N = (2 + o(1))n$. Mais que isso, $\mathbb{E}N = O(n)$ com alta probabilidade. De fato, $\sum_{x \in S} h(x)$ é soma de n variáveis Geom(1/2) independentes (cada elemento é sorteado com moedas próprias). Para $a = 2$, a cota exata de Chernoff para soma de geométricas, equação (4.24), dá

Como $|S_i| = 0$ para $i > H$, a soma $\sum_{i=0}^{H} |S_i|$ coincide com $\sum_{i \geqslant 0} |S_i|$, e a linearidade se aplica. Já o termo $2(H+1)$ dos sentinelas depende de H, que é *aleatório*; por isso entra $\mathbb{E}H$ em $\mathbb{E}N$ (veja o Exercício 36 no final deste capítulo).

$$\mathbb{P}\left[\sum_{x \in S} h(x) \geqslant 4n \right] \leqslant \left(2\left(\frac{2}{3}\right)^3\right)^n = \left(\frac{16}{27}\right)^n < (0{,}6)^n < \mathrm{e}^{-0{,}5\,n}$$

portanto, temos $\sum_{x \in S} h(x) < 4n$ com probabilidade $< \exp(-n/2)$ e, pela Proposição 5.1, $2H + 2 > 4\log_2 n + 4$ com probabilidade $\leqslant 1/n$. Como $N \leqslant 4n + 4\log_2 n + 4 \leqslant 5n$ para todo $n \geqslant 24$, temos $N > 5n$ com probabilidade pelo menos $1 - 1/n - \exp(-n/2)$, uma *skip list* que representa um conjunto com n elementos usa espaço $O(n)$.

Proposição 5.2: O tamanho é linear com alta probabilidade

Se S é uma *skip list* para um conjunto com n elementos então o tamanho N satisfaz

$$\mathbb{E}N = (2 + o(1))n \qquad \text{e} \qquad \mathbb{P}[\, N > 5n \,] = O\left(\frac{1}{n}\right).$$

5.1.1 *O tempo de uma busca*

Para determinar o número esperado de passos numa busca sobre uma *skip list* vamos limitar o número de comparações em dois grupos de níveis: os mais altos e os mais baixos. Em cada nível visitado, a busca compara x com o próximo elemento da lista: se ele é menor ou igual a x, a busca *avança* no mesmo nível; caso contrário, *desce* um nível (ou termina, no nível 0). Assim, o número de comparações no nível i é o número a_i de avanços nele mais uma comparação, a que provoca a descida ou o término, totalizando

$$\sum_{i=0}^{H} (a_i + 1)$$

comparações.

Fixado $\ell := \lfloor \log_2 n \rfloor$, os níveis altos são os níveis $\ell, \ell+1, \ldots, H$ e os níveis baixos $0, 1, \ldots, \ell-1$.

Proposição 5.3: Comparações nos níveis altos

O número esperado de comparações feitas, durante uma busca, nos níveis $\ell, \ldots, H$ de uma *skip list* com n elementos é menor que 9.

Demonstração. Seja $N' := \sum_{i \geqslant \ell} |S_i|$ o número de cópias de elementos nesses níveis ($S_i = \varnothing$ para $i \geqslant H$). O número de comparações é

$$= \underbrace{\left(\sum_{i \geqslant \ell} a_i \right)}_{\text{avanços}} + \underbrace{\text{níveis visitados}}_{\text{uma comparação por nível}} .$$

em cada nível a busca visita cada nó no máximo uma vez, logo o número total de avanços nesses níveis é no máximo N'. O número de níveis visitados é no máximo $H - \ell + 1$. Se $H > \ell$, os níveis $\ell, \ldots, H-1$ são não vazios, e então $H - \ell \leqslant N'$; só o nível H, vazio, não é contado em N'. Cada nível visitado contribui com uma comparação além dos avanços, de modo que o número de comparações nos níveis $\geqslant \ell$ é

$$\leqslant N' + (H - \ell + 1) \leqslant N' + (N' + 1) = 2N' + 1.$$

Resta estimar $\mathbb{E}N'$. Como $x \in S_i$ se, e somente se, $i < h(x)$, cada elemento x tem[2] $(h(x) - \ell)^+$ cópias nesses níveis, logo $N' = \sum_{x \in S} (h(x) - \ell)^+$ e, por (5.1),

$$\mathbb{E}(h(x) - \ell)^+ = \sum_{i \geqslant \ell} \mathbb{P}[\, h(x) > i \,] = \sum_{i \geqslant \ell} 2^{-i} = 2 \cdot 2^{-\ell}.$$

Como $2^\ell > n/2$, vale $n\, 2^{-\ell} < 2$ e, pela linearidade, $\mathbb{E}N' = 2n\, 2^{-\ell} < 4$. Logo o número esperado de comparações nos níveis mais altos é menor que $2 \cdot 4 + 1 = 9$. □

[2] $x^+ = \max\{x, 0\}$.

O segundo passo é estimar o número de comparações nos ℓ níveis mais baixos, $0, \ldots, \ell - 1$, onde se concentram a maior parte dos elementos. A ideia-chave é percorrer o caminho da busca *de trás para frente*.

Ideia importante

O caminho reverso: suponha que o caminho da busca de x termina, no nível 0, no nó y que é o maior elemento de S_0 menor

ou igual a x (ou $-\infty$). O *caminho reverso* começa em y e, estando em um nó v do nível i, o próximo passo

- **sobe**, se v tem cópia no nível $i+1$, isto é, se $v \in S_{i+1}$;
- **para a esquerda**, ao elemento anterior de S_i, caso contrário.

Isso reproduz exatamente o caminho da busca: se v ocorre em S_{i+1}, então v é o último elemento de S_{i+1} menor ou igual a x, e a busca chegou a v descendo do nível $i+1$; se $v \notin S_{i+1}$, então a busca chegou a v avançando no nível i.

Cada passo reverso para cima corresponde a uma descida e cada passo para a esquerda, a um avanço. O número de comparações nos níveis $0, \ldots, \ell - 1$ é

$$\sum_{i=0}^{\ell-1} (a_i + 1) = T,$$

o número de passos do caminho reverso do nível 0 ao nível ℓ (as ℓ subidas e os $\sum_{i<\ell} a_i$ passos à esquerda). Se $H < \ell$, a busca só tem os níveis $0, \ldots, H$ e o número de comparações é menor.

Qual é a probabilidade de um passo reverso ser para cima? Ela é a probabilidade de $v \in S_{i+1}$, dado que $v \in S_i$, que é $1/2$. Além disso, o caminho reverso nunca visita duas vezes o mesmo par (elemento, nível), então cada passo depende de uma moeda que ainda não foi examinada (princípio das decisões adiadas[3]). Logo cada passo é "para cima" com probabilidade $1/2$, independentemente dos anteriores.

Para ir do nível 0 ao nível ℓ são necessárias ℓ subidas. O número de passos de cada trecho "esquerda, ..., esquerda, sobe" é o número de moedas até a primeira cara, ou seja, tem distribuição Geom(1/2), com valores em $\{1, 2, \ldots\}$ e média 2.

O caminho reverso pode, porém, alcançar o sentinela $-\infty$ (ou o último nível antes de completar as ℓ subidas) e daí em diante só sobe, sem passos horizontais. Imaginando que o processo continua com moedas fictícias (como nos particionamentos fictícios do *quicksort*), o número T de passos reverso até o nível ℓ satisfaz

$$T \leqslant G_1 + \cdots + G_\ell, \qquad G_j \sim \text{Geom}(1/2) \text{ independentes},$$

e, pela linearidade da esperança, $\mathbb{E}T \leqslant 2\ell$. O custo esperado nos níveis mais baixos é, portanto, no máximo 2ℓ.

[3] Quando um algoritmo ou uma análise depende de muitas escolhas aleatórias, não é preciso sortear todas de antemão. Podemos sortear cada uma só no momento em que ela é consultada pela primeira vez. Se a escolha, no momento da consulta, ainda é uniformemente distribuída e independente de tudo o que foi observado até ali, o resultado é idêntico em lei ao de sortear tudo no início.

Teorema 5.1: O tempo esperado de uma busca

O número esperado de comparações feitas por uma busca em uma *skip list* que representa um conjunto com n elementos é

$O(\log n)$.

Demonstração. As comparações dos níveis $0, \ldots, \ell - 1$ têm esperança no máximo 2ℓ, e as dos níveis $\ell, \ldots, H$ têm esperança menor que 9. Pela linearidade da esperança, o total é menor que

$$2\lfloor \log_2 n \rfloor + 9 = O(\log n). \qquad \square$$

Teorema 5.2

Numa *skip list* que representa um conjunto S com cardinalidade $n \geqslant 3$, para todo $x \in U$ fixado, uma busca por x faz mais de $15 \log_2 n$ comparações com probabilidade no máximo $2n^{-2}$. Além disso, com probabilidade pelo menos $1 - 3/n$, *toda* busca, por qualquer $x \in U$, faz no máximo $15 \log_2 n$ comparações.

Demonstração. Sejam

$$\begin{aligned} L &\coloneqq \log_2 n, \\ a &\coloneqq \lceil 3L \rceil, \\ c &\coloneqq \lceil 15L \rceil. \end{aligned}$$

Seja T o número de comparações da busca, que é o número de passos do caminho reverso.

Como T é inteiro, $T > 15L$ implica $T \geqslant c$. Os eventos $[H \leqslant a]$ e $[H > a]$ particionam o espaço amostral; logo

$$\begin{aligned} [T > 15L] &\subseteq [T \geqslant c] \\ &= \big([T \geqslant c] \cap [H > a]\big) \cup \big([T \geqslant c] \cap [H \leqslant a]\big) \\ &\subseteq [H > a] \cup \big([T \geqslant c] \cap [H \leqslant a]\big) \end{aligned}$$

e, pela subaditividade,

$$\mathbb{P}[\, T > 15L \,] \leqslant \mathbb{P}[\, H > a \,] + \mathbb{P}(\, [T \geqslant c] \cap [H \leqslant a] \,) \tag{5.6}$$

Como $\mathbb{P}[\, h(x) > a \,] = 2^{-a} \leqslant 2^{-3L} = n^{-3}$, a subaditividade sobre os n elementos dá

$$\mathbb{P}[\, H > a \,] \leqslant \sum_{x \in S} \mathbb{P}[\, h(x) > a \,] \leqslant n \cdot n^{-3} = n^{-2}. \tag{5.7}$$

Percorremos o caminho reverso a partir do nó final em S_0, completado por moedas fictícias depois que chega a $-\infty$. Pelo princípio das decisões adiadas, os passos são determinados por uma sequência $f_1, f_2, \ldots$ de moedas justas independentes (cara = subir), e, se

$$\tau_j \text{ é o instante da } j\text{-ésima cara em } (f_i)_i,$$

Se a altura fosse um número fixo $H = k$ e o caminho nunca chegasse a $-\infty$ antes do topo, o caminho reverso seria: lançar moedas justas até obter a k-ésima cara $\tau_k \sim \mathrm{BN}(k, 1/2)$. Entretanto, (1) quando o caminho chega a $-\infty$ antes de completar as subidas, os passos restantes são só subidas, sem moeda, $T \leqslant \tau_k$; (2) H é variável aleatória e está correlacionada com as moedas que o caminho, condicionar em $H = k$ muda a lei das moedas (por exemplo, força que algum elemento tenha $h(x) = k$ e nenhum tenha mais). Daí a estratégia da prova: usar a monotonicidade de τ_j em j para a inclusão em (5.8) em que τ_a é binomial negativa com parâmetro fixo a (f_i)$_i$ é i.i.d. por construção e a aleatoriedade de H é tratada à parte

então $T \leqslant \tau_H$, pois o caminho tem H subidas e cada uma é precedida, em $(f_i)_i$, pelos passos à esquerda, os avanços, que lhe correspondem. Como τ_j é crescente em j,

$$H \leqslant a \implies T \leqslant \tau_a$$

ou seja, $[H \leqslant a] \subseteq [T \leqslant \tau_a]$, então $[T \geqslant c] \cap [H \leqslant a] \subseteq [c \leqslant T \leqslant \tau_a]$, portanto

$$[T \geqslant c] \cap [H \leqslant a] \subseteq [\tau_a \geqslant c] \tag{5.8}$$

Além disso, $\tau_a \geqslant c$ equivale a haver menos de a caras em $f_1, \ldots, f_{c-1}$. Tome B como o número de caras nesses $c-1$ lançamentos. A variável B tem distribuição Binomial$(c-1, 1/2)$ e temos

$$[\tau_a \geqslant c] = [B < a]$$

Retomando (5.6) e (5.7), temos

$$\mathbb{P}[\, T > 15L \,] \leqslant n^{-2} + \mathbb{P}[\, B < a \,]$$

e para fechar a prova, usamos a desigualdade de Chernoff–Hoeffding (Teorema 4.4) fazendo $a = \mathbb{E}B - t$, ou seja, tomando

$$\begin{aligned} t &\coloneqq a - \mathbb{E}B \\ &< 3L + 1 - (c-1)/2 \\ &< 3L + 1 - (15L - 1)/2 \\ &= -4{,}5L + 0{,}5 \end{aligned}$$

de modo que a probabilidade de $B < a$ é

$$\leqslant \mathbb{P}[\, B \leqslant \mathbb{E}B - t \,] \leqslant \exp\left(-\frac{2t^2}{c-1}\right) \leqslant \exp\left(-\frac{2(4{,}5L - 1{,}5)^2}{15L}\right).$$

No lado direito, no argumento da função exponencial, usando que $1{,}4\ln(n) < \log_2(n) = L < 1{,}5\ln(n)$, temos que o expoente pode ser limitado superiormente por

$$\begin{aligned} \frac{-40{,}5L^2 + 27L - 4{,}5}{15L} &= -2{,}7L + 1{,}8 - \frac{0{,}3}{L} \\ &< -2{,}7 \cdot (1{,}4\ln(n)) + 1{,}8 \\ &= -3{,}78\ln(n) + 1{,}8 \end{aligned}$$

logo Aplicando a função exponencial, obtemos:

$$\exp\left(-\frac{2(4{,}5L - 1{,}5)^2}{15L}\right) < \exp(-3{,}78\ln(n) + 1{,}8) = e^{1{,}8} \cdot n^{-3{,}78} = O(n^{-3{,}78}).$$

Como $3{,}78 > 2$, para n suficientemente grande, este termo é estritamente menor ou igual a n^{-2}. Portanto, substituindo de volta na cota total da probabilidade

$$\mathbb{P}[\, T > 15L \,] \leqslant n^{-2} + n^{-2} = 2n^{-2} = O(n^{-2}),$$

o que prova que a cauda da distribuição decai polinomialmente, concluindo a demonstração.

Todas as buscas. Uma busca por x termina, no nível 0, no nó $y_0 := \max\{\, u \in S : u \leqslant x \,\}$ (com $y_0 = -\infty$ se não houver tal u). Para todo $u \in S$ vale

$$u \leqslant x \iff u \leqslant y_0$$

e $+\infty$ é maior que ambos; logo todas as comparações da busca por x têm o mesmo resultado que as da busca por y_0, e as duas buscas percorrem o mesmo caminho. Assim, o caminho (e o número T de seus passos) depende de x apenas por meio de y_0, que pertence a $S \cup \{-\infty\}$, um conjunto com $n+1 \leqslant 2n$ elementos. Isso vale para todo $x \in U$, esteja ou não em S.

O evento $[H > a]$ não depende de y_0 e entra uma só vez; o evento $[B < a]$ entra uma vez para cada y_0. Logo

$$\mathbb{P}\big[\, \exists \text{ busca com } > 15L \text{ passos} \,\big] \leqslant n^{-2} + 2n \cdot n^{-2} \leqslant \frac{3}{n}. \qquad \square$$

5.2 *Treap*

Como no caso de *skip lists*, denotamos por U o conjunto universo e $S \subset U$ deve ser representado de modo a permitir as operações de dicionário: inserção, busca e remoção. Uma ***treap*** é uma árvore binária em que a cada nó v estão associados chave(v) e prioridade(v), de modo que a árvore se comporta como árvore binária de busca com relação às chaves e como uma *heap* de máximo com relação às prioridades (no sentido de árvore ordenada por prioridades, e não de uma *heap* implícita em vetor: aqui a forma da árvore não é determinada por um critério de completude). Supomos as chaves distintas entre si e as prioridades distintas entre si. Um nó v tem a propriedade *heap* se a sua prioridade é maior que a de todos os seus descendentes próprios, e tem a propriedade de árvore de busca se sua chave é maior que as chaves de todos os nós da sua subárvore esquerda e menor que as de todos os nós da sua subárvore direita.

As *treaps* foram propostas por (Vuillemin, 1980), que as chamou de árvores cartesianas. Outra forma de descrever uma *treap* é que a estrutura é a árvore binária de busca que resulta da inserção dos nós, um por um, em uma árvore inicialmente vazia, em ordem *decrescente* de prioridade, usando o algoritmo padrão de inserção (o nó de maior prioridade é inserido primeiro e fica na raiz).

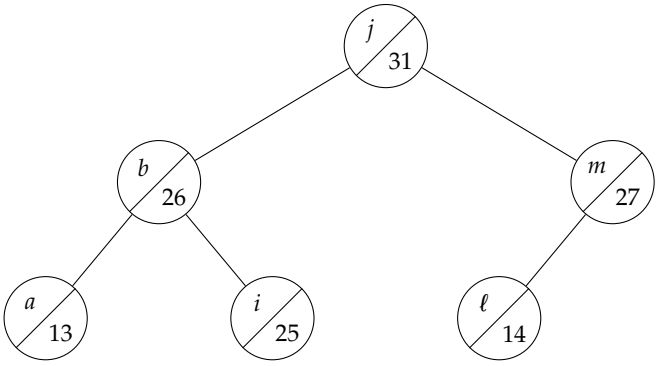


Figura 5.3: Exemplo de *treap* com 6 elementos. As letras são as chaves e os números as prioridades.

Proposição 5.4

Dado um conjunto de pares (chave, prioridade) com chaves distintas e prioridades distintas, existe uma única *treap* que o representa.

Demonstração. Por indução no número de nós. A propriedade *heap* obriga a raiz a ser o nó de maior prioridade; a propriedade de busca obriga a subárvore esquerda a conter exatamente os nós de chave menor que a da raiz e a direita, os de chave maior; e cada subárvore é, ela própria, uma *treap*, única pela hipótese de indução. □

Em particular, a forma da árvore depende apenas das chaves e das prioridades, e não da ordem em que os nós foram inseridos. Seja S um conjunto de elementos de um universo U representados por uma *treap*. As operações de dicionário são descritas a seguir.

busca — Dado $x \in U$ queremos saber se $x \in S$. A busca é feita como em árvore binária de busca: a partir da raiz comparamos x com a chave do nó; se x for igual, a busca termina com sucesso; se x for menor, continuamos na subárvore esquerda; se for maior, na subárvore direita; e a busca falha ao chegar a uma subárvore vazia. O custo é proporcional à altura da árvore;

inserção — Dado $x \in U$ queremos inserir x em S. Fazemos uma busca por x e, caso falhe, inserimos x como folha, no lugar em que a busca terminou, com uma prioridade sorteada para x. Isso mantém a propriedade de árvore de busca, mas pode destruir a propriedade *heap*, que é refeita por rotações: enquanto x tem prioridade maior que a de seu pai y, fazemos a rotação simples que coloca x no lugar de y (uma rotação à direita em y se x é filho esquerdo de y, à esquerda se é filho direito), como na figura 5.4. Durante o processo, a propriedade *heap* só pode ser violada entre x e seu pai; cada rotação preserva a propriedade de busca e, como x

tem prioridade maior que a de y, que por sua vez já era maior que as de todos os nós das subárvores B e C, nenhuma nova violação é criada. O número de rotações é no máximo a profundidade de x;

remoção — Dado $x \in S$ queremos remover x de S. Após uma busca por x, enquanto x não for uma folha rotacionamos x com o seu filho de *maior* prioridade (ou com o único filho, se só houver um), que passa a ser o pai de x e, portanto, tem prioridade maior que a do outro filho, o que preserva a propriedade *heap*. Quando x é uma folha, é removido. O número de rotações é no máximo a altura da subárvore de x.

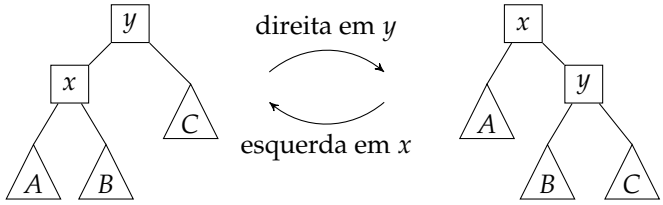


Figura 5.4: Rotações. A rotação à direita em y (da esquerda para a direita) sobe x e desce y; a rotação à esquerda em x (da direita para a esquerda) faz o inverso. Em ambas, a ordem em-ordem A, x, B, y, C é preservada, apenas a subárvore B muda de pai, e o custo é $O(1)$.

Essas operações têm custo proporcional à altura da árvore e usamos aleatoriedade para garantir altura logarítmica: a prioridade atribuída a um nó quando ele é inserido é sorteada uniformemente em $[0, 1]$, independentemente das demais (em particular, ao reinserir uma chave removida sorteamos uma prioridade nova). Supomos também que a sequência de operações é escolhida independentemente das prioridades (adversário *oblívio*): um adversário que enxergasse as prioridades poderia, por exemplo, remover sempre os nós de menor prioridade, e as prioridades restantes deixariam de ser i.i.d. uniformes. Com probabilidade 1 as prioridades são distintas (a prioridade de um nó não precisa ser um número real; basta que as prioridades sejam distintas e a ordem relativa seja uniforme). Pela Proposição 5.4, depois de qualquer sequência (oblívia) de operações a árvore é a *treap* do conjunto atual, com prioridades independentes e uniformes, pois a remoção de um nó não altera as prioridades dos demais. Por isso basta analisar uma *treap* com n nós e prioridades i.i.d. uniformes.

Seja x_k o k-ésimo menor elemento do conjunto S. Vamos estimar a que distância esse nó está da raiz. Dizemos que x_j é *ancestral próprio* de x_k, e escrevemos $x_j \prec x_k$, se $x_j \neq x_k$ está no caminho da raiz até x_k. Seja $I_j \coloneqq \mathbb{1}_{[x_j \prec x_k]}$. A *profundidade* de x_k é o seu número de ancestrais próprios,

$$D_k = \sum_{j \neq k} I_j.$$

Ela é o comprimento, em arestas, do caminho da raiz até x_k, e a *altura* da árvore é $\max_k D_k$. Para $j < k$ defina $X(j,k) = \{x_j, x_{j+1}, \ldots, x_k\}$ e $X(k,j) = X(j,k)$.

Proposição 5.5

Seja $j \neq k$. Então x_j é ancestral próprio de x_k se, e somente se, x_j tem a *maior prioridade* entre os elementos de $X(j,k)$.

Demonstração. Nesta demonstração convencionamos que todo nó é ancestral de si mesmo. Seja a o ancestral comum mais baixo de x_j e x_k. Vamos mostrar que a é o nó de maior prioridade em $X(j,k)$.

(i) $a \in X(j,k)$: se $a \notin \{x_j, x_k\}$, então x_j e x_k estão em subárvores distintas de a e, pela propriedade de busca, a chave de a está entre as de x_j e x_k.

(ii) $X(j,k)$ está contido na subárvore de a: seja x_i com chave entre as de x_j e x_k. Em cada ancestral próprio b de a, x_j e x_k estão na mesma subárvore de b, logo a chave de b não está entre as deles e x_i fica do mesmo lado de b. Assim, a busca por x_i a partir da raiz segue o mesmo caminho que a busca por x_j até a, e x_i está na subárvore de a.

(iii) Pela propriedade *heap*, a tem prioridade maior que a de todos os demais nós de sua subárvore, em particular que a dos de $X(j,k)$. Como as prioridades são distintas, a é o único nó de maior prioridade em $X(j,k)$.

Agora, como $j \neq k$, x_j é ancestral próprio de x_k se, e somente se, $a = x_j$, o que por (i)–(iii) equivale a x_j ter a maior prioridade em $X(j,k)$. □

Como as prioridades são i.i.d. contínuas, todo elemento de $X(j,k)$ tem a mesma probabilidade de ser o de maior prioridade, e $|X(j,k)| = |k-j|+1$; logo

$$\mathbb{P}\big[\, I_j = 1 \,\big] = \frac{1}{|k-j|+1},$$

e, somando separadamente $j < k$ e $j > k$,

$$\mathbb{E}D_k = \sum_{j<k} \frac{1}{k-j+1} + \sum_{j>k} \frac{1}{j-k+1} = (H_k - 1) + (H_{n-k+1} - 1) = H_k + H_{n-k+1} - 2,$$

onde $H_n = \sum_{i=1}^{n} 1/i = \ln n + \gamma + \Theta(n^{-1})$ é o n-ésimo número harmônico e $\gamma \approx 0{,}577$ é a constante de Euler–Mascheroni (veja Graham, Knuth e Patashnik, 1994). O número de nós no caminho da raiz até x_k é $D_k + 1$, de esperança $H_k + H_{n-k+1} - 1$. Como $H_m \leqslant 1 + \ln m$ (pois $1/i \leqslant \int_{i-1}^{i} \mathrm{d}x/x$ para $i \geqslant 2$), vale

$$\mathbb{E}D_k \leqslant 2H_n - 2 \leqslant 2\ln n = O(\log n)$$

para todo k: a profundidade de qualquer nó tem esperança logarítmica.

Para obter limitantes com alta probabilidade usamos a desigualdade de Chernoff. Ela exige independência, e os indicadores I_j *não* são todos independentes (veja a observação abaixo), mas são independentes de cada lado de k separadamente.

Lema 5.1

Fixado k, os indicadores I_j, $j<k$, são independentes, com $\mathbb{P}\left[\, I_j=1 \,\right]=1/(k-j+1)$. O mesmo vale para os I_j, $j>k$.

Demonstração. Seja y_i a prioridade de x_{k-i+1}, para $i = 1,\ldots,k$ (o caso $i = 1$ corresponde ao próprio x_k, para o qual I_k não é definido, e serve apenas para completar a permutação). Pela Proposição 5.5, para $i \geqslant 2$, $I_{k-i+1} = 1$ se, e somente se, $y_i > \max\{y_1,\ldots,y_{i-1}\}$. Seja $\rho_i \in \{1,\ldots,i\}$ o posto de y_i entre $y_1,\ldots,y_i$ (posto i é o maior). A ordem relativa de $y_1,\ldots,y_k$ é uma permutação uniforme, e a aplicação que leva a permutação a $(\rho_1,\ldots,\rho_k)$ é injetora (reconstruímos a permutação inserindo $y_1, y_2, \ldots$ nas posições indicadas pelos postos); como os dois conjuntos têm $k!$ elementos, ela é bijetora. Logo $\rho_1,\ldots,\rho_k$ são independentes, com ρ_i uniforme em $\{1,\ldots,i\}$. Como $I_{k-i+1} = \mathbb{1}_{[\rho_i=i]}$ depende só de ρ_i, os indicadores são independentes, com $\mathbb{P}[\, I_{k-i+1} = 1\,] = 1/i$. O caso $j > k$ é simétrico. □

Observação 10. Os indicadores de lados opostos não são independentes. Com $n = 3$ e $k = 2$, $\mathbb{P}[\, x_1 \prec x_2,\ x_3 \prec x_2\,] = \mathbb{P}\left[\text{ a prioridade de } x_2 \text{ é a menor }\right] = 1/3$, enquanto $\mathbb{P}[\, x_1 \prec x_2\,]\mathbb{P}[\, x_3 \prec x_2\,] = 1/4$. Por isso separamos $D_k = L_k + R_k$, com $L_k = \sum_{j<k} I_j$ e $R_k = \sum_{j>k} I_j$.

Teorema 5.3

Numa *treap* com $n \geqslant 2$ nós e prioridades i.i.d. uniformes, com probabilidade pelo menos $1-2n^{-7}$ a profundidade de todo nó é menor que $2\mathrm{e}^2 \ln n < 15 \ln n$. Em particular, a altura é $O(\log n)$ com probabilidade $1-O(n^{-7})$, e, nesse instante, cada operação de dicionário tem custo $O(\log n)$ com essa probabilidade.

Demonstração. Fixe k. Pelo Lema 5.1, L_k é soma de $k-1$ variáveis de Bernoulli independentes, com parâmetros $1/i$, $2 \leqslant i \leqslant k$, e $\mathbb{E}L_k = H_k - 1 \leqslant H_n - 1 \leqslant \ln n$ (pois $H_n \leqslant 1 + \ln n$). Para $s > 0$, usando $1 + x \leqslant \mathrm{e}^x$,

$$\mathbb{E}\mathrm{e}^{sL_k} = \prod_{i=2}^{k}\left(1 + \frac{\mathrm{e}^s - 1}{i}\right) \leqslant \exp((\mathrm{e}^s - 1)\,\mathbb{E}L_k) \leqslant \exp((\mathrm{e}^s - 1)\ln n).$$

Pela desigualdade de Markov aplicada a e^{sL_k}, com $s = 2$ e o limiar $\mathrm{e}^2 \ln n$,

$$\mathbb{P}\left[\, L_k \geqslant \mathrm{e}^2 \ln n \,\right] \leqslant \mathrm{e}^{-2\mathrm{e}^2 \ln n}\,\mathrm{e}^{(\mathrm{e}^2-1)\ln n} = n^{-(\mathrm{e}^2+1)} < n^{-8}.$$

O mesmo vale para R_k. Se $L_k < \mathrm{e}^2 \ln n$ e $R_k < \mathrm{e}^2 \ln n$, então $D_k < 2\mathrm{e}^2 \ln n$. Pela subaditividade, sobre os dois lados e os n nós,

$$\mathbb{P}\left[\, \exists k : \; D_k \geqslant 2\mathrm{e}^2 \ln n \,\right] \leqslant 2n \cdot n^{-8} = 2n^{-7}.$$

Fora desse evento, todo nó tem profundidade menor que $2\mathrm{e}^2 \ln n < 15 \ln n$ (note que $2\mathrm{e}^2 \approx 14{,}78$), e portanto a altura, medida em arestas, é menor que $15 \ln n$ (e, medida em nós, é no máximo $15 \ln n + 1$). A hipótese $n \geqslant 2$ garante $\ln n > 0$; para $n = 1$ a desigualdade estrita $0 < 0$ falharia. □

Observação 11. O Teorema 5.3 refere-se a uma *treap* num instante fixo. Para uma sequência (oblívia) de m operações, cada estado intermediário é uma *treap* com prioridades i.i.d. uniformes. Seja $N \geqslant 2$ o maior número de nós ao longo da sequência. Como $\mathbb{E}L_k \leqslant \ln n \leqslant \ln N$ em cada estado, a demonstração do teorema vale com $\ln N$ no lugar de $\ln n$, e a subaditividade sobre os m estados mostra que todas as operações têm custo menor que $15 \ln N + 1$ com probabilidade pelo menos $1 - 2m\,N^{-7}$. Em particular, isso vale com probabilidade $1 - O(N^{-5})$ para $m = O(N^2)$.

5.3 *Streaming*

Um ***fluxo*** (*streaming*) de dados é uma sequência extremamente longa de itens provenientes de um universo, que pode ser lida apenas uma vez, em ordem. Há dados demais para armazenar, e eles chegam rápido demais para qualquer computação mais elaborada. Três exemplos:

- os pacotes que passam por um roteador de rede, em que queremos saber quantos endereços de origem distintos aparecem (o que pode indicar um ataque) ou quais enviam mais tráfego;
- as requisições a um servidor web ou as consultas a um mecanismo de busca, em que queremos contar visitantes únicos ou descobrir os termos mais buscados;
- as leituras de sensores, como os de temperatura ou de vibração de máquinas, que geram dados continuamente e muitas vezes em dispositivos com memória muito limitada.

No modelo de ***streaming***, os dados chegam um a um, como uma sequência $\sigma = (x_1, x_2, \ldots, x_m)$, em geral com m muito grande e possivelmente desconhecido, e cada x_i é um elemento do universo $\{1, \ldots, n\}$. O algoritmo dispõe de uma memória muito menor que m, idealmente polilogarítmica em m e n.[4] Com tão pouco espaço, resultados exatos costumam ser impossíveis, e recorremos a aleatoriedade e

[4] Isto é, da ordem de $(\log m + \log n)^{O(1)}$ bits, para ε e δ fixos. O termo $\log n$ é o custo de escrever um elemento do universo, e $\log m$ o de escrever um contador que chega a m; o algoritmo pode guardar $(\log(nm))^{O(1)}$ desses objetos, mas não uma quantidade que cresça como potência de m ou de n. Para comparação, memorizar o fluxo inteiro custaria $m \log n$ bits, e guardar um bit por elemento do universo, n bits.

a aproximações do tipo (ε, δ): com probabilidade pelo menos $1 - \delta$, o erro relativo é no máximo ε.

Alguns problemas básicos nesse modelo são:

a) *Elementos distintos*: estimar quantos valores diferentes aparecem no fluxo, como os endereços de origem distintos num roteador ou os visitantes únicos de um servidor web.

b) *Estimativa de frequências*: dado um elemento i, estimar quantas vezes ele apareceu, sem manter um contador por elemento. Isso permite identificar os itens mais frequentes (*heavy hitters*), como os termos mais buscados ou as *hashtags* em alta.

c) *Momentos de frequência*: se f_i é o número de ocorrências do elemento i em σ, o k-ésimo momento é $F_k = \sum_{i=1}^{n} f_i^k$ (com $0^0 = 0$). Assim, F_0 é o número de elementos distintos, F_1 é o comprimento do fluxo e F_2 mede a não uniformidade da distribuição. O problema é estimar F_k para cada $k \geqslant 0$.

d) *Amostragem em fluxo*: manter uma amostra uniforme de ℓ elementos de um fluxo de tamanho desconhecido. Relaciona-se à prática de inspecionar apenas uma amostra dos pacotes que passam por um roteador.

e) *Contagem aproximada*: contar o número m de itens usando muito menos que $\log_2 m$ bits. É o problema mais simples da lista e o que abordamos em seguida. Em vez do valor exato, guarda-se um contador que cresce probabilisticamente, de modo que seu valor é da ordem de $\log m$ e ocupa apenas $O(\log \log m)$ bits, para ε e δ fixos.

Comecemos pela contagem exata: dado um fluxo de comprimento em $\{1, \ldots, m\}$, com o limite m conhecido de antemão, determinar seu comprimento. Uma solução é manter um contador c, inicialmente nulo, e aumentá-lo de uma unidade a cada item lido. Basta guardar o resto de c na divisão por m, que assume m valores distintos e pode ser escrito com $\lceil \log_2 m \rceil$ bits; ao final, o resto 0 é interpretado como m. É possível usar bem menos? Para algoritmos determinísticos que devolvem a resposta exata, não: a proposição a seguir mostra que nem um único bit a menos basta.

Proposição 5.6

Seja $m \geqslant 2$. Nenhum algoritmo determinístico que usa no máximo $\lceil \log_2 m \rceil - 1$ bits de memória devolve o comprimento exato de toda sequência de comprimento em $\{1, \ldots, m\}$. O mesmo vale para algoritmos aleatorizados que nunca erram.

Observe que o limite da Proposição 5.6 é justo: o contador módulo m descrito acima usa exatamente $\lceil \log_2 m \rceil$ bits.

Demonstração. Seja $b = \lceil \log_2 m \rceil - 1 \geqslant 0$. Como $\lceil \log_2 m \rceil < \log_2 m + 1$, temos $2^b < m$, isto é, há menos de m estados de memória possíveis. Em um algoritmo determinístico o estado inicial é fixo, o estado após ler uma sequência depende apenas dela, e a saída é função do estado final.

Para cada $i \in \{1, \ldots, m\}$ seja S_i o estado após ler a sequência constante $(1, \ldots, 1)$ de comprimento i. Como há m sequências e menos de m estados, existem $i \neq j$ com $S_i = S_j$. O algoritmo devolve então a mesma resposta para as duas sequências, mas as respostas corretas, i e j, são diferentes.

Suponha agora que o algoritmo é aleatorizado, que seus bits aleatórios vêm de uma semente r (não contada na memória) e que ele nunca erra, isto é, responde corretamente para toda semente e toda sequência. Fixada r, o algoritmo torna-se determinístico, usa no máximo b bits e acerta em todas as sequências, o que acabamos de ver ser impossível. □

Observe que o limite da Proposição 5.6 é justo: o contador módulo m descrito acima usa exatamente $\lceil \log_2 m \rceil$ bits.

Permitindo estimativas e aleatorização, a economia de memória pode ser enorme. A ideia é de Morris (1978), que a propôs em 1978 para contar muitos eventos distintos em registradores de apenas 8 bits.

Definição 5.1: (ε, δ)-aproximação

Dados os números reais $\varepsilon, \delta \in (0,1)$, chamamos um algoritmo aleatorizado de uma ***(ε, δ)-aproximação*** se, para todo fluxo de comprimento m, calcula uma estimativa $\widehat{m}$ de m tal que

$$\mathbb{P}\left[\, \left| \widehat{m} - m \right| \leqslant \varepsilon m \,\right] \geqslant 1 - \delta,$$

em que a probabilidade é sobre as escolhas aleatórias do algoritmo. Ou seja, $1 - \varepsilon \leqslant \widehat{m}/m \leqslant 1 + \varepsilon$ com probabilidade $\geqslant 1 - \delta$. Equivalentemente, $\mathbb{P}\left[\, \left| \widehat{m} - m \right| > \varepsilon m \,\right] \leqslant \delta$.

Veja o Exercício 30, pág. 109, e sseguintes.

Naturalmente, quanto menores ε e δ, melhor a garantia, e em geral maior a memória necessária.

Algoritmo 5.1: Algoritmo de Morris

Instância: um fluxo $(x_1, \ldots, x_m)$, $x_i \in \{1, 2, \ldots, n\}$.
Resposta: uma estimativa $\widehat{m}$ de m.

```
1 X ← 0;
2 para cada item lido faça
3 |   com probabilidade 2^{-X}, faça X ← X + 1;
4 responda 2^X − 1.
```

A saída $2^X - 1$ é a estimativa $\widehat{m}$. Quando $X = j$, o contador é incrementado com probabilidade 2^{-j} a cada item, de modo que o número de itens até o incremento é geométrico, com média 2^j. Assim X passa de j para $j+1$ depois de cerca de 2^j itens, e 2^X acompanha o número de itens vistos[5]. O algoritmo guarda apenas X, que, com alta probabilidade, é da ordem de $\log_2 m$ e portanto pode ser escrito com $O(\ln \ln m)$ bits. Os dois resultados a seguir tornam isso preciso. Antes, fixamos alguma notação.

[5] Como $1 + 2 + \cdots + 2^{j-1} = 2^j - 1$, chegar a $X = j$ leva em média $2^j - 1$ itens, o que explica a saída $2^X - 1$.

Seja X_i o valor de X após processar i itens, com $X_0 = 0$. Dado $X_{i-1} = j$,

$$X_i = \begin{cases} j+1 & \text{com probabilidade } 2^{-j} \\ j & \text{com probabilidade } 1 - 2^{-j}, \end{cases}$$

sendo o sorteio do i-ésimo item independente do passado. Para uma função $f : \mathbb{N} \to \mathbb{N}$ defina

$$g_f(j) := \left(1 - 2^{-j}\right) f(j) + 2^{-j} f(j+1).$$

Condicionando em X_{i-1} e usando a lei da esperança total, para $i \geqslant 1$ temos

$$\sum_j \mathbb{E}(\, f(X_i) \mid X_{i-1} = j \,)\mathbb{P}[\, X_{i-1} = j \,] = \sum_j \Big((1 - 2^{-j}) f(j) + 2^{-j} f(j+1)\Big)\mathbb{P}[\, X_{i-1} = j \,]$$

o lado esquerdo é $\mathbb{E} f(X_i)$ e o direito $\mathbb{E} g_f(X_{i-1})$. Portanto,

$$\mathbb{E} f(X_i) = \mathbb{E} g_f(X_{i-1}). \tag{5.9}$$

Como $X_i \in \{0, 1, \ldots, i\}$, as esperanças acima são somas finitas e existem para qualquer f.

Teorema 5.4

Para toda entrada de comprimento $m \geqslant 0$, a esperança sobre as escolhas aleatórias do algoritmo satisfaz $\mathbb{E} 2^{X_m} = m + 1$. Em particular, a saída $\widehat{m} = 2^{X_m} - 1$ satisfaz $\mathbb{E}\widehat{m} = m$, isto é, $\widehat{m}$ é um estimador não viesado de m.

Demonstração. A prova é por indução em m. Para $m = 0$, $X_0 = 0$ e $\mathbb{E}2^{X_0} = 1$. Seja $m \geqslant 1$ e suponha $\mathbb{E}2^{X_{m-1}} = m$. Para $f(j) = 2^j$,

$$g_f(j) = \left(1 - 2^{-j}\right)2^j + 2^{-j}2^{j+1} = 2^j - 1 + 2 = 2^j + 1,$$

e por (5.9) , pela linearidade da esperança e pela hipótese de indução,

$$\mathbb{E}2^{X_m} = \mathbb{E}g_f(X_{m-1}) = \mathbb{E}2^{X_{m-1}} + 1 = m + 1.$$

Por fim, $\mathbb{E}\widehat{m} = \mathbb{E}2^{X_m} - 1 = m$. □

Logo o algoritmo de Morris é um estimador não viesado de m. Falta controlar a dispersão pois ueremos também que $\widehat{m}$ se concentre em torno de sua esperança, e para isso precisamos da variância, que calculamos a partir do segundo momento de 2^{X_m}.

Lema 5.2

Para toda entrada de comprimento $m \geqslant 0$,

$$\mathbb{E}4^{X_m} = \frac{3}{2}m^2 + \frac{3}{2}m + 1.$$

Demonstração. Para $f(j) = 4^j$,

$$g_f(j) = \left(1 - 2^{-j}\right)4^j + 2^{-j}4^{j+1} = \left(4^j - 2^j\right) + 4 \cdot 2^j = 4^j + 3 \cdot 2^j.$$

Seja $i \geqslant 1$. Por (5.9), pela linearidade da esperança e pelo Teorema 5.4, aplicado ao comprimento $i - 1$,

$$\mathbb{E}4^{X_i} = \mathbb{E}4^{X_{i-1}} + 3\,\mathbb{E}2^{X_{i-1}} = \mathbb{E}4^{X_{i-1}} + 3i.$$

Aplicando essa recorrência para $i = m, m-1, \ldots, 1$ e usando $\mathbb{E}4^{X_0} = 1$,

$$\mathbb{E}4^{X_m} = 1 + 3\sum_{i=1}^{m} i = 1 + \frac{3m(m+1)}{2} = \frac{3}{2}m^2 + \frac{3}{2}m + 1.$$ □

Corolário 5.1

Para toda entrada de comprimento $m \geqslant 0$,

$$\mathrm{Var}\left(\widehat{m}\right) = \frac{m(m-1)}{2}.$$

Demonstração. Como $\widehat{m} = 2^{X_m} - 1$, temos $\mathrm{Var}\left(\widehat{m}\right) = \mathrm{Var}\left(2^{X_m}\right)$. Usando $4^{X_m} = \left(2^{X_m}\right)^2$, o Teorema 5.4 e o Lema 5.2,

$$\begin{aligned}\mathrm{Var}\left(2^{X_m}\right) &= \mathbb{E}4^{X_m} - \left(\mathbb{E}2^{X_m}\right)^2 \\ &= \frac{3}{2}m^2 + \frac{3}{2}m + 1 - (m+1)^2 = \frac{m^2 - m}{2}.\end{aligned}$$ □

Pelo Corolário 5.1, para $m \geqslant 1$ temos $\operatorname{Var}(\widehat{m}) = m(m-1)/2 \leqslant m^2/2$. Em particular, o desvio padrão de $\widehat{m}$ é da ordem de $m/\sqrt{2}$, isto é, comparável ao próprio m. Como $\widehat{m}$ é não viesado (Teorema 5.4), a desigualdade de Chebyshev dá, para todo $\varepsilon > 0$,

$$\mathbb{P}\left[\,\left|\widehat{m} - m\right| \geqslant \varepsilon m\,\right] \leqslant \frac{\operatorname{Var}(\widehat{m})}{\varepsilon^2 m^2} \leqslant \frac{1}{2\varepsilon^2}.$$

Em particular, o desvio padrão de $\widehat{m}$ é $\sqrt{m(m-1)/2} \leqslant m/\sqrt{2}$, e para m grande é aproximadamente $m/\sqrt{2} \approx 0{,}71m$: o erro relativo σ/m típico é constante[6], cerca de 71%.

[6] O erro relativo constante, que não diminui quando m cresce, é inútil para qualquer precisão razoável

Esse limitante só é não trivial se $\varepsilon > 1/\sqrt{2}$. Como na definição tomamos $\varepsilon \in (0,1)$, ele é sempre maior que $1/2$: não garante $\delta < 1/2$ para nenhuma precisão $\varepsilon < 1$, e é inútil na prática. Precisamos melhorar a concentração, e veremos dois truques comuns para isso. O primeiro é tomar a média de s cópias independentes do algoritmo, o que divide a variância por s. O segundo é tomar a mediana de várias dessas médias, o que amplifica a confiança, isto é, diminui a probabilidade de falha δ.

5.3.1 *O truque da média*

Pela desigualdade de Chebyshev, a probabilidade de erro é controlada pela variância, então podemos melhorar a concentração reduzindo-a. Lembremos que $\operatorname{Var}(cX) = c^2 \operatorname{Var}(X)$ para toda constante c, e que $\operatorname{Var}(X+Y) = \operatorname{Var}(X) + \operatorname{Var}(Y)$ para variáveis independentes X e Y.

Executamos o algoritmo de Morris t vezes sobre o mesmo fluxo, em paralelo e com sorteios independentes, obtendo saídas $\widehat{m}_1, \ldots, \widehat{m}_t$, independentes e com a mesma distribuição, e devolvemos

$$\widehat{m}^* := \frac{1}{t}\sum_{i=1}^{t} \widehat{m}_i.$$

Pela linearidade da esperança, $\mathbb{E}\widehat{m}^* = m$ e, pela independência,

$$\operatorname{Var}(\widehat{m}^*) = \frac{1}{t^2}\sum_{i=1}^{t} \operatorname{Var}(\widehat{m}_i) = \frac{\operatorname{Var}(\widehat{m}_1)}{t} \leqslant \frac{m^2}{2t}$$

(Corolário 5.1). Para $m \geqslant 1$, a desigualdade de Chebyshev dá

$$\mathbb{P}\left[\,\left|\widehat{m}^* - m\right| \geqslant \varepsilon m\,\right] \leqslant \frac{1}{2t\varepsilon^2}.$$

Tomando $t = \lceil 1/(2\varepsilon^2\delta) \rceil$, a probabilidade de que $\widehat{m}^*$ erre por mais que εm é no máximo δ, isto é, $\widehat{m}^*$ é uma (ε, δ)-aproximação. A memória é a de t contadores, com $O(\ln \ln m)$ bits cada (com alta probabilidade), ou seja, $O\left(\varepsilon^{-2}\delta^{-1} \ln \ln m\right)$ bits. A dependência em $1/\delta$ é ruim: queremos uma probabilidade de falha muito pequena sem pagar tanto. É o que faz o próximo truque.

5.3.2 *O truque da mediana*

Escolhemos $t = \lceil 3/(2\varepsilon^2) \rceil$ e executamos o algoritmo da média, independentemente e em paralelo, s vezes, com s ímpar. Denotemos as saídas por $\widehat{m}_1^*, \ldots, \widehat{m}_s^*$. Como $\mathrm{Var}(\widehat{m}_i^*) \leqslant m^2/(2t)$, Chebyshev dá, para cada i,

$$\mathbb{P}\big[\, |\, \widehat{m}_i^* - m\, | \geqslant \varepsilon m \,\big] \leqslant \frac{1}{2t\varepsilon^2} \leqslant \frac{1}{3}.$$

Devolvemos a mediana $\widehat{m}^{**}$, isto é, o $\frac{s+1}{2}$-ésimo menor valor.

Seja Y_i o indicador do evento *bom*

$$|\, \widehat{m}_i^* - m\, | < \varepsilon m.$$

As Y_i são independentes e $\mathbb{P}[\, Y_i = 1\,] \geqslant 2/3$; logo $Y \coloneqq \sum_{i=1}^{s} Y_i$ satisfaz $\mathbb{E}Y \geqslant 2s/3$.

Se a mediana é ruim, isto é, $|\, \widehat{m}^{**} - m\, | \geqslant \varepsilon m$, então pelo menos $(s+1)/2$ valores são ruins: se $\widehat{m}^{**} \geqslant (1+\varepsilon)m$, todos os $\frac{s+1}{2}$ valores maiores ou iguais à mediana são ruins, e analogamente se $\widehat{m}^{**} \leqslant (1-\varepsilon)m$ com os menores ou iguais. Logo $Y \leqslant s - \frac{s+1}{2} < \frac{s}{2}$ e, como $\mathbb{E}Y \geqslant 2s/3$,

$$Y - \mathbb{E}Y < \frac{s}{2} - \frac{2s}{3} = -\frac{s}{6}.$$

Pela cota aditiva de Chernoff–Hoeffding (Teorema 4.4) para as s variáveis $Y_i \in [0,1]$,

$$\mathbb{P}\big[\, |\, \widehat{m}^{**} - m\, | \geqslant \varepsilon m \,\big] \leqslant \mathbb{P}\Big[\, Y - \mathbb{E}Y \leqslant -\frac{s}{6} \,\Big] \leqslant \exp\!\left(-\frac{2(s/6)^2}{s}\right) = \exp\!\left(-\frac{s}{18}\right).$$

(A cota aditiva depende só do desvio $s/6$, e não do valor exato de $\mathbb{E}Y$; isso evita supor $\mathbb{E}Y = 2s/3$.) Para que a falha de precisão seja $\leqslant \delta/2$, tomamos s o menor ímpar com $s \geqslant 18\ln(2/\delta)$.

5.3.3 *Espaço e resumo das garantias*

Até aqui controlamos apenas o *erro* das estimativas. Esta subseção mostra que os contadores, de fato, ocupam pouca memória, e reúne as garantias das duas variantes. Supomos conhecido um limite superior para m, com logaritmo da ordem de $\log m$, e escrevemos m nas cotas; é ele que permite reservar o espaço dos contadores antes de ler o fluxo.

Observação 12 (*O espaço dos contadores*). Considere $N \geqslant 1$ execuções do algoritmo de Morris sobre entradas de comprimento $m \geqslant 1$ (não precisam ser independentes), com contadores finais $X^{(1)}, \ldots, X^{(N)}$, e seja $\eta \in (0,1)$. Pelo Teorema 5.4 e pela desigualdade de Markov, para cada j,

$$\mathbb{P}\left[\, 2^{X^{(j)}} \geqslant \frac{N(m+1)}{\eta} \,\right] \leqslant \frac{\eta}{N}.$$

Pela cota da união, com probabilidade pelo menos $1-\eta$ vale $X^{(j)} < \log_2 \frac{N(m+1)}{\eta}$ para todo j, e então cada contador cabe em

$$\log_2 \log_2 \frac{N(m+1)}{\eta} + O(1) = O\left(\log\log m + \log\log \frac{N}{\eta}\right)$$

bits. O espaço efetivamente usado é aleatório. Para ter memória fixa, o algoritmo reserva esse espaço e *aborta* se algum contador o exceder, o que ocorre com probabilidade no máximo η.

Teorema 5.5

Sejam $\varepsilon, \delta \in (0,1)$ e $m \geqslant 1$, com $1/(\varepsilon\delta) \leqslant m^{O(1)}$. Existem algoritmos que (ε,δ)-aproximam m, com os seguintes usos de memória durante a leitura do fluxo:

a) ***(média)*** com $t = \lceil 1/(\varepsilon^2\delta)\rceil$ contadores,

$$O\left(\frac{\log\log m}{\varepsilon^2\delta}\right) \text{ bits;}$$

b) ***(mediana de médias)*** com ts contadores, para $t = \lceil 3/(2\varepsilon^2)\rceil$ e s é o menor ímpar com $s \geqslant 18\ln(2/\delta)$,

$$O\left(\frac{1}{\varepsilon^2}\cdot \ln\frac{2}{\delta}\cdot \log\log m\right) \text{ bits.}$$

Demonstração. Seja N o número de contadores ($N = t$ em a), $N = ts$ em b)) e seja A a variante correspondente, sem limite de espaço. Pelas subseções anteriores, o evento E_1 de que a saída de A erra por εm ou mais tem probabilidade no máximo $\delta/2$.

Pela Observação 12 com $\eta = \delta/2$, o evento E_2 de que algum contador de A excede $\log_2 \frac{2N(m+1)}{\delta}$ tem probabilidade no máximo $\delta/2$. Seja A' o algoritmo que se comporta como A, mas reserva esse espaço para cada contador e aborta se o exceder. Fora de E_2, as execuções de A e A' coincidem; logo A' erra apenas se $E_1 \cup E_2$ ocorre, com probabilidade no máximo δ.

O espaço de A' é N vezes $O(\log\log m + \log\log(N/\delta))$. Como $N \leqslant \mathrm{poly}(1/(\varepsilon\delta))$ e $1/(\varepsilon\delta) \leqslant m^{O(1)}$, temos $\log\log(N/\delta) = O(\log\log m)$. Substituindo $N = O(\varepsilon^{-2}\delta^{-1})$ em a) e $N = O(\varepsilon^{-2}\ln(2/\delta))$ em b), obtemos os limites. □

Observação 13. Os limites acima referem-se ao estado mantido *durante a leitura do fluxo*. As médias e a mediana são calculadas ao final, a partir dos contadores guardados. Isso usa $O(\log m)$ bits de memória de trabalho: as médias são comparadas pelas somas dos t valores (o que dispensa a divisão por t) e recalculadas sob demanda para achar o

elemento de posto $(s+1)/2$, sem guardar as s médias. A própria saída, escrita em binário, já ocupa $\Theta(\log m)$ bits.

Comparando as duas variantes, a mediana troca o fator $1/\delta$ por $\ln(2/\delta)$ ao custo de um fator constante, o que a torna preferível quando δ é pequeno.

5.4 Exercícios

Exercício 34. Dado um conjunto de n números e um real positivo ε, uma ε-aproximação da mediana é um elemento cujo posto (posição considerando os mesmo elementos em ordem crescente) está no intervalo $[(1-\varepsilon)n/2, (1+\varepsilon)n/2]$. Projete um algoritmo aleatorizado para computar uma 1/2-aproximação da mediana de um vetor com n elementos com tempo de execução $O(\log n \log\log n)$ e probabilidade de erro $2n^{-2}$ (*dica*: amostre e ordene).

Exercício 35. Para dados ε e c positivos, projete um algoritmo aleatorizado para computar uma ε-aproximação da mediana de um vetor com n elementos com tempo de execução $O(\log n \log\log n)$ e probabilidade de erro n^{-c}.

Exercício 36. Sejam $X_i \sim \text{Bernoulli}(1/2)$, para $i \geqslant 1$, variáveis aleatórias independentes e $N = \min\{\, n \geqslant 1 \colon X_{n+1} = 1 \,\}$. Prove que $N+1 \sim \text{Geom}(1/2)$ e que $\mathbb{E}N = 1$. Assuma que se $N = 0$ então $X_1 + \cdots + X_N = 0$ e prove que

$$\mathbb{E}\sum_{i=1}^{N} X_i \neq \sum_{i=1}^{\mathbb{E}N} \mathbb{E}X_i. \tag{5.10}$$

Exercício 37. Prove que numa *skip list*,

$$\mathbb{P}\big[\, H > 100\log_2(n) \,\big] \leqslant \frac{1}{n^{99}}.$$

Exercício 38. Verifique à mão que $\mathbb{E}2^{X_m} = 3,4$ e $\text{Var}(\,\widehat{m}\,) = 1,3$ para $m = 2,3$, e calcule $\mathbb{P}[\, X_2 = j \,]$ para $j = 1,2$.

Exercício 39. (Morris com base $1+\alpha$.) Considere a variante em que X sobe com probabilidade $(1+\alpha)^{-X}$ e a saída é $\widehat{m} = ((1+\alpha)^X - 1)/\alpha$. Mostre que $\mathbb{E}\widehat{m} = m$ e que $\text{Var}(\,\widehat{m}\,) = \alpha\, m(m-1)/2$. Conclua que $\alpha = 2\varepsilon^2\delta$ já dá uma (ε,δ)-aproximação por Chebyshev, sem cópias paralelas.

Exercício 40. Suponha que temos uma fonte de bits aleatórias que responde 0 com probabilidade $p \in (0,1)$ e responde 1 com probabilidade $1-p$, independentemente. Escreva um algoritmo que usa essa fonte responda 0 ou 1 uniforme e independentemente. Calcule o tempo esperado de execução em função de p.

Exercício 41. Prove que se distribuímos ao acaso m bolas em n caixas com a condição que $m < (2/\mathrm{e})n\ln(n)$, então com alta probabilidade o maior número de bolas em uma caixa é

$$\frac{4\ln(n)}{\ln\left(\frac{2n}{m\mathrm{e}}\ln(n)\right)}.$$

Exercício 42 (lei de grandes desvios para variáveis aleatórias binomiais). Sejam $X_i \sim \text{Bernoulli}(1/2)$ variáveis aleatórias independentes $1/2 < \alpha \leqslant 1$ um real. Seja $S_n = X_1 + \cdots + X_n$. Verifique que

$$\frac{1}{2^n}\frac{n!}{\lceil \alpha n\rceil!(n-\lceil \alpha n\rceil)!} \leqslant \mathbb{P}[\, S_n \geqslant \alpha n\,] \leqslant \frac{n+1}{2^n}\frac{n!}{\lceil \alpha n\rceil!(n-\lceil \alpha n\rceil)!}$$

e conclua, usando a aproximação de Stirling, que

$$\lim_{n\to\infty}\frac{1}{n}\mathbb{P}[\, S_n \geqslant \alpha n\,] = -I(\alpha)$$

onde $I(\alpha) = \alpha\ln\alpha + (1-\alpha)\ln(1-\alpha) + \ln 2$.

6
Hashing

Uma ***função de hash*** é uma função $h : U \to N$ que transforma objetos de um conjunto *muito grande* U, o ***universo*** (números, cadeias de caracteres, arquivos, grafos), em valores de um conjunto bem menor N, em geral $N = \{0, 1, \ldots, n-1\}$ ou o conjunto das cadeias de k bits. Como $|U|$ é muito maior que $|N|$, a função *comprime* a informação: o valor $h(x)$ é uma espécie de "resumo" de x, que ocupa pouco espaço e pode ser comparado e usado como índice com custo constante. O preço dessa compressão é que elementos distintos podem receber o mesmo valor, o que chamamos de *colisão*, e que, pelo princípio da casa dos pombos, não pode ser evitado.

O que torna uma função de *hash* útil não é, portanto, ser injetora, mas ter algumas propriedades que dependem do uso:

- ser ***fácil de computar***: calcular $h(x)$ deve custar pouco tempo, idealmente tempo constante;
- ter ***descrição curta***: poucos bits devem bastar para armazenar a função;
- ***espalhar bem*** os elementos que de fato aparecem: dado um conjunto $S \subseteq U$, os valores $h(x)$, $x \in S$, devem se distribuir de modo aproximadamente uniforme em N, de modo que as colisões sejam poucas.

A terceira propriedade é a mais delicada. Para qualquer função fixa existem conjuntos S em que todos os elementos colidem, de modo que nenhuma h determinística espalha bem *todos* os conjuntos. A saída, que é o fio condutor deste capítulo, é usar ***aleatoriedade***: sortear h de uma família $\mathcal{H}$ de funções e analisar o comportamento esperado, ou com alta probabilidade, para qualquer S fixo. Uma função totalmente aleatória espalha bem, mas não tem descrição curta; o problema central é encontrar famílias pequenas, de funções fáceis de computar, que preservem as propriedades estatísticas de que precisamos. É nesse ponto que entram as famílias universais.

As funções de *hash* aparecem em muitos contextos: como estrutura de dados para operações de dicionário, na verificação rápida de igualdade e de integridade de dados ("impressões digitais"), na teoria da complexidade e na desaleatorização de algoritmos, e na criptografia, onde se exige de h propriedades bem mais fortes, como a dificuldade de encontrar colisões. Nosso foco são as propriedades *probabilísticas* de famílias de funções.

6.1 Tabelas de espalhamento

Uma ***tabela de espalhamento***, ou ***tabela hashing***, é uma solução bastante conhecida e estudada para a representação computacional de um conjunto, seja ele estático ou dinâmico. Um modo de implementar uma tabela de espalhamento é usar um vetor H cujas entradas são listas ligadas e o acesso à tabela é feito por meio de uma ***função de hash*** $h : U \to \{0, 1, \ldots, n-1\}$. Dado $x \in U$, a inserção, remoção ou busca de x em H é realizada na lista ligada $H[h(x)]$ (veja uma ilustração na Figura 6.1).

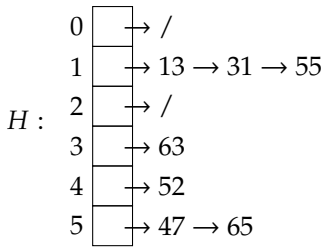


Figura 6.1: tabela de espalhamento com os elementos $\{13, 31, 47, 52, 55, 63, 65\}$ distribuídos de acordo com a função $h(x) = x \bmod 6$.

As operações de busca, inserção e remoção de um elemento numa tabela H que representa um conjunto dinâmico $S \subset U$ com função de *hash* $h : U \to N$, para $N = \{0, 1, \ldots, n-1\}$, são descritas a seguir.

busca: dado $x \in U$, uma operação de busca por x em S responde à pergunta "$x \in S$?" e ainda, no caso positivo, retorna um apontador para x. Numa tabela de espalhamento isso é realizado por uma busca sequencial na lista ligada $H[h(x)]$. Uma busca por x em H é dita *com sucesso* caso $x \in H$, senão é dita *sem sucesso*. O custo (ou tempo) de pior caso de uma busca é proporcional ao número de elementos na maior lista;

inserção: dado $x \in U$, uma operação de inserção acrescenta na estrutura que representa S o elemento x, caso esse ainda não faça parte de S. A inserção propriamente dita numa tabela de espalhamento é simplesmente inserir o elemento x no início da lista ligada $H[h(x)]$ e o custo dessa operação é constante;

remoção: dado $x \in U$, a remoção de x retira esse elemento da estrutura

que representa S, caso $x \in S$. A remoção propriamente dita numa tabela de espalhamento, dada a posição de x na lista ligada através de um apontador, é a remoção do elemento de uma lista ligada e o custo de pior caso dessa operação também é constante.

Para a análise do desempenho das operações de dicionário nessa estrutura de dados, o tempo de busca de um item é importante e, no pior caso, é o tempo de busca na lista $H[i]$ com o maior número de elementos. No emprego de tabelas de espalhamento, usualmente, temos a seguinte situação: o ***conjunto universo*** U é muito grande, o que significa que o custo de uma representação do conjunto S usando, por exemplo, um vetor de bits de tamanho $|U|$ é proibitivo. Se fosse viável, teríamos uma estrutura com tempo de busca $O(1)$. O conjunto S, de cardinalidade $m := |S|$, é uma fração de U e o caso interessante é quando $m = \Omega(n)$. É desejável que os elementos de S fiquem bem espalhados na tabela, pois ***colisões*** (elementos distintos mapeados para a mesma lista) afetam o desempenho das operações. Como U tem muito mais que n elementos não há como evitar colisões.

Das funções de *hash*, além do bom espalhamento, queremos que seja fácil de computar e que a representação seja sucinta, isto é, relativamente poucos bits sejam necessários para armazenar a função. Esse tipo de função, além de uma grande ferramenta prática como descrevemos abaixo, é bastante útil em Complexidade Computacional e em Criptografia.

Para qualquer h, existe um conjunto S em que todos os elementos colidem, basta escolher m elementos de U na mesma pré-imagem, o que sempre pode ser feito pois tem tamanho pelo menos $|U|/n$ e U é assumido grande. Por isso o desempenho precisa ser analisado em média, e a aleatoriedade entra de forma natural.

Hashing com funções aleatórias Uma função h escolhida uniformemente no conjunto N^U de todas as $|N|^{|U|}$ funções de U em N produz, quando $n = \Theta(m)$, listas de tamanho no máximo $O(\log m)$ com alta probabilidade. Isso garante, com alta probabilidade, um tempo de busca equivalente ao das árvores de buscas, com a vantagem de manutenção mais simples. Além disso, o tempo médio de busca é $\approx m/n = O(1)$, quando $n = \Theta(m)$.

Nesse modelo probabilístico, a escolha de uma função aleatória equivale a escolher, independentemente para cada elemento $x \in U$, uma posição $h(x)$ uniformemente em N.

Um problema nessa estratégia é que tal função não tem uma representação sucinta. Algumas delas requerem pelo menos $|U| \log(n)$ bits para serem representadas. Por ora analisaremos o caso de uma função aleatória para um conjunto S fixo, porém arbitrário. Nesse caso o tamanho de uma lista é uma variável aleatória.

Vamos considerar o modelo probabilístico $(N^U, \mathbb{P})$ com $\mathbb{P}(\, h \,) = 1/|N^U|$ para toda função $h \in N^U$. Notemos que vale

$$\mathbb{P}[\, h(x) = i \,] = \frac{1}{|N|} \tag{6.1}$$

para todo $x \in U$ e todo $i \in N$. De fato, sortear uniformemente uma função é equivalente a sortear uniformemente e independentemente uma imagem para cada elemento do domínio.

Fixamos os parâmetros $m = |S|$ e $n = |N|$ e então a fração

$$c = c(n, m) \coloneqq \frac{m}{n} \tag{6.2}$$

é denominada ***carga*** da tabela. A carga da tabela é o valor esperado para a quantidade de elementos de S numa mesma posição da tabela, segundo a medida da equação (6.1). Tomemos a variável aleatória

$$\mathbb{1}_{[h(x)=h(y)]} \colon N^U \to \{\, 0, 1 \,\}$$

indicadora de colisão dos elementos $x, y \in U$ sob a escolha $h \in N^U$. A probabilidade de colisão é

$$\begin{aligned} \mathbb{P}[\, h(x) = h(y) \,] &= \sum_{i \in N} \mathbb{P}[\, h(x) = i \,] \mathbb{P}[\, h(y) = i \,] \qquad (x \neq y) \\ &= n \cdot \frac{1}{n} \cdot \frac{1}{n} = \frac{1}{n}. \end{aligned} \tag{6.3}$$

assim, o número de itens na lista $H[h(x)]$ é dado por $\sum_{y \in S} \mathbb{1}_{[h(x)=h(y)]}$ e

$$\mathbb{E}\mathbb{1}_{[h(x)=h(y)]} = \begin{cases} \frac{1}{n}, & \text{se } y \neq x \\ 1, & \text{caso contrário,} \end{cases}$$

portanto o tamanho esperado da lista $H[h(x)]$ é, pela linearidade da esperança

$$\sum_{y \in S} \mathbb{E}\mathbb{1}_{[h(x)=h(y)]} = \begin{cases} \frac{m}{n}, & \text{se } x \notin S, \\ \frac{(m-1)}{n} + 1, & \text{caso contrário.} \end{cases} \tag{6.4}$$

O tempo esperado de uma busca em uma tabela de espalhamento com uma função *hash* h escolhida aleatoriamente em N^U é proporcional à carga c da tabela e, portanto, é constante quando $n = \Theta(m)$.

Proposição 6.1

Sejam $S \subseteq U$, $|S| = m$, e H uma tabela de espalhamento com n posições, usando uma função de *hash* $h \colon \quad U \to N$ escolhida aleatoriamente. Suponha que os elementos de S são inseridos no início da lista ligada correspondente a cada célula de H. Então:

1. o tempo esperado de uma busca *sem sucesso* é $c+1$,
2. o tempo esperado de uma busca *com sucesso* é $1+\frac{c}{2}-\frac{1}{2n}$,

onde $c=m/n$ é a carga média da tabela.

Demonstração. Se $x \notin S$, a busca percorre todos os elementos na lista $H[h(x)]$. Pelo modelo de função aleatória (equação (6.4)), o tamanho esperado dessa lista é $m/n = c$, assim chegamos ao final da lista com $c+1$ comparações em média.

Suponha que $x \in S$ e que foi o i-ésimo elemento inserido. Como inserimos sempre no início da lista, x estará na frente da lista no momento da inserção. Dos $m-i$ elementos restantes que ainda serão inseridos, em média $(m-i)/n$ colidirão com x, de modo que o tempo esperado para achar x nessa lista será $(m-i)/n+1$ comparações. A média sobre todos os possíveis valores de i é

$$\frac{1}{m}\sum_{i=1}^{m}\left(1+\frac{m-i}{n}\right) = 1+\frac{1}{mn}\sum_{i=1}^{m}(m-i) = 1+\frac{m-1}{2n}.$$

Assim, o tempo médio de busca com sucesso é $1+c/2-1/(2n)$. □

Lema 6.1: a maior lista é sublogarítmica

Para $X_i := |\{ y \in S : h(y)=i \}|$, n suficientemente grande e $c \leqslant 1$,

$$\mathbb{P}\left[\max_i X_i \geqslant \frac{8\ln n}{\ln\ln n}\right] \leqslant \frac{1}{n}.$$

Como $n=\Theta(m)$, temos $\ln n=\Theta(\ln m)$, e a maior lista tem tamanho $O(\log m/\log\log m)$ com probabilidade $\geqslant 1-1/n$.

Demonstração. Fixemos $i \in N$ e $k \geqslant 1$. Se $X_i \geqslant k$, existe $T \subseteq S$ com $|T| = k$ e $h(y) = i$ para todo $y \in T$. Pela independência dos valores $h(y)$ e por $\mathbb{P}[\, h(y)=i \,] = 1/n$, cada T tem probabilidade n^{-k}. Usando a subaditividade em T dá

$$\mathbb{P}[\, X_i \geqslant k \,] \leqslant \binom{m}{k}\frac{1}{n^k} \leqslant \frac{m^k}{k!\,n^k} = \frac{c^k}{k!} \leqslant \frac{1}{k!},$$

onde usamos $\binom{m}{k} \leqslant m^k/k!$ e $c = m/n \leqslant 1$. Para limitar $k!$, note que $e^k = \sum_{j\geq 0} k^j/j! \geqslant k^k/k!$, logo $k! \geqslant (k/e)^k$ e

$$\mathbb{P}[\, X_i \geqslant k \,] \leq \left(\frac{e}{k}\right)^k. \tag{6.5}$$

Logo, sobre as n posições

$$\mathbb{P}\left[\max_i X_i \geqslant k\right] \leqslant n\left(\frac{e}{k}\right)^k = n\exp(-k(\ln k-1)).$$

Aqui não precisamos de independência entre as listas, que de fato não são independentes (a soma dos tamanhos é m).

Tome $k_0 = 8\ln n/\ln\ln n$, $k = \lceil k_0 \rceil$ e escreva $y = \ln\ln n$. A função $\phi(t) := t(\ln t - 1)$ é crescente para $t \geqslant 1$, pois $\phi'(t) = \ln t \geqslant 0$. Como $k \geqslant k_0$, vale $\phi(k) \geqslant \phi(k_0)$, e basta estimar $\phi(k_0)$. Temos

$$\ln k_0 = \ln 8 + y - \ln y \geqslant \tfrac{1}{2}y,$$

pois isso equivale a $\ln y \leqslant \frac{1}{2}y + \ln 8$, que vale para todo $y > 0$ (o máximo de $\ln y - \frac{y}{2}$ é $\ln 2 - 1 < 0$). Para n grande o bastante, $y \geq 4$, e então $\ln k_0 - 1 \geqslant \frac{1}{2}y - 1 \geqslant \frac{1}{4}y$. Logo

$$\phi(k_0) = k_0(\ln k_0 - 1) \geqslant \frac{8\ln n}{y} \cdot \frac{y}{4} = 2\ln n,$$

e portanto, como $\phi(k) \geqslant \phi(k_0) \geqslant 2\ln n$,

$$\mathbb{P}\left[\max_i X_i \geqslant k\right] \leqslant n\, e^{-\phi(k)} \leqslant n \cdot e^{-2\ln n} = \frac{1}{n}. \qquad \square$$

Observação 14. Se $n = \Theta(m)$ com $c \leq C$, a cota em (6.5) fica $(Ce/k)^k$. Basta trocar e por Ce e ajustar a constante 8 que o resultado é o mesmo. ◊

Observação 15 (*A cota é justa*). Prova-se, via um argumento de segundo momento sobre o número de listas com $\geqslant k$ elementos, que com alta probabilidade a maior lista tem tamanho $\Omega(\log n/\log\log n)$. Portanto, a maior lista é $\Theta(\log n/\log\log n)$. ◊

6.1.1 *O paradoxo dos aniversários e um limiar para colisões*

Para S fixo e C a quantidade de pares de S que colidem, o número esperado de colisões é

$$\mathbb{E}C = \binom{m}{2}\frac{1}{n} = \frac{m(m-1)}{2n} \tag{6.6}$$

assim, usando (3.5)

$$\mathbb{P}[\,C = 0\,] \geqslant 1 - \mathbb{E}C = 1 - \frac{m(m-1)}{2n} \tag{6.7}$$

e no caso $m = \sqrt{n}$ temos $\mathbb{E}C < 1/2$ e $\mathbb{P}[\,C = 0\,] \geqslant 1/2$.

Para $m \leqslant n$ há $n(n-1)(n-2)\cdots(n-m+1)$ sequências sem repetições em N^m. Se $(h(x_1), h(x_2), \ldots, h(x_m))$ é uma escolha aleatória

em N^m e C é o número de colisões, então nessa escolha

$$\begin{aligned}\mathbb{P}[\,C=0\,] &= \frac{n(n-1)(n-2)\cdots(n-m+1)}{n^m}\\ &= \left(1-\frac{1}{n}\right)\left(1-\frac{2}{n}\right)\cdots\left(1-\frac{m-2}{n}\right)\left(1-\frac{m-1}{n}\right)\\ &< \exp\left(-\frac{1}{n}\right)\exp\left(-\frac{2}{n}\right)\cdots\exp\left(-\frac{m-1}{n}\right)\\ &= \exp\left(-\frac{m(m-1)}{2n}\right)\end{aligned}$$

na segunda linha usamos que $\exp(-x) > 1-x$ (veja (d.1)).

O ***paradoxo dos aniversários*** é o caso $m = 23$ e $n = 365$ na equação acima: $\mathbb{P}[\,C>0\,] = 1-\mathbb{P}[\,C=0\,] = 1-\exp(-506/730) > 0{,}5$ (pois $506/730 \approx 0{,}693151 > \ln 2 \approx 0{,}693147$), ou seja, apenas 23 pessoas são suficientes para que duas delas façam aniversário no mesmo dia com probabilidade maior que $1/2$, supondo que os nascimentos ocorram uniformemente ao longo do ano.

Para todo real $x \in (0, 3/4]$ vale[1] $1-x > \exp(-2x)$.

[1] Seja $f(x) = \ln(1-x)+2x$. Então $f(0)=0$ e $f'(x) = 2-\frac{1}{1-x}$, que é positiva em $(0,1/2)$ e negativa em $(1/2,3/4]$. Logo f cresce e depois decresce, e portanto $f(x) > \min\{f(0), f(3/4)\}$ em $(0,3/4]$. Como $f(3/4) = \frac{3}{2} - \ln 4 > 0$, segue que $f > 0$ em todo o intervalo.

Aplicando essa desigualdade a $x = j/n$, com $1 \leqslant j \leqslant m-1$, o que é permitido quando $m \leqslant (3/4)n$, obtemos

$$\begin{aligned}\mathbb{P}[\,C=0\,] = \prod_{j=1}^{m-1}\left(1-\frac{j}{n}\right) &> \prod_{j=1}^{m-1}\exp\left(-\frac{2j}{n}\right)\\ &= \exp\left(-\frac{m(m-1)}{n}\right).\end{aligned}$$

Em particular, se $m \leqslant \sqrt{n}$, então $m(m-1)/n < 1$ e

$$\mathbb{P}[\,C=0\,] > e^{-1} > 0{,}36.$$

Ou seja, para $m = O(\sqrt{n})$ a probabilidade de inserir os m elementos sem colisão é limitada inferiormente por uma constante positiva.

Por outro lado, a cota superior $\exp\left(-\frac{m(m-1)}{2n}\right)$ obtida acima tende a 0 quando $m = \omega(\sqrt{n})$, e portanto $\sqrt{n}$ é o limiar para o aparecimento de colisões.

Markov × exp Para $m \leqslant \sqrt{n}$, a desigualdade de Markov, usada no início dessa seção, fornece uma cota melhor. Como $\mathbb{E}C = \frac{m(m-1)}{2n} < \frac{1}{2}$, temos

$$\mathbb{P}[\,C=0\,] \geqslant 1-\mathbb{E}C > \frac{1}{2} > e^{-1}.$$

A cota exponencial acima é mais fraca nesse regime porque o fator 2 em $1-x > \exp(-2x)$ foi escolhido para valer em todo o intervalo $(0,3/4]$, e não é justo para x pequeno. Em compensação, ela vale para todo $m \leqslant (3/4)n$, onde a cota de Markov deixa de ser informativa: para $m \geqslant \sqrt{2n}+1$ temos $\mathbb{E}C \geqslant 1$, e a cota $1-\mathbb{E}C$ torna-se trivial.

6.1.2 *Variância do número de colisões e do tamanho de uma lista*

Para uma função $h \in_{\mathrm{R}} N^U$, os valores $h(x)$, com $x \in U$, são independentes e uniformes em N. Em particular, para todos $x \neq y$ em U e todos $i, j \in N$, os indicadores $\mathbb{1}_{[h(x)=i]}$ e $\mathbb{1}_{[h(y)=j]}$ são independentes, isto é,

$$\mathbb{P}(\,[h(x)=i]\cap[h(y)=j]\,) = \frac{|\,\{\,h\in N^U\colon h(x)=i,\ h(y)=j\,\}\,|}{n^{|U|}} = \frac{1}{n^2}$$

e, em particular, $\mathbb{P}[\,h(x)=h(y)\,] = \sum_{i\in N}\mathbb{P}(\,[h(x)=i]\cap[h(y)=i]\,) = 1/n$.

Seja X_i o número de elementos de S que caem na posição i

$$X_i = \sum_{x\in S}\mathbb{1}_{[h(x)=i]}.$$

Sabemos que $\mathbb{E}X_i = c$. Como as variáveis indicadoras são duas a duas independentes,

$$\begin{aligned}\operatorname{Var}(\,X_i\,) = \operatorname{Var}\left(\sum_{x\in S}\mathbb{1}_{[h(x)=i]}\right) &= \sum_{x\in S}\operatorname{Var}\left(\,\mathbb{1}_{[h(x)=i]}\,\right)\\ &= \sum_{x\in S}\tfrac{1}{n}\left(1-\tfrac{1}{n}\right) = m\frac{1}{n}\left(1-\frac{1}{n}\right) = c\left(1-\frac{1}{n}\right).\end{aligned}\tag{6.8}$$

Assim, a desigualdade de Chebyshev dá

$$\mathbb{P}[\,|X_i - c| \geqslant t\,] \leqslant \frac{c(1-1/n)}{t^2} \leqslant \frac{c}{t^2},$$

e, por exemplo, tomando $t = c$,

$$\mathbb{P}[\,X_i \geqslant 2c\,] \leqslant \mathbb{P}[\,|X_i - c| \geqslant c\,] \leqslant \frac{1}{c} - \frac{1}{cn}.$$

O que só é útil para c grande.

Pela cota da união sobre as n listas,

$$\mathbb{P}\left[\,\max_i X_i \geqslant c + t\,\right] \leqslant n\cdot\frac{c}{t^2} = \frac{m}{t^2},$$

e, com $t = \sqrt{2m}$, a maior lista tem tamanho no máximo $c + \sqrt{2m} = O(\sqrt{m})$ com probabilidade pelo menos $1/2$ para $n = \Omega(\sqrt{m})$.

O número esperado de colisões é $\mathbb{E}C = \binom{m}{2}/n$ (eq. (6.6)), onde

$$C = \sum_{\substack{\{x,y\}\subseteq S\\ x\neq y}}\mathbb{1}_{[h(x)=h(y)]}$$

conta os pares não ordenados que colidem.

Para pares distintos $\{x,y\} \neq \{z,w\}$ em S, os indicadores de colisão são independentes. Se os pares são disjuntos, eles dependem de quatro valores independentes. Se compartilham um elemento, digamos $\{x,y\}$ e $\{x,z\}$, então

$$\mathbb{P}[\, h(x) = h(y) = h(z)\,] = \sum_{a \in N} \frac{1}{n^3} = \frac{1}{n^2} = \mathbb{P}[\, h(x) = h(y)\,]\mathbb{P}[\, h(x) = h(z)\,]. \tag{6.9}$$

Logo os indicadores são independentes dois a dois e a variância da soma é a soma das variâncias. Cada um tem variância $\frac{1}{n} - \frac{1}{n^2}$ e, portanto,

$$\operatorname{Var}(\, C\,) = \sum_{\substack{\{x,y\} \subseteq S \\ x \neq y}} \operatorname{Var}\big(\, \mathbb{1}_{[h(x)=h(y)]}\,\big) = \binom{m}{2}\left(\frac{1}{n} - \frac{1}{n^2}\right).$$

Como consequência, a desigualdade de Chebyshev dá

$$\mathbb{P}[\, C = 0\,] \leqslant \mathbb{P}[\, |C - \mathbb{E}C| \geqslant \mathbb{E}C\,] \leqslant \frac{\operatorname{Var}(\, C\,)}{(\mathbb{E}C)^2} = \frac{n(1-1/n)}{\binom{m}{2}} \approx \frac{2n}{m^2},$$

de modo que, para $m \gg \sqrt{n}$, há colisão com alta probabilidade. Isso complementa o limiar $m \approx \sqrt{n}$ do paradoxo dos aniversários.

Ideia importante

Vimos que para as estimativas de interesse para colisões basta controlar a colisão entre pares: qualquer família em que dois elementos distintos colidem com probabilidade no máximo $1/n$ tem, no máximo, o mesmo número esperado de colisões que uma função aleatória.
Para uma função aleatória, a probabilidade de colisão de um par é exatamente $1/n$, e foi só isso que usamos para o número esperado de colisões. Basta, portanto, que para uma família $\mathcal{H} \subseteq N^U$ de funções valha $\mathbb{P}_{h \in_R \mathcal{H}}[\, h(x)=h(y)\,] \leqslant \frac{1}{n}$ para todos $x \neq y$ em U. Já para a variância do tamanho da lista, a independência par a par dos indicadores $\mathbb{1}_{[h(x)=i]}$ também é suficiente. Isso é útil porque funções aleatórias não são práticas: não têm descrição pequena, e armazená-las exigiria espaço proporcional a $|U|$. É possível, como veremos, sortear h de uma família menor cujas funções são fáceis de computar, têm descrição curta e preservam as propriedades estatísticas de que precisamos. Note que se comportar como uma função aleatória é uma propriedade da família, não de uma função isolada.

Observação 16. A variância de X_i e, consequentemente, a cota $c + \sqrt{2m}$ para a maior lista usam apenas independência dois a dois e, portanto, valem também para as famílias da Seção 7; em contraste com

o $\Theta(\log n / \log\log n)$, que usa independência de muitas variáveis ao mesmo tempo, esse é o preço da representação sucinta.

Já a fórmula para $\mathrm{Var}(\,C\,)$ usa, por meio de (6.9), a independência de três e de quatro valores $h(x)$ ao mesmo tempo. Ela vale para a função totalmente aleatória (e para famílias com independência de ordem 4), mas não para famílias apenas 2-universais, para as quais só se garante $\mathbb{E}C = \binom{m}{2}/n$.

6.2 *Hashing universal*

Idealmente, o que procuramos para funções de espalhamento são funções que tenham representação sucinta e imitem uma função aleatória nas estatísticas de interesse, como tempo constante de busca e a ausência de listas longas, e que também possam ser computadas eficientemente em cada ponto do domínio.

A ideia principal para resolver o problema do armazenamento de funções é reduzir a aleatoriedade na escolha de h. Formalmente, em vez de selecionar h de maneira aleatória em N^U, sorteamos uma função de uma coleção menor e não vazia de funções, $\mathcal{H} \subseteq N^U$. Em vez de exigirmos que a equação (6.1) seja válida para todo x e todo i, pedimos que seja válida a condição

$$\mathop{\mathbb{P}}_{h \in_R \mathcal{H}} [\, h(x) = h(y) \,] \leqslant \frac{1}{n}, \tag{6.10}$$

para todos $x \neq y$ em U. Uma família não vazia $\mathcal{H} \subseteq N^U$ de funções que satisfazem a equação (6.10) é chamada de ***universal***.

Para uma família universal, ainda valem, como desigualdades, as principais conclusões obtidas para funções aleatórias:

- o tamanho esperado da lista $H[h(x)]$ é no máximo c se $x \notin S$ e no máximo $1 + \frac{m-1}{n} \leqslant 1 + c$ se $x \in S$, pois a conta em (6.4) usa apenas $\mathbb{P}[\, h(x) = h(y) \,] \leqslant 1/n$;
- os tempos esperados de busca da Proposição 6.1 são *no máximo* $c+1$ (sem sucesso) e $1 + \frac{c}{2} - \frac{1}{2n}$ (com sucesso), pois a prova usa apenas a probabilidade de colisão de pares e o fato de que a ordem de inserção não depende de h;
- o número esperado de colisões é no máximo $\binom{m}{2}\frac{1}{n} = \frac{m(m-1)}{2n}$ e, no caso $n = m^2$, esse valor é menor que $1/2$, de modo que, por (3.5), não há colisão com probabilidade maior que $1/2$ (verifique).

Teorema 6.1: colisões para *hashing* universal

Se $\mathcal{H}$ é universal, então para qualquer conjunto $S \subseteq U$ de cardinalidade m e para qualquer $x \in U$, se h é escolhido aleatoria-

mente em $\mathcal{H}$, então o número esperado de colisões entre x e os elementos de $S \setminus \{ x \}$ é no máximo m/n.

Demonstração. Pela linearidade da esperança e por (6.10),

$$\mathbb{E} \sum_{y \in S \setminus \{ x \}} \mathbb{1}_{[h(x)=h(y)]} = \sum_{y \in S \setminus \{ x \}} \mathbb{P}[\, h(x) = h(y) \,] \leqslant \frac{|S \setminus \{ x \}|}{n} \leqslant \frac{m}{n}. \qquad \square$$

Como não precisamos de funções genuinamente aleatórias para termos as boas propriedades estatísticas dessas funções, vamos procurar por uma família universal de funções de *hash* com representações sucintas e que sejam calculadas eficientemente. Por exemplo, a família $\{ f_1, f_2, f_3 \}$ de funções de $\{ 1, 2 \}$ em $\{ 0, 1 \}$ dadas na Tabela 6.1 é universal (verifique). Note que nessa família a equação (6.1) não vale:

	1	2
f_1	0	0
f_2	1	0
f_3	0	1

Tabela 6.1: exemplo de uma família universal.

$\mathbb{P}[\, f(1) = 0 \,] = 2/3 \neq 1/2$. Ou seja, universal não implica que cada $h(x)$ seja uniforme em N.

Exemplo 6.1: uma família universal linear

Podemos definir uma função linear

$$\begin{aligned} h \colon \{ 0,1 \}^d &\to \{ 0,1 \}^k \\ \mathsf{x} &\mapsto \mathsf{A} \cdot \mathsf{x} \end{aligned}$$

sorteando os bits de uma matriz $\mathsf{A} = (a_{\ell,j})$ de dimensão $k \times d$ e tomando as operações de soma e multiplicação módulo 2. Fazendo $U := \{ 0,1 \}^d$ e $N := \{ 0,1 \}^k$, com $|U| = 2^d$ e $|N| = 2^k$, para armazenar a função precisamos apenas da matriz A, que tem $kd = O(\log |N| \cdot \log |U|)$ bits.
Nesse caso, a equação (6.1) não vale para todo x e todo i, pois $h(\mathsf{0}) = \mathsf{0}$ para qualquer escolha de A.

A família é universal: sejam $\mathsf{x}, \mathsf{y} \in U$ distintos. Como h é linear, $h(\mathsf{x}) = h(\mathsf{y})$ se, e somente se, $\mathsf{A} \cdot (\mathsf{x} - \mathsf{y}) = \mathsf{0}$, isto é,

$$\sum_{j=1}^{d} a_{\ell,j} (\mathsf{x} - \mathsf{y})_j = 0 \text{ para cada } \ell \in \{ 1, \ldots, k \}.$$

Seja r uma coordenada não nula de $\mathsf{x} - \mathsf{y}$, ou seja, $(\mathsf{x} - \mathsf{y})_r = 1$ (em aritmética módulo 2). Fixe todos os bits de A fora da coluna r. Então, para cada ℓ, a equação acima se verifica se, e

somente se,

$$a_{\ell,r} = \sum_{\substack{j=1 \\ j \neq r}}^{d} a_{\ell,j}(\mathsf{x}-\mathsf{y})_j \pmod 2,$$

que determina um único valor para o bit $a_{\ell,r}$. Como os k bits da coluna r são sorteados uniformemente e de forma independente, essa condição vale para todas as k linhas com probabilidade 2^{-k}, qualquer que seja a escolha dos demais bits. Portanto,

$$\mathop{\mathbb{P}}_{\mathsf{A} \in_{\mathrm{R}} \{0,1\}^{k \times d}} [\, \mathsf{A}\cdot\mathsf{x} = \mathsf{A}\cdot\mathsf{y} \,] = \frac{1}{2^k} = \frac{1}{|N|}.$$

Carter e Wegman (1979) introduziu o conceito de *hashing universal*: em vez de exigir independência total entre as imagens de todas as chaves, o que consome muitos bits aleatórios, basta que a probabilidade de colisão entre quaisquer duas chaves distintas seja no máximo $1/n$. Famílias com a propriedade mais forte de independência de pares (Seção 7) também são universais, mas a recíproca é falsa.

Exemplo 6.2: o exemplo canônico de uma família universal

Tomamos $U := \{0, 1, \ldots, u-1\}$ e $N := \{0, 1, \ldots, n-1\}$, com $u > n$, e fixamos um primo p com $u < p \leqslant 2u$ (que existe pelo postulado de Bertrand). Definimos a família de funções

$$\mathcal{H}_{p,n} := \left\{ h_{(a,b)} : a, b \in \{0, 1, \ldots, p-1\},\ a \neq 0 \right\}$$

com $h_{(a,b)}(x) = \big((ax + b) \bmod p\big) \bmod n$. Sortear uma função de $\mathcal{H}_{p,n}$ significa sortear (a, b) uniformemente em $\{1, \ldots, p-1\} \times \{0, \ldots, p-1\}$. A restrição $a \neq 0$ é essencial: com $a = 0$ a função seria constante e todos os pares colidiriam. Sejam $x \neq y$ em U. Como $u < p$, temos $0 < |x - y| < p$ e, sendo p primo, $p \nmid x - y$. Se $a \neq 0$, então $p \nmid a(x - y)$, ou seja,

$$(ax + b) \bmod p \neq (ay + b) \bmod p.$$

Ademais, para quaisquer $i, j \in \{0, 1, \ldots, p-1\}$ distintos existe exatamente um par (a, b) com $a \neq 0$ tal que

$$\begin{pmatrix} x & 1 \\ y & 1 \end{pmatrix} \begin{pmatrix} a \\ b \end{pmatrix} \equiv \begin{pmatrix} i \\ j \end{pmatrix} \pmod p, \tag{6.11}$$

pois a matriz é invertível módulo p (seu determinante $x - y$ não é divisível por p). A solução tem $a \neq 0$ justamente porque $i \neq j$: subtraindo as equações, $a(x - y) \equiv i - j \not\equiv 0$. São $p(p-1)$ pares (i, j) distintos e o mesmo tanto de pares (a, b) com $a \neq 0$,

logo há uma bijeção entre esses pares. Disso tiramos que, para $x \neq y$ dados, se sorteamos (a, b) uniformemente, o par $(i, j) = \big((ax + b) \bmod p, (ay + b) \bmod p\big)$ resultante é qualquer par de valores distintos módulo p com a mesma probabilidade. Resta contarmos a quantidade de pares (i, j) de números distintos e congruentes módulo n.
Para cada $i \in \{0, 1, \ldots, p-1\}$, os $j \neq i$ em $\{0, 1, \ldots, p-1\}$ com $j \equiv i \pmod{n}$ correspondem aos múltiplos *não nulos* de n entre os p inteiros consecutivos $\{-i, \ldots, -i + p - 1\}$ (o múltiplo 0 corresponde a $j = i$). Entre p inteiros consecutivos há no máximo $\lceil p/n \rceil \leqslant (p-1)/n + 1$ múltiplos de n, logo há no máximo $(p-1)/n$ valores de j. Assim, há no máximo $p(p-1)/n$ pares (i, j) distintos e congruentes módulo n, e para $x \neq y$

$$\mathbb{P}\big[\, h_{(a,b)}(x) = h_{(a,b)}(y) \,\big] \leqslant \frac{p(p-1)/n}{p(p-1)} = \frac{1}{n}.$$

Como p é fixo e conhecido, cada função é descrita apenas pelo par (a, b), com $2\lceil \log p \rceil \leqslant 2 \log u + O(1) = O(\log |U|)$ bits. No modelo RAM, com palavras de $\Theta(\log u)$ bits, a função consiste em um número constante de operações aritméticas (uma multiplicação, uma soma e dois restos), logo pode ser calculada em tempo constante.

6.2.1 *Hashing perfeito*

Dizemos que uma função de *hash* é ***perfeita*** para um conjunto *estático* S se não há colisões em S, isto é, h é injetora em S. Nesse caso, cada lista tem no máximo um elemento e uma busca custa $O(1)$ no pior caso.

Supomos $|U| > m^2$, para que as famílias do Exemplo 6.2 possam ser usadas com contradomínios de até m^2 posições.

Primeira construção Se $\mathcal{H}$ é universal e $n = m^2$, então o número C de colisões em S satisfaz

$$\mathbb{E}C \leqslant \binom{m}{2} \frac{1}{m^2} = \frac{m(m-1)}{2m^2} < \frac{1}{2},$$

e, por (3.5), $\mathbb{P}[\, C \geqslant 1 \,] \leqslant \mathbb{E}C < \frac{1}{2}$. Logo, escolhendo h aleatoriamente em $\mathcal{H}$, a probabilidade de não haver colisões é maior que $1/2$ (veja (6.6) e (6.7)). Isso sugere um algoritmo do tipo Las Vegas, supondo que $h(x)$ é calculado em tempo $O(1)$:

1. sorteie h em $\mathcal{H}$;
2. teste todos os $O(m^2)$ pares de elementos de S para colisão;

3. repita os passos 1 e 2 até encontrar h sem colisões.

Cada tentativa custa $O(m^2) = O(n)$ e tem probabilidade de sucesso maior que $1/2$. O número de tentativas é uma variável aleatória geométrica de média menor que 2, portanto a função perfeita é encontrada em tempo *esperado* $O(n)$. Dessa forma, temos uma tabela de *hashing* para um conjunto fixo de tamanho m, com tempo de busca $O(1)$ no pior caso e espaço $O(m^2)$.

Segunda construção (espaço linear) É possível obter tempo de busca constante no pior caso usando apenas espaço $O(m)$. O método tem dois níveis:

- *primeiro nível:* espalhamos S em uma tabela H de tamanho m usando uma função h de uma família universal (digamos $h(x) = ((ax + b) \bmod p) \bmod m$), o que poderá resultar em colisões;
- *segundo nível:* se m_i elementos vão parar na posição i de H, eles são distribuídos em uma tabela secundária H_i com m_i^2 posições, usando uma função h_i sem colisões (digamos $h_i(x) = ((a_i x + b_i) \bmod p) \bmod m_i^2$), como na primeira construção. Se $m_i = 0$ não há tabela e, se $m_i = 1$, a tabela tem uma posição.

Para buscar x, calculamos $i = h(x)$. Se $m_i = 0$, então $x \notin S$; caso contrário, comparamos x com o elemento armazenado em $H_i[h_i(x)]$, o que custa $O(1)$ no pior caso.

O espaço usado no segundo nível é $\sum_i m_i^2$. Como $m_i^2 = m_i + m_i(m_i - 1) = m_i + 2\binom{m_i}{2}$ e $\sum_i m_i = m$,

$$\mathbb{E} \sum_{i=0}^{m-1} m_i^2 = m + 2\,\mathbb{E} \sum_{i=0}^{m-1} \binom{m_i}{2}.$$

Aqui $\binom{m_i}{2}$ conta os pares não ordenados de elementos que colidem na posição i da tabela de primeiro nível, portanto $\sum_i \binom{m_i}{2}$ é o número de colisões no *hashing* primário, e cada par que colide é contado exatamente uma vez. Como a probabilidade de um dado par colidir é no máximo $1/m$,

$$\mathbb{E} \sum_i \binom{m_i}{2} \leqslant \frac{1}{m}\binom{m}{2} = \frac{m-1}{2},$$

e portanto $\mathbb{E} \sum_i m_i^2 \leqslant m + (m-1) < 2m$. Pela desigualdade de Markov,

$$\mathbb{P}\left[\sum_i m_i^2 \geqslant 4m \right] \leqslant \frac{\mathbb{E} \sum_i m_i^2}{4m} < \frac{2m}{4m} = \frac{1}{2},$$

ou seja, com probabilidade maior que $1/2$ a soma dos tamanhos das tabelas secundárias é menor que $4m$.

Construção. Para encontrar h com $\sum_i m_i^2 < 4m$, usamos o mesmo procedimento de tentativa e repetição da primeira construção. Para testar uma escolha de h, usamos um vetor de m contadores (inicializado em tempo $O(m)$) e percorremos S, incrementando o contador de $h(x)$ para cada $x \in S$; isso dá os valores m_i em tempo $O(m)$. A probabilidade de sucesso em cada tentativa é maior que $1/2$, logo o número de tentativas é geométrico de média menor que 2 e o tempo esperado para encontrar h é $O(m)$.

Fixada essa função de primeiro nível, para cada i com $m_i \geqslant 1$ sorteamos h_i até que não haja colisões entre os m_i elementos que caem na posição i. Pela primeira construção, o tempo esperado para construir h_i é $O(m_i^2)$. Os sorteios dos h_i são independentes de h e, dado h, o tempo esperado total para construir as tabelas secundárias é $O\left(\sum_i m_i^2\right) = O(m)$, pois $\sum_i m_i^2 < 4m$ vale *por construção*; a aleatoriedade restante está apenas nos sorteios dos h_i.

Por fim, o espaço total é m (tabela primária) mais $\sum_i m_i^2 < 4m$ (tabelas secundárias) mais $O(1)$ palavras para os parâmetros (a, b) e (a_i, b_i) de cada tabela, ou seja, $O(m)$. Resumindo: para um conjunto estático S de tamanho m, construímos em tempo esperado $O(m)$ uma estrutura de espaço $O(m)$ com busca em tempo $O(1)$ no pior caso. Este é o resultado de Fredman, Komlós e Szemerédi (1984).

6.2.2 *Aplicação em streaming: Count-Min sketch*

Suponha que itens $x_1, x_2, \ldots, x_m \in U$ chegam um a um, como num fluxo de dados (acessos a páginas, pacotes numa rede), e que queremos, a qualquer momento, estimar a *frequência* $f(x) \coloneqq |\{\, t : x_t = x \,\}|$ de um item $x \in U$. Guardar um contador para cada item de U exige espaço $|U|$, que é proibitivo. Armazenar os m itens também pode ser proibitivo. O ***Count-Min sketch*** usa funções de *hash* universais para resumir o fluxo em uma pequena matriz de contadores. Note que $\sum_{y \in U} f(y) = m$ e que o fluxo é fixo, isto é, não depende das funções sorteadas.

Sejam $n, d \geqslant 1$ inteiros e $h_1, \ldots, h_d : U \to \{0, 1, \ldots, n-1\}$ funções escolhidas *independentemente* e uniformemente em uma família universal $\mathcal{H}$ (por exemplo, a do Exemplo 6.2). Mantemos uma matriz de contadores (*sketch*) $C[j][k]$, com $1 \leqslant j \leqslant d$ e $0 \leqslant k < n$, inicialmente nulos.

- *chegada de x:* para cada j, incrementamos $C[j][h_j(x)]$;
- *consulta de x:* devolvemos $\widehat{f}(x) \coloneqq \min_{1 \leqslant j \leqslant d} C[j][h_j(x)]$.

Proposição 6.2: Count-Min sketch

Para todo $x \in U$ vale $\widehat{f}(x) \geqslant f(x)$. Além disso, dados $\varepsilon, \delta \in (0,1)$, se $n = \lceil 2/\varepsilon \rceil$ e $d = \lceil \log_2(1/\delta) \rceil$, então

$$\mathbb{P}\Big[\, \widehat{f}(x) > f(x) + \varepsilon m \,\Big] \leqslant \delta.$$

O *sketch* usa $nd = O\big(\frac{1}{\varepsilon} \log \frac{1}{\delta}\big)$ contadores, cada um com $O(\log m)$ bits. Para a família do Exemplo 6.2, cada uma das d funções se descreve com $O(\log |U|)$ bits.

Demonstração. Fixemos $x \in U$ e, para cada linha j, seja $C_j := C[j][h_j(x)]$. Cada chegada de x incrementa C_j, de modo que $C_j \geqslant f(x)$ para todo j, e então $\widehat{f}(x) \geqslant f(x)$. O ***erro*** da linha j é

$$E_j := C_j - f(x) = \sum_{y \neq x} f(y)\, \mathbb{1}_{[h_j(y) = h_j(x)]} \geqslant 0,$$

pois é a soma das frequências dos outros itens que colidem com x na linha j. Como $\mathcal{H}$ é universal, pela linearidade da esperança

$$\mathbb{E} E_j = \sum_{y \neq x} f(y)\, \mathbb{P}\big[\, h_j(y) = h_j(x) \,\big] \leqslant \frac{1}{n} \sum_{y \neq x} f(y) \leqslant \frac{m}{n},$$

em que usamos $\sum_y f(y) = m$. Como $E_j \geqslant 0$, a desigualdade de Markov (3.5) dá

$$\mathbb{P}\big[\, E_j > \varepsilon m \,\big] \leqslant \mathbb{P}\big[\, E_j \geqslant \varepsilon m \,\big] \leqslant \frac{\mathbb{E} E_j}{\varepsilon m} \leqslant \frac{1}{\varepsilon n} \leqslant \frac{1}{2},$$

pois $n \geqslant 2/\varepsilon$. Agora, $\widehat{f}(x) = f(x) + \min_j E_j$, de modo que $\widehat{f}(x) > f(x) + \varepsilon m$ se, e somente se, $E_j > \varepsilon m$ para *todo* j.

Como o fluxo é fixo e E_j depende apenas de h_j, a independência ***mútua*** das funções $h_1, \ldots, h_d$ torna os eventos $[E_j > \varepsilon m]$ mutuamente independentes, e

$$\mathbb{P}\Big[\, \widehat{f}(x) > f(x) + \varepsilon m \,\Big] = \prod_{j=1}^{d} \mathbb{P}\big[\, E_j > \varepsilon m \,\big] \leqslant 2^{-d} \leqslant \delta.$$

A contagem de espaço segue dos valores de n e d, e de que cada contador nunca excede m. □

A estimativa nunca é menor que a frequência verdadeira (o erro é unilateral) e, com probabilidade pelo menos $1 - \delta$, excede-a em no máximo εm. O espaço não depende de $|U|$ nem de m (exceto pelos $\log m$ bits de cada contador), e a escolha de d ilustra o padrão que vimos no hashing perfeito: uma probabilidade de falha constante em cada tentativa, reduzida exponencialmente por repetições independentes.

Observação 17. Dentro de cada h_j, a demonstração usa apenas a universalidade, $\mathbb{P}[\,h(x) = h(y)\,] \leqslant 1/n$, e a desigualdade de Markov; não é necessária a independência de pares. Já a independência ***mútua*** entre $h_1, \ldots, h_d$ é essencial para a cota 2^{-d}. O erro é proporcional ao comprimento m do fluxo, e não a $f(x)$, de modo que a estimativa *só é informativa para itens frequentes*, com $f(x) \gg \varepsilon m$, que é o caso de interesse (por exemplo, na detecção dos itens mais acessados). A análise acima supõe que os itens apenas chegam; se houver remoções, a propriedade $\widehat{f}(x) \geqslant f(x)$ pode falhar e a análise é outra. ◊

6.2.3 *Aplicação: filtro de Bloom*

Suponha que queremos representar um conjunto $S \subseteq U$ com $m = |S|$ elementos e responder a consultas "$x \in S$?". Uma tabela de espalhamento resolve o problema, mas guarda os próprios elementos e, portanto, usa pelo menos $\log_2 \binom{|U|}{m} \geqslant m \log_2(|U|/m)$ bits. Em muitas aplicações, como decidir se um endereço está numa lista de páginas maliciosas ou se uma chave está num arquivo em disco antes de pagar o custo do acesso, é aceitável errar *num único sentido*: ocasionalmente responder "sim" para um $x \notin S$ (um ***falso positivo***), mas nunca responder "não" para um $x \in S$ (um ***falso negativo***). Em troca do erro unilateral, ganhamos espaço: poucos bits por elemento, sem depender do tamanho dos elementos. É o que faz o ***filtro de Bloom*** (Bloom, 1970).

Sejam $n, k \geqslant 1$ inteiros e $h_1, \ldots, h_k \colon U \to \{0, 1, \ldots, n-1\}$ funções escolhidas *independentemente* e uniformemente em uma família universal $\mathcal{H}$ (por exemplo, a do Exemplo 6.2). Mantemos uma matriz de bits $B[j][l]$, com $1 \leqslant j \leqslant k$ e $0 \leqslant l < n$, inicialmente nulos. A estrutura é a do *Count-Min sketch* com contadores de um bit:

- *inserção de x:* para cada j, fazemos $B[j][h_j(x)] \leftarrow 1$;
- *consulta de x:* devolvemos 1 ("talvez $x \in S$") se $B[j][h_j(x)] = 1$ para *todo* j e 0 ("certamente $x \notin S$") caso contrário.

O espaço é kn bits, mais $O(\log |U|)$ bits para descrever cada uma das k funções (para a família do Exemplo 6.2).

Proposição 6.3: filtro de Bloom

Sejam $S \subseteq U$ com $|S| = m$ e $x \in U$ fixados *antes* do sorteio das funções, e suponha que todos os elementos de S foram inseridos num filtro de Bloom com k linhas de n bits, em que $h_1, \ldots, h_k$ são escolhidas independentemente e uniformemente em uma família universal com contradomínio $\{0, \ldots, n-1\}$ (a do Exemplo 6.2 exige $|U| > n$). Então

1. se $x \in S$, a consulta devolve 1 com probabilidade 1, para qualquer escolha das funções;
2. se $x \notin S$, a consulta devolve 1 com probabilidade no máximo $(m/n)^k$.

Em particular, dado $\delta \in (0,1)$, se $n = 2m$ e $k = \lceil \log_2(1/\delta) \rceil$, a probabilidade de falso positivo é no máximo δ e o espaço é $kn = 2m\lceil \log_2(1/\delta) \rceil$ bits, além dos $O(\log |U| \log(1/\delta))$ bits das funções (na família do Exemplo 6.2).

Demonstração. Se $x \in S$, a inserção de x colocou 1 em todas as posições $B[j][h_j(x)]$, e nenhum bit volta a ser 0; logo a consulta devolve 1.

Fixemos $x \notin S$ e uma linha j. Como só a função h_j escreve na linha j, temos $B[j][h_j(x)] = 1$ se, e somente se, existe $y \in S$ com $h_j(y) = h_j(x)$; chamemos esse evento de E_j. Como $x \neq y$ para todo $y \in S$, a cota da união e a universalidade de $\mathcal{H}$ dão

$$\mathbb{P}\left[E_j \right] \leqslant \sum_{y \in S} \mathbb{P}\left[h_j(y) = h_j(x) \right] \leqslant \frac{m}{n}.$$

Os conjuntos S e $\{ x \}$ estão fixos e E_j depende apenas de h_j; como as funções são independentes, os eventos $E_1, \ldots, E_k$ são independentes, e a consulta devolve 1 se, e somente se, todos ocorrem. Portanto

$$\mathbb{P}\left[\text{falso positivo} \right] = \prod_{j=1}^{k} \mathbb{P}\left[E_j \right] \leqslant \left(\frac{m}{n} \right)^k.$$

Para $n = 2m$ essa cota é $2^{-k} \leqslant \delta$. □

O erro é *unilateral*, como no protocolo de impressões digitais (Seção 7.1), e a análise segue o padrão que já vimos no *Count-Min sketch* e no *hashing* perfeito: uma probabilidade de falha de no máximo $1/2$ em cada linha (com $n = 2m$), obtida com a cota da união e a universalidade, é reduzida exponencialmente por $k = \log_2(1/\delta)$ repetições independentes. De fato, o filtro é um *Count-Min sketch* com contadores de um bit que saturam em 1: a consulta, que no *Count-Min* é o mínimo dos contadores, passa a ser a conjunção (AND) dos bits. A cota só é informativa se $n > m$, isto é, com mais de um bit por elemento em cada linha.

A Proposição trata de x fixo, e a probabilidade é sobre a escolha das funções. Na prática, porém, o filtro é construído uma vez e depois consultado muitas vezes. O corolário seguinte diz que, para a maioria das escolhas das funções, a *fração* de consultas que erram também é pequena.

Corolário 6.1: taxa de falsos positivos

Sejam S e o filtro como na Proposição 6.3 e seja Q uma distribuição de probabilidade sobre $U \setminus S$, fixada independentemente de $h_1, \ldots, h_k$ (por exemplo, a uniforme). Seja Φ a probabilidade, segundo Q, de que a consulta de $x \sim Q$ devolva 1, isto é, a taxa de falsos positivos do filtro construído. Então $\mathbb{E}\Phi \leqslant (m/n)^k$ e, para todo $a > 1$,

$$\mathbb{P}\left[\, \Phi \geqslant a\,(m/n)^k \,\right] \leqslant \frac{1}{a}.$$

Demonstração. Se $\mathbb{1}_{[x \text{ é falso positivo}]}$ vale 1 quando a consulta de x devolve 1, então $\Phi = \sum_{x \notin S} Q(x)\, \mathbb{1}_{[x \text{ é falso positivo}]}$ e, pela linearidade da esperança e pela Proposição 6.3 aplicada a cada $x \notin S$, $\mathbb{E}\Phi = \sum_{x \notin S} Q(x) \mathbb{P}\left[\, x \text{ é falso positivo} \,\right] \leqslant (m/n)^k$. Como $\Phi \geqslant 0$, a desigualdade de Markov dá o resto. □

Por exemplo, com $n = 2m$ e $k = \lceil \log_2(1/\delta) \rceil$, com probabilidade pelo menos 0,9 sobre a escolha das funções a taxa de falsos positivos do filtro construído é no máximo $10\,\delta$.

A variante clássica: um único vetor No filtro de Bloom original as k funções escrevem num mesmo vetor B de n bits, com $h_j : U \to \{0, 1, \ldots, n-1\}$, em vez de em k linhas separadas de n bits cada; aqui n passa a designar o espaço total do filtro. A análise exata pede mais do que universalidade, pois os bits de um mesmo vetor deixam de ser independentes entre as sondagens. Aqui fazemos a conta no modelo de funções totalmente aleatórias, como na Seção 6.1.

Depois de inserir m elementos foram feitas km escolhas independentes e uniformes de posição em n bits. Seja X o número de bits iguais a 1 no vetor. Cada bit continua nulo com probabilidade $(1 - 1/n)^{km}$, de modo que

$$\mathbb{E}X = n\left(1 - \left(1 - \frac{1}{n}\right)^{km}\right).$$

Para $x \notin S$, as k posições sondadas são independentes e uniformes, e independentes do vetor. Dado o vetor, a consulta devolve 1 se, e somente se, todas as k posições sondadas são bits 1, o que ocorre com probabilidade $(X/n)^k$. Como X é aleatório e os bits do vetor não são independentes, a probabilidade de falso positivo é a esperança $\mathbb{E}(X/n)^k$, e não o produto das probabilidades marginais:

$$\mathbb{P}\left[\, \text{falso positivo} \,\right] = \mathbb{E}\left(\frac{X}{n}\right)^k \geqslant \left(\frac{\mathbb{E}X}{n}\right)^k = \left(1 - \left(1 - \frac{1}{n}\right)^{km}\right)^k > \left(1 - e^{-km/n}\right)^k,$$

em que a primeira desigualdade é a de Jensen ($t \mapsto t^k$ é convexa) e a última vem de $1 - 1/n < e^{-1/n}$. Portanto a fórmula clássica

$$\left(1 - e^{-km/n}\right)^k \tag{6.12}$$

é um limitante *inferior* para a probabilidade de falso positivo e, para k fixo e m/n fixo, com n grande, é conhecido da literatura que a diferença para o valor exato é desprezível (resultado que não provamos). Assim, a fórmula serve para dimensionar o filtro, com a ressalva de que o erro real é um pouco maior.

Qual k minimiza (6.12), fixados n e m? Escrevendo $u = e^{-km/n}$, de modo que $k = -\frac{n}{m}\ln u$, temos

$$\left(1 - e^{-km/n}\right)^k = \exp\!\left(-\frac{n}{m}\, f(u)\right), \qquad f(u) := \ln u \cdot \ln(1-u) > 0.$$

Minimizar (6.12) equivale a maximizar f em $(0,1)$. A função f é simétrica ($f(u) = f(1-u)$) e estritamente côncava[2], portanto tem um único máximo, em $u = 1/2$, onde $f = (\ln 2)^2$. Isso ocorre para

$$k = \frac{n}{m}\ln 2,$$

(que na prática é arredondado para um inteiro). Nesse valor, metade dos bits do vetor é 1 e

$$\left(1 - \tfrac{1}{2}\right)^k = 2^{-k} = 2^{-(n/m)\ln 2}.$$

Para obter probabilidade de falso positivo (aproximadamente) δ tomamos $k = \log_2(1/\delta)$ e

$$n = \frac{m \log_2(1/\delta)}{\ln 2} = (\log_2 e)\, m \log_2(1/\delta) \approx 1{,}44\, m \log_2(1/\delta)$$

bits, contra os $2m\lceil \log_2(1/\delta)\rceil$ da Proposição 6.3. Como o erro real é um pouco maior que (6.12), na prática escolhe-se n ligeiramente maior. Em outras palavras, o espaço por elemento depende só do erro desejado δ, e não de m nem de $|U|$: cerca de 9,6 bits por elemento para $\delta = 1\%$ (com $k = 7$) e cerca de 14,4 bits para $\delta = 0{,}1\%$ (com $k = 10$).

[2] Seja $F(u) := 2u(1-u) + (1-u)^2\ln(1-u) + u^2 \ln u$. Um cálculo direto dá $f''(u) = -F(u)/\big(u^2(1-u)^2\big)$. Temos $F(0) = F(1) = 0$ (pelos limites) e $F''(u) = 2\ln(u(1-u)) + 2 \leqslant 2\ln\frac{1}{4} + 2 < 0$, pois $u(1-u) \leqslant \frac{1}{4}$. Logo F é estritamente côncava e, como se anula nos extremos, $F > 0$ em $(0,1)$, isto é, $f'' < 0$.

Exemplo 6.3: comparação de espaço

Seja $m = 10^8$ endereços de 50 bytes (400 bits cada) e $\delta = 10^{-2}$. A tabela compara o espaço necessário.

estrutura	bits	aprox.
guardar os endereços	4×10^{10}	5 GB
guardar impressões de 34 bits	$3{,}4 \times 10^9$	425 MB
Bloom em k linhas, $n = 2m$, $k = 7$	$1{,}4 \times 10^9$	175 MB
Bloom em vetor único, $k = 7$	$9{,}6 \times 10^8$	120 MB

Na segunda linha, cada endereço é substituído por uma impressão digital de $r = \lceil \log_2(m/\delta) \rceil = 34$ bits, calculada por uma função de uma família *universal* (por exemplo, a do Exemplo 6.2, com contradomínio de 2^r valores), cuja descrição, de $O(\log |U|)$ bits, é paga uma única vez e é desprezível diante de mr. Pela cota da união, a probabilidade de um $x \notin S$ coincidir com alguma impressão é no máximo $m2^{-r} \leqslant \delta$. O custo mr cresce com $\log m$, enquanto o do filtro de Bloom é de poucos bits por elemento; além disso, mr não inclui a estrutura necessária para guardar e consultar as impressões. Com as famílias ε-quase universais da Seção 7.1, que têm descrição ainda mais curta mas colisão por par de $\approx m_0/p$, onde $m_0 = 400$ é o número de bits de cada endereço, seriam necessários cerca de $\log_2(m\, m_0/\delta) \approx 42$ bits por impressão.

Observação 18. Qualquer estrutura que não tenha falsos negativos e tenha probabilidade de falso positivo no máximo δ precisa, para $m \ll |U|$, de cerca de $m \log_2(1/\delta)$ bits (resultado clássico, que não provamos). O filtro de Bloom em vetor único está, portanto, a um fator $\log_2 e \approx 1{,}44$ do ótimo.

Algumas propriedades práticas: (i) a união de dois filtros com as mesmas funções e o mesmo tamanho é o OR bit a bit, e é o filtro da união dos conjuntos; (ii) *não* há como remover um elemento, pois zerar um bit pode apagar outros elementos e criar falsos negativos. A variante com remoção troca cada bit por um contador, incrementado na inserção e decrementado na remoção, o que a aproxima ainda mais do *Count-Min sketch*; (iii) a garantia vale para até m elementos, e inserir muito mais que isso degrada a probabilidade de falso positivo; (iv) a estrutura não permite listar os elementos de S. ◊

Aplicações O filtro de Bloom é usado sempre que uma consulta negativa barata evita uma operação cara. Em bancos de dados baseados em arquivos ordenados em disco, como Bigtable, HBase e Cassandra, cada arquivo mantém um filtro de suas chaves em memória; antes de ler o arquivo, consulta-se o filtro, e a resposta "certamente não" dispensa o acesso a disco. Os falsos positivos custam apenas uma leitura desnecessária, enquanto a ausência de falsos negativos garante a correção do resultado. O mesmo princípio vale para *caches* de rede e de conteúdo (verificar se um objeto já foi visto ou armazenado antes de buscá-lo), para *crawlers* (descartar endereços já visitados sem guardar a lista completa) e para junções em bancos de dados distribuídos, em que um nó envia a outro um filtro com as chaves de uma tabela, para que apenas as linhas candidatas sejam transmitidas, reduzindo

o tráfego. Na bioinformática, filtros armazenam conjuntos enormes de subcadeias de tamanho fixo (*k-mers*) de genomas, em espaço muito menor que o das próprias subcadeias. Em todos esses casos o que importa é a troca central desta seção: aceitar uma probabilidade pequena e controlável δ de erro unilateral em troca de cerca de $1{,}44 \log_2(1/\delta)$ bits por elemento, independentemente do tamanho dos elementos.

6.3 Exercícios

Exercício 43. Dizemos que uma família $\mathcal{H}$ de funções hash é ***fracamente k-universal*** se para quaisquer $x_1, \ldots, x_k \in \{0,1\}^m$

$$\mathop{\mathbb{P}}_{h \in \mathcal{H}} (\, h(x_1) = h(x_2) = \cdots = h(x_k) \,) \leqslant \frac{1}{n^{k-1}}. \tag{6.13}$$

Prove que a família

$$h_{(a,b)}(x) = (ax + b \mod p) \mod 2^n$$

para $a,\ b \in \{0, 1, \ldots, p-1\}$ é fracamente 2-universal se p é um primo com $m+1$ bits na sua representação binária.

Exercício 44. Seja $\mathcal{H}$ uma família qualquer de funções hash. Dados $x,\ y \in \{0,1\}^m$ e $h \in \mathcal{H}$ defina

$$\delta(x, y, h) = \begin{cases} 1, & \text{se } x \neq y \text{ e } h(x) = h(y) \\ 0, & \text{caso contrário.} \end{cases}$$

Prove que

$$\sum_{h \in \mathcal{H}} \delta(x, y, h) > \frac{|\mathcal{H}|}{2^n} - \frac{|\mathcal{H}|}{2^m}.$$

Exercício 45. Para p primo, prove que as p^{r+1} funções de $U = \{0, 1, \ldots, p-1\}^{r+1}$ em $\{0, 1, \ldots, p-1\}$ dadas por

$$h_{\mathsf{a}}(\mathsf{x}) = \langle \mathsf{a}, \mathsf{x} \rangle \bmod p = \sum_{i=0}^{r} a_i x_i \bmod p$$

é universal (sortear uma função equivale a sortear a em U).

Exercício 46. Na seção 6.1, página 144, foi dito que se uma tabela de espalhamento usa uma função aleatória escolhida numa família universal, então o número esperado de colisões para S fixo é $\binom{n}{2}(1/m) = n(n-1)/(2m)$ de modo que se $m = n^2$ então $\mathbb{E}C < 1/2$ e não há colisão com probabilidade pelo menos $1/2$. Portanto, se S é um conjunto fixo (estático) podemos sortear uma função até que encontremos uma que não ocasiona colisões para elementos de S. Escreva um algoritmo aleatorizado que dado S encontra uma função de

hash h perfeita. Determine a complexidade desse algoritmo. É possível usar o método das esperanças condicionais nesse caso?

Exercício 47. No filtro de Bloom em k linhas de w bits, com funções totalmente aleatórias, mostre que a probabilidade de falso positivo para $x \notin S$ é exatamente $(1 - (1 - 1/w)^m)^k$ e compare com a cota $(m/w)^k$ da Proposição 6.3.

Exercício 48. Sejam F_1 e F_2 filtros de Bloom com as mesmas funções e o mesmo tamanho, construídos a partir de S_1 e S_2. Mostre que o OR bit a bit de F_1 e F_2 é exatamente o filtro construído a partir de $S_1 \cup S_2$. O AND bit a bit é o filtro de $S_1 \cap S_2$? Mostre que ele não tem falsos negativos para $S_1 \cap S_2$ e dê um exemplo em que tem mais bits 1 que o filtro construído diretamente a partir de $S_1 \cap S_2$.

Exercício 49. Para $m = 10^6$ e $n = 8 \times 10^6$ bits, determine o k inteiro que minimiza (6.12) e calcule o valor aproximado da probabilidade de falso positivo. Confirme, derivando duas vezes, que o ponto crítico $k = (n/m) \ln 2$ é de fato um mínimo de $g(k)$.

Exercício 50. Um fluxo tem $m = 10^9$ chegadas. Queremos que, com probabilidade pelo menos $1 - 10^{-6}$, a estimativa da frequência exceda $f(x)$ em no máximo εm, com $\varepsilon = 10^{-3}$.

1. Determine n e d pela proposição e calcule o número de contadores nd.
2. Cada contador precisa de quantos bits? Qual é o espaço total em KB?
3. Qual é o erro absoluto garantido? Para que valores de $f(x)$ a estimativa tem erro relativo de no máximo 10%?

Exercício 51. Suponha que o fluxo também possa conter remoções: remover x decrementa $C[j][h_j(x)]$ para todo j. Seja $f(y)$ a frequência líquida (chegadas menos remoções) no instante da consulta, e suponha $f(y) \geq 0$ para todo y. Seja $m' = \sum_y f(y)$.

(a) Mostre que, nesse instante, $C[j][h_j(x)] = \sum_{y\,:\,h_j(y)=h_j(x)} f(y)$.

(b) Conclua que $\widehat{f}(x) \geq f(x)$ e que $\mathbb{P}[\widehat{f}(x) > f(x) + \varepsilon m'] \leq \delta$ com os mesmos n e d.

(c) Dê um exemplo, com uma frequência líquida negativa, em que $\widehat{f}(x) < f(x)$.

(Dica: a linearidade dos contadores reduz tudo à prova da proposição, com m' no lugar de m. Para (c), uma remoção de x sem chegada anterior já serve.)

Exercício 52. Queremos um filtro para $m = 10^6$ elementos com probabilidade de falso positivo no máximo $\delta = 10^{-3}$.

1. Com k linhas e $n = 2m$, qual k basta e quantos bits o filtro usa?
2. Com um único vetor de n bits, calcule n e k pela fórmula clássica, em bits e em MB.
3. Compare com o limite inferior $m \log_2(1/\delta)$.

Exercício 53. Sejam B_1 e B_2 os filtros (com as mesmas funções $h_1, \ldots, h_k$ e o mesmo tamanho) de S_1 e S_2.

1. Mostre que o OR bit a bit $B_1 \vee B_2$ é exatamente o filtro de $S_1 \cup S_2$. Conclua que a probabilidade de falso positivo de $B_1 \vee B_2$, para $x \notin S_1 \cup S_2$, é no máximo $\left(|S_1 \cup S_2|/n\right)^k$, no filtro em k linhas.
2. Mostre, com um exemplo pequeno, que remover um elemento zerando seus k bits pode produzir um falso negativo para outro elemento de S.
3. Explique por que trocar cada bit por um contador, incrementado na inserção e decrementado na remoção, evita o problema do item (b), desde que só se removam elementos inseridos.

(Dica: em (a), cada bit de B_i vale 1 se, e somente se, algum elemento de S_i colide nele, e o filtro da união é o OR desses eventos. Para (b), basta que $a \neq b$ compartilhem uma posição.)

7
Hashing 2-universal

Na seção anterior (Seção 6.2) vimos que qualquer família em que dois elementos distintos colidem com probabilidade no máximo $1/n$ (*família universal*) dá, para as estatísticas que dependem apenas de colisões aos pares, os mesmos limites esperados que uma função de *hash* aleatória. As funções aleatórias não têm uma descrição pequena, e a ideia-chave para contornar esse problema foi dada por Carter e Wegman (1979) (Exemplo 6.2): a função de *hash* é escolhida de uma família relativamente pequena de funções que são fáceis de computar, precisam de pouco espaço para serem descritas e têm algumas das propriedades estatísticas importantes das funções aleatórias.

O problema é, então, encontrar uma família pequena, fácil de computar, que se comporte como uma função aleatória nas estatísticas de que precisamos. Esse problema é comum em muitos contextos da teoria da computação e é um dos principais problemas no estudo da desaleatorização. Nesta seção, usaremos ***independência par a par*** para caracterizar o que significa se comportar como uma função aleatória. De fato, essa é uma característica de uma família de funções, não de uma única função.

Para uma família $\mathcal{H} = \{ h_\lambda \in N^U : \lambda \in \Lambda \}$ de funções de *hash*, pedimos que cada h_λ seja computável eficientemente e tenha descrição curta, que $|\Lambda|$ não seja muito grande e que as variáveis aleatórias

$$H_x(\lambda) \coloneqq h_\lambda(x), \qquad x \in U,$$

tenham a propriedade de independência de pares definida a seguir. A condição sobre $|\Lambda|$ tem uma razão concreta: sortear $\lambda \in_R \Lambda$ custa $\log |\Lambda|$ bits aleatórios, contra cerca de $|U| \log n$ bits para uma função totalmente aleatória.

Definição 7.1: família 2-universal de funções

Uma família $\mathcal{H} = \{ h_\lambda : \lambda \in \Lambda \} \subseteq N^U$, com $|U| \geqslant |N| \geqslant 2$, é 2-

universal se, munida da distribuição uniforme em Λ, temos

$$\mathop{\mathbb{P}}_{\lambda\in\Lambda}\big([H_x{=}i]\cap[H_y{=}j]\big) = \mathop{\mathbb{P}}_{\lambda\in\Lambda}([h_\lambda(x){=}i]\cap[h_\lambda(y){=}j]) = \frac{1}{|N|^2},$$

para quaisquer $x, y \in U$ distintos e quaisquer $i, j \in N$.

Dado $x \in U$ e $i \in N$, tome qualquer $y \in U$ com $y \neq x$ (que existe pois $|U| \geqslant |N| \geqslant 2$). Então

$$\begin{aligned}\mathbb{P}_{H_x}(i) &= \mathop{\mathbb{P}}_{\lambda\in\Lambda}[\,h_\lambda(x) = i\,] \\ &= \sum_{j\in N} \mathop{\mathbb{P}}_{\lambda\in\Lambda}([h_\lambda(x) = i]\cap[h_\lambda(y) = j]) \\ &= \sum_{j\in N} \frac{1}{|N|^2} = \frac{1}{|N|}\end{aligned} \tag{7.1}$$

donde concluímos que cada H_x é uniforme em N. Logo, para $x \neq y$,

$$\mathop{\mathbb{P}}_{\lambda\in\Lambda}\big([H_x = i]\cap[H_y = j]\big) = \frac{1}{|N|}\cdot\frac{1}{|N|} = \mathbb{P}_{H_x}(i)\,\mathbb{P}_{H_y}(j),$$

isto é, $[H_x = i]$ e $[H_y = j]$ são eventos independentes em Λ. Ou seja, as variáveis H_x são independentes *par a par*; a definição não garante independência conjunta de três ou mais delas. Em particular, a probabilidade de colisão é *exatamente* a da função aleatória

$$\mathop{\mathbb{P}}_{\lambda\in\Lambda}[\,h_\lambda(x) = h_\lambda(y)\,] = \sum_{i\in N}\frac{1}{|N|^2} = \frac{1}{|N|}.$$

Como $\mathbb{P}[\,h(x) = h(y)\,] \leqslant 1/|N|$, toda família 2-universal é universal e, portanto, vale para ela tudo o que foi provado na seção anterior a partir apenas da linearidade da esperança e das probabilidades de colisão aos pares (tempo esperado de busca, número esperado de colisões, cota de Markov).

Exemplo 7.1: uma família universal que não é 2-universal

Para $U{=}N{=}\{0,1,\ldots,p-1\}$ com p primo, a família $\{\,h_a \in N^U : a\in U\,\}$ das funções dadas por

$$h_a(x){=}(ax) \bmod p$$

onde uma escolha aleatória $a \in_{\mathrm{R}} U$ define unicamente uma função.
Dados $x{\neq}y$, temos $h_a(x){=}h_a(y)$ se, e somente se, $a(x-y){\equiv}0 \pmod p$, o que, como p é primo, só ocorre para $a{=}0$. Logo x e

y colidem com probabilidade $1/p = 1/|N|$ e a família é *universal*. Essa família, porém, *não* é 2-universal: $h_a(0) = 0$ para todo a, de modo que H_0 não é uniforme, e, como há apenas p funções para p^2 pares (i, j), a probabilidade de $[H_x = i] \cap [H_y = j]$ nunca é $1/p^2$.

Exemplo 7.2

Para $U = N = \{0, 1, \ldots, p-1\}$ com p primo, a família $\{h_{a,b} : (a, b) \in U^2\}$, com $(a, b) \in_R U^2$, dada pelas funções

$$h_{a,b}(x) = (ax + b) \bmod p$$

tem p^2 funções, cada uma descrita por $2\lceil \log p \rceil$ bits. Note que aqui $a = 0$ é permitido.
Dados $x \neq y$ e $i, j \in N$, o sistema

$$\begin{cases} ax + b \equiv i \pmod{p} \\ ay + b \equiv j \pmod{p} \end{cases}$$

tem determinante $x - y \not\equiv 0 \pmod{p}$, logo tem exatamente uma solução $(a, b) \in U^2$. Assim,

$$\mathbb{P}[\,[h_{a,b}(x) = i] \cap [h_{a,b}(y) = j]\,] = \frac{1}{p^2},$$

e a família é 2-universal. A permissão de $a = 0$ é o que a distingue da família $\mathcal{H}_{p,n}$ do Exemplo 6.2, onde $a \neq 0$ exclui os pares (i, i) e o resto módulo n destrói a uniformidade. Por outro lado, a independência é só de pares: há apenas p^2 funções para p^3 triplas de valores.

Exemplo 7.3

Seja $\mathbb{F}$ um corpo finito com q elementos e $d \geqslant 1$ um inteiro. Tomemos $U = \mathbb{F}^d$, $N = \mathbb{F}$ (de modo que $|N| = q$) e a família de funções de $\mathbb{F}^d$ em $\mathbb{F}$

$$\mathcal{H} := \left\{ h_{(\mathsf{a},b)}(\mathsf{x}) = \langle \mathsf{a}, \mathsf{x} \rangle + b : \mathsf{a} \in \mathbb{F}^d,\ b \in \mathbb{F} \right\},$$

onde $\langle \mathsf{u}, \mathsf{v} \rangle = \sum_{k=1}^{d} u_k v_k$ denota o produto escalar usual. Note que $\mathsf{a} = 0$ é permitido.
Uma escolha aleatória de função é dada por $(\mathsf{a}, b) \in_R \mathbb{F}^d \times \mathbb{F}$, isto é, sorteando $a_1, \ldots, a_d, b$ independentemente e uniformemente em $\mathbb{F}$.

Se $\mathsf{z} \neq 0$ então, para a sorteado em $\mathbb{F}^d$ e qualquer $t \in \mathbb{F}$,

$$\mathbb{P}[\,\langle \mathsf{a}, \mathsf{z}\rangle = t\,] = \frac{1}{q},$$

pelo princípio da decisão adiada: tome k com $z_k \neq 0$ e sorteie primeiro os a_l com $l \neq k$; então deve valer $a_k = z_k^{-1}\big(t - \sum_{l\neq k} a_l z_l\big)$, que é um único valor de $\mathbb{F}$ e é sorteado com probabilidade $1/q$. Dados $\mathsf{x} \neq \mathsf{y}$ em $\mathbb{F}^d$ e $i, j \in \mathbb{F}$, o evento

$$[\langle \mathsf{a}, \mathsf{x}\rangle + b = i] \cap [\langle \mathsf{a}, \mathsf{y}\rangle + b = j]$$

coincide com

$$[\langle \mathsf{a}, \mathsf{x} - \mathsf{y}\rangle = i - j] \cap [b = i - \langle \mathsf{a}, \mathsf{x}\rangle].$$

Como $\mathsf{x} - \mathsf{y} \neq 0$, o primeiro evento tem probabilidade $1/q$. Fixado qualquer a, o segundo evento pede um valor determinado para b, que é independente de a e uniforme, com probabilidade $1/q$. Condicionando em a,

$$\mathbb{P}[\,[\langle \mathsf{a}, \mathsf{x}\rangle + b = i] \cap [\langle \mathsf{a}, \mathsf{y}\rangle + b = j]\,] = \sum_{\substack{\mathsf{a}:\\ \langle \mathsf{a}, \mathsf{x}-\mathsf{y}\rangle = i-j}} \frac{1}{q^d} \cdot \frac{1}{q} = \frac{1}{q} \cdot \frac{1}{q} = \frac{1}{q^2},$$

pois, pelo parágrafo anterior, a soma tem q^{d-1} termos. Concluímos que $\mathcal{H}$ é 2-universal.
Para $d = 1$ e $\mathbb{F} = \mathbb{F}_p$ obtemos a família $h_{a,b}(x) = (ax + b) \bmod p$ do Exemplo 7.2.

Observação 19. *Quanto a terminologia* Na literatura, "universal" (no sentido de Carter e Wegman (1979)) costuma significar apenas $\mathbb{P}[\,h(x) = h(y)\,] \leqslant 1/|N|$ para $x \neq y$, e a independência de pares da definição acima é chamada de ***fortemente 2-universal*** ou ***2-independente***.

A condição forte implica a fraca, mas não vale a recíproca: o Exemplo 7.1 e a família linear $h(\mathsf{x}) = \mathsf{A}\mathsf{x}$ do exemplo da seção anterior (Exemplo 6.1) são universais, mas, como $h(0) = 0$ sempre, não são 2-universais. ◊

No caso particular do exemplo acima com $\mathbb{F} = \mathbb{F}_2$ e $d = 2$, $\mathcal{H}$ é o conjunto das 2^3 funções de $\{0,1\}^2$ em $\{0,1\}$. Cada função é dada por 3 bits, dos quais 2 são do parâmetro a e 1 do parâmetro b. Assim, sorteando 3 bits obtemos uma sequência de 4 bits, $h_{(\mathsf{a},b)}(00)$, $h_{(\mathsf{a},b)}(01)$, $h_{(\mathsf{a},b)}(10)$ e $h_{(\mathsf{a},b)}(11)$, cada um com distribuição uniforme e dois a dois independentes (mas não mutuamente independentes: há só 8 sequências possíveis em 16).

No caso geral do corpo binário, sorteando $d+1$ bits obtemos uma sequência de 2^d bits $h_{(\mathsf{a},b)}(\mathsf{x})$, $\mathsf{x} \in \{0,1\}^d$, com distribuição uniforme e dois a dois independentes. Essa sequência pode ser usada para a desaleatorização de algoritmos que usam bits aleatórios com independência dois a dois, como é o caso do algoritmo para achar cortes grandes em grafos (Algoritmo 7.1, página 164).

Concentração via Chebyshev Para $S \subseteq U$ fixo, de cardinalidade m, e $y \in N$, com $n \coloneqq |N|$ e $c = m/n$, seja $Z \coloneqq \sum_{x\in S} \mathbb{1}_{[H_x=y]} = |S \cap h_\lambda^{-1}(y)|$. Pela 2-universalidade, os indicadores $\mathbb{1}_{[H_x=y]}$ são uniformes ($\mathbb{P} = 1/n$) e independentes dois a dois, de modo que $\mathbb{E}Z = c$ e, como em (6.8), $\mathrm{Var}(Z) = c(1-1/n)$. Pela desigualdade de Chebyshev, para todo $\varepsilon > 0$,

$$\mathbb{P}[\, |Z-c| > \varepsilon m \,] \leqslant \frac{(1/n)(1-1/n)}{\varepsilon^2 m},$$

e, pela cota da união sobre os n valores de y,

$$\mathbb{P}\Big[\, \exists y \in N : |S \cap h_\lambda^{-1}(y)| > (\varepsilon + 1/n)m \,\Big] \leqslant \frac{1-1/n}{\varepsilon^2 m} \leqslant \frac{1}{\varepsilon^2 m}.$$

Essa cota só diz algo para $\varepsilon \gg 1/\sqrt{m}$, isto é, para desvios maiores que $\sqrt{m}$ em torno de c.

7.0.1 *Desaleatorização de corte grande em grafos*

Algoritmos aproximativos Muitos problemas de otimização são NP-difíceis, o que quer dizer que, a menos que P = NP, não têm algoritmo eficiente que os resolva exatamente no pior caso. Há casos, no entanto, em que soluções próximas da ótima são razoavelmente boas.

Para problemas de maximização, um ***algoritmo aproximativo*** é um algoritmo que encontra soluções próximas da ótima, para uma garantia $0 < \alpha \leqslant 1$ fixada: o valor devolvido pelo algoritmo é no máximo o valor ótimo OPT e pelo menos $\alpha \cdot \mathrm{OPT}$. Nesse caso dizemos que é uma ***α-aproximação***. Uma questão central é para quais valores de α podemos esperar um algoritmo de aproximação de tempo polinomial.

Os algoritmos aproximativos são muito estudados em teoria da computação pois, dentre outros fatos, podem levar a resultados surpreendentes. O problema MAX-CUT[1] é NP-difícil, isto é, não se conhece algoritmo de tempo polinomial que o resolva exatamente. O algoritmo abaixo é uma 1/2-aproximação: como $\mathrm{OPT} \leqslant m$, um corte com pelo menos $m/2$ arestas tem pelo menos OPT/2 arestas, ou seja, sua quantidade de arestas está entre $(1/2)\mathrm{OPT}$ e OPT. Existem aproximações melhores. Em particular, o algoritmo de Goemans e Williamson (1995) é um marco teórico, usa relaxação semidefinida e arredondamento por hiperplano aleatório para garantir uma razão de aproximação de

[1] O problema computacional do corte máximo em grafos é o problema de otimização: dado um grafo G, determine um corte de cardinalidade $\max_s |\nabla(S)|$. A versão de decisão é NP-completa: dados um grafo G e um inteiro positivo k, existe S tal que $|\nabla(S)| \geqslant k$?

pelo menos 87.8% do valor ótimo, mas há um limite: uma $(16/17 + \varepsilon)$-aproximação em tempo polinomial para MAX-CUT, para qualquer $\varepsilon > 0$, implica P = NP (Håstad, 2001).

Corte grande em grafos Dado um grafo $G = (V, E)$, queremos determinar um corte com muitas arestas em G. Recordemos que o corte definido por $S \subseteq V$ em G é o conjunto das arestas com exatamente uma extremidade em S,

$$\nabla(S) = \{\, \{i, j\} \in E : i \in S \text{ e } j \in \overline{S} \,\}.$$

Assumimos, sem perda de generalidade, que $V = \{1, 2, \ldots, n\}$ e escrevemos $m = |E|$.

Consideramos o espaço amostral $\Omega := \{0, 1\}^n$ munido da medida uniforme, de modo que um subconjunto aleatório $S \subseteq V$ é identificado pelo ponto amostral $(x_1, \ldots, x_n) \in \Omega$: para cada vértice $i \in V$, se $x_i = 1$ então $i \in S$, senão $i \in \overline{S}$. O número de arestas no corte é a variável aleatória

$$|\nabla(S)| = \sum_{\{i,j\} \in E} \mathbb{1}_{[\{i,j\} \in \nabla(S)]}.$$

Temos $\{i, j\} \in \nabla(S)$ se, e somente se, $x_i \neq x_j$, o que ocorre com probabilidade $1/2$ e independentemente para cada aresta. Pela linearidade da esperança,

$$\mathbb{E}|\nabla(S)| = \sum_{\{i,j\} \in E} \mathbb{P}\big[\, x_i \neq x_j \,\big] = \frac{m}{2}.$$

Se o valor médio do tamanho de um corte em G é $m/2$, então G deve conter um corte com pelo menos $m/2$ arestas.

Observe que a probabilidade $\mathbb{P}\big[\, x_i \neq x_j \,\big] = 1/2$ depende apenas da distribuição conjunta de ***dois*** bits, um fato que usaremos mais adiante.

Podemos transformar esse resultado num algoritmo aleatorizado que determina um corte grande em G, isto é, um corte com pelo menos metade das arestas.

Algoritmo 7.1: $1/2$**-aproximação para** MAX-CUT

Instância: grafo G sobre os vértices $V = \{1, \ldots, n\}$ e com m arestas.
Resposta: $S \subseteq V$ tal que $\nabla(S)$ tem $\geqslant \frac{m}{2}$ arestas.

```
repita
    para cada i ∈ {1, ..., n} faça x_i ←R {0, 1};
    S ← { i : x_i = 1 };
    calcule |∇(S)|;
até que |∇(S)| ⩾ m/2
responda S.
```

As linhas 2 a 4 têm custo proporcional ao tamanho do grafo, $O(n+m)$. O número total de instruções executadas é uma variável aleatória que depende do número de rodadas do laço. O número de rodadas até que ocorra um sucesso ($|\nabla(S)| \geqslant \frac{m}{2}$) é uma variável aleatória $Z \sim \text{Geom}(p)$, cuja esperança é $\mathbb{E}Z = 1/p$.

Proposição 7.1: probabilidade de sucesso para o corte

Seja G um grafo com $m \geq 1$ arestas e seja p a probabilidade com que um subconjunto aleatório $S \subseteq V$ define um corte com pelo menos $m/2$ arestas. Então

$$p \geqslant \frac{1}{m+2}.$$

Demonstração. Seja $X = |\nabla(S)|$ o número de arestas no corte e seja p_j a probabilidade de que $X = j$. Como visto acima, $\mathbb{E}X = m/2$, ou seja,

$$\frac{m}{2} = \mathbb{E}X = \sum_{j=0}^{m} j\, p_j. \tag{7.2}$$

Seja M o maior natural estritamente menor que $m/2$. Então $X \geqslant m/2$ se, e somente se, $X \geqslant M+1$, e portanto

$$\sum_{j=0}^{M} p_j = 1-p \qquad \text{e} \qquad \sum_{j=M+1}^{m} p_j = p. \tag{7.3}$$

Majorando j por M na primeira soma e por m na segunda,

$$\sum_{j=0}^{m} j\, p_j \leqslant M \sum_{j=0}^{M} p_j + m \sum_{j=M+1}^{m} p_j = M(1-p) + mp. \tag{7.4}$$

De (7.2), (7.3) e (7.4) deduzimos que

$$\frac{m}{2} \leqslant M(1-p) + mp, \qquad \text{isto é,} \qquad p\,(m-M) \geqslant \frac{m}{2} - M,$$

logo

$$p \geqslant \frac{m-2M}{2m-2M}.$$

Pela escolha de M temos $2M < m$ e, como ambos são naturais, $m - 2M \geqslant 1$. Também de $m/2 \leqslant M+1$ deduzimos que $2m - 2M \leqslant m+2$. Portanto $p \geqslant 1/(m+2)$. □

Pela Proposição 7.1, a probabilidade p de que uma rodada tenha sucesso satisfaz

$$p \geqslant \frac{1}{m+2}$$

(a prova usa apenas $\mathbb{E}|\nabla(S)| = m/2$ e $|\nabla(S)| \leqslant m$). Portanto, o número esperado de rodadas do laço é $\mathbb{E}Z \leqslant m+2$ e o custo esperado de uma

execução do algoritmo é $O(m(m+n))$ para um grafo com n vértices e m arestas. (Se $m = 0$, qualquer corte serve e o algoritmo pára na primeira rodada.)

A probabilidade de que o algoritmo realize pelo menos km rodadas até parar é

$$\mathbb{P}[\, Z \geqslant km \,] = (1-p)^{km-1} \leqslant \left(1 - \frac{1}{m+2}\right)^{km-1}$$

para todo k. Para $k = m$ essa cota é menor que 0,00019 para todo grafo com $m \geqslant 10$ arestas e, para $m \geqslant 90$, é menor que 5×10^{-39}.

Desaleatorização usando 2-universalidade

O Algoritmo 7.1 sorteia n bits independentes, um por vértice. Mostramos que bastam $O(\log n)$ bits aleatórios e que, como o espaço amostral resultante é pequeno, podemos percorrê-lo inteiro, o que dá um algoritmo determinístico.

Retomemos o problema: dado $G = (V, E)$ com $V = \{1, \ldots, n\}$ e $m = |E|$ arestas, queremos um corte com pelo menos $m/2$ arestas. Para $S \subseteq V$ definido por $(x_1, \ldots, x_n) \in \{0,1\}^n$, o número esperado de arestas no corte é

$$\mathbb{E}|\nabla(S)| = \sum_{\{i,j\} \in E} \mathbb{P}\big[\, x_i \neq x_j \,\big].$$

Cada parcela depende apenas da distribuição conjunta de *dois* bits. Se x_i e x_j são uniformes e independentes, então

$$\mathbb{P}\big[\, x_i \neq x_j \,\big] = \mathbb{P}\big[\, x_i = 0, x_j = 1 \,\big] + \mathbb{P}\big[\, x_i = 1, x_j = 0 \,\big] = \frac{1}{2}$$

e $\mathbb{E}|\nabla(S)| = m/2$. Não é preciso que os n bits sejam mutuamente independentes: basta independência dois a dois.

Bits dois a dois independentes com poucos bits aleatórios. Seja $d := \lceil \log_2 n \rceil$, de modo que $2^d \geqslant n$ e $2^d < 2n$. Associamos a cada vértice i um vetor $\mathsf{v}_i \in \mathbb{F}_2^d$, a representação binária de $i-1$ com d bits; vértices distintos recebem vetores distintos. Usamos a família 2-universal do Exemplo 7.3 com $\mathbb{F} = \mathbb{F}_2$,

$$h_{(\mathsf{a},b)}(\mathsf{v}) = \langle \mathsf{a}, \mathsf{v} \rangle + b, \qquad (\mathsf{a}, b) \in \mathbb{F}_2^d \times \mathbb{F}_2,$$

e definimos, para (a, b) sorteado uniformemente,

$$x_i := h_{(\mathsf{a},b)}(\mathsf{v}_i), \qquad 1 \leqslant i \leqslant n.$$

Para $i \neq j$ temos $\mathsf{v}_i \neq \mathsf{v}_j$ e, pela definição de família 2-universal, o par (x_i, x_j) tem distribuição uniforme em $\{0,1\}^2$, isto é, x_i e x_j são

uniformes e independentes. Logo, pelo parágrafo anterior, para essa distribuição vale ainda

$$\mathbb{E}|\nabla(S)| = \frac{m}{2},$$

mas agora o sorteio usa apenas $d + 1 = O(\log n)$ bits.

Enumeração. O espaço amostral é $\mathbb{F}_2^d \times \mathbb{F}_2$, com $2^{d+1} < 4n$ pontos equiprováveis. Como a média do tamanho do corte sobre esses pontos é $m/2$, existe um ponto (a, b) para o qual $|\nabla(S)| \geqslant m/2$. O algoritmo determinístico percorre todos os $2^{d+1} < 4n$ pontos, calcula o corte $S_{(\mathsf{a},b)} = \{\, i : x_i = 1 \,\}$ de cada um em tempo $O(n + m)$ e devolve o melhor. O tempo total é $O(n(n + m))$ e a resposta tem pelo menos $m/2$ arestas.

Observação 20. O ganho está na troca de n bits independentes, que levariam à enumeração de 2^n pontos, por $d + 1 = O(\log n)$ bits dois a dois independentes, que levam a $O(n)$ pontos.

Isso só foi possível porque a quantidade que nos interessa, $\mathbb{E}|\nabla(S)|$, depende apenas de probabilidades de pares.

Para análises que usem a independência de três ou mais variáveis (como a cota da maior lista, com Chernoff), essa técnica não se aplica diretamente. Observe também que o Algoritmo 7.1 repete sorteios até obter um corte bom e que a sua análise de tempo esperado usa a probabilidade de sucesso $p \geqslant 1/(m + 2)$, que não é preservada por bits apenas dois a dois independentes. Na versão desta seção não repetimos nada: percorremos todos os pontos, e o argumento da média garante que há um bom. ◊

Existe também um algoritmo determinístico eficiente de 1/2-aproximação para esse problema. Começamos com uma partição arbitrária dos vértices do grafo dado $G = (V, E)$ e movemos um vértice de cada vez de um lado da partição para o outro se isso melhora a solução, até que não haja mais movimentos que melhorem a solução. O número de iterações é no máximo m, porque cada movimento melhora o corte em pelo menos uma aresta e o corte nunca excede m. Para encontrar um vértice que melhora o corte basta contar, para cada vértice, quantos vizinhos estão de cada lado, o que custa $O(n + m)$, de modo que o tempo total é $O(m(n + m))$.

7.0.2 Lema de misturabilidade do hashing 2-universal

Uma função de *hash* escolhida de uma família 2-universal usa poucos bits aleatórios, $\log|\Lambda|$ em vez dos cerca de $|U| \log|N|$ de uma função totalmente aleatória. Ainda assim, ela espalha conjuntos grandes quase como uma função aleatória faria. Esta subseção formaliza essa ideia em três resultados. O primeiro diz que, para quase toda função

da família, um conjunto grande S distribui-se de modo aproximadamente uniforme em cada posição i da tabela. O segundo generaliza isso para um conjunto T de posições. O terceiro, o ***lema de misturabilidade*** (Nisan, 1992), diz que, para quase toda função, a imagem $h(u)$ de um $u \in U$ sorteado ao acaso é quase independente do fato de u pertencer a S. A utilidade é dupla. Em estruturas de dados, garante que, para qualquer conjunto fixo S, escolher h ao acaso na família produz, com alta probabilidade, uma tabela bem equilibrada, sem que seja preciso armazenar uma função aleatória completa. Em desaleatorização e em teoria da complexidade, mostra que uma família pequena pode substituir uma função aleatória sempre que o algoritmo só precise de estimativas de contagem desse tipo, e é uma ferramenta clássica no estudo de extratores de aleatoriedade. A demonstração usa apenas a desigualdade de Chebyshev e a independência par a par que a 2-universalidade fornece.

Uma propriedade de famílias de funções independentes em pares é chamada de misturabilidade[2], do inglês *mixing*. Fixados $S \subseteq U$ e $T \subseteq N$, suponha que escolhemos uma função aleatória $h \in N^U$. Para quaisquer $x \in S$ e $y \in T$ temos $h(x) = y$ com probabilidade $1/|N|$, assim esperamos que $|S||T|/|N|$ pares (x, y) satisfaçam $h(x) = y$, ou seja, que $|S||T|/|N|$ elementos de S tenham imagem em T. Para uma família 2-universal essa propriedade vale, com um pequeno erro, quando a função é escolhida aleatoriamente na família.

[2] O termo vem da teoria de processos estocásticos, onde *mixing* significa que, com o passar do tempo, as dependências entre os estados se dissipam e o processo "esquece" suas condições iniciais. Aqui não há tempo, mas a ideia é análoga: a imagem $h(u)$ comporta-se como quase independente de $u \in S$.

No caso de uma função aleatória $h \in_{\mathrm{R}} N^U$, se X é a quantidade de elementos de $S \subseteq U$ que são mapeados em $i \in N$, então $c = |S|/|N|$ é o valor esperado de X. A desigualdade de Chebyshev nos diz que

$$\mathbb{P}[\,|X - c| < \varepsilon c\,] \geqslant 1 - \frac{1}{\varepsilon^2 c},$$

ou seja, uma fração $\geqslant 1 - 1/(\varepsilon^2 c)$ das $|N|^{|U|}$ funções mapeia os elementos de S de modo que $(1-\varepsilon)c < X < (1+\varepsilon)c$: a quantidade de elementos de S mapeados em i é próxima da média. Esse resultado pode ser transferido para famílias 2-universais, para todo S suficientemente grande: quase toda função da família distribui os elementos de S de modo aproximadamente uniforme no contradomínio.

Lema 7.1: primeiro lema de misturabilidade

Seja $\mathcal{H} \subseteq N^U$ uma família 2-universal de funções de *hash*. Para todo $\varepsilon \in (0,1)$, todo $i \in N$ e todo $S \subseteq U$, se $|S| > \varepsilon^{-3}|N|$, então para pelo menos uma fração $1-\varepsilon$ das funções h em $\mathcal{H}$ vale

$$(1-\varepsilon)\frac{|S|}{|N|} < \big|\{\, u \in S \colon h(u) = i \,\}\big| < (1+\varepsilon)\frac{|S|}{|N|}. \tag{7.5}$$

Demonstração. Vamos provar que, para uma escolha aleatória uni-

forme de função em $\mathcal{H} = \{ h_\lambda : \lambda \in \Lambda \}$, o evento correspondente à equação (7.5) tem probabilidade pelo menos $1 - \varepsilon$.

Fixado $i \in N$, seja X a variável aleatória dada por

$$X(\lambda) := \sum_{u \in S} \mathbb{1}_{[h_\lambda(u)=i]} = \big|\{ u \in S : h_\lambda(u) = i \}\big|,$$

cujo valor esperado, como já vimos, é $c = |S|/|N|$. Pela 2-universalidade, os indicadores $\mathbb{1}_{[h(u)=i]}$, $u \in S$, são independentes dois a dois, de modo que $\mathrm{Var}(X) = \sum_{u \in S} \mathrm{Var}\big(\mathbb{1}_{[h(u)=i]}\big) \leqslant c$ (é aqui que a hipótese do lema é usada). Pela desigualdade de Chebyshev, equação (3.7) da página 75,

$$\mathbb{P}[\, |X - c| \geqslant \varepsilon c \,] \leqslant \frac{\mathrm{Var}(X)}{\varepsilon^2 c^2} \leqslant \frac{c}{\varepsilon^2 c^2} = \frac{1}{\varepsilon^2 c} < \varepsilon,$$

em que a última desigualdade decorre de $c > \varepsilon^{-3}$, que é a hipótese $|S| > \varepsilon^{-3}|N|$. Daí, para uma escolha aleatória uniforme em $\mathcal{H}$ vale, com probabilidade maior que $1 - \varepsilon$, que $|X - c| < \varepsilon c$, isto é, para uma fração maior que $1 - \varepsilon$ das funções $(1 - \varepsilon)c < X < (1 + \varepsilon)c$, que é a afirmação do lema. □

A cota do lema vale para cada i fixo, e a fração $1 - \varepsilon$ de funções boas depende de i. Para que a conclusão valha para todos os $i \in N$ simultaneamente, pela cota da união basta $\varepsilon^{-2} c^{-1} |N| \leqslant \varepsilon$, isto é, $|S| \geqslant \varepsilon^{-3}|N|^2$. Observe também que o parágrafo "Concentração via Chebyshev" acima (pág. 163) prova uma cota semelhante, com desvio *absoluto* εm em vez de relativo εc.

O resultado generaliza-se para um conjunto T de posições, e o lema anterior é o caso $T = \{ i \}$.

Corolário 7.1

Seja $\mathcal{H} \subseteq N^U$ uma família 2-universal. Para todo $\varepsilon \in (0,1)$, todo $\varnothing \neq T \subseteq N$ e todo $S \subseteq U$, se $|S||T| > \varepsilon^{-3}|N|$, então para pelo menos uma fração $1 - \varepsilon$ das funções h em $\mathcal{H}$ vale

$$(1 - \varepsilon)\,|S|\frac{|T|}{|N|} < \big|\{ u \in S : h(u) \in T \}\big| < (1 + \varepsilon)\,|S|\frac{|T|}{|N|}. \qquad (7.6)$$

Demonstração. Seja

$$Y(\lambda) := \sum_{u \in S} \mathbb{1}_{[h_\lambda(u) \in T]} = \big|\{ u \in S : h_\lambda(u) \in T \}\big|. \qquad (7.7)$$

Cada indicador $\mathbb{1}_{[h(u)\in T]}$ é uma função de H_u e, como as variáveis H_u são independentes duas a duas, os indicadores também são. Cada um vale 1 com probabilidade $p = |T|/|N|$. Logo $\mathbb{E}Y = |S|p = c|T|$ e $\mathrm{Var}(Y) = |S|p(1-p) \leqslant c|T|$. Por Chebyshev,

$$\mathbb{P}[\, |Y - c|T|| \geqslant \varepsilon c|T| \,] \leqslant \frac{c|T|}{\varepsilon^2 c^2 |T|^2} = \frac{|N|}{\varepsilon^2 |S||T|} < \varepsilon,$$

pela hipótese $|S||T| > \varepsilon^{-3}|N|$. Daí segue (7.6) como na demonstração do lema anterior. □

Agora consideremos o subconjunto das funções $h_\lambda \in \mathcal{H}$ que são *boas* para (S,T), no sentido de que

$$\left| \frac{Y(\lambda)}{|U|} - \frac{|S|}{|U|}\frac{|T|}{|N|} \right| \leqslant \varepsilon, \tag{7.8}$$

em que Y é a variável aleatória definida em (7.7). Como $Y(\lambda)/|U|$ é a probabilidade de que um $u \in U$ sorteado uniformemente satisfaça $u \in S$ e $h_\lambda(u) \in T$, a equação (7.8) equivale a

$$\left| \mathop{\mathbb{P}}_{u\in U}([u \in S] \cap [h(u) \in T]) - \mathop{\mathbb{P}}_{U}(S)\,\mathop{\mathbb{P}}_{N}(T) \right| \leqslant \varepsilon. \tag{7.9}$$

Ou seja, a probabilidade de que um u escolhido uniformemente esteja em S e tenha imagem em T é aproximadamente o produto das probabilidades de escolher, uniforme e independentemente, um elemento de U em S e um elemento de N em T. Nesse caso, dizemos que a função de *hash* $h\colon U \to N$ é ***ε-independente*** para (S,T). Note que aqui o erro ε é *aditivo*, em probabilidades, enquanto no lema anterior era relativo à média.

Lema 7.2: Hash mixing lemma

Seja $\mathcal{H} \subseteq N^U$ uma família 2-universal. Então, para quaisquer $\varepsilon > 0$, $S \subseteq U$ e $T \subseteq N$,

$$\mathop{\mathbb{P}}_{h\in\mathcal{H}}[\, h \text{ não é } \varepsilon\text{-independente para } (S,T)\,] \leqslant \frac{1}{\varepsilon^2|U|}\cdot\frac{|S|}{|U|}\cdot\frac{|T|}{|N|}.$$

Demonstração. Seja Y como em (7.7). Como no corolário, Y é a soma de $|S|$ indicadores independentes dois a dois, cada um com probabilidade $p = |T|/|N|$, de modo que $\mathbb{E}Y = |S||T|/|N|$ e $\mathrm{Var}(Y) = |S|p(1-p) \leqslant \mathbb{E}Y$. A função h não é ε-independente para (S,T) se, e somente se, $|Y - \mathbb{E}Y| > \varepsilon|U|$, e esse evento está contido em $[\,|Y - \mathbb{E}Y| \geqslant \varepsilon|U|\,]$. Por Chebyshev,

$$\mathbb{P}[\,|Y - \mathbb{E}Y| \geqslant \varepsilon|U|\,] \leqslant \frac{\mathrm{Var}(Y)}{\varepsilon^2|U|^2} \leqslant \frac{|S||T|/|N|}{\varepsilon^2|U|^2} = \frac{1}{\varepsilon^2|U|}\cdot\frac{|S|}{|U|}\cdot\frac{|T|}{|N|}. \quad \square$$

Observe que a cota do lema só diz algo quando S é *denso* em U. De fato, $0 \leqslant Y(\lambda)/|U| \leqslant |S|/|U|$ e também $0 \leqslant \frac{|S|}{|U|}\frac{|T|}{|N|} \leqslant |S|/|U|$, de modo que a diferença em (7.8) é, em valor absoluto, no máximo $|S|/|U|$. Logo, se $|S| \leqslant \varepsilon|U|$, *toda* função h é ε-independente para (S,T), e a afirmação do lema é trivial. O caso interessante é $|S| > \varepsilon|U|$. Nele, como $\frac{|S|}{|U|}\frac{|T|}{|N|} \leqslant 1$, a cota do lema é no máximo $1/(\varepsilon^2|U|)$, que é pequena quando $|U| \gg \varepsilon^{-2}$: quase toda função da família é ε-independente

para (S, T), qualquer que seja $T \subseteq N$ fixado. Para conjuntos S *esparsos*, que são o caso comum em tabelas de espalhamento, o erro aditivo ε é grande demais para ser informativo, e é o Corolário (com erro relativo à média) que deve ser usado.

7.1 *Impressões digitais e verificação de igualdade*

Nesta seção ilustramos como a aleatorização pode nos ajudar a resolver problemas computacionais de modo mais eficiente que as soluções determinísticas. Eficiência aqui é com respeito à troca de informação entre partes, isto é, estamos falando de ***complexidade de comunicação***. Nesta seção, m é o número de *bits* dos arquivos e não deve ser confundido com $m = |S|$ das seções anteriores.

"Impressões digitais" aparece na bibliografia, em inglês, como *Fingerprint*.

Protocolos Alice e Bob desejam computar colaborativamente uma função $f(x, y)$ conhecida por ambos, onde $f : \{0,1\}^m \times \{0,1\}^m \to \{0,1\}$. Alice só conhece x, Bob só conhece y, a comunicação é cara e eles já tinham acordado um *protocolo*. Em um protocolo cada mensagem enviada pode depender de todas as mensagens anteriores e da entrada local: Alice envia uma mensagem ma_1 para Bob; Bob, de posse dessa mensagem e de y, responde com uma mensagem ba_1; continuam dessa forma até que um deles seja capaz de calcular o valor de $f(x, y)$ e comunicá-lo para a outra parte. O ***custo*** do protocolo é o total de bits $|ma_1| + |ba_1| + \cdots + |ma_t| + |ba_t|$ trocados no pior caso, isto é, com a entrada (x, y) que maximiza esse total.

A ***complexidade de comunicação*** (determinística) de f é o custo mínimo dentre todos os protocolos determinísticos que calculam f. Por exemplo, a função igualdade, $\text{EQ}(x, y) = 1$ se, e somente se, $x = y$, tem complexidade pelo menos m (Arora e Barak, 2009, teo. 13.4).

Um protocolo *aleatorizado* também pode usar sorteios. Aqui a aleatoriedade é *privada*: um sorteio de Alice só é conhecido por Bob se for comunicado, e isso entra no custo. O custo é o número máximo de bits trocados, e o ***erro*** é a maior, sobre todas as entradas, probabilidade de resposta errada, tomada sobre os sorteios. É por isso que, para funções de *hash*, a *descrição curta* importa.

O problema Alice e Bob têm, cada um, uma cópia de um enorme banco de dados, x e y em $\{0,1\}^m$, e querem saber se as cópias são iguais. Uma saída trivial é: Alice envia os m bits para Bob, então Bob verifica se os dois vetores são iguais e envia o resultado (sim ou não) para Alice. Toda a comunicação usa 2 mensagens e $m + 1$ bits, o que é essencialmente o melhor que um protocolo *determinístico* pode fazer. Com aleatoriedade, basta enviar uma pequena ***impressão digital***: um valor curto $h(x)$ que, com alta probabilidade, difere de $h(y)$ quando

$x \neq y$.

Escrevemos $x = (a_{m-1} \ldots a_1 a_0)_2$ e $y = (b_{m-1} \ldots b_1 b_0)_2$, e identificamos x com o inteiro $\sum_i a_i 2^i$. Seja $P_x(z) := \sum_{i=0}^{m-1} a_i z^i$ o polinômio cujos coeficientes são os bits de x, de modo que $x = P_x(2)$.

7.1.1 *Famílias quase universais e o protocolo geral*

Definição 7.2: família ε-quase universal

Sejam $\varepsilon > 0$ e N um conjunto finito. Uma família

$$\mathcal{H} = \left\{ h_\lambda \in N^{\{0,1\}^m} : \lambda \in \Lambda \right\}$$

de funções é ***ε-quase universal*** se, para $\lambda \in_R \Lambda$ e quaisquer $x \neq y$,

$$\mathop{\mathbb{P}}_{\lambda \in_R \Lambda} [\, h_\lambda(x) = h_\lambda(y) \,] \leqslant \varepsilon.$$

Uma família universal, no sentido de (6.10), é ε-quase universal com $\varepsilon = 1/|N|$. Aqui admitimos ε maior, em troca de uma descrição mais curta de λ.

Lema 7.3: protocolo de impressão digital

Seja $\mathcal{H}$ uma família ε-quase universal em que λ é descrito por d bits e cada valor $h_\lambda(x)$ por b bits. No protocolo

Alice sorteia $\lambda \in_R \Lambda$ e envia λ e $h_\lambda(x)$;

Bob responde 1 ("iguais") se $h_\lambda(y) = h_\lambda(x)$ e 0 caso contrário,

são trocados $d + b + 1$ bits e vale:

1. se $x = y$, Bob responde "iguais" com probabilidade 1;
2. se $x \neq y$, Bob responde "iguais" (erro) com probabilidade no máximo ε.

Repetindo o protocolo t vezes com sorteios independentes (Alice envia os t pares e Bob responde "iguais" se, e somente se, todos coincidem), o custo é $t(d + b) + 1$ e o erro é no máximo ε^t.

Demonstração. Se $x = y$ então $h_\lambda(x) = h_\lambda(y)$ para todo λ. Se $x \neq y$, Bob erra se, e somente se, $h_\lambda(x) = h_\lambda(y)$, o que ocorre com probabilidade $\leqslant \varepsilon$. Na versão com t repetições, Bob só erra se ocorrer colisão em todas, e os sorteios são independentes, o que dá ε^t. □

O erro é unilateral: uma resposta "diferentes" está sempre certa, e só a resposta "iguais" pode errar.

7.1.2 *Impressão digital por resto módulo um primo aleatório*

Seja $k \geqslant 2$ um inteiro. A família

$$\mathcal{H}_{m,k} \coloneqq \{\, h_p : p \text{ primo},\ p \leqslant m^k \,\}, \qquad h_p(x) \coloneqq x \bmod p,$$

corresponde ao seguinte protocolo. Alice sorteia um primo $p \leqslant m^k$ uniformemente (localmente, sem comunicação: sorteia inteiros até encontrar um primo, o que dá uma escolha uniforme entre os primos), e envia p e $x \bmod p$, cada um em um bloco de $\lfloor \log(m^k) \rfloor + 1$ bits, para que Bob possa separá-los. Bob calcula $y \bmod p$, compara com o resto recebido e responde 1 ou 0. Como $x = P_x(2)$, a impressão é o valor do polinômio P_x no ponto fixo $z = 2$, módulo um primo aleatório; na subseção seguinte fixaremos o primo e sortearemos o ponto.

Para $k = 2$, o custo é

$$2(\lfloor \log(m^2) \rfloor + 1) + 1 \leqslant 2\log(m^2) + 2 + 1 < 4(\log m + 1) = 4\log(2m).$$

O protocolo erra se $x \neq y$, porém $x \equiv y \pmod{p}$. Por exemplo, com $m = 7$ (portanto, primos $\leqslant m^2 = 49$), $1000000_2 = 64$ e $1001011_2 = 75$ e $64 \bmod 11 = 9 = 75 \bmod 11$. Dentre os primos menores ou iguais a 49, o 11 é o único que causa erro, pois $K = |75 - 64| = 11$ é primo; a probabilidade de erro é $1/15$.

2, 3, 5, 7, 11, 13, 17, 19, 23, 29, 31, 37, 41, 43 e 47 são todos os primos menores ou iguais a 49

Proposição 7.2: erro do resto módulo primo

Para $m \geqslant 6$ e $k \geqslant 2$, a família $\mathcal{H}_{m,k}$ é ε-quase universal com

$$\varepsilon \leqslant \frac{10}{9} \cdot \frac{k \ln m}{m^{k-1}}.$$

Em particular, para $k=2$, $\varepsilon \leqslant \frac{20}{9}\frac{\ln m}{m}$.

Demonstração. Sejam $x \neq y$ e $K \coloneqq |\, x - y \,|$, de modo que $1 \leqslant K < 2^m$. O primo p causa colisão se, e somente se, p divide K. Se $K = p_1^{e_1} \cdots p_r^{e_r}$ com $p_1, \ldots, p_r$ primos distintos, então $K \geqslant 2^r$, logo $r \leqslant \log K < m$: no máximo $m - 1$ primos causam erro. Como $m^k \geqslant 36$, a estimativa de Chebyshev[3] dá $\pi(m^k) > 0{,}9\, m^k / \ln(m^k)$, e então

$$\varepsilon \leqslant \frac{m-1}{\pi(m^k)} < \frac{m\, k \ln m}{0{,}9\, m^k} = \frac{10}{9} \cdot \frac{k \ln m}{m^{k-1}}. \qquad \square$$

[3] Seja $\pi(x)$ a quantidade de primos menores ou iguais a x. O teorema dos números primos afirma que $\pi(x)\ln(x)/x \to 1$ quando $x \to \infty$. Antes dele, foi provado por Chebyshev (1852, seção V) que

$$\pi(x) > 0{,}9\, \frac{x}{\ln x} \qquad (7.10)$$

para todo $x \geqslant 30$.

7.1.3 *Impressão digital por avaliação de polinômio*

O primeiro protocolo precisa sortear um primo, e sua análise usa a estimativa de Chebyshev para $\pi(x)$. Podemos inverter os papéis: fixar o primo e sortear o ***ponto*** de avaliação.

Dado um limiar $\delta \in (0, 1)$ para a probabilidade de erro, Alice e Bob combinam previamente um primo p com $m/\delta < p \leqslant 2m/\delta$ (que

existe pelo postulado de Bertrand); como depende só de m e δ, p não é comunicado. Para $r \in \mathbb{F}_p$ definimos

$$h_r(x) \coloneqq P_x(r) \bmod p,$$

e a família $\mathcal{H}_p \coloneqq \{\, h_r : r \in \mathbb{F}_p \,\}$, com $r \in_{\mathrm{R}} \mathbb{F}_p$. Cada r e cada valor $h_r(x)$ cabem em $\lceil \log p \rceil$ bits.

Proposição 7.3: erro da avaliação de polinômio

Para $x \neq y$ em $\{0,1\}^m$ e p primo,

$$\mathbb{P}_{r \in_{\mathrm{R}} \mathbb{F}_p} [\, h_r(x) = h_r(y) \,] \leqslant \frac{m-1}{p}.$$

Logo $\mathcal{H}_p$ é ε-quase universal com $\varepsilon = (m-1)/p$.

Demonstração. O polinômio $Q \coloneqq P_x - P_y \in \mathbb{F}_p[z]$ tem grau no máximo $m-1$. Ele é não nulo: como $x \neq y$, existe i com $a_i - b_i = \pm 1$, e $\pm 1 \not\equiv 0 \pmod p$. Um polinômio não nulo de grau $\leqslant m-1$ sobre um corpo tem no máximo $m-1$ raízes: se a é raiz, $Q(z) = (z-a)Q_1(z)$ com Q_1 não nulo de grau menor, e as demais raízes de Q são raízes de Q_1 porque $\mathbb{F}_p$ não tem divisores de zero. Agora, $h_r(x) = h_r(y)$ se, e somente se, $Q(r) = 0$, isto é, se r é uma das no máximo $m-1$ raízes de Q, entre os p valores equiprováveis de r. Logo a probabilidade é no máximo $(m-1)/p$. □

Pelo Lema 7.3, com $d = b = \lceil \log p \rceil$, o protocolo tem custo $2\lceil \log p \rceil + 1$ e, se $x \neq y$, erro no máximo $(m-1)/p < m/p < \delta$. Como $p \leqslant 2m/\delta$, o custo é $O(\log m + \log(1/\delta))$.

7.1.4 *Comparação e um exemplo numérico*

Os dois protocolos têm custo $O(\log m + \log(1/\delta))$ para erro δ. No primeiro, para diminuir o erro podemos repetir, ou ampliar a faixa dos primos: com $p \leqslant m^k$ o erro cai para $O(k \ln m / m^{k-1})$ e o custo é $2\lceil k \log m \rceil + O(1)$. No segundo, basta tomar δ menor. A vantagem do segundo é a simplicidade: o primo é fixo, não é preciso sortear primos nem testar primalidade, a análise usa só o fato de que um polinômio não nulo tem poucas raízes (e não a estimativa de $\pi(x)$) e o erro é um parâmetro direto.

Digamos que Alice está em algum lugar da Europa, Bob no Brasil e a base de dados deles tem 1,25 petabytes (PB), ou $m = 10^{16}$ bits (no sistema decimal). O tempo necessário para transmitir 1,25 PB da Europa para o Brasil com largura de banda de 10 Gbps (10^{10} bits por segundo) é 10^6 segundos, ou quase 12 dias. A tabela compara os protocolos.

protocolo	bits	erro
determinístico	$10^{16}+1$	0
resto, $p \leqslant m^2$	215	$< 0{,}9\times 10^{-14}$
resto, $p \leqslant m^2$, 5 repetições	1071	$< 6\times 10^{-71}$
resto, $p \leqslant m^6$	639	$< 3\times 10^{-78}$
polinômio, $\delta = 10^{-14}$	203	$< 10^{-14}$
polinômio, $\delta = 10^{-71}$	583	$< 10^{-71}$

Os valores vêm do Lema 7.3 e das Proposições 7.2 e 7.3. Por exemplo, para $k = 2$, $2(\lfloor \log(10^{32}) \rfloor + 1) + 1 = 215$ e o erro é $\leqslant \frac{20}{9}\frac{\ln 10^{16}}{10^{16}} = \frac{320 \ln 10}{9\cdot 10^{16}} < 0{,}9\times 10^{-14}$. Para o polinômio com $\delta = 10^{-14}$, $10^{30} < p \leqslant 2\cdot 10^{30} < 2^{101}$ e o custo é $2\cdot 101 + 1 = 203$; com $\delta = 10^{-71}$, $10^{87} < p \leqslant 2\cdot 10^{87} < 2^{291}$ e o custo é $2\cdot 291 + 1 = 583$. Com 5 repetições, cada uma com sorteio independente, o erro é $< (0{,}9\times 10^{-14})^5 < 6\times 10^{-71}$ e o custo é $5\cdot 214 + 1 = 1071$.

Cabe destacarmos que canais de transmissão estão sujeitos a erros. As especificações dos equipamentos trazem uma taxa de erro de bits, da ordem de 10^{-12} nas especificações usuais, o que significa que, para cada 10^{12} bits transmitidos, espera-se que 1 seja corrompido. O protocolo determinístico, ao transmitir 10^{16} bits, espera cerca de $10^{16}\cdot 10^{-12} = 10^4$ bits corrompidos, e por isso, na prática, usa códigos de correção de erros e *checksums*, o que o torna ainda mais custoso. Já os 215 bits do protocolo aleatorizado têm probabilidade de cerca de $215\cdot 10^{-12} \approx 2\times 10^{-10}$ de sofrer alguma corrupção, que é muito maior que o erro 10^{-14} do próprio protocolo: o erro do canal domina o erro algorítmico.

Observação 21. As famílias $\mathcal{H}_{m,k}$ e $\mathcal{H}_p$ ***não*** são universais no sentido de (6.10): as probabilidades de colisão são limitadas por $\varepsilon \approx k \ln m / m^{k-1}$ e por $(m-1)/p$, respectivamente, e não por $1/|N|$, que seria aproximadamente $1/m^k$ e $1/p$. O fator extra (de ordem $m \ln m$ no primeiro caso e $m-1$ no segundo) é o preço da descrição curta, de $O(\log m)$ bits em vez dos $\Theta(m)$ bits da família universal canônica do Exemplo 6.2 para $U = \{0,1\}^m$. O algoritmo de Karp–Rabin para busca de padrões em texto usa impressões digitais desse tipo: a impressão digital do padrão é comparada com a de cada janela do texto, e a análise dos falsos positivos é semelhante à da Proposição 7.2. A Proposição 7.3 é, por sua vez, o caso mais simples do teste de identidade de polinômios, em que se avalia um polinômio em um ponto aleatório. Se Alice e Bob compartilhassem bits aleatórios, o sorteio não precisaria ser comunicado; aqui supomos aleatoriedade privada. ◊

7.2 Exercícios

Exercício 54. Sejam $n \geqslant k > 0$ inteiros. Identifique $\{0,1\}$ com o corpo $\mathbb{F}_2$, tome $\mathsf{A} \in {\mathbb{F}_2}^{k\times n}$ e $\mathsf{b} \in {\mathbb{F}_2}^{k}$. Prove que a família de funções $h_{\mathsf{A},\mathsf{b}} \colon {\mathbb{F}_2}^{n} \to {\mathbb{F}_2}^{k}$ dadas por $h_{\mathsf{A},\mathsf{b}}(\mathsf{x}) = \mathsf{A}\mathsf{x} + \mathsf{b}$, com (A,b) sorteado uniformemente, é 2-universal. (Dica: argumente linha a linha como no Exemplo 7.3; as k linhas de (A,b) são independentes.)

Exercício 55. Considere a família $\mathcal{H}$ de funções de *hashing* do Exemplo 7.3 e fixe $S \subset \mathbb{F}^n$. Prove que se $|S| \leqslant \sqrt{|\mathbb{F}|}$ então para uma escolha aleatória de $h \in \mathcal{H}$ a probabilidade de não ocorrer colisão para os elementos de S é pelo menos $1/2$.

Exercício 56. Suponha que $\mathcal{H}$ seja uma família 2-universal de funções $\{0,1\}^n \to \{0,1\}^n$. Para $m < n$ podemos definir uma família $\mathcal{H}'$ de funções $\{0,1\}^n \to \{0,1\}^m$ fazendo para cada $h \in \mathcal{H}$

$$h'(x) \coloneqq h(x) \restriction_m$$

em que $h(x) \restriction_m$ denota a restrição de $h(x)$ aos primeiros m bits. $\mathcal{H}'$ é uma família 2-universal?

Exercício 57. A família de funções $h \colon \{0,1\}^n \to \{0,1\}^m$ indexada pelas matriz binárias $\mathsf{M} \in \{0,1\}^{(n+1)\times m}$ definida para todo $\mathsf{x} \in \{0,1\}^n$ por

$$h_M(\mathsf{x}) \coloneqq (\mathsf{x},1) \cdot \mathsf{M}$$

Mostre que essa família é 2-universal.

Exercício 58. Uma família $\mathcal{H} \subset M^U$ de funções de *hash* é ε-universal para $S \subset U$ se $\mathbb{P}[\, h(u) = h(s) \,] \leqslant \varepsilon$ para todos $u \neq s \in S$. Prove que nesse caso deve valer $\varepsilon \geqslant \frac{1}{|M|} - \frac{1}{|U|}$.

Exercício 59. Uma família de funções $\mathcal{H} = \{\, h_\lambda \in N^U : \lambda \in \Lambda \,\}$ tais que para quaisquer $x \neq y$

$$\mathop{\mathbb{P}}_{\lambda\in\Lambda}[\, h_\lambda(x) = h_\lambda(y) \,] \leqslant \frac{1}{|N|}.$$

é chamada de *hash fracamente* 2-*universal*. Verifique que a família de funções de Carter e Wegman (1979), dada no Exemplo 6.2, página 146 não é 2-universal, mas é fracamente 2-universal.

Exercício 60. Vamos repetir para MAX-E3SAT a desaleatorização do corte grande.

Uma instância de MAX-E3SAT consiste em uma fórmula booleana $\varphi = \bigwedge_{j=1}^{m} C_j$, em que cada cláusula tem a forma

$$C_j = \ell_{j,1} \vee \ell_{j,2} \vee \ell_{j,3},$$

e cada literal $\ell_{j,k}$ é uma variável booleana v_i ou sua negação $\neg v_i$. O objetivo é encontrar uma atribuição $a \in \{0,1\}^n$ que maximize o número de cláusulas satisfeitas.

Seja $C = \{C_1, \ldots, C_m\}$ uma instância de MAX-E3SAT sobre as variáveis $V = \{v_1, \ldots, v_n\}$, em que cada cláusula tem exatamente três literais, sobre variáveis distintas. Seja $d = \lceil \log_2 n \rceil$ e identifique as variáveis com elementos distintos de $\mathbb{F}_{2^d}$ (ou de $\mathbb{F}_2^d$)

$$V \ni v_i \leftrightarrow x_i \in \mathbb{F}_{2^d}.$$

Para uma distribuição sobre valorações $(x_1, \ldots, x_n)$, seja X o número de cláusulas satisfeitas.

1. *Usando independência de par a par.* Suponha que $x_1, \ldots, x_n$ são uniformes e independentes *dois a dois*. Seja $C = \ell_1 \vee \ell_2 \vee \ell_3$ uma cláusula e A_k o evento "o literal ℓ_k vale 1".
   (a) Mostre que $\mathbb{P}(A_k) = 1/2$ e $\mathbb{P}(A_j \cap A_k) = 1/4$ para $j \neq k$.
   (b) Prove, por inclusão e exclusão, que $\mathbb{P}(A_1 \cup A_2 \cup A_3) \geqslant \sum_k \mathbb{P}(A_k) - \sum_{j<k} \mathbb{P}(A_j \cap A_k)$ e conclua que $\mathbb{P}[\, C \text{ é satisfeita} \,] \geqslant 3/4$.
   (c) Conclua que $\mathbb{E}X \geqslant 3m/4$.
2. *A cota $3/4$ é justa para pares.* Considere a cláusula $v_1 \vee v_2 \vee v_3$ e bits x_1, x_2 uniformes e independentes com $x_3 \coloneqq x_1 \oplus x_2$. Mostre que x_1, x_2, x_3 são uniformes e independentes dois a dois e que a cláusula é satisfeita com probabilidade exatamente $3/4$.
3. *Desaleatorização com pares.* Use a família do Exemplo 7.3 com $\mathbb{F} = \mathbb{F}_2$ para obter um algoritmo determinístico que devolve uma valoração satisfazendo pelo menos $3m/4$ cláusulas. Quantas valorações ele examina e qual o seu tempo?

Exercício 61. Nesse exercício vamos estender a análise do MAX-E3SAT.

1. Imite a demonstração da Proposição 7.1 e demonstre: *Seja φ uma instância de MAX-E3SAT e p a probabilidade com que uma valoração satisfaz pelo menos $7/8$ de todas as cláusulas. Então*
$$p \geqslant \frac{1}{m+8}.$$
2. Escreva um algoritmo Las Vegas que determina tal valoração e determine o seu tempo médio de execução.
3. *Independência de três a três.* Seja $\mathbb{F} = \mathbb{F}_{2^d}$ e, para $(\alpha_0, \alpha_1, \alpha_2) \in \mathbb{F}^3$,
$$g_\alpha(y) \coloneqq \alpha_0 + \alpha_1 y + \alpha_2 y^2.$$

(a) Mostre que, para $y_1, y_2, y_3 \in \mathbb{F}$ distintos e quaisquer $z_1, z_2, z_3 \in \mathbb{F}$, existe exatamente um $\alpha \in \mathbb{F}^3$ com $g_\alpha(y_k) = z_k$ para $k = 1, 2, 3$. (Dica: matriz de Vandermonde.) Conclua que, para α uniforme, $g_\alpha(y_1), g_\alpha(y_2), g_\alpha(y_3)$ são uniformes e independentes em $\mathbb{F}$.

(b) Seja $\lambda\colon \mathbb{F} \to \mathbb{F}_2$ uma função linear sobrejetora (por exemplo, a primeira coordenada de $\mathbb{F} \cong \mathbb{F}_2^d$). Mostre que cada valor de $\mathbb{F}_2$ tem exatamente $q/2$ preimagens e conclua que os bits $x_i \coloneqq \lambda(g_\alpha(y_i))$, onde y_i é o elemento de $\mathbb{F}$ associado à variável v_i, são uniformes e *independentes três a três*.

(c) Mostre que, para essa distribuição, cada cláusula é satisfeita com probabilidade exatamente $7/8$ e que $\mathbb{E}X = 7m/8$.

4. *O algoritmo.* Descreva um algoritmo determinístico que enumera todos os $\alpha \in \mathbb{F}^3$, avalia a valoração correspondente e devolve a melhor, e prove que ele satisfaz pelo menos $7m/8$ cláusulas. Mostre que o número de valorações examinadas é $q^3 < 8n^3$ e que o tempo total é $O(n^3(n+m))$, supondo operações em $\mathbb{F}$ de custo constante. Compare com a enumeração de todas as 2^n valorações e com a versão do item 3.

5. *Versão aleatorizada com poucos bits.* Mostre que a prova da proposição que dá $p \geqslant 1/(m+8)$ usa apenas $\mathbb{E}X = 7m/8$ e $X \leqslant m$. Conclua que o algoritmo com o sorteio de α em $\mathbb{F}^3$ (isto é, $3d = O(\log n)$ bits por rodada), tem a mesma garantia $\mathbb{E}Z \leqslant m + 8$ para o número de rodadas que o algoritmo desenvolvido no item 2.

8
Teste de Identidade de Polinômios

8.1 Emparelhamentos Perfeitos em Grafos Bipartidos

Seja $G = (U, V, E)$ um grafo bipartido com $|U| = |V| = n$. Um ***emparelhamento perfeito*** em G é um conjunto de arestas

$$(u_1, v_{\pi(1)}), (u_2, v_{\pi(2)}), \ldots, (u_n, v_{\pi(n)}),$$

onde $\pi \in S_n$ é uma permutação.

Para $u \in U$, denote por $N(u) \subseteq V$ o conjunto dos vizinhos de u em G. Para $U' \subseteq U$, seja $N(U') = \bigcup_{u \in U'} N(u)$ o conjunto dos vértices de V que são vizinhos de algum vértice de U'.

Teorema 8.1: Teorema de Hall

G possui um emparelhamento perfeito se e somente se, para todo subconjunto $U' \subseteq U$, vale que $|N(U')| \geqslant |U'|$.

Corolário 8.1

Sejam $S_1, \ldots, S_n \subseteq [n]$ conjuntos. Podemos escolher $x_i \in S_i$ tais que $\{ x_1, \ldots, x_n \} = [n]$ se e somente se, para todo $I \subseteq [n]$,

$$|\{ i : S_i \cap I \neq \varnothing \}| \geqslant |I|.$$

Demonstração. Construa o grafo bipartido com $U = V = [n]$ e $(i, j) \in E$ se $i \in S_j$, e aplique o Teorema de Hall. □

Prova do Teorema de Hall. A condição é necessária. Se G possui um emparelhamento perfeito $\{ (u_i, v_{\pi(i)}) : i \in [n] \}$ para alguma permutação π, então, para $U' = \{ u_{i_1}, \ldots, u_{i_k} \}$, temos $v_{\pi(i_1)}, \ldots, v_{\pi(i_k)} \in N(U')$ e, portanto, $|N(U')| \geqslant k = |U'|$.

A condição é suficiente. Suponha que G não possui emparelhamento perfeito; mostraremos que existe $U' \subseteq U$ com $|N(U')| < |U'|$. Sem perda de generalidade (após possivelmente renomear os vértices), assuma que $M = \{ (u_1, v_1), \ldots, (u_m, v_m) \}$ é um emparelhamento parcial

de tamanho máximo em G; note que $m < n$. Seja $u \in U \setminus \{u_1, \ldots, u_m\}$. Se conseguíssemos construir um emparelhamento parcial cobrindo $\{u_1, \ldots, u_m, u\}$, contradiríamos a maximalidade de M.

Se $(u, v) \in E$ para algum $v \notin \{v_1, \ldots, v_m\}$, então claramente M não é máximo, pois podemos adicionar a aresta (u, v) a ele. Mais geralmente, dizemos que um caminho P em G é um ***caminho aumentante*** para M se ele tem a forma

$$P = u, v_{i_1}, u_{i_1}, v_{i_2}, u_{i_2}, \ldots, v_{i_k}, u_{i_k}, v$$

com $v \notin \{v_1, \ldots, v_m\}$. Note que as arestas de posição par em P estão no emparelhamento M, e as de posição ímpar não estão. Tal caminho também nos permitiria aumentar o tamanho do emparelhamento em uma unidade, tomando

$$M' = \{(u, v_{i_1}), (u_{i_1}, v_{i_2}), \ldots, (u_{i_k}, v)\} \cup \{(u_j, v_j) \colon j \notin \{i_1, \ldots, i_k\}\}.$$

Assim, pela hipótese de que M é um emparelhamento parcial de tamanho máximo, não existem caminhos aumentantes em G que começam em u.

Dizemos que um caminho P em G é um ***caminho alternado*** se uma aresta sim, outra não, pertence ao emparelhamento M (as arestas de posição par, como acima). Seja P um caminho alternado de comprimento máximo em G começando em u. Ele tem comprimento pelo menos 1, pois u tem pelo menos um vizinho. Assim, ele tem a forma

$$P = u, v_{i_1}, u_{i_1}, v_{i_2}, u_{i_2}, \ldots$$

Este caminho não pode terminar em um vértice $v_i \in V$, pois ele sempre pode ser estendido até $u_i \in U$ (se v_i não fosse emparelhado, P seria aumentante). Logo, ele termina em algum vértice $u_{i_k} \in \{u_1, \ldots, u_m\}$:

$$P = u, v_{i_1}, u_{i_1}, v_{i_2}, u_{i_2}, \ldots, v_{i_k}, u_{i_k}.$$

Sejam $U' = \{u, u_{i_1}, \ldots, u_{i_k}\}$ e $V' = \{v_{i_1}, \ldots, v_{i_k}\}$. Afirmamos que $V' = N(U')$, o que violaria a condição de Hall, já que $|U'| = k + 1$ e $|V'| = k$. Para ver isso, seja $v \in N(U')$. Se $v \in \{v_1, \ldots, v_m\}$, digamos $v = v_i$, então, pela maximalidade de P (caso contrário poderíamos estendê-lo por v_i e u_i), temos $u_i \in U'$ e, portanto, $v_i \in V'$. Caso contrário, se $v \notin \{v_1, \ldots, v_m\}$, então v pode ser usado para construir um caminho aumentante. De fato, se $(u_{i_\ell}, v) \in E$ para algum $1 \leqslant \ell \leqslant k$, então

$$P' = u, v_{i_1}, u_{i_1}, v_{i_2}, u_{i_2}, \ldots, v_{i_\ell}, u_{i_\ell}, v$$

é um caminho aumentante, uma contradição (o caso $(u, v) \in E$ foi tratado acima). □

Portanto, temos um critério matemático para verificar se um grafo bipartido possui um emparelhamento perfeito. Além disso, pode-se verificar que a prova do Teorema de Hall é, de fato, algorítmica: ela pode ser usada para encontrar emparelhamentos parciais cada vez maiores em um grafo. Isso é muito melhor do que verificar as condições do teorema, o que, ingenuamente, exigiria tempo 2^n para enumerar todos os subconjuntos de U. Veremos agora uma maneira totalmente diferente de verificar se um grafo possui um emparelhamento perfeito, usando teste de identidade de polinômios.

8.2 *Representação de Polinômios*

Consideraremos polinômios multivariados em $x_1, \ldots, x_n$ de grau d. Como podemos representá-los? Uma maneira é explicitamente, por sua lista de coeficientes:

$$f(x_1, \ldots, x_n) = \sum_{\substack{e_1,\ldots,e_n \geqslant 0 \\ \sum_i e_i \leqslant d}} f_{e_1,\ldots,e_n} \, x_1^{e_1} \cdots x_n^{e_n}.$$

Para graus grandes, essa representação pode ser enorme: o número de monômios em n variáveis de grau $\leqslant d$ é $\binom{n+d}{n}$, que é exponencialmente grande se tanto n quanto d forem grandes. Isso significa que avaliar o polinômio em uma única entrada levaria tempo exponencial.

Outra maneira é por meio de uma computação. Considere, por exemplo, $f(x) = (x+1)^{2^n}$. Ele possui $2^n + 1$ coeficientes, de modo que avaliá-lo somando sobre todos os coeficientes exigiria tempo exponencial. No entanto, podemos computá-lo em tempo $O(n)$ avaliando primeiro $x + 1$ e, em seguida, elevando o resultado ao quadrado, iterativamente, n vezes.

A maneira de generalizar essa ideia é por meio da noção de circuito algébrico.

Definição 8.1: Circuito algébrico

Um ***circuito algébrico*** é um grafo direcionado acíclico. Assumiremos que ele possui várias folhas (nós sem arestas de entrada) e uma única raiz (nó sem arestas de saída). Cada nó computa um polinômio nas variáveis de entrada. As folhas correspondem a variáveis ou constantes. Os nós internos (também chamados de ***portas***) computam uma soma ou um produto de seus filhos. O circuito computa o polinômio que é calculado na raiz.

Exemplo 8.1: Circuito para $(x+1)^{2^n}$

Podemos computar $(x+1)^{2^n}$ usando um circuito algébrico de tamanho $O(n)$ (ou seja, $O(\log N)$ para $(x+1)^N$ com $N=2^n$):

- suas folhas são v_1, v_2, que computam $f(v_1)=x$ e $f(v_2)=1$;
- o nó v_3 tem filhos v_1, v_2 e computa a soma deles, de modo que $f(v_3)=x+1$;
- os nós $v_4, \ldots, v_{n+3}$ são tais que, para $i \geqslant 4$, os filhos de v_i são v_{i-1} e v_{i-1}, e v_i computa o produto deles. Assim, $f(v_{3+i})=(x+1)^{2^i}$ para $1 \leqslant i \leqslant n$;
- a raiz é v_{n+3}, que computa o polinômio $(x+1)^{2^n}$.

Definição 8.2: Circuito eficiente

Um circuito algébrico é ***eficiente*** se ele computa um polinômio de grau $n^{O(1)}$ e tem tamanho $n^{O(1)}$. A classe dos polinômios que podem ser computados por circuitos algébricos eficientes é chamada de ***VP***.

Um exemplo não trivial é o determinante de uma matriz. Seja M a matriz cuja entrada (i,j) é $x_{i,j}$. O polinômio determinante é

$$\det(M) = \sum_{\pi \in S_n} \operatorname{sgn}(\pi) \prod_{i=1}^{n} x_{i,\pi(i)}.$$

Aqui, S_n é o conjunto de todas as permutações de n elementos, e o sinal $\operatorname{sgn}(\pi) \in \{+1, -1\}$ de uma permutação é um número associado a ela (com cuja definição específica não nos importaremos aqui). Assim, o determinante é um polinômio em n^2 variáveis de grau n. Como soma de monômios, ele possui $n!$ monômios, o que é muito ineficiente. No entanto, sabemos que o determinante pode ser computado eficientemente, por exemplo, por eliminação de Gauss. Acontece que ele também possui um circuito algébrico eficiente.

8.3 O Lema de Schwartz–Zippel

Uma questão básica em matemática é saber se dois objetos são iguais. Aqui, consideraremos o seguinte problema: dados dois polinômios $f(x)$ e $g(x)$, possivelmente por meio de um circuito algébrico, é verdade que $f(x) = g(x)$? De forma equivalente, como podemos criar um circuito que computa $f(x) - g(x)$, basta verificar se um dado polinômio é zero.

Se esse polinômio for dado por sua lista de coeficientes, podemos simplesmente verificar se todos eles são zero. No entanto, esse pode ser um procedimento muito caro, pois o número de coeficientes pode ser exponencialmente grande. Por exemplo, será que

$$\det\begin{pmatrix} 1 & x & x^2 \\ 1 & y & y^2 \\ 1 & z & z^2 \end{pmatrix} = (z-y)(y-x)(z-x)?$$

Veremos que, usando aleatoriedade, isso pode ser verificado. Isso será feito por meio do seguinte lema, chamado ***lema de Schwartz–Zippel***, que generaliza para polinômios multivariados o fato de que polinômios univariados de grau d possuem no máximo d raízes.

Teorema 8.2: Lema de Schwartz–Zippel

Seja $f(x_1, \ldots, x_n)$ um polinômio não nulo de grau d sobre um corpo $\mathbb{F}$, e seja $S \subseteq \mathbb{F}$ um subconjunto finito. Então, se $a_1, \ldots, a_n \in S$ são sorteados de forma independente e uniforme,

$$\mathbb{P}_{a_1,\ldots,a_n \in S}\left[f(a_1, \ldots, a_n) = 0\right] \leqslant \frac{d}{|S|}.$$

Observação 22. O lema é justo (*tight*), mesmo no caso univariado: se $f(x) = \prod_{i=1}^{d}(x-i)$ e $S = \{1, \ldots, s\}$, com $s \geqslant d$, então $\mathbb{P}_{a \in S}[f(a) = 0] = d/s$.

Demonstração. A prova é por indução em n. Se $n = 1$, então $f(x_1)$ é um polinômio univariado de grau d, logo possui no máximo d raízes e, assim, $\mathbb{P}_{a_1 \in S}[f(a_1) = 0] \leqslant d/|S|$.

Se $n > 1$, escreva o polinômio como

$$f(x_1, \ldots, x_n) = \sum_{i=0}^{d} x_n^i \, f_i(x_1, \ldots, x_{n-1}),$$

onde $f_0, \ldots, f_d$ são polinômios nas $n-1$ variáveis restantes, com $\deg(f_i) \leqslant d - i$. Seja $e \leqslant d$ o maior índice tal que $f_e \neq 0$. Sorteie $a_1, \ldots, a_n \in S$ de forma independente e uniforme. Considere primeiro o evento $f_e(a_1, \ldots, a_{n-1}) = 0$. Pela hipótese de indução, sua probabilidade é limitada por

$$\mathbb{P}_{a_1,\ldots,a_{n-1} \in S}\left[f_e(a_1, \ldots, a_{n-1}) = 0\right] \leqslant \frac{\deg(f_e)}{|S|} \leqslant \frac{d-e}{|S|}.$$

Caso contrário, fixe $a_1, \ldots, a_{n-1} \in S$ tais que $f_e(a_1, \ldots, a_{n-1}) \neq 0$. O polinômio $f(a_1, \ldots, a_{n-1}, x)$ é univariado de grau e e, portanto, possui no máximo e raízes. Logo, para qualquer escolha desse tipo de $a_1, \ldots, a_{n-1}$,

$$\mathbb{P}_{a_n \in S}\left[f(a_1, \ldots, a_{n-1}, a_n) = 0\right] \leqslant \frac{e}{|S|}.$$

Assim, podemos limitar a probabilidade de que $f(a_1, \ldots, a_n) = 0$ pela soma das probabilidades de dois eventos: ou $f_e(a_1, \ldots, a_{n-1}) = 0$, ou isso não ocorre, mas $f(a_1, \ldots, a_n) = 0$. Logo,

$$\mathbb{P}_{a_1,\ldots,a_n \in S}\left[f(a_1, \ldots, a_n) = 0\right] \leqslant \frac{d-e}{|S|} + \frac{e}{|S|} = \frac{d}{|S|}. \qquad \square$$

Corolário 8.2

Sejam f, g dois polinômios multivariados distintos de grau no máximo d. Então

$$\mathbb{P}_{a_1,\ldots,a_n \in \{1,\ldots,\lceil d/\varepsilon \rceil\}}\left[f(a) = g(a)\right] \leqslant \varepsilon.$$

Note que, se tivermos circuitos algébricos eficientes que computam f e g, podemos executar esse teste eficientemente por meio de um algoritmo aleatorizado, que avalia os dois circuitos em um mesmo ponto escolhido aleatoriamente.

8.4 *Emparelhamentos Perfeitos via Teste de Identidade de Polinômios*

Veremos uma maneira eficiente de decidir se um grafo bipartido possui um emparelhamento perfeito usando teste de identidade de polinômios.

Defina a seguinte matriz $n \times n$: $M_{i,j} = x_{i,j}$ se $(u_i, v_j) \in E$, e $M_{i,j} = 0$ caso contrário. O determinante de M é

$$\det(M) = \sum_{\pi \in S_n} \operatorname{sgn}(\pi) \prod_{i=1}^{n} M_{i,\pi(i)}.$$

Proposição 8.1: Determinante e emparelhamentos perfeitos

G possui um emparelhamento perfeito se e somente se $\det(M)$ não é o polinômio nulo.

Demonstração. Cada termo $\prod_{i=1}^{n} M_{i,\pi(i)}$ é o monômio $\prod_{i=1}^{n} x_{i,\pi(i)}$ se π corresponde a um emparelhamento perfeito (isto é, se $(u_i, v_{\pi(i)}) \in E$ para todo i), e é zero caso contrário. Além disso, permutações distintas dão origem a monômios distintos, de modo que cada monômio aparece no máximo uma vez e, portanto, não há cancelamentos. $\square$

Obtivemos, assim, um algoritmo aleatorizado eficiente para testar se um grafo bipartido possui um emparelhamento perfeito: execute o algoritmo de teste de identidade de polinômios sobre o polinômio $\det(M)$.

Corolário 8.3

Seja $\mathbb{F}=\mathbb{F}_p$ um corpo finito, com p primo e $p \geqslant n/\varepsilon$. Defina uma matriz aleatória M de tamanho $n \times n$ sobre $\mathbb{F}$ da seguinte forma: se $(i,j) \in E$, sorteie $M_{i,j} \in \mathbb{F}$ uniformemente; se $(i,j) \notin E$, defina $M_{i,j}=0$. Então

- se G não possui emparelhamentos perfeitos, então sempre $\det(M)=0$;
- se G possui emparelhamentos perfeitos, então $\mathbb{P}[\det(M)=0] \leqslant \varepsilon$.

A
Sobre convergência de séries

A.1 Sequências e séries

(s.1) Uma série $\sum_{i\geqslant 1} x_i$ ***converge*** se existe o limite das somas parciais $S_n := \sum_{i=1}^{n} x_i$

$$\lim_{n\to\infty} S_n = \lim_{n\to\infty} \sum_{i=1}^{n} x_i \tag{A.1}$$

e ***converge absolutamente*** se $\sum_{i\geqslant 1} |x_i|$ converge. Uma prova dos seguintes resultados pode ser encontrada em [1].

[1]

(a) Uma série que converge absolutamente também converge.

(b) Se $\sum_n x_n$ converge e $\sum_n y_n$ é a série obtida de $\sum_n x_n$ eliminando-se os termos $x_n = 0$, então $\sum_n y_n$ converge para o mesmo valor.

(c) Se uma série converge absolutamente então qualquer série obtida rearranjando os termos dessa série converge absolutamente para o mesmo valor. Ademais, vale que se $\{ A_i : i \in I \}$ é uma partição finita ou enumerável de $\mathbb{N}$ e $y_i = \sum_{j\in A_i} x_j$, então

$$\sum_n x_n = \sum_{i\in I} y_i.$$

(s.2) Se $\sum_{i\geqslant 1} x_i$ é tal que $x_i \geqslant 0$ para todo i, então a série converge ou tende ao infinito. A série converge se, e só se, converge absolutamente.

(s.3) Teste de convergência por comparação: se $0 \leqslant x_n \leqslant y_n$ para todo n suficientemente grande e $\sum_n y_n$ converge então $\sum_n x_n$ converge.

(s.4) a convergência absoluta de uma série implica que toda subsérie da série é convergente. Isso segue de (s.1b) acima e do teste de convergência por comparação.

(s.5) Seja I, J conjuntos enumeráveis (finitos ou infinitos) e $(x_{i,j} : i \in I,\ j \in J)$ uma família duplamente indexada. Para termos não negativos, ou absolutamente somáveis, a soma sobre $I \times J$ não depende da enumeração escolhida para $I \times J$.

(Tonelli) Se $x_{i,j} \geqslant 0$ para todo (i, j), então

$$\sum_{i\in I}\sum_{j\in J} x_{i,j} = \sum_{(i,j)\in I\times J} x_{i,j} = \sum_{j\in J}\sum_{i\in I} x_{i,j} \in [0, +\infty].$$

(Fubini) Se $\sum_{(i,j)\in I\times J} |x_{i,j}| < \infty$, então cada soma interna converge absolutamente, a série dupla $\sum_{(i,j)} x_{i,j}$ converge absolutamente e

$$\sum_{i\in I}\sum_{j\in J} x_{i,j} = \sum_{(i,j)\in I\times J} x_{i,j} = \sum_{j\in J}\sum_{i\in I} x_{i,j} \in \mathbb{R}.$$

(Produto) Se $a_i, b_j \geq 0$, então $\sum_{(i,j)} a_i b_j = (\sum_i a_i)\Big(\sum_j b_j\Big)$ em $[0, \infty]$ (com $0 \cdot \infty = 0$). Se $\sum_i |a_i| < \infty$ e $\sum_j |b_j| < \infty$, a igualdade vale também sem o sinal, e a família $(a_i b_j)$ é absolutamente somável.

(s.6) se $|x| < 1$ então

(a) $\sum_{n\geqslant 0} x^n = (1-x)^{-1}$;
(b) $\sum_{n\geqslant k} x^n = x^k(1-x)^{-1}$;
(c) $\sum_{n\geqslant 1} nx^n = x(1-x)^{-2}$.

(s.7) O Teorema Binomial (de Newton) generalisado

$$(1-x)^{-k} = \sum_{t=0}^{\infty} \binom{t+k-1}{t} x^t.$$

(s.8) $\sum_{n\geqslant 1} n^{-2} = \pi^2/6$.

A convergência dessa série foi estabelecida pela primeira vez por Euler e é um dos resultados responsáveis por lançar à notoriedade, na epóca, o matemático.

(s.9) A sequência $(1 + 1/n)^n$ é estritamente crescente e a sequência $(1 - 1/n)^{-n}$ é estritamente decrescente, ambas convergem para a constante e = 2,71... quando $n \to \infty$. Além disso, para todo x real

$$\mathrm{e}^x = \sum_{n\geqslant 0} \frac{x^n}{n!}.$$

B
Desigualdades

(d.1) De (s.9), para todo $n \geqslant 0$ vale

$$\left(1-\frac{1}{n}\right)^{-n} \geqslant \mathrm{e} \geqslant \left(1+\frac{1}{n}\right)^{n}$$

e para qualquer $x > 0$

$$1 - x + \frac{x^2}{2} > \mathrm{e}^{-x} > (1-x).$$

(d.2) O coeficiente binomial tem os seguintes limitantes triviais

$$0 \leqslant \binom{n}{i} \leqslant 2^n.$$

Para um limitante inferior melhor podemos escrever

$$\binom{n}{i} = \prod_{j=0}^{i-1} \frac{n-j}{j-i} \geqslant \left(\frac{n}{i}\right)^{i}$$

e para um limitante superior usamos o teorema binômial de Newton e (s.9)

$$\mathrm{e}^{nx} \geqslant (1+x)^n = \sum_{i=0}^{n} \binom{n}{i} x^i \geqslant \binom{n}{i} x^i$$

para todo $x > 0$ e todo $i \in \{\, 0, 1, \ldots, n \,\}$. Logo

$$\binom{n}{i} \leqslant \mathrm{e}^{nx} x^{-i}.$$

Em particular, fazendo $x = i/n$, temos a segunda desigualdade de

$$\left(\frac{n}{i}\right)^{i} \leqslant \binom{n}{i} \leqslant \left(\mathrm{e}\frac{n}{i}\right)^{i}.$$

(d.3) A seguinte igualdade assintótica conhecida como fórmula de Stirling

$$n! = \left(1 + O\left(\frac{1}{n}\right)\right) \sqrt{2\pi n} \left(\frac{n}{\mathrm{e}}\right)^{n} = (1+o(1))\sqrt{2\pi n}\left(\frac{n}{\mathrm{e}}\right)^{n} \qquad \text{(B.1)}$$

A seguinte tabela que exibe exemplos para números pequenos nos dá ideia da qualidade dessa aproximação

n	$n!$	Stirling
1	1	0.922137
3	6	5.83621
7	5040	4980.396
10	3628800	3598696
20	$2.432902e+18$	$2.422787e+18$
50	$3.041409e+64$	$3.036345e+64$
75	$2.480914e+109$	$2.478159e+109$
100	$9.332622e+157$	$9.324848e+157$
142	$2.695364e+245$	$2.693783e+245$

também valem os limitantes

$$\sqrt{2\pi n}\left(\frac{n}{\mathrm{e}}\right)^n \leqslant n! \leqslant \mathrm{e}\sqrt{n}\left(\frac{n}{\mathrm{e}}\right)^n$$

Nos limitantes em (d.2) para $\binom{n}{i}$ usamos que

$$\prod_{j=0}^{i-1}(n-j) > (n-i)^i = \left(1-\frac{i}{n}\right)^i n^i \geqslant \left(1-\frac{i^2}{n}\right)n^i = (1+o(1))n^i$$

e se $i = o(\sqrt{n})$

$$\binom{n}{i} = (1+o(1))\frac{n^i}{i!} = (1+o(1))\frac{1}{\sqrt{2\pi i}}\left(\frac{\mathrm{e}n}{i}\right)^i.$$

(d.4) Para quaisquer números reais $x_1, x_2, \ldots$, para todo natural n

$$|x_1 + \cdots + x_n| \leqslant |x_1| + \cdots + |x_n|.$$

Ademais, $|x_1| + \cdots + |x_n| \leqslant |x_1| + |x_2| + \cdots$, portanto, $|x_1 + \cdots + x_n| \leqslant |x_1| + |x_2| + \cdots$ e pela continuidade da função valor absoluto $\lim_{n\to\infty} |x_1 + \cdots + x_n| = |x_1 + x_2 + \cdots|$ portanto

$$|x_1 + x_2 + \cdots| \leqslant |x_1| + |x_2| + \cdots$$

sempre que $\sum_n x_n$ converge.

C
Resolução dos exercícios

1. Sejam os eventos:

   - U_1: urna escolhida é a das duas bolas brancas;
   - U_2: urna escolhida é a das duas bolas pretas;
   - U_3: urna escolhida é a mista (uma branca, uma preta);
   - Br: a bola retirada é branca.

   Queremos a probabilidade de a bola que ficou na urna ser preta, o que só pode acontecer se a urna escolhida foi a urna U_3 (mista). Ou seja, queremos $\mathbb{P}(\, U_3 \mid Br\,)$.

   Cada urna é escolhida com probabilidade 1/3: $\mathbb{P}(\, U_1\,) = \mathbb{P}(\, U_2\,) = \mathbb{P}(\, U_3\,) = \frac{1}{3}$.

   A probabilidade de sair bola branca dado cada urna:

   $$\mathbb{P}(\, Br \mid U_1\,) = 1, \qquad \mathbb{P}(\, Br \mid U_2\,) = 0, \qquad \mathbb{P}(\, Br \mid U_3\,) = \frac{1}{2}.$$

   Probabilidade total de sair branca

   $$\begin{aligned}\mathbb{P}(\, Br\,) &= \mathbb{P}(\, Br \mid U_1\,)\mathbb{P}(\, U_1\,) + \mathbb{P}(\, Br \mid U_2\,)\mathbb{P}(\, U_2\,) + \mathbb{P}(\, Br \mid U_3\,)\mathbb{P}(\, U_3\,) \\ &= 1 \cdot \frac{1}{3} + 0 \cdot \frac{1}{3} + \frac{1}{2} \cdot \frac{1}{3} = \frac{1}{3} + \frac{1}{6} = \frac{1}{2}.\end{aligned}$$

   Agora,

   $$\mathbb{P}(\, U_3 \mid Br\,) = \frac{\mathbb{P}(\, Br \mid U_3\,)\,\mathbb{P}(\, U_3\,)}{\mathbb{P}(\, Br\,)} = \frac{\frac{1}{2} \cdot \frac{1}{3}}{\frac{1}{2}} = \frac{1/6}{1/2} = \frac{1}{3}.$$

   Portanto $\mathbb{P}\big[\,$ bola restante é preta $\mid$ bola retirada é branca $\big] = \frac{1}{3}$.

2.

3. Seja k o número de bits de M, ou seja, $2^{k-1} \leqslant M < 2^k$. No algoritmo, $N = \sum_i d_i 2^i$ é obtido a partir de $k+t$ bits uniformes e independentes, logo N é uniforme sobre $\{0, 1, \ldots, K-1\}$, onde $K = 2^{k+t}$. A saída do algoritmo é $N \bmod M$.

   Na divisão euclidiana de K por M

$$K = qM + r, \quad 0 \leqslant r < M, \quad q = \left\lfloor \frac{K}{M} \right\rfloor$$

   e para cada resto $n \in \{0, \ldots, M-1\}$, os inteiros em $\{0, \ldots, K-1\}$ congruentes a n módulo M são

$$n,\ n+M,\ n+2M,\ \ldots$$

   e há exatamente $q+1$ deles se $n < r$, e exatamente q deles se $n \geqslant r$ (isso decorre diretamente de $K = qM + r$).

   Como N é uniforme em $\{0, \ldots, K-1\}$,

$$\mathbb{P}[\, N = n \,] = \begin{cases} \dfrac{q+1}{K}, & 0 \leqslant n < r, \\[2ex] \dfrac{q}{K}, & r \leqslant n \leqslant M-1. \end{cases}$$

   Agora, calculando os desvios em relação a $1/M$.

   De $K = qM + r$ obtemos $q = \dfrac{K-r}{M}$, logo:

$$\frac{1}{M} - \frac{q}{K} = \frac{1}{M} - \frac{K-r}{MK} = \frac{r}{MK},$$

$$\frac{q+1}{K} - \frac{1}{M} = \frac{K-r+M}{MK} - \frac{1}{M} = \frac{M-r}{MK}.$$

   Ambas as quantidades são não negativas (pois $0 \leqslant r < M$), então

$$\left| \mathbb{P}[\, N = n \,] - \frac{1}{M} \right| = \begin{cases} \dfrac{M-r}{MK}, & 0 \leqslant n < r, \\[2ex] \dfrac{r}{MK}, & r \leqslant n \leqslant M-1. \end{cases} \qquad f$$

   Há r valores de n no primeiro caso e $M-r$ valores no segundo, logo

$$\sum_{n=0}^{M-1} \left| \mathbb{P}[\, N = n \,] - \frac{1}{M} \right| = r \cdot \frac{M-r}{MK} + (M-r) \cdot \frac{r}{MK} = \frac{2r(M-r)}{MK}.$$

   A função $r \mapsto r(M-r)$ é uma parábola côncava em r, com máximo em $r = M/2$, onde vale $M^2/4$. Assim, para todo $r \in [0, M]$ (em particular para o inteiro r em questão),

$$r(M-r) \leqslant \frac{M^2}{4}.$$

Substituindo, usando que $M < 2^k$ e $K = 2^{k+t}$

$$\sum_{n=0}^{M-1} \left| \mathbb{P}[\, N = n \,] - \frac{1}{M} \right| \leqslant \frac{2}{MK} \cdot \frac{M^2}{4} = \frac{M}{2K} < \frac{1}{2^{t+1}}.$$

4. seja p_n a probabilidade de o laço `repeat–until` executar pelo menos n vezes, para $n \geqslant 1$.

```
1 j ← 0;
2 repita
3 |   j ← j + 1;
4 |   para cada i ∈ { 1, 2, ..., j } faça d_i ←R {0, 1};
5 até que d_i = 1 para todo i.
```

   Na j-ésima execução do corpo do laço, sorteiam-se j bits $d_1, \ldots, d_j$ uniformes e independentes em $\{0,1\}$, e o laço termina se, e somente se, todos eles forem iguais a 1. Como esses bits são *redefinidos do zero* a cada execução, o evento

$$E_j \coloneqq \big[\text{“todos os } j \text{ bits sorteados na iteração } j \text{ são iguais a 1”}\big]$$

   tem probabilidade

$$\mathbb{P}\big[\, E_j \,\big] = 2^{-j},$$

   e os eventos $E_1, E_2, E_3, \ldots$ são mutuamente independentes, pois dizem respeito a sorteios distintos e independentes entre si.

   O laço executa pelo menos n vezes se, e somente se, ele não é interrompido em nenhuma das iterações $j = 1, \ldots, n-1$, ou seja, se nenhum dos eventos $E_1, \ldots, E_{n-1}$ ocorre. Pela independência,

$$p_n = \mathbb{P}\Big[\, \overline{E_1} \cap \cdots \cap \overline{E_{n-1}} \,\Big] = \prod_{j=1}^{n-1} \left(1 - 2^{-j}\right),$$

   com a convenção usual de que o produto vazio (caso $n = 1$) vale 1.

   Para cada $j \geqslant 1$ temos $2^{-j} \in (0,1)$, logo cada fator $1 - 2^{-j}$ pertence a $(0,1)$. Como p_n é um produto *finito* de números estritamente positivos, segue que $p_n > 0$.

   Como

$$p_{n+1} = p_n \cdot (1 - 2^{-n}) \quad \text{e} \quad 0 < 1 - 2^{-n} < 1,$$

   temos $p_{n+1} \leqslant p_n$ para todo n. Sendo decrescente e limitada inferiormente por 0, a sequência (p_n) converge para algum limite $L \geqslant 0$. Resta mostrar que $L > 0$.

   Como $2^{-j} \leqslant \frac{1}{2}$ para todo $j \geqslant 1$, podemos aplicar a desigualdade $1 - x \geqslant e^{-2x}$, válida para $x \in [0, 1/2]$, com $x = 2^{-j}$:

$$1 - 2^{-j} \;\geqslant\; \exp\left(-2 \cdot 2^{-j}\right) = \exp\left(-2^{1-j}\right).$$

Multiplicando essas desigualdades para $j = 1, \ldots, n-1$ (todos os fatores são positivos, logo a desigualdade é preservada pelo produto):

$$p_n = \prod_{j=1}^{n-1} \left(1 - 2^{-j}\right) \geqslant \prod_{j=1}^{n-1} \exp\left(-2^{1-j}\right) = \exp\left(-\sum_{j=1}^{n-1} 2^{1-j}\right) = \exp\left(-2\sum_{j=1}^{n-1} 2^{-j}\right).$$

A soma geométrica satisfaz

$$\sum_{j=1}^{n-1} 2^{-j} = 1 - 2^{-(n-1)} < 1 \qquad \text{para todo } n \geqslant 1,$$

donde

$$p_n \geqslant \exp\left(-2\left(1 - 2^{-(n-1)}\right)\right) > \exp(-2),$$

para todo $n \geqslant 1$. Ou seja, obtemos uma cota inferior *uniforme*, independente de n:

$$p_n > e^{-2} \qquad \text{para todo } n.$$

Como $(p_n)_{n\geqslant 1}$ é decrescente, converge para $L = \lim_{n\to\infty} p_n$, e como $p_n > e^{-2}$ para todo n, segue que

$$L = \lim_{n\to\infty} p_n \geqslant e^{-2} > 0.$$

Portanto $\lim_{n\to\infty} p_n > 0$.

5.

6. De f convexa em I, deduzimos que para todo $a \in I$ existe um real m_a tal que
$$\frac{f(a) - f(x)}{a - x} \leqslant m_a \leqslant \frac{f(y) - f(a)}{y - a}$$
para todo $x < a$ e todo $y > a$. Portanto, $f(x) \geqslant f(a) + m_a(x - a)$ para todo $x \in I$ e, tomando $a = \mathbb{E}X$, $x = X$ e a esperança nos dois lados dessa desigualdades
$$\mathbb{E}(\, f(X)\,) \geqslant f(\mathbb{E}X) + m_a \mathbb{E}(X - \mathbb{E}(\, X\,))$$
donde segue a desigualdade que queremos demonstrar.

7.

8.

9. Construiremos um algoritmo Las Vegas B a partir do algoritmo Monte Carlo A da seguinte maneira.

   Dada uma instância I de tamanho n, o algoritmo B repete independentemente os seguintes passos:

(a) Execute A sobre I e obtenha uma solução s.

(b) Verifique a corretude de s em tempo $t(n)$.

(c) Se s for correta, retorne s; caso contrário, repita.

Como a solução só é retornada depois de ser verificada, o algoritmo B sempre fornece uma resposta correta. Resta analisar seu tempo esperado de execução.

Cada tentativa consiste em executar A e verificar a solução obtida. Como o tempo esperado de execução de A é no máximo $T(n)$, o tempo esperado de uma tentativa é no máximo $T(n) + t(n)$.

Além disso, pela hipótese, cada execução de A produz uma solução correta com probabilidade $\gamma(n)$. Como as execuções são independentes, o número N de tentativas até obter a primeira solução correta tem distribuição geométrica com parâmetro $\gamma(n)$. Assim, $\mathbb{E}N = \frac{1}{\gamma(n)}$.

Seja X_k o tempo gasto na k-ésima tentativa. O tempo total de B é $X_1 + \cdots + X_N$.

Como cada tentativa tem tempo esperado no máximo $T(n) + t(n)$, obtemos

$$\mathbb{E}\left(\sum_{k=1}^{N} X_k\right) \leqslant \mathbb{E}(\,N\,)\big(T(n) + t(n)\big).$$

Portanto,

$$\mathbb{E}[\text{tempo}(B)] \leqslant \frac{T(n) + t(n)}{\gamma(n)}.$$

Logo, B é um algoritmo Las Vegas: ele sempre retorna uma solução correta e seu tempo esperado de execução é, no máximo,

$$\frac{T(n) + t(n)}{\gamma(n)}.$$

10. Por definição

$$\mathbb{E}\sum_{i\geqslant 1} X_i = \sum_{\omega\in\Omega}\left(\sum_{i\geqslant 1} X_i(\omega)\right)\mathbb{P}(\,\omega\,),$$

desde que essa soma (dupla) esteja bem definida, o que precisamos justificar antes de trocar a ordem de somação.

Por hipótese, $\sum_{i\geqslant 1}\mathbb{E}|X_i| = \sum_{i\geqslant 1}\sum_{\omega}|X_i(\omega)|\mathbb{P}(\,\omega\,)$ converge. Como os termos $|X_i(\omega)|\mathbb{P}(\,\omega\,)$ são todos não negativos, essa soma dupla converge *absolutamente*, independentemente da ordem em que é somada (é uma soma de termos não negativos indexada por $\mathbb{N}\times\Omega$, um conjunto enumerável). Em particular, para $\mathbb{P}$-quase todo ω a série $\sum_i X_i(\omega)$ converge absolutamente, então $\sum_i X_i(\omega)$ está bem definida.

Pelo teorema de Tonelli–Fubini para séries (s.5) (o mesmo resultado já usado na demonstração do Teorema 3.3) a convergência absoluta de $\sum_{i,\omega} X_i(\omega)\mathbb{P}(\omega)$ garante que podemos trocar a ordem das somas:

$$\sum_{\omega\in\Omega}\sum_{i\geqslant 1} X_i(\omega)\mathbb{P}(\omega) = \sum_{i\geqslant 1}\sum_{\omega\in\Omega} X_i(\omega)\mathbb{P}(\omega).$$

O lado esquerdo é, por definição, $\mathbb{E}\sum_{i\geqslant 1} X_i$, e cada termo do lado direito é $\mathbb{E}X_i$. Logo

$$\mathbb{E}\sum_{i\geqslant 1} X_i = \sum_{i\geqslant 1}\mathbb{E}X_i.$$

11. Com essa definição,

$$\mathbb{E}X_n = \sum_{j\geqslant 1} X_n(j)\mathbb{P}(j) = 2^n 2^{-n} + \left(-2^{n+1}\right)2^{-(n+1)} = 0,$$

portanto, $\sum_{n\geqslant 1}\mathbb{E}X_n = 0$. No entanto, para a variável aleatória $X = \sum_{n\geqslant 1} X_n$ temos $X(1) = 2$ e para todo $j \geqslant 2$

$$X(j) = \sum_{n\geqslant 1} X_n(j) = 0 + \cdots + 0 + (-2)^j + 2^j + 0 + 0 + \cdots = 0$$

portanto, $\mathbb{E}X = \sum_{n\geqslant 1} X(n)\mathbb{P}(n) = 2\frac{1}{2} + 0 + 0 + \cdots = 1$. Logo $\mathbb{E}\sum_n X_n \neq \sum_n \mathbb{E}X_n$.

12. Em $2k$ lançamentos independentes de uma moeda com $\mathbb{P}(\text{cara}) = \frac{1}{5}$ e $\mathbb{P}(\text{coroa}) = \frac{4}{5}$, a probabilidade de sair menos que k coroas é

$$\sum_{i=0}^{k-1}\binom{2k}{i}\left(\frac{4}{5}\right)^i\left(\frac{1}{5}\right)^{2k-i}.$$

Primeiro, escrevemos cada termo como

$$\left(\frac{4}{5}\right)^i\left(\frac{1}{5}\right)^{2k-i} = \frac{4^i}{5^{2k}}.$$

Assim,

$$\sum_{i=0}^{k-1}\binom{2k}{i}\left(\frac{4}{5}\right)^i\left(\frac{1}{5}\right)^{2k-i} = \frac{1}{5^{2k}}\sum_{i=0}^{k-1}\binom{2k}{i}4^i.$$

Como para $i \leqslant k-1$ temos $4^i \leqslant 4^k$, obtemos a cota simples:

$$\frac{1}{5^{2k}}\sum_{i=0}^{k-1}\binom{2k}{i}4^i \leqslant \frac{1}{5^{2k}}\cdot 4^k\sum_{i=0}^{k-1}\binom{2k}{i}.$$

Isto é exatamente a primeira desigualdade pedida:

$$\sum_{i=0}^{k-1}\binom{2k}{i}\left(\frac{4}{5}\right)^i\left(\frac{1}{5}\right)^{2k-i} < \left(\frac{1}{5}\right)^{2k}\cdot 4^k\sum_{i=0}^{k-1}\binom{2k}{i}.$$

Agora, majoramos o somatório de binomiais. Sabemos que

$$\sum_{i=0}^{2k} \binom{2k}{i} = 2^{2k}$$

e que os coeficientes binomiais são simétricos em torno de $i = k$. Logo,

$$\sum_{i=0}^{k-1} \binom{2k}{i} \leqslant \frac{1}{2} \sum_{i=0}^{2k} \binom{2k}{i} = \frac{1}{2} \cdot 2^{2k} = 2^{2k-1}.$$

(essa desigualdade é imediata porque a soma dos termos até $k-1$ nãopode ultrapassar metade da soma total — a igualdade só ocorreria se$\binom{2k}{k} = 0$, o que não acontece.)Combinando as duas cotas:

$$\sum_{i=0}^{k-1} \binom{2k}{i} \left(\frac{4}{5}\right)^i \left(\frac{1}{5}\right)^{2k-i} \leqslant \frac{1}{5^{2k}} \cdot 4^k \cdot 2^{2k-1} = \frac{1}{2} \left(\frac{4}{5}\right)^{2k}.$$

Portanto, a probabilidade pedida é menor que

$$\frac{1}{2} \left(\frac{4}{5}\right)^{2k},$$

e, em particular, é menor que $\left(\frac{4}{5}\right)^{2k}$, como queríamos demonstrar.

13. Fixado $x \in S$, considere a sequência de subsequências $S'_0 = S, S'_1, \ldots, S'_M$ às quais x pertence ao longo da execução, onde $M = M(x)$ é o número total de particionamentos pelos quais x passa.

    Em cada particionamento, o pivô z é removido da subsequência (ele não é reinserido em S_1 nem em S_2), logo

    $$|S'_{i+1}| \leqslant |S'_i| - 1 < |S'_i| \qquad \text{para todo } i.$$

    Em particular, a sequência $|S'_0|, |S'_1|, \ldots, |S'_M|$ é estritamente decrescente.

    Por definição, o i-ésimo particionamento (o particionamento de S'_i) é bom se o pivô não está entre os 10% menores nem entre os 10% maiores elementos de S'_i. Nesse caso, tanto S_1 quanto S_2 (e portanto a subsequência S'_{i+1} que contém x, seja ela qual for) têm tamanho no máximo $9|S'_i|/10$:

    $$|S'_{i+1}| \leqslant \frac{9}{10} |S'_i|.$$

    Suponha que, entre os M particionamentos que x sofre, exatamente k sejam bons, ocorrendo nos passos $i_1 < i_2 < \cdots < i_k$ (em ordem cronológica). Pelo Fato 1, o tamanho da subsequência só pode diminuir nos passos entre dois particionamentos bons consecutivos;

logo o tamanho imediatamente antes do $(j+1)$-ésimo particionamento bom é no máximo o tamanho imediatamente depois do j-ésimo particionamento bom. Combinando isso com o Fato 2, obtemos, para $j = 1, \ldots, k-1$,

$$|S'_{i_{j+1}}| \leqslant |S'_{i_j+1}| \leqslant \frac{9}{10}\,|S'_{i_j}|,$$

e também $|S'_{i_1}| \leqslant |S'_0| = n$. Por indução em j,

$$|S'_{i_j}| \leqslant n\left(\frac{9}{10}\right)^{j-1}, \qquad j = 1, \ldots, k,$$

ao k-ésimo particionamento bom,

$$|S'_{i_k+1}| \leqslant \frac{9}{10}\,|S'_{i_k}| \leqslant n\left(\frac{9}{10}\right)^{k}.$$

Como x pertence à subsequência S'_{i_k+1}, e toda subsequência não vazia tem tamanho pelo menos 1, segue que

$$1 \leqslant |S'_{i_k+1}| \leqslant n\left(\frac{9}{10}\right)^{k} \implies \left(\frac{10}{9}\right)^{k} \leqslant n \implies k \leqslant \log_{10/9} n.$$

Como k é um número inteiro, concluímos que

$$k \leqslant \lfloor \log_{10/9} n \rfloor,$$

ou seja, x participa de no máximo $\lfloor \log_{10/9} n \rfloor$ particionamentos bem-sucedidos (bons). ■

14.

15.

16.

17. **(a)** Fixe i e um histórico $(x_1, \ldots, x_{i-1}) \in \{0,1\}^{i-1}$ de probabilidade positiva. Pela descrição do algoritmo, a probabilidade condicional de sucesso no i-ésimo particionamento depende apenas de se o particionamento anterior (o $(i-1)$-ésimo, i.e., x_{i-1}) foi sucesso ou fracasso, e vale

$$\mathbb{P}[\, X_i = 1 \mid X_1 = x_1, \ldots, X_{i-1} = x_{i-1} \,] = \begin{cases} 0{,}7, & \text{se } x_{i-1} = 1 \text{ (sucesso anterior)}, \\ 0{,}9, & \text{se } x_{i-1} = 0 \text{ (fracasso anterior)}, \end{cases}$$

(com a convenção usual para $i = 1$, em que não há particionamento anterior). Em qualquer um dos dois casos,

$$\mathbb{P}[\, X_i = 1 \mid X_1 = x_1, \ldots, X_{i-1} = x_{i-1} \,] \geqslant 0{,}7 = \alpha,$$

pois $0{,}7 \geqslant 0{,}7$ e $0{,}9 \geqslant 0{,}7$. Como isso vale para todo i e todo histórico de probabilidade positiva, a hipótese do Lema 3.1 é satisfeita com $\alpha = 0{,}7$ — mesmo a sequência (X_i) não sendo i.i.d., já que a distribuição de X_i depende de X_{i-1}.

(b) Seja T o número de particionamentos necessários até x acumular $r = L + 1 = 29$ sucessos. Pelo item (b) do Lema 3.1 (com $\alpha = 0{,}7$), T é dominado estocasticamente por uma BN(29, 0,7), e portanto

$$\mathbb{E}(T) \leqslant \frac{r}{\alpha} = \frac{29}{0{,}7} = \frac{290}{7} \approx 41{,}43.$$

Logo, o número esperado de particionamentos necessários para acumular 29 sucessos é no máximo 290/7.

(c) Seria errado aplicar diretamente a fórmula $\mathbb{E}(T) = r/\alpha$ da binomial negativa BN(29, 0,7) como valor exato, porque os sucessos aqui não formam um processo i.i.d. Bernoulli(0,7): a probabilidade de sucesso é 0,9 (estritamente maior que 0,7) sempre que o particionamento anterior foi um fracasso, de modo que T apenas é dominado por (e não tem a mesma distribuição que) uma BN(29, 0,7), fazendo de 290/7 apenas um limitante superior, e não o valor exato de $\mathbb{E}(T)$.

18. **(c)** O limitante de Markov do item (b) afirma que

$$\mathbb{P}\Big[\, T \geqslant 200\, n \lceil \log_{10/9} n \rceil \,\Big] \leqslant \frac{1}{100} = O(1),$$

ou seja, é uma probabilidade de erro ***constante*** (não decresce com n): por maior que n seja, o limitante garante apenas que o algoritmo realiza $O(n \log n)$ comparações com probabilidade pelo menos 99%.

Já o Teorema 3.2 garante que $T = O(n \ln n)$ com probabilidade

$$1 - O(n^{-29}),$$

uma probabilidade de erro que *tende a zero* (polinomialmente, e rapidamente) quando $n \to \infty$.

Para n grande, o segundo resultado é muito mais forte: ele diz que a chance de o algoritmo ser lento fica desprezível à medida que n cresce, enquanto o limitante de Markov mantém sempre a mesma chance de 1% de falha, não importa quão grande seja n.

A desigualdade de Markov, aplicada *sozinha e diretamente a T* como no item (a)–(b), **não** é suficiente para provar o teorema mais forte: ela usa apenas $\mathbb{E}(T)$, e por si só dá um limitante da forma $\mathbb{P}[\, T \geqslant c \cdot \mathbb{E}(T) \,] \leqslant 1/c$, que é sempre $\Omega(1)$ em c fixo — para obter

uma probabilidade de exceção que decai como n^{-29} seria preciso tomar c crescendo com n (por exemplo $c = n^{29} \cdot (\text{constante})$), o que tornaria o limitante correspondente, $c \cdot 2n\lceil \log_{10/9} n \rceil = \Theta(n^{30} \log n)$, muito maior que $O(n \ln n)$ e portanto inútil para concluir que T é $O(n \ln n)$. Ou seja, Markov sozinha, aplicada a T como um todo, não tem "resolução"suficiente para dar simultaneamente um limitante *linear-log* em T *e* uma probabilidade de exceção polinomialmente pequena; é preciso a análise mais refinada do Teorema 3.2.

(d) A diferença fundamental está em *sobre o que* se aplica a concentração.

No item (a)–(b), a desigualdade de Markov é aplicada a uma *única* variável aleatória, $T = \sum_i X_i$, a soma de todas as comparações do algoritmo. Isso "achata"toda a informação da execução em um único número (sua esperança $\mathbb{E}(T)$), descartando qualquer estrutura sobre como as comparações se distribuem entre os n elementos. Com apenas essa esperança global, o único controle que se tem sobre o desvio de T é grosseiro: $\mathbb{P}[\, T \geqslant c\,\mathbb{E}(T)\,] \leqslant 1/c$, que decai apenas de forma *linear* (recíproca) em c, e não pode, sozinho, produzir uma cauda que decaia polinomialmente rápido em n sem sacrificar o expoente do limitante em $n \log n$.

Já a abordagem do Teorema 3.2 decompõe T em n variáveis $X_1, \ldots, X_n$, uma para cada elemento x_i, onde X_i conta os particionamentos (comparações) envolvendo x_i. Para *cada* X_i individualmente aplica-se um limitante de cauda muito mais forte (do tipo exponencial/Chernoff, via a dominação estocástica do lema anterior), obtendo $\mathbb{P}[\, X_i > L\,]$ decaindo rapidamente (polinomialmente pequeno, e ajustável para ser $O(n^{-30})$, digamos). Só depois, usa-se a união de eventos sobre os n elementos:

$$\mathbb{P}[\, \exists i : \; X_i > L\,] \leqslant \sum_{i=1}^{n} \mathbb{P}[\, X_i > L\,] \leqslant n \cdot O(n^{-30}) = O(n^{-29}).$$

Em outras palavras: a primeira abordagem usa apenas 1 "grau de liberdade"(a variável agregada T) e por isso só pode extrair da esperança um controle fraco sobre a cauda. A segunda usa n variáveis aleatórias distintas, cada uma analisada com uma cauda forte e individual, e paga o preço de somar n termos na união de eventos — mas como cada termo individual já decai muito mais rápido que $1/n$, a soma ainda é pequena. É exatamente esse "dividir para depois unir", em vez de tratar T como um bloco só, que permite trocar uma probabilidade de erro constante por uma que decai polinomialmente em n.

19. ($\Rightarrow$) Se $X \geq Y$, a definição vale para todo $t \in \mathbb{R}$, em particular para $t = j$ com $j \in \mathbb{Z}_{\geqslant 0}$, donde $\mathbb{P}[\, X > j\,] \geqslant \mathbb{P}[\, Y > j\,] = 2^{-j}$.

($\Leftarrow$) Suponha $\mathbb{P}[\, X > j \,] \geqslant 2^{-j}$ para todo inteiro $j \geqslant 0$. Precisamos mostrar $\mathbb{P}[\, X > t \,] \geqslant \mathbb{P}[\, Y > t \,]$ para todo $t \in \mathbb{R}$, não apenas para t inteiro.

Como X e Y assumem valores em $\{1, 2, \dots\}$, ambas as funções de sobrevivência $t \mapsto \mathbb{P}[\, X > t \,]$ e $t \mapsto \mathbb{P}[\, Y > t \,]$ são constantes em cada intervalo $[j, j+1)$, $j \in \mathbb{Z}_{\geqslant 0}$: de fato, para $t \in [j, j+1)$, como X só assume valores inteiros, $[X > t] = [X \geqslant j+1] = [X > j]$, e o mesmo vale para Y. Logo

$$\mathbb{P}[\, X > t \,] = \mathbb{P}[\, X > j \,] \quad \text{e} \quad \mathbb{P}[\, Y > t \,] = \mathbb{P}[\, Y > j \,] = 2^{-j} \qquad \text{para todo } t \in [j, j+1).$$

Pela hipótese, $\mathbb{P}[\, X > j \,] \geqslant 2^{-j}$, logo $\mathbb{P}[\, X > t \,] \geqslant \mathbb{P}[\, Y > t \,]$ para todo $t \in [j, j+1)$, $j \geqslant 0$.

Para $t < 1$ (incluindo $t < 0$), como $X, Y \geqslant 1$ sempre, $\mathbb{P}[\, X > t \,] = \mathbb{P}[\, Y > t \,] = 1$ trivialmente.

Como todo $t \in \mathbb{R}$ está em algum desses casos, $\mathbb{P}[\, X > t \,] \geqslant \mathbb{P}[\, Y > t \,]$ para todo $t \in \mathbb{R}$, ou seja, $X \succeq Y$.

20. (Igualdade em distribuição)

Suponha agora $X \succeq Y$ e $Y \succeq X$. Para todo $t \in \mathbb{R}$:

$$\mathbb{P}[\, X > t \,] \geqslant \mathbb{P}[\, Y > t \,] \qquad \text{e} \qquad \mathbb{P}[\, Y > t \,] \geqslant \mathbb{P}[\, X > t \,].$$

Combinando as duas desigualdades e as as funções de distribuição acumulada, obtemos, para todo $t \in \mathbb{R}$:

$$1 - F_X(t) = 1 - F_X(t)\mathbb{P}[\, X > t \,] = \mathbb{P}[\, Y > t \,] = 1 - F_Y(t)$$

equivalente a

$$F_X(t) = F_Y(t) \quad \text{para todo } t \in \mathbb{R}.$$

Como duas variáveis aleatórias reais têm a mesma distribuição se, e somente se, possuem a mesma função de distribuição acumulada, concluímos que $X \overset{d}{=} Y$.

Isso mostra que $\succeq$ é uma ***pré-ordem*** (reflexiva e transitiva) no espaço de todas as variáveis aleatórias reais.

21. **(a)** Pela desigualdade de Chebyshev, para qualquer variável aleatória W com média $\mu = \mathbb{E}(W)$ e qualquer $t > 0$,

$$\mathbb{P}[\, |W - \mu| \geqslant t \,] \leqslant \frac{\mathrm{Var}(W)}{t^2}.$$

Aplicando isso a $W = W_i$, com $t = \mu - \ell$, temos que o evento $\{W_i \leqslant \ell\}$ está contido no evento $\{|W_i - \mu| \geqslant \mu - \ell\} = \{|W_i - \mu| \geqslant t\}$ (pois $W_i \leqslant \ell$ implica $\mu - W_i \geqslant \mu - \ell = t$, logo $|W_i - \mu| \geqslant t$). Assim,

$$\mathbb{P}[\, W_i \leqslant \ell \,] \leqslant \mathbb{P}[\, |W_i - \mu| \geqslant t \,] \leqslant \frac{\mathrm{Var}(W_i)}{t^2}.$$

Como $\mathrm{Var}(W_i) \leqslant L\alpha(1-\alpha) = O(\ell)$ e $t = \mu - \ell = O(\ell)$ (de modo que $t^2 = O(\ell^2)$), obtemos

$$\mathbb{P}[\, W_i \leqslant \ell \,] \leqslant \frac{O(\ell)}{\Theta(\ell^2)} = O\left(\frac{1}{\ell}\right) = O\left(\frac{1}{\log n}\right),$$

já que $\ell = \Theta(\log n)$.

(b) Pela união de eventos sobre os n elementos $x_1, \ldots, x_n$,

$$\mathbb{P}[\, \exists i : \; W_i \leqslant \ell \,] \;\leqslant\; \sum_{i=1}^{n} \mathbb{P}[\, W_i \leqslant \ell \,] \;\leqslant\; n \cdot O\left(\frac{1}{\log n}\right) = O\left(\frac{n}{\log n}\right).$$

Como $n/\log n \;\to\; \infty$ quando $n \;\to\; \infty$, essa cota tende a ∞, não a 0 — ou seja, o limitante superior obtido para a probabilidade de falha (algum elemento ter poucos sucessos) é maior que 1 para n suficientemente grande, o que é trivialmente verdadeiro e não diz absolutamente nada de útil sobre a probabilidade real do evento. O argumento "por elemento + união"exige que cada termo individual $\mathbb{P}[\, W_i \leqslant \ell \,]$ decaia mais rápido que $1/n$ (idealmente, polinomialmente em n) para que a soma dos n termos ainda tenda a 0; um decaimento de apenas $O(1/\log n)$ é rápido demais devagar para isso, e a cota de Chebyshev é, portanto, inútil aqui.

(c) Temos $t = \mu - \ell = \Theta(\ell)$, enquanto o desvio-padrão é

$$\sqrt{\mathrm{Var}(W_i)} = \sqrt{O(\ell)} = \Theta(\sqrt{\ell}).$$

Assim, o desvio t que estamos exigindo é apenas uma constante vezes o desvio-padrão elevado ao quadrado dividido por ele mesmo, ou mais precisamente: o número de desvios-padrão que t representa é

$$\frac{t}{\sqrt{\mathrm{Var}(W_i)}} = \frac{\Theta(\ell)}{\Theta(\sqrt{\ell})} = \Theta(\sqrt{\ell}) = \Theta(\sqrt{\log n}),$$

que cresce apenas como $\sqrt{\log n}$ — um crescimento muito lento em n. A desigualdade de Chebyshev converte "k desvios-padrão de distância"em uma probabilidade de cauda de ordem $1/k^2$; aqui isso dá $1/k^2 = O(1/\log n)$. Para que a união sobre n elementos funcione, precisaríamos de uma cauda de ordem $1/n^{1+\varepsilon}$ (ou melhor), o que exigiria $k^2 \;=\; \Omega(n^{1+\varepsilon})$, ou seja, t da ordem de $\sqrt{n} \cdot \sqrt{\mathrm{Var}(W_i)}$ — muitíssimo maior que o $t \;=\; \Theta(\ell) \;=\; \Theta(\log n)$ de que efetivamente dispomos. Em suma: como o afastamento t que temos disponível corresponde a apenas $\Theta(\sqrt{\log n})$ desvios-padrão (e não a algo que cresce como uma potência de n), o quadrado no denominador de Chebyshev, t^2, nunca poderá compensar o fator n trazido pela união de eventos — os dois crescem em escalas incompatíveis ($\log n$ contra n).

(d) O problema de fundo é que a desigualdade de Chebyshev fornece apenas uma cauda polinomial (de ordem $1/k^2$ em número de desvios-padrão k), enquanto o argumento "por elemento + união sobre n elementos"exige, para cada um dos n termos, uma probabilidade de exceção que decaia mais rápido que $1/n$ — idealmente, de forma que a soma dos n termos ainda vá a 0 (ou até seja $O(n^{-c})$ para algum $c > 0$, como no Teorema 3.2). Como no nosso regime o desvio t é apenas $\Theta(\sqrt{\log n})$ desvios-padrão, uma cauda polinomial como a de Chebyshev produz um limitante da ordem de $1/\log n$, que é grande demais: multiplicado por n, diverge.

Uma desigualdade de Chernoff, por outro lado, fornece uma cauda ***exponencial*** no desvio t (tipicamente da forma $e^{-\Theta(t^2/\mu)}$ ou similar), e não apenas $1/t^2$. Com $t = \Theta(\ell) = \Theta(\log n)$, uma cauda exponencial produz um limitante da forma $e^{-\Theta(\log n)} = n^{-\Theta(1)}$ — ou seja, *polinomialmente pequeno em n*, e ajustável (escolhendo as constantes da análise) para ser tão pequeno quanto $O(n^{-30})$, por exemplo. Só assim a soma dos n termos na união de eventos permanece pequena ($n \cdot O(n^{-30}) = O(n^{-29})$), e o argumento "por elemento + união" tem sucesso. É exatamente por isso que a análise do Teorema 3.2 precisa de Chernoff, e não pode ser feita apenas com Chebyshev.

22.

23.

24.

25.

26.

27.

28.

29.

30. Seja $S = \sum_{i=1}^{m} X_i$, de modo que $\mathbb{E}S = m\mu$ e $\overline{X}_m = S/m$. Como os X_i são independentes com valores em $[0, 1]$, vale o limitante de Chernoff (forma multiplicativa, bilateral): para $0 < \varepsilon \leqslant 1$,

$$\mathbb{P}[\,|S - \mathbb{E}S| \geqslant \varepsilon\,\mathbb{E}S\,] \;\leqslant\; 2\exp\!\left(-\frac{\varepsilon^2\,\mathbb{E}S}{3}\right).$$

Substituindo $\mathbb{E}S = m\mu$ e dividindo por m dentro da probabilidade,

$$\mathbb{P}[\,\left|\overline{X}_m - \mu\right| \geqslant \varepsilon\mu\,] \;\leqslant\; 2\exp\!\left(-\frac{\varepsilon^2 m\mu}{3}\right).$$

Se $m \geqslant 3\ln(2/\delta)/(\varepsilon^2\mu)$, então $\varepsilon^2 m\mu/3 \geqslant \ln(2/\delta)$, logo

$$2\exp\left(-\frac{\varepsilon^2 m\mu}{3}\right) \leqslant 2\exp\big(-\ln(2/\delta)\big) = 2\cdot\frac{\delta}{2} = \delta,$$

o que prova (4.29).

Passando ao evento complementar,

$$\mathbb{P}[\,\left|\overline{X}_m - \mu\right| \leqslant \varepsilon\mu\,] \geqslant \mathbb{P}[\,\left|\overline{X}_m - \mu\right| < \varepsilon\mu\,] \geqslant 1-\delta,$$

isto é, $\overline{X}_m$ é uma (ε,δ)-aproximação para μ.

31. Seja $U = \bigcup_{i=1}^n S_i$. Para $x \in U$, $1 \leqslant \mathrm{cob}(x) \leqslant n$, e

$$s = \sum_{i=1}^n |S_i| = \sum_{i=1}^n \sum_{x\in S_i} 1 = \sum_{x\in U} \mathrm{cob}(x). \tag{C.1}$$

Segue de (C.1) que $|U| \leqslant s \leqslant n|U|$.

O espaço amostral do algoritmo é o conjunto $\Omega = \{(i,x)\colon 1 \leqslant i \leqslant n,\ x \in S_i\}$, de cardinalidade s. O algoritmo escolhe S_i com probabilidade $|S_i|/s$ e depois $x \in S_i$ com probabilidade $1/|S_i|$. Logo, para todo $(i,x) \in \Omega$,

$$\mathbb{P}[\,(i,x)\,] = \frac{|S_i|}{s}\cdot\frac{1}{|S_i|} = \frac{1}{s},$$

ou seja, o par (i,x) é sorteado uniformemente em Ω, e $X = s/\mathrm{cob}(x)$ é função desse par.

Esperança:

$$\mathbb{E}X = \sum_{i=1}^n \sum_{x\in S_i} \frac{1}{s}\cdot\frac{s}{\mathrm{cob}(x)} = \sum_{i=1}^n \sum_{x\in S_i} \frac{1}{\mathrm{cob}(x)} = \sum_{x\in U} \sum_{i\,:\,x\in S_i} \frac{1}{\mathrm{cob}(x)} = \sum_{x\in U} \frac{\mathrm{cob}(x)}{\mathrm{cob}(x)} = |U|.$$

Variância:

$$\mathbb{E}X^2 = \sum_{i=1}^n \sum_{x\in S_i} \frac{1}{s}\cdot\frac{s^2}{\mathrm{cob}(x)^2} = s\sum_{x\in U}\frac{\mathrm{cob}(x)}{\mathrm{cob}(x)^2} = s\sum_{x\in U}\frac{1}{\mathrm{cob}(x)} \leqslant s\,|U| \leqslant n\,|U|^2,$$

pois $\mathrm{cob}(x) \geqslant 1$ e $s \leqslant n|U|$. Portanto

$$\mathrm{Var}(\,X\,) = \mathbb{E}X^2 - (\mathbb{E}X)^2 \leqslant n|U|^2 - |U|^2 = (n-1)\,(\mathbb{E}X)^2.$$

32. Seja $V = \mathbb{E}X = |U|$ (Exercício 2) e $\mu = V/s$.

(a) Seja $Z_i = X_i/s$. Os Z_i são independentes, e $Z_i = 1/\mathrm{cob}(x_i) \in [1/n, 1] \subseteq [0,1]$, com $\mathbb{E}Z_i = V/s = \mu$. Como $s \leqslant nV$, temos $\mu \geqslant 1/n > 0$. Além disso, $\overline{X}_m = s\,\overline{Z}_m$ e $V = s\mu$, de modo que

$$|\overline{X}_m - V| \geqslant \varepsilon V \iff |\overline{Z}_m - \mu| \geqslant \varepsilon\mu.$$

Pelo Exercício 1, se $m \geqslant 3\ln(2/\delta)/(\varepsilon^2\mu)$, essa probabilidade é no máximo δ. Como $\mu \geq 1/n$, basta

$$m \;\geqslant\; \frac{3n\ln(2/\delta)}{\varepsilon^2}.$$

Finalmente, para $n \geq 3$ vale $3n \leqslant \frac{9}{2}(n-1)$ (equivale a $\frac{3}{2}n \geqslant \frac{9}{2}$). Logo $m \geqslant \frac{9}{2}(n-1)\varepsilon^{-2}\ln(2/\delta)$ implica a condição acima, e passando ao complementar $\overline{X}_m$ é uma (ε,δ)-aproximação para V.

(b) Pela linearidade, $\mathbb{E}\overline{X}_m = V$; pela independência e pelo Exercício 2,

$$\operatorname{Var}(\overline{X}_m) = \frac{\operatorname{Var}(X)}{m} \leqslant \frac{(n-1)V^2}{m}.$$

Pela desigualdade de Chebyshev,

$$\mathbb{P}\Big[\,\Big|\overline{X}_m - V\Big| \geqslant \varepsilon V\,\Big] \leqslant \frac{\operatorname{Var}(\overline{X}_m)}{\varepsilon^2 V^2} \leqslant \frac{n-1}{m\,\varepsilon^2}.$$

Se $m \geqslant (n-1)/(\varepsilon^2\delta)$, a probabilidade é no máximo δ, e passando ao complementar $\overline{X}_m$ é uma (ε,δ)-aproximação para V.

33. (a) Com $\delta = 1/4$ em (b), basta $m_0 \geqslant 4(n-1)/\varepsilon^2$; logo a média de $m_0 = \lceil 4(n-1)/\varepsilon^2 \rceil$ rodadas é uma $(\varepsilon, 1/4)$-aproximação, isto é, cada Y_j é ruim com probabilidade $p \leqslant 1/4$.

(b) Se $N < k/2$, mais da metade dos Y_j pertence ao intervalo $[(1-\varepsilon)V, (1+\varepsilon)V]$. Como a mediana de k números tem pelo menos metade deles de cada lado (inclusive ela mesma), ela também pertence a esse intervalo, pois um intervalo contendo mais da metade dos valores contém a mediana. Logo $|Y - V| \leqslant \varepsilon V$.

(c) Os indicadores de "Y_j ruim" são independentes, e $\mathbb{E}N = kp \leqslant k/4$. O limitante de Chernoff para a cauda superior, $\mathbb{P}[\,N \geqslant (1+\gamma)\nu\,] \leqslant e^{-\gamma^2\nu/3}$ para $0 < \gamma \leqslant 1$ e qualquer $\nu \geqslant \mathbb{E}N$, aplicado com $\nu = k/4$ e $\gamma = 1$, dá

$$\mathbb{P}[\,N \geqslant k/2\,] \leqslant e^{-k/12}.$$

Se $k \geq 12\ln(1/\delta)$, isso é no máximo δ; por (ii), $\mathbb{P}[\,|Y - V| \leqslant \varepsilon V\,] \geq 1 - \delta$. O número total de rodadas é

$$k\,m_0 \;\leqslant\; 12\ln(1/\delta)\cdot\left(\frac{4(n-1)}{\varepsilon^2} + 1\right) = O\left(\frac{n}{\varepsilon^2}\ln\frac{1}{\delta}\right).$$

34. Para $\varepsilon = 1/2$, o intervalo desejado é $[n/4,\ 3n/4]$.

Algoritmo. Se $n < 6$, ordene o vetor inteiro (tempo $O(1)$) e devolva a mediana exata. Caso contrário:

(a) Seja $k = \lceil 64\ln n \rceil$.

(b) Sorteie k índices $i_1, \ldots, i_k$ independentemente e uniformemente em $\{1, \ldots, n\}$ (amostragem com reposição) e forme a amostra $S = (A[i_1], \ldots, A[i_k])$.

(c) Ordene S (por exemplo, com *mergesort*).

(d) Devolva o elemento na posição $m = \lceil k/2 \rceil$ de S ordenada.

Tempo de execução. O sorteio e a leitura dos k elementos custam $O(k)$, supondo acesso aleatório ao vetor em tempo $O(1)$. A ordenação custa $O(k \log k)$. Como $k = O(\log n)$, temos $\log k = O(\log \log n)$ e o tempo total é

$$O(k \log k) = O(\log n \ \log \log n).$$

Corretude. Usaremos a desigualdade de Chernoff–Hoeffding: se $X = X_1 + \cdots + X_k$ é soma de variáveis aleatórias independentes com valores em $\{0, 1\}$, então, para todo $t > 0$,

$$\mathbb{P}[X - \mathbb{E}[X] \geq t] \leq e^{-2t^2/k}.$$

Seja $n \geq 6$. Chamamos de *baixos* os elementos de posto $< n/4$ e de *altos* os de posto $> 3n/4$. O algoritmo só erra se o elemento devolvido for baixo ou alto.

Há menos de $n/4$ elementos baixos. Os altos têm postos $\lfloor 3n/4 \rfloor + 1, \ldots, n$, e sua quantidade é $n - \lfloor 3n/4 \rfloor = \lceil n/4 \rceil \leq n/4 + 3/4$. Em ambos os casos, a fração p de elementos ruins satisfaz

$$p \ \leq \ \frac{1}{4} + \frac{3}{4n} \ \leq \ \frac{1}{4} + \frac{1}{8} = \frac{3}{8},$$

pois $n \geq 6$.

Erro por elemento baixo. Se o elemento na posição m da amostra ordenada é baixo, então todos os elementos nas posições $1, \ldots, m$ também são baixos (têm posto menor ou igual). Logo a amostra contém pelo menos $m \geq k/2$ elementos baixos.

Erro por elemento alto. Se o elemento na posição m é alto, então todos os das posições $m, \ldots, k$ são altos, o que dá $k - m + 1 = \lfloor k/2 \rfloor + 1 > k/2$ elementos altos na amostra.

Em cada caso, seja X o número de elementos ruins do tipo em questão (baixos ou altos) na amostra. Os sorteios são independentes, então $X = \sum_{j=1}^{k} X_j$ com X_j indicadoras independentes, e $\mathbb{E}[X] \leq 3k/8$. O erro implica $X \geq k/2$, logo $X - \mathbb{E}[X] \geq k/2 - 3k/8 = k/8$. Por Hoeffding,

$$\mathbb{P}[X \geq k/2] \ \leq \ \exp\Big(-\frac{2(k/8)^2}{k}\Big) = e^{-k/32} \ \leq \ e^{-2\ln n} = n^{-2},$$

pois $k \geq 64 \ln n$.

Pela cota da união sobre os dois tipos de erro, a probabilidade de o algoritmo devolver um elemento fora de $[n/4, 3n/4]$ é no máximo $n^{-2} + n^{-2} = 2n^{-2}$. Para $n < 6$ o algoritmo é determinístico e correto.

35.

36.

37. Cada elemento x dos n elementos da lista tem altura $h(x)$ igual ao número de caras antes da primeira coroa numa sequência de lançamentos de moeda justa, e as alturas dos elementos são independentes. Assim, para todo inteiro $k \geq 0$,

$$\mathbb{P}[\, h(x) \geq k \,] = 2^{-k},$$

e $H = \max_x h(x)$.

Seja $t = 100 \log_2 n$. Como $h(x)$ é inteiro, $h(x) > t$ equivale a $h(x) \geq \lfloor t \rfloor + 1$. Logo

$$\mathbb{P}[\, h(x) > t \,] = 2^{-(\lfloor t \rfloor + 1)} \leq 2^{-t} = 2^{-100 \log_2 n} = n^{-100},$$

pois $\lfloor t \rfloor + 1 > t$.

O evento $\{H > t\}$ ocorre se, e somente se, existe um elemento x com $h(x) > t$. Pela cota da união,

$$\mathbb{P}\left[\, H > 100 \log_2 n \,\right] \leq \sum_x \mathbb{P}[\, h(x) > t \,] \leq n \cdot n^{-100} = \frac{1}{n^{99}}.$$

38. Como $X_0 = 0$, o contador sobe com probabilidade $2^0 = 1$ no primeiro item, logo $X_1 = 1$ com probabilidade 1.

$m = 2$. Dado $X_1 = 1$, o contador sobe com probabilidade $1/2$. Então

$$\mathbb{P}[\, X_2 = 1 \,] = \frac{1}{2}, \qquad \mathbb{P}[\, X_2 = 2 \,] = \frac{1}{2}.$$

Os valores de 2^{X_2} são 2 e 4, e a saída $\hat{m} = 2^{X_2} - 1$ vale 1 ou 3, cada uma com probabilidade $1/2$. Logo

$$\mathbb{E}2^{X_2} = \frac{2+4}{2} = 3, \qquad \mathbb{E}\hat{m} = 2, \qquad \mathrm{Var}(\,\hat{m}\,) = \frac{(1-2)^2 + (3-2)^2}{2} = 1.$$

$m = 3$. A partir de $X_2 = 1$ (probabilidade $1/2$) o contador sobe com probabilidade $1/2$; a partir de $X_2 = 2$ (probabilidade $1/2$) sobe com probabilidade $1/4$. Assim

$$\mathbb{P}[\, X_3 = 1 \,] = \frac{1}{2} \cdot \frac{1}{2} = \frac{1}{4}, \quad \mathbb{P}[\, X_3 = 2 \,] = \frac{1}{2} \cdot \frac{1}{2} + \frac{1}{2} \cdot \frac{3}{4} = \frac{5}{8}, \quad \mathbb{P}[\, X_3 = 3 \,] = \frac{1}{2} \cdot \frac{1}{4} = \frac{1}{8},$$

e a soma é 1. A saída vale $1, 3, 7$ com essas probabilidades. Então

$$\mathbb{E}2^{X_3} = \frac{2}{4} + \frac{4\cdot 5}{8} + \frac{8}{8} = 4, \qquad \mathbb{E}\hat{m} = \frac{1}{4} + \frac{15}{8} + \frac{7}{8} = 3,$$

$$\mathbb{E}\hat{m}^2 = \frac{1}{4} + \frac{9\cdot 5}{8} + \frac{49}{8} = 12, \qquad \mathrm{Var}(\,\hat{m}\,) = 12 - 3^2 = 3.$$

Isso coincide com $\mathbb{E}2^{X_m} = m+1$ e $\mathrm{Var}(\,\hat{m}\,) = m(m-1)/2$ para $m = 2, 3$.

39. Seja $b \coloneqq 1+\alpha$, $\alpha > 0$. Dado $X_{i-1} = j$, o contador sobe com probabilidade b^{-j}, e para f qualquer $\mathbb{E}f(X_i) = \mathbb{E}g_f(X_{i-1})$ com $g_f(j) = (1-b^{-j})f(j) + b^{-j}f(j+1)$.

Esperança. Para $f(j) = b^j$,

$$g_f(j) = b^j - 1 + b = b^j + \alpha.$$

Logo $\mathbb{E}b^{X_m} = \mathbb{E}b^{X_{m-1}} + \alpha$ e, como $\mathbb{E}b^{X_0} = 1$, $\mathbb{E}b^{X_m} = 1 + \alpha m$. Portanto $\mathbb{E}\hat{m} = (\mathbb{E}b^{X_m} - 1)/\alpha = m$.

Variância. Para $f(j) = b^{2j}$,

$$g_f(j) = b^{2j} - b^j + b^{j+2} = b^{2j} + (b^2-1)\,b^j = b^{2j} + \alpha(2+\alpha)\,b^j.$$

Então $\mathbb{E}b^{2X_m} = \mathbb{E}b^{2X_{m-1}} + \alpha(2+\alpha)\big(1+\alpha(m-1)\big)$, e, somando de 1 a m,

$$\mathbb{E}b^{2X_m} = 1 + \alpha(2+\alpha)\Big(m + \alpha\frac{m(m-1)}{2}\Big).$$

Subtraindo $(\mathbb{E}b^{X_m})^2 = (1+\alpha m)^2 = 1 + 2\alpha m + \alpha^2 m^2$,

$$\begin{aligned}\mathrm{Var}(\,b^{X_m}\,) &= \alpha^2 m + \alpha^2(2+\alpha)\frac{m(m-1)}{2} - \alpha^2 m^2 \\ &= \alpha^2\Big[-m(m-1) + (2+\alpha)\frac{m(m-1)}{2}\Big] = \alpha^3\,\frac{m(m-1)}{2}.\end{aligned}$$

Como $\hat{m} = (b^{X_m}-1)/\alpha$, vale $\mathrm{Var}(\,\hat{m}\,) = \mathrm{Var}(\,b^{X_m}\,)/\alpha^2 = \alpha\, m(m-1)/2$. (Para $\alpha = 1$ recuperamos o algoritmo original.)

Chebyshev. Para $m \geqslant 1$,

$$\mathbb{P}[\,|\,\hat{m} - m\,| \geqslant \varepsilon m\,] \leqslant \frac{\alpha\, m(m-1)/2}{\varepsilon^2 m^2} \leqslant \frac{\alpha}{2\varepsilon^2}.$$

Com $\alpha = 2\varepsilon^2\delta$ a probabilidade é $\leqslant \delta$, logo $\hat{m}$ é uma (ε,δ)-aproximação, sem cópias paralelas.

Espaço. Por Markov, $X_m < \log_b \frac{1+\alpha m}{\delta'}$ com probabilidade $\geqslant 1-\delta'$. Como $\ln(1+\alpha) \geqslant \alpha/2$ para $\alpha \in (0,2]$, isso dá $X_m \leqslant \frac{2}{\alpha}\ln\frac{1+\alpha m}{\delta'}$, e o contador cabe em $O\big(\log\frac{1}{\alpha} + \log\log m + \log\log\frac{1}{\delta'}\big)$ bits. Com $\alpha = 2\varepsilon^2\delta$ e $\delta' = \delta/2$:

$$O\Big(\log\frac{1}{\varepsilon} + \log\frac{1}{\delta} + \log\log m\Big)$$

bits, contra $O(\varepsilon^{-2}\delta^{-1}\log\log m)$ do truque da média.

40.

41.

42.

Referências Bibliográficas

Robert G. Bartle. *The elements of real analysis*. John Wiley & Sons, New York-London-Sydney, second edition, 1976.

Sheldon Ross. *Probabilidade: Um Curso Moderno com Aplicações*. Porto Alegre: Bookman, 8.º ed., 2010.

Walter Rudin. *Principles of Mathematical Analysis*. International Series in Pure and Applied Mathematics. McGraw-Hill, New York, 3rd edition, 1976.

Devdatt Dubhashi e Alessandro Panconesi. *Concentration of Measure for the Analysis of Randomized Algorithms*. Cambridge: Cambridge University Press, 2009.

Juraj Hromkovic. *Design and Analysis of Randomized Algorithms: Introduction to Design Paradigms*. Berlin: Springer, 2005. (online)

Sanjeev Arora e Boaz Barak. *Computational Complexity: A Modern Approach*. Cambridge: Cambridge University Press, 2009.

Avrim Blum, John Hopcroft e Ravindran Kannan. *Foundations of Data Science*. Cambridge: Cambridge University Press, 2020. (online)

Roman Vershynin. *High-Dimensional Probability: An Introduction with Applications in Data Science*. Cambridge: Cambridge University Press, 2018. (online, soluções)

Olle Häggström. *Finite Markov Chains and Algorithmic Applications*. Cambridge: Cambridge University Press, 2002.

Michael Mitzenmacher e Eli Upfal. *Probability and Computing: Randomized Algorithms and Probabilistic Analysis*. Cambridge: Cambridge University Press, 2005.

Rajeev Motwani e Prabhakar Raghavan. *Randomized Algorithms*. Cambridge: Cambridge University Press, 1995.

Thomas H. Cormen, Charles E. Leiserson, Ronald L. Rivest e Clifford Stein. *Introduction to Algorithms*. 3rd ed. Cambridge: MIT Press, 2009.

Patrick Billingsley. *Probability and Measure*. 3rd. ed. New York: John Wiley & Sons, 1995.

Donald E. Knuth. *The Art of Computer Programming, Volume 3: Sorting and Searching*. Addison-Wesley, Reading, Massachusetts, 2nd edition, 1998.

Robert Sedgewick. *The Analysis of Quicksort Programs*. Acta Informatica 7(4), 327–355, 1977.

Robert Sedgewick and Philippe Flajolet. *An Introduction to the Analysis of Algorithms*. Addison-Wesley, Reading, Massachusetts, 1996.

Vasileios Iliopoulos and David Penman. *Variance of the number of Comparisons of Randomized Quicksort*. arXiv 1006.4063, 2010. https://arxiv.org/abs/1006.4063.

Sergei Bernstein. *On a modification of Chebyshev's inequality and of the error formula of Laplace*. Ann. Sci. Inst. Sav. Ukraine, Sect. Math, 1(4), 38–49, 1924.

Herman Chernoff. *A Measure of Asymptotic Efficiency for Tests of a Hypothesis Based on the sum of Observations*. The Annals of Mathematical Statistics, 23(4), 493 – 507, 1952.

Herman Chernoff. *A career in statistics* em Past, Present, and Future of Statistical Science. Ed. Lin, X. and Genest, C. and Banks, D.L. and Molenberghs, G. and Scott, D.W. and Wang, J.L.. CRC Press, pages = 29–40, 2014.

Wassily Hoeffding. *Probability inequalities for sums of bounded random variables*. The collected works of Wassily Hoeffding, 409–426, Springer, 1994.

William Pugh. *Skip lists: a probabilistic alternative to balanced trees*. Algorithms and data structures (Ottawa, ON, 1989), Lecture Notes in Comput. Sci., 382, 437–449, Springer 1989.

Richard M. Karp e Michael Luby. *Monte-Carlo algorithms for enumeration and reliability problems*, Foundations of Computer Science, IEEE Annual Symposium on, 56–64, 1983.

Jean Vuillemin. *A unifying look at data structures*. Commun. ACM, 23(4), 1980, 229–239.

Robert Morris. *Counting large numbers of events in small registers*. Communications of the ACM, 21(10), 840–842, 1978.

J. Lawrence Carter and Mark N. Wegman. *Universal classes of hashing functions*. Journal of Computer and System Science, 18, 143–154, 1979.

Noam Nisan. *Pseudorandom generators for space-bounded computation*. Combinatorica, 12(4), 449–461, 1992.

Ronald L. Graham e Donald E. Knuth e Oren Patashnik. *Concrete mathematics*, 2nd Ed. Addison-Wesley, 1994.

Johan Håstad. *Some Optimal Inapproximability Results*. J. ACM, 48(4), 2001.

Michel X. Goemans e David P. Williamson. *Improved Approximation Algorithms for Maximum Cut and Satisfiability Problems Using Semidefinite Programming*. Journal of the ACM, 42(6), 1115–1145, 1995.

Pafnuty L. Tchebichef. *Mémoire sur les nombres premiers*. Journal de mathématiques pures et appliquées, 17, 366–390, 1852.

Sanjeev Arora e Boaz Barak. *Computational complexity. A modern approach*. Cambridge University Press, Cambridge, 2009.

Burton H. Bloom. *Space/Time Trade-offs in Hash Coding with Allowable Errors*. Communications of the ACM, 13(7), 422–426, 1970.

Índice Remissivo

(ε, δ)-aproximação, 127
$X \sim \text{Geom}(p)$, 32
$X \sim \text{Poisson}(\lambda)$, 62
$X(\Omega)$, 29
$X \sim \text{Bernoulli}(p)$, 31
$X \sim \text{Binomial}(n, p)$, 32
α-aproximação, 163
$[X = a]$, 30
$[X \in A]$, 31
$[X \leqslant a]$, 31
ε-quase universal, 172
$\text{BN}(r, p)$, 44
k-a-k independente, 17
k-ésimo momento, 88
k-ésimo momento central, 88
σ-álgebra de subconjuntos de Ω, 7
$X \stackrel{d}{=} Y$, 63
2-independente, 162
2-universal, 159

A probabilidade do complemento, 8
Aditividade enumerável, 7
Aditividade finita:, 8
Algoritmos Las Vegas, 27
Algoritmos Monte Carlo, 19
altura da *skip list*, 113
altura de x, 113

caminho alternado, 180
caminho aumentante, 180
carga, 138
circuito algébrico, 181
complexidade de comunicação, 171
continuidade da medida de probabilidade, 23
converge, 187
converge absolutamente, 187

desigualdade de Bienaymé–Chebyshev, 75
desigualdade de Chebyshev, 75
desigualdade de Jensen, 56
desigualdade de Markov, 72
desvio padrão, 76
distribuição, 31
distribuição binomial, 32
distribuição binomial negativa, 43
distribuição de Bernoulli, 31
distribuição de Poisson, 62
distribuição de Rademacher, 90
distribuição geométrica, 32

eficiente, 182
emparelhamento perfeito, 179
ensaio de Bernoulli, 31
escolha aleatória uniforme, 9
espaço amostral, 7
espaço de probabilidade, 7
espaço de probabilidade discreto, 10
esperança, 33
esperança condicional, 70

evento impossível, 8
eventos independentes, 16

falso negativo, 151
falso positivo, 151
filtro de Bloom, 151
fluxo, 125
fortemente 2-universal, 162
fracamente k-universal, 156
função de *hash*, 136
função geradora de cumulantes, 92
função geradora de momentos, 88, 89
função massa de probabilidade, 10

iguais em distribuição, 63
independentes, 32

lei, 31
lema de Schwartz–Zippel, 183
lista do nível 0, 111
lista do nível $i + 1$, 111

medida de probabilidade, 7
modelo probabilístico discreto, 10
Monotonicidade, 8
monótona, 23
mutuamente independente, 17
mutuamente independentes, 33

Normalização, 7
Não-negatividade, 7

paradoxo dos aniversários, 141
perfeita, 147
portas, 181
posto, 67
probabilidade condicional, 13
probabilidade de A dado E, 13
probabilidade uniforme, 9

Regra da adição, 8
regra do produto, 13

skip list, 111
streaming, 125
Subaditividade, 8

tabela de espalhamento, 136
tabela hashing, 136
teorema da multiplicação, 13
treap, 120
Truque da mediana, 110

uniforme em $[a, b]$, 52
universal, 144

valor esperado, 33
variável aleatória discreta, 29
variável aleatória indicadora, 29
variância, 88
VP, 182