Desaleatorização:
o método das esperanças condicionais

Aplicações a max-sat e max-cut

Algoritmos Probabilísticos

J.D.

CMCC – UFABC

Motivação

- Muitos algoritmos probabilísticos funcionam bem *na média*.
- Queremos uma garantia *absoluta*: um algoritmo determinístico, sem perder a qualidade da solução.
- **Desaleatorização**: transformar o algoritmo probabilístico em determinístico.
- Ferramenta: **esperança condicional**.

Roteiro

1. Distribuição e esperança condicionais (definições e resultados)
2. O método
3. Aplicação 1: max-sat
4. Aplicação 2: max-cut

Esperança condicional

Esperança condicional dado um evento

Sejam $(\Omega, \mathbb{P})$ um espaço discreto de probabilidade, A um evento com $\mathbb{P}(A) > 0$ e X variável aleatória real integrável (ou não negativa).

Medida condicionada a A

$$\mathbb{P}_A(B) := \mathbb{P}(B \mid A) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(A)}$$

Esperança condicional de X dado A

$$\mathbb{E}[\ X \ \mid \ A\ ] = \sum_r r\, \mathbb{P}(X = r \mid A) = \frac{\mathbb{E}[X \cdot \mathbb{1}_A]}{\mathbb{P}(A)}$$

Propriedades

Se X, Y são integráveis, $\mathbb{P}(A) > 0$, B é um evento e $a, b \in \mathbb{R}$:

1. $\mathbb{E}[\ a \mid A\ ] = a$.
2. $\mathbb{E}[\ \mathbb{1}_B \mid A\ ] = \mathbb{P}(B \mid A)$.
3. Se $X \leqslant Y$ então $\mathbb{E}[\ X \mid A\ ] \leqslant \mathbb{E}[\ Y \mid A\ ]$.
4. $\mathbb{E}[\ aX + bY \mid A\ ] = a\,\mathbb{E}[\ X \mid A\ ] + b\,\mathbb{E}[\ Y \mid A\ ]$ (**linearidade**).
5. Se X e $\mathbb{1}_A$ são independentes, então $\mathbb{E}[\ X \mid A\ ] = \mathbb{E}X$.

Distribuição e esperança condicionais dada uma variável

Suporte
$S_X := \{x \ : \ \mathbb{P}(X = x) > 0\}$. Em Ω discreto, $\mathbb{P}(X \in S_X) = 1$.

Distribuição condicional
Para $x \in S_X$: $\mathbb{P}_{Y|X=x}(y) := \mathbb{P}(Y = y \mid X = x)$.

Esperança condicional de Y dado $X = x$

$$\mathbb{E}[\ Y \mid X = x\ ] = \sum_r r\, \mathbb{P}_{Y|X=x}(r) = \frac{\mathbb{E}[Y \cdot \mathbb{1}_{[X=x]}]}{\mathbb{P}(X = x)}$$

Esperança condicional de Y dado X
Com $\psi(x) := \mathbb{E}[\ Y \mid X = x\ ]$ para $x \in S_X$:

$$\mathbb{E}[\ Y \mid X\ ] := \psi(X) = \sum_{x \in S_X} \mathbb{E}[\ Y \mid X = x\ ]\, \mathbb{1}_{[X=x]}$$

é uma *variável aleatória*.

Lei da Esperança Total

Lei da Esperança Total
Se Y é integrável (ou não negativa), então

$$\mathbb{E}Y = \sum_{x \in S_X} \mathbb{E}[\ Y \mid X = x\ ]\,\mathbb{P}(X = x)$$

e, em particular, $\mathbb{E}[\ Y \mid X\ ]$ *é integrável (se* Y *é) e*

$$\mathbb{E}Y = \mathbb{E}\big[\mathbb{E}[\ Y \mid X\ ]\big] \qquad \text{(lei da esperança iterada).}$$

Lei da Esperança Total
Se Y é integrável (ou não negativa), então

$$\mathbb{E}Y = \sum_{x \in S_X} \mathbb{E}[\ Y \mid X = x\ ]\,\mathbb{P}(X = x)$$

e, em particular, $\mathbb{E}[\ Y \mid X\ ]$ é integrável (se Y é) e

$$\mathbb{E}Y = \mathbb{E}\big[\mathbb{E}[\ Y \mid X\ ]\big] \qquad \text{(lei da esperança iterada).}$$

Tomando $X = \mathbb{1}_A$ e $Y = \mathbb{1}_B$ recuperamos o teorema da probabilidade total:

$$\mathbb{P}(B) = \mathbb{P}(B \mid A)\mathbb{P}(A) + \mathbb{P}(B \mid A^c)\mathbb{P}(A^c).$$

O método das esperanças condicionais

O método das esperanças condicionais: hipóteses

- S conjunto finito e $f : S^n \to \mathbb{R}$ uma função.
- $X_1, \ldots, X_n$ variáveis aleatórias independentes com valores em S, cada elemento de S com probabilidade positiva.
- $Y := f(X_1, \ldots, X_n)$ com $\mathbb{E}Y \geqslant \mu$.

Objetivo: determinar $(x_1, \ldots, x_n) \in S^n$ com $f(x_1, \ldots, x_n) \geqslant \mu$.

Busca exaustiva
Percorrer S^n pode ser ineficiente. O método funciona quando conseguimos calcular *eficientemente* $\mathbb{E}[\ Y \mid X_1 = x_1, \ldots, X_i = x_i\ ]$ para todo i.

O método: o passo

Invariante: já escolhidos $x_1, \ldots, x_i$ tais que

$$\mathbb{E}[\ Y \mid X_1 = x_1, \ldots, X_i = x_i\ ] \geqslant \mu.$$

Para $i = 0$ isso é a hipótese $\mathbb{E}Y \geqslant \mu$.

Pela Lei da Esperança Total,

$$\mathbb{E}\big[\mathbb{E}[\ Y \mid X_1 = x_1, \ldots, X_i = x_i, X_{i+1}\ ]\big] = \mathbb{E}[\ Y \mid X_1 = x_1, \ldots, X_i = x_i\ ] \geqslant \mu.$$

O lado esquerdo é uma média, com pesos positivos, dos valores
$\mathbb{E}[\ Y \mid X_1 = x_1, \ldots, X_i = x_i, X_{i+1} = r\ ]$, $r \in S$.

Consequência (primeiro momento)
Existe $r \in S$ com $\mathbb{E}[\ Y \mid X_1 = x_1, \ldots, X_i = x_i, X_{i+1} = r\ ] \geqslant \mu$. Fazemos $x_{i+1} := r$: o invariante vale para $i + 1$.

O método: o algoritmo

1. **para** $i = 0, 1, \ldots, n-1$:
   1.1 para cada $r \in S$, calcule $\mathbb{E}[\ Y \mid X_1 = x_1, \ldots, X_i = x_i, X_{i+1} = r\ ]$;
   1.2 escolha $x_{i+1} := r$ com valor $\geqslant \mu$.
2. **devolva** $(x_1, \ldots, x_n)$.

Ao final,

$$f(x_1, \ldots, x_n) = \mathbb{E}[\ Y \mid X_1 = x_1, \ldots, X_n = x_n\ ] \geqslant \mu.$$

Nas aplicações abaixo: $S = \{0, 1\}$ e $(X_1, \ldots, X_n)$ uniforme em $\{0, 1\}^n$.

MAX-SAT

max-sat: o problema

Entrada: fórmula 3-CNF $\mathcal{C} = \{C_1, \ldots, C_m\}$ sobre $v_1, \ldots, v_n$, cada cláusula com três literais de variáveis *distintas*.

Objetivo: valoração $(x_1, \ldots, x_n) \in \{0,1\}^n$ que satisfaça pelo menos $7/8$ das cláusulas.

Algoritmo aleatorizado: sortear a valoração uniformemente em $\{0,1\}^n$ até obter uma com a propriedade desejada.

Modelagem

- $X_1, \ldots, X_n$ independentes, uniformes em $\{0,1\}$;
- $f(x_1, \ldots, x_n) =$ número de cláusulas satisfeitas por $v_i \mapsto x_i$;
- $Y = f(X_1, \ldots, X_n)$ e $\mathbb{E}Y = \dfrac{7m}{8}$ (logo, $\mu = 7m/8$).

max-sat: calculando as esperanças condicionais

Dados $x_1, \ldots, x_i$ satisfazendo $(*)$, para $r = 0, 1$ precisamos de

$$\mathbb{E}[\ Y \mid X_1 = x_1, \ldots, X_i = x_i, X_{i+1} = r\ ] = \sum_{j=1}^{m} \mathbb{E}\Big[\ \mathbb{1}_{[C_j=1]} \ \Big|\ X_1 = x_1, \ldots, X_i = x_i, X_{i+1} = r\ \Big].$$

Variável *fixada* = índice $\leqslant i+1$; k = nº de variáveis de C_j não fixadas. Cada termo vale:

1. 1, se algum literal fixado de C_j já a satisfaz;
2. $1 - 2^{-k}$, caso contrário (C_j fica falsa só se as k variáveis restantes, independentes e uniformes, falsificam seus literais).

Em particular, $7/8,\ 3/4,\ 1/2,\ 0$ para $k = 3, 2, 1, 0$.

max-sat: escolha e custo

- Cada termo é avaliado em tempo constante; a soma, em $O(m)$.
- Após as somas para $r = 0$ e $r = 1$, escolhemos x_{i+1} com esperança condicional $\geqslant 7m/8$ (a Lei da Esperança Total garante que um dos dois serve).
- Ao final dos n passos: valoração que satisfaz $\geqslant 7m/8$ cláusulas, com custo total $O(nm)$.

Melhoria para $O(n + m)$
Ao fixar $X_{i+1} = r$, só mudam as cláusulas que contêm v_{i+1}. Mantendo, para cada variável, a lista das cláusulas em que ocorre e, para cada cláusula, o nº de variáveis não fixadas e se já está satisfeita, cada cláusula é examinada no máximo 3 vezes. Custo total $O(n + m)$ (listas construídas em $O(n + m)$).

MAX-CUT

max-cut: o problema

Entrada: grafo $G = (V, E)$, $V = \{1, \ldots, n\}$, com m arestas.

Objetivo: corte com pelo menos metade das arestas.

Algoritmo aleatorizado: sorteia $(x_1, \ldots, x_n) \in \{0,1\}^n$, forma $S = \{i \in V : x_i = 1\}$ e, se $|\nabla(S)| \geqslant m/2$, termina; senão repete o sorteio.

Modelagem

- $f(x_1, \ldots, x_n) := |\nabla(S)|$, com $(x_1, \ldots, x_n)$ o vetor característico de S;
- $X_1, \ldots, X_n$ independentes, uniformes em $\{0,1\}$ e $Y = f(X_1, \ldots, X_n)$;
- $\mathbb{E}Y \geqslant m/2$ (logo, $\mu = m/2$).

max-cut: calculando as esperanças condicionais

Vértice *decidido* = índice $\leqslant i+1$. Pela linearidade,

$$\mathbb{E}[\, Y \mid X_1 = x_1, \ldots, X_i = x_i, X_{i+1} = r \,] = \sum_{jk \in E} \mathbb{E}\big[\, \mathbb{1}_{[jk \in \nabla(S)]} \;\big|\; X_1 = x_1, \ldots, X_i = x_i, X_{i+1} = r \,\big].$$

Cada termo:

max-cut: calculando as esperanças condicionais

Vértice *decidido* = índice $\leqslant i+1$. Pela linearidade,

$$\mathbb{E}[\ Y \mid X_1 = x_1, \ldots, X_i = x_i, X_{i+1} = r\ ] = \sum_{jk \in E} \mathbb{E}\big[\ \mathbb{1}_{[jk \in \nabla(S)]} \ \big|\ X_1 = x_1, \ldots, X_i = x_i, X_{i+1} = r\ \big].$$

Cada termo:

1. se j e k estão decididos: vale 1 se $\{j,k\} \in \nabla(S)$ e 0 caso contrário;
2. se algum extremo não está decidido: vale $1/2$ (a aresta está no corte se, e só se, o extremo não decidido, uniforme e independente dos demais, assume o valor oposto).

max-cut: escolha e custo

- Cada esperança condicional é calculada em $O(m)$.
- Dois cálculos por passo ($r = 0, 1$) e n passos: obtemos S com $|\nabla(S)| \geqslant m/2$ em tempo total $O(nm)$.
- Algoritmo determinístico, de custo polinomial, sem repetir sorteios.

Melhoria para $O(n + m)$
Ao decidir o vértice $i + 1$, só mudam os termos das arestas incidentes a $i + 1$; as demais contribuem igualmente para $r = 0$ e $r = 1$. Com listas de adjacência, cada aresta é examinada no máximo duas vezes (uma por extremo). Custo total $O(n + m)$.

Resumo

- **Ideia:** manter o invariante $\mathbb{E}[\ Y \mid X_1 = x_1, \ldots, X_i = x_i\ ] \geqslant \mu$ e fixar uma variável por vez.
- **Por que funciona:** Lei da Esperança Total $\Rightarrow$ alguma escolha de r não piora a esperança.
- **Requisito:** calcular eficientemente as esperanças condicionais.

Problema	μ	Cada esperança	Custo total
max-sat (3-CNF)	$7m/8$	$O(m)$	$O(nm)$, ou $O(n+m)$
max-cut	$m/2$	$O(m)$	$O(nm)$, ou $O(n+m)$