Hashing: funções aleatórias e colisões

J. D.

UFABC

Outubro 23, 2026

Roteiro

1. **Funções de hash** e por que precisamos de aleatoriedade
2. **Tabelas de espalhamento** e custo de busca com função aleatória
3. **A maior lista**: cota $O(\log n / \log \log n)$
4. **Paradoxo dos aniversários** e o limiar $\sqrt{n}$
5. **Variância** e independência par a par
6. **Síntese**: o que basta para famílias universais

Fio condutor

Uma função totalmente aleatória espalha bem, mas não tem descrição curta.
Quais propriedades dela *realmente* usamos?

O que é uma função de hash?

Definição 1

Uma função de hash é uma função $h\colon U \to N$, onde o universo U é *muito grande* e $N = \{0, 1, \ldots, n-1\}$.

- $h(x)$ é um "resumo" de x: ocupa pouco espaço, é comparável e serve de índice em tempo constante.
- Como $|U| \gg |N|$, há colisões: $x \neq y$ com $h(x) = h(y)$. Pelo princípio da casa dos pombos, não dá para evitá-las.

O que é uma função de hash?

Definição 1

Uma função de hash é uma função $h\colon U \to N$, onde o universo U é *muito grande* e $N = \{0, 1, \ldots, n-1\}$.

- $h(x)$ é um "resumo" de x: ocupa pouco espaço, é comparável e serve de índice em tempo constante.
- Como $|U| \gg |N|$, há colisões: $x \neq y$ com $h(x) = h(y)$. Pelo princípio da casa dos pombos, não dá para evitá-las.

Usos: dicionários (tabelas de espalhamento), impressões digitais e verificação de igualdade, desaleatorização, criptografia (exige mais: colisões difíceis de achar).

Foco desta aula

Propriedades *probabilísticas* de famílias de funções.

O que torna uma função de hash útil?

Não é ser injetora. São propriedades que dependem do uso:

(i) **fácil de computar**: $h(x)$ em tempo (quase) constante;

(ii) **descrição curta**: poucos bits para armazenar h;

(iii) **espalhar bem** os elementos de um conjunto $S \subseteq U$: valores $h(x)$, $x \in S$, aproximadamente uniformes em N, poucas colisões.

O que torna uma função de hash útil?

Não é ser injetora. São propriedades que dependem do uso:

(i) **fácil de computar**: $h(x)$ em tempo (quase) constante;

(ii) **descrição curta**: poucos bits para armazenar h;

(iii) **espalhar bem** os elementos de um conjunto $S \subseteq U$: valores $h(x)$, $x \in S$, aproximadamente uniformes em N, poucas colisões.

O problema com (iii)

Para *qualquer* h fixa, existe S em que todos colidem: basta escolher $m := |S|$ elementos numa mesma pré-imagem (tem tamanho $\geq |U|/n$). Nenhuma h determinística espalha bem *todos* os conjuntos.

O que torna uma função de hash útil?

Não é ser injetora. São propriedades que dependem do uso:

(i) **fácil de computar**: $h(x)$ em tempo (quase) constante;

(ii) **descrição curta**: poucos bits para armazenar h;

(iii) **espalhar bem** os elementos de um conjunto $S \subseteq U$: valores $h(x)$, $x \in S$, aproximadamente uniformes em N, poucas colisões.

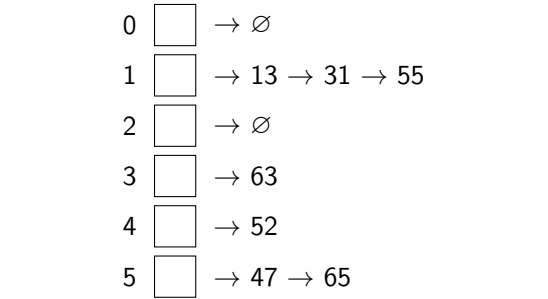
O problema com (iii)

Para *qualquer* h fixa, existe S em que todos colidem: basta escolher $m := |S|$ elementos numa mesma pré-imagem (tem tamanho $\geq |U|/n$). Nenhuma h determinística espalha bem *todos* os conjuntos.

Saída: sortear h de uma família $\mathcal{H}$ e analisar o comportamento *esperado*, ou com alta probabilidade, para qualquer S *fixo*.

Tabela de espalhamento (com listas ligadas)

- Vetor H com n posições; cada $H[i]$ é uma lista ligada.
- Acesso via $h\colon U \to \{0, 1, \ldots, n-1\}$: o elemento x vive na lista $H[h(x)]$.
- $S \subseteq U$ com $m = |S|$; o caso interessante é $m = \Theta(n)$.
- Um vetor de bits de tamanho $|U|$ daria busca $O(1)$, mas é inviável.



$S = \{13, 31, 47, 52, 55, 63, 65\}$, $h(x) = x \bmod 6$

Operações e custos

Inserção colocar x no início de $H[h(x)]$: custo constante.

Remoção (com apontador para x) retirar da lista: custo constante.

Busca percorrer a lista $H[h(x)]$. Pode ser *com sucesso* ($x \in S$) ou *sem sucesso* ($x \notin S$).

Operações e custos

Inserção colocar x no início de $H[h(x)]$: custo constante.

Remoção (com apontador para x) retirar da lista: custo constante.

Busca percorrer a lista $H[h(x)]$. Pode ser *com sucesso* ($x \in S$) ou *sem sucesso* ($x \notin S$).

Quem manda no desempenho?

O pior caso da busca é o tamanho da maior lista. Tudo se reduz a entender os tamanhos das listas, que dependem de como h distribui S.

Operações e custos

Inserção colocar x no início de $H[h(x)]$: custo constante.

Remoção (com apontador para x) retirar da lista: custo constante.

Busca percorrer a lista $H[h(x)]$. Pode ser *com sucesso* ($x \in S$) ou *sem sucesso* ($x \notin S$).

Quem manda no desempenho?

O pior caso da busca é o tamanho da maior lista. Tudo se reduz a entender os tamanhos das listas, que dependem de como h distribui S.

Primeiro modelo: h uniforme em N^U (todas as $n^{|U|}$ funções). Equivale a sortear, *independentemente* para cada $x \in U$, um valor $h(x)$ uniforme em N.

Função aleatória: probabilidade de colisão e carga

Para todo $x \in U$ e $i \in N$: $\mathbb{P}[h(x) = i] = \frac{1}{n}$.

Função aleatória: probabilidade de colisão e carga

Para todo $x \in U$ e $i \in N$: $\quad \mathbb{P}[h(x) = i] = \dfrac{1}{n}$.

Colisão de um par

Para $x \neq y$, por independência,

$$\mathbb{P}[h(x) = h(y)] = \sum_{i \in N} \mathbb{P}[h(x) = i]\, \mathbb{P}[h(y) = i] = n \cdot \frac{1}{n} \cdot \frac{1}{n} = \frac{1}{n}.$$

Função aleatória: probabilidade de colisão e carga

Para todo $x \in U$ e $i \in N$: $\quad \mathbb{P}[h(x) = i] = \dfrac{1}{n}$.

Colisão de um par

Para $x \neq y$, por independência,

$$\mathbb{P}[h(x) = h(y)] = \sum_{i \in N} \mathbb{P}[h(x) = i]\, \mathbb{P}[h(y) = i] = n \cdot \frac{1}{n} \cdot \frac{1}{n} = \frac{1}{n}.$$

Definição 2

A carga da tabela é $c = m/n$, o número esperado de elementos de S por posição.

Tamanho esperado da lista $H[h(x)]$

O número de itens na lista de x é $\sum_{y \in S} \mathbb{1}_{[h(x)=h(y)]}$, e

$$\mathbb{E}\, \mathbb{1}_{[h(x)=h(y)]} = \begin{cases} 1/n, & y \neq x, \\ 1, & y = x. \end{cases}$$

Tamanho esperado da lista $H[h(x)]$

O número de itens na lista de x é $\sum_{y \in S} \mathbb{1}_{[h(x)=h(y)]}$, e

$$\mathbb{E}\, \mathbb{1}_{[h(x)=h(y)]} = \begin{cases} 1/n, & y \neq x, \\ 1, & y = x. \end{cases}$$

Pela linearidade da esperança,

$$\mathbb{E}\left|H[h(x)]\right| = \begin{cases} \dfrac{m}{n} = c, & x \notin S, \\ \dfrac{m-1}{n} + 1 = c + \left(1 - \dfrac{1}{n}\right), & x \in S. \end{cases}$$

Tamanho esperado da lista $H[h(x)]$

O número de itens na lista de x é $\sum_{y \in S} \mathbb{1}_{[h(x)=h(y)]}$, e

$$\mathbb{E}\, \mathbb{1}_{[h(x)=h(y)]} = \begin{cases} 1/n, & y \neq x, \\ 1, & y = x. \end{cases}$$

Pela linearidade da esperança,

$$\mathbb{E}\left|H[h(x)]\right| = \begin{cases} \dfrac{m}{n} = c, & x \notin S, \\ \dfrac{m-1}{n} + 1 = c + \left(1 - \dfrac{1}{n}\right), & x \in S. \end{cases}$$

Conclusão

Com h aleatória em N^U, o tempo esperado de busca é proporcional à carga $O(1)$ quando $n = \Theta(m)$.

Custo esperado das buscas

Proposição 1

Seja H com n posições e h aleatória; elementos inseridos no início das listas. Então

1. *busca sem sucesso: tempo esperado $c + 1$;*
2. *busca com sucesso: tempo esperado $\frac{c}{2} + 1 - \frac{1}{2n}$.*

Custo esperado das buscas

Proposição 1

Seja H com n posições e h aleatória; elementos inseridos no início das listas. Então

1. *busca sem sucesso: tempo esperado $c + 1$;*
2. *busca com sucesso: tempo esperado $\dfrac{c}{2} + 1 - \dfrac{1}{2n}$.*

Ideia da prova do item 2. Se x foi o i-ésimo inserido, só os $m - i$ elementos inseridos *depois* podem ficar na frente de x; em média $(m - i)/n$ deles colidem com x. Logo

$$\frac{1}{m}\sum_{i=1}^{m}\left(1 + \frac{m-i}{n}\right) = 1 + \frac{m-1}{2n} = 1 + \frac{c}{2} - \frac{1}{2n}.$$

Qual é o problema?

O que ganhamos

- busca esperada $O(1)$;
- maior lista $O(\log m)$ com alta probabilidade (próximo bloco).

O que perdemos

- uma função aleatória em N^U precisa de $\approx |U| \log n$ bits para ser descrita;
- guardar h custa mais que o vetor de bits que queríamos evitar.

Qual é o problema?

O que ganhamos

- busca esperada $O(1)$;
- maior lista $O(\log m)$ com alta probabilidade (próximo bloco).

O que perdemos

- uma função aleatória em N^U precisa de $\approx |U| \log n$ bits para ser descrita;
- guardar h custa mais que o vetor de bits que queríamos evitar.

Pergunta

Das propriedades que usamos até aqui, quais dependem de h ser *totalmente aleatória.*

Vamos acompanhar isso ao longo das próximas análises.

A maior lista é sublogarítmica

Lema 3
Seja $X_i = |\{\, y \in S : h(y) = i \,\}|$, $c \leq 1$ *e* n *suficientemente grande. Então*

$$\mathbb{P}\left[\max_i X_i \;\geq\; \frac{8 \ln n}{\ln \ln n}\right] \;\leq\; \frac{1}{n}.$$

Como $n = \Theta(m)$, a maior lista tem tamanho $O(\log m / \log \log m)$ com probabilidade $\geq 1 - 1/n$.

Prova (1): cota para uma posição

Se $X_i \geq k$, existe $T \subseteq S$, $|T| = k$, com $h(y) = i$ para todo $y \in T$. Pela independência, cada T tem probabilidade n^{-k}. Pela cota da união,

$$\mathbb{P}[X_i \geq k] \leq \binom{m}{k} \frac{1}{n^k} \leq \left(\frac{em}{kn}\right)^k = \left(\frac{ec}{k}\right)^k \leq \left(\frac{e}{k}\right)^k$$

Cota da união sobre as n listas (*não* precisamos que sejam independentes):

$$\mathbb{P}\big[\max_i X_i \geq k\big] \leq n\left(\frac{e}{k}\right)^k = n\, e^{-k(\ln k - 1)} = n\, e^{-\phi(k)}. \qquad (k = k(n)\colon \phi(k) > \ln(n^{-2})?)$$

Prova (1): cota para uma posição

Se $X_i \geq k$, existe $T \subseteq S$, $|T| = k$, com $h(y) = i$ para todo $y \in T$. Pela independência, cada T tem probabilidade n^{-k}. Pela cota da união,

$$\mathbb{P}[X_i \geq k] \leq \binom{m}{k} \frac{1}{n^k} \leq \left(\frac{em}{kn}\right)^k = \left(\frac{ec}{k}\right)^k \leq \left(\frac{e}{k}\right)^k$$

Cota da união sobre as n listas (*não* precisamos que sejam independentes):

$$\mathbb{P}\big[\max_i X_i \geq k\big] \leq n\left(\frac{e}{k}\right)^k = n\, e^{-k(\ln k - 1)} = n\, e^{-\phi(k)}. \qquad (k = k(n)\colon \phi(k) > \ln(n^{-2})?)$$

Queremos k tal que $e^{-k(\ln k - 1)} \leq e^{-2(\ln n)}$ ou seja

$$k \ln k = 2 \ln n$$

Queremos isolar k em termos de n para grandes valores de n.

Estimação de k

Heurística k deve crescer com n, mas de forma muito mais lenta que n (pois k^k cresce super-exponencialmente), testamos um chute educado para k:

$$k = \frac{a \ln n}{f(n)}$$

onde $1 \ll f(n) \ll \ln n$ é alguma função de crescimento lento e a é uma constante.

Calculando $\ln k$

$$k = \frac{a \ln n}{f(n)} \quad \Longrightarrow \quad \ln k = \ln a + \ln(\ln n) - \ln(f(n))$$

Para n grande, o termo dominante em $\ln k$ é $\ln(\ln n)$, logo

$$\ln k \approx \ln \ln n$$

e

$$k \ln k \approx \left(\frac{a \ln n}{f(n)} \right) (\ln \ln n)$$

de volta à estimação da probabilidade

$$\frac{a \ln n \cdot \ln \ln n}{f(n)} \approx 2 \ln n \quad \Longrightarrow \quad \frac{a \ln \ln n}{f(n)} \approx 2 \quad \Longrightarrow \quad f(n) = \Theta(\ln \ln(n))$$

Prova (2): escolha de k

Tome $k_0 = \dfrac{8 \ln n}{\ln \ln n}$, $k = \lceil k_0 \rceil$, $y = \ln \ln n$ e $\phi(t) = t(\ln t - 1)$, crescente para $t \geq 1$.

Prova (2): escolha de k

Tome $k_0 = \dfrac{8 \ln n}{\ln \ln n}$, $k = \lceil k_0 \rceil$, $y = \ln \ln n$ e $\phi(t) = t(\ln t - 1)$, crescente para $t \geq 1$.

- $\ln k_0 = \ln 8 + y - \ln y \ \geq \ \frac{1}{2} y$ (pois $\ln y \leq \frac{y}{2} + \ln 8$ para todo $y > 0$);
- para n grande, $y \geq 4$, então $\ln k_0 - 1 \geq \frac{1}{2} y - 1 \geq \frac{1}{4} y$.

Prova (2): escolha de k

Tome $k_0 = \dfrac{8 \ln n}{\ln \ln n}$, $k = \lceil k_0 \rceil$, $y = \ln \ln n$ e $\phi(t) = t(\ln t - 1)$, crescente para $t \geq 1$.

- $\ln k_0 = \ln 8 + y - \ln y \ \geq \ \frac{1}{2} y$ (pois $\ln y \leq \frac{y}{2} + \ln 8$ para todo $y > 0$);
- para n grande, $y \geq 4$, então $\ln k_0 - 1 \geq \frac{1}{2} y - 1 \geq \frac{1}{4} y$.

Logo

$$\phi(k) \geq \phi(k_0) = k_0(\ln k_0 - 1) \geq \frac{8 \ln n}{y} \cdot \frac{y}{4} = 2 \ln n,$$

e portanto

$$\mathbb{P}\big[\max_i X_i \geq k\big] \leq n\, e^{-\phi(k)} \leq n\, e^{-2 \ln n} = \frac{1}{n}. \qquad \blacksquare$$

Observações sobre a cota

- **Carga constante.** Se $c \leq C$, a cota vira $(Ce/k)^k$; basta trocar e por Ce e ajustar a constante 8.

Observações sobre a cota

- **Carga constante.** Se $c \leq C$, a cota vira $(Ce/k)^k$; basta trocar e por Ce e ajustar a constante 8.
- **A cota é justa.** Um argumento de segundo momento sobre o número de listas com $\geq k$ elementos mostra que, com alta probabilidade, a maior lista tem tamanho $\Omega(\log n / \log\log n)$. Portanto

$$\max_i X_i = \Theta\Big(\frac{\log n}{\log\log n}\Big).$$

Observações sobre a cota

- **Carga constante.** Se $c \leq C$, a cota vira $(Ce/k)^k$; basta trocar e por Ce e ajustar a constante 8.
- **A cota é justa.** Um argumento de segundo momento sobre o número de listas com $\geq k$ elementos mostra que, com alta probabilidade, a maior lista tem tamanho $\Omega(\log n / \log\log n)$. Portanto

$$\max_i X_i = \Theta\Big(\frac{\log n}{\log\log n}\Big).$$

- **O que foi usado?** A independência de k valores $h(y)$ ao mesmo tempo (probabilidade n^{-k} para cada T).

Este resultado precisa de "muita independência".

Número esperado de colisões

Seja C o número de pares $\{x, y\} \subseteq S$ que colidem: $C = \sum_{\{x,y\}} \mathbb{1}_{[h(x)=h(y)]}$. Por linearidade,

$$\mathbb{E}\, C = \binom{m}{2} \frac{1}{n} = \frac{m(m-1)}{2n}.$$

Número esperado de colisões

Seja C o número de pares $\{x, y\} \subseteq S$ que colidem: $C = \sum_{\{x,y\}} \mathbb{1}_{[h(x)=h(y)]}$. Por linearidade,

$$\mathbb{E}\, C = \binom{m}{2} \frac{1}{n} = \frac{m(m-1)}{2n}.$$

Pela desigualdade de Markov,

$$\mathbb{P}[C = 0] \;\geq\; 1 - \mathbb{E}\, C = 1 - \frac{m(m-1)}{2n}.$$

Em particular, para $m = \sqrt{n}$: $\mathbb{E}\, C < \frac{1}{2}$ e $\mathbb{P}[C = 0] \geq \frac{1}{2}$.

Número esperado de colisões

Seja C o número de pares $\{x, y\} \subseteq S$ que colidem: $C = \sum_{\{x,y\}} \mathbb{1}_{[h(x)=h(y)]}$. Por linearidade,

$$\mathbb{E}\, C = \binom{m}{2} \frac{1}{n} = \frac{m(m-1)}{2n}.$$

Pela desigualdade de Markov,

$$\mathbb{P}[C = 0] \;\geq\; 1 - \mathbb{E}\, C = 1 - \frac{m(m-1)}{2n}.$$

Em particular, para $m = \sqrt{n}$: $\mathbb{E}\, C < \frac{1}{2}$ e $\mathbb{P}[C = 0] \geq \frac{1}{2}$.

Observação

Só usamos $\mathbb{P}[h(x) = h(y)] = 1/n$ para pares. Isto é informação sobre pares.

Probabilidade de nenhuma colisão: fórmula exata

Para $m \leq n$ há $n(n-1)\cdots(n-m+1)$ sequências sem repetição em N^m, logo

$$\mathbb{P}[C = 0] = \frac{n(n-1)\cdots(n-m+1)}{n^m} = \prod_{j=1}^{m-1}\Big(1 - \frac{j}{n}\Big).$$

Probabilidade de nenhuma colisão: fórmula exata

Para $m \leq n$ há $n(n-1)\cdots(n-m+1)$ sequências sem repetição em N^m, logo

$$\mathbb{P}[C = 0] = \frac{n(n-1)\cdots(n-m+1)}{n^m} = \prod_{j=1}^{m-1}\Big(1 - \frac{j}{n}\Big).$$

Cota superior

$1 - x < e^{-x}$ para $x > 0$, logo

$$\mathbb{P}[C = 0] < \exp\Big(-\frac{m(m-1)}{2n}\Big).$$

Probabilidade de nenhuma colisão: fórmula exata

Para $m \leq n$ há $n(n-1)\cdots(n-m+1)$ sequências sem repetição em N^m, logo

$$\mathbb{P}[C = 0] = \frac{n(n-1)\cdots(n-m+1)}{n^m} = \prod_{j=1}^{m-1}\Big(1 - \frac{j}{n}\Big).$$

Cota superior

$1 - x < e^{-x}$ para $x > 0$, logo

$$\mathbb{P}[C = 0] < \exp\Big(-\frac{m(m-1)}{2n}\Big).$$

Cota inferior

$1 - x > e^{-2x}$ para $x \in (0, \frac{3}{4}]$. Se $m \leq \frac{3}{4}n$,

$$\mathbb{P}[C = 0] > \exp\Big(-\frac{m(m-1)}{n}\Big).$$

Probabilidade de nenhuma colisão: fórmula exata

Para $m \le n$ há $n(n-1)\cdots(n-m+1)$ sequências sem repetição em N^m, logo

$$\mathbb{P}[C=0] = \frac{n(n-1)\cdots(n-m+1)}{n^m} = \prod_{j=1}^{m-1}\Big(1-\frac{j}{n}\Big).$$

Cota superior

$1-x < e^{-x}$ para $x>0$, logo

$$\mathbb{P}[C=0] < \exp\Big(-\frac{m(m-1)}{2n}\Big).$$

Cota inferior

$1-x > e^{-2x}$ para $x \in (0, \frac{3}{4}]$. Se $m \le \frac{3}{4}n$,

$$\mathbb{P}[C=0] > \exp\Big(-\frac{m(m-1)}{n}\Big).$$

Em ambas, tudo depende de $m(m-1)/n \approx m^2/n$.

Exemplo: o paradoxo dos aniversários

Com $n = 365$ dias e m pessoas (nascimentos uniformes e independentes):

$$\mathbb{P}[C > 0] = 1 - \mathbb{P}[C = 0] > 1 - \exp\Big(-\frac{m(m-1)}{2n}\Big).$$

Exemplo: o paradoxo dos aniversários

Com $n = 365$ dias e m pessoas (nascimentos uniformes e independentes):

$$\mathbb{P}[C > 0] = 1 - \mathbb{P}[C = 0] > 1 - \exp\Big(-\frac{m(m-1)}{2n}\Big).$$

$m = 23$

$$\frac{m(m-1)}{2n} = \frac{506}{730} \approx 0{,}693151 > \ln 2 \approx 0{,}693147 \quad \Longrightarrow \quad \mathbb{P}[C > 0] > \tfrac{1}{2}.$$

Basta uma turma de 23 pessoas para haver aniversário repetido com probabilidade maior que $1/2$.

O limiar $\sqrt{n}$ para colisões

Juntando as duas cotas, para $m \leq \frac{3}{4}n$:

$$\exp\Big(-\frac{m(m-1)}{n}\Big) < \mathbb{P}[C = 0] < \exp\Big(-\frac{m(m-1)}{2n}\Big).$$

O limiar $\sqrt{n}$ para colisões

Juntando as duas cotas, para $m \leq \frac{3}{4}n$:

$$\exp\Big(-\frac{m(m-1)}{n}\Big) < \mathbb{P}[C = 0] < \exp\Big(-\frac{m(m-1)}{2n}\Big).$$

Regime	**Conclusão**	**Cota usada**
$m \leq \sqrt{n}$	$\mathbb{P}[C = 0] > e^{-1} > 0{,}36$	inferior
$m = \Theta(\sqrt{n})$	$\mathbb{P}[C = 0]$ entre duas constantes em $(0, 1)$	ambas
$m = \omega(\sqrt{n})$	$\mathbb{P}[C = 0] \to 0$	superior

O limiar $\sqrt{n}$ para colisões

Juntando as duas cotas, para $m \leq \frac{3}{4}n$:

$$\exp\Big(-\frac{m(m-1)}{n}\Big) < \mathbb{P}[C = 0] < \exp\Big(-\frac{m(m-1)}{2n}\Big).$$

Regime	**Conclusão**	**Cota usada**
$m \leq \sqrt{n}$	$\mathbb{P}[C = 0] > e^{-1} > 0{,}36$	inferior
$m = \Theta(\sqrt{n})$	$\mathbb{P}[C = 0]$ entre duas constantes em $(0, 1)$	ambas
$m = \omega(\sqrt{n})$	$\mathbb{P}[C = 0] \to 0$	superior

Limiar

$\sqrt{n}$ é o limiar: até ele, inserimos sem colisão com probabilidade constante; acima dele, há colisão quase certamente.

O limiar $\sqrt{n}$ para colisões

Juntando as duas cotas, para $m \leq \frac{3}{4}n$:

$$\exp\Big(-\frac{m(m-1)}{n}\Big) < \mathbb{P}[C=0] < \exp\Big(-\frac{m(m-1)}{2n}\Big).$$

Regime	**Conclusão**	**Cota usada**
$m \leq \sqrt{n}$	$\mathbb{P}[C=0] > e^{-1} > 0{,}36$	inferior
$m = \Theta(\sqrt{n})$	$\mathbb{P}[C=0]$ entre duas constantes em $(0,1)$	ambas
$m = \omega(\sqrt{n})$	$\mathbb{P}[C=0] \to 0$	superior

Limiar

$\sqrt{n}$ é o limiar: até ele, inserimos sem colisão com probabilidade constante; acima dele, há colisão quase certamente.

Markov: para $m \leq \sqrt{n}$ dá $\mathbb{P}[C=0] \geq 1 - \mathbb{E}C > \frac{1}{2}$ (melhor que e^{-1}), mas é trivial quando $\mathbb{E}C \geq 1$, isto é, $m \geq \sqrt{2n}+1$.

Variância do tamanho de uma lista

Seja $X_i = \sum_{x \in S} \mathbb{1}_{[h(x)=i]}$, com $\mathbb{E}X_i = c$. Para $x \neq y$ os indicadores são independentes. Então

$$\text{Var}(\, X_i \,) = \sum_{x \in S} \frac{1}{n}\left(1 - \frac{1}{n}\right) = c\left(1 - \frac{1}{n}\right).$$

Variância do tamanho de uma lista

Seja $X_i = \sum_{x \in S} \mathbb{1}_{[h(x)=i]}$, com $\mathbb{E}X_i = c$. Para $x \neq y$ os indicadores são independentes. Então

$$\text{Var}(\, X_i \,) = \sum_{x \in S} \frac{1}{n}\Big(1 - \frac{1}{n}\Big) = c\Big(1 - \frac{1}{n}\Big).$$

Chebyshev:

$$\mathbb{P}[\, |X_i - c| \geq t \,] \leq \frac{c(1 - 1/n)}{t^2} \leq \frac{c}{t^2}.$$

Variância do tamanho de uma lista

Seja $X_i = \sum_{x \in S} \mathbb{1}_{[h(x)=i]}$, com $\mathbb{E}X_i = c$. Para $x \neq y$ os indicadores são independentes. Então

$$\mathrm{Var}(\, X_i \,) = \sum_{x \in S} \frac{1}{n}\Big(1 - \frac{1}{n}\Big) = c\Big(1 - \frac{1}{n}\Big).$$

Chebyshev:

$$\mathbb{P}[\, |X_i - c| \geq t \,] \leq \frac{c(1 - 1/n)}{t^2} \leq \frac{c}{t^2}.$$

Com $t = c$: $\mathbb{P}[X_i \geq 2c] \leq \frac{1}{c}$, só útil para c grande.

Observação-chave

Esta conta só usa que os indicadores $\mathbb{1}_{[h(x)=i]}$ são independentes dois a dois.

Maior lista via Chebyshev

Cota da união sobre as n listas:

$$\mathbb{P}\big[\max_i X_i \geq c + t\big] \leq n \cdot \frac{c}{t^2} = \frac{m}{t^2}.$$

Com $t = \sqrt{2m}$, a maior lista tem tamanho

$$\leq c + \sqrt{2m} = O(\sqrt{m})$$

com probabilidade pelo menos $1/2$.

Maior lista via Chebyshev

Cota da união sobre as n listas:

$$\mathbb{P}\big[\max_i X_i \geq c + t\big] \leq n \cdot \frac{c}{t^2} = \frac{m}{t^2}.$$

Com $t = \sqrt{2m}$, a maior lista tem tamanho

$$\leq c + \sqrt{2m} = O(\sqrt{m})$$

com probabilidade pelo menos $1/2$.

Comparação

Método	**Cota**	**Independência usada**
Cota da união sobre T	$O(\log n / \log\log n)$	muitas variáveis
Chebyshev	$O(\sqrt{m})$	só pares

Mais fraca, mas vale também para famílias com descrição curta.

Variância do número de colisões

$C = \sum_{\{x,y\}} \mathbb{1}_{[h(x)=h(y)]}$. Para pares distintos $\{x, y\} \neq \{z, w\}$:

- disjuntos: dependem de quatro valores independentes;
- com elemento comum ($\{x, y\}$ e $\{x, z\}$):

$$\mathbb{P}[h(x) = h(y) = h(z)] = \sum_{a \in N} \frac{1}{n^3} = \frac{1}{n^2} = \mathbb{P}[h(x) = h(y)]\,\mathbb{P}[h(x) = h(z)].$$

Variância do número de colisões

$C = \sum_{\{x,y\}} \mathbb{1}_{[h(x)=h(y)]}$. Para pares distintos $\{x, y\} \neq \{z, w\}$:

- disjuntos: dependem de quatro valores independentes;
- com elemento comum ($\{x, y\}$ e $\{x, z\}$):

$$\mathbb{P}[h(x) = h(y) = h(z)] = \sum_{a \in N} \frac{1}{n^3} = \frac{1}{n^2} = \mathbb{P}[h(x) = h(y)]\,\mathbb{P}[h(x) = h(z)].$$

Os indicadores são independentes dois a dois, logo $\mathrm{Var}(C) = \binom{m}{2}\left(\frac{1}{n} - \frac{1}{n^2}\right)$ e, por Chebyshev,

$$\mathbb{P}[C = 0] \leq \frac{\mathrm{Var}(C)}{(\mathbb{E}C)^2} = \frac{n(1 - 1/n)}{\binom{m}{2}} \approx \frac{2n}{m^2}.$$

Para $m \gg \sqrt{n}$ há colisão com alta probabilidade, complementando o limiar do paradoxo dos aniversários.

Cuidado: onde a independência de ordem maior entra

Na conta acima, a igualdade

$$\mathbb{P}[h(x) = h(y) = h(z)] = \mathbb{P}[h(x) = h(y)]\,\mathbb{P}[h(x) = h(z)]$$

usa a independência de três valores $h(x), h(y), h(z)$, e o caso de pares disjuntos usa quatro.

Cuidado: onde a independência de ordem maior entra

Na conta acima, a igualdade

$$\mathbb{P}[h(x) = h(y) = h(z)] = \mathbb{P}[h(x) = h(y)]\,\mathbb{P}[h(x) = h(z)]$$

usa a independência de três valores $h(x), h(y), h(z)$, e o caso de pares disjuntos usa quatro.

Consequência

A fórmula para Var(C) vale para a funções sorteadas em famílias com independência de ordem 4.

Já a variância de X_i usa apenas independência par a par.

O que usamos de cada propriedade

Resultado	**Propriedade necessária**
$\mathbb{E}\, C = \binom{m}{2}/n$, tempo esperado de busca	$\mathbb{P}[h(x) = h(y)] \leq 1/n$ (pares)
$\mathrm{Var}(\, X\,)_i$, maior lista $O(\sqrt{m})$	independência par a par
$\mathrm{Var}(\, C\,)$	independência de ordem 4
maior lista $\Theta(\log n / \log\log n)$	independência de muitas variáveis

O que usamos de cada propriedade

Resultado	**Propriedade necessária**
$\mathbb{E}\, C = \binom{m}{2}/n$, tempo esperado de busca	$\mathbb{P}[h(x) = h(y)] \leq 1/n$ (pares)
$\mathrm{Var}(\, X\,)_i$, maior lista $O(\sqrt{m})$	independência par a par
$\mathrm{Var}(\, C\,)$	independência de ordem 4
maior lista $\Theta(\log n / \log\log n)$	independência de muitas variáveis

Ideia central

Qualquer família em que dois elementos distintos colidem com probabilidade $\leq 1/n$ tem, no máximo, o mesmo número esperado de colisões que uma função aleatória.

Para onde vamos: famílias universais

Funções aleatórias não são práticas: descrição de tamanho $\approx |U|$.

Para onde vamos: famílias universais

Funções aleatórias não são práticas: descrição de tamanho $\approx |U|$.

A meta

Uma família $\mathcal{H} \subseteq N^U$ *pequena* tal que, para $h \in \mathcal{H}$ uniforme,

$$\mathbb{P}_h[h(x) = h(y)] \leq \frac{1}{n} \qquad \text{para todos } x \neq y \text{ em } U,$$

com funções fáceis de computar e descrição curta.

Para onde vamos: famílias universais

Funções aleatórias não são práticas: descrição de tamanho $\approx |U|$.

A meta

Uma família $\mathcal{H} \subseteq N^U$ *pequena* tal que, para $h \in \mathcal{H}$ uniforme,

$$\mathbb{P}_h[h(x) = h(y)] \leq \frac{1}{n} \qquad \text{para todos } x \neq y \text{ em } U,$$

com funções fáceis de computar e descrição curta.

- Comportar-se como função aleatória é propriedade da *família*, não de uma função isolada.
- Tudo que depende só de pares continuará valendo (esperança de colisões, tempo esperado de busca, $\mathrm{Var}(X_i)$).

A ideia: reduzir a aleatoriedade

Desejamos funções que

- tenham representação sucinta;
- imitem uma função aleatória nas estatísticas de interesse (busca em tempo constante, ausência de listas longas);
- sejam calculadas eficientemente em cada ponto.

A ideia: reduzir a aleatoriedade

Desejamos funções que

- tenham representação sucinta;
- imitem uma função aleatória nas estatísticas de interesse (busca em tempo constante, ausência de listas longas);
- sejam calculadas eficientemente em cada ponto.

Estratégia

Em vez de sortear h em N^U, sortear h de uma coleção menor e não vazia $\mathcal{H} \subseteq N^U$.

A ideia: reduzir a aleatoriedade

Desejamos funções que

- tenham representação sucinta;
- imitem uma função aleatória nas estatísticas de interesse (busca em tempo constante, ausência de listas longas);
- sejam calculadas eficientemente em cada ponto.

Estratégia

Em vez de sortear h em N^U, sortear h de uma coleção menor e não vazia $\mathcal{H} \subseteq N^U$.

A condição $\mathbb{P}[h(x) = i] = \frac{1}{n}$ (para todo x e todo i) é substituída por uma condição só sobre pares:

Família universal

Definição 4

Uma família não vazia $\mathcal{H} \subseteq N^U$ é universal se

$$\mathbb{P}_{h \in \mathcal{H}}[h(x) = h(y)] \leq \frac{1}{n} \qquad \text{para todos } x \neq y \text{ em } U.$$

Família universal

Definição 4

Uma família não vazia $\mathcal{H} \subseteq N^U$ é universal se

$$\mathbb{P}_{h \in \mathcal{H}}[h(x) = h(y)] \;\leq\; \frac{1}{n} \qquad \text{para todos } x \neq y \text{ em } U.$$

- Para a função totalmente aleatória vale a igualdade, $= 1/n$.
- Carter e Wegman (1979): em vez de exigir independência total entre as imagens de todas as chaves, o que consome muitos bits aleatórios, basta controlar a colisão entre *quaisquer duas* chaves.
- Famílias com independência de pares também são universais; a recíproca é falsa.

O que continua valendo (como desigualdades)

As contas dos slides anteriores que usam apenas $\mathbb{P}[h(x) = h(y)] \leq 1/n$ valem para $\mathcal{H}$ universal:

- tamanho esperado da lista $H[h(x)]$: $\leq c$ se $x \notin S$ e $\leq 1 + \frac{m-1}{n} \leq 1 + c$ se $x \in S$;

O que continua valendo (como desigualdades)

As contas dos slides anteriores que usam apenas $\mathbb{P}[h(x) = h(y)] \leq 1/n$ valem para $\mathcal{H}$ universal:

- tamanho esperado da lista $H[h(x)]$: $\leq c$ se $x \notin S$ e $\leq 1 + \frac{m-1}{n} \leq 1 + c$ se $x \in S$;
- tempo esperado de busca: $\leq c + 1$ (sem sucesso) e $\leq 1 + \frac{c}{2} - \frac{1}{2n}$ (com sucesso). A prova só usa colisão de pares e o fato de a ordem de inserção *não depender de h*;

O que continua valendo (como desigualdades)

As contas dos slides anteriores que usam apenas $\mathbb{P}[h(x) = h(y)] \leq 1/n$ valem para $\mathcal{H}$ universal:

- tamanho esperado da lista $H[h(x)]$: $\leq c$ se $x \notin S$ e $\leq 1 + \frac{m-1}{n} \leq 1 + c$ se $x \in S$;
- tempo esperado de busca: $\leq c + 1$ (sem sucesso) e $\leq 1 + \frac{c}{2} - \frac{1}{2n}$ (com sucesso). A prova só usa colisão de pares e o fato de a ordem de inserção *não depender de h*;
- número esperado de colisões: $\mathbb{E}C \leq \binom{m}{2}\frac{1}{n}$. Com $n = m^2$, $\mathbb{E}C < \frac{1}{2}$ e, por Markov, $\mathbb{P}[C = 0] > \frac{1}{2}$.

O que continua valendo (como desigualdades)

As contas dos slides anteriores que usam apenas $\mathbb{P}[h(x) = h(y)] \leq 1/n$ valem para $\mathcal{H}$ universal:

- tamanho esperado da lista $H[h(x)]$: $\leq c$ se $x \notin S$ e $\leq 1 + \frac{m-1}{n} \leq 1 + c$ se $x \in S$;
- tempo esperado de busca: $\leq c + 1$ (sem sucesso) e $\leq 1 + \frac{c}{2} - \frac{1}{2n}$ (com sucesso). A prova só usa colisão de pares e o fato de a ordem de inserção *não depender de h*;
- número esperado de colisões: $\mathbb{E}C \leq \binom{m}{2}\frac{1}{n}$. Com $n = m^2$, $\mathbb{E}C < \frac{1}{2}$ e, por Markov, $\mathbb{P}[C = 0] > \frac{1}{2}$.

Cuidado

O que *não* se transfere é o que usava independência de ordem maior: Var(C) e a cota $\Theta(\log n / \log\log n)$ da maior lista.

Teorema: colisões com um elemento fixo

Teorema 5

Se $\mathcal{H}$ é universal, $S \subseteq U$ com $|S| = m$ e $x \in U$, então para h escolhida em $\mathcal{H}$, o número esperado de colisões entre x e os elementos de $S \setminus \{x\}$ é no máximo m/n.

Teorema: colisões com um elemento fixo

Teorema 5

Se $\mathcal{H}$ é universal, $S \subseteq U$ com $|S| = m$ e $x \in U$, então para h escolhida em $\mathcal{H}$, o número esperado de colisões entre x e os elementos de $S \setminus \{x\}$ é no máximo m/n.

Proof.

Linearidade da esperança e universalidade:

$$\mathbb{E} \sum_{y \in S \setminus \{x\}} \mathbb{1}_{[h(x)=h(y)]} = \sum_{y \in S \setminus \{x\}} \mathbb{P}[h(x) = h(y)] \leq \frac{|S \setminus \{x\}|}{n} \leq \frac{m}{n}. \qquad \square$$

Universal não implica uniforme

$U = \{1, 2\}$, $N = \{0, 1\}$, $n = 2$

	1	2
f_1	0	0
f_2	1	0
f_3	0	1

- $\mathbb{P}[f(1) = f(2)] = \frac{1}{3} \leq \frac{1}{2}$: a família é universal.

Universal não implica uniforme

$U = \{1, 2\}$, $N = \{0, 1\}$,

$n = 2$

	1	2
f_1	0	0
f_2	1	0
f_3	0	1

- $\mathbb{P}[f(1) = f(2)] = \frac{1}{3} \leq \frac{1}{2}$: a família é universal.
- Mas $\mathbb{P}[f(1) = 0] = \frac{2}{3} \neq \frac{1}{2}$: cada $h(x)$ não é uniforme em N.

Universal não implica uniforme

$U = \{1, 2\}$, $N = \{0, 1\}$,

$n = 2$

	1	2
f_1	0	0
f_2	1	0
f_3	0	1

- $\mathbb{P}[f(1) = f(2)] = \frac{1}{3} \leq \frac{1}{2}$: a família é universal.
- Mas $\mathbb{P}[f(1) = 0] = \frac{2}{3} \neq \frac{1}{2}$: cada $h(x)$ não é uniforme em N.

Lição

Universalidade é uma propriedade sobre *pares*, não sobre cada valor $h(x)$ isoladamente.

Uma família universal linear

$U = \{0,1\}^d$, $N = \{0,1\}^k$ ($|U| = 2^d$, $|N| = 2^k$).

Definição

Sorteie os bits de A ($k \times d$) e defina $h(\mathrm{x}) = \mathrm{A} \cdot \mathrm{x}$, com soma e produto módulo 2.

Uma família universal linear

$U = \{0,1\}^d$, $N = \{0,1\}^k$ ($|U| = 2^d$, $|N| = 2^k$).

Definição

Sorteie os bits de A ($k \times d$) e defina $h(x) = A \cdot x$, com soma e produto módulo 2.

- **Descrição:** só a matriz, $kd = O(\log|N| \cdot \log|U|)$ bits.
- **Não é uniforme:** $h(0) = 0$ para toda escolha de A.
- **É universal:** próximo slide.

A família linear é universal

Sejam $x \neq y$. Por linearidade, $h(x) = h(y) \iff A(x - y) = 0$, isto é,

$$\sum_{j=1}^{d} a_{\ell,j}(x - y)_j = 0 \quad \text{para cada } \ell = 1, \ldots, k.$$

A família linear é universal

Sejam $x \neq y$. Por linearidade, $h(x) = h(y) \iff A(x - y) = 0$, isto é,

$$\sum_{j=1}^{d} a_{\ell,j}(x - y)_j = 0 \quad \text{para cada } \ell = 1, \ldots, k.$$

Seja r com $(x - y)_r = 1$. Fixe todos os bits de A fora da coluna r. **Para cada** ℓ, a equação vale se, e somente se,

$$a_{\ell,r} = \sum_{j \neq r} a_{\ell,j}(x - y)_j \pmod 2,$$

que fixa um único valor para $a_{\ell,r}$.

A família linear é universal

Sejam $x \neq y$. Por linearidade, $h(x) = h(y) \iff A(x - y) = 0$, isto é,

$$\sum_{j=1}^{d} a_{\ell,j}(x - y)_j = 0 \quad \text{para cada } \ell = 1, \ldots, k.$$

Seja r com $(x - y)_r = 1$. Fixe todos os bits de A fora da coluna r. **Para cada** ℓ, a equação vale se, e somente se,

$$a_{\ell,r} = \sum_{j \neq r} a_{\ell,j}(x - y)_j \pmod 2,$$

que fixa um único valor para $a_{\ell,r}$. Os k bits da coluna r são independentes e uniformes, logo

$$\mathbb{P}[Ax = Ay] = 2^{-k} = \frac{1}{|N|}. \qquad \blacksquare$$

O exemplo canônico: $h_{(a,b)}$

$U = \{0, \ldots, u-1\}$, $N = \{0, \ldots, n-1\}$, $u > n$, e um primo p com $u < p \leq 2u$ (postulado de Bertrand).

Família $\mathcal{H}_{p,n}$

$$h_{(a,b)}(x) = \big((ax + b) \bmod p\big) \bmod n, \qquad a \in \{1, \ldots, p-1\},\ b \in \{0, \ldots, p-1\}.$$

Sortear h é sortear (a, b) uniformemente: $p(p-1)$ escolhas.

O exemplo canônico: $h_{(a,b)}$

$U = \{0, \ldots, u-1\}$, $N = \{0, \ldots, n-1\}$, $u > n$, e um primo p com $u < p \leq 2u$ (postulado de Bertrand).

Família $\mathcal{H}_{p,n}$

$$h_{(a,b)}(x) = \big((ax + b) \bmod p\big) \bmod n, \qquad a \in \{1, \ldots, p-1\},\ b \in \{0, \ldots, p-1\}.$$

Sortear h é sortear (a, b) uniformemente: $p(p-1)$ escolhas.

Por que $a \neq 0$?

Com $a = 0$ a função é constante e todos os pares colidem.

O exemplo canônico: $h_{(a,b)}$

$U = \{0, \ldots, u-1\}$, $N = \{0, \ldots, n-1\}$, $u > n$, e um primo p com $u < p \leq 2u$ (postulado de Bertrand).

Família $\mathcal{H}_{p,n}$

$$h_{(a,b)}(x) = \big((ax + b) \bmod p\big) \bmod n, \qquad a \in \{1, \ldots, p-1\},\ b \in \{0, \ldots, p-1\}.$$

Sortear h é sortear (a, b) uniformemente: $p(p-1)$ escolhas.

Por que $a \neq 0$?

Com $a = 0$ a função é constante e todos os pares colidem.

Plano da prova ($x \neq y$ fixos):

1. módulo p nunca há colisão, e $(a, b) \leftrightarrow (i, j)$ é bijeção;
2. contar os pares (i, j) distintos com $i \equiv j \pmod{n}$.

Passo 1: nenhuma colisão módulo p; bijeção

Como $u < p$, $0 < |x - y| < p$ e, sendo p primo, $p \nmid x - y$. Para $a \neq 0$, $p \nmid a(x - y)$, logo

$$(ax + b) \bmod p \;\neq\; (ay + b) \bmod p.$$

Passo 1: nenhuma colisão módulo p; bijeção

Como $u < p$, $0 < |x - y| < p$ e, sendo p primo, $p \nmid x - y$. Para $a \neq 0$, $p \nmid a(x - y)$, logo

$$(ax + b) \bmod p \;\neq\; (ay + b) \bmod p.$$

Para $i, j \in \{0, \ldots, p - 1\}$ distintos, o sistema

$$\begin{pmatrix} x & 1 \\ y & 1 \end{pmatrix} \begin{pmatrix} a \\ b \end{pmatrix} \equiv \begin{pmatrix} i \\ j \end{pmatrix} \pmod{p}$$

tem exatamente uma solução (a, b), pois o determinante $x - y$ é invertível módulo p. E $a \neq 0$ porque $a(x - y) \equiv i - j \not\equiv 0$.

Passo 1: nenhuma colisão módulo p; bijeção

Como $u < p$, $0 < |x - y| < p$ e, sendo p primo, $p \nmid x - y$. Para $a \neq 0$, $p \nmid a(x - y)$, logo

$$(ax + b) \bmod p \;\neq\; (ay + b) \bmod p.$$

Para $i, j \in \{0, \ldots, p - 1\}$ distintos, o sistema

$$\begin{pmatrix} x & 1 \\ y & 1 \end{pmatrix} \begin{pmatrix} a \\ b \end{pmatrix} \equiv \begin{pmatrix} i \\ j \end{pmatrix} \pmod{p}$$

tem exatamente uma solução (a, b), pois o determinante $x - y$ é invertível módulo p. E $a \neq 0$ porque $a(x - y) \equiv i - j \not\equiv 0$.

Consequência

Há $p(p - 1)$ pares (a, b) com $a \neq 0$ e $p(p - 1)$ pares (i, j) distintos: uma bijeção. Para (a, b) uniforme, (i, j) é uniforme entre os pares de valores distintos módulo p.

Passo 2: contar pares congruentes módulo n

Queremos o número de pares (i, j), $i \neq j$ em $\{0, \ldots, p-1\}$, com $j \equiv i \pmod{n}$.

Passo 2: contar pares congruentes módulo n

Queremos o número de pares (i, j), $i \neq j$ em $\{0, \ldots, p-1\}$, com $j \equiv i \pmod{n}$.

- Fixado i, os $j \neq i$ com $j \equiv i$ correspondem aos múltiplos não nulos de n em $\{-i, \ldots, -i+p-1\}$ (a diferença $j-i$); o múltiplo 0 corresponde a $j = i$.

Passo 2: contar pares congruentes módulo n

Queremos o número de pares (i, j), $i \neq j$ em $\{0, \ldots, p-1\}$, com $j \equiv i \pmod{n}$.

- Fixado i, os $j \neq i$ com $j \equiv i$ correspondem aos múltiplos não nulos de n em $\{-i, \ldots, -i+p-1\}$ (a diferença $j - i$); o múltiplo 0 corresponde a $j = i$.
- Entre p inteiros consecutivos há no máximo $\lceil p/n \rceil \leq \frac{p-1}{n} + 1$ múltiplos de n. Tirando o 0, sobram no máximo $\dfrac{p-1}{n}$ valores de j.

Passo 2: contar pares congruentes módulo n

Queremos o número de pares (i, j), $i \neq j$ em $\{0, \ldots, p-1\}$, com $j \equiv i \pmod{n}$.

- Fixado i, os $j \neq i$ com $j \equiv i$ correspondem aos múltiplos não nulos de n em $\{-i, \ldots, -i+p-1\}$ (a diferença $j-i$); o múltiplo 0 corresponde a $j = i$.
- Entre p inteiros consecutivos há no máximo $\lceil p/n \rceil \leq \frac{p-1}{n} + 1$ múltiplos de n. Tirando o 0, sobram no máximo $\dfrac{p-1}{n}$ valores de j.
- Portanto, há no máximo $\dfrac{p(p-1)}{n}$ pares (i, j) distintos e congruentes módulo n.

Conclusão: $\mathcal{H}_{p,n}$ é universal

Para $x \neq y$ em U:

$$\mathbb{P}[h_{(a,b)}(x) = h_{(a,b)}(y)] \;\leq\; \frac{p(p-1)/n}{p(p-1)} = \frac{1}{n}.$$

Conclusão: $\mathcal{H}_{p,n}$ é universal

Para $x \neq y$ em U:

$$\mathbb{P}[h_{(a,b)}(x) = h_{(a,b)}(y)] \;\leq\; \frac{p(p-1)/n}{p(p-1)} = \frac{1}{n}.$$

Custo da família

- **Descrição:** o par (a, b), com $2\lceil \log p \rceil \leq 2 \log u + O(1) = O(\log |U|)$ bits (p é fixo e conhecido).
- **Tempo:** no modelo RAM com palavras de $\Theta(\log u)$ bits, uma multiplicação, uma soma e dois restos: tempo constante.

Conclusão: $\mathcal{H}_{p,n}$ é universal

Para $x \neq y$ em U:

$$\mathbb{P}[h_{(a,b)}(x) = h_{(a,b)}(y)] \;\leq\; \frac{p(p-1)/n}{p(p-1)} = \frac{1}{n}.$$

Custo da família

- **Descrição:** o par (a, b), com $2\lceil \log p \rceil \leq 2 \log u + O(1) = O(\log |U|)$ bits (p é fixo e conhecido).
- **Tempo:** no modelo RAM com palavras de $\Theta(\log u)$ bits, uma multiplicação, uma soma e dois restos: tempo constante.

Compare com a função totalmente aleatória: $\approx |U| \log n$ bits.

Exercícios

1. Verifique que $\{ f_1, f_2, f_3 \}$ do slide 7 é universal.
2. Mostre que, para $\mathcal{H}$ universal e $n = m^2$, vale $\mathbb{P}[C = 0] > \frac{1}{2}$.
3. Na família linear, mostre que $\mathbb{P}[h(\mathrm{x}) = 0] \neq 2^{-k}$ para $\mathrm{x} = 0$. O que isso diz sobre a uniformidade?
4. Na família $\mathcal{H}_{p,n}$, por que a conta do Passo 2 contaria errado se não removêssemos o múltiplo 0?
5. (Desafio) Dê uma família universal em que Var(C) *não* é $\binom{m}{2}(\frac{1}{n} - \frac{1}{n^2})$.

Resumo

- Universal: $\mathbb{P}_{h \in \mathcal{H}}[h(x) = h(y)] \leq 1/n$ para $x \neq y$.
- Preserva, como desigualdades, o que depende só de pares: colisões esperadas, tempo esperado de busca ($\leq c + 1$).
- Exemplos: *linear* sobre $\mathbb{F}_2$ (kd bits) e $h_{(a,b)}$ com primo p ($O(\log|U|)$ bits, tempo constante).
- Universal não implica uniforme, nem independência de ordem maior que 2.

Próximo passo

Independência de pares (2-universalidade): controlar a distribuição conjunta de $(h(x), h(y))$, e não só a probabilidade de colisão.

Funções de hash: motivação

- Objetivo: mapear elementos de um universo grande U para um conjunto pequeno N.
- Para obter garantias, usamos uma família $\mathcal{H} \subseteq N^U$ e sorteamos $h \in \mathcal{H}$ com aleatoriedade.
- Queremos propriedades "pseudoaleatórias" mantendo a família pequena.
- Importante para:
  - **estruturas de dados** e **algoritmos de streaming**: basta guardar uma "semente" que indica qual função foi escolhida;
  - **desaleatorização**: trocamos aleatoriedade verdadeira por pseudoaleatoriedade, enumerando todas as funções da família.

Independência par a par

Notação: $u = |U|$ e $n = |N|$.

Definição 6 (Família independente par a par)

Uma família $\mathcal{H} \subseteq N^U$ é independente par a par se, para quaisquer $x \neq y$ em U e quaisquer $i, j \in N$ (possivelmente iguais),

$$\mathbb{P}_{h \in \mathcal{H}}\big[h(x) = i \text{ e } h(y) = j\big] = \frac{1}{n^2}.$$

Ou seja: para todo par de elementos distintos, $(h(x), h(y))$ é uniforme em $N \times N$.

Observação

Somando sobre $i = j$: $\mathbb{P}[h(x) = h(y)] = n \cdot \frac{1}{n^2} = \frac{1}{n}$. Toda família independente par a par é universal.

Construção para $N = \{0,1\}$

- Supomos $u = |U| = 2^d$ (aumentando U se necessário) e identificamos $U = \{0,1\}^d$, com elementos x.
- Definimos

$$\mathcal{H} = \left\{ h_{(\mathrm{a},b)}(\mathrm{x}) = \langle \mathrm{a}, \mathrm{x} \rangle + b \bmod 2 : \ \mathrm{a} \in \{0,1\}^d, \ b \in \{0,1\} \right\}.$$

- Tamanho: $|\mathcal{H}| = 2^{d+1} = 2u$.

Afirmação 1

Seja $x \in \{0,1\}^d$, $x \neq 0$. *Então* $\mathbb{P}_{a \in \{0,1\}^d}\left[\langle a, x \rangle \bmod 2 = 0\right] = \dfrac{1}{2}$.

Proof.

Seja r com $x_r = 1$. O evento equivale a $a_r = \sum_{j \neq r} a_j x_j \pmod 2$, que ocorre com probabilidade $1/2$ para qualquer escolha dos demais a_j. □

$\mathcal{H}$ é independente par a par

Lema 7

A família $\mathcal{H}$ acima é independente par a par.

Proof.

Fixe $x \neq y$ e $i, j \in \{0,1\}$ (contas módulo 2). Queremos $\mathbb{P}_{a,b}[\langle a, x\rangle + b = i \text{ e } \langle a, y\rangle + b = j] = \frac{1}{4}$.

Só sobre a, pela Afirmação (o caso $k = 1$ é o complementar), para todo $k \in \{0,1\}$:

$$\mathbb{P}_a\big[\langle a, x\rangle - \langle a, y\rangle = k\big] = \mathbb{P}_a\big[\langle a, x - y\rangle = k\big] = \tfrac{1}{2}.$$

Sorteando também b:

$$\begin{aligned}&\mathbb{P}_{a,b}[\langle a, x\rangle + b = i \text{ e } \langle a, y\rangle + b = j] \\ &= \mathbb{P}_{a,b}\big[\langle a, x - y\rangle = i - j \text{ e } b = i - \langle a, x\rangle\big] = \tfrac{1}{2} \cdot \tfrac{1}{2} = \tfrac{1}{4}.\end{aligned}$$

□

Visão equivalente: distribuição sobre u bits

- Seja $U = \{ x_1, \ldots, x_u \}$. Para gerar uma cadeia $z_1, \ldots, z_u$: sorteie $h \in \mathcal{H}$ e faça $z_\ell = h(x_\ell)$.
- Qualquer par de bits é uniforme.
- O suporte tem tamanho $\leq |\mathcal{H}| = O(u)$, muito menor que as 2^u cadeias da distribuição uniforme.
- Podemos representar a cadeia pela função que a gerou: apenas $\log|\mathcal{H}| = \log u + O(1)$ bits.

Exemplo

Para $u = 4$, sortear uniformemente do conjunto abaixo (com $8 = 2^3$ cadeias) dá bits independentes par a par:

$$\{ 0000, 0011, 0101, 0110, 1001, 1010, 1100, 1111 \}.$$

O problema MAXCUT

- Seja $G = (V, E)$ um grafo simples não direcionado. Para $S \subseteq V$,

$$E(S, S^c) = \{\, \{v, w\} \in E \colon v \in S,\ w \in S^c \,\}$$

  é o conjunto de arestas que cruzam o corte S.
- O problema pede o maior número de arestas em um corte:

$$\mathrm{MAXCUT}(G) = \max_{S \subseteq V} |E(S, S^c)|.$$

- Calcular MAXCUT é NP-difícil.
- Mas há um algoritmo aleatorizado simples que o aproxima com fator 2. Seja $u = |V|$ e $V = \{\, v_1, \ldots, v_u \,\}$ (identificado com o universo U, de modo que uma cadeia $z \in \{\, 0, 1 \,\}^u$ descreve $S = \{\, v_\ell \colon z_\ell = 1 \,\}$).

Algoritmo aleatorizado: aproximação de fator 2

Lema 8

Sejam $z_1, \ldots, z_u \in \{0,1\}$ uniformes e independentes, e $S = \{v_\ell : z_\ell = 1\}$. Então

$$\mathbb{E}_S\big[|E(S, S^c)|\big] \;\geq\; \frac{|E|}{2} \;\geq\; \frac{\mathrm{MAXCUT}(G)}{2}.$$

Proof.

Somando sobre pares ordenados (v_k, v_ℓ) com $\{v_k, v_\ell\} \in E$, $|E(S, S^c)| = \sum_{(v_k, v_\ell)} \mathbb{1}_{[v_k \in S]}\, \mathbb{1}_{[v_\ell \in S^c]}$. Cada aresta é contada duas vezes (como (v_k, v_ℓ) e (v_ℓ, v_k)), mas no máximo uma delas cruza o corte. Por linearidade da esperança:

$$\begin{aligned}\mathbb{E}_S|E(S, S^c)| &= \sum_{(v_k, v_\ell)} \mathbb{E}\, \mathbb{1}_{[z_k = 1]} \mathbb{1}_{[z_\ell = 0]} = \sum_{(v_k, v_\ell)} \mathbb{P}[z_k = 1 \text{ e } z_\ell = 0] \\ &= 2|E| \cdot \tfrac{1}{4} = \tfrac{|E|}{2}.\end{aligned}$$

□

Probabilidade de sucesso

Corolário 1

$$\mathbb{P}_S\left[|E(S,S^c)| \geq \tfrac{|E|}{2}\right] \;\geq\; \frac{1}{2|E|} \;\geq\; \frac{1}{u^2}.$$

Proof.

Seja $X = |E(S,S^c)|$ e $\mu = |E|/2$, de modo que $\mathbb{E}\,X \geq \mu$.

- Se $X < \mu$, então $X \leq \mu - \frac{1}{2}$, pois X é inteiro e μ é meio-inteiro.
- Sempre vale $X \leq |E| = 2\mu$.

Seja $q = \mathbb{P}[X \geq \mu]$. Então

$$\begin{aligned}\mathbb{E}\,X &= \mathbb{E}[X \mid X \geq \mu]\,\mathbb{P}[X \geq \mu] + \mathbb{E}[X \mid X \leq \mu - \tfrac{1}{2}]\,\mathbb{P}[X \leq \mu - \tfrac{1}{2}] \\ &\leq 2\mu q + (\mu - \tfrac{1}{2})(1-q) \;\leq\; \mu - \tfrac{1}{2} + 2\mu q.\end{aligned}$$

Como $\mathbb{E}\,X \geq \mu$, devemos ter $2\mu q \geq \frac{1}{2}$, ou seja, $q \geq \frac{1}{4\mu} = \frac{1}{2|E|}$. □

Desaleatorização com bits independentes par a par

- Podemos sortear $O(u^2)$ conjuntos S, calcular o corte de cada um e, com alta probabilidade, o máximo será $\geq |E|/2$.
- Com bits independentes par a par, desaleatorizamos o algoritmo e reduzimos o tempo de $O(u^2)$ para apenas $O(u)$ conjuntos testados.

Lema 9

Sejam $z_1, \ldots, z_u \in \{0, 1\}$ bits independentes par a par e $S = \{v_\ell : z_\ell = 1\}$. Então $\mathbb{E}_S |E(S, S^c)| \geq |E|/2$.

Proof.

A uniformidade foi usada apenas no cálculo $\mathbb{P}[z_k = 1 \text{ e } z_\ell = 0] = \frac{1}{4}$ para $k \neq \ell$, o que também vale para bits independentes par a par. □

Em particular, para algum dos $O(u)$ conjuntos S gerados, $|E(S, S^c)|$ supera a média e, portanto, $|E(S, S^c)| \geq |E|/2$.

Otimalidade do espaço amostral

Geramos $O(u)$ cadeias de u bits, e sortear uma delas dá bits independentes par a par. Isso é ótimo.

Lema 10

Seja $Z \subseteq \{0,1\}^u$ tal que, para quaisquer $k \neq \ell$ em $\{1,\ldots,u\}$ e $c', c'' \in \{0,1\}$, $\mathbb{P}_{z\in Z}[z_k = c' \text{ e } z_\ell = c''] = \frac{1}{4}$. Então $|Z| \geq u$.

Ideia da prova. Associamos a cada coordenada k um vetor $w_k \in \{-1,1\}^{|Z|}$, mostramos que $w_1,\ldots,w_u$ são ortogonais (logo linearmente independentes) em $\mathbb{R}^{|Z|}$, e concluímos $|Z| \geq u$.

Otimalidade: prova

Seja $t = |Z|$, $Z = \{ z^1, \ldots, z^t \}$. Para cada coordenada k, defina $w_k \in \{ -1, 1 \}^t$ por $(w_k)_s = (-1)^{(z^s)_k}$.

Ortogonalidade. Para $k \neq \ell$,

$$\langle w_k, w_\ell \rangle = \sum_{z \in Z} (-1)^{z_k + z_\ell} = |\{ z \in Z \colon z_k = z_\ell \}| - |\{ z \in Z \colon z_k \neq z_\ell \}|.$$

Pela hipótese, ambos os conjuntos têm tamanho $|Z|/2$; logo $\langle w_k, w_\ell \rangle = 0$.

Independência linear. Suponha $\sum_k \alpha_k w_k = 0$ com $\alpha_k \in \mathbb{R}$. Para todo ℓ,

$$0 = \left\langle \sum_k \alpha_k w_k,\ w_\ell \right\rangle = \sum_k \alpha_k \langle w_k, w_\ell \rangle = \alpha_\ell \|w_\ell\|^2 = |Z|\, \alpha_\ell,$$

logo $\alpha_\ell = 0$ para todo ℓ. Assim $w_1, \ldots, w_u$ são linearmente independentes e geram um subespaço de dimensão u de $\mathbb{R}^t$. Portanto $t \geq u$. ■

Construção para $N = \mathbb{F}_p$

- Supomos $n = |N| = p$ primo (a exigência pode ser relaxada) e identificamos $N = \mathbb{F}_p$.
- Supomos $u = |U| = p^d$ e identificamos $U = \mathbb{F}_p^d$.
- Definimos
$$\mathcal{H} = \left\{ h_{(\mathrm{a},b)}(\mathrm{x}) = \langle \mathrm{a}, \mathrm{x} \rangle + b : \ \mathrm{a} \in \mathbb{F}_p^d, \ b \in \mathbb{F}_p \right\}.$$
- Tamanho: $|\mathcal{H}| = p^{d+1} = u \cdot n$.

Afirmação 2

Seja $x \in \mathbb{F}_p^d$, $x \neq 0$. Então, para todo $k \in \mathbb{F}_p$, $\mathbb{P}_{a \in \mathbb{F}_p^d}[\langle a, x \rangle = k] = \frac{1}{p}$.

Proof.

Seja r com $x_r \neq 0$. O evento é $a_r x_r = k - \sum_{j \neq r} a_j x_j$. Fixados os a_j com $j \neq r$, $a_r x_r$ é uniforme em $\mathbb{F}_p$, logo assume qualquer valor com probabilidade exatamente $1/p$. □

$\mathcal{H}$ é independente par a par

Lema 11

A família $\mathcal{H}$ acima é independente par a par.

Proof.

Fixe $x \neq y$ em $\mathbb{F}_p^d$ e $i, j \in \mathbb{F}_p$. Queremos $\mathbb{P}_{a,b}[\langle a, x\rangle + b = i \text{ e } \langle a, y\rangle + b = j] = \frac{1}{p^2}$.
Só sobre a, pela Afirmação, para todo $k \in \mathbb{F}_p$:

$$\mathbb{P}_a[\langle a, x\rangle - \langle a, y\rangle = k] = \mathbb{P}_a[\langle a, x - y\rangle = k] = \frac{1}{p}.$$

Sorteando também b:

$$\begin{aligned}&\mathbb{P}_{a,b}[\langle a, x\rangle + b = i \text{ e } \langle a, y\rangle + b = j] \\ &= \mathbb{P}_{a,b}\big[\langle a, x - y\rangle = i - j \text{ e } b = i - \langle a, x\rangle\big] = \frac{1}{p} \cdot \frac{1}{p} = \frac{1}{p^2}.\end{aligned}$$

□

Hash livre de colisões

- Seja $S \subseteq U$. Uma função $h\colon U \to N$ é livre de colisões para S se é injetora em S: $h(x) \neq h(y)$ para todos $x \neq y$ em S.
- Se n for grande o bastante, toda família independente par a par contém muitas funções livres de colisões para qualquer conjunto pequeno S.
- Útil para compressão sem perdas de elementos de um universo grande para um contradomínio pequeno.

Lema 12
Seja $\mathcal{H} \subseteq N^U$ independente par a par e $S \subseteq U$ com $|S| = m$ e $m^2 \leq n$. Então

$$\mathbb{P}_{h \in \mathcal{H}}[h \text{ é livre de colisões para } S] \geq \frac{1}{2}.$$

Hash livre de colisões: prova

Proof.

Seja $C = \sum_{\{x,y\} \subseteq S,\, x \neq y} \mathbb{1}_{[h(x)=h(y)]}$ o número de pares de S que colidem. Então

$$\mathbb{E}\, C = \sum_{\{x,y\} \subseteq S} \mathbb{P}_h[h(x) = h(y)] = \binom{m}{2} \frac{1}{n} \leq \frac{m^2}{2n} \leq \frac{1}{2}.$$

Como C é inteira e não negativa, pela desigualdade de Markov

$$\mathbb{P}[C \geq 1] \leq \mathbb{E}\, C \leq \tfrac{1}{2}.$$

Logo pelo menos metade das funções $h \in \mathcal{H}$ é livre de colisões para S. □

Dicionários: o problema

- Escrevemos $N_t = \{0, 1, \ldots, t-1\}$ (assim $N = N_n$). Supomos que, para todo t, existe uma família independente par a par $\mathcal{H} \subseteq N_t^U$. (Nossas construções exigiam t primo ou potência de primo, o que no máximo dobra o contradomínio e muda o espaço só por um fator constante.)
- Dado $S \subseteq U$ com $|S| = m$, queremos uma estrutura que responda "$x \in S$?", minimizando espaço e tempo de consulta.
- Guardar S como lista de m elementos: espaço $O(m \log u)$ e consulta em tempo $O(m \log u)$.
- Com hashing, podemos melhorar.

Esquema simples de hashing

- Tome $t = m^2$ e $\mathcal{H} \subseteq N_{m^2}^U$ independente par a par.
- Uma $h \in \mathcal{H}$ sorteada é livre de colisões em S com probabilidade $\geq \frac{1}{2}$; basta sortear até acertar (em média, 2 tentativas).
- Seja A um vetor de tamanho m^2, quase vazio, com $A[h(x)] = x$ para todo $x \in S$.
- **Consulta:** calcule $h(x)$ e verifique se $A[h(x)] = x$. Tempo $O(\log u)$.
- **Problema:** espaço grande. Para guardar m elementos usamos m^2 posições (pelo menos m^2 bits, talvez até $O(m^2 \log u)$).

Veremos um esquema em dois níveis, de Ajtai, Komlós e Szemerédi, que evita esse desperdício: espaço $O(m \log m + \log u)$ e consulta ainda em $O(\log u)$.

Esquema de Ajtai–Komlós–Szemerédi: preparação

- Passo preliminar: aplicamos o hash livre de colisões anterior.
- A partir daqui supomos $u = O(m^2)$ e $S \subseteq U$ com $|S| = m$.

Passo 1. Encontrar $h\colon U \to N_m$ com poucas colisões. Seja C_h o número de pares de S que colidem sob h:

$$C_h = |\{\, \{x, y\} \subseteq S \colon x \neq y,\ h(x) = h(y) \,\}|.$$

Se $\mathcal{H} \subseteq N_m^U$ é independente par a par:

$$\mathbb{E}_{h \in \mathcal{H}}\, C_h = \sum_{\{x,y\} \subseteq S} \mathbb{P}[h(x) = h(y)] = \binom{m}{2} \frac{1}{m} \leq \frac{m^2}{2m} = \frac{m}{2}.$$

Pela desigualdade de Markov, $\mathbb{P}_h[C_h \geq m] \leq \frac{1}{2}$. Em média, em 2 sorteios achamos h com $C_h \leq m$. Fixamos essa h, representada por apenas $O(\log m)$ bits.

Esquema AKS: Passo 2

Para $i \in N_m$, seja $S_i = \{\, x \in S : h(x) = i \,\}$. Observe que $\sum_i |S_i| = m$ e

$$\sum_i \binom{|S_i|}{2} = C_h \leq m.$$

Seja $m_i = |S_i|^2$. Então $\sum_i m_i = 2\,C_h + \sum_i |S_i| \leq 3m$.

- Para cada i, escolhemos $h_i : U \to N_{m_i}$ livre de colisões em S_i, sorteando de uma família independente par a par $\mathcal{H}_i$ (sucesso em média em 2 tentativas); tempo total $O(m)$ para achar todas.
- Cada h_i ocupa $O(\log m)$ bits; no total, $O(m \log m)$ bits.
- Seja A um vetor de tamanho $3m$ e $\mathrm{offset}_i = \sum_{j<i} m_j$. O sub-vetor $A[\mathrm{offset}_i : \mathrm{offset}_i + m_i]$ guarda os elementos de S_i:

$$A[\mathrm{offset}_i + h_i(x)] = x \qquad \forall x \in S_i.$$

- Não há colisões em A, pois cada h_i é livre de colisões em S_i. Guardamos também $\{\, \mathrm{offset}_i \,\}$ em outro vetor.

Esquema AKS: consulta, espaço e tempo de preparação

Consulta ("$x \in S$?"):

1. calcule $i = h(x)$;
2. leia offset_i;
3. verifique se $A[\mathrm{offset}_i + h_i(x)] = x$.

Custo: $O(\log m)$ operações de bit.

Espaço. h: $O(\log m)$ bits; $\{ h_i \}$: $O(m \log m)$ bits; A: $O(m \log m)$ bits.

Tempo de preparação (aleatorizado; esperado $O(m \log m)$ operações de bit):

- achar h: $O(m \log m)$ (tempo para verificar que não há colisões em excesso);
- achar cada h_i: $O(|S_i| \log m)$, em total $O(m \log m)$;
- montar $\{ \mathrm{offset}_i \}$ e A: $O(m \log m)$.

Modelo de bits vs. modelo RAM

- Até aqui contamos operações de bit.
- Computadores operam eficientemente sobre palavras. O modelo RAM permite operações básicas sobre palavras de $\log m$ bits.
- Nesse modelo, verifica-se que:
  - tempo de consulta: $O(1)$ operações de palavra;
  - espaço: $O(m)$ palavras;
  - tempo de preparação: $O(m)$ operações de palavra.

Filtros de Bloom

- Estrutura ainda mais eficiente para pertinência, se tolerarmos alguns erros.
- Seja $S \subseteq U$ com $|S| = m$ e $h\colon U \to N$ uma função de hash uniforme ($n = |N|$ a determinar).
- Mantemos um vetor de bits A de tamanho n, inicialmente zero. Para cada $x \in S$, fazemos $A[h(x)] = 1$.
- Para testar $x \in S$, respondemos "sim" se $A[h(x)] = 1$.

Garantias:

- Sem falsos negativos: se $x \in S$, sempre respondemos "sim".
- Poucos falsos positivos: se $x \notin S$, respondemos "sim" com probabilidade $\dfrac{|\{\, i \in N\colon A[i] = 1 \,\}|}{n}$.

Filtros de Bloom: escolha de n

- Com $n = 2m$, para $x \notin S$ respondemos "não" com probabilidade pelo menos $\frac{1}{2}$. Na verdade é mais, pois ao espalhar m elementos em $2m$ posições há colisões e o número de 1's fica menor que m.
- Para probabilidade $\frac{1}{2}$ basta $n \approx 1{,}44\, m$, pois

$$\mathbb{P}_h[A[i] = 0] = \mathbb{P}[h(x) \neq i,\ \forall x \in S] = \left(1 - \frac{1}{n}\right)^m \approx e^{-m/n}.$$

- Para $n = m/\ln 2 \approx 1{,}44\, m$, o número esperado de zeros em A é $n/2$.

Filtros de Bloom: conclusões

- Um filtro de Bloom usa $O(m)$ bits, muito menos que os $O(m \log u)$ bits necessários sem erros.
- Pode-se mostrar que h não precisa ser uniforme: uma função de hash $O(\log m)$-independente dá as mesmas garantias e pode ser armazenada de forma muito eficiente, com apenas $O(\log^2 m)$ bits.

Resumo: independência par a par

- **Independência par a par:** $\mathbb{P}[h(x) = i,\ h(y) = j] = 1/n^2$ para $x \neq y$; implica universal.
- **Construção:** $h_{(\mathrm{a},b)}(\mathrm{x}) = \langle \mathrm{a}, \mathrm{x} \rangle + b$ sobre $\mathbb{F}_2$ ou $\mathbb{F}_p$, com $|\mathcal{H}| = u \cdot n$.
- **MAXCUT:** $O(u)$ cadeias de u bits independentes par a par bastam para desaleatorizar a aproximação de fator 2; e u cadeias são necessárias.
- **Colisões:** se $m^2 \leq n$, ao menos metade das funções é livre de colisões em S.
- **Dicionários (AKS):** espaço $O(m)$ palavras e consulta em $O(1)$ no modelo RAM.
- **Filtros de Bloom:** $O(m)$ bits, sem falsos negativos e com poucos falsos positivos.