Hashing: funções aleatórias e colisões

J. D.

UFABC

Outubro 21, 2026

Roteiro

1. **Funções de hash** e por que precisamos de aleatoriedade
2. **Tabelas de espalhamento** e custo de busca com função aleatória
3. **A maior lista**: cota $O(\log n / \log \log n)$
4. **Paradoxo dos aniversários** e o limiar $\sqrt{n}$
5. **Variância** e independência par a par
6. **Síntese**: o que basta para famílias universais

Fio condutor

Uma função totalmente aleatória espalha bem, mas não tem descrição curta.
Quais propriedades dela *realmente* usamos?

O que é uma função de hash?

Definição 1

Uma função de hash é uma função $h\colon U \to N$, onde o universo U é *muito grande* e $N = \{0, 1, \ldots, n-1\}$.

- $h(x)$ é um "resumo" de x: ocupa pouco espaço, é comparável e serve de índice em tempo constante.
- Como $|U| \gg |N|$, há colisões: $x \neq y$ com $h(x) = h(y)$. Pelo princípio da casa dos pombos, não dá para evitá-las.

O que é uma função de hash?

Definição 1

Uma função de hash é uma função $h\colon U \to N$, onde o universo U é *muito grande* e $N = \{0, 1, \ldots, n-1\}$.

- $h(x)$ é um "resumo" de x: ocupa pouco espaço, é comparável e serve de índice em tempo constante.
- Como $|U| \gg |N|$, há colisões: $x \neq y$ com $h(x) = h(y)$. Pelo princípio da casa dos pombos, não dá para evitá-las.

Usos: dicionários (tabelas de espalhamento), impressões digitais e verificação de igualdade, desaleatorização, criptografia (exige mais: colisões difíceis de achar).

Foco desta aula

Propriedades *probabilísticas* de famílias de funções.

O que torna uma função de hash útil?

Não é ser injetora. São propriedades que dependem do uso:

(i) **fácil de computar**: $h(x)$ em tempo (quase) constante;

(ii) **descrição curta**: poucos bits para armazenar h;

(iii) **espalhar bem** os elementos de um conjunto $S \subseteq U$: valores $h(x)$, $x \in S$, aproximadamente uniformes em N, poucas colisões.

O que torna uma função de hash útil?

Não é ser injetora. São propriedades que dependem do uso:

(i) **fácil de computar**: $h(x)$ em tempo (quase) constante;

(ii) **descrição curta**: poucos bits para armazenar h;

(iii) **espalhar bem** os elementos de um conjunto $S \subseteq U$: valores $h(x)$, $x \in S$, aproximadamente uniformes em N, poucas colisões.

O problema com (iii)

Para *qualquer* h fixa, existe S em que todos colidem: basta escolher $m := |S|$ elementos numa mesma pré-imagem (tem tamanho $\geq |U|/n$). Nenhuma h determinística espalha bem *todos* os conjuntos.

O que torna uma função de hash útil?

Não é ser injetora. São propriedades que dependem do uso:

(i) **fácil de computar**: $h(x)$ em tempo (quase) constante;

(ii) **descrição curta**: poucos bits para armazenar h;

(iii) **espalhar bem** os elementos de um conjunto $S \subseteq U$: valores $h(x)$, $x \in S$, aproximadamente uniformes em N, poucas colisões.

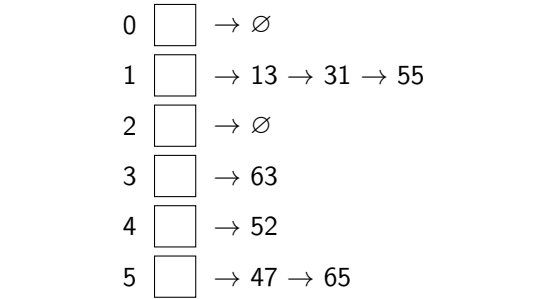
O problema com (iii)

Para *qualquer* h fixa, existe S em que todos colidem: basta escolher $m := |S|$ elementos numa mesma pré-imagem (tem tamanho $\geq |U|/n$). Nenhuma h determinística espalha bem *todos* os conjuntos.

Saída: sortear h de uma família $\mathcal{H}$ e analisar o comportamento *esperado*, ou com alta probabilidade, para qualquer S *fixo*.

Tabela de espalhamento (com listas ligadas)

- Vetor H com n posições; cada $H[i]$ é uma lista ligada.
- Acesso via $h\colon U \to \{0, 1, \ldots, n-1\}$: o elemento x vive na lista $H[h(x)]$.
- $S \subseteq U$ com $m = |S|$; o caso interessante é $m = \Theta(n)$.
- Um vetor de bits de tamanho $|U|$ daria busca $O(1)$, mas é inviável.



$S = \{13, 31, 47, 52, 55, 63, 65\}$, $h(x) = x \bmod 6$

Operações e custos

Inserção colocar x no início de $H[h(x)]$: custo constante.

Remoção (com apontador para x) retirar da lista: custo constante.

Busca percorrer a lista $H[h(x)]$. Pode ser *com sucesso* ($x \in S$) ou *sem sucesso* ($x \notin S$).

Operações e custos

Inserção colocar x no início de $H[h(x)]$: custo constante.

Remoção (com apontador para x) retirar da lista: custo constante.

Busca percorrer a lista $H[h(x)]$. Pode ser *com sucesso* ($x \in S$) ou *sem sucesso* ($x \notin S$).

Quem manda no desempenho?

O pior caso da busca é o tamanho da maior lista. Tudo se reduz a entender os tamanhos das listas, que dependem de como h distribui S.

Operações e custos

Inserção colocar x no início de $H[h(x)]$: custo constante.

Remoção (com apontador para x) retirar da lista: custo constante.

Busca percorrer a lista $H[h(x)]$. Pode ser *com sucesso* ($x \in S$) ou *sem sucesso* ($x \notin S$).

Quem manda no desempenho?

O pior caso da busca é o tamanho da maior lista. Tudo se reduz a entender os tamanhos das listas, que dependem de como h distribui S.

Primeiro modelo: h uniforme em N^U (todas as $n^{|U|}$ funções). Equivale a sortear, *independentemente* para cada $x \in U$, um valor $h(x)$ uniforme em N.

Função aleatória: probabilidade de colisão e carga

Para todo $x \in U$ e $i \in N$: $\mathbb{P}[h(x) = i] = \frac{1}{n}$.

Função aleatória: probabilidade de colisão e carga

Para todo $x \in U$ e $i \in N$: $\quad \mathbb{P}[h(x) = i] = \dfrac{1}{n}$.

Colisão de um par

Para $x \neq y$, por independência,

$$\mathbb{P}[h(x) = h(y)] = \sum_{i \in N} \mathbb{P}[h(x) = i]\, \mathbb{P}[h(y) = i] = n \cdot \frac{1}{n} \cdot \frac{1}{n} = \frac{1}{n}.$$

Função aleatória: probabilidade de colisão e carga

Para todo $x \in U$ e $i \in N$: $\quad \mathbb{P}[h(x) = i] = \dfrac{1}{n}$.

Colisão de um par

Para $x \neq y$, por independência,

$$\mathbb{P}[h(x) = h(y)] = \sum_{i \in N} \mathbb{P}[h(x) = i]\, \mathbb{P}[h(y) = i] = n \cdot \frac{1}{n} \cdot \frac{1}{n} = \frac{1}{n}.$$

Definição 2

A carga da tabela é $c = m/n$, o número esperado de elementos de S por posição.

Tamanho esperado da lista $H[h(x)]$

O número de itens na lista de x é $\sum_{y \in S} \mathbb{1}_{[h(x)=h(y)]}$, e

$$\mathbb{E}\, \mathbb{1}_{[h(x)=h(y)]} = \begin{cases} 1/n, & y \neq x, \\ 1, & y = x. \end{cases}$$

Tamanho esperado da lista $H[h(x)]$

O número de itens na lista de x é $\sum_{y \in S} \mathbb{1}_{[h(x)=h(y)]}$, e

$$\mathbb{E}\, \mathbb{1}_{[h(x)=h(y)]} = \begin{cases} 1/n, & y \neq x, \\ 1, & y = x. \end{cases}$$

Pela linearidade da esperança,

$$\mathbb{E}\left|H[h(x)]\right| = \begin{cases} \dfrac{m}{n} = c, & x \notin S, \\ \dfrac{m-1}{n} + 1 = c + \left(1 - \dfrac{1}{n}\right), & x \in S. \end{cases}$$

Tamanho esperado da lista $H[h(x)]$

O número de itens na lista de x é $\sum_{y \in S} \mathbb{1}_{[h(x)=h(y)]}$, e

$$\mathbb{E}\, \mathbb{1}_{[h(x)=h(y)]} = \begin{cases} 1/n, & y \neq x, \\ 1, & y = x. \end{cases}$$

Pela linearidade da esperança,

$$\mathbb{E}\left|H[h(x)]\right| = \begin{cases} \dfrac{m}{n} = c, & x \notin S, \\ \dfrac{m-1}{n} + 1 = c + \left(1 - \dfrac{1}{n}\right), & x \in S. \end{cases}$$

Conclusão

Com h aleatória em N^U, o tempo esperado de busca é proporcional à carga $O(1)$ quando $n = \Theta(m)$.

Custo esperado das buscas

Proposição 1

Seja H com n posições e h aleatória; elementos inseridos no início das listas. Então

1. *busca sem sucesso: tempo esperado $c + 1$;*
2. *busca com sucesso: tempo esperado $\frac{c}{2} + 1 - \frac{1}{2n}$.*

Custo esperado das buscas

Proposição 1

Seja H com n posições e h aleatória; elementos inseridos no início das listas. Então

1. *busca sem sucesso: tempo esperado $c + 1$;*
2. *busca com sucesso: tempo esperado $\dfrac{c}{2} + 1 - \dfrac{1}{2n}$.*

Ideia da prova do item 2. Se x foi o i-ésimo inserido, só os $m - i$ elementos inseridos *depois* podem ficar na frente de x; em média $(m - i)/n$ deles colidem com x. Logo

$$\frac{1}{m}\sum_{i=1}^{m}\left(1 + \frac{m-i}{n}\right) = 1 + \frac{m-1}{2n} = 1 + \frac{c}{2} - \frac{1}{2n}.$$

Qual é o problema?

O que ganhamos

- busca esperada $O(1)$;
- maior lista $O(\log m)$ com alta probabilidade (próximo bloco).

O que perdemos

- uma função aleatória em N^U precisa de $\approx |U| \log n$ bits para ser descrita;
- guardar h custa mais que o vetor de bits que queríamos evitar.

Qual é o problema?

O que ganhamos

- busca esperada $O(1)$;
- maior lista $O(\log m)$ com alta probabilidade (próximo bloco).

O que perdemos

- uma função aleatória em N^U precisa de $\approx |U| \log n$ bits para ser descrita;
- guardar h custa mais que o vetor de bits que queríamos evitar.

Pergunta

Das propriedades que usamos até aqui, quais dependem de h ser *totalmente aleatória.*

Vamos acompanhar isso ao longo das próximas análises.

A maior lista é sublogarítmica

Lema 3
Seja $X_i = |\{\, y \in S : h(y) = i \,\}|$, $c \leq 1$ *e* n *suficientemente grande. Então*

$$\mathbb{P}\left[\max_i X_i \;\geq\; \frac{8 \ln n}{\ln \ln n}\right] \;\leq\; \frac{1}{n}.$$

Como $n = \Theta(m)$, a maior lista tem tamanho $O(\log m / \log \log m)$ com probabilidade $\geq 1 - 1/n$.

Prova (1): cota para uma posição

Se $X_i \geq k$, existe $T \subseteq S$, $|T| = k$, com $h(y) = i$ para todo $y \in T$. Pela independência, cada T tem probabilidade n^{-k}. Pela cota da união,

$$\mathbb{P}[X_i \geq k] \leq \binom{m}{k} \frac{1}{n^k} \leq \frac{m^k}{k!\, n^k} = \frac{c^k}{k!} \leq \frac{1}{k!}.$$

Prova (1): cota para uma posição

Se $X_i \geq k$, existe $T \subseteq S$, $|T| = k$, com $h(y) = i$ para todo $y \in T$. Pela independência, cada T tem probabilidade n^{-k}. Pela cota da união,

$$\mathbb{P}[X_i \geq k] \leq \binom{m}{k} \frac{1}{n^k} \leq \frac{m^k}{k!\, n^k} = \frac{c^k}{k!} \leq \frac{1}{k!}.$$

De $e^k = \sum_{j \geq 0} k^j / j! \geq k^k / k!$ obtemos $k! \geq (k/e)^k$, logo

$$\mathbb{P}[X_i \geq k] \leq \left(\frac{e}{k}\right)^k.$$

Prova (1): cota para uma posição

Se $X_i \geq k$, existe $T \subseteq S$, $|T| = k$, com $h(y) = i$ para todo $y \in T$. Pela independência, cada T tem probabilidade n^{-k}. Pela cota da união,

$$\mathbb{P}[X_i \geq k] \leq \binom{m}{k} \frac{1}{n^k} \leq \frac{m^k}{k!\, n^k} = \frac{c^k}{k!} \leq \frac{1}{k!}.$$

De $e^k = \sum_{j \geq 0} k^j / j! \geq k^k / k!$ obtemos $k! \geq (k/e)^k$, logo

$$\mathbb{P}[X_i \geq k] \leq \left(\frac{e}{k}\right)^k.$$

Cota da união sobre as n listas (*não* precisamos que sejam independentes):

$$\mathbb{P}\big[\max_i X_i \geq k\big] \leq n\left(\frac{e}{k}\right)^k = n\, e^{-k(\ln k - 1)}.$$

Estimação de k

Queremos k tal que $e^{-k(\ln k - 1)} \leq e^{-2(\ln n)}$ ou seja

$$k \ln k = 2 \ln n$$

Queremos isolar k em termos de n para grandes valores de n.

Heurística k deve crescer com n, mas de forma muito mais lenta que n (pois k^k cresce super-exponencialmente), testamos um chute educado para k:

$$k = \frac{c \ln n}{f(n)}$$

onde $1 \ll f(n) \ll \ln n$ é alguma função de crescimento lento e C é uma constante.

Calculando $\ln k$

$$k = \frac{C \ln n}{f(n)} \quad \Longrightarrow \quad \ln k = \ln C + \ln(\ln n) - \ln(f(n))$$

Para n grande, o termo dominante em $\ln k$ é $\ln(\ln n)$, logo

$$\ln k \approx \ln \ln n$$

e

$$k \ln k \approx \left(\frac{C \ln n}{f(n)} \right) (\ln \ln n)$$

de volta à estimação da probabilidade

$$\frac{C \ln n \cdot \ln \ln n}{f(n)} \approx 2 \ln n \quad \Longrightarrow \quad \frac{C \ln \ln n}{f(n)} \approx 2 \quad \Longrightarrow \quad f(n) = \Theta(\ln \ln(n))$$

Calculando $\ln k$

Para que essa igualdade seja consistente para qualquer n grande, a função $f(n)$ no denominador precisa cancelar o $\ln \ln n$ do numerador. Portanto, escolhemos:

$$f(n) = \ln \ln n \quad \text{e} \quad c = 2$$

Substituindo de volta, chegamos à forma assintótica:

$$k \sim \frac{2 \ln n}{\ln \ln n}$$

Em termos de ordem de grandeza (notação Θ), o fator constante 2 é absorvido, concluindo que:

$$k = \Theta\left(\frac{\ln n}{\ln \ln n}\right)$$

Prova (2): escolha de k

Tome $k_0 = \dfrac{8 \ln n}{\ln \ln n}$, $k = \lceil k_0 \rceil$, $y = \ln \ln n$ e $\phi(t) = t(\ln t - 1)$, crescente para $t \geq 1$.

Prova (2): escolha de k

Tome $k_0 = \dfrac{8 \ln n}{\ln \ln n}$, $k = \lceil k_0 \rceil$, $y = \ln \ln n$ e $\phi(t) = t(\ln t - 1)$, crescente para $t \geq 1$.

- $\ln k_0 = \ln 8 + y - \ln y \ \geq \ \frac{1}{2} y$ (pois $\ln y \leq \frac{y}{2} + \ln 8$ para todo $y > 0$);
- para n grande, $y \geq 4$, então $\ln k_0 - 1 \geq \frac{1}{2} y - 1 \geq \frac{1}{4} y$.

Prova (2): escolha de k

Tome $k_0 = \dfrac{8 \ln n}{\ln \ln n}$, $k = \lceil k_0 \rceil$, $y = \ln \ln n$ e $\phi(t) = t(\ln t - 1)$, crescente para $t \geq 1$.

- $\ln k_0 = \ln 8 + y - \ln y \ \geq \ \frac{1}{2} y$ (pois $\ln y \leq \frac{y}{2} + \ln 8$ para todo $y > 0$);
- para n grande, $y \geq 4$, então $\ln k_0 - 1 \geq \frac{1}{2} y - 1 \geq \frac{1}{4} y$.

Logo

$$\phi(k) \geq \phi(k_0) = k_0(\ln k_0 - 1) \geq \frac{8 \ln n}{y} \cdot \frac{y}{4} = 2 \ln n,$$

e portanto

$$\mathbb{P}\big[\max_i X_i \geq k\big] \leq n\, e^{-\phi(k)} \leq n\, e^{-2 \ln n} = \frac{1}{n}. \qquad \blacksquare$$

Observações sobre a cota

- **Carga constante.** Se $c \leq C$, a cota vira $(Ce/k)^k$; basta trocar e por Ce e ajustar a constante 8.

Observações sobre a cota

- **Carga constante.** Se $c \leq C$, a cota vira $(Ce/k)^k$; basta trocar e por Ce e ajustar a constante 8.
- **A cota é justa.** Um argumento de segundo momento sobre o número de listas com $\geq k$ elementos mostra que, com alta probabilidade, a maior lista tem tamanho $\Omega(\log n / \log\log n)$. Portanto

$$\max_i X_i = \Theta\Big(\frac{\log n}{\log\log n}\Big).$$

Observações sobre a cota

- **Carga constante.** Se $c \leq C$, a cota vira $(Ce/k)^k$; basta trocar e por Ce e ajustar a constante 8.
- **A cota é justa.** Um argumento de segundo momento sobre o número de listas com $\geq k$ elementos mostra que, com alta probabilidade, a maior lista tem tamanho $\Omega(\log n / \log\log n)$. Portanto

$$\max_i X_i = \Theta\Big(\frac{\log n}{\log\log n}\Big).$$

- **O que foi usado?** A independência de k valores $h(y)$ ao mesmo tempo (probabilidade n^{-k} para cada T).

Este resultado precisa de "muita independência".

Número esperado de colisões

Seja C o número de pares $\{x, y\} \subseteq S$ que colidem: $C = \sum_{\{x,y\}} \mathbb{1}_{[h(x)=h(y)]}$. Por linearidade,

$$\mathbb{E}\, C = \binom{m}{2} \frac{1}{n} = \frac{m(m-1)}{2n}.$$

Número esperado de colisões

Seja C o número de pares $\{x, y\} \subseteq S$ que colidem: $C = \sum_{\{x,y\}} \mathbb{1}_{[h(x)=h(y)]}$. Por linearidade,

$$\mathbb{E}\, C = \binom{m}{2} \frac{1}{n} = \frac{m(m-1)}{2n}.$$

Pela desigualdade de Markov,

$$\mathbb{P}[C = 0] \;\geq\; 1 - \mathbb{E}\, C = 1 - \frac{m(m-1)}{2n}.$$

Em particular, para $m = \sqrt{n}$: $\mathbb{E}\, C < \frac{1}{2}$ e $\mathbb{P}[C = 0] \geq \frac{1}{2}$.

Número esperado de colisões

Seja C o número de pares $\{x, y\} \subseteq S$ que colidem: $C = \sum_{\{x,y\}} \mathbb{1}_{[h(x)=h(y)]}$. Por linearidade,

$$\mathbb{E}\, C = \binom{m}{2} \frac{1}{n} = \frac{m(m-1)}{2n}.$$

Pela desigualdade de Markov,

$$\mathbb{P}[C = 0] \;\geq\; 1 - \mathbb{E}\, C = 1 - \frac{m(m-1)}{2n}.$$

Em particular, para $m = \sqrt{n}$: $\mathbb{E}\, C < \frac{1}{2}$ e $\mathbb{P}[C = 0] \geq \frac{1}{2}$.

Observação

Só usamos $\mathbb{P}[h(x) = h(y)] = 1/n$ para pares. Isto é informação sobre pares.

Probabilidade de nenhuma colisão

Para $m \leq n$ há $n(n-1)\cdots(n-m+1)$ sequências sem repetição em N^m:

$$\mathbb{P}[C = 0] = \prod_{j=1}^{m-1}\Big(1 - \frac{j}{n}\Big) \;<\; \prod_{j=1}^{m-1} e^{-j/n} = \exp\Big(-\frac{m(m-1)}{2n}\Big),$$

usando $1 - x < e^{-x}$.

Probabilidade de nenhuma colisão

Para $m \leq n$ há $n(n-1)\cdots(n-m+1)$ sequências sem repetição em N^m:

$$\mathbb{P}[C = 0] = \prod_{j=1}^{m-1}\Big(1 - \frac{j}{n}\Big) \;<\; \prod_{j=1}^{m-1} e^{-j/n} = \exp\Big(-\frac{m(m-1)}{2n}\Big),$$

usando $1 - x < e^{-x}$.

Paradoxo dos aniversários ($m = 23$, $n = 365$)

$$\mathbb{P}[C > 0] > 1 - e^{-506/730} > \tfrac{1}{2},$$

pois $506/730 \approx 0{,}693151 > \ln 2 \approx 0{,}693147$. Basta uma turma de 23 pessoas para haver aniversário repetido com probabilidade $> 1/2$.

O limiar $\sqrt{n}$

Cota inferior. Para $x \in (0, 3/4]$, $1 - x > e^{-2x}$. Se $m \leq \frac{3}{4}n$,

$$\mathbb{P}[C = 0] > \prod_{j=1}^{m-1} e^{-2j/n} = \exp\Big(-\frac{m(m-1)}{n}\Big).$$

O limiar $\sqrt{n}$

Cota inferior. Para $x \in (0, 3/4]$, $1 - x > e^{-2x}$. Se $m \le \frac{3}{4}n$,

$$\mathbb{P}[C = 0] > \prod_{j=1}^{m-1} e^{-2j/n} = \exp\Big(-\frac{m(m-1)}{n}\Big).$$

- Se $m \le \sqrt{n}$: $\mathbb{P}[C = 0] > e^{-1} > 0{,}36$ (limitada por constante positiva).
- Se $m = \omega(\sqrt{n})$: a cota superior $e^{-m(m-1)/(2n)} \to 0$.

O limiar $\sqrt{n}$

Cota inferior. Para $x \in (0, 3/4]$, $1 - x > e^{-2x}$. Se $m \le \frac{3}{4}n$,

$$\mathbb{P}[C = 0] > \prod_{j=1}^{m-1} e^{-2j/n} = \exp\Big(-\frac{m(m-1)}{n}\Big).$$

- Se $m \le \sqrt{n}$: $\mathbb{P}[C = 0] > e^{-1} > 0{,}36$ (limitada por constante positiva).
- Se $m = \omega(\sqrt{n})$: a cota superior $e^{-m(m-1)/(2n)} \to 0$.

Limiar

$\sqrt{n}$ é o limiar para o aparecimento de colisões.

Markov dá $\mathbb{P}[C = 0] \ge 1 - \mathbb{E}C > \frac{1}{2}$ para $m \le \sqrt{n}$, melhor que e^{-1} nesse regime, mas vira trivial para $m \ge \sqrt{2n} + 1$ (onde $\mathbb{E}C \ge 1$). A cota exponencial vale até $m \le \frac{3}{4}n$.

Variância do tamanho de uma lista

Seja $X_i = \sum_{x \in S} \mathbb{1}_{[h(x)=i]}$, com $\mathbb{E}X_i = c$. Para $x \neq y$ os indicadores são independentes. Então

$$\text{Var}(\, X\,)_i = \sum_{x \in S} \frac{1}{n}\Big(1 - \frac{1}{n}\Big) = c\Big(1 - \frac{1}{n}\Big).$$

Variância do tamanho de uma lista

Seja $X_i = \sum_{x \in S} \mathbb{1}_{[h(x)=i]}$, com $\mathbb{E}X_i = c$. Para $x \neq y$ os indicadores são independentes. Então

$$\text{Var}(\, X \,)_i = \sum_{x \in S} \frac{1}{n}\Big(1 - \frac{1}{n}\Big) = c\Big(1 - \frac{1}{n}\Big).$$

Chebyshev:

$$\mathbb{P}[\,|X_i - c| \geq t\,] \leq \frac{c(1 - 1/n)}{t^2} \leq \frac{c}{t^2}.$$

Variância do tamanho de uma lista

Seja $X_i = \sum_{x \in S} \mathbb{1}_{[h(x)=i]}$, com $\mathbb{E}X_i = c$. Para $x \neq y$ os indicadores são independentes. Então

$$\mathrm{Var}(\, X\,)_i = \sum_{x \in S} \frac{1}{n}\Big(1 - \frac{1}{n}\Big) = c\Big(1 - \frac{1}{n}\Big).$$

Chebyshev:

$$\mathbb{P}[\,|X_i - c| \geq t\,] \leq \frac{c(1-1/n)}{t^2} \leq \frac{c}{t^2}.$$

Com $t = c$: $\mathbb{P}[X_i \geq 2c] \leq \frac{1}{c}$, só útil para c grande.

Observação-chave

Esta conta só usa que os indicadores $\mathbb{1}_{[h(x)=i]}$ são independentes dois a dois.

Maior lista via Chebyshev

Cota da união sobre as n listas:

$$\mathbb{P}\big[\max_i X_i \geq c + t\big] \leq n \cdot \frac{c}{t^2} = \frac{m}{t^2}.$$

Com $t = \sqrt{2m}$, a maior lista tem tamanho

$$\leq c + \sqrt{2m} = O(\sqrt{m})$$

com probabilidade pelo menos $1/2$.

Maior lista via Chebyshev

Cota da união sobre as n listas:

$$\mathbb{P}\big[\max_i X_i \geq c + t\big] \leq n \cdot \frac{c}{t^2} = \frac{m}{t^2}.$$

Com $t = \sqrt{2m}$, a maior lista tem tamanho

$$\leq c + \sqrt{2m} = O(\sqrt{m})$$

com probabilidade pelo menos $1/2$.

Comparação

Método	**Cota**	**Independência usada**
Cota da união sobre T	$O(\log n / \log\log n)$	muitas variáveis
Chebyshev	$O(\sqrt{m})$	só pares

Mais fraca, mas vale também para famílias com descrição curta.

Variância do número de colisões

$C = \sum_{\{x,y\}} \mathbb{1}_{[h(x)=h(y)]}$. Para pares distintos $\{x, y\} \neq \{z, w\}$:

- disjuntos: dependem de quatro valores independentes;
- com elemento comum ($\{x, y\}$ e $\{x, z\}$):

$$\mathbb{P}[h(x) = h(y) = h(z)] = \sum_{a \in N} \frac{1}{n^3} = \frac{1}{n^2} = \mathbb{P}[h(x) = h(y)]\,\mathbb{P}[h(x) = h(z)].$$

Variância do número de colisões

$C = \sum_{\{x,y\}} \mathbb{1}_{[h(x)=h(y)]}$. Para pares distintos $\{x, y\} \neq \{z, w\}$:

- disjuntos: dependem de quatro valores independentes;
- com elemento comum ($\{x, y\}$ e $\{x, z\}$):

$$\mathbb{P}[h(x) = h(y) = h(z)] = \sum_{a \in N} \frac{1}{n^3} = \frac{1}{n^2} = \mathbb{P}[h(x) = h(y)]\,\mathbb{P}[h(x) = h(z)].$$

Os indicadores são independentes dois a dois, logo $\mathrm{Var}(C) = \binom{m}{2}\left(\frac{1}{n} - \frac{1}{n^2}\right)$ e, por Chebyshev,

$$\mathbb{P}[C = 0] \leq \frac{\mathrm{Var}(C)}{(\mathbb{E}C)^2} = \frac{n(1 - 1/n)}{\binom{m}{2}} \approx \frac{2n}{m^2}.$$

Para $m \gg \sqrt{n}$ há colisão com alta probabilidade, complementando o limiar do paradoxo dos aniversários.

Cuidado: onde a independência de ordem maior entra

Na conta acima, a igualdade

$$\mathbb{P}[h(x) = h(y) = h(z)] = \mathbb{P}[h(x) = h(y)]\,\mathbb{P}[h(x) = h(z)]$$

usa a independência de três valores $h(x), h(y), h(z)$, e o caso de pares disjuntos usa quatro.

Cuidado: onde a independência de ordem maior entra

Na conta acima, a igualdade

$$\mathbb{P}[h(x) = h(y) = h(z)] = \mathbb{P}[h(x) = h(y)]\,\mathbb{P}[h(x) = h(z)]$$

usa a independência de três valores $h(x), h(y), h(z)$, e o caso de pares disjuntos usa quatro.

Consequência

A fórmula para Var(C) vale para a função totalmente aleatória (e para famílias com independência de ordem 4), mas não para famílias apenas 2-universais, para as quais só se garante $\mathbb{E}\, C = \binom{m}{2}/n$.

Já a variância de X_i usa apenas independência par a par.

O que usamos de cada propriedade

Resultado	**Propriedade necessária**
$\mathbb{E}\, C = \binom{m}{2}/n$, tempo esperado de busca	$\mathbb{P}[h(x) = h(y)] \leq 1/n$ (pares)
$\mathrm{Var}(\, X\,)_i$, maior lista $O(\sqrt{m})$	independência par a par
$\mathrm{Var}(\, C\,)$	independência de ordem 4
maior lista $\Theta(\log n / \log\log n)$	independência de muitas variáveis

O que usamos de cada propriedade

Resultado	**Propriedade necessária**
$\mathbb{E}\, C = \binom{m}{2}/n$, tempo esperado de busca	$\mathbb{P}[h(x) = h(y)] \leq 1/n$ (pares)
$\mathrm{Var}(\, X\,)_i$, maior lista $O(\sqrt{m})$	independência par a par
$\mathrm{Var}(\, C\,)$	independência de ordem 4
maior lista $\Theta(\log n / \log\log n)$	independência de muitas variáveis

Ideia central

Qualquer família em que dois elementos distintos colidem com probabilidade $\leq 1/n$ tem, no máximo, o mesmo número esperado de colisões que uma função aleatória.

Para onde vamos: famílias universais

Funções aleatórias não são práticas: descrição de tamanho $\approx |U|$.

Para onde vamos: famílias universais

Funções aleatórias não são práticas: descrição de tamanho $\approx |U|$.

A meta

Uma família $\mathcal{H} \subseteq N^U$ *pequena* tal que, para $h \in \mathcal{H}$ uniforme,

$$\mathbb{P}_h[h(x) = h(y)] \leq \frac{1}{n} \qquad \text{para todos } x \neq y \text{ em } U,$$

com funções fáceis de computar e descrição curta.

Para onde vamos: famílias universais

Funções aleatórias não são práticas: descrição de tamanho $\approx |U|$.

A meta

Uma família $\mathcal{H} \subseteq N^U$ *pequena* tal que, para $h \in \mathcal{H}$ uniforme,

$$\mathbb{P}_h[h(x) = h(y)] \leq \frac{1}{n} \qquad \text{para todos } x \neq y \text{ em } U,$$

com funções fáceis de computar e descrição curta.

- Comportar-se como função aleatória é propriedade da *família*, não de uma função isolada.
- Tudo que depende só de pares continuará valendo (esperança de colisões, tempo esperado de busca, $\mathrm{Var}(X)_i$).

Resumo

- Colisões são inevitáveis; nenhuma h fixa serve para todo S, então sorteamos h.
- Com h aleatória em N^U: busca esperada $O(1)$ para $n = \Theta(m)$.
- Maior lista: $\Theta(\log n / \log \log n)$ com alta probabilidade (cota da união + $k! \geq (k/e)^k$).
- Paradoxo dos aniversários: limiar de colisão em $m \approx \sqrt{n}$.
- Variância via Chebyshev precisa só de independência par a par; Var(C) precisa de mais.

Próxima aula

Famílias universais e 2-universais: descrição curta com garantias de pares.