# Relaxação e arredondamento aleatório

## Corte máximo e o algoritmo de Goemans–Williamson

Algoritmos Probabilísticos

J.D.

# Roteiro

Relaxação e arredondamento

Corte máximo

Análise

Conclusão

Satisfabilidade máxima

Conclusão

# Relaxação e arredondamento

# Motivação

Muitos problemas de otimização combinatória são NP-difíceis, então buscamos algoritmos de aproximação.

**Estratégia geral:**

1. relaxar o problema em um que saibamos resolver eficientemente;
2. arredondar aleatoriamente a solução obtida.

Aplicações neste capítulo:

- corte máximo $\rightarrow$ relaxação **semidefinida**;
- satisfabilidade máxima $\rightarrow$ relaxação **linear**.

# Relaxação de um problema de programação matemática

Problema $P$ de maximização:

$$\mathrm{opt}(P) := \sup\{\, f(x) \colon x \in X \,\}.$$

Uma relaxação: $X'$,

# Relaxação de um problema de programação matemática

Problema $P$ de maximização:

$$\mathrm{opt}(P) := \sup\{\, f(x) \colon x \in X \,\}.$$

Uma relaxação: $X'$, $f' \colon X' \to \mathbb{R}$ e

# Relaxação de um problema de programação matemática

Problema $P$ de maximização:

$$\operatorname{opt}(P) := \sup\{\, f(x) \colon x \in X \,\}.$$

Uma relaxação: $X'$, $f' \colon X' \to \mathbb{R}$ e $\iota \colon X \hookrightarrow X'$ tais que

$$f'(\iota(x)) \geqslant f(x) \qquad \text{para todo } x \in X,$$

com $\operatorname{opt}(R) := \sup\{\, f'(y) \colon y \in X' \,\}$.

Em geral $X \subseteq X'$ e $\iota$ é a inclusão (restrições afrouxadas), mas nem sempre: no max-cut, $X = \{-1, 1\}^n$ e $X'$ é o conjunto das $n$-uplas de vetores unitários, com $\iota(x) = (x_1 \mathrm{e}, \ldots, x_n \mathrm{e})$.

# A relaxação limita o ótimo

Para todo $x \in X$,

$$\operatorname{opt}(R) \geqslant f'(\iota(x)) \geqslant f(x).$$

Tomando o supremo sobre $x \in X$:

$$\boxed{\operatorname{opt}(R) \geqslant \operatorname{opt}(P)}$$

Limitante superior para o ótimo do problema original (inverte-se para minimização).

A relaxação só é útil se $R$ é resolvível eficientemente:

- exatamente (programas lineares), ou
- com erro arbitrariamente pequeno (programas semidefinidos).

# Exemplo: max sat PPI

Considere a fórmula

$$\varphi = (x_1 \vee \neg x_2) \wedge (\neg x_1 \vee x_3) \wedge (x_2 \vee x_3).$$

A formulação correspondente é:

$$\begin{aligned} \max \quad & z_1 + z_2 + z_3 \\ \text{sujeito a} \quad & z_1 \leqslant x_1 + (1 - x_2), \\ & z_2 \leqslant (1 - x_1) + x_3, \\ & z_3 \leqslant x_2 + x_3, \\ & x_1, x_2, x_3 \in \{0, 1\}, \\ & z_1, z_2, z_3 \in \{0, 1\}. \end{aligned}$$

# Exemplo: max sat Relaxação

Considere a fórmula

$$\varphi = (x_1 \vee \neg x_2) \wedge (\neg x_1 \vee x_3) \wedge (x_2 \vee x_3).$$

A relaxação é:

$$\begin{aligned} \max \quad & z_1 + z_2 + z_3 \\ \text{sujeito a} \quad & z_1 \leqslant y_1 + (1 - y_2), \\ & z_2 \leqslant (1 - y_1) + y_3, \\ & z_3 \leqslant y_2 + y_3, \\ & y_1, y_2, y_3 \in [0, 1], \\ & z_1, z_2, z_3 \in [0, 1]. \end{aligned}$$

# Arredondamento aleatório

Solução ótima de $R$ em geral não é viável para $P$.

**Arredondamento aleatório:** converte uma solução de $R$ em uma de $P$ por sorteios cujas distribuições vêm da própria solução de $R$.

- max-sat: variável $i$ é $\lceil \widehat{y}_i \rceil$ com probabilidade $\widehat{y}_i$, independentemente;
- max-cut: sorteia-se $r$ uniforme na esfera e $i \in S$ se $\langle v_i, r \rangle > 0$.

# Esquema geral de análise

Resolva $R$ (solução ótima $\widehat{y}$) e arredonde $\widehat{y}$ aleatoriamente, obtendo uma solução de $P$. O valor de uma solução é soma de parcelas, uma por cláusula (ou aresta):

- $W = \sum_k W_k$: valor da solução arredondada (aleatório);
- $\widehat{W_k}$: parcela $k$ avaliada em $\widehat{y}$ (fixo), com $\operatorname{opt}(R) = \sum_k \widehat{W_k}$.

1. $\mathbb{E}W = \sum_k \mathbb{E}W_k$ (linearidade da esperança).
2. Parcela a parcela: $\mathbb{E}W_k \geqslant c\,\widehat{W_k}$, com $c \in (0, 1]$ independente da instância.
3. Somando: $\mathbb{E}W \geqslant c \operatorname{opt}(R) \geqslant c \operatorname{opt}(P)$.

Razão de aproximação $c$, sem conhecer $\operatorname{opt}(P)$: $\alpha \approx 0{,}878$ (max-cut); $3/4$ (max-sat).

# Esquema geral de análise

Seja $W = \sum_k W_k$ o valor obtido e $\widehat{W}_k$ a parcela correspondente em uma solução ótima de $R$, com $\operatorname{opt}(R) = \sum_k \widehat{W}_k$.

1. Linearidade da esperança: $\mathbb{E}W = \sum_k \mathbb{E}W_k$.
2. Parcela a parcela: $\mathbb{E}W_k \geqslant c\,\widehat{W}_k$, com $c \in (0, 1]$ independente da instância.
3. Somando:
$$\mathbb{E}W \geqslant c \sum_k \widehat{W}_k = c \operatorname{opt}(R) \geqslant c \operatorname{opt}(P).$$

Razão de aproximação $c$, sem conhecer $\operatorname{opt}(P)$.

$c = \alpha \approx 0{,}878$ (max-cut), $c = 1 - 1/\mathrm{e} \approx 0{,}632$ e depois $3/4$ (max-sat).

# Do valor esperado a uma solução

Pelo princípio do primeiro momento, existe solução de valor $\geqslant c\,\mathrm{opt}(P)$. Duas maneiras de obtê-la:

- desaleatorizar (método das esperanças condicionais);
- repetir o sorteio e ficar com o melhor.

Com $Z = \mathrm{opt}(P) - W \geqslant 0$ e $\mathbb{E}Z \leqslant (1-c)\mathrm{opt}(P)$, Markov dá

$$\mathbb{P}(\, W \geqslant (1-\varepsilon)c\,\mathrm{opt}(P)\,) \geqslant \frac{\varepsilon c}{1-c+\varepsilon c} \geqslant \varepsilon c.$$

Com $t = \lceil (\varepsilon c)^{-1} \ln(1/\delta) \rceil$ repetições independentes, falha com probabilidade $\leqslant (1-\varepsilon c)^t \leqslant \delta$.

# Do valor esperado a uma solução

Sabemos $\mathbb{E}W \geqslant c\,\mathrm{opt}(P)$. Queremos uma execução boa.

**Passo 1: Markov na perda.** Como $W \leqslant \mathrm{opt}(P)$, a variável $Z = \mathrm{opt}(P) - W \geqslant 0$ mede o que falta, e $\mathbb{E}Z \leqslant (1-c)\mathrm{opt}(P)$. Então $W < (1-\varepsilon)c\,\mathrm{opt}(P)$ equivale a $Z > (1-c+\varepsilon c)\mathrm{opt}(P)$, e

$$\mathbb{P}(\, W \geqslant (1-\varepsilon)c\,\mathrm{opt}(P)\,) \geqslant 1 - \frac{1-c}{1-c+\varepsilon c} = \frac{\varepsilon c}{1-c+\varepsilon c} \geqslant \varepsilon c.$$

Com $\varepsilon = 0$ a cota é inútil: a folga $\varepsilon$ é o que torna a probabilidade de sucesso positiva.

# Do valor esperado a uma solução

**Passo 2: repetir.** Com $t = \lceil (\varepsilon c)^{-1} \ln(1/\delta) \rceil$ execuções independentes, todas falham com probabilidade

$$\leqslant (1 - \varepsilon c)^t \leqslant \mathrm{e}^{-\varepsilon c t} \leqslant \delta.$$

Ficando com a melhor, obtemos valor $\geqslant (1 - \varepsilon) c \operatorname{opt}(P)$ com probabilidade $\geqslant 1 - \delta$.

Exemplo: $c \approx 0{,}878$ e $\varepsilon = 0{,}01$ dão $t \approx 114 \ln(1/\delta)$.

# Corte máximo

# O problema do corte máximo

$G = (V, E)$, $V = \{1, \ldots, n\}$, pesos $\rho_{ij} = \rho_{ji} \geqslant 0$ ($\rho_{ij} = 0$ se $ij \notin E$).

Peso do corte de $S \subseteq V$:

$$w(\nabla(S)) \coloneqq \sum_{i \in S,\ j \notin S} \rho_{ij}.$$

max-cut: encontrar $S$ que maximize $w(\nabla(S))$.

- NP-difícil, mesmo com $\rho_{ij} \in \{0, 1\}$.
- Håstad: se $\mathrm{P} \neq \mathrm{NP}$, não há aproximação com razão $> 16/17$.
- Goemans–Williamson (1995): razão $\approx 0{,}878$ com relaxação semidefinida.

# Formulação como programa quadrático inteiro

Variável $x_i \in \{-1, 1\}$, com $x_i = 1$ se $i \in S$. Então $1 - x_i x_j = 2$ se $ij$ está no corte e 0 caso contrário:

$$\text{(PQI)} \qquad \begin{aligned} \text{maximizar} \quad & \tfrac{1}{2} \sum_{i<j} \rho_{ij}(1 - x_i x_j) \\ \text{sujeito a} \quad & x_i \in \{-1, 1\},\ \forall i \in V. \end{aligned}$$

Equivalente ao max-cut (logo NP-difícil). Vamos relaxá-lo.

# A relaxação vetorial (RV)

Troca-se $x_i \in \{-1, 1\}$ por vetores unitários $v_i$ e $x_i x_j$ por $\langle v_i, v_j \rangle$:

$$\text{(RV)} \qquad \begin{aligned} &\text{maximizar} && \tfrac{1}{2} \sum_{i<j} \rho_{ij} \big(1 - \langle v_i, v_j \rangle\big) \\ &\text{sujeito a} && v_i \in \mathbb{S}^{n-1}, \ \forall i \in V. \end{aligned}$$

- É relaxação: com $\iota(x) = (x_1 \mathrm{e}, \ldots, x_n \mathrm{e})$, $\langle x_i \mathrm{e}, x_j \mathrm{e} \rangle = x_i x_j$.

$$\gamma := \mathrm{opt}(\mathsf{RV}) \geqslant \mathrm{opt}(\mathsf{PQI}) = \mathrm{opt}.$$

# O algoritmo de arredondamento

Dada uma solução ótima $v_1, \ldots, v_n$ de (RV):

1. sorteie $r$ uniformemente em $\mathbb{S}^{n-1}$;
2. $S \coloneqq \{\, i \in V : \langle v_i, r \rangle > 0 \,\}$; devolva $\nabla(S)$.

Geometricamente: o hiperplano $h \perp r$ pela origem separa os vetores.

Intuição: vetores quase opostos ($\langle v_i, v_j \rangle \approx -1$) são separados com probabilidade próxima de 1; vetores próximos quase nunca. Como (RV) coloca vetores opostos em vértices que "querem" ficar em lados distintos, as arestas pesadas tendem a ser cortadas.

# Como sortear $r$ na esfera

**Truque:** $g = (g_1, \ldots, g_n)$ com $g_k \sim \mathcal{N}(0,1)$ independentes, densidade

$$\varphi(x) = (2\pi)^{-n/2} \mathrm{e}^{-\|x\|^2/2},$$

que depende de $x$ só por $\|x\|$. Então:

- $g$ é invariante por rotações ($Qg \sim g$ para $Q$ ortogonal);
- $r := g/\|g\|$ é uniforme em $\mathbb{S}^{n-1}$ (e independente de $\|g\|$);
- $\operatorname{sinal}\langle v, g\rangle = \operatorname{sinal}\langle v, r\rangle$: podemos usar $g$ no lugar de $r$.

Custo: $O(n)$ normais (Box–Muller) + $O(n^2)$ para os produtos internos.

# Análise

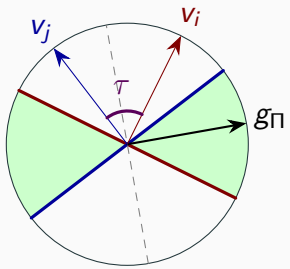
# Probabilidade de separação

**Proposição**

Para $i \neq j$, $\mathbb{P}(\operatorname{sinal}\langle v_i, r\rangle \neq \operatorname{sinal}\langle v_j, r\rangle) = \dfrac{1}{\pi}\arccos(\langle v_i, v_j\rangle)$.

**Ideia da prova:**

- Projete $g$ no plano $\Pi$ gerado por $v_i, v_j$: a projeção é uma gaussiana padrão em $\mathbb{R}^2$, de ângulo $\theta \in_{\mathrm{R}} [0, 2\pi)$.
- Com $\tau = \arccos\langle v_i, v_j\rangle$: $\langle v_i, g\rangle = \rho\cos\theta$, $\langle v_j, g\rangle = \rho\cos(\theta - \tau)$.
- Sinais diferem em dois arcos de comprimento $\tau$: probabilidade $\dfrac{2\tau}{2\pi} = \dfrac{\tau}{\pi}$.




Sinais diferem se, e só se, $g_\Pi$ cai nas regiões verdes.

# Peso esperado do corte

**Teorema**
Fixada a solução $v_1, \ldots, v_n$ de (RV), o peso $W$ do corte devolvido satisfaz

$$\mathbb{E}W = \frac{1}{\pi} \sum_{i<j} \rho_{ij} \arccos(\langle v_i, v_j \rangle).$$

**Prova.** Seja $X_{ij}$ o indicador de $ij \in \nabla(S)$. Pela proposição, $\mathbb{E}X_{ij} = \frac{1}{\pi} \arccos\langle v_i, v_j \rangle$. Como $W = \sum_{i<j} \rho_{ij} X_{ij}$, a linearidade da esperança conclui. □

# Fechamento: $\mathbb{E}[W] \geqslant \alpha\gamma \geqslant \alpha \operatorname{opt}$

Escreva $y_{ij} = \langle v_i, v_j \rangle$. Então

$$\mathbb{E}[W] = \sum_{i<j} \rho_{ij} \, \frac{\arccos(y_{ij})}{\pi}, \qquad \gamma = \sum_{i<j} \rho_{ij} \, \tfrac{1}{2}(1 - y_{ij}).$$

Queremos uma constante $\alpha$ tal que $\mathbb{E}[W] \geqslant \alpha\gamma$. Basta que, para todo $y \in [-1, 1]$,

$$\frac{\arccos(y)}{\pi} \;\geqslant\; \alpha \cdot \tfrac{1}{2}(1 - y).$$

Pondo $\psi = \arccos y$, a razão entre os dois lados é $\beta(\psi) = \dfrac{2}{\pi} \cdot \dfrac{\psi}{1 - \cos\psi}$ para $0 < \psi \leqslant \pi$.

A constante que funciona para todas as arestas é $\alpha = \min \beta$.

# A constante $\alpha$

**Proposição**

Seja $\beta(\psi) = \dfrac{2}{\pi} \cdot \dfrac{\psi}{1 - \cos\psi}$ para $0 < \psi \leqslant \pi$ e $\alpha := \min_{0<\psi\leqslant\pi} \beta(\psi)$. Então

1. $\alpha \approx 0{,}878567$, atingido em $\psi^* \approx 2{,}331122$;
2. para todo $-1 \leqslant y \leqslant 1$: $\dfrac{\arccos(y)}{\pi} \geqslant \alpha \cdot \dfrac{1}{2}(1 - y)$.

**Ideia:** $\beta(\psi) \to +\infty$ em $0^+$ e $\beta(\pi) = 1$; $\beta'$ tem o sinal de $N(\psi) = 1 - \cos\psi - \psi\sin\psi$, que tem uma única raiz $\psi^* \in (\pi/2, \pi)$ (com $\cos\psi^* + \psi^*\sin\psi^* = 1$). Logo $\beta$ decresce e depois cresce, e $\alpha = \beta(\psi^*) = 2/(\pi\sin\psi^*)$. O item (ii) é $\alpha \leqslant \beta(\psi)$ com $\psi = \arccos y$.

# Garantia de aproximação

**Teorema (Goemans–Williamson)**
Para uma solução ótima de (RV), o algoritmo devolve um corte de peso esperado

$$\mathbb{E}W \geqslant \alpha \operatorname{opt} \geqslant 0{,}87856 \operatorname{opt}.$$

**Prova.** Como $\rho_{ij} \geqslant 0$,

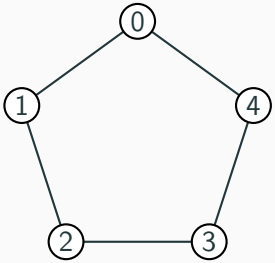
$$\mathbb{E}W = \frac{1}{\pi} \sum_{i<j} \rho_{ij} \arccos(\langle v_i, v_j \rangle) \geqslant \alpha \sum_{i<j} \rho_{ij} \tfrac{1}{2}\big(1 - \langle v_i, v_j \rangle\big) = \alpha\gamma \geqslant \alpha \operatorname{opt}. \quad \square$$

Observações:

- pesos não negativos são essenciais;
- a análise é ótima para essa relaxação.

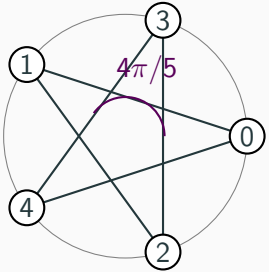
# Exemplo: o circuito $C_5$ — a relaxação não é exata

**O grafo** ($\rho_{ij} = 1$)




Corte máximo: $\mathrm{opt} = 4$ (como 5 é ímpar, nenhum corte pega as 5 arestas).

**Uma solução de (RV)**




$v_k = (\cos \frac{4\pi k}{5}, \sin \frac{4\pi k}{5}, 0, \ldots, 0)$: vértices adjacentes no ciclo ficam quase opostos.

# Exemplo: circuito $C_5$ — relaxação×arredondamento

Todas as arestas têm $\langle v_i, v_j \rangle = \cos\frac{4\pi}{5}$. Portanto:

| | | |
|---|---|---|
| **Corte máximo real** | $\mathrm{opt}$ | $= 4$ |
| **Valor de (RV) nesta solução** | $5 \cdot \frac{1}{2}\big(1 - \cos\frac{4\pi}{5}\big)$ | $= \dfrac{25 + 5\sqrt{5}}{8} \approx 4{,}52$ |
| **Corte esperado do arredondamento** | $5 \cdot \dfrac{1}{\pi}\arccos\big(\cos\frac{4\pi}{5}\big) = 5 \cdot \dfrac{4}{5}$ | $= 4$ |

- $\gamma \geqslant 4{,}52 > \mathrm{opt}$: a relaxação não é exata.
- Mesmo assim o arredondamento recupera $\mathrm{opt} = 4$ em esperança.
- Consistente com o teorema: $\alpha\gamma \approx 0{,}8786 \cdot 4{,}52 \approx 3{,}97 \leqslant 4$.
- A razão $\mathrm{opt}/\gamma \approx 0{,}885$ já está bem perto de $\alpha$: grafos assim mostram por que $\alpha$ não pode ser muito maior.

# Conclusão

# Resumo

- **Relaxar:** $\mathrm{opt}(R) \geqslant \mathrm{opt}(P)$ serve de referência.
- **Arredondar:** sorteios guiados pela solução de $R$; análise por linearidade da esperança, parcela a parcela.
- **Max-cut:** (RV) + hiperplano aleatório (via gaussiana) $\Rightarrow$ razão $\alpha \approx 0{,}878$.
- Da esperança a uma solução: repetir o sorteio ou desaleatorizar.
- Limite: o intervalo de integralidade $\gamma^*$ restringe o que se prova comparando com $\mathrm{opt}(R)$.

# Satisfabilidade máxima

# O problema max-sat

- Variáveis booleanas $x_1, \ldots, x_n$.
- Cláusulas $C_1, \ldots, C_m$, cada uma uma disjunção de literais ($x_i$ ou $\neg x_i$), com pesos $w_j \geqslant 0$.
- **Objetivo:** atribuir valores às variáveis de modo a maximizar o peso total das cláusulas satisfeitas.

NP-difícil. Queremos um algoritmo de aproximação.

# Programa linear inteiro e sua relaxação

Variáveis $y_i \in \{0,1\}$ ($y_i = 1$ se $x_i$ é verdadeira) e $z_j \in \{0,1\}$ ($z_j = 1$ se $C_j$ é satisfeita):

$$\begin{aligned} \text{maximizar} \quad & \sum_j w_j z_j \\ \text{sujeito a} \quad & z_j \leqslant \sum_{i \in C_j^+} y_i + \sum_{i \in C_j^-} (1 - y_i), \quad \forall j \end{aligned}$$

em que $C_j^+$ ($C_j^-$) são as variáveis que aparecem não negadas (negadas) em $C_j$.

Relaxação linear: troca-se $y_i, z_j \in \{0,1\}$ por $0 \leqslant y_i, z_j \leqslant 1$. Resolvível em tempo polinomial, e $\mathrm{opt}(\mathrm{PL}) \geqslant \mathrm{opt}$.

# Arredondamento aleatório

Seja $(\widehat{y}, \widehat{z})$ uma solução ótima da relaxação.

**Algoritmo:** faça $x_i$ verdadeira com probabilidade $\widehat{y}_i$, independentemente das demais.

Para uma cláusula $C_j$ com $k$ literais, a probabilidade de *não* ser satisfeita é um produto de $k$ termos $(1 - p_l)$ com $\sum_l p_l \geqslant \widehat{z}_j$. Pela desigualdade entre as médias aritmética e geométrica,

$$\mathbb{P}(\, C_j \text{ satisfeita} \,) \geqslant 1 - \left(1 - \frac{\widehat{z}_j}{k}\right)^k \geqslant \left(1 - \left(1 - \tfrac{1}{k}\right)^k\right)\widehat{z}_j \geqslant \left(1 - \frac{1}{\mathrm{e}}\right)\widehat{z}_j.$$

# Garantia do arredondamento

**Teorema**
O arredondamento da relaxação linear devolve, em esperança, peso pelo menos

$$\Big(1 - \frac{1}{\mathrm{e}}\Big)\,\mathrm{opt} \approx 0{,}632\,\mathrm{opt}.$$

Somando sobre as cláusulas:
$\mathbb{E}W \geqslant (1 - 1/\mathrm{e}) \sum_j w_j \widehat{z}_j = (1 - 1/\mathrm{e})\,\mathrm{opt}(\mathsf{PL}) \geqslant (1 - 1/\mathrm{e})\,\mathrm{opt}.$

Observação: a razão é pior para cláusulas grandes ($k \to \infty$ dá $1 - 1/\mathrm{e}$) e melhor para pequenas ($k = 1$ dá 1).

# Atribuição uniforme: o outro extremo

Faça cada $x_i$ verdadeira com probabilidade $1/2$.

Uma cláusula com $k$ literais é satisfeita com probabilidade

$$1 - 2^{-k} \geqslant \frac{1}{2},$$

melhor para cláusulas grandes, justamente onde a relaxação linear é pior.

# Combinando os dois: razão 3/4

Execute, com probabilidade $1/2$ cada, o arredondamento linear ou a atribuição uniforme (ou execute ambos e fique com o melhor). Para uma cláusula de tamanho $k$:

$$\frac{1}{2}\Big[1-\big(1-\tfrac{1}{k}\big)^{k}\Big]\widehat{z}_j+\frac{1}{2}\big(1-2^{-k}\big)\widehat{z}_j \;\geqslant\; \frac{3}{4}\,\widehat{z}_j.$$

(Para $k=1$ e $k=2$ vale com igualdade; para $k\geqslant 3$ a soma dos dois coeficientes é maior que $3/2$.)

**Teorema**
A combinação devolve, em esperança, peso pelo menos $\frac{3}{4}\,\mathrm{opt}$.

# Conclusão

# Resumo

- **Relaxar:** $\mathrm{opt}(R) \geqslant \mathrm{opt}(P)$ serve de referência.
- **Arredondar:** sorteios guiados pela solução de $R$; análise por linearidade da esperança, parcela a parcela.
- **Max-cut:** (RV) + hiperplano aleatório (via gaussiana) $\Rightarrow$ razão $\alpha \approx 0{,}878$.
- **Max-sat:** relaxação linear + arredondamento $\Rightarrow 1 - 1/\mathrm{e} \approx 0{,}632$; combinado com a atribuição uniforme, $3/4$.
- Da esperança a uma solução: repetir o sorteio ou desaleatorizar.
- Limite: o intervalo de integralidade $\gamma^*$ restringe o que se prova comparando com $\mathrm{opt}(R)$.