

1

Noções de probabilidade

Intuitivamente, uma medida de probabilidade é uma forma quantitativa de expressar a chance de ocorrência de eventos associados a um experimento aleatório, cujos resultados não podem ser previamente determinados. A teoria da probabilidade é a área da matemática dedicada à modelagem e ao estudo rigoroso desses fenômenos sob condições de incerteza.

Uma medida de probabilidade $\mathbb{P}$ é definida sobre uma família $\mathcal{E}$ de subconjuntos de Ω , os eventos aleatórios, que deve satisfazer:

- (i) $\Omega \in \mathcal{E}$;
- (ii) se $A \in \mathcal{E}$ então $\overline{A} \in \mathcal{E}$;
- (iii) se $A_i \in \mathcal{E}$ para todo $i \geq 1$, então $\bigcup_{i \geq 1} A_i \in \mathcal{E}$.

Uma família de subconjuntos que satisfaz essas propriedades é chamada de *σ -álgebra de subconjuntos de Ω* .

Um *espaço de probabilidade*, ou um modelo probabilístico, é uma terna $(\Omega, \mathcal{E}, \mathbb{P})$ tal que Ω é um conjunto não vazio, chamado *espaço amostral*; $\mathcal{E}$ é uma σ -álgebra de subconjuntos de Ω ; e $\mathbb{P}: \mathcal{E} \rightarrow [0, 1]$ é uma *medida de probabilidade*, que atribui a cada evento aleatório um número real satisfazendo

Não-negatividade $\mathbb{P}(A) \geq 0$ para todo $A \in \mathcal{E}$.

Normalização $\mathbb{P}(\Omega) = 1$.

Aditividade enumerável se $\{A_i \in \mathcal{E} : i \geq 1\}$ é um conjunto enumerável de eventos mutuamente exclusivos, então

$$\mathbb{P}\left(\bigcup_{i=1}^{\infty} A_i\right) = \sum_{i=1}^{\infty} \mathbb{P}(A_i).$$

O lado esquerdo dessa igualdade não depende de uma enumeração particular dos conjuntos A_i e o mesmo vale para o lado direito.

Neste texto, usaremos os termos *espaço de probabilidade* e *modelo probabilístico* de maneira intercambiável, sem distinção.

Proposição 1.1: Propriedades de $\mathbb{P}$

Para uma medida de probabilidade $\mathbb{P}$ sobre um espaço de eventos $\mathcal{E}$ do espaço amostral Ω valem as seguintes propriedades.

1. A probabilidade do *evento impossível* é

$$\mathbb{P}(\emptyset) = 0.$$

2. *Aditividade finita*: se $A_1, A_2, \dots, A_n \in \mathcal{E}$ são eventos mutuamente exclusivos então

$$\mathbb{P}\left(\bigcup_{i=1}^n A_i\right) = \sum_{i=1}^n \mathbb{P}(A_i). \quad (1.1)$$

3. *A probabilidade do complemento* é

$$\mathbb{P}(\overline{A}) = 1 - \mathbb{P}(A)$$

para todo evento $A \in \mathcal{E}$.

4. *Monotonicidade*: se $A \subseteq B$, então $\mathbb{P}(A) \leq \mathbb{P}(B)$.

Também, $\mathbb{P}(B \setminus A) = \mathbb{P}(B) - \mathbb{P}(A)$.

5. *Regra da adição*: Para quaisquer A, B

$$\mathbb{P}(A \cup B) = \mathbb{P}(A) + \mathbb{P}(B) - \mathbb{P}(A \cap B).$$

6. *Subaditividade*: Se $A_1, A_2, \dots, A_n$ são eventos, então

$$\mathbb{P}\left(\bigcup_{i=1}^n A_i\right) \leq \sum_{i=1}^n \mathbb{P}(A_i). \quad (1.2)$$

Demonstração. Fazendo $A_1 = \Omega$ e $A_i = \emptyset$ para todo $i \geq 2$ temos, pela aditividade enumerável, que

$$\mathbb{P}(\Omega) = \mathbb{P}(\Omega \cup \emptyset \cup \emptyset \cup \dots \cup \emptyset \cup \dots) = \mathbb{P}(\Omega) + \sum_{i=2}^{\infty} \mathbb{P}(\emptyset)$$

portanto, pela não-negatividade, resta que $\mathbb{P}(\emptyset) = 0$. Agora, definindo $A_i = \emptyset$ para todo $i > n$

$$\mathbb{P}\left(\bigcup_{i=1}^n A_i\right) = \mathbb{P}\left(\bigcup_{i=1}^{\infty} A_i\right) = \sum_{i=1}^{\infty} \mathbb{P}(A_i) = \sum_{i=1}^n \mathbb{P}(A_i) + \sum_{i>n} \mathbb{P}(\emptyset) = \sum_{i=1}^n \mathbb{P}(A_i)$$

que é o resultado afirmado no item 2.

A probabilidade do complemento segue do item anterior e da normalização. Os detalhes ficam a cargo do leitor.

Para monotonicidade, consideremos A e B eventos tais que $A \subseteq B$. Usamos que B pode ser escrito como a união disjunta $A \cup (B \setminus A)$,

donde $\mathbb{P}(B) = \mathbb{P}(A) + \mathbb{P}(B \setminus A)$ e como $\mathbb{P}(\overline{A} \cap B) \geq 0$ temos $\mathbb{P}(B) \geq \mathbb{P}(A)$. Notemos que, como consequência imediata, temos $\mathbb{P}(A) \leq 1$ para todo evento A .

Finalmente, a união $A \cup B$ pode ser escrita como duas uniões disjuntas $(A \setminus B) \cup (B \setminus A) \cup (A \cap B)$ donde concluímos que

$$\mathbb{P}(A \cup B) = \mathbb{P}(A \setminus B) + \mathbb{P}(B \setminus A) + \mathbb{P}(A \cap B). \quad (1.3)$$

Agora, A pode ser escrito como a união disjunta $(A \setminus B) \cup (A \cap B)$ e, analogamente, $B = (B \setminus A) \cup (A \cap B)$, portanto $\mathbb{P}(A) = \mathbb{P}(A \setminus B) + \mathbb{P}(A \cap B)$ assim como $\mathbb{P}(B) = \mathbb{P}(B \setminus A) + \mathbb{P}(A \cap B)$. Isolando $\mathbb{P}(A \setminus B)$ e $\mathbb{P}(B \setminus A)$ nessas duas igualdades e substituindo na equação (1.3) prova a regra da adição. $\square$

1.1 Convenções notacionais

Sejam A uma descrição de um evento aleatório e A_Ω o subconjunto que o representa em $(\Omega, \mathcal{E}, \mathbb{P})$. Denotamos por $\mathbb{P}[A]$ a probabilidade do evento descrito por A , isto é, $\mathbb{P}[A] := \mathbb{P}(A_\Omega)$. Caso haja a necessidade de evidenciar o espaço amostral escreveremos

$$\mathbb{P}_\Omega[A] \quad \text{ou} \quad \mathbb{P}_{\omega \in \Omega}[\text{ocorre } A] \quad \text{ou} \quad \mathbb{P}_{\omega \in \Omega}[\omega \in A] \quad (1.4)$$

com o mesmo sentido, o de $\mathbb{P}(A_\Omega)$.

Por exemplo, no caso em que uma moeda equilibrada é lançada até sair coroa, o evento caracterizado por “o número de lançamentos é par” é definido em $(\Omega, \mathcal{E}, \mathbb{P})$ por $A_\Omega := \{(c_1, \dots, c_i) : i \text{ é par}\}$ e $\mathbb{P}[\text{número par de lançamentos}]$ denota o mesmo que $\mathbb{P}(A_\Omega)$.

Quando Ω é finito e a menos que seja dada explicitamente outra medida, então a notação na equação (1.4) significa que estamos assumindo a medida de **probabilidade uniforme**: $\mathbb{P}(\omega) = 1/|\Omega|$ para todo $\omega \in \Omega$. Por exemplo, seja $p(x)$ um polinômio não nulo e Ω um conjunto finito de números. A probabilidade de que o sorteio de um elemento de Ω , todos com a mesma probabilidade de ocorrência, resulte numa raiz do polinômio é descrita por

$$\mathbb{P}_{x \in \Omega} [p(x) = 0]$$

que é a probabilidade do evento $R = \{\omega \in \Omega : p(\omega) = 0\}$.

Nos algoritmos assumiremos a possibilidade de se fazer escolhas aleatórias, ou seja, assumiremos que os algoritmos dispõem da instrução

$$a \xleftarrow{\mathbb{R}} \Omega$$

chamada de atribuição por uma **escolha aleatória uniforme** em Ω (finito), o que significa que a assume qualquer um dos elementos de

Ω com igual probabilidade, a saber $1 / |\Omega|$. Por exemplo, a partir de uma fonte de bits aleatórios, a instrução

$$a \stackrel{R}{\leftarrow} \{0, 1\}$$

denota o fato de que a é uma variável do algoritmo e que após a execução da atribuição $\stackrel{R}{\leftarrow}$ o valor da variável a é um elemento qualquer de $\{0, 1\}$ com probabilidade $1/2$.

<i>Notação</i>	<i>Eventos</i>	<i>Conjunto</i>
Ω	espaço amostral, evento certo	universo
$\emptyset$	evento impossível	vazio
$\{\omega\}$	evento elementar	conjunto unitário
A	evento	subconjunto
A	ocorre A	$\omega \in A$
$\overline{A}$	não ocorre A	$\omega \notin A$ (complemento)
$A \cap B$	ocorre A e B	$\omega \in A \cap B$ (intersecção)
$A \cup B$	ocorre A ou B	$\omega \in A \cup B$ (união)
$A \setminus B$	ocorre A e não ocorre B	$\omega \in A$ e $\omega \notin B$ (diferença)
$A \triangle B$	ocorre A ou B , não ambos	$\omega \in A \cup B$ e $\omega \notin A \cap B$ (diferença simétrica)
$A \subseteq B$	se ocorre A , então ocorre B	$\omega \in A \Rightarrow \omega \in B$ (inclusão)

Tabela 1.1: pequeno dicionário de termos da probabilidade.

1.2 Probabilidade discreta

Um *modelo probabilístico discreto*, ou *espaço de probabilidade discreto*, é um espaço $(\Omega, \mathcal{E}, \mathbb{P})$ em que Ω é enumerável (finito ou infinito) e $\mathcal{E} = 2^\Omega$.

Nesse caso, todo experimento tem seu modelo probabilístico especificado quando estabelecemos

1. um espaço amostral enumerável Ω ;
2. uma função $p: \Omega \rightarrow [0, 1]$ tal que $\sum_{\omega \in \Omega} p(\omega) = 1$, chamada *função massa de probabilidade*.

De fato, dado (Ω, p) como acima, podemos definir uma função $\mathbb{P}$ em 2^Ω tomando

$$\mathbb{P}(A) := \sum_{\omega \in A} p(\omega), \quad A \subseteq \Omega. \quad (1.5)$$

Essa soma está bem definida e $0 \leq \mathbb{P}(A) \leq 1$ para todo $A \subseteq \Omega$. Claramente, $\mathbb{P}(\Omega) = \sum_{\omega} \mathbb{P}(\{\omega\}) = 1$. Além disso, se A_i para $i \geq 1$ são eventos mutuamente exclusivos, então

$$\mathbb{P}\left(\bigcup_{i=1}^{\infty} A_i\right) = \sum_{i=1}^{\infty} \mathbb{P}(A_i)$$

Se A é conjunto, 2^A denota o conjunto das partes de A .

segue da convergência absoluta e da exclusão mútua. Portanto, $\mathbb{P}$ é uma medida de probabilidade sobre 2^Ω .

Assim, em um espaço de probabilidade discreto, a função massa de probabilidade determina completamente a medida de probabilidade.

Convencionamos a notação

$$\mathbb{P}(\omega) := \mathbb{P}(\{\omega\})$$

para os eventos elementares.

Exemplo 1.1: Moeda equilibrada

Uma moeda equilibrada é lançada repetidamente até sair coroa. No espaço amostral definimos a função massa de probabilidade

$$p((c_1, c_2, \dots, c_i)) = \begin{cases} 2^{-i} & \text{para } c_j = \text{Ca se } j < i \text{ e } c_i = \text{Co,} \\ 0 & \text{nos outros casos.} \end{cases}$$

Ω e p definem um modelo probabilístico discreto para o experimento.

MONTY HALL

Vejamos um modelo probabilístico para o problema de Monty Hall: o apresentador Monty Hall mostra três portas a um espectador que concorre ao prêmio escondido atrás das portas.

O protocolo é o seguinte: Monty Hall escolhe, ao acaso, uma das portas para esconder um carro; nas outras duas esconde um bode em cada. Na primeira etapa o concorrente escolhe uma porta ao acaso (que ainda não é aberta); em seguida Monty Hall abre uma das outras duas portas que o concorrente não escolheu, sabendo que ela esconde um bode e escolhendo ao acaso se houver mais de uma possibilidade. Com duas portas fechadas apenas e sabendo que o carro está atrás de uma delas, o apresentador oferece ao concorrente a oportunidade de trocar de porta. O concorrente tem que decidir se permanece com a porta que escolheu no início do jogo ou se muda para a outra porta que ainda está fechada. Feita a escolha, o apresentador abre a porta escolhida e o concorrente leva o prêmio escondido pela porta. Qual é a estratégia que maximiza a chance de ganhar o carro?

O experimento consiste das seguintes três etapas

1. o apresentador esconde o carro atrás de uma das portas escolhida com probabilidade $1/3$;
2. com probabilidade $1/3$, uma porta é escolhida pelo jogador;

Monty Hall é o nome do apresentador de um concurso televisivo que era exibido na década de 1970, nos Estados Unidos, chamado *Let's Make a Deal*.

3. o apresentador revela, dentre as duas que o jogador não escolheu, aquela que não esconde o carro. Se houver duas possibilidades então o apresentador escolhe uma delas com probabilidade $1/2$.

Um espaço amostral fica definido pelas ternas (e_1, e_2, e_3) em que e_i é a porta escolhida no passo i descrito acima e, se as portas estão numeradas por 1, 2 e 3, então definimos um modelo probabilístico discreto com Ω dado por

$$\{(1, 2, 3), (1, 3, 2), (2, 1, 3), (2, 3, 1), (3, 1, 2), (3, 2, 1), (1, 1, 2), (1, 1, 3), (2, 2, 1), (2, 2, 3), (3, 3, 1), (3, 3, 2)\}.$$

e probabilidades de acordo com o diagrama de árvore mostrado na Figura 1.1 abaixo; um caminho seguido pelo jogador numa rodada do jogo corresponde a um caminho na árvore, a partir da raiz (o ponto mais alto) até uma folha (um dos pontos mais baixos). A primeira ramificação corresponde a escolha de porta para esconder o carro, as segundas ramificações correspondem a escolha do jogador e as terceiras ramificações correspondem a escolha de porta para abrir feita pelo apresentador. Os eventos que interessam, a saber “o joga-




Figura 1.1: diagrama de árvore de um modelo para Monty Hall.

dor vence trocando de porta” e “o jogador vence não trocando de porta”, são complementares e denotados por A e $\bar{A}$ respectivamente, de modo que $A = \{(1, 2, 3), (1, 3, 2), (2, 1, 3), (2, 3, 1), (3, 1, 2), (3, 2, 1)\}$ e $\bar{A}$ é dada pelas ternas restantes de Ω . O jogador ganha o carro trocando de porta com probabilidade

$$\mathbb{P}(A) = \mathbb{P}(\{(1, 2, 3), (1, 3, 2), (2, 1, 3), (2, 3, 1), (3, 1, 2), (3, 2, 1)\}) = \frac{2}{3}$$

portanto, ganha sem trocar de porta com probabilidade $1 - 2/3 = 1/3$, que corresponde à probabilidade de ter escolhido a porta certa já na primeira oportunidade de escolha. Portanto, a melhor estratégia é trocar de porta quando é oferecida essa oportunidade pois isso dobra a probabilidade de ganhar o carro.

1.3 Probabilidade condicional

Em um espaço de probabilidade discreto definido por Ω e $\mathbb{P}$, a probabilidade de ocorrência do evento A condicionada à ocorrência o evento E , ou como dizemos a **probabilidade condicional** de A dado E , em que $\mathbb{P}(E) \neq 0$, é definida por

$$\mathbb{P}(A | E) := \frac{\mathbb{P}(A \cap E)}{\mathbb{P}(E)} \quad (1.6)$$

e $\mathbb{P}(A | E)$ é lido como a **probabilidade de A dado E** .

Por exemplo, se Ω é finito com medida de probabilidade uniforme e $E \neq \emptyset$ então

$$\mathbb{P}(A | E) = \frac{\mathbb{P}(A \cap E)}{\mathbb{P}(E)} = \frac{|A \cap E|}{|E|} \quad (1.7)$$

Ideia importante

Considere um espaço de probabilidade $(\Omega, \mathcal{E}, \mathbb{P})$ e um evento com probabilidade positiva $E \in \mathcal{E}$.

$\mathbb{P}_E(A) := \mathbb{P}(A | E)$ é uma medida de probabilidade para os eventos em $\mathcal{E}$ (i.e, satisfaz os axiomas de probabilidade).

Também, $(E, \{A \cap E : A \in \mathcal{E}\}, \mathbb{P}_E)$ é um espaço de probabilidade.

Regra do produto: A igualdade, que decorre da definição,

$$\mathbb{P}(A \cap B) = \mathbb{P}(A | B) \cdot \mathbb{P}(B)$$

é consequência direta da definição de probabilidade condicional e é conhecida como **teorema da multiplicação** ou **regra do produto**.

Essa regra é facilmente estendida para calcular $\mathbb{P}(A \cap B \cap C)$:

$$\begin{aligned} \mathbb{P}(A \cap B \cap C) &= \mathbb{P}(A) \cdot \mathbb{P}(B \cap C | A) \\ &= \mathbb{P}(A) \cdot \mathbb{Q}(B \cap C) \\ &= \mathbb{P}(A) \cdot \mathbb{Q}(B) \cdot \mathbb{Q}(C | B) \end{aligned}$$

onde $\mathbb{Q}$ é a medida $\mathbb{P}(\cdot | A)$. Mas

$$\mathbb{Q}(C | B) = \frac{\mathbb{P}(B \cap C | A)}{\mathbb{P}(B | A)} = \frac{\frac{\mathbb{P}(A \cap B \cap C)}{\mathbb{P}(A)}}{\frac{\mathbb{P}(A \cap B)}{\mathbb{P}(A)}} = \mathbb{P}(C | A \cap B)$$

assim

$$\mathbb{P}(A \cap B \cap C) = \mathbb{P}(A) \cdot \mathbb{P}(B | A) \cdot \mathbb{P}(C | A \cap B) \quad (1.8)$$

(identifique o uso dessa regra no modelo probabilístico para o problema de Monty Hall, página 9).

Um caso geral desse teorema é dado abaixo, cuja prova é exercício.

Teorema 1.1: Teorema da multiplicação

Sejam $A_1, A_2, \dots, A_n$ eventos de um modelo probabilístico.
Prove que

$$\begin{aligned} \mathbb{P}(A_1 \cap \dots \cap A_n) &= \mathbb{P}(A_1) \cdot \mathbb{P}(A_2 \mid A_1) \cdot \\ &\quad \mathbb{P}(A_3 \mid A_2 \cap A_1) \cdots \\ &\quad \mathbb{P}(A_n \mid A_{n-1} \cap A_{n-2} \cap \dots \cap A_1) \end{aligned} \quad (1.9)$$

sempre que as probabilidades condicionais estão definidas
(veja que é suficiente pedir que $\mathbb{P}(A_1 \cap \dots \cap A_{n-1}) > 0$).

A Lei da Probabilidade Total: Se E e A são eventos, com $0 < \mathbb{P}(E) < 1$, então o evento A ocorre se e somente se ocorre $(A \text{ e } E)$ ou $(A \text{ e } \bar{E})$, e esses eventos entre parênteses são disjuntos; mais que isso $\{A \cap E, A \cap \bar{E}\}$ é uma partição de A , portanto,

$$\begin{aligned} \mathbb{P}(A) &= \mathbb{P}((A \cap E) \cup (A \cap \bar{E})) \\ &= \mathbb{P}(A \cap E) + \mathbb{P}(A \cap \bar{E}) \end{aligned} \quad (1.10)$$

$$= \mathbb{P}(A \mid E) \mathbb{P}(E) + \mathbb{P}(A \mid \bar{E}) \mathbb{P}(\bar{E}). \quad (1.11)$$

No problema de Monty Hall se o convidado fica com a porta que escolheu inicialmente, então a probabilidade de ganhar um carro é $1/3$, que é a probabilidade dele ter escolhido a porta certa logo de início. Agora, vamos supor que o convidado troca de porta. Nesse caso, denotamos por A o evento “ganha o carro” e por E o evento “a porta escolhida na primeira etapa esconde o carro”. Claramente, $\mathbb{P}(A \mid E) = 0$ e $\mathbb{P}(E) = 1/3$. Se a primeira escolha não era a correta então o convidado ganha o carro, ou seja, $\mathbb{P}(A \mid \bar{E}) = 1$. Com isso temos por (1.11)

$$\mathbb{P}(A) = \mathbb{P}(A \mid E) \mathbb{P}(E) + \mathbb{P}(A \mid \bar{E}) \mathbb{P}(\bar{E}) = 0 \cdot \frac{1}{3} + 1 \cdot \frac{2}{3} = \frac{2}{3}$$

portanto, é melhor trocar de porta.

O caso geral dessa igualdade é conhecido como o teorema da probabilidade total. Segue da dedução acima e usando indução em n que se $\{E_1, E_2, \dots, E_n\}$ é um conjunto de eventos que particionam o espaço amostral Ω com $\mathbb{P}(E_i) > 0$ para todo $i \geq 1$, então vale

$$\mathbb{P}(A) = \sum_{i=1}^n \mathbb{P}(A \cap E_i) = \sum_{i=1}^n \mathbb{P}(A \mid E_i) \mathbb{P}(E_i) \quad (1.12)$$

para qualquer evento A . Deixamos a prova por conta do leitor do resultado abaixo considerando partições enumeráveis.

Teorema 1.2: Lei da probabilidade total

Seja $\{E_i: i \geq 1\}$ uma partição (enumerável) do espaço amostral Ω com $\mathbb{P}(E_i) > 0$ para todo i . Então

$$\mathbb{P}(A) = \sum_{i=1}^{\infty} \mathbb{P}(A \cap E_i) = \sum_{i=1}^{\infty} \mathbb{P}(A | E_i) \mathbb{P}(E_i) \quad (1.13)$$

para qualquer evento A .

Demonstração. Os conjuntos $A \cap E_i$ são disjuntos dois a dois e da união deles resulta A , logo a primeira igualdade em (1.13) segue de $\mathbb{P}$ ser medida de probabilidade. A segunda igualdade segue de $\mathbb{P}(A \cap E_i) = \mathbb{P}(A | E_i) \mathbb{P}(E_i)$ para todo i . $\square$

Exemplo 1.2

As seguradoras de automóveis classificam motoristas em *mais propensos a acidentes* e *menos propensos a acidentes*. Com isso estimam que os mais propensos são 30% da população e que esses se envolvem em acidente no período de um ano com probabilidade 0,4, enquanto que os menos propensos a acidentes se envolvem em acidente no período de um ano com probabilidade 0,2. Denotemos por A^+ o evento definido pelos motoristas mais propensos a acidentes. Então a probabilidade de um novo segurado se envolver em acidente em um ano é

$$\begin{aligned} \mathbb{P}(A_1) &= \mathbb{P}(A_1 | A^+) \mathbb{P}(A^+) + \mathbb{P}(A_1 | \overline{A^+}) \mathbb{P}(\overline{A^+}) \\ &= 0,4 \cdot 0,3 + 0,2 \cdot 0,7 = 0,26 \end{aligned}$$

e se um novo segurado se envolve em acidente nesse prazo, a probabilidade dele ser propenso a acidentes é

$$\begin{aligned} \mathbb{P}(A^+ | A_1) &= \frac{\mathbb{P}(A_1 \cap A^+)}{\mathbb{P}(A_1)} = \frac{\mathbb{P}(A_1 | A^+) \mathbb{P}(A^+)}{\mathbb{P}(A_1)} \\ &= \frac{0,4 \cdot 0,3}{0,26} = \frac{6}{13}. \end{aligned}$$

Portanto, a probabilidade de ser propenso a acidente dado que se envolve em acidente em um ano é 0,46, aproximadamente. Dado que o motorista não se envolve em acidente em um ano, a probabilidade de ser propenso a acidente é $\mathbb{P}(A^+ | \overline{A_1}) \approx 0,24$. (Ross, 2010)

1.3.1 Independência de eventos

Se um dado é lançado duas vezes, então temos

$$\mathbb{P}[\text{a soma é } 7 \mid \text{o primeiro resultado é } 4] = \frac{1}{6} = \mathbb{P}[\text{a soma é } 7]$$

entretanto

$$\mathbb{P}[\text{a soma é } 12 \mid \text{o primeiro resultado é } 4] = 0 \neq \mathbb{P}[\text{a soma é } 12].$$

O condicionamento de ocorrência de um evento A à ocorrência de B pode afetar ou não a probabilidade de ocorrência de A .

Definição 1.1: Independência

Definimos que o evento A é independente do evento B se

$$\mathbb{P}(A \cap B) = \mathbb{P}(A) \mathbb{P}(B)$$

Notemos que se A é independente de B então B é independente de A de modo que dizemos A e B são *eventos independentes*.

É imediato da Definição 1.1 o seguinte fato.

Proposição 1.2

Todo evento A de um modelo probabilístico é independente do evento certo Ω e do evento impossível $\emptyset$. $\square$

Se os eventos têm probabilidade não nula então decorre da definição acima que a independência de A e B equivale a

$$\mathbb{P}(A \mid B) = \mathbb{P}(A) \quad \text{e} \quad \mathbb{P}(B \mid A) = \mathbb{P}(B).$$

Por exemplo, de

$$\mathbb{P}[\text{a soma é } 7 \mid \text{o primeiro resultado é } 4] = \mathbb{P}[\text{a soma é } 7]$$

temos que “a soma é 7” é um evento independente de “o primeiro resultado é 4” se o experimento é lançar um dado duas vezes.

Exemplo 1.3: 2 lançamentos de uma moeda

Considere

$$\Omega = \{ \text{CaCa}, \text{CaCo}, \text{CoCa}, \text{CoCo} \},$$

onde todos os resultados têm probabilidade $1/4$.

Considere os eventos

$$A = [\text{o primeiro lançamento é cara}] = \{ \text{CaCa}, \text{CaCo} \},$$

$$B = [\text{os dois lançamentos são iguais}] = [\text{CaCa}, \text{CoCo}].$$

Intuitivamente, pode parecer que os eventos são dependentes. De fato, saber que os dois lançamentos são iguais restringe os resultados possíveis a $\{\text{CaCa}, \text{CoCo}\}$. Assim, parece que essa informação deveria afetar a probabilidade de o primeiro lançamento ser cara. Entretanto,

$$\mathbb{P}(A) = \frac{1}{2} \quad \text{e} \quad \mathbb{P}(B) = \frac{1}{2}.$$

Além disso, $A \cap B = \{\text{CaCa}\}$, de modo que

$$\mathbb{P}(A \cap B) = \frac{1}{4}.$$

Portanto, $\mathbb{P}(A \cap B) = \mathbb{P}(A)\mathbb{P}(B)$. Logo, A e B são independentes.

Equivalentemente,

$$\mathbb{P}(A \mid B) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)} = \frac{1/4}{1/2} = \frac{1}{2} = \mathbb{P}(A).$$

Assim, embora a ocorrência de B elimine metade dos resultados possíveis, ela não altera a probabilidade de A . Esse exemplo ilustra que a independência não significa que dois eventos não tenham qualquer relação ou que a ocorrência de um não forneça nenhuma informação sobre o experimento. O que importa é se a ocorrência de um evento altera ou não a probabilidade do outro. Embora saber que os dois lançamentos são iguais forneça informação sobre os resultados possíveis, essa informação não altera a probabilidade de o primeiro lançamento ser cara.

Uma família enumerável de eventos $\mathcal{E} = \{E_n : n \in I\}$ é dita *mutuamente independente* se para todo subconjunto finito $J \subseteq I$ vale que

$$\mathbb{P}\left(\bigcap_{\ell \in J} E_\ell\right) = \prod_{\ell \in J} \mathbb{P}(E_\ell). \quad (1.14)$$

Para $k \geq 2$ fixo, dizemos que a coleção $\mathcal{E}$ é *k-a-k independente* se todo subconjunto de índices $J \subseteq I$ com $|J| \leq k$ define uma subcoleção de eventos mutuamente independentes.

1.3.2 Teste de identidade polinomial

Nosso primeiro exemplo de um algoritmo aleatorizado é um teste de identidade entre polinômios: dados dois polinômios p e q sobre x ,

decidir de modo eficiente se eles são idênticos.

Há muitas questões a serem esclarecidas nessa formulação do problema: o que significam “eficiente”, “dado um polinômio” e “idênticos”? Por ora, deixemos de lado tais questões e vamos ver como decidir, se dado um polinômio f por uma “caixa preta”, da qual a função polinomial $p(x)$ pode ser avaliada em qualquer número x , o polinômio dado f é identicamente nulo. Um algoritmo que resolve esse problema também resolve o problema original, basta tomarmos $f(x) = p(x) - q(x)$.

Fato 1. Esse problema aparentemente simples pode ser generalizado para polinômios em várias variáveis. Um algoritmo determinístico eficiente para o caso multivariado tem consequências profundas em Teoria da Computação, especificamente, em Complexidade Computacional.

Um algoritmo para esse problema funciona do seguinte modo: dado $f(x)$ de grau no máximo d , escolhemos aleatoriamente $a \in \{1, 2, \dots, 4d\}$ e avaliamos $f(a)$; se $f(a) = 0$, então respondemos *sim*, caso contrário respondemos *não*. A resposta *sim* significa que $f(x)$ é o polinômio nulo e a resposta *não* significa que $f(x)$ não é o polinômio nulo. Esse algoritmo pode responder errado dependendo de f e da escolha aleatória a e devemos tentar garantir que a probabilidade de ocorrer o erro seja pequena.

Se o polinômio f é nulo então a resposta está sempre certa. Suponhamos que f não é nulo. Nesse caso, se a escolha aleatória a for uma raiz do polinômio então $f(a) = 0$ e a resposta *sim* dada pelo algoritmo está errada e se a escolha aleatória a não for uma raiz do polinômio então $f(a) \neq 0$ e a resposta a resposta *sim* dada pelo algoritmo está correta. Em resumo, uma resposta *não* dada pelo algoritmo está correta e uma resposta *sim* pode estar errada. O algoritmo descrito abaixo resume essa estratégia.

Algoritmo 1.1: Teste de identidade entre polinômios

Instância: d inteiro positivo e f polinômio de grau no máximo d .

Resposta: *não* se f não é nulo, senão *sim* com probabilidade de erro no máximo $1/4$.

- 1 $a \xleftarrow{R} \{1, 2, \dots, 4d\}$;
- 2 se $f(a) = 0$ então responda *sim*.
- 3 senão responda *não*.

Para determinar um limitante para a probabilidade do algoritmo responder errado, seja f um polinômio não nulo e de grau

no máximo d e consideremos o evento E formado pelas raízes de f que pertencem ao espaço amostral $\Omega = \{1, 2, \dots, 4d\}$. Então $|E| \leq \text{grau}(f) \leq d$ pois f tem no máximo $\text{grau}(f)$ raízes distintas pelo teorema fundamental da álgebra. O algoritmo erra se a escolha aleatória resulta num elemento de E , portanto,

$$\mathbb{P}[\text{erro}] \leq \frac{1}{4}.$$

Podemos fazer essa probabilidade arbitrariamente pequena ao custo de mais computação. Intuitivamente, como no caso dos lançamentos de moedas, imagine tal algoritmo sendo executado k vezes com a mesma entrada.

Basta uma rodada responder *não* para que a resposta definitiva seja *não*. Se todas as rodadas respondem *sim*, qual a probabilidade de todas estarem erradas?

$$\mathbb{P}[\text{erro em } k \text{ rodadas independentes}] \leq \left(\frac{1}{4}\right)^k.$$

Se $k = 10$ a probabilidade de erro é a probabilidade de 10 respostas *sim*, ou seja, no máximo $(1/4)^{10} < 10^{-6}$ (em metros é menos que o diâmetro do fio da teia de uma aranha), valor desprezível na prática.

Ideia importante

Assumimos que os sorteios realizados durante a execução de um algoritmo são independentes. Além disso, sorteios realizados em diferentes execuções do mesmo algoritmo são independentes entre si.

Algoritmos Monte Carlo Algoritmos aleatorizados com tempo de execução que depende somente da entrada e não dos sorteios e que podem responder errado, são conhecidos na literatura como algoritmos *Monte Carlo*. O teste de identidade polinomial é um algoritmo que pode errar, no entanto, somos capazes de delimitar a probabilidade de tal solução incorreta ocorrer.

Observamos uma propriedade útil de um algoritmo Monte Carlo: se o algoritmo for executado repetidamente com escolhas aleatórias independentes a cada vez, a probabilidade de falha pode se tornar arbitrariamente pequena, às custas do tempo de execução.

Observação 1 (erros de hardware). Para um base de comparação, sem a intenção de ser rigoroso, *hardware* apresentam falhas no processamento, transmissão e armazenamento de informação. Estudos da IBM realizados na década de 1990 indicaram que os efeitos de radiação cósmica podem produzir soft errors em memórias semicondutoras.

T. J. O’Gorman et. al. (1996). *Field testing for cosmic ray soft errors in semiconductor memories*. IBM J. Res. Dev., 40(1):41–50.

Uma estimativa frequentemente associada aos estudos da IBM é de aproximadamente um erro induzido por raios cósmicos para cada 256 MB de memória por mês. Essa taxa corresponde, aproximadamente, a $\approx 1,4 \times 10^{-15}$ por byte-segundo.

Schroeder, Pinheiro e Weber (2009), em um estudo de larga escala realizado em uma grande frota de servidores do Google, analisaram erros de DRAM durante aproximadamente 2,5 anos. Os autores encontraram taxas de erro muito superiores às previstas por estudos laboratoriais anteriores, da ordem de 25.000 a 70.000 erros por bilhão de horas de dispositivo por Mbit, além de observarem que os erros registrados eram predominantemente associados a falhas permanentes (*hard errors*), e não a *soft errors* causados por radiação¹.

Como ilustração da grande variabilidade das taxas de erro reportadas na literatura, taxas de 120 a 81.000 FIT por Mbit foram posteriormente compiladas em trabalhos sobre confiabilidade de hardware. Como 1 FIT corresponde a uma falha por 10^9 horas, essas taxas correspondem aproximadamente a um erro a cada 950 anos e a cada 1,4 anos, respectivamente, para cada Mbit de memória. Para uma máquina com 4 GiB de DRAM, essas taxas corresponderiam, respectivamente, a aproximadamente 3 e 2.000 erros por mês, supondo uma taxa constante e proporcional à quantidade de memória.

Nightingale et al. (2011), em um estudo da Microsoft envolvendo aproximadamente 950.000 computadores, encontraram uma probabilidade de aproximadamente $1/2700$ de uma primeira falha classificada como DRAM one-bit flip entre as máquinas com pelo menos cinco dias de tempo acumulado de CPU (TACT). Para máquinas com pelo menos 30 dias de TACT, essa probabilidade era de aproximadamente $1/1700$. Esses valores representam probabilidades de falha observada no sistema, e não uma taxa de erro por bit ou por unidade de tempo.

AMPLIFICAÇÃO

Para *problemas de decisão* — problemas computacionais para os quais a resposta para uma instância é “sim” ou “não”), — existem dois tipos de algoritmos Monte Carlo:

- com *erro unilateral* (*one-sided error*), se a probabilidade de errar for zero para pelo menos uma das respostas possíveis;
- com *erro bilateral* (*two-sided error*), se houver uma probabilidade não nula de ele errar tanto quando responde “sim” quanto quando responde “não”.

Para algoritmos Monte Carlo de erro unilateral, com probabilidade de erro $\leq \varepsilon$, para $\varepsilon \in (0, 1)$, podemos usar a estratégia de repetições

Bianca Schroeder et. al. (2009). *DRAM errors in the wild: A large-scale field study*. Proceedings of the Eleventh International Joint Conference on Measurement and Modeling of Computer Systems, SIGMETRICS '09, pages 193–204.

¹ Assim, esses resultados não devem ser interpretados diretamente como uma taxa de erros induzidos por raios cósmicos.

Edmund B. Nightingale et. al. (2011). *Cycles, cells and platters: An empirical analysis of hardware failures on a million consumer PCs*. Proceedings of the Sixth Conference on Computer Systems, EuroSys '11, pages 343–356.

independentes para atingir um limiar $\delta \in (0, 1)$ para a probabilidade de erro.

Se A é um algoritmo Monte Carlo que erra apenas nas respostas “sim”, então em t rodadas do algoritmo com a mesma entrada o erro só se dá se todas as t respostas forem “sim”. A probabilidade de erro será no máximo δ para todo t tal que $\varepsilon^t \leq \delta$, portanto, para todo

$$t \geq \frac{\ln(1/\delta)}{\ln(1/\varepsilon)}.$$

Para A que erra apenas nas respostas “não” o resultado é análogo.

Proposição 1.3: Amplificação unilateral

Dados um limiar $\delta \in (0, 1)$ e um algoritmo Monte Carlo A de erro unilateral limitado por ε , com $\lceil \ln(1/\delta)/\ln(1/\varepsilon) \rceil$ ou mais repetições de A temos um algoritmo Monte Carlo de erro (unilateral) no máximo δ . $\square$

Assim, dado conhecido um algoritmo probabilístico A de erro unilateral ε , com $O(\ln(1/\delta))$ repetições baixamos o erro para $< \delta$.

No caso de erro bilateral nenhuma das duas respostas é definitiva, a estratégia é repetir o algoritmo t vezes e devolver a resposta de maior ocorrência.

Proposição 1.4: Amplificação bilateral

Seja $\varepsilon < 1/2$ fixo. Dados um limiar $\delta \in (0, 1)$ e um algoritmo Monte Carlo A de erro bilateral no máximo ε , um número $O(\ln(1/\delta))$ de repetições independentes de A fornece um algoritmo Monte Carlo de erro bilateral no máximo δ . A constante implícita depende de ε .

Demonstração. Se $\varepsilon = 0$, o próprio A já tem erro $0 \leq \delta$ e nada há a fazer. Suponha, então, $0 < \varepsilon < \frac{1}{2}$.

O algoritmo amplificado executa A independentemente $t = 2k + 1$ vezes e retorna a resposta majoritária, que é bem definida por ser t ímpar. Ao final da prova escolhemos k em função de δ e de ε .

Seja S o número dessas t execuções que produzem a resposta correta. Cada execução está correta com probabilidade $p \geq 1 - \varepsilon > \frac{1}{2}$, independentemente das demais, de modo que

$$\mathbb{P}[X = i] = \binom{t}{i} p^i (1 - p)^{t-i}$$

que é não crescente em p , e portanto basta tratar o pior caso $p = 1 - \varepsilon$; suporemos isso daqui em diante. Escrevendo

$$p = 1 - \varepsilon = \frac{1}{2} + q, \quad \text{onde } q := \frac{1}{2} - \varepsilon \in \left(0, \frac{1}{2}\right),$$

temos $1 - p = \frac{1}{2} - q = \varepsilon$ e

$$\mathbb{P}[S = i] = \binom{2k+1}{i} \left(\frac{1}{2} + q\right)^i \left(\frac{1}{2} - q\right)^{2k+1-i}.$$

Como t é ímpar, não há empates: o algoritmo amplificado erra exatamente quando a resposta correta é minoritária, isto é, quando $S \leq k$. Sua probabilidade de erro é, pois,

$$\mathbb{P}[S \leq k] = \sum_{i=0}^k \binom{2k+1}{i} \left(\frac{1}{2} + q\right)^i \left(\frac{1}{2} - q\right)^{2k+1-i}.$$

Estimamos os dois fatores separadamente. Para $i \leq k$ vale $2k+1-i \geq k+1$ e, como $\frac{1}{2} + q > \frac{1}{2} - q$, trocar um fator $\left(\frac{1}{2} - q\right)$ por $\left(\frac{1}{2} + q\right)$ só pode aumentar o produto; aplicando essa troca $k-i$ vezes,

$$\left(\frac{1}{2} + q\right)^i \left(\frac{1}{2} - q\right)^{2k+1-i} \leq \left(\frac{1}{2} + q\right)^k \left(\frac{1}{2} - q\right)^{k+1}.$$

Quanto aos coeficientes binomiais, a identidade

$$\binom{2k+1}{i} = \binom{2k+1}{2k+1-i}$$

estabelece uma bijeção entre os índices $0, \dots, k$ e os índices $k+1, \dots, 2k+1$ que preserva o valor do coeficiente. Como esses dois conjuntos particionam $\{0, 1, \dots, 2k+1\}$, cada um deles responde por metade da soma total, e o Teorema Binomial dá

$$\sum_{i=0}^k \binom{2k+1}{i} = \frac{1}{2} \sum_{i=0}^{2k+1} \binom{2k+1}{i} = \frac{2^{2k+1}}{2} = 2^{2k}.$$

Combinando as duas estimativas e usando $\frac{1}{2} - q = \varepsilon$,

$$\mathbb{P}[S \leq k] \leq 2^{2k} \left(\frac{1}{2} + q\right)^k \left(\frac{1}{2} - q\right)^{k+1} = \varepsilon \left[4 \left(\frac{1}{2} + q\right) \left(\frac{1}{2} - q\right)\right]^k = \varepsilon (1 - 4q^2)^k \leq (1 - 4q^2)^k.$$

Escreva

$$\alpha := 1 - 4q^2 = 1 - 4\left(\frac{1}{2} - \varepsilon\right)^2.$$

De $0 < q < \frac{1}{2}$ segue $0 < \alpha < 1$, e o que provamos é que a probabilidade de o algoritmo amplificado produzir uma resposta incorreta é no máximo $\alpha^k = \alpha^{(t-1)/2}$. Essa cota é no máximo δ sempre que

$$k \geq \frac{\ln(1/\delta)}{\ln(1/\alpha)},$$

de modo que basta tomar

$$k = \left\lceil \frac{\ln(1/\delta)}{\ln(1/\alpha)} \right\rceil, \quad t = 2k + 1.$$

Sendo ε fixo, $\ln(1/\alpha)$ é uma constante positiva e, consequentemente, $t = O(\ln(1/\delta))$. $\square$

1.3.3 Continuidade de uma medida de probabilidade

Uma sequência qualquer $(A_n: n \geq 1)$ de eventos em um espaço de probabilidade $(\Omega, \mathcal{E}, \mathbb{P})$ é dita *monótona* se vale um dos casos

crescente: $A_1 \subseteq A_2 \subseteq \dots \subseteq A_n \subseteq A_{n+1} \subseteq \dots$ e definimos

$$\lim_{n \rightarrow \infty} A_n := \bigcup_{n=1}^{\infty} A_n.$$

decrecente: $A_1 \supseteq A_2 \supseteq \dots \supseteq A_n \supseteq A_{n+1} \supseteq \dots$ e definimos

$$\lim_{n \rightarrow \infty} A_n := \bigcap_{n=1}^{\infty} A_n.$$

Se $(A_n: n \geq 1)$ é uma sequência crescente, então o limite pode ser escrito como uma união de eventos disjuntos $A_1 \cup (A_2 \setminus A_1) \cup (A_3 \setminus A_2) \cup \dots$ de modo que se tomamos $A_0 := \emptyset$ então

$$\mathbb{P}\left(\lim_{n \rightarrow \infty} A_n\right) = \lim_{n \rightarrow \infty} \sum_{i=1}^n \mathbb{P}(A_i \setminus A_{i-1}) = \lim_{n \rightarrow \infty} \sum_{i=1}^n (\mathbb{P}(A_i) - \mathbb{P}(A_{i-1})) = \lim_{n \rightarrow \infty} \mathbb{P}(A_n).$$

No caso em que $(A_n: n \geq 1)$ é decrescente tomamos os complementos e temos que $(\overline{A_n}: n \geq 1)$ é crescente, portanto,

$$\mathbb{P}\left(\lim_{n \rightarrow \infty} \overline{A_n}\right) = \mathbb{P}\left(\bigcup_{n=1}^{\infty} \overline{A_n}\right) = \mathbb{P}\left(\overline{\bigcap_{n=1}^{\infty} A_n}\right) = \mathbb{P}\left(\overline{\lim_{n \rightarrow \infty} A_n}\right) = 1 - \mathbb{P}\left(\lim_{n \rightarrow \infty} A_n\right)$$

por outro lado

$$\mathbb{P}\left(\lim_{n \rightarrow \infty} \overline{A_n}\right) = \lim_{n \rightarrow \infty} \mathbb{P}(\overline{A_n}) = \lim_{n \rightarrow \infty} (1 - \mathbb{P}(A_n)) = 1 - \lim_{n \rightarrow \infty} \mathbb{P}(A_n)$$

portanto

$$\lim_{n \rightarrow \infty} \mathbb{P}(A_n) = \mathbb{P}\left(\lim_{n \rightarrow \infty} A_n\right).$$

Em resumo, se $(A_n: n \geq 1)$, é uma sequência monótona de eventos então

$$\mathbb{P}\left(\lim_{n \rightarrow \infty} A_n\right) = \lim_{n \rightarrow \infty} \mathbb{P}(A_n). \quad (1.15)$$

A propriedade (1.15) é chamada de *continuidade da medida de probabilidade*.

Consideremos novamente o exemplo do lançamento de uma moeda equilibrada até sair coroa

$$\Omega = \{(Co), (Ca, Co), \dots, (Ca, Ca, \dots)\}$$

munido da função massa de probabilidade $p((c_1, c_2, \dots, c_n)) = 2^{-n}$ para a sequência que termina em coroa após n lançamentos.

Definimos o evento A_n definido por “não sai coroa até o n -ésimo lançamento”. Esse evento ocorre com probabilidade

$$1 - \mathbb{P}(\overline{A_n}) = 1 - \sum_{i=1}^n \left(\frac{1}{2}\right)^i = 1 - \frac{1/2 - (1/2)^{n+1}}{1/2} = \left(\frac{1}{2}\right)^n.$$

Intuitivamente, “nunca sair coroa” tem probabilidade $\lim_{n \rightarrow \infty} 2^{-n} = 0$. Essa passagem ao limite, $\mathbb{P}(\lim_{n \rightarrow \infty} A_n) = \lim_{n \rightarrow \infty} \mathbb{P}(A_n)$, é garantida pela continuidade.

A sequência $(A_n : n \geq 1)$ é monótona pois $A_n \supseteq A_{n-1}$ para todo $n > 1$, portanto,

$$\mathbb{P}(\text{Ca, Ca, } \dots) = \mathbb{P}\left(\lim_{n \rightarrow \infty} A_n\right) = \lim_{n \rightarrow \infty} \mathbb{P}(A_n) = 0.$$

Ideia importante

A interpretação correta desse fato é que “sair cara para sempre” é um resultado possível, mas tem probabilidade zero. Isso porque, nesse caso, o espaço amostral não é discreto: o resultado $(\text{Ca, Ca, } \dots)$ é um elemento do espaço amostral, mas o conjunto que contém apenas esse resultado tem probabilidade zero. Em contraste, se o espaço amostral é discreto e todo resultado elementar tem probabilidade positiva, então

$$\mathbb{P}(A) = 0 \Rightarrow A = \emptyset.$$

De fato, se $A \neq \emptyset$, existe algum resultado elementar $\omega \in A$ e, pela monotonicidade da probabilidade, $\mathbb{P}(A) \geq \mathbb{P}(\omega) > 0$. Nesse contexto, portanto, um evento de probabilidade zero é necessariamente impossível.

1.4 Um gerador de números aleatórios

Dada uma fonte que gera bits aleatórios de modo uniforme e independente, como projetar um algoritmo que recebe um inteiro positivo M e devolve uma escolha aleatória em $\{0, 1, \dots, M-1\}$?

Se M é uma potência de 2, digamos que $M = 2^k$, então a resposta é simples: basta sortearmos $k = \log M$ bits aleatórios $d_0, d_1, \dots, d_{k-1} \in \{0, 1\}$ que o resultado é o número $\sum_{i=0}^{k-1} d_i 2^i$ no domínio desejado com probabilidade $1/M$.

No caso em que M não é potência de 2, digamos que $2^{k-1} < M < 2^k$ (o que significa que precisamos de $k = \lceil \log M \rceil$ bits aleatórios), usamos o mesmo processo descrito no parágrafo anterior com a exceção de que se o resultado for maior ou igual a M , o processo é reiniciado e é repetido até que um número entre 0 e $M-1$ seja obtido.

Algoritmo 1.2: Gerador de números aleatórios**Instância:** inteiro positivo $M \geq 2$.**Resposta:** uma escolha uniforme em $\{0, 1, \dots, M-1\}$.

```

1 repita
2   para cada  $i \in \{0, \dots, \lceil \log M \rceil - 1\}$  faça  $d_i \xleftarrow{R} \{0, 1\}$ ;
3    $N \leftarrow \sum_i d_i 2^i$ ;
4 até que  $N < M$ ;
5 responda  $N$ .

```

O resultado das escolhas aleatórias na linha 2 do Algoritmo 1.2, digamos que seja a sequência $d_{k-1}d_{k-2}\dots d_0$, é um evento que tem probabilidade $\mathbb{P}^{(k)}(d_{k-1}d_{k-2}\dots d_0) = (1/2)^k$.

Essa sequência é a representação binária do número $\sum_{i=0}^{k-1} d_i 2^i$ que pertence ao conjunto $\{0, 1, \dots, 2^k - 1\}$.

O ALGORITMO TERMINA?

Isto é, eventualmente a condição $N < M$ na linha 4 é satisfeita?

Fixamos uma instância M com

$$2^{k-1} < M \leq 2^k \quad \text{e} \quad k = \lceil \log M \rceil.$$

A probabilidade com que uma rodada do laço da linha 1 resulte em um inteiro N que pertença ao conjunto $\bar{A} = \{M, \dots, 2^k - 1\}$ é

$$\mathbb{P}(\bar{A}) = \frac{2^k - M}{2^k} = 1 - \frac{M}{2^k} < 1 - \frac{2^{k-1}}{2^k} = \frac{1}{2},$$

pois $M > 2^{k-1}$.

Para todo $n \geq 1$,

A_n é o evento “o algoritmo leva mais que n rodadas para terminar”.

Tal evento ocorre se nas n primeiras tentativas do laço na linha 1 ocorre um sorteio em $\bar{A}$ e daí pra diante pode ocorrer qualquer um dos dois casos, A ou $\bar{A}$, logo, pela independência da ocorrência dos eventos $\bar{A}$ em cada rodada do laço

$$\mathbb{P}(A_n) = \left(1 - \frac{M}{2^k}\right)^n$$

portanto,

$$\mathbb{P}(A_n) < \left(\frac{1}{2}\right)^n.$$

Os eventos A_n formam uma sequência decrescente $A_n \supset A_{n+1}$ e $\lim_{n \rightarrow \infty} A_n = \bigcap_{n \geq 1} A_n$ é o evento “o algoritmo não termina”, cuja

probabilidade é, por continuidade (equação (1.15) na página 21),

$$\begin{aligned}
 \mathbb{P}[\text{o algoritmo não termina}] &= \mathbb{P}\left(\bigcap_{n \geq 1} A_n\right) \\
 &= \lim_{n \rightarrow \infty} \mathbb{P}(A_n) \\
 &= \lim_{n \rightarrow \infty} \left(1 - \frac{M}{2^k}\right)^n \\
 &= 0.
 \end{aligned} \tag{1.16}$$

Consequentemente, $\mathbb{P}[\text{o algoritmo termina}] = 1$. O algoritmo termina *quase certamente*.

SE TERMINA, QUÃO RÁPIDO TERMINA?

A aleatoriedade influencia na duração das rodadas, isto é, no número de rodadas do laço da linha 1 necessárias para que ele termine.

O algoritmo não apenas termina quase certamente, como, de fato, termina em poucas rodadas com alta probabilidade. De $M > 2^{k-1}$ temos $\mathbb{P}(\bar{A}) < 1/2$, portanto, em n rodadas do laço todos os inteiros sorteados pertencem a $\bar{A}$ com probabilidade menor que 2^{-n} . A probabilidade de não terminar em, por exemplo, 4 rodadas é menor que 0,07, em 10 rodadas é menor que 0,00098.

SE O ALGORITMO TERMINA, RESPONDE CERTO?

Por exemplo, se $M = 7$ então $k = 3$. Com três bits $d_2 d_1 d_0$ temos as representações binárias dos naturais de 0 a 7. O laço da linha 1 gera qualquer um desses números com a mesma probabilidade, a saber $1/2^3 = 1/8$. Porém o algoritmo só termina se o sorteio for diferente de 7, isto é, não ocorre o evento $d_2 d_1 d_0 = 111$. Dado que esse evento não ocorre, qual a probabilidade do algoritmo responder 4?

Seja N a resposta do algoritmo. Usando probabilidade condicional $\mathbb{P}[N = 4 \mid N \neq 7] = (1/8) / (7/8) = 1/7$ e, de fato, o algoritmo escolhe qualquer número em $\{0, \dots, 6\}$ com probabilidade $1/7$.

No caso geral, definimos o evento $A = \{0, 1, \dots, M-1\}$ e para qualquer $t \in A$ a probabilidade da resposta N do algoritmo ser t dado que $N \in A$ é

$$\mathbb{P}_{N \in \{0, \dots, 2^k-1\}}[N = t \mid N \in A] = \frac{\mathbb{P}(\{t\} \cap A)}{\mathbb{P}(A)} = \frac{(1/2)^k}{M/2^k} = \frac{1}{M}.$$

Portanto, se o algoritmo termina, ou seja, dado que o sorteio N satisfaça $N < M$, então ele responde com um número entre 0 e $M-1$ de modo uniforme.

Diferente do algoritmo para identidade polinomial, o Algoritmo 1.2 não responde errado. Em contrapartida, o tempo de execução depende dos sorteios.

Algoritmos Las Vegas O algoritmo gerador de números aleatórios sempre fornece a solução correta. A única variação de uma execução para outra é o seu tempo de execução. Chamamos esse tipo de algoritmo de *algoritmo Las Vegas*. Um algoritmo Las Vegas é, por definição, um algoritmo Monte Carlo com probabilidade de erro igual a o cujo tempo de execução é uma variável aleatória (nosso próximo tema). Em geral, deseja-se que esses algoritmos tenham tempo de execução esperado pequeno e que a probabilidade de uma execução demorar muito seja pequena.

Dizemos que um algoritmo Las Vegas é um algoritmo *Las Vegas eficiente* se, para qualquer entrada, seu *tempo de execução esperado*² for delimitado por uma função polinomial do tamanho da entrada.

² A esperança da variável aleatória para o tempo de execução

Dizemos que um algoritmo Monte Carlo é um algoritmo *Monte Carlo eficiente* se, para qualquer entrada, seu tempo de execução no pior caso for delimitado por uma função polinomial do tamanho da entrada.

Exercícios

Exercício 1. Há três urnas e em cada urna um par de bolas. Na primeira urna há um par de bolas brancas, na segunda um par de bolas pretas e na terceira um par com uma bola de cada cor. Uma urna é escolhida uniformemente e, sem olhar para o interior da urna, uma bola é escolhida uniformemente e retirada. A bola retirada é branca. Qual a probabilidade da bola que ficou sozinha na urna ser preta?

Exercício 2. Considere a seguinte proposta de algoritmo que recebe um inteiro positivo $M > 0$ e devolve um inteiro escolhido aleatoriamente em $\{0, 1, \dots, M - 1\}$:

Instância: inteiro positivo M .

Resposta: uma escolha aleatória em $\{0, 1, \dots, M - 1\}$.

- 1 seja k o número de bits de M ;
- 2 $(d_0, d_1, \dots, d_{k-1}) \xleftarrow{R} \{0, 1\}^k$;
- 3 $N \leftarrow \sum_i d_i 2^i$;
- 4 **responda** $N \bmod M$.

Prove que as respostas não são equiprováveis quando M não é potência de 2.

Exercício 3. Agora, considere o seguinte gerador de números aleatórios adaptado do anterior.

Instância: inteiros positivos M e t .

Resposta: uma escolha aleatória em $\{0, 1, \dots, M-1\}$.

- 1 seja k o número de bits de M ;
- 2 $(d_0, d_1, \dots, d_{k+t-1}) \stackrel{\mathcal{R}}{\leftarrow} \{0, 1\}^{k+t}$;
- 3 $N \leftarrow \sum_i d_i 2^i$;
- 4 **responda** $N \bmod M$.

No caso $t = 0$ a probabilidade da resposta não é uniforme (como vimos acima). Prove que

$$\sum_{n=0}^{M-1} \left| \mathbb{P}[N = n] - \frac{1}{M} \right| \leq \frac{1}{2^{t-1}}.$$

Isso mostra que, à medida que t cresce, a distribuição de $N \bmod M$ converge exponencialmente rápido para a distribuição uniforme em $\{0, \dots, M-1\}$, o que justifica usar valores modestos de t (por exemplo $t = O(\log(1/\delta))$) para obter uma amostragem “quase uniforme” com erro estatístico δ arbitrariamente pequeno.

Exercício 4. Prove que no seguinte algoritmo a probabilidade p_n do laço executar pelo menos n vezes, para todo $n \geq 2$, é maior que 0 e, mais que isso, essa probabilidade é maior que 0 no limite, ou seja, $\lim p_n > 0$ quando $n \rightarrow \infty$ (pode ser útil a desigualdade $1 - x \geq \exp(-2x)$ para $x \in [0, 1/2]$).

- 1 $j \leftarrow 0$;
- 2 **repita**
- 3 $j \leftarrow j + 1$;
- 4 **para cada** $i \in \{1, 2, \dots, j\}$ **faça** $d_i \stackrel{\mathcal{R}}{\leftarrow} \{0, 1\}$;
- 5 **até que** $d_i = 1$ para todo i .

2

Variáveis aleatórias discretas

As variáveis aleatórias são funções que descrevem grandezas observáveis em fenômenos aleatórios, como o tempo de execução de um algoritmo aleatorizado, o número de comparações realizadas por um procedimento de busca, ou o tamanho de uma estrutura de dados gerada aleatoriamente. No Algoritmo 1.2, o número de rodadas do laço é uma variável aleatória. Note que execuções diferentes do algoritmo, mesmo que com a entrada M fixa, a quantidade de rodadas do laço pode ser diferente.

Definição 2.1: Variável aleatória discreta

Se $(\Omega, \mathcal{A}, \mathbb{P})$ é um espaço de probabilidade, então uma função

$$X: \Omega \rightarrow \mathbb{R}$$

é uma *variável aleatória discreta* se sua imagem, que denotamos por $X(\Omega)$, é enumerável.

Em particular, se Ω é enumerável, então qualquer função

$X: \Omega \rightarrow \mathbb{R}$ é uma *variável aleatória discreta*.

A definição mais geral para v.a. discreta é: existe um enumerável S tal que $\mathbb{P}[X \in S] = 1$. Note que isso permite $\omega \in \Omega$ tal que $X(\omega) \notin S$, desde que $\mathbb{P}(\omega) = 0$. Entretanto, neste texto, não será preciso toda essa generalidade. Quase sempre trabalharemos com Ω enumerável.

Usaremos, quase sempre, as letras maiúsculas finais do alfabeto, como X, Y, Z, W , para denotar variáveis aleatórias.

Exemplo 2.1: Variável aleatória indicadora

Para qualquer evento A de um espaço de probabilidade $(\Omega, \mathcal{A}, \mathbb{P})$, definimos a variável aleatória $\mathbb{1}_A: \Omega \rightarrow \{0, 1\}$ por

$$\mathbb{1}_A(\omega) := \begin{cases} 1, & \text{se } \omega \in A \\ 0, & \text{caso contrário,} \end{cases}$$

e que chamamos de *variável aleatória indicadora* da ocorrência do evento A .

Proposição 2.1: Variável aleatória como soma de indicadoras

Toda variável aleatória discreta pode ser escrita como uma combinação linear de variáveis indicadoras.

Demonstração. Seja X uma variável aleatória discreta e seja $\{x_1, x_2, \dots\} \subseteq \mathbb{R}$ o conjunto dos valores que X pode assumir. Para cada i , considere a variável aleatória $\mathbb{1}_{A_i}$ indicadora do evento $A_i = [X = x_i]$.

Como X assume, necessariamente, um dos valores x_i , para todo $\omega \in \Omega$, existe um único i tal que $X(\omega) = x_i$. Consequentemente,

$$\sum_{i=1}^{\infty} x_i \mathbb{1}_{A_i}(\omega) = X(\omega).$$

Logo,

$$X = \sum_{i=1}^{\infty} x_i \mathbb{1}_{A_i} = \sum_i x_i \mathbb{1}_{[X=x_i]}.$$

No caso em que X assume apenas um número finito de valores, a soma é finita; no caso enumerável, trata-se de uma soma enumerável (série). $\square$

Proposição 2.2

Se X é uma variável aleatória que assume valores nos inteiros positivos, então

$$X = \sum_{k=1}^{\infty} \mathbb{1}_{[X \geq k]}. \quad (2.1)$$

Demonstração. Para cada $\omega \in \Omega$, existe um único $m = X(\omega) \in \mathbb{Z}_+$. Então, dado $k \geq 1$

$$\mathbb{1}_{[X \geq k]}(\omega) = \begin{cases} 1, & \text{se } k \leq m, \\ 0, & \text{se } k > m. \end{cases}$$

Logo,

$$\sum_{k=1}^{\infty} \mathbb{1}_{[X \geq k]}(\omega) = \underbrace{1 + \dots + 1}_{m \text{ termos}} = m = X(\omega).$$

Como vale para todo $\omega \in \Omega$, concluímos (2.1) $\square$

2.1 Distribuição

Se X é uma v.a. discreta. Para $a \in X(\Omega)$, $[X = a]$ denota o evento

$$[X = a] := \{\omega \in \Omega: X(\omega) = a\}$$

que ocorre com probabilidade

$$\mathbb{P}_X(a) := \mathbb{P}[X = a].$$

A função $a \mapsto \mathbb{P}_X(a)$ é chamada *lei*, ou *distribuição*, de X : trata-se de uma medida de probabilidade em $(X(\Omega), 2^{X(\Omega)})$.

Analogamente, $[X \leq a]$ denota o evento $\{\omega \in \Omega: X(\omega) \leq a\}$.

Para a v.a. indicadora, como no Exemplo 2.1 acima, temos

$$[\mathbb{1}_A \leq t] = \begin{cases} \emptyset, & \text{se } t < 0 \\ \overline{A}, & \text{se } 0 \leq t < 1 \\ \Omega, & \text{se } t \geq 1 \end{cases}$$

Ainda, a notação $[X \in A]$ é usada para o evento dado pela pré-imagem de A , i.e.,

$$[X \in A] = X^{-1}(A) = \{\omega \in \Omega: X(\omega) \in A\},$$

para todo $A \subseteq X(\Omega)$.

Por exemplo, as pré-imagens $\mathbb{1}_A^{-1}(B)$ são $\emptyset$, A , $\overline{A}$ e Ω nos casos, respectivamente, $\{0, 1\} \cap B = \emptyset$, $\{0, 1\} \cap B = \{1\}$, $\{0, 1\} \cap B = \{0\}$ e $\{0, 1\} \cap B = \{0, 1\}$ para todo $B \subseteq \mathbb{R}$.

Experimentos aleatórios com apenas duas possibilidades de resultado, *sucesso* ou *fracasso*, recebem o nome de *ensaio de Bernoulli*.

Modelamos um ensaio de Bernoulli por uma variável aleatória

$X: \Omega \rightarrow \mathbb{R}$, com $X(\Omega) \in \{0, 1\}$ e 0 representa *fracasso* e 1 representa *sucesso*.

Exemplo 2.2: Distribuição de Bernoulli

Se X é uma variável aleatória com imagem $\{0, 1\}$ e lei

$$\mathbb{P}_X(1) = p \quad \text{e} \quad \mathbb{P}_X(0) = 1 - p$$

então dizemos que X tem *distribuição de Bernoulli* com parâmetro p , onde $p \in [0, 1]$ é a probabilidade de sucesso, e usamos

$$X \sim \text{Bernoulli}(p)$$

para indicar esse fato.

Em n ensaios de Bernoulli idênticos e independentes, uma resposta específica $(b_1, b_2, \dots, b_n)$ com exatamente $t \in \{0, \dots, n\}$ sucessos e $n - t$ fracassos ocorre com probabilidade $p^t(1 - p)^{n-t}$. A quantidade de sequências de respostas distintas com exatamente t sucessos é $\binom{n}{t}$, assim a probabilidade de exatamente t sucessos é

$$\binom{n}{t} p^t (1 - p)^{n-t}.$$

Exemplo 2.3: Distribuição binomial

Se X é a quantidade de sucessos em n ensaios de Bernoulli, idênticos e independentes, então

$$\mathbb{P}_X(t) := \binom{n}{t} p^t (1-p)^{n-t}, \quad t \in \{0, 1, \dots, n\}$$

chamada **distribuição binomial** com parâmetros n e p . Nesse caso, escrevemos

$$X \sim \text{Binomial}(n, p).$$

Se $X_1, \dots, X_n \sim \text{Bernoulli}(p)$ são variáveis aleatórias mutuamente independentes, então

$$X = \sum_{i=1}^n X_i \sim \text{Binomial}(n, p).$$

Exemplo 2.4: Distribuição geométrica

Uma variável geométrica conta o número de realizações de ensaios de Bernoulli independentes e identicamente distribuídos realizados até, e incluindo, o primeiro sucesso.

Se X é uma variável aleatória geométrica, então para $X = t$ é necessário que nas primeiras $t - 1$ iterações ocorra fracasso e na t -ésima iteração ocorra sucesso. Como os ensaios são independentes, a lei de X é

$$\mathbb{P}_X(t) := (1-p)^{t-1} p, \quad t \in \{1, 2, \dots\}$$

e dizemos que X tem **distribuição geométrica** com parâmetro p , o que denotamos por $X \sim \text{Geom}(p)$.

Em alguns textos a distribuição geométrica conta o número de fracassos antes do primeiro sucesso. Nesse caso a variável aleatória $Y = X - 1$ assume valores em $\{0, 1, 2, \dots\}$ e tem distribuição $\mathbb{P}_Y(t) = \mathbb{P}_X(t + 1)$.

INDEPENDÊNCIA

As variáveis aleatórias discretas X e Y definidas em Ω são **independentes** se para quaisquer $A, B \subset \mathbb{R}$

$$\mathbb{P}([X \in A] \cap [Y \in B]) = \mathbb{P}[X \in A] \cdot \mathbb{P}[Y \in B].$$

Considerando as leis $\mathbb{P}_{(X,Y)}$ do vetor aleatório (X, Y) , $\mathbb{P}_X$ de X e $\mathbb{P}_Y$ de Y temos que independência como definido acima é equivalente a

$$1. \quad \mathbb{P}_{(X,Y)}(A \times B) = \mathbb{P}_X(A) \cdot \mathbb{P}_Y(B);$$

2. $[X = a]$ e $[Y = b]$ são independentes, para quaisquer $a \in X(\Omega)$ e $b \in Y(\Omega)$;
3. $\mathbb{P}_{(X,Y)}((a,b)) = \mathbb{P}_X(a) \cdot \mathbb{P}_Y(b)$, para quaisquer $a \in X(\Omega)$ e $b \in Y(\Omega)$;
4. $\mathbb{P}([X \leq a] \cap [Y \leq b]) = \mathbb{P}[X \leq a] \cdot \mathbb{P}[Y \leq b]$ para quaisquer $a, b \in \mathbb{R}$.

Mais geralmente, as variáveis aleatórias $X_1, X_2, \dots, X_n$ são *mutua-mente independentes* se para quaisquer subconjuntos $A_1, \dots, A_n \subseteq \mathbb{R}$

$$\mathbb{P}\left(\bigcap_{i=1}^n [X_i \in A_i]\right) = \mathbb{P}_{\mathbf{X}}(A_1 \times \dots \times A_n) = \prod_{i=1}^n \mathbb{P}_{X_i}(A_i) = \prod_{i=1}^n \mathbb{P}[X_i \in A_i].$$

Equivalentemente,

$$\mathbb{P}_{\mathbf{X}}(A_1 \times \dots \times A_n) = \prod_{i=1}^n \mathbb{P}_{X_i}(A_i)$$

em que $\mathbf{X} = (X_1, X_2, \dots, X_n)$.

2.2 Valor esperado de uma variável aleatória discreta

O *valor esperado* ou, ainda, *esperança* da variável aleatória X é, ingenuamente, a média dos valores que X assume, ponderada pela probabilidade de assumir tais valores.

Uma variável aleatória X é chamada de *simples* se pode ser escrita como combinação linear finita de funções indicadoras de eventos, ou seja, existem valores $x_1, \dots, x_k \in \mathbb{R}$ e eventos $A_1, \dots, A_k$ tais que

$$X = \sum_{i=1}^k x_i \mathbb{1}_{A_i}.$$

Podem existir muitas maneiras de escrever uma variável aleatória simples como combinação linear de indicadoras. Descrevemos a seguir uma *forma canônica*: sejam $x_1, \dots, x_m$ os valores *distintos* assumidos por X e $B_i = [X = x_i]$. Os B_i são eventos não vazios, disjuntos dois a dois, e formam uma partição de Ω ; a *representação canônica* é

$$X = \sum_{i=1}^m x_i \mathbb{1}_{B_i}.$$

Queremos que a esperança seja linear e que $\mathbb{E}\mathbb{1}_A = \mathbb{P}(A)$. Sobre a representação canônica, isso força a seguinte definição.

Definição 2.2: Esperança de uma variável simples

Se X é uma variável aleatória simples, com valores distintos $x_1, \dots, x_m$ e $B_i = [X = x_i]$, então

$$\mathbb{E}X := \sum_{i=1}^m x_i \mathbb{P}(B_i) = \sum_{i=1}^m x_i \mathbb{P}[X = x_i].$$

Vamos verificar que essa definição é compatível com as outras representações de X . É isso que fazem os resultados a seguir. Primeiro tratamos as representações por partições, que é o que precisamos para a linearidade.

Proposição 2.3: Boa definição via refinamento comum

Sejam $\{A_i\}_{i=1}^n$ e $\{B_j\}_{j=1}^m$ partições finitas de Ω em eventos (possivelmente vazios) e suponha

$$X = \sum_{i=1}^n x_i \mathbb{1}_{A_i} = \sum_{j=1}^m a_j \mathbb{1}_{B_j}.$$

Então

$$\sum_{i=1}^n x_i \mathbb{P}(A_i) = \sum_{j=1}^m a_j \mathbb{P}(B_j).$$

Demonstração. Seja $C_{ij} = A_i \cap B_j$. Estes conjuntos são disjuntos dois a dois e

$$A_i = \bigcup_j C_{ij}, \quad B_j = \bigcup_i C_{ij},$$

logo, por aditividade finita de $\mathbb{P}$,

$$\mathbb{P}(A_i) = \sum_j \mathbb{P}(C_{ij}), \quad \mathbb{P}(B_j) = \sum_i \mathbb{P}(C_{ij}). \quad (2.2)$$

Afirmamos que $x_i \mathbb{P}(C_{ij}) = a_j \mathbb{P}(C_{ij})$ para todo par (i, j) . Se $C_{ij} = \emptyset$, ambos os lados são nulos. Caso contrário, tome $\omega \in C_{ij}$: como as famílias são partições, $\mathbb{1}_{A_k}(\omega) = 1$ apenas para $k = i$ e $\mathbb{1}_{B_l}(\omega) = 1$ apenas para $l = j$, de modo que $x_i = X(\omega) = a_j$. Combinando com (2.2),

$$\sum_i x_i \mathbb{P}(A_i) = \sum_{i,j} x_i \mathbb{P}(C_{ij}) = \sum_{i,j} a_j \mathbb{P}(C_{ij}) = \sum_j a_j \mathbb{P}(B_j). \quad \square$$

Corolário 2.1: Qualquer partição calcula $\mathbb{E}X$

Se $X = \sum_{j=1}^m a_j \mathbb{1}_{A_j}$ com $\{A_j\}$ partição finita de Ω em eventos, então $\mathbb{E}X = \sum_{j=1}^m a_j \mathbb{P}(A_j)$.

Demonstração. A representação canônica é uma representação por partição. Aplique a Proposição 2.3 a ela e à representação dada. $\square$

Proposição 2.4: Linearidade

Se X e Y são variáveis aleatórias simples e $a, b \in \mathbb{R}$, então $aX + bY$ é simples e

$$\mathbb{E}(aX + bY) = a \mathbb{E}X + b \mathbb{E}Y.$$

Demonstração. Sejam $X = \sum_{i=1}^n x_i \mathbb{1}_{B_i}$ e $Y = \sum_{j=1}^m y_j \mathbb{1}_{C_j}$ as representações canônicas. A família $\{B_i \cap C_j\}$ é uma partição de Ω em eventos e, para $\omega \in B_i \cap C_j$, $(aX + bY)(\omega) = ax_i + by_j$. Logo

$$aX + bY = \sum_{i=1}^n \sum_{j=1}^m (ax_i + by_j) \mathbb{1}_{B_i \cap C_j},$$

o que mostra que $aX + bY$ é simples. Esta é uma representação por partição de $aX + bY$, talvez não canônica (os valores $ax_i + by_j$ podem se repetir). Pelo Corolário 2.1,

$$\mathbb{E}(aX + bY) = \sum_{i,j} (ax_i + by_j) \mathbb{P}(B_i \cap C_j).$$

Por aditividade finita, $\sum_j \mathbb{P}(B_i \cap C_j) = \mathbb{P}(B_i)$ e $\sum_i \mathbb{P}(B_i \cap C_j) = \mathbb{P}(C_j)$, donde

$$\mathbb{E}(aX + bY) = a \sum_{i=1}^n x_i \mathbb{P}(B_i) + b \sum_{j=1}^m y_j \mathbb{P}(C_j) = a \mathbb{E}X + b \mathbb{E}Y. \quad \square$$

Corolário 2.2: Linearidade finita

Se $X_1, \dots, X_n$ são variáveis aleatórias simples e $a_1, \dots, a_n \in \mathbb{R}$, então $\sum_{i=1}^n a_i X_i$ é simples e

$$\mathbb{E}\left(\sum_{i=1}^n a_i X_i\right) = \sum_{i=1}^n a_i \mathbb{E}(X_i).$$

Demonstração. Indução em n : o caso $n = 1$ é trivial, e o passo segue da Proposição 2.4 aplicada a $\sum_{i < n} a_i X_i$ e X_n . $\square$

Corolário 2.3: Indicadoras arbitrárias

Se $A_1, \dots, A_k$ são eventos quaisquer (não necessariamente disjuntos) e $c_1, \dots, c_k \in \mathbb{R}$, então

$$\mathbb{E}\left(\sum_{l=1}^k c_l \mathbb{1}_{A_l}\right) = \sum_{l=1}^k c_l \mathbb{P}(A_l).$$

Em particular, o valor de $\mathbb{E}X$ não depende de qual represen-

tação de X como combinação linear finita de indicadoras é usada.

Demonstração. Como $\mathbb{1}_A = 1 \cdot \mathbb{1}_A + 0 \cdot \mathbb{1}_{\bar{A}}$ é uma representação por partição, o Corolário 2.1 dá $\mathbb{E}\mathbb{1}_A = \mathbb{P}(A)$. O resultado segue do Corolário 2.2. $\square$

Observação 2. Reagrupando a soma da Definição 2.2, e supondo Ω enumerável, temos

$$\mathbb{E}X = \sum_{i=1}^m x_i \mathbb{P}(B_i) = \sum_{\omega \in \Omega} X(\omega) \mathbb{P}(\omega),$$

a média dos valores de X ponderada pela probabilidade de cada ponto. Em um espaço geral (por exemplo, $[0, 1]$ com a medida de Lebesgue) vale $\mathbb{P}(\{\omega\}) = 0$ e a soma sobre Ω não faz sentido; a fórmula correta é $\mathbb{E}X = \sum_x x \mathbb{P}(X = x)$.

Exemplo 2.5: Média pode ser pouco representativa

Consideremos um jogo de azar no qual em cada aposta pagamos R\$10,00 e, ou ganhamos R\$1.000,00 com probabilidade $p \in (0, 1)$ ou não ganhamos nada, ou seja, perdemos os R\$10,00 que já foram pagos, com probabilidade $1 - p$. Se Y é o ganho líquido em uma aposta, então a esperança do ganho por aposta é $\mathbb{E}Y = 10^6 p - 10(1 - p) = 1.000.010p - 10$.

Se $p = 1/100$ então a probabilidade de ganhar o valor alto é muito pequeno quando comparado com a probabilidade de perder 10 reais, mas o prêmio é tão grande que o ganho esperado por aposta ainda é positivo: $\mathbb{E}Y = 9.990,10$.

Apesar do ganho esperado por aposta ser positivo, a probabilidade de efetivamente ganhar o prêmio é de apenas 1%: em 99% das vezes o jogador simplesmente perde os R\$ 10,00 investidos. A esperança, portanto, não descreve o que tipicamente acontece a quem joga, apenas uma média que só se manifestaria após repetições muito numerosas do jogo.

Exemplo 2.6

Se $X \in_{\mathbb{R}} \{1, 2, 3, 4, 5, 6\}$ é o resultado de um lançamento de um dado, então

$$\mathbb{E}X = 1\frac{1}{6} + 2\frac{1}{6} + 3\frac{1}{6} + 4\frac{1}{6} + 5\frac{1}{6} + 6\frac{1}{6} = \frac{7}{2}$$

e se Y é o resultado de outro lançamento de dado, qual é a esperança da soma $X + Y$ dos pontos nos dois lançamentos do

dado?

$$\mathbb{E}(X + Y) = \mathbb{E}(X) + \mathbb{E}(Y) = 7$$

pela linearidade da esperança é 7.

Assumindo que os lançamentos são independentes, a esperança do produto é

$$\mathbb{E}(X \cdot Y) = \mathbb{E}(X) \cdot \mathbb{E}(Y) = \frac{49}{4}.$$

A distribuição do produto $X \cdot Y$ é mostrada na Tabela 2.1 abaixo.

$X \cdot Y$	1	2	3	4	5	6	8	9	10	12	15	16	18	20	24	25	30	36
$\mathbb{P}_{X \cdot Y}$	$\frac{1}{36}$	$\frac{2}{36}$	$\frac{2}{36}$	$\frac{3}{36}$	$\frac{2}{36}$	$\frac{4}{36}$	$\frac{2}{36}$	$\frac{1}{36}$	$\frac{2}{36}$	$\frac{4}{36}$	$\frac{2}{36}$	$\frac{1}{36}$	$\frac{2}{36}$	$\frac{2}{36}$	$\frac{2}{36}$	$\frac{1}{36}$	$\frac{2}{36}$	$\frac{1}{36}$

Tabela 2.1: distribuição do produto de dois dados.

Exemplo 2.7: Esperança da distribuição de Bernoulli

Se $X \sim \text{Bernoulli}(p)$, então podemos considerar o evento dado por $A = \{\omega \in \Omega: X(\omega) = 1\}$, de forma que $X = \mathbb{1}_A$. Dessa forma,

$$\mathbb{E}X = \mathbb{P}_X(1) = \mathbb{P}(A) = p.$$

Exemplo 2.8: Esperança da distribuição binomial

Se $X \sim \text{Binomial}(n, p)$, então

$$X = \sum_{i=1}^n X_i \sim \text{Binomial}(n, p)$$

com $X_i \sim \text{Bernoulli}(p)$ e, pela linearidade da esperança (Corol. 2.2),

$$\mathbb{E}X = \mathbb{E}\left(\sum_{i=1}^n X_i\right) = \sum_{i=1}^n \mathbb{E}(X_i) = np.$$

Uma variável aleatória geométrica tem imagem enumerável infinita $\{1, 2, \dots\}$ e gostaríamos de estender, de modo natural, a definição de valor esperado de uma variável simples, ou seja, se X tem valores $\{x_1, x_2, \dots\} \subseteq \mathbb{R}$ queremos

$$\mathbb{E}X = \sum_{n \geq 1} x_n \mathbb{P}[X = x_n]. \quad (2.3)$$

Exemplo 2.9: Rearranjos podem convergir para somas distintas

Desde o século XIX sabe-se que rearrranjos da série harmônica alternada

$$\sum_{i=1}^{\infty} \frac{(-1)^{i+1}}{i}$$

podem resultar em limites diferentes. Por exemplo,

$$1 - \frac{1}{2} + \frac{1}{3} - \cdots + \frac{(-1)^{n+1}}{n} + \cdots = \ln(2)$$

enquanto que, no rearrranjo atribuído a Laurent,

$$1 - \frac{1}{2} - \frac{1}{4} + \frac{1}{3} - \frac{1}{6} - \frac{1}{8} + \cdots + \frac{1}{2k-1} - \frac{1}{2(2k-1)} - \frac{1}{4k} + \cdots = \frac{\ln(2)}{2}.$$

Seja X a variável aleatória que assume os valores (distintos)

$$x_i := (-1)^{i+1} i, \quad i = 1, 2, \dots, \quad \mathbb{P}[X = x_i] = \frac{6}{(\pi i)^2}.$$

Então $x_i \mathbb{P}[X = x_i] = \frac{6}{\pi^2} \frac{(-1)^{i+1}}{i}$ e, para uma enumeração σ dos valores,

$$\sum_{i=1}^{\infty} x_{\sigma(i)} = \mathbb{P}[X = x_{\sigma(i)}] \begin{cases} \frac{6}{\pi^2} \ln(2) & \text{se } \sigma \text{ é a permutação identidade} \\ \frac{3}{\pi^2} \ln(2) & \text{se } \sigma \text{ é a permutação de Laurent} \end{cases}, \quad (2.4)$$

Note que $\sum_i x_i^+ \mathbb{P}[X = x_i] = \sum_i x_i^- \mathbb{P}[X = x_i] = \infty$ (os termos de cada sinal são da ordem de $1/i$). Portanto, X não tem um valor esperado bem definido.

Para que (2.3) defina um número real, é necessário que o valor da soma não dependa da ordem dos termos. O índice n não carrega nenhuma ordem imposta pela estrutura do problema: os eventos $\{X = x_n\}$ formam um conjunto enumerável, não uma sequência canonicamente ordenada (a ordem em que escrevemos $x_1, x_2, \dots$ é apenas uma escolha arbitrária de enumeração). Assim, para que (2.3) defina uma esperança finita, é necessário que a série seja *incondicionalmente convergente*, isto é, que qualquer reordenação de seus termos convirja sempre para a mesma soma.

Um teorema atribuído a Riemann (veja em Rudin, 1976, teorema

3.54) estabelece que, se $\sum_n a_n$ converge e $\sum_{i \geq 1} |a_i| = \infty$, então, para qualquer $S \in \mathbb{R} \cup \{-\infty, +\infty\}$, existe uma permutação σ dos inteiros positivos tal que $\sum_{i \geq 1} a_{\sigma(i)} = S$. Se a série nem converge na ordem original, também não é incondicionalmente convergente. Por outro lado, séries com $\sum_{i \geq 1} |a_i| < \infty$ convergem para a mesma soma em qualquer ordem (Rudin, 1976, teorema 3.55). Portanto,

a série é incondicionalmente convergente, se e só se $\sum_{i \geq 1} |a_i| < \infty$.

e nesse caso dizemos que a série *converge absolutamente*.

Se $(a_n: n \geq 1)$ uma sequência de números reais com $a_n \geq 0$ para todo n , então a soma parcial $\sum_{n=1}^m a_n$ é crescente e, portanto, sempre tende a um limite S , possivelmente infinito, $S \in [0, \infty]$. Assim, tal série

- *converge* para um número real (finito), caso em que escrevemos $\sum_{n \geq 1} a_n < \infty$; ou
- *converge para* ∞ e escrevemos $\sum_{n \geq 1} a_n = \infty$.

Em ambos os casos, o valor da série não se altera se a ordem dos termos for modificada.

No caso geral, onde $a_n \in \mathbb{R}$, definimos $a^+ := \max\{a, 0\}$ e $a^- := \max\{-a, 0\}$ e

$$S^+ := \sum_{n: a_n \geq 0} a_n^+ \quad \text{e} \quad S^- := \sum_{n: a_n < 0} a_n^-. \quad (2.5)$$

Há três casos.

- Se $S^+ < \infty$ e $S^- < \infty$, então a série converge absolutamente e $S = S^+ - S^-$, em qualquer ordem.
- Se exatamente um entre S^+ e S^- é infinito, então $S = +\infty$ (se $S^+ = \infty$) ou $S = -\infty$ (se $S^- = \infty$), independentemente da ordem de somação.
- Se $S^+ = S^- = \infty$, a soma não está bem definida: pode depender da ordem dos termos, e diferentes rearranjos podem levar a valores distintos.

Em particular, para X discreta com imagem $\{x_1, x_2, \dots\}$, eventos $B_i = [X = x_i]$ as somas

$$\mathbb{E}(X^+) := \sum_i x_i^+ \mathbb{P}(B_i) \in [0, \infty], \quad \mathbb{E}(X^-) := \sum_i x_i^- \mathbb{P}(B_i) \in [0, \infty]$$

estão sempre bem definidas, independentemente da enumeração escolhida.

Definição 2.3: Esperança matemática de uma v.a. discreta

Seja X uma variável aleatória discreta com imagem $\{x_1, x_2, \dots\}$ (valores distintos) e $B_i = [X = x_i]$.

Se **não** ocorrer $\mathbb{E}(X^+) = \mathbb{E}(X^-) = \infty$, então dizemos que $\mathbb{E}X$ está *definida* e nesse caso

$$\mathbb{E}X := \mathbb{E}(X^+) - \mathbb{E}(X^-) \in [-\infty, \infty].$$

Dizemos que X tem *esperança finita* ou que X é *integrável*, se $\mathbb{E}(X^+) < \infty$ e $\mathbb{E}(X^-) < \infty$, o que equivale a

$$\sum_i |x_i| \mathbb{P}[X = x_i] < \infty,$$

e, nesse caso, $\mathbb{E}X$ é finita e, como a série converge absolutamente,

$$\mathbb{E}X = \sum_i x_i \mathbb{P}[X = x_i] \quad (2.6)$$

em qualquer ordem de somação.

Quando X é simples, esta definição coincide com a Definição 2.2, pois a soma é finita e os sinais se separam termo a termo.

Cabe perguntar se o valor de $\mathbb{E}X$ também independe da *representação* de X , isto é, se qualquer outra decomposição enumerável de Ω em que X seja constante leva ao mesmo resultado. A resposta é sim, e é o análogo, para o caso enumerável, da Proposição 2.3.

Proposição 2.5: Independência da partição

Sejam $\{A_i\}_i$ e $\{B_j\}_j$ partições enumeráveis de Ω em eventos (possivelmente vazios) tais que

$$X = \sum_i x_i \mathbb{1}_{A_i} = \sum_j b_j \mathbb{1}_{B_j}.$$

(a) Se $x_i, b_j \geq 0$ para todos i, j , então

$$\sum_i x_i \mathbb{P}(A_i) = \sum_j b_j \mathbb{P}(B_j)$$

em $[0, \infty]$.

(b) Se $\sum_i |x_i| \mathbb{P}(A_i) < \infty$, então

$$\sum_j |b_j| \mathbb{P}(B_j) < \infty \quad \text{e} \quad \sum_i x_i \mathbb{P}(A_i) = \sum_j b_j \mathbb{P}(B_j).$$

Demonstração. Seja $C_{ij} = A_i \cap B_j$. Para i e j fixos, $A_i = \bigcup_j C_{ij}$ e

$B_j = \dot{\bigcup}_i C_{ij}$ são uniões disjuntas *enumeráveis*, de modo que, pela aditividade enumerável de $\mathbb{P}$ (e não apenas a finita),

$$\mathbb{P}(A_i) = \sum_j \mathbb{P}(C_{ij}), \quad \mathbb{P}(B_j) = \sum_i \mathbb{P}(C_{ij}).$$

Além disso, $x_i \mathbb{P}(C_{ij}) = b_j \mathbb{P}(C_{ij})$ para todo par (i, j) : se $C_{ij} = \emptyset$ ambos os lados são nulos; caso contrário, avaliando $X(\omega)$ nas duas representações para $\omega \in C_{ij}$, obtemos $x_i = b_j$. O mesmo vale com módulos.

(a) Se todos os termos são não negativos, então a soma dupla $\sum_{i,j} x_i \mathbb{P}(C_{ij}) \in [0, \infty]$ pode ser calculada em qualquer ordem (Tonelli para séries, s.5 no apêndice). Somando primeiro em j obtemos $\sum_i x_i \mathbb{P}(A_i)$; como $x_i \mathbb{P}(C_{ij}) = b_j \mathbb{P}(C_{ij})$, somando primeiro em i obtemos $\sum_j b_j \mathbb{P}(B_j)$.

(b) Aplicando (a) a $|x_i|$ e $|b_j|$ (que também representam $|X|$), temos

$$\sum_j |b_j| \mathbb{P}(B_j) = \sum_{i,j} |b_j| \mathbb{P}(C_{ij}) = \sum_{i,j} |x_i| \mathbb{P}(C_{ij}) = \sum_i |x_i| \mathbb{P}(A_i) < \infty.$$

Logo a família $\{x_i \mathbb{P}(C_{ij})\}_{i,j}$ é absolutamente somável e Fubini para séries permite somar em qualquer ordem, com o mesmo argumento de (a). $\square$

Corolário 2.4: Qualquer partição calcula $\mathbb{E}X$

Se $X = \sum_j b_j \mathbb{1}_{B_j}$, com $\{B_j\}$ uma partição enumerável de Ω em eventos, então

(a) se $b_j \geq 0$ para todo j ,

$$\mathbb{E}X = \sum_j b_j \mathbb{P}(B_j)$$

em $[0, \infty]$;

(b) se $\sum_j |b_j| \mathbb{P}(B_j) < \infty$, então X é integrável e

$$\mathbb{E}X = \sum_j b_j \mathbb{P}(B_j).$$

Em particular, $\mathbb{E}X^+ = \sum_j b_j^+ \mathbb{P}(B_j)$ e $\mathbb{E}X^- = \sum_j b_j^- \mathbb{P}(B_j)$ para qualquer partição em que X seja constante em cada elemento.

Demonstração. A partição canônica $[X = x_i]$ é uma partição enumerável em que $X = \sum_i x_i \mathbb{1}_{[X=x_i]}$. Aplique a Proposição 2.5 a ela e à partição dada. Para $X^\pm$, observe que $X^\pm = \sum_j b_j^\pm \mathbb{1}_{B_j}$ com coeficientes não negativos e aplique (a). $\square$

Observação 3. A Proposição 2.5 expõe um ingrediente que a definição usual $\mathbb{E}X := \sum_i x_i \mathbb{P}[X = x_i]$, apresentada sem passar pela construção via indicadoras, deixa implícito. A definição pela partição canônica já está bem posta apenas com convergência absoluta. Já a *compatibilidade com outras representações* depende também da aditividade enumerável de $\mathbb{P}$, algo que não era necessário no caso de variáveis simples, onde bastava aditividade finita.

Para *coberturas* enumeráveis não disjuntas $X = \sum_i y_i \mathbb{1}_{C_i}$ a igualdade $\mathbb{E}X = \sum_i y_i \mathbb{P}(C_i)$ exige a hipótese adicional $\sum_i |y_i| \mathbb{P}(C_i) < \infty$ (sem ela pode falhar, mesmo com convergência pontual) e é adiada para depois da integral geral, onde a troca entre esperança e série é justificada.

Analogamente à Observação 2, se Ω é enumerável e X é integrável, então podemos rearranjar a série de $\mathbb{E}X$. Os passos abaixo são justificados porque

$$\sum_t \sum_{\omega} |t| \mathbb{1}_{[X(\omega)=t]} \mathbb{P}(\omega) = \sum_t |t| \mathbb{P}[X = t] < \infty$$

(Tonelli para séries), o que torna a família absolutamente somável e autoriza Fubini na quarta igualdade:

$$\begin{aligned} \mathbb{E}X &= \sum_t t \mathbb{P}[X = t] \\ &= \sum_t t \sum_{\omega: X(\omega)=t} \mathbb{P}(\omega) \\ &= \sum_t t \left(\sum_{\omega} \mathbb{1}_{[X(\omega)=t]} \mathbb{P}(\omega) \right) \\ &= \sum_{\omega} \left(\sum_t t \mathbb{1}_{[X(\omega)=t]} \right) \mathbb{P}(\omega) \\ &= \sum_{\omega} X(\omega) \mathbb{P}(\omega). \end{aligned}$$

Portanto, com $B_i = [X = x_i]$,

$$\sum_i x_i \mathbb{P}(B_i) = \sum_{\omega} X(\omega) \mathbb{P}(\omega), \quad (2.7)$$

e a série do lado direito também converge absolutamente.

Ideia importante

A esperança de uma variável aleatória depende apenas da sua distribuição, ou seja, se X e Y têm a mesma distribuição, então $\mathbb{E}Y = \mathbb{E}X$. De fato, a Definição 2.3 usa apenas os valores x_i e as probabilidades $\mathbb{P}[X = x_i]$.

Em particular, a esperança pode ser vista como uma propriedade da

distribuição de X , não do espaço amostral subjacente.

Exemplo 2.10: Esperança da distribuição geométrica

Seja $X \sim \text{Geom}(p)$ com $p \in (0, 1)$. Lembremos que

$$\mathbb{P}_X(t) = (1-p)^{t-1}p, \quad t \in \{1, 2, \dots\}$$

portanto,

$$\mathbb{E}X = \sum_{t \geq 1} t(1-p)^{t-1}p$$

e pelo teste da razão a série converge absolutamente. Assim, usando s.6c, do apêndice,

$$\mathbb{E}X = p \sum_{t \geq 1} t(1-p)^{t-1} = p \cdot \frac{1}{(1-(1-p))^2} = \frac{1}{p}. \quad (2.8)$$

ANÁLISE DO ALGORITMO 1.2

Dado $M \geq 2$, tome $k = \lceil \log_2 M \rceil$ e seja X o número de rodadas do laço repita. Então $X \sim \text{Geom}(p)$ para $p = \mathbb{P}[N < M] = \frac{M}{2^k} > 1/2$. A esperança é

$$\mathbb{E}X = \frac{1}{p} < 2.$$

Vimos no Exemplo 2.5 que o valor esperado pode ser pouco representativo, mas aqui sabemos mais. Usando o Exercício 8, no final deste capítulo, temos que a probabilidade de ocorrerem mais que 5 vezes o número esperado de rodadas do repita

$$\mathbb{P}\left[X > \frac{5}{p}\right] = (1-p)^{\frac{5}{p}} < \left(\frac{1}{2}\right)^{10} = 0.0009765625$$

O tempo de execução das instruções dentro do laço é $O(k) = O(\ln M)$. Assim, se a variável aleatória T é o tempo de execução do algoritmo, então com entrada M

$$\mathbb{E}T(M) = \mathbb{E}(X) \cdot O(k) = \frac{1}{p} \cdot O(\ln M) = O(\ln M).$$

Exemplo 2.11: Distribuição binomial negativa

Há dois entendimentos para variável com *distribuição binomial negativa*.

(1) X conta o número *total* de tentativas de Bernoulli, independentes e idênticas, com parâmetro p até o r -ésimo sucesso.

Nesse caso

$$X = G_1 + \dots + G_r$$

com $G_i \sim \text{Geom}(p)$ e sua distribuição é

$$\mathbb{P}_X(t) = \binom{t-1}{r-1} p^r (1-p)^{t-r}, \quad t = r, r+1, \dots$$

Nesse caso, $\mathbb{E}X = r/p$, por linearidade.

(2) Y conta o número de *fracassos* antes do r -ésimo sucesso.

Nesse caso, em função de (1), $Y = X - r$ e tem distribuição

$$\mathbb{P}_X(t) = \binom{t+r-1}{t} (1-p)^t p^r, \quad t = 0, 1, 2, \dots$$

Notemos que o caso $r = 1$ é a lei da distribuição geométrica.

Denotamos por $\text{BN}(r, p)$ no caso 2, que chamamos de distribuição binomial negativa com parâmetros $r \in \mathbb{Z}_+$ e $p \in (0, 1)$.

Nesse caso, $\mathbb{E}Y = \frac{r}{p} - r$, por linearidade.

2.3 Propriedades da esperança

A seguir veremos propriedades importantes para a média das variáveis aleatórias discretas a valores reais. Começamos por um lema técnico com os fatos sobre $\mathbb{E}|X|$, comparação e igualdade quase certa que serão usados adiante. Todas as variáveis são discretas e usamos a Definição 2.3 e o Corolário 2.4.

Lema 2.1: Ferramentas básicas

Sejam Z, W, X, Y variáveis aleatórias discretas.

(a) Sejam z_i os valores distintos de Z . Para a v.a. $|Z|$ vale

$$\mathbb{E}|Z| = \mathbb{E}Z^+ + \mathbb{E}Z^- = \sum_i |z_i| \mathbb{P}[Z = z_i] \in [0, \infty].$$

Em particular, Z é integrável se, e só se, $\mathbb{E}|Z| < \infty$.

(b) (*Monotonicidade em $[0, \infty]$*) Se $0 \leq Z \leq W$, então $\mathbb{E}Z \leq \mathbb{E}W$.

(c) (*Domínio*) Se $|Z| \leq W$ e W é integrável, então Z é integrável e $\mathbb{E}|Z| \leq \mathbb{E}W$.

(d) (*Igualdade quase certa*) Se $\mathbb{P}[X = Y] = 1$, então, para todo $t \in \mathbb{R}$, vale $\mathbb{P}[X = t] = \mathbb{P}[Y = t]$.

Logo X e Y têm a mesma esperança (definida ou não, finita ou não).

Demonstração. (a) Escreva $|Z| = \sum_i |z_i| \mathbb{1}_{[Z=z_i]}$, uma representação por partição enumerável com coeficientes não negativos. Pelo Co-

rolário 2.4(a), $\mathbb{E}|Z| = \sum_i |z_i| \mathbb{P}[Z = z_i]$. Como $|z_i| = z_i^+ + z_i^-$ e os termos são não negativos, a série se separa em $\sum_i z_i^+ \mathbb{P}[Z = z_i] + \sum_i z_i^- \mathbb{P}[Z = z_i] = \mathbb{E}Z^+ + \mathbb{E}Z^-$.

(b) Sejam $A_i = [Z = z_i]$ e $B_j = [W = w_j]$ as partições canônicas e $C_{ij} = A_i \cap B_j$. Se $C_{ij} \neq \emptyset$, tomando $\omega \in C_{ij}$ obtemos $z_i = Z(\omega) \leq W(\omega) = w_j$; se $C_{ij} = \emptyset$ vale $z_i \mathbb{P}(C_{ij}) = 0 = w_j \mathbb{P}(C_{ij})$. Logo $z_i \mathbb{P}(C_{ij}) \leq w_j \mathbb{P}(C_{ij})$ para todo par (i, j) . Por aditividade enumerável e Tonelli para séries (termos não negativos),

$$\mathbb{E}Z = \sum_i z_i \mathbb{P}(A_i) = \sum_{i,j} z_i \mathbb{P}(C_{ij}) \leq \sum_{i,j} w_j \mathbb{P}(C_{ij}) = \sum_j w_j \mathbb{P}(B_j) = \mathbb{E}W.$$

(c) Como $0 \leq |Z| \leq W$, o item (b) dá $\mathbb{E}|Z| \leq \mathbb{E}W < \infty$, e o item (a) mostra que Z é integrável.

(d) Como $\mathbb{P}[X \neq Y] = 0$, $\mathbb{P}[X = t] = \mathbb{P}([X = t] \cap [X = Y]) = \mathbb{P}([Y = t] \cap [X = Y]) = \mathbb{P}[Y = t]$. A Definição 2.3 depende de X apenas por seus valores e essas probabilidades. $\square$

Teorema 2.1: Linearidade da esperança

Se X e Y são variáveis aleatórias integráveis e $a, b \in \mathbb{R}$, então $aX + bY$ é integrável e sua esperança satisfaz

$$\mathbb{E}(aX + bY) = a \mathbb{E}X + b \mathbb{E}Y.$$

Demonstração. Sejam S_X e S_Y conjuntos enumeráveis que contêm os valores de X e Y . Para $(x, y) \in S_X \times S_Y$, seja $D_{xy} = [X = x] \cap [Y = y]$. A família $\{D_{xy}\}$ é uma partição enumerável de Ω em eventos (possivelmente vazios) e, por aditividade enumerável,

$$\sum_{y \in S_Y} \mathbb{P}(D_{xy}) = \mathbb{P}[X = x], \quad \sum_{x \in S_X} \mathbb{P}(D_{xy}) = \mathbb{P}[Y = y]. \quad (2.9)$$

Em cada D_{xy} a variável $Z = aX + bY$ vale $ax + by$, ou seja,

$$Z = \sum_{x,y} (ax + by) \mathbf{1}_{D_{xy}}.$$

Em particular, Z é discreta (seus valores estão no conjunto enumerável $\{ax + by\}$). Os valores $ax + by$ podem se repetir, então esta não é a partição canônica de Z , e o Corolário 2.4 é o que permite usá-la.

Como $|ax + by| \leq |a||x| + |b||y|$, por Tonelli para séries e por (2.9),

$$\begin{aligned} \sum_{x,y} |ax + by| \mathbb{P}(D_{xy}) &\leq |a| \sum_x |x| \sum_y \mathbb{P}(D_{xy}) + |b| \sum_y |y| \sum_x \mathbb{P}(D_{xy}) \\ &= |a| \mathbb{E}|X| + |b| \mathbb{E}|Y| < \infty. \end{aligned}$$

Pelo Corolário 2.4(b), Z é integrável e $\mathbb{E}Z = \sum_{x,y} (ax + by) \mathbb{P}(D_{xy})$.

Pela estimativa acima, as famílias $\{x\mathbb{P}(D_{xy})\}$ e $\{y\mathbb{P}(D_{xy})\}$ são absolutamente somáveis (suas somas de módulos valem $\mathbb{E}|X|$ e $\mathbb{E}|Y|$). Portanto podemos separar a soma e, por Fubini para séries, somar primeiro em y (ou em x):

$$\begin{aligned}\mathbb{E}Z &= a \sum_x x \sum_y \mathbb{P}(D_{xy}) + b \sum_y y \sum_x \mathbb{P}(D_{xy}) \\ &= a \sum_x x \mathbb{P}[X = x] + b \sum_y y \mathbb{P}[Y = y] = a \mathbb{E}X + b \mathbb{E}Y,\end{aligned}$$

onde usamos (2.9). $\square$

Teorema 2.2: Monotonicidade da esperança

Se X e Y são integráveis tais que $X \leq Y$ então $\mathbb{E}X \leq \mathbb{E}Y$.

Demonstração. Se $X \leq Y$ então $Y - X \geq 0$, logo $\mathbb{E}(Y - X) \geq 0$. Da linearidade da esperança $\mathbb{E}Y - \mathbb{E}X \geq 0$ donde segue o teorema. $\square$

Corolário 2.5: Consequências da linearidade e monotonicidade

As seguintes propriedades decorrem dos teoremas acima.

1. Se $X = c$ então $\mathbb{E}X = c$, para qualquer $c \in \mathbb{R}$.
2. Se $\mathbb{E}X$ é integrável, então $\mathbb{E}(aX + b) = a\mathbb{E}X + b$.
3. Se $\mathbb{P}[a \leq X \leq b] = 1$, então X é integrável e $a \leq \mathbb{E}X \leq b$.
4. Se X é integrável então $X \cdot \mathbb{1}_A$ é integrável para todo evento A .
5. Se $\mathbb{E}X$ está definida então $|\mathbb{E}X| \leq \mathbb{E}|X|$.

Demonstração. Vamos demonstrar apenas os três últimos itens, os outros ficam para verificação do leitor.

3. Seja $E = [a \leq X \leq b]$, com $\mathbb{P}(E) = 1$, e $X' = X\mathbb{1}_E + a\mathbb{1}_{\bar{E}}$. Então $a \leq X' \leq b$ em todo ponto e $\mathbb{P}[X' = X] \geq \mathbb{P}(E) = 1$. Como $|X'| \leq \max\{|a|, |b|\}$, que é constante e portanto integrável, o Lema 2.1(c) mostra que X' é integrável, e o Teorema 2.2 (com as constantes a e b) dá $a \leq \mathbb{E}X' \leq b$. Pelo Lema 2.1(d), $\mathbb{E}X = \mathbb{E}X'$ (e X é integrável pois X e X' têm a mesma distribuição).

4. Temos $|X\mathbb{1}_A| = |X|\mathbb{1}_A \leq |X|$ e $|X|$ é integrável pelo Lema 2.1(a). O Lema 2.1(c) dá a integrabilidade de $X\mathbb{1}_A$.

5. Pelo Lema 2.1(a), $\mathbb{E}|X| = \mathbb{E}X^+ + \mathbb{E}X^-$. Se X não é integrável, como $\mathbb{E}X$ está definida, um entre $\mathbb{E}X^+$ e $\mathbb{E}X^-$ é infinito, logo $\mathbb{E}|X| = \infty \geq |\mathbb{E}X|$. Se X é integrável, $|X|$ também é, e de $-|X| \leq X \leq |X|$ o Teorema 2.2 dá $-\mathbb{E}|X| \leq \mathbb{E}X \leq \mathbb{E}|X|$, isto é, $|\mathbb{E}X| \leq \mathbb{E}|X|$. $\square$

O item 2 vale também quando $\mathbb{E}X = \pm\infty$ (com $a \neq 0$; para $a = 0$ é preciso a convenção $0 \cdot \infty = 0$), mas a prova exige um argumento separado com $\mathbb{E}X^\pm$, pois os teoremas acima são enunciados para variáveis integráveis. Para $a < 0$ os papéis de X^+ e X^- se trocam.

Proposição 2.6

Se X assume valores inteiros e não negativos, então $\mathbb{E}X$ está bem definida e

$$\mathbb{E}X = \sum_{n=0}^{\infty} \mathbb{P}[X > n].$$

Demonstração. Se X assume valores não negativos, $\mathbb{E}X = \mathbb{E}X^+ \in [0, \infty]$ e que $\mathbb{E}X$ está definida. Rearranjando os termos (Tonelli para séries), a esperança é

$$\begin{aligned} \sum_{t=0}^{\infty} t \mathbb{P}_X(t) &= \mathbb{P}_X(1) + \mathbb{P}_X(2) + \mathbb{P}_X(3) + \mathbb{P}_X(4) + \cdots \\ &\quad + \mathbb{P}_X(2) + \mathbb{P}_X(3) + \mathbb{P}_X(4) + \cdots \\ &\quad + \mathbb{P}_X(3) + \mathbb{P}_X(4) + \cdots \\ &\quad + \mathbb{P}_X(4) + \cdots \\ &\quad \vdots \\ &= \sum_{n=0}^{\infty} \sum_{t=n+1}^{\infty} \mathbb{P}_X(t). \end{aligned}$$

Por aditividade enumerável, como $[X > n] = \dot{\bigcup}_{t>n} [X = t]$, temos $\sum_{t>n} \mathbb{P}[X = t] = \mathbb{P}[X > n]$, o que conclui a prova. $\square$

Proposição 2.7: Condição de integrabilidade

Uma variável aleatória X é integrável se, e somente se,

$$\sum_{n=1}^{\infty} \mathbb{P}[|X| \geq n] < +\infty.$$

Demonstração. Seja $Y = |X| \geq 0$. Pelo Lema 2.1(a), X é integrável se, e somente se, $\mathbb{E}Y < \infty$. Como Y é discreta, $\lfloor Y \rfloor$ também é, com valores inteiros e não negativos, e $0 \leq \lfloor Y \rfloor \leq Y \leq \lfloor Y \rfloor + 1$.

Pelo Lema 2.1(b) (monotonicidade em $[0, \infty]$), $\mathbb{E}\lfloor Y \rfloor \leq \mathbb{E}Y \leq \mathbb{E}\lfloor Y \rfloor + 1$. Além disso, $\mathbb{E}\lfloor Y \rfloor + 1 = \mathbb{E}\lfloor Y \rfloor + 1$ em $[0, \infty]$: se $\lfloor Y \rfloor = \sum_i w_i \mathbb{1}_{A_i}$ é a representação canônica, o Corolário 2.4(a) e a separação de séries de termos não negativos dão $\mathbb{E}\lfloor Y \rfloor + 1 = \sum_i (w_i + 1) \mathbb{P}(A_i) = \mathbb{E}\lfloor Y \rfloor + \sum_i \mathbb{P}(A_i) = \mathbb{E}\lfloor Y \rfloor + 1$. Logo

$$\mathbb{E}\lfloor Y \rfloor \leq \mathbb{E}Y \leq \mathbb{E}\lfloor Y \rfloor + 1. \quad (2.10)$$

Para $n \in \mathbb{Z}$, como $\lfloor Y \rfloor$ é o maior inteiro $\leq Y$, temos $n \leq Y \iff n \leq \lfloor Y \rfloor$, isto é, $\lfloor Y \rfloor \geq n \iff \lfloor Y \rfloor > n-1$. Pela Proposição 2.6, e como $\lfloor Y \rfloor > n \iff \lfloor Y \rfloor \geq n+1$,

$$\mathbb{E} \lfloor Y \rfloor = \sum_{n \geq 0} \mathbb{P}[\lfloor Y \rfloor \geq n+1] = \sum_{n \geq 1} \mathbb{P}[\lfloor Y \rfloor \geq n] = \sum_{n \geq 1} \mathbb{P}[Y \geq n].$$

Substituindo em (2.10),

$$\sum_{n \geq 1} \mathbb{P}[|X| \geq n] \leq \mathbb{E}|X| \leq \sum_{n \geq 1} \mathbb{P}[|X| \geq n] + 1,$$

em $[0, \infty]$. Portanto $\mathbb{E}|X| < \infty$ se, e só se, $\sum_{n \geq 1} \mathbb{P}(|X| \geq n) < \infty$. $\square$

Teorema 2.3: Produto de variáveis aleatórias independentes

Sejam

$$X: \Omega \rightarrow S \quad \text{e} \quad Y: \Omega \rightarrow R$$

variáveis aleatórias discretas independentes (S e R enumeráveis) e sejam

$$f: S \rightarrow \mathbb{R} \quad \text{e} \quad g: R \rightarrow \mathbb{R}$$

funções tais que $f(X)$ e $g(Y)$ são integráveis. Então $f(X) \cdot g(Y)$ é integrável e

$$\mathbb{E}(f(X) \cdot g(Y)) = \mathbb{E}(f(X)) \mathbb{E}(g(Y)).$$

Demonstração. Seja $D_{xy} = [X = x] \cap [Y = y]$, partição enumerável de Ω em que $f(X)g(Y)$ vale $f(x)g(y)$. Pela independência, $\mathbb{P}(D_{xy}) = \mathbb{P}[X = x]\mathbb{P}[Y = y]$. Aplicando o Corolário 2.4(a) a $|f(X)g(Y)|$ e Tonelli para séries,

$$\begin{aligned} \mathbb{E}|f(X)g(Y)| &= \sum_{x,y} |f(x)||g(y)|\mathbb{P}[X = x]\mathbb{P}[Y = y] \\ &= \left(\sum_x |f(x)|\mathbb{P}[X = x] \right) \left(\sum_y |g(y)|\mathbb{P}[Y = y] \right) = \mathbb{E}|f(X)| \mathbb{E}|g(Y)| < \infty, \end{aligned}$$

onde a última igualdade usa o mesmo corolário na partição $[X = x]$ (em que $|f(X)|$ é constante), e analogamente para Y . Logo $f(X)g(Y)$ é integrável, o Corolário 2.4(b) dá

$$\mathbb{E}(f(X)g(Y)) = \sum_{x,y} f(x)g(y)\mathbb{P}[X = x]\mathbb{P}[Y = y]$$

e, como a família é absolutamente somável, Fubini para séries dá

$$\mathbb{E}f(X)g(Y) = \left(\sum_x f(x)\mathbb{P}[X = x] \right) \left(\sum_y g(y)\mathbb{P}[Y = y] \right) = \mathbb{E}(f(X)) \mathbb{E}(g(Y)).$$

$\square$

Corolário 2.6

Se X e Y são discretas independentes e integráveis, então XY é integrável e

$$\mathbb{E}(XY) = \mathbb{E}(X) \mathbb{E}(Y). \quad (2.11)$$

Demonstração. Tome f e g como a identidade no teorema. $\square$

Observação 4. O Teorema 2.2, da monotonicidade, ainda vale com as hipóteses de $\mathbb{E}X$ e $\mathbb{E}Y$ definidos. Basta, por exemplo, $\mathbb{E}X^- < \infty$ ou $\mathbb{E}Y^+ < \infty$ para que ambas estejam definidas.

Se X é integrável, $\mathbb{E}Y$ está definida e $a, b \in \mathbb{R}$, então $\mathbb{E}aX + bY$ está definida e $\mathbb{E}aX + bY = a\mathbb{E}X + b\mathbb{E}Y$ (com $0 \cdot \infty = 0$). Em geral, $aX + bY$ é integrável se, e só se, bY o é.

2.3.1 Esperança de funções de variáveis aleatórias

Seja $X: \Omega \rightarrow S$, com $S \subset \mathbb{R}$ enumerável. A lei de X é a medida de probabilidade $\mathbb{P}_X$ em $(S, 2^S)$ dada por $\mathbb{P}_X(A) = \mathbb{P}[X \in A]$. Em particular, $(S, \mathbb{P}_X)$ é um espaço de probabilidade discreto.

Toda $f: S \rightarrow \mathbb{R}$ é uma variável aleatória em $(S, \mathbb{P}_X)$, discreta pois $f(S)$ é enumerável. Sua lei é a medida imagem (*pushforward*) de $\mathbb{P}_X$ por f , classicamente denotado $\mathbb{P}_X \circ f^{-1}$:

$$(\mathbb{P}_X \circ f^{-1})(\{y\}) = \mathbb{P}_X[f = y] \quad \text{para } y \in f(S).$$

Por outro lado, $f(X)$ é variável aleatória em $(\Omega, \mathbb{P})$ e

$$\mathbb{P}[f(X) = y] = \mathbb{P}[X \in f^{-1}(y)] = \mathbb{P}_X(f^{-1}(y)) = (\mathbb{P}_X \circ f^{-1})(\{y\}).$$

Portanto, **f em $(S, \mathbb{P}_X)$ e $f(X)$ em $(\Omega, \mathbb{P})$ têm a mesma lei.** Como a esperança depende apenas da lei, $\mathbb{E}f(X)$ pode ser calculada em $(S, \mathbb{P}_X)$.

Proposição 2.8: Mudança de espaço

Para toda $f: S \rightarrow \mathbb{R}$, a esperança $\mathbb{E}_S[f]$ está definida se, e somente se, $\mathbb{E}_\Omega[f(X)]$ está, e nesse caso

$$\mathbb{E}_S[f] = \mathbb{E}_\Omega[f(X)].$$

Além disso, f é integrável em $(S, \mathbb{P}_X)$ se, e somente se, $f(X)$ é integrável em $(\Omega, \mathbb{P})$.

Demonstração. Se $g: S \rightarrow \mathbb{R}$ é qualquer função, o mesmo cálculo que mostra que f e $f(X)$ têm a mesma lei dá $\mathbb{P}_X[g = y] = \mathbb{P}[g(X) = y]$ para todo $y \in \mathbb{R}$, com ambos os lados nulos se $y \notin g(S)$. Logo,

as somas $\sum_y y^\pm \mathbb{P}_E(X)g = y$ e $\sum_y y^\pm \mathbb{P}[g(X) = y]$ têm os mesmos termos não nulos, e portanto

$$\mathbb{E}_S[g^\pm] = \mathbb{E}_\Omega(g(X))^\pm \quad \text{em } [0, \infty],$$

onde usamos $g^\pm(X) = (g(X))^\pm$. Tomando $g = f$, como “ $\mathbb{E}$ está definida” e o valor $\mathbb{E}f = \mathbb{E}f^+ - \mathbb{E}f^-$ dependem só desses dois números, seguem a equivalência e a igualdade. Tomando $g = |f|$, obtemos $\mathbb{E}_S[|f|] = \mathbb{E}_\Omega[|f(X)|]$, o que dá a equivalência de integrabilidade. $\square$

Teorema 2.4: Lei do Estatístico Inconsciente (LOTUS)

Seja $f: S \rightarrow \mathbb{R}$.

- (a) Se $f \geq 0$, então $\mathbb{E}f(X) = \sum_{s \in S} f(s) \mathbb{P}[X = s]$ em $[0, \infty]$.
- (b) Se $\mathbb{E}f(X)$ está definida, então a série $\sum_s f(s) \mathbb{P}[X = s]$ está definida e $\mathbb{E}f(X) = \sum_s f(s) \mathbb{P}[X = s]$. Se $f(X)$ é integrável, a série converge absolutamente.

Demonstração. (a) Seja $A_y = \{s \in S: f(s) = y\}$, $y \in f(S)$, a partição canônica de f em $(S, \mathbb{P}_X)$, que é um espaço de probabilidade, e a $\{\{s\}\}_{s \in S}$ a partição fina, com $\mathbb{P}_X(\{s\}) = \mathbb{P}[X = s]$. Pela Proposição 2.8 e pela definição de $\mathbb{E}$ em $(S, \mathbb{P}_X)$, $\mathbb{E}f(X) = \mathbb{E}_S f = \sum_y y \mathbb{P}_X(A_y)$. Como $f = \sum_s f(s) \mathbb{1}_{\{s\}}$ e todos os coeficientes são não negativos, o item (a) da Proposição 2.5, aplicada a $(S, \mathbb{P}_X)$, dá $\sum_y y \mathbb{P}_X(A_y) = \sum_s f(s) \mathbb{P}_X(\{s\})$.

(b) Aplique (a) a f^+ e f^- , usando $f^\pm(X) = (f(X))^\pm$: $\mathbb{E}((f(X))^\pm) = \sum_s f^\pm(s) \mathbb{P}[X = s]$. Como $\mathbb{E}f(X)$ está definida, não são ambas infinitas, e subtraindo obtém-se a igualdade. Se $f(X)$ é integrável, então $\mathbb{E}|f(X)| = \mathbb{E}(f(X))^+ + \mathbb{E}(f(X))^- < \infty$ (Lema 2.1(a)) e, por (a) aplicado a $|f|$, temos $\sum_s |f(s)| \mathbb{P}[X = s] < \infty$. $\square$

Observação 5. A Proposição 2.8 não exige integrabilidade: é uma igualdade de somas de termos não negativos. A LOTUS compara duas partições de S , a grossa $\{A_y\}$ e a fina $\{\{s\}\}$. A igualdade das duas somas é a independência da partição (Proposição 2.5), e a convergência absoluta dá o valor finito. Para $f \geq 0$, não é preciso hipótese alguma.

2.4 Variáveis contínuas, a Uniforme e simulação

Até aqui, toda variável aleatória X que consideramos era discreta, sua distribuição estava concentrada em um conjunto enumerável e $\mathbb{P}[X \in B] = \sum_{x \in B} \mathbb{P}[X = x]$. Isso não cobre situações básicas, como

O termo “Lei do Estatístico Inconsciente” foi cunhado por Sheldon Ross em seu famoso livro “A First Course in Probability” (1976). A piada interna da comunidade acadêmica é que mudar o parâmetro de x para $f(x)$ dentro do somatório ou da integral parece tão óbvio e natural que as pessoas fazem isso mecanicamente, como se fosse uma mera definição, quando na verdade trata-se de um teorema que exige demonstração.

“sortear um ponto ao acaso em $[0, 1]$ ”, em que cada valor individual deve ter probabilidade zero e, ainda assim, o valor sorteado existe. Além disso, “sortear um ponto ao acaso em $[0, 1]$ ” pode ser uma ferramenta para tratar casos discretos (em Acoplamento, por exemplo).

Seja X uma variável aleatória real com **distribuição acumulada** $F_X(x) = \mathbb{P}[X \leq x]$. Dizemos que X (ou sua distribuição) é **absolutamente contínua** se existe uma função contínua por partes¹ $f_X: \mathbb{R} \rightarrow [0, \infty)$ tal que

$$F_X(x) = \int_{-\infty}^x f_X(t) dt \quad \text{para todo } x \in \mathbb{R}. \quad (2.12)$$

A função f_X é chamada de **densidade**² de X .

Proposição 2.9

Seja X absolutamente contínua com densidade $f = f_X$. Então

(a) $\int_{-\infty}^{\infty} f(x) dx = 1;$

(b) $\mathbb{P}[X = x] = 0$ para todo $x \in \mathbb{R}$; em particular, F_X é contínua

$$\mathbb{P}[a < X < b] = \mathbb{P}[a \leq X \leq b] = \mathbb{P}[a < X \leq b] = \int_a^b f(x) dx$$

para quaisquer $a < b$;

(c) $F'_X(x) = f(x)$ em todo ponto x onde f é contínua.

Demonstração. Exercício. □

Como no caso discreto, esperanças se calculam integrando contra a distribuição; agora, contra a densidade. Se g é contínua por partes e $\int_{-\infty}^{\infty} |g(x)| dF_X(x) < \infty$, então

$$\mathbb{E}(g(X)) := \int_{-\infty}^{\infty} g(x) dF_X(x). \quad (2.13)$$

em que a integral é de Riemann–Stieltjes (imprópria). A definição vale para X discreta com g contínua. Quando X é absolutamente contínua com densidade f_X , vale $dF_X(x) = f_X(x) dx$, e portanto

$$\mathbb{E}(g(X)) = \int_{-\infty}^{\infty} g(x) f_X(x) dx. \quad (2.14)$$

Em particular, $\mathbb{E}(X) = \int x f_X(x) dx$.

2.4.1 A distribuição uniforme (contínua)

Sejam $a < b$. Dizemos que X tem distribuição **uniforme em $[a, b]$** , e escrevemos $X \sim U(a, b)$, se X é absolutamente contínua com densidade

$$f(x) = \frac{1}{b-a} \mathbb{1}_{[a,b]}(x)$$

¹ Uma função $f: \mathbb{R} \rightarrow \mathbb{R}$ é **contínua por partes** se, em cada intervalo limitado, ela é contínua exceto em um número finito de pontos, nos quais existem os limites laterais (finitos). De fato, basta ser Borel-mensurável.

² A densidade *não* é uma probabilidade, $f(x)$ pode ser maior que 1. Sua interpretação é local: para h pequeno, $\mathbb{P}[x < X \leq x+h] \approx f(x)h$. Além disso, como $\mathbb{P}[X = x] = 0$ para todo x , alterar o valor de f em um número finito de pontos não muda a distribuição de X .

e função de distribuição acumulada

$$F(x) = \begin{cases} 0, & x < a, \\ \frac{x-a}{b-a}, & a \leq x \leq b, \\ 1, & x > b. \end{cases}$$

Para $[c, d] \subseteq [a, b]$,

$$\mathbb{P}(c \leq X \leq d) = \frac{d-c}{b-a},$$

ou seja, a probabilidade de um intervalo é proporcional ao seu comprimento.

Se $X \sim U(a, b)$, então

$$\mathbb{E}X = \int_a^b \frac{x}{b-a} dx = \frac{a+b}{2}, \quad \mathbb{E}(X^2) = \int_a^b \frac{x^2}{b-a} dx = \frac{a^2 + ab + b^2}{3}.$$

A uniforme em $[0, 1]$ é o “*gerador básico de aleatoriedade*”, no sentido da proposição a seguir.

Proposição 2.10: Transformação integral da probabilidade

Seja F uma função de distribuição qualquer e defina

$$F^{-1}(u) := \inf\{x \in \mathbb{R} : F(x) \geq u\}$$

para $u \in (0, 1)$.

Se $U \sim U(0, 1)$, então $F^{-1}(U)$ tem função de distribuição F .

Demonstração. Pela continuidade à direita de F , vale $F^{-1}(u) \leq x$ se, e somente se, $u \leq F(x)$. Logo $\mathbb{P}[F^{-1}(U) \leq x] = \mathbb{P}[U \leq F(x)] = F(x)$. $\square$


Assim, qualquer distribuição pode ser simulada a partir de uma variável uniforme, o que será explorado nos algoritmos probabilísticos.

Exemplo 2.12: Simulação de uma Bernoulli

Seja $X \sim \text{Bernoulli}(p)$, de modo que

$$F_X(x) = \begin{cases} 0, & x < 0 \\ 1-p, & 0 \leq x < 1 \\ 1, & x \geq 1. \end{cases}$$

A função tem um salto de tamanho $1-p$ em $x = 0$ e de tamanho p em $x = 1$.



O cálculo de F_X^{-1} , via ínfimo, dá

$$F_X^{-1}(u) = \inf\{x: F_X(x) \geq u\} = \begin{cases} 0, & u \leq 1-p \\ 1, & u > 1-p \end{cases}$$

Dado $U \sim U(0,1)$, a v.a. $X' = F_X^{-1}(U) = \mathbb{1}_{[U > 1-p]}$ tem a mesma distribuição de X , pela proposição 2.10.

Note que $1-U \sim U(0,1)$ e que $\mathbb{P}[U \leq p] = p$, de modo que a variável $X' := \mathbb{1}_{[U \leq p]}$ também tem distribuição Bernoulli(p). Por isso, costuma-se escrever de forma simétrica que U nos dá

$$X' = \mathbb{1}_{[U \leq p]}$$

que é exatamente como qualquer implementação sorteia ω uniformemente, compara com p e gera uma Bernoulli:

```
if random() <= p:
    return 1
else:
    return 0
```

Por exemplo, para simular um dado justo, $X \in \{1, 2, 3, 4, 5, 6\}$ com distribuição uniforme (discreta).

função de distribuição F_X é

$$F_X(x) = \sum_{k=1}^6 \frac{1}{6} \mathbb{1}_{[k \leq x]} = \begin{cases} 0, & x < 1 \\ 1/6, & 1 \leq x < 2 \\ 2/6, & 2 \leq x < 3 \\ 3/6, & 3 \leq x < 4 \\ 4/6, & 4 \leq x < 5 \\ 5/6, & 5 \leq x < 6 \\ 1, & x \geq 6 \end{cases}$$

Ela é constante por partes, com saltos de tamanho $1/6$ em cada inteiro de 1 a 6. Não é bijetora, então não existe inversa de F_X no sentido clássico.




Figura 2.1: FDA de $X(\omega) = \omega$ no lançamento de um dado equilibrado.

Para $u \in (0, 1)$, $F_X^{-1}(u) = \inf\{x: F_X(x) \geq u\}$ é, por definição, o menor valor x cuja “escada” F_X já atingiu ou ultrapassou o nível u . Como F só cresce nos pontos $1, \dots, 6$, o resultado é sempre um desses inteiros (veja Figura 2.1):

$$F^{-1}(u) = k \quad \text{sempre que} \quad \frac{k-1}{6} < u \leq \frac{k}{6}, \quad k = 1, \dots, 6.$$

Dado $U \sim U(0, 1)$, devolva

$$X' = F_X^{-1}(U) = \lceil 6U \rceil,$$

que é, exatamente, k quando U cai no intervalo $\left(\frac{k-1}{6}, \frac{k}{6}\right]$. Pela proposição, X' tem função de distribuição F_X , ou seja, X' é um dado justo.

Exercícios

Exercício 5. Sejam $X = \sum_{k=1}^n x_k \mathbb{1}_{A_k}$ e $Y = \sum_{\ell=1}^m y_\ell \mathbb{1}_{B_\ell}$ duas variáveis aleatórias simples de $(\Omega, \mathbb{P})$. Verifique que valem as seguintes identidades

1. para quaisquer $a, b \in \mathbb{R}$

$$aX + bY = \sum_{k=1}^n \sum_{\ell=1}^m (ax_k + by_\ell) \mathbb{1}_{A_k \cap B_\ell};$$

- 2.

$$X \cdot Y = \sum_{k=1}^n \sum_{\ell=1}^m (x_k \cdot y_\ell) \mathbb{1}_{A_k \cap B_\ell}.$$

Exercício 6 (desigualdade de Jensen). Sejam X uma variável aleatória integrável, $I \subseteq \mathbb{R}$ um intervalo tal que $\mathbb{P}[X \in I] = 1$ e $f: I \rightarrow \mathbb{R}$ uma função convexa em I , então $\mathbb{E}(f(X))$ está definida e

$$\mathbb{E}(f(X)) \geq f(\mathbb{E}X). \quad (2.15)$$

$f: [a, b] \rightarrow \mathbb{R}$ é dita convexa se para quaisquer $x, y \in [a, b]$ e para todo $t \in [0, 1]$, tem-se que o segmento de reta que une x e y fica acima do gráfico de f entre x e y , isto é, $f(tx + (1-t)y) \leq tf(x) + (1-t)f(y)$

Exercício 7. Conclua do teorema acima que $\mathbb{E}|X| \geq |\mathbb{E}X|$ e que $\mathbb{E}(X^2) \geq (\mathbb{E}X)^2$.

Exercício 8. Mostre que se Z tem distribuição geométrica com parâmetro p então $\mathbb{P}[Z > n-1] = (1-p)^{n-1}$ para todo $n \geq 1$.

Exercício 9. Este exercício fornece uma maneira de derivar um algoritmo Las Vegas a partir de um algoritmo Monte Carlo.

Considere um algoritmo Monte Carlo A para um problema computacional Π cujo tempo de execução esperado é de no máximo $T(n)$ em qualquer instância de tamanho n e que produz uma solução correta com probabilidade $\gamma(n)$. Suponha ainda que, dada uma solução para Π , possamos verificar sua corretude no tempo $t(n)$. Mostre como obter um algoritmo Las Vegas que sempre fornece uma resposta correta para Π e roda em um tempo esperado de no máximo $(T(n) + t(n))/\gamma(n)$.

Exercício 10 (linearidade da esperança, o caso de séries). Prove que se $X_1, X_2, \dots$ são variáveis aleatórias sobre Ω enumerável e $\sum_{i \geq 1} \mathbb{E}|X_i|$ converge, então $\mathbb{E} \sum_{i \geq 1} X_i = \sum_{i \geq 1} \mathbb{E}X_i$.

Exercício 11. Verifique que a hipótese de convergência é necessária no Exercício 10. Para tal, considere o espaço de probabilidade $(\mathbb{N}, \mathbb{P})$ com $\mathbb{P}(n) = 2^{-n}$ e as variáveis aleatórias

$$X_n(j) := \begin{cases} 2^n, & \text{se } j = n, \\ -2^{n+1}, & \text{se } j = n+1, \\ 0, & \text{caso contrário.} \end{cases}$$

1. Mostre que $\mathbb{E}X_n = 0$ para todo $n \geq 1$.
2. Tome $X = \sum_{n \geq 1} X_n$. Determine $X(1), X(2), X(3), \dots$.
3. Usando o item anterior determine $\mathbb{E}X = \sum_{n \geq 1} X(n)\mathbb{P}(n)$.

Conclua que $\mathbb{E} \sum_n X_n \neq \sum_n \mathbb{E}X_n$.

Exercício 12. Considere uma moeda que resulta em cara com probabilidade $1/5$ e coroa com probabilidade $4/5$. Justifique que a probabilidade de sair menos que k coroas em $2k$ lançamentos (independentes) é

$$\sum_{i=0}^{k-1} \binom{2k}{i} (4/5)^i (1/5)^{2k-i} < (1/5)^{2k} 4^k \sum_{i=0}^{k-1} \binom{2k}{i}.$$

Prove que a probabilidade de sair menos que k coroas em $2k$ lançamentos dessa moeda é menor que $(4/5)^{2k}$ (dica: teorema do binômio de Newton para o somatório na equação acima).