

3

Quicksort probabilístico

O *quicksort* é um algoritmo recursivo de ordenação que, grosso modo, funciona da seguinte maneira: dada uma sequência S de números, dos quais o primeiro é chamado de *pivô*, o *quicksort*(S) compara o pivô com cada outro elemento de S e rearranja a sequência, os elementos menores que o pivô formam a subsequência S_E (alocados à esquerda do pivô no vetor) e os demais, que não o pivô, formam a subsequência S_D (alocados à direita do pivô no vetor); o algoritmo devolve a sequência (*quicksort*(S_E), pivô, *quicksort*(S_D)) ordenada recursivamente.

O *quicksort* foi inventado por Charles A. R. Hoare por volta de 1960 e sabemos que é muito rápido em geral, mas é lento em algumas raras instâncias. É um algoritmo que ordena os números em função dos resultados das comparações entre elementos da entrada e, nesse tipo de algoritmo, medimos a eficiência do algoritmo contando o número de comparações realizadas para ordenar a sequência. O algoritmo *quicksort* executa $O(n \ln n)$ comparações em média e $O(n^2)$ comparações no pior caso para ordenar sequências de tamanho n . A Figura 3.1 abaixo ilustra exemplos de melhor caso e de pior caso da árvore de recursão para uma sequência de tamanho 6.




Figura 3.1: em cima à direita temos uma árvore de recursão do *quicksort* onde o pivô é a mediana da sequência. A outra árvore, abaixo e à esquerda, é o caso onde o pivô é sempre o menor elemento da sequência.

É sabido que para garantir $O(n \ln n)$ comparações numa execução é suficiente garantir que as subsequências geradas no pivotamento tenham sempre uma fração aproximadamente constante do tamanho da sequência que as origina. Por exemplo, se S_E (ou S_D) sempre tem 10% do tamanho de S então o número de comparações executadas pelo *quicksort* numa instância de tamanho n , que denotamos $T(n)$, é o número de comparações executadas em S_E mais o número de comparações executadas em S_D mais as $O(n)$ comparações executadas no particionamento que cria essas subsequências

$$T(n) = T(0,1n) + T(0,9n) + O(n)$$

cuja solução é uma função em $O(n \ln n)$. Não há nada de especial na escolha de 10%. De fato, se uma proporção for mantida no particionamento, digamos que a menor parte tem uma fração α da entrada, então a recorrência $t(n) \leq t(\lfloor \alpha n \rfloor) + t(\lfloor (1 - \alpha)n \rfloor) + cn$ para constantes $\alpha, c > 0$ tem solução $O(n \ln n)$ (Cormen et al., 2009).

Na versão probabilística do *quicksort* a aleatoriedade é usada para descaracterizar o pior caso no sentido de que, sorteando o pivô como qualquer elemento da sequência, com grande chance evitamos os 10% menores e os 10% maiores elementos do vetor de modo que na maior parte do tempo os particionamentos garantem pelo menos uma fração constante da sequência original no menor lado.

Algoritmo 3.1: *Quicksort* aleatorizado.

Instância: uma sequência numérica $S = (x_1, x_2, \dots, x_n)$.

Resposta: os elementos de S em ordem crescente.

```

1 se  $|S| \leq 50$  então
2   ordene  $S$  na força bruta ;
3   responda a sequência ordenada.
4 senão  $z \xleftarrow{R} S$ ;
5 para cada  $y \in S, y \neq z$  faça
6   se  $y < z$  então insira  $y$  em  $S_E$ ;
7   senão insira  $y$  em  $S_D$ ;
8 ordene recursivamente a subsequência  $S_E$ ;
9 ordene recursivamente a subsequência  $S_D$ ;
10 responda  $(S_E, z, S_D)$ .
```

Sedgewick (1977) analisou matematicamente a sobrecarga das chamadas recursivas do *quicksort* em vetores muito pequenos. Ele provou que interromper a recursão para subsequências com tamanho $\leq n_0$ e aplicar o *insertion sort* reduz significativamente o tempo total de execução. Nos resultados originais da década de 1970, a constante ideal encontrada para n_0 situava-se na faixa de 10 a 25 elementos

(com 20 a 25 sendo o ponto ideal nos modelos computacionais analisados na época). Em arquiteturas modernas e linguagens atuais, esse limite costuma variar entre 10 e 15 devido ao comportamento de cache e otimizações de instrução do processador. Aqui, por conveniência, usamos 50.

Para simplificar a análise assumimos que na instância os elementos de S são distintos. Mostraremos que, com essa estratégia, o número de comparações entre elementos de S é $O(n \ln n)$ com alta probabilidade.

A análise desse algoritmo é um detalhamento da seguinte ideia: consideremos um elemento x de uma instância S para o algoritmo. Sejam $S_0 := S$ e $S_1, S_2, \dots, S_M$ as subsequências a que x pertence após cada particionamento durante uma execução. O i -ésimo particionamento é *bom* se o pivô não está entre os 10% menores nem entre os 10% maiores elementos de S_i , o que supomos, neste parágrafo, ocorrer com probabilidade exatamente $4/5$ e independente dos outros particionamentos, de modo que $|S_i|/10 \leq |S_{i+1}| \leq 9|S_i|/10$ e portanto x passa por no máximo $\log_{10/9}(n)$ particionamentos bons. Agora, a variável aleatória $M = M(x)$ não deve ser muito maior que $2 \log_{10/9}(n)$ pois pelo Exercício 12, página 55, a probabilidade de ocorrerem menos que $\log_{10/9}(n)$ particionamentos bons em $2 \log_{10/9}(n)$ particionamentos é menor que

$$\left(\frac{4}{5}\right)^{2 \log_{10/9}(n)} < \left(\frac{9}{10}\right)^{2 \log_{10/9}(n)} = \frac{1}{n^2}.$$

A cada particionamento o elemento não-pivô x é comparado uma única vez, com o pivô sorteado. Assim, o número total de comparações numa execução é a soma para todo x do número de particionamentos pelos quais x passa. Portanto, uma execução realiza mais que $2n \log_{10/9}(n)$ comparações somente se existe um x que passa por mais que $2 \log_{10/9}(n)$ particionamentos o que ocorre com probabilidade no máximo $n(1/n^2) = 1/n$. Portanto, com alta probabilidade, o *quicksort* realiza $O(n \ln n)$ comparações.

As ordenações “na força bruta” das subsequências disjuntas com até 50 elementos também fazem comparações, mas são $O(1)$ comparações em cada uma e isso soma $O(n)$, o que não altera o resultado.

3.1 Dominação estocástica

Em muitas análises de algoritmos probabilísticos a distribuição exata de uma variável aleatória é complicada, mas sabemos que ela é “pelo menos tão grande quanto” (ou “no máximo tão grande quanto”) uma variável cuja distribuição conhecemos bem. Por exemplo, no *quicksort* aleatorizado a probabilidade de um particionamento ser um sucesso

muda a cada passo, mas sabemos que ela nunca é menor que uma constante p . A *dominação estocástica* formaliza essa comparação.

Intuitivamente, a dominação estocástica captura a ideia de que uma variável “tende a assumir valores maiores” do que a outra. Para variáveis aleatórias reais, ela é definida em termos de probabilidades de cauda, ou equivalentemente em termos de funções de distribuição acumulada.

Definição 3.1: Dominação estocástica

Sejam X e Y variáveis aleatórias reais (não necessariamente definidas no mesmo espaço de probabilidade). Dizemos que X *domina estocasticamente* Y , e escrevemos $X \succeq Y$, se

$$\mathbb{P}[X > t] \geq \mathbb{P}[Y > t]$$

para todo $t \in \mathbb{R}$.

Observemos que a definição compara apenas as *distribuições*; nada é dito sobre a relação entre os valores de X e Y numa mesma realização do experimento. Na verdade, X e Y podem até ser independentes, e nesse caso pode ocorrer $X < Y$ com probabilidade positiva, mesmo com $X \succeq Y$.

Por exemplo, se $X \sim \text{Bernoulli}(p)$ e $Y \sim \text{Bernoulli}(q)$ com $p \geq q$. Para $t < 0$ as duas probabilidades $\mathbb{P}[X > t] = \mathbb{P}[Y > t]$ valem 1; para $0 \leq t < 1$ temos $\mathbb{P}[X > t] = p \geq q = \mathbb{P}[Y > t]$; para $t \geq 1$ ambas valem 0. Logo $X \succeq Y$.

Exemplo 3.1: Quando Poisson $\succeq$ Bernoulli

Seja X uma variável aleatória discreta representando a contagem de eventos e $\lambda \in (0, \infty)$.

Dizemos que X segue uma *distribuição de Poisson* com parâmetro de taxa λ , denotado por $X \sim \text{Poisson}(\lambda)$, se tem lei

$$\mathbb{P}_X(k) = \frac{\lambda^k e^{-\lambda}}{k!}, \quad k \in \{0, 1, \dots\}.$$

Sejam $X \sim \text{Poisson}(\lambda)$ e $Y \sim \text{Bernoulli}(p)$ ($p \in (0, 1)$).

- Para $t < 0$, $\mathbb{P}[X > t] = \mathbb{P}[Y > t] = 1$.
- Para $0 \leq t < 1$, $\mathbb{P}[X > t] = \mathbb{P}[X \geq 1] = 1 - e^{-\lambda}$ e $\mathbb{P}[Y > t] = p$.
- Para $t \geq 1$, $\mathbb{P}[X > t] \geq 0 = \mathbb{P}[Y > t]$.

Assim, $\mathbb{P}[X > t] \geq \mathbb{P}[Y > t]$ se e somente se

$$1 - e^{-\lambda} \geq p \Leftrightarrow \lambda \geq -\ln(1 - p)$$

logo, $X \succeq Y$ se, e somente se, $\lambda \geq \ln((1-p)^{-1})$.

Escrevemos $X \stackrel{d}{=} Y$ para denotar que

$$\mathbb{P}[X \leq t] = \mathbb{P}[Y \leq t]$$

para todo $t \in \mathbb{R}$, e dizemos que as variáveis aleatórias X e Y são *iguais em distribuição*.

Exemplo 3.2: Dominação entre geométricas

Sejam $0 < q \leq p < 1$. Se $Y \sim \text{Geom}(q)$ e $X \sim \text{Geom}(p)$, então $\mathbb{P}[Y > j] = (1-q)^j \geq (1-p)^j = \mathbb{P}[X > j]$. Portanto, $Y \succeq X$, ou seja, um sucesso mais provável chega mais cedo.

3.1.1 Acoplamento

Para comparar duas variáveis aleatórias, podemos colocá-las no mesmo experimento aleatório, de modo que possamos observar diretamente quando elas diferem. Um acoplamento cria uma dependência entre elas sem alterar suas distribuições individuais.

Suponha que $X \sim \text{Bernoulli}(p)$ e $Y \sim \text{Bernoulli}(q)$, com $p \geq q$. Podemos gerar (veja Exemplo 2.12) uma única variável $U \sim U[0, 1]$ e definir

$$X' := \mathbb{1}_{[U \leq p]}, \quad Y' := \mathbb{1}_{[U \leq q]}.$$

Assim, $X' \sim \text{Bernoulli}(p)$ e $Y' \sim \text{Bernoulli}(q)$ no mesmo espaço de probabilidade, como desejado. Ademais, temos algo interessante: $Y'(\omega) \leq X'(\omega)$ para todo ω , pois $[U \leq q] \subseteq [U \leq p]$. Em outras palavras, o par (Y', X') nunca assume o valor $(1, 0)$.

Note que $Y' \leq X'$ é uma propriedade do par construído, e não de X e Y (que podem ser, por exemplo, independentes). O que se conclui sobre X e Y é que, para toda função h não decrescente, $\mathbb{E}(h(Y)) \leq \mathbb{E}(h(X))$, pois esses valores *dependem apenas das distribuições* de X e Y .

A caracterização a seguir é a que mais usamos na prática: dominação estocástica equivale a poder construir, num mesmo espaço de probabilidade, variáveis X' e Y' com as mesmas distribuições de X e Y , respectivamente, tais que $Y' \leq X'$ com probabilidade 1.¹ Construir duas variáveis com distribuições dadas num mesmo espaço de probabilidade é chamado de *acoplamento*.

¹ Se $Y' \leq X'$ vale fora de um conjunto N com $\mathbb{P}(N) = 0$, defina $X'' := X' \mathbb{1}_{\bar{N}}$ e $Y'' := Y' \mathbb{1}_{\bar{N}}$, isto é, ambas valem 0 em N . Como N tem probabilidade zero, X'' e Y'' têm as mesmas distribuições de X' e Y' , e agora $Y'' \leq X''$ vale para todo ω : em N por serem ambas nulas, e fora de N porque nada mudou. Assim, exigir $Y' \leq X'$ com probabilidade 1 ou para todo ω dá o mesmo resultado.

Teorema 3.1: teorema de Strassen para ordem estocástica na reta

Para variáveis aleatórias reais X e Y , vale $X \succeq Y$ se, e somente se, existem variáveis aleatórias $X' \stackrel{d}{=} X$ e $Y' \stackrel{d}{=} Y$ definidas num mesmo espaço de probabilidade tais que $Y' \leq X'$ com probabilidade 1.

Demonstração. ($\Rightarrow$) Sejam $F_X(t) = \mathbb{P}[X \leq t]$ e $F_Y(t) = \mathbb{P}[Y \leq t]$ as funções de distribuição de X e Y . Para uma função de distribuição F qualquer e $u \in (0,1)$, seja

$$F^{-1}(u) := \inf\{t: F(t) \geq u\}$$

a função quantil (finita para $u \in (0,1)$).

Se $U \sim U(0,1)$, então $F^{-1}(U)$ tem função de distribuição F , pela Proposição 2.10.

Da hipótese $X \succeq Y$ temos $F_X(t) \leq F_Y(t)$ para todo t . Assim, se $F_X(t) \geq u$ então $F_Y(t) \geq u$, isto é, $\{t: F_X(t) \geq u\} \subseteq \{t: F_Y(t) \geq u\}$, e o ínfimo do conjunto menor é o maior: $F_X^{-1}(u) \geq F_Y^{-1}(u)$ para todo $u \in (0,1)$. Tomando $X' = F_X^{-1}(U)$ e $Y' = F_Y^{-1}(U)$, com o mesmo U , temos $X' \stackrel{d}{=} X$, $Y' \stackrel{d}{=} Y$ e $Y' \leq X'$ sempre que $U \in (0,1)$, isto é, com probabilidade 1.

($\Leftarrow$) Se $Y' \leq X'$ com probabilidade 1, então, para todo t , o evento $[Y' > t]$ está contido em $[X' > t]$ a menos de um conjunto de probabilidade zero, logo

$$\mathbb{P}[Y > t] = \mathbb{P}[Y' > t] \leq \mathbb{P}[X' > t] = \mathbb{P}[X > t].$$

Portanto $\mathbb{P}[X > t] \geq \mathbb{P}[Y > t]$ para todo t , isto é, $X \succeq Y$. $\square$

Corolário 3.1

Se $X \succeq Y$, então $\mathbb{E}Y \leq \mathbb{E}X$ (quando as esperanças existem) e, mais geralmente, $\mathbb{E}f(Y) \leq \mathbb{E}f(X)$ para toda função f não decrescente. Além disso, $\mathbb{P}[X \leq k] \leq \mathbb{P}[Y \leq k]$ para todo k .

Demonstração. Tome o acoplamento $Y' \leq X'$. Como f é não decrescente, $f(Y') \leq f(X')$ e a monotonicidade da esperança dá o resultado. A última afirmação é o complementar da definição. $\square$

O corolário é o que justifica, nas análises, passar de uma variável complicada para uma variável simples. Basta que a simples esteja do lado correto da desigualdade.

Exemplo 3.3: Dominação entre Binomiais

Se $X \sim \text{Binomial}(m, p)$ e $Y \sim \text{Binomial}(m, q)$ com $1 \geq p \geq q \geq 0$, então $X \succeq Y$.

Sejam $U_1, \dots, U_m$ independentes e uniformes em $[0, 1]$ e defina

$$B_i = 1_{[U_i \leq p]} \quad \text{e} \quad C_i = 1_{[U_i \leq q]}, \quad i = 1, \dots, m.$$

Como as U_i são independentes, $B_1, \dots, B_m$ são independentes com distribuição Bernoulli(p), e $C_1, \dots, C_m$ são independentes com distribuição Bernoulli(q). Portanto

$$X' := \sum_{i=1}^m B_i \sim \text{Binomial}(m, p) \quad \text{e} \quad Y' := \sum_{i=1}^m C_i \sim \text{Binomial}(m, q),$$

isto é, $X' \stackrel{d}{=} X$ e $Y' \stackrel{d}{=} Y$. (Note que B_i e C_i não são independentes, pois usam o mesmo U_i ; isso é o que se deseja e não afeta as distribuições de X' e Y' .)

Como $q \leq p$, vale $[U_i \leq q] \subseteq [U_i \leq p]$, logo $C_i \leq B_i$ para todo i e todo ω . Somando, $Y' \leq X'$. Pelo Teorema, $X \succeq Y$.

3.1.2 Dominação estocástica na análise do QS

Como dito acima, a ideia é estimar quão longa é a cadeia de subsequências $S, S'_1, S'_2, \dots, S'_M$ obtidas por particionamento e que contêm um elemento fixo, mas arbitrário x . Se cada particionamento fosse um sucesso com probabilidade p fixa, independentemente do histórico de particionamentos, então estaríamos no caso de estimar quantos particionamentos até ocorrer um sucesso, que sabemos se tratar de uma variável geométrica de média $1/p$. Como o número de sucessos é limitado, digamos que por ℓ , então queremos estimar o número de particionamentos até ocorrer o $(\ell + 1)$ -ésimo sucesso em uma sequência de experimentos independentes de Bernoulli com parâmetro p , uma binomial negativa de parâmetros $\ell + 1, p$ (cf. 2.11).

Entretanto, assumindo que sucesso resulta em não escolher o pivô entre os 10% menores nem entre os 10% maiores, se a subsequência tem 100 elementos, então a probabilidade de sucesso é 0,8, mas se a subsequência tem 51 elementos, então a probabilidade de sucesso é $(\lfloor 0,9 \cdot 51 \rfloor - \lceil 0,1 \cdot 51 \rceil) / 51 \approx 0,765$ devido aos arredondamentos. As tentativas *não* são independentes, e a probabilidade de sucesso de cada uma depende do que aconteceu antes. O que sabemos é apenas que, dado qualquer histórico, a probabilidade de sucesso é *pelo menos* uma constante $\alpha \in (0, 1)$.

Lema 3.1

Sejam $Z_1, Z_2, \dots$ variáveis com valores em $\{0, 1\}$ tais que, para todo i e todo histórico $(z_1, \dots, z_{i-1})$ de probabilidade positiva,

$$\mathbb{P}[Z_i = 1 \mid Z_1 = z_1, \dots, Z_{i-1} = z_{i-1}] \geq \alpha.$$

Então

- (a) o número de sucessos em m tentativas, $\sum_{i=1}^m Z_i$, domina estocasticamente uma $\text{Binomial}(m, \alpha)$;
- (b) o número de tentativas até o r -ésimo sucesso é dominado estocasticamente por uma binomial negativa de parâmetros (r, α) . Em particular, o número esperado de tentativas até o r -ésimo sucesso é no máximo r/α .

Demonstração. Para todo $i \geq 1$ tome

$$U_i \sim U(0, 1), \quad Y_i = \mathbb{1}_{[U_i \leq \alpha]}, \quad Z_i = \mathbb{1}_{[U_i \leq p_i]}$$

em que $U_1, U_2, \dots$ são independentes e $p_i \geq \alpha$ é a probabilidade condicional de sucesso na i -ésima tentativa dado o histórico $Z_1, \dots, Z_{i-1}$.

Como U_i é independente de $U_1, \dots, U_{i-1}$ e p_i é função dessas variáveis, $\mathbb{P}[Z_i = 1 \mid U_1, \dots, U_{i-1}] = p_i$; assim, por indução, $(Z_i)_i$ tem a distribuição conjunta exigida. Além disso, $Y_i \sim \text{Bernoulli}(\alpha)$ e $Y_1, Y_2, \dots$ são independentes, pois cada Y_i é função só de U_i .

Como $\alpha \leq p_i$, vale a inclusão de eventos $[U_i \leq \alpha] \subseteq [U_i \leq p_i]$, isto é, $Y_i = 1 \Rightarrow Z_i = 1$. Logo $Y_i \leq Z_i$ com probabilidade 1 (não apenas em distribuição)².

(a) Da desigualdade pontual acima,

$$\sum_{i=1}^m Z_i \geq \sum_{i=1}^m Y_i.$$

Ademais, as Y_i são independentes com $\mathbb{P}[Y_i = 1] = \alpha$, de modo que $\sum_{i=1}^m Y_i \sim \text{Binomial}(m, \alpha)$.

(b) Seja τ_Z (resp. τ_Y) o instante do r -ésimo sucesso da sequência $(Z_i)_i$ (resp. $(Y_i)_i$). Como $Y_i \leq Z_i$ para todo i , todo sucesso de $(Y_i)_i$ é também sucesso de $(Z_i)_i$, logo o r -ésimo sucesso em $(Z_i)_i$ ocorre no máximo no instante do r -ésimo sucesso em $(Y_i)_i$. Portanto $\tau_Z \leq \tau_Y$. Como τ_Y é a soma de r geométricas independentes de parâmetro α , $\mathbb{E}\tau_Z \leq \mathbb{E}\tau_Y = r/\alpha$. $\square$

² é o mesmo U_i usado nas duas variáveis que torna essa comparação possível.

Fixado um elemento x , os particionamentos de que ele participa formam uma sequência de tentativas cuja probabilidade de sucesso depende do tamanho corrente da subseqüência de x , e portanto do

passado. Dado qualquer histórico, essa probabilidade é pelo menos α (com α a constante da análise). O lema acima permite, então, trocar essa sequência por tentativas independentes de parâmetro α : o número de particionamentos até o $(\ell + 1)$ -ésimo sucesso tem esperança no máximo $(\ell + 1)/\alpha$. Disso podemos deduzir o número esperado de comparações pelas quais passa x sem precisar da distribuição exata do número de particionamentos.

3.2 Análise do quicksort probabilístico

O particionamento (ou pivotamento) de S nas linhas 4, 5, 6 e 7 do algoritmo acima é considerado um *sucesso* se $\min\{|S_E|, |S_D|\} \geq (1/10)|S|$, caso contrário, dizemos que o particionamento foi um fracasso. Um sucesso significa que o pivô não está entre os 10% maiores elementos da sequência particionada e nem está entre os 10% menores elementos da sequência particionada.

Para pivô de posto³ r temos $|S_E| = r - 1$ e $|S_D| = |S| - r$. O número de postos para bons pivôs é, então, $\lfloor 0,9 |S| \rfloor - \lceil 0,1 |S| \rceil$. Como $\lfloor 0,9 |S| \rfloor > 0,9 |S| - 1$ e $\lceil 0,1 |S| \rceil < 0,1 |S| + 1$, o número de pivôs bons é maior que $0,8 |S| - 2$, portanto, $p > 0,8 - 2/|S| \geq 0,76$ para $|S| > 50$. Por outro lado, $\lfloor 0,9 |S| \rfloor - \lceil 0,1 |S| \rceil \leq 0,8 |S|$, portanto

$$0,76 < p \leq 0,8.$$

³ *posto* é a posição do elemento na sequência ordenada.

Consideremos uma execução do *quicksort* com entrada $S = (x_1, x_2, \dots, x_n)$. Fixado $i \in \{1, 2, \dots, n\}$, seja X_i o número de comparações entre o elemento x_i da entrada e algum pivô durante toda uma execução do algoritmo. Em cada particionamento x_i é comparado uma única vez (com o pivô) e se x_i é escolhido pivô então: (1) cada elemento da subsequência da qual x_i pertence é comparado com ele e tais comparações são contabilizadas pelos outros elementos e (2) a partir daí x_i nunca mais participará de um particionamento e nunca mais será comparado com outro elemento de S .

Exercício 13. Mostre que x_i participa de no máximo $\lfloor \log_{10/9} n \rfloor$ particionamentos com sucesso.

Fixemos x_i e escrevamos $\ell := \lfloor \log_{10/9} n \rfloor$. O tamanho da subsequência que contém x_i muda a cada particionamento, e com ele a probabilidade de sucesso. Seja s_k o tamanho da subsequência que contém x_i imediatamente antes do k -ésimo particionamento.

Lembremos que toda subsequência com no máximo 50 elementos é ordenada por força bruta; assim, enquanto x_i participa de particionamentos, a subsequência que o contém tem mais de 50 elementos.

Suponha conhecido tudo o que aconteceu nos $k - 1$ primeiros par-

ticionamentos de x_i (tamanhos das subsequências e pivôs sorteados). Isso determina s_k . Dado s_k , o pivô é escolhido uniformemente entre os s_k postos, e portanto a probabilidade de o k -ésimo particionamento ser um sucesso depende apenas de s_k . Como $s_k > 50$ (pois o k -ésimo particionamento é real), ela é maior que 0,76.

O Lema 3.1, porém, pede essa cota sabendo apenas quais dos $k - 1$ primeiros particionamentos foram sucessos ou fracassos, o que é menos informação. Ela continua valendo: vários históricos completos são compatíveis com a mesma sequência de sucessos e fracassos, e a probabilidade de sucesso no k -ésimo particionamento, sabendo só essa sequência, é uma média ponderada das probabilidades correspondentes a esses históricos. Como todas são maiores que 0,76, a média também é.

Para que a análise não dependa do instante em que x_i deixa de participar de particionamentos (por ter sido escolhido pivô ou por ter caído no caso base), imaginamos que, a partir daí, x_i continua participando de particionamentos *fictícios*, cada um deles com sucesso com probabilidade 0,76 *independentemente* do passado. Assim, para cada x_i está definida uma sequência infinita de particionamentos (os reais, seguidos dos fictícios), cada um com probabilidade condicional de sucesso pelo menos 0,76 dados os resultados (sucesso ou fracasso) dos particionamentos anteriores (que é exatamente a hipótese do Lema 3.1).

Seja M_i o número de particionamentos reais de que x_i participa, e seja τ_i o instante do $(\ell + 1)$ -ésimo sucesso na sequência completada.

Pelo Exercício, os M_i primeiros particionamentos da sequência completada, que são os reais, contêm no máximo ℓ sucessos. Logo o $(\ell + 1)$ -ésimo sucesso, no instante τ_i , não está entre eles, assim $\tau_i > M_i$.

Pelo Lema 3.1(b), com $\alpha = 0,76$ e $r = \ell + 1$,

$$\mathbb{E}\tau_i \leq \frac{\ell + 1}{0,76} < \frac{10}{7}(\ell + 1) \leq 2\ell,$$

onde a última desigualdade vale porque $\ell \geq 37 \geq 3$ para $n > 50$.

Em cada particionamento de que participa sem ser o pivô, x_i é comparado uma única vez com o pivô; portanto o número X_i de comparações de x_i com pivôs satisfaz $X_i \leq M_i \leq \tau_i$. Pela monotonicidade da esperança,

$$\mathbb{E}X_i \leq \mathbb{E}\tau_i < 2\ell.$$

O número total de comparações com pivôs durante toda a execução é $T := \sum_{i=1}^n X_i$ e, pela linearidade da esperança, $\mathbb{E}T < 2n\ell$. Em resumo,

$$\mathbb{E}X_i < 2\lceil \log_{\frac{10}{9}} n \rceil \quad \text{e} \quad \mathbb{E}T < 2n\lceil \log_{\frac{10}{9}} n \rceil. \quad (3.1)$$

Além disso, as subsequências disjuntas ordenadas na força-bruta na linha 2 fazem, cada uma, $O(1)$ comparações, contribuindo no total

com $O(n)$ comparações que, somadas às $O(n \ln n)$ de (3.1), totalizam $O(n \ln n)$ comparações.

Lema 3.2: O número esperado de comparações do QS

O número esperado de comparações entre elementos de uma sequência com n elementos numa execução do *quicksort* aleatorizado é $O(n \ln n)$. $\square$

Da disciplina Análise de Algoritmos sabemos que todo algoritmo de ordenação baseado em comparação realiza $\Omega(n \ln n)$ comparações para ordenar n elementos, ou seja, em esperança o *quicksort* aleatorizado é o melhor possível (Cormen et al., 2009). Porém, saber que um algoritmo é bom em média não nos garante que ele é bom quase sempre. Vamos mostrar que com alta probabilidade o desempenho do algoritmo está próximo da média.

Teorema 3.2

O número de comparações numa execução do *quicksort* aleatorizado com uma entrada de tamanho n é $O(n \ln n)$ com probabilidade $1 - O(n^{-33})$.

Demonstração. Definimos

$$\begin{aligned}\ell &:= \lfloor \log_{10/9} n \rfloor \\ L &:= 12 \lfloor \log_{10/9} n \rfloor = 12\ell \\ F &:= L - \ell = 11\ell.\end{aligned}$$

Consideramos o evento $[X_i > L]$ que, segundo (3.1), diz que o elemento x_i foi comparado a um pivô mais do que seis vezes o valor esperado.

Como $X_i \leq M_i$, o evento $[X_i > L]$ implica que x_i participa de mais que L particionamentos reais (não fictícios); em particular, os primeiros L particionamentos de sua sequência completa são todos reais. Pelo Exercício 13, x_i tem no máximo ℓ sucessos reais ao longo de toda a execução, logo, nesse evento, há no máximo ℓ sucessos entre os primeiros L particionamentos da sequência completada.

Tomemos $Z_k^{(i)}$ o indicador de sucesso do k -ésimo particionamento de x_i e W_i o número de sucessos entre esses L particionamentos, isto é, $W_i = \sum_{k \leq L} Z_k^{(i)}$. Então

$$[X_i > L] \subseteq [W_i \leq \ell].$$

Pelo Lema 3.1(a), com $\alpha = 0,76$ e $m = L$ tentativas, W_i domina

estocasticamente uma Binomial($L, 0,76$), portanto

$$\begin{aligned}\mathbb{P}[X_i > L] &\leq \mathbb{P}[W_i \leq \ell] \leq \mathbb{P}[\text{Binomial}(L, 0,76) \leq \ell] \\ &= \sum_{j=F}^L \binom{L}{j} (0,24)^j (0,76)^{L-j}.\end{aligned}$$

Usando o limitante usual para o coeficiente binomial (veja (d.2)), para $j \geq F$,

$$\binom{L}{j} (0,24)^j (0,76)^{L-j} \leq \left(\frac{eL}{j} \cdot \frac{0,24}{0,76} \right)^j (0,76)^L \leq \left(\frac{eL}{F} \cdot \frac{0,24}{0,76} \right)^j (0,76)^L.$$

Como $L/F = 12/11$ e $0,24/0,76 = 6/19$,

$$e \cdot \frac{L}{F} \cdot \frac{0,24}{0,76} = e \cdot \frac{12}{11} \cdot \frac{6}{19} = \frac{72e}{209} < 0,9365 < 1.$$

Logo, para $c = \frac{72e}{209}$

$$\begin{aligned}\mathbb{P}[X_i > L] &\leq (0,76)^L \sum_{j \geq F} c^j = (0,76)^L \frac{c^F}{1-c} \\ &= \frac{209}{209-72e} (0,76)^{12\ell} c^{11\ell} < 16 \left((0,76)^{12} c^{11} \right)^\ell\end{aligned}$$

portanto, $\mathbb{P}[X_i > L] < 16 (0,019)^\ell$.

Convertendo para potência de n , com $\ell > \log_{10/9}(n) - 1$,

$$(0,019)^\ell < (0,019)^{-1} (0,019)^{\log_{10/9}(n)} < 53n^{\log_{10/9}(0,019)} < 53n^{-37},$$

portanto $\text{Prob}EX_i > L < 848 n^{-37} < n^{-34}$.

A probabilidade de existir i com $X_i > L$ é

$$\mathbb{P}\left(\bigcup_{i=1}^n [X_i > L]\right) < n \cdot n^{-34} = n^{-33},$$

logo, com probabilidade $1 - O(n^{-33})$, vale $X_i \leq 12 \lfloor \log_{10/9} n \rfloor$

para todo i , e nessa probabilidade o *quicksort* aleatorizado executa $O(n \ln n)$ comparações, incluídas as $O(n)$ comparações “força bruta” feitas na linha 2 do algoritmo. $\square$

3.3 Esperança condicional

Sejam $(\Omega, \mathbb{P})$ um espaço de probabilidade discreto, A um evento desse espaço com probabilidade positiva e X uma variável aleatória real e integrável (ou apenas não negativa). A ocorrência de A implica uma nova medida $\mathbb{P}_A$ em Ω e temos uma nova lei, condicionada a A ,

para a variável X . A **esperança condicional** da variável X dado A é o valor médio de X com respeito à lei condicional

$$\mathbb{E}(X | A) = \sum_r r \mathbb{P}[X = r | A] = \sum_r r \mathbb{P}_A[X = r] = \sum_r r \mathbb{P}_{X|A}(r). \quad (3.2)$$

Por ser uma média de uma variável aleatória com respeito a uma distribuição, a esperança condicional usufrui das mesmas propriedades da esperança: se X e Y são integráveis, A um evento de probabilidade positiva, B um evento qualquer e $a, b \in \mathbb{R}$, então

1. $\mathbb{E}(c | A) = c$.
2. $\mathbb{E}(\mathbb{1}_B | A) = \mathbb{P}(B | A)$.
3. Se $X \leq Y$ então $\mathbb{E}(X | A) \leq \mathbb{E}(Y | A)$.
4. $\mathbb{E}(aX + bY | A) = a\mathbb{E}(X | A) + b\mathbb{E}(Y | A)$.
5. Se X e A são independentes então $\mathbb{E}(X | A) = \mathbb{E}X$. Ademais, $\mathbb{E}(XY | A) = \mathbb{E}(X | A) \cdot \mathbb{E}(Y | A)$ nem sempre decorre da independência global de X e Y , mas vale caso X e Y são independentes sob a distribuição condicionada⁴ a A .

⁴ $\mathbb{P}_A([X = x] \cap [Y = y]) = \mathbb{P}_A[X = x] \mathbb{P}_A[Y = y]$ para todos x, y

Sobre o último item acima, considere X e Y independentes, cada um com distribuição Bernoulli(1/2). A distribuição conjunta é uniforme sobre os 4 pares possíveis

$$\mathbb{P}[(X, Y) = (x, y)] = \frac{1}{4}, \quad (\forall x, y \in \{0, 1\}).$$

Agora defina o evento $A := \{X = Y\}$, ou seja, A ocorre quando X e Y são iguais. Temos

$$\mathbb{P}(A) = \mathbb{P}(\{(0, 0), (1, 1)\}) = \frac{1}{2}$$

logo $\mathbb{E}(X | A) = 1/2$, $\mathbb{E}(Y | A) = 1/2$ e $\mathbb{E}(XY | A) = 1/2$. Nesse caso, globalmente, X e Y são independentes mas, ao condicionar em A eles se tornam dependentes. Isso mostra que a fatoração $\mathbb{E}(XY | A) = \mathbb{E}(X | A) \cdot \mathbb{E}(Y | A)$ não vale em geral, apesar de X e Y serem independentes globalmente, $1/2 \neq 1/4$ e o item 5 exige independência sob a lei condicionada a A (que aqui falha, já que A força $X = Y$).

Exemplo 3.4: Esperança da distribuição geométrica

Seja X o número de tentativas de Bernoulli até o primeiro sucesso, com probabilidade de sucesso p . Condicionando no primeiro resultado, seja A o evento “sucesso”,

- A ocorre na primeira tentativa, então $X = 1$;
- $\bar{A}$ ocorre na primeira tentativa, nesse caso, já gastamos 1 tentativa, então $X = 1 + Y$, com $Y \sim \text{Geom}(p)$ (o processo recomeça do zero). Portanto,

Assim,

$$\begin{aligned}
 \mathbb{E}(X) &= \sum_x x \mathbb{P}[X = x] \\
 &= \sum_x x (\mathbb{P}[X = x \mid A] \mathbb{P}(A) + \mathbb{P}[X = x \mid \bar{A}] \mathbb{P}(\bar{A})) \\
 &= \left(\sum_x x \mathbb{P}_A[X = x] \right) \mathbb{P}(A) + \left(\sum_x x \mathbb{P}_{\bar{A}}[X = x] \right) \mathbb{P}(\bar{A}) \\
 &= \mathbb{E}(X \mid A) \mathbb{P}(A) + \mathbb{E}(X \mid \bar{A}) \mathbb{P}(\bar{A})
 \end{aligned}$$

Agora, $\mathbb{E}(X \mid A) = 1$ e $\mathbb{E}(X \mid \bar{A}) = \mathbb{E}(Y) + 1 = \mathbb{E}(X) + 1$, portanto $\mathbb{E}(X) = 1 \cdot p + (\mathbb{E}(X) + 1)(1 - p)$ e resolvendo para $\mathbb{E}X$

$$\mathbb{E}(X) = \frac{1}{p}.$$

Teorema 3.3: Lei de esperança total

Se Y é uma variável aleatória integrável, então

$$\mathbb{E}Y = \sum_{x \in S_X} \mathbb{E}(Y \mid X = x) \mathbb{P}[X = x]. \quad (3.3)$$

Demonstração. Seja Y uma variável aleatória integrável. Então,

$$\begin{aligned}
 \mathbb{E}Y &= \sum_{y \in S_Y} y \mathbb{P}[Y = y] \\
 &= \sum_{y \in S_Y} y \left(\sum_{x \in S_X} \mathbb{P}([Y = y] \cap [X = x]) \right) \\
 &= \sum_{y \in S_Y} \sum_{x \in S_X} y \mathbb{P}[Y = y \mid X = x] \mathbb{P}[X = x] \\
 &= \sum_{x \in S_X} \sum_{y \in S_Y} y \mathbb{P}[Y = y \mid X = x] \mathbb{P}[X = x] \\
 &= \sum_{x \in S_X} \mathbb{E}(Y \mid X = x) \mathbb{P}[X = x]
 \end{aligned}$$

em que a troca das ordens de soma é pelo teorema de Tonelli–Fubini para séries (s.5). $\square$

3.4 Desigualdade de Markov

A **desigualdade de Markov** tem um enunciado simples e a vantagem de valer em situações bem gerais, sem muitas hipóteses sobre a variável aleatória, o que a torna amplamente aplicável. Por outro lado, ela pode fornecer limitantes fracos que, às vezes, são pouco úteis.

Andrey Markov (1856–1922) foi um matemático russo conhecido principalmente por suas contribuições no que foi posteriormente conhecido como Cadeias de Markov. Seu filho Andrey Markov Jr (1903–1979) ficou conhecido pelas contribuições em Teoria da Computação.

Teorema 3.4: Desigualdade de Markov

Se X é uma variável aleatória integrável,

$$\mathbb{P}[|X| \geq t] \leq \frac{\mathbb{E}|X|}{t} \quad (3.4)$$

para todo $t > 0$. Em particular, se X assume valores não negativos,

$$\mathbb{P}[X \geq t] \leq \frac{\mathbb{E}X}{t} \quad (3.5)$$

para todo $t > 0$.

Demonstração. De X integrável $|X|$ também é integrável. Ademais, $|X| \geq |X| \cdot \mathbb{1}_{|X| \geq t}$, para todo $t > 0$, logo a desigualdade de Markov segue da monotonicidade da esperança

$$\begin{aligned} \mathbb{E}(|X|) &\geq \mathbb{E}(|X| \mathbb{1}_{|X| \geq t}) \geq \mathbb{E}(t \mathbb{1}_{|X| \geq t}) = \\ &= t \mathbb{E}(\mathbb{1}_{|X| \geq t}) = t \mathbb{P}[|X| \geq t]. \quad \square \end{aligned}$$

Há casos onde essa desigualdade é justa, como mostra o seguinte exemplo. Seja X uma variável aleatória que assume o valor 0 com probabilidade 99/100 e assume o valor 10 com probabilidade 1/100. Então $\mathbb{E}X = 1/10$ e

$$\mathbb{P}[X \geq 10] \leq \frac{1/10}{10} = \frac{1}{100}$$

que é exatamente a probabilidade do evento $[X \geq 10]$.

ANÁLISE DO QS USANDO A DESIGUALDADE DE MARKOV

Vejam uma prova alternativa de que em uma execução do *quick-sort* probabilístico o número esperado de comparações entre elementos de uma instância com n elementos é $O(n \ln n)$ com alta probabilidade. Nesta seção, para ilustrar a robustez do método de Markov mesmo no pior caso de recursão, consideramos a variante do algoritmo cujo caso base é $|S| \leq 2$ (isto é, a recursão prossegue para toda subsequência com 3 ou mais elementos).

Para pivô de posto r temos $|S_E| = r - 1$ e $|S_D| = |S| - r$. O número de postos para bons pivôs é $\lfloor 0,9 |S| \rfloor - \lceil 0,1 |S| \rceil$. Diferentemente do caso $|S| > 50$, aqui não há uma cota inferior próxima de

0,8: o pior caso ocorre no menor tamanho recursivo, $|S| = 3$, onde há um único posto bom (o do meio) entre três, dando assim,

$$\frac{1}{3} \leq p \leq \frac{4}{5}.$$

Consideremos um elemento x de uma instância S para o algoritmo 3.1 e $S_0 = S, S_1, S_2, \dots, S_M$ as subsequências a que x pertence após cada particionamento durante uma execução.

Sorteando um pivô o i -ésimo particionamento é *bom* se $|S_i|/10 \leq |S_{i+1}| \leq 9|S_i|/10$ o que ocorre com probabilidade $0,33 < p \leq 0,8$.

Fixado $|S_i| = k$, o particionamento cai em um de dois casos, dependendo do pivô sorteado: se for *sucesso* (o que ocorre com probabilidade p), então, por definição, $|S_{i+1}| \leq 9k/10$; caso contrário (*fracasso*, com probabilidade $1 - p$), não há garantia melhor que a trivial $|S_{i+1}| \leq |S_i| = k$. Tomando a esperança condicional em cada um desses dois casos e combinando-as segundo suas probabilidades,

$$\mathbb{E}(|S_{i+1}| \mid |S_i| = k) \leq \underbrace{p \cdot \frac{9k}{10}}_{\text{sucesso}} + \underbrace{(1-p) \cdot k}_{\text{fracasso}} = \left(1 - \frac{p}{10}\right)k,$$

onde a última igualdade é apenas a fatoração de k nos dois termos. Como $1 - p/10$ é *decrecente* em p , o maior valor possível dessa cota e, portanto, o pior caso, ocorre no menor p garantido. Com $p \geq 1/3$

$$\left(1 - \frac{p}{10}\right)k \leq \left(1 - \frac{1}{30}\right)k = \frac{29}{30}k.$$

Agora, podemos usar a lei de esperança total para escrever

$$\begin{aligned} \mathbb{E}|S_{i+1}| &= \sum_k \mathbb{E}(|S_{i+1}| \mid |S_i| = k) \mathbb{P}[|S_i| = k] \\ &\leq \sum_k \frac{29}{30} k \mathbb{P}[|S_i| = k] \\ &= \frac{29}{30} \sum_k k \mathbb{P}[|S_i| = k] \\ &= \frac{29}{30} \mathbb{E}|S_i| \end{aligned}$$

iterando essa desigualdade, partindo de $|S_0| = |S| = n$, concluímos

$$\mathbb{E}|S_M| < \left(\frac{29}{30}\right)^M n.$$

Queremos escolher M de modo que essa cota seja pequena o bastante para, somada sobre os n elementos da instância, ainda dar uma probabilidade de falha que tende a zero. Para isso, tomando $M := a \log_{30/29} n$, para uma constante $a > 0$ a ser escolhida,

$$\left(\frac{29}{30}\right)^M n = \left(\frac{29}{30}\right)^{a \log_{30/29} n} n = \left(\frac{30}{29}\right)^{-a \log_{30/29} n} n = n^{-a} \cdot n = n^{1-a}.$$

Assim, $\mathbb{E}|S_M| < n^{1-a}$. Para que essa probabilidade, somada sobre os n elementos da instância, ainda tenda a zero; por isso fixamos, desde já, $a \geq 3$.

Pela desigualdade de Markov, aplicada à variável aleatória (não negativa) $|S_M|$ com $t = 2$ (o limiar do caso base)

$$\mathbb{P}[|S_M| > 2] \leq \frac{\mathbb{E}|S_M|}{2} < \frac{n^{1-a}}{2},$$

ou seja, a probabilidade de que o elemento fixado x ainda esteja participando de particionamentos após $M = a \log_{30/29} n$ passos é menor que $n^{1-a}/2$.

Pela união desse evento sobre os n elementos de S , a probabilidade de que *exista* algum $x \in S$ que passe por mais que $a \log_{30/29} n$ particionamentos é

$$< n \cdot \frac{n^{1-a}}{2} = \frac{n^{2-a}}{2}$$

ou seja, o número de comparações efetuadas pelo *quicksort* é $O(n \ln n)$ com probabilidade pelo menos

$$1 - \frac{n^{2-a}}{2} \stackrel{(a=3)}{\geq} 1 - \frac{1}{2n}.$$

3.5 Desigualdade de Chebyshev

A próxima desigualdade é conhecida por desigualdade de Chebyshev, também conhecida por *desigualdade de Bienaymé–Chebyshev*. Da equação (3.5) obtemos a *desigualdade de Chebyshev*

$$\mathbb{P}[|X| \geq t] \leq \frac{\mathbb{E}(X^2)}{t^2} \quad (3.6)$$

que é mais conhecida na forma enunciada a seguir.

Teorema 3.5: desigualdade de Chebyshev

Para toda constante $t > 0$ e toda variável aleatória X com quadrado integrável temos

$$\mathbb{P}[|X - \mathbb{E}X| \geq t] \leq \frac{\text{Var}(X)}{t^2}. \quad (3.7)$$

Demonstração. Segue da desigualdade (3.6) com a variável aleatória $X - \mathbb{E}X$. □

A desigualdade (3.7) pode ser justa como no seguinte exemplo. Seja X uma variável aleatória que assume o valor 0 com probabilidade $q \in (0, 1)$ e os valores 1 e -1 com probabilidade $p/2$ cada, com

Pafnuty Lvovich Chebyshev (1821–1894) foi um matemático russo conhecido por suas contribuição à Probabilidade, dentre seus alunos vários são matemáticos reconhecidos e um deles foi Andrey Markov. Irénée-Jules Bienaymé (1796–1878) foi um estatístico francês, contribuiu para a Probabilidades e o desenvolvimento da Estatística e suas aplicações.

$p = 1 - q$. A esperança de X é 0 e a variância é p . A probabilidade do evento $[|X| \geq 1]$ é p de modo que

$$p = \mathbb{P}[|X - 0| \geq 1] \leq \frac{\text{Var}(X)}{1^2} = p.$$

Quando a variância está definida mas não é finita, a desigualdade de Chebyshev não é útil. Por exemplo se X tem lei $\mathbb{P}_X(z) = c/z^3$, para $c > 0$ constante e $k \in \mathbb{Z}^+$, então $\mathbb{E}(X) = c\pi^2/6$ (veja (s.8)) e $\mathbb{E}(X^2) = +\infty$. Com $\text{Var}(X) = \infty$, a desigualdade de Chebyshev não dá informação, enquanto que pela desigualdade de Markov obtemos $\mathbb{P}[X \geq t] \leq c\pi^2/6t$.

Tomando o *desvio padrão* $\sigma_X = \sqrt{\text{Var}(X)}$ e trocando t por $t\sigma_X > 0$ na desigualdade de Chebyshev, obtemos

$$\mathbb{P}[|X - \mathbb{E}X| \geq t\sigma_X] \leq \frac{1}{t^2}$$

e com $t\mathbb{E}X > 0$, obtemos

$$\mathbb{P}[|X - \mathbb{E}X| \geq t\mathbb{E}X] \leq \frac{\text{Var}(X)}{t^2(\mathbb{E}X)^2} \leq \frac{\mathbb{E}(X^2)}{t^2(\mathbb{E}X)^2} \quad (3.8)$$

onde a segunda desigualdade segue do fato de

$$\frac{\text{Var}(X)}{(\mathbb{E}X)^2} = \frac{\mathbb{E}(X^2)}{(\mathbb{E}X)^2} - 1. \quad (3.9)$$

ANÁLISE DO QS USANDO A DESIGUALDADE DE CHEBYSHEV

Uma terceira estratégia para mostrar que T concentra em torno de sua média é aplicar a desigualdade de Chebyshev diretamente ao total T , em vez de tratar cada X_i separadamente e somar as probabilidades de falha. Isso requer conhecer (ou estimar) $\text{Var}(T)$.

É um resultado conhecido na literatura (citado na seção 5.2.2, pág. 120 de Knuth, 1998, como consequência do exerc. 6.2.2-8) que a variância do número de comparações do *quicksort* aleatorizado satisfaz (Iliopoulos e Penman, 2010)

$$\text{Var}(T) = \left(7 - \frac{2\pi^2}{3}\right)n^2 + O(n \log n) \approx 0,4203 n^2.$$

Pela desigualdade de Chebyshev, para qualquer $t > 0$,

$$\mathbb{P}[|T - \mathbb{E}T| \geq t] \leq \frac{\text{Var}(T)}{t^2}.$$

Tomando $t = c n \log n$ para uma constante $c > 0$, e usando $\mathbb{E}T = O(n \log n)$,

$$\mathbb{P}[T > \mathbb{E}T + c n \log n] \leq \frac{0,4203 n^2}{c^2 n^2 \log^2 n} = \frac{0,4203}{c^2 \log^2 n} \xrightarrow{n \rightarrow \infty} 0.$$

Ou seja, $T = O(n \log n)$ com probabilidade $1 - o(1)$.

3.6 Exercícios

Exercício 14. Em um treino, paraquedistas formam, de início, um grupo de n paraquedistas enfileirados nas posições $1, 2, \dots, n$ dentro de um avião. Em cada etapa do treinamento, um paraquedista é escolhido e seu grupo é dividido em dois grupos. A escolha é uniformemente ao acaso. O paraquedista escolhido cumprimenta todos os paraquedistas do seu grupo e salta do avião. A divisão do grupo em dois é assim: um novo grupo formado pelos paraquedistas que se encontravam à esquerda daquele que pulou e o outro grupo formado pelos paraquedistas à direita.

O procedimento é repetido para cada um dos grupos restantes até que todos os grupos tenham um único paraquedista; esses últimos paraquedistas saltam, então, um a um. A ordem relativa dos paraquedistas dentro de cada grupo é sempre preservada.

Observe que, a partir do momento em que dois paraquedistas pertencem a grupos distintos, eles não se cumprimentam mais.

Prove que os paraquedistas das posições i e j , com $j > i$, se cumprimentam com probabilidade $2/(j - i + 1)$.

Exercício 15. Assuma que as instâncias para o *quicksort* padrão, sem sorteios, são as permutações de $(1, 2, \dots, n)$. Demonstre que o número médio de comparações para ordenar essas instâncias é $O(n \ln n)$ (dica: o exercício dos paraquedistas).

Exercício 16. Considere o *quicksort* aleatorizado (Algoritmo 3.1) executando sobre uma sequência de n elementos distintos, mas com o limiar do caso base alterado de 50 para 100 elementos (ou seja, sequências com até 100 elementos são ordenadas na força bruta).

- Ref faça o cálculo que leva à desigualdade $0,76 < p < 0,8$ feito no texto, obtendo os novos limitantes para a probabilidade p de um particionamento ser *bom* quando $|S| > 100$.
- Explique por que a mudança do limiar não altera a ordem de grandeza $O(n \ln n)$ do número esperado de comparações, mas pode alterar a constante multiplicativa na cota $\mathbb{E}T < 2n \lceil \log_{10/9} n \rceil$ de (3.1).

Exercício 17. No Lema 3.1, a hipótese é que a probabilidade *condicional* de sucesso, dado qualquer histórico, é pelo menos α . Considere a seguinte variante do particionamento do *quicksort*: suponha que, em vez de sortear o pivô uniformemente, o algoritmo sorteia o pivô de modo que a probabilidade de sucesso no i -ésimo particionamento de uma dada subsequência de x seja *exatamente* 0,7 se o particionamento anterior de x foi um sucesso, e 0,9 se foi um fracasso (mas sempre

pelo menos 0,7).

- (a) Verifique que as hipóteses do Lema 3.1 continuam satisfeitas com $\alpha = 0,7$, mesmo essa sequência de tentativas não sendo i.i.d.
- (b) Usando o item (b) do lema, dê um limitante superior para o número esperado de particionamentos necessários para x acumular $L + 1 = 29$ sucessos.
- (c) Explique, em uma frase, por que seria *errado* aplicar diretamente a fórmula da esperança de uma binomial negativa $BN(L+1, 0,7)$ para calcular exatamente (e não apenas limitar superiormente) o número esperado de particionamentos nesse cenário.

Exercício 18. Em uma execução do *quicksort* aleatorizado sobre uma entrada de tamanho n , seja T o número total de comparações entre elementos realizadas pelo algoritmo. Vimos em (3.1) que $\mathbb{E}T < 2n \lceil \log_{10/9} n \rceil$.

- (a) Usando a desigualdade de Markov (Teorema 3.4), mostre que, para qualquer constante $c > 1$,

$$\mathbb{P}[T \geq c \cdot 2n \lceil \log_{10/9} n \rceil] \leq \frac{1}{c}.$$

- (b) Em particular, tome $c = 100$. Conclua que a probabilidade de o *quicksort* realizar mais que $200n \lceil \log_{10/9} n \rceil$ comparações é no máximo 1%.
- (c) Compare o limitante obtido no item anterior com o limitante do Teorema que afirma que T é $O(n \ln n)$ com probabilidade $1 - O(n^{-29})$. Qual dos dois resultados é mais forte para n grande? A desigualdade de Markov, sozinha, seria suficiente para provar esse teorema mais forte? Justifique.
- (d) Explique, em termos gerais (sem repetir a conta), por que a desigualdade de Markov aplicada diretamente a T fornece um limitante muito mais fraco do que a análise feita no Teorema 3.2 via $\mathbb{P}[X_i > L]$ para cada elemento x_i individualmente, seguida de união de eventos. (Dica: pense em quantos "graus de liberdade", ou quantas variáveis aleatórias diferentes, cada abordagem usa.)

Exercício 19. Seja $Y \sim \text{Geom}(1/2)$. Mostre que $X \succeq Y$ se, e só se, $\mathbb{P}[X > j] \geq 2^{-j}$ para todo inteiro $j \geq 0$, para toda X com valores nos naturais positivos.

Exercício 20. Mostre que a dominação estocástica é transitiva e que $Y \succeq X$ e $X \succeq Y$ implicam que $X \stackrel{d}{=} Y$.

Exercício 21. Considere, para cada elemento x_i da instância, a variável W_i igual ao número de particionamentos bem sucedidos entre os $L = 12\ell$ primeiros particionamentos sofridos por x_i , de modo que $\mathbb{E}(W_i) = \mu = L\alpha$ e $\text{Var}(W_i) \leq L\alpha(1 - \alpha) = O(\ell)$.

O objetivo deste exercício é mostrar que, se tentarmos substituir a desigualdade de Chernoff por uma aplicação *ingênua* da desigualdade de Chebyshev a cada W_i individualmente, o argumento “por elemento + união de eventos” deixa de funcionar.

- (a) Usando a desigualdade de Chebyshev (Teorema 3.5) com $t = \mu - \ell = O(\ell)$, mostre que

$$\mathbb{P}[W_i \leq \ell] \leq \frac{\text{Var}(W_i)}{t^2} = O\left(\frac{1}{\ell}\right) = O\left(\frac{1}{\log n}\right).$$

- (b) Aplicando a união de eventos sobre os n elementos $x_1, \dots, x_n$ da instância, mostre que o limitante obtido no item (a) fornece apenas

$$\mathbb{P}[\exists i: W_i \leq \ell] \leq n \cdot O\left(\frac{1}{\log n}\right),$$

e explique por que essa cota é *inútil* (isto é, por que ela não tende a 0 quando $n \rightarrow \infty$).

- (c) Compare a ordem de grandeza do desvio $t = \mu - \ell$ com a do desvio-padrão $\sqrt{\text{Var}(W_i)}$ nesse regime. Explique, em termos gerais, por que o fato de ambos serem da mesma ordem ($t = \Theta(\ell)$ e o desvio-padrão $\Theta(\sqrt{\ell})$) faz com que o quadrado no denominador de Chebyshev não seja suficiente para compensar o fator n introduzido pela união de eventos.
- (d) Conclua explicando por que, nesse argumento “por elemento + união”, é necessário usar um limitante de cauda exponencial (como o de Chernoff) em vez de um limitante polinomial como o de Chebyshev.

VARIÂNCIA DO NÚMERO DE COMPARAÇÕES DO QS

Seja C_n o número de comparações do *quicksort* ao ordenar n elementos distintos, com pivô escolhido uniformemente. Seja $U_n \sim U\{0, \dots, n-1\}$. Então, em distribuição,

$$C_n \stackrel{d}{=} C_{U_n} + C'_{n-1-U_n} + n - 1, \quad (3.10)$$

onde, para cada k , C'_k é uma cópia independente de C_k (duas execuções físicas distintas do algoritmo) e independente de U_n . Escrevemos

$$\mu_n := \mathbb{E}(C_n), \quad s_n := \mathbb{E}(C_n^2), \quad v_n := \text{Var}(C_n) = s_n - \mu_n^2,$$

com $C_0 = C_1 = 0$, e

$$H_n := \sum_{j=1}^n \frac{1}{j}, \quad H_n^{(2)} := \sum_{j=1}^n \frac{1}{j^2}.$$

Condicionando em $U_n = k$ em (3.10),

$$\mu_n = n - 1 + \frac{1}{n} \sum_{k=0}^{n-1} (\mu_k + \mu_{n-1-k}) = n - 1 + \frac{2}{n} \sum_{k=0}^{n-1} \mu_k.$$

Multiplicando por n e subtraindo a mesma identidade para $n - 1$,

$$\begin{aligned} n\mu_n - (n-1)\mu_{n-1} &= 2(n-1) + 2\mu_{n-1} \\ \Rightarrow \frac{\mu_n}{n+1} &= \frac{\mu_{n-1}}{n} + \frac{2(n-1)}{n(n+1)} = \frac{\mu_{n-1}}{n} + \frac{4}{n+1} - \frac{2}{n}. \end{aligned}$$

Somando de 1 a n (com $\mu_0 = 0$):

$$\frac{\mu_n}{n+1} = 4(H_{n+1} - 1) - 2H_n = 2H_n + \frac{4}{n+1} - 4,$$

e portanto

$$\mu_n = 2(n+1)H_n - 4n. \quad (3.11)$$

Condicionando em $U_n = k$ e usando a independência,

$$\mathbb{E}\left((C_k + C'_{n-1-k} + n - 1)^2\right) = s_k + s_{n-1-k} + 2\mu_k\mu_{n-1-k} + 2(n-1)(\mu_k + \mu_{n-1-k}) + (n-1)^2.$$

Fazendo a média sobre k e multiplicando por n , com $T_n := \sum_{k=0}^{n-1} \mu_k\mu_{n-1-k}$

e $P_n := \sum_{k=0}^{n-1} \mu_k$,

$$n s_n = 2 \sum_{k=0}^{n-1} s_k + 2T_n + 4(n-1)P_n + n(n-1)^2, \quad \forall n \geq 1. \quad (3.12)$$

Funções geradoras. Seja

$$L = L(z) := -\ln(1-z) = \sum_{m \geq 1} \frac{1}{m} z^m$$

e sejam $\mu(z) = \sum_n \mu_n z^n$ e $M(z) = \sum_n s_n z^n$.

Da recorrência $n\mu_n = n(n-1) + 2P_n$ e de $\sum_{n \geq 1} n(n-1)z^{n-1} = 2z/(1-z)^3$,

$$\begin{aligned} \mu'(z) &= \frac{2z}{(1-z)^3} + \frac{2\mu(z)}{1-z} \iff \\ &((1-z)^2\mu)' = \frac{2z}{1-z} = 2\left(\frac{1}{1-z} - 1\right); \end{aligned}$$

Integrando de 0 a z ,

$$\mu(z) = \frac{2(L-z)}{(1-z)^2}. \quad (3.13)$$

A função geradora de (3.12): multiplicando (3.12) por z^{n-1} e somando em $n \geq 1$:

- $\sum_{n \geq 1} n s_n z^{n-1} = M'$;
- $\sum_{n \geq 1} (2 \sum_{k < n} s_k) z^{n-1} = \frac{2M}{1-z}$;
- $\sum_{n \geq 1} 2T_n z^{n-1} = 2\mu(z)^2$ (produto de séries);
- como $\sum_{n \geq 1} P_n z^{n-1} = B(z) := \frac{\mu}{1-z} = \frac{2(L-z)}{(1-z)^3}$, temos $\sum_{n \geq 1} 4(n-1)P_n z^{n-1} = 4zB'(z)$, e

$$B'(z) = \frac{2z + 6(L-z)}{(1-z)^4} \implies 4zB'(z) = \frac{24zL - 16z^2}{(1-z)^4};$$

- $\sum_{n \geq 1} n(n-1)^2 z^{n-1} = \sum n(n-1)(n-2)z^{n-1} + \sum n(n-1)z^{n-1} = \frac{6z^2}{(1-z)^4} + \frac{2z}{(1-z)^3} = \frac{4z^2 + 2z}{(1-z)^4}$.

Logo

$$M' = \frac{2M}{1-z} + 2\mu^2 + F, \quad F(z) := \frac{24zL - 12z^2 + 2z}{(1-z)^4}.$$

Multiplicando por $(1-z)^2$,

$$((1-z)^2 M)' = (1-z)^2 (2\mu^2 + F) = \frac{8L^2 + 8zL - 4z^2 + 2z}{(1-z)^2},$$

pois $(1-z)^2 \cdot 2\mu^2 = 8(L-z)^2/(1-z)^2$. Como $M(0) = 0$,

$$(1-z)^2 M(z) = \int_0^z \frac{8L(t)^2 + 8tL(t) - 4t^2 + 2t}{(1-t)^2} dt.$$

Usando $L' = 1/(1-t)$ e integração por partes, obtêm-se as primitivas

$$\begin{aligned} \int_0^z \frac{L^2}{(1-t)^2} dt &= \frac{L^2 - 2L + 2}{1-z} - 2, \\ \int_0^z \frac{L}{(1-t)^2} dt &= \frac{L-1}{1-z} + 1, \quad \int_0^z \frac{L}{1-t} dt = \frac{L^2}{2}, \\ \int_0^z \frac{-4t^2 + 2t}{(1-t)^2} dt &= -\frac{2}{1-z} + 2 + 6L - 4z, \end{aligned}$$

onde a última usa $-4t^2 + 2t = -2 + 6(1-t) - 4(1-t)^2$ e $tL/(1-t)^2 = L/(1-t)^2 - L/(1-t)$. Somando com os pesos 8, 8 e 1,

$$M(z) = \frac{8L^2 - 8L + 6}{(1-z)^3} + \frac{-4L^2 + 6L - 4z - 6}{(1-z)^2}. \quad (3.14)$$

Lema 3.1. Para $r \geq 0$ inteiro,

$$\begin{aligned} [z^n] \frac{1}{(1-z)^{r+1}} &= \binom{n+r}{r}, \\ [z^n] \frac{L}{(1-z)^{r+1}} &= \binom{n+r}{r} (H_{n+r} - H_r), \\ [z^n] \frac{L^2}{(1-z)^{r+1}} &= \binom{n+r}{r} [(H_{n+r} - H_r)^2 - (H_{n+r}^{(2)} - H_r^{(2)})]. \end{aligned}$$

Demonstração. Para $\alpha > 0$, $(1 - z)^{-\alpha} = e^{\alpha L}$ e

$$[z^n](1 - z)^{-\alpha} = \Gamma(n + \alpha) / (\Gamma(\alpha) n!).$$

Derivando j vezes em α obtém-se $L^j(1 - z)^{-\alpha}$ do lado esquerdo. Do lado direito,

$$\partial_\alpha \ln \frac{\Gamma(n + \alpha)}{\Gamma(\alpha)} = \psi(n + \alpha) - \psi(\alpha)$$

e

$$\partial_\alpha^2 \ln \frac{\Gamma(n + \alpha)}{\Gamma(\alpha)} = \psi'(n + \alpha) - \psi'(\alpha).$$

Em $\alpha = r + 1$, $\psi(n + r + 1) - \psi(r + 1) = H_{n+r} - H_r$ e $\psi'(n + r + 1) - \psi'(r + 1) = -(H_{n+r}^{(2)} - H_r^{(2)})$. Basta aplicar $\partial_\alpha^2 e^f = (f'^2 + f'')e^f$ com $f = \ln \frac{\Gamma(n + \alpha)}{\Gamma(\alpha)}$. $\square$

Fixe

$$p := n + 1, \quad a := H_{n+1} \quad \text{e} \quad a_2 := H_{n+1}^{(2)}.$$

Aplicando o lema a (3.14) (com $r = 2$ nos termos em $(1 - z)^{-3}$ e $r = 1$ nos termos em $(1 - z)^{-2}$, e lembrando $H_2 = \frac{3}{2}$, $H_2^{(2)} = \frac{5}{4}$, $H_{n+2} = a + \frac{1}{p+1}$), os seis blocos de $[z^n]M(z)$ são:

$$\begin{aligned} \frac{8L^2}{(1-z)^3} &\mapsto 4p(p+1)(a^2 - 3a - a_2 + \frac{7}{2}) + 8pa - 12p, \\ \frac{-8L}{(1-z)^3} &\mapsto -4p(p+1)a + 6p(p+1) - 4p, \\ \frac{6}{(1-z)^3} &\mapsto 3p(p+1), \\ \frac{-4L^2}{(1-z)^2} &\mapsto -4pa^2 + 8pa - 8p + 4pa_2, \\ \frac{6L}{(1-z)^2} &\mapsto 6pa - 6p, \\ \frac{-4z-6}{(1-z)^2} &\mapsto -10p + 4. \end{aligned}$$

Somando,

$$s_n = 4p^2a^2 - 4p^2a_2 - 16p^2a + 6pa + 23p^2 - 17p + 4. \quad (3.15)$$

A variância. Por (3.11), como $H_n = a - \frac{1}{p}$, temos $\mu_n = 2pa - 4p + 2$, e então

$$\mu_n^2 = 4p^2a^2 - 16p^2a + 8pa + 16p^2 - 16p + 4.$$

Subtraindo de (3.15) (os termos em a^2 e em p^2a cancelam):

$$v_n = s_n - \mu_n^2 = 7p^2 - p - 4p^2a_2 - 2pa.$$

Voltando a n , com $a_2 = H_n^{(2)} + \frac{1}{(n+1)^2}$ e $a = H_n + \frac{1}{n+1}$:

$$\text{Var}(C_n) = 7n^2 + 13n - 4(n+1)^2H_n^{(2)} - 2(n+1)H_n. \quad (3.16)$$

Como $H_n^{(2)} = \zeta(2) - \sum_{j>n} j^{-2} \approx \frac{1}{n+1} < \sum_{j>n} j^{-2} < \frac{1}{n}$, temos
 $H_n^{(2)} = \frac{\pi^2}{6} - \frac{1}{n} + O(n^{-2})$. Logo

$$-4(n+1)^2 H_n^{(2)} = -\frac{2\pi^2}{3}(n+1)^2 + 4n + O(1),$$

e, com $H_n = \ln n + \gamma + O(1/n)$,

$$\text{Var}(C_n) = \left(7 - \frac{2\pi^2}{3}\right)n^2 - 2n \ln n + O(n).$$

