

4

Desigualdade de Chernoff–Hoeffding

As desigualdades de Chernoff formam uma classe de desigualdades derivadas da desigualdade de Markov e de limitantes para a função geradora de momentos. Essa técnica foi introduzida por [Bernstein \(1924\)](#), que desenvolveu limitantes para a soma de variáveis aleatórias com variâncias finitas. [Chernoff \(1952\)](#) derivou limitantes para soma de variáveis aleatórias independentes

“Devo mencionar que Cramér (1938) havia obtido resultados muito mais elegantes e gerais sobre grandes desvios. Descobri isso depois de derivar meus próprios resultados. No entanto, Cramér exigia uma condição que não era satisfeita pelas variáveis aleatórias de valores inteiros no meu problema. Shannon havia publicado um artigo usando o Teorema Central do Limite como uma aproximação para grandes desvios e foi criticado por isso. Meu artigo permitiu que ele modificasse seus resultados e gerou muita publicidade na literatura de ciência da computação para o que ficou conhecido como o limitante de Chernoff, que, na verdade, era o resultado de Rubin.” Herman Chernoff, ([Chernoff, 2014](#)).

Sergei N. Bernstein, 1880–1968 foi um matemático soviético. Em 1917, sugeriu a primeira base axiomática da teoria de probabilidade. Conhecido também por resolver o décimo nono problema de Hilbert sobre a solução analítica de equações diferenciais elípticas.

Por fim, [Hoeffding \(1994\)](#) introduziu uma desigualdade para soma de variáveis aleatórias independentes e limitadas.

4.1 O método de Chernoff

Se X é uma variável aleatória, $f: \mathbb{R} \rightarrow \mathbb{R}_+$ uma função estritamente crescente e $t \in \mathbb{R}$, então vale $[X \geq t] = [f(X) \geq f(t)]$ e, pela desigualdade de Markov, deduzimos

$$\mathbb{P}[X \geq t] = \mathbb{P}[f(X) \geq f(t)] \leq \frac{\mathbb{E}f(X)}{f(t)}$$

donde derivamos, anteriormente, a desigualdade de Chebyshev usando $f(x) = x^2$. Agora, neste contexto, tomamos a função $f(x) = \exp(sx)$ para algum parâmetro $s \in \mathbb{R}$ e temos que

- se $s > 0$, então $[X \geq t] = [sX \geq st] = [\exp(sX) \geq \exp(st)]$, logo

$$\mathbb{P}[X \geq t] = \mathbb{P}[e^{sX} \geq e^{st}] \leq \frac{\mathbb{E}e^{sX}}{e^{st}}, \quad (4.1)$$

- se $s < 0$, então $[X \leq t] = [sX \geq st] = [\exp(sX) \geq \exp(st)]$, logo

$$\mathbb{P}[X \leq t] = \mathbb{P}[e^{sX} \geq e^{st}] \leq \frac{\mathbb{E}e^{sX}}{e^{st}}. \quad (4.2)$$

A esperança $M_X(s) := \mathbb{E}e^{sX}$ é a *função geradora de momentos* (FGM) de X , que estudamos com mais cuidado na Seção 4.2; aqui basta saber que ela está definida para os $s \in \mathbb{R}$ em que a esperança é finita. As desigualdades (4.1) e (4.2) valem para todo s (do sinal indicado) em que a FGM de X é finita, e, quando ela diverge, o lado direito vale $+\infty$ e a desigualdade é trivial. Obtemos delas o seguinte resultado.

Teorema 4.1: método de Chernoff–Cramér

Se X é uma variável aleatória e $t \in \mathbb{R}$, então

$$\mathbb{P}[X \geq t] \leq \inf_{s>0} \frac{\mathbb{E}e^{sX}}{e^{st}} \quad (4.3)$$

$$\mathbb{P}[X \leq t] \leq \inf_{s<0} \frac{\mathbb{E}e^{sX}}{e^{st}}. \quad (4.4)$$

O método de Chernoff–Cramér consiste em estimar o lado direito dessas desigualdades e é especialmente útil no caso de variáveis aleatórias que podem ser escritas como soma de variáveis aleatórias independentes, pois nesse caso a FGM da soma é o produto das FGMs.

4.2 Momentos e função geradora de momentos

Dado um inteiro positivo k , definimos o momento de ordem k , ou o *k -ésimo momento* da variável aleatória $X: \Omega \rightarrow \mathbb{R}$, como a esperança de X^k

$$\mathbb{E}X^k = \sum_r r^k \mathbb{P}_X(r)$$

quando está definida. De $|x|^k \leq |x|^{k+1} + 1$ para todo $x \in \mathbb{R}$, temos que se o momento de ordem $k+1$ é finito então o de ordem k também é finito. Ainda, usando a desigualdade de Markov, podemos provar facilmente que, dado um inteiro positivo k , vale

$$\mathbb{P}[|X| \geq t] = \mathbb{P}[|X|^k \geq t^k] \leq \frac{\mathbb{E}|X|^k}{t^k} \quad (4.5)$$

para toda constante $t > 0$, sempre que $|X|^k$ é integrável.

Se X tem esperança finita, definimos o *k -ésimo momento central* por $\mathbb{E}(X - \mathbb{E}X)^k$. Em particular, a *variância* de uma variável aleatória integrável é o segundo momento central dessa variável

$$\text{Var}(X) := \mathbb{E}(X - \mathbb{E}X)^2 = \mathbb{E}X^2 - (\mathbb{E}X)^2. \quad (4.6)$$

A *função geradora de momentos* (FGM) de uma variável aleatória real X é

$$M_X(s) := \mathbb{E}e^{sX}, \quad s \in \mathbb{R}, \quad (4.7)$$

definida nos valores de s para os quais a esperança é finita. Sempre vale $M_X(0) = 1$. Se a função está definida em algum intervalo $(-x_0, x_0)$ com $x_0 > 0$, então a variável aleatória X tem todos os seus momentos finitos e, usando a série de Taylor em torno de 0, vale que

$$M_X(s) = \sum_{k=0}^{\infty} \frac{s^k}{k!} \mathbb{E}X^k \quad (4.8)$$

para todo $s \in (-x_0, x_0)$ (ver Billingsley, 1995, Seção 21).

O nome vem do fato de que, expandindo e^{sX} em série de Taylor e trocando soma com esperança (quando isso é válido),

$$M_X(s) = \mathbb{E} \sum_{k=0}^{\infty} \frac{(sX)^k}{k!} = \sum_{k=0}^{\infty} \frac{\mathbb{E}X^k}{k!} s^k,$$

ou seja, os *momentos* $\mathbb{E}X^k$ aparecem como os coeficientes de Taylor de M_X em $s = 0$ (a menos do fatorial). Equivalentemente, $\mathbb{E}X^k = M_X^{(k)}(0)$, a k -ésima derivada de M_X avaliada em $s = 0$. Em particular, $M_X'(0) = \mathbb{E}X$ e $M_X''(0) = \mathbb{E}X^2$.

A FGM pode não estar definida para todo s : para variáveis com cauda muito pesada¹, $M_X(s)$ pode divergir para todo $s \neq 0$. Felizmente, nas aplicações deste capítulo a FGM está definida em um intervalo em torno de 0: para variáveis limitadas, como as indicadoras, em todo $\mathbb{R}$; para a geométrica, em $s < \ln 2$ (Exemplo 4.2 e Seção 4.6).

A propriedade central que torna a FGM valiosa em nossas aplicações é que ela transforma *soma de variáveis independentes* em *produto de FGMs*. Se $X_1, \dots, X_n$ são independentes,

$$M_{X_1 + \dots + X_n}(s) = \mathbb{E}e^{s(X_1 + \dots + X_n)} = \mathbb{E} \prod_{i=1}^n e^{sX_i} = \prod_{i=1}^n \mathbb{E}e^{sX_i} = \prod_{i=1}^n M_{X_i}(s),$$

onde a penúltima igualdade usa a independência (a esperança do produto é o produto das esperanças).

¹ por exemplo, distribuições com densidade proporcional a $|x|^{-3}$ para $|x| \geq 1$

Exemplo 4.1: FGM da binomial

Se $X \sim \text{Binomial}(n, p)$, então $X = \sum_i X_i$ com X_i independentes e distribuição de Bernoulli(p), e

$$M_{X_i}(s) = \mathbb{E}e^{sX_i} = pe^s + 1 - p,$$

logo

$$M_X(s) = (pe^s + 1 - p)^n$$

para todo $s \in \mathbb{R}$.

Exemplo 4.2: FGM da geométrica

Se $X \sim \text{Geom}(p)$, então

$$\begin{aligned} M_X(s) &= \sum_{k=1}^{\infty} e^{sk} p(1-p)^{k-1} = pe^s \sum_{k=1}^{\infty} (e^s(1-p))^{k-1} \\ &= \frac{pe^s}{1 - e^s(1-p)} \quad (4.9) \end{aligned}$$

sempre que $e^s(1-p) < 1$, ou seja, $s < -\ln(1-p)$. Em particular, $\mathbb{E}X = M'_X(0) = 1/p$.

4.3 Somas de variáveis aleatórias uniformes

Antes do caso geral, vejamos duas somas em que as contas são particularmente simples.

SOMA DE VARIÁVEIS ALEATÓRIAS DE RADEMACHER

Uma variável aleatória tem *distribuição de Rademacher* se assume os valores $\{-1, 1\}$ com probabilidade uniforme.

Teorema 4.2: Chernoff para variáveis Rademacher

Se $X = \sum_{i=1}^n X_i$ com $X_1, \dots, X_n \in_{\mathbb{R}}\{-1, 1\}$ independentes e $t > 0$, então

$$\mathbb{P}[|X| \geq t] \leq 2 \exp\left(\frac{-t^2}{2n}\right). \quad (4.10)$$

Demonstração. Seja X uma variável aleatória como no enunciado. Pela independência das X_i , para todo $s \in \mathbb{R}$,

$$\mathbb{E}e^{sX} = \prod_{i=1}^n \mathbb{E}e^{sX_i} = \prod_{i=1}^n \frac{e^s + e^{-s}}{2} = (\cosh s)^n.$$

Pela série de Taylor do cosseno hiperbólico e pelo fato de que $(2i)! \geq$

$\cosh(s)$ é a função cosseno hiperbólico.

$2^i i!$ para todo inteiro $i \geq 0$ (segue facilmente por indução em i),

$$\cosh s = \sum_{i=0}^{\infty} \frac{s^{2i}}{(2i)!} \leq \sum_{i=0}^{\infty} \frac{(s^2/2)^i}{i!} = e^{s^2/2},$$

logo $\mathbb{E}e^{sX} \leq e^{s^2 n/2}$. Para $s > 0$, a desigualdade de Markov aplicada à variável não negativa e^{sX} dá

$$\mathbb{P}[X \geq t] = \mathbb{P}[e^{sX} \geq e^{st}] \leq e^{-st} \mathbb{E}e^{sX} \leq \exp\left(\frac{s^2 n}{2} - st\right).$$

O mínimo do lado direito, entre os $s > 0$, é atingido em $s = t/n$ (positivo, pois $t > 0$), de modo que

$$\mathbb{P}[X \geq t] \leq e^{-t^2/2n}. \quad (4.11)$$

Como $-X$ tem a mesma distribuição de X (as $-X_i$ também são independentes e uniformes em $\{-1, 1\}$), $\mathbb{P}[-X \geq t] = \mathbb{P}[X \geq t]$ e, pela subaditividade (equação (1.2)),

$$\mathbb{P}[|X| \geq t] \leq 2e^{-t^2/2n}$$

para todo $t > 0$. □

SOMA DE VARIÁVEIS ALEATÓRIAS DE BERNOULLI

Sejam $X_1, \dots, X_n \in_{\mathbb{R}} \{-1, 1\}$ independentes. Então $Y_i := (X_i + 1)/2 \in_{\mathbb{R}} \{0, 1\}$ são independentes e $Y := \sum_i Y_i \sim \text{Binomial}(n, 1/2)$, com $\sum_i X_i = 2Y - n$. Aplicando o Teorema 4.3 com parâmetro $2t$, para todo $t > 0$,

$$\mathbb{P}[|Y - n/2| \geq t] = \mathbb{P}[|2Y - n| \geq 2t] \leq 2 \exp\left(-\frac{(2t)^2}{2n}\right).$$

Do mesmo modo, a cota unilateral (4.11), também com parâmetro $2t$, dá $\mathbb{P}[Y - n/2 \geq t] = \mathbb{P}[2Y - n \geq 2t] \leq e^{-(2t)^2/2n} = e^{-2t^2/n}$. Disso concluímos o seguinte resultado.

Teorema 4.3: Chernoff para v.a. binomial padrão

Se $X \sim \text{Binomial}(n, 1/2)$, então $\mathbb{E}X = n/2$ e, para todo $t > 0$,

$$\mathbb{P}[X - \mathbb{E}X \geq t] \leq e^{-2t^2/n} \quad (4.12)$$

$$\mathbb{P}[X - \mathbb{E}X \leq -t] \leq e^{-2t^2/n},$$

e, portanto,

$$\mathbb{P}[|X - \mathbb{E}X| \geq t] \leq 2 \exp\left(-\frac{2t^2}{n}\right). \quad (4.13)$$

A demonstração é a discussão que precede o enunciado: a primeira desigualdade é a cota unilateral (4.11) aplicada com parâmetro $2t$, a segunda segue da primeira porque $n - X$ também tem distribuição Binomial($n, 1/2$), e a terceira, da subaditividade.

Exemplo 4.3: Markov, Chebyshev e Chernoff no lançamento de moedas

Consideremos S_n a quantidade de caras no lançamento de n moedas equilibradas. O número esperado de caras é $n/2$, portanto, pela desigualdade de Markov,

$$\mathbb{P}\left[S_n \geq \frac{3}{4}n\right] \leq \frac{n/2}{3n/4} = \frac{2}{3}.$$

Usando a desigualdade de Chebyshev, com $\text{Var}(S)_n = n \cdot \frac{1}{4} = \frac{n}{4}$ (as n moedas são independentes),

$$\mathbb{P}\left[\left|S_n - \frac{n}{2}\right| \geq \frac{n}{4}\right] \leq \frac{n/4}{(n/4)^2} = \frac{4}{n},$$

em particular, $\mathbb{P}[S_n \geq 3n/4] \leq 4/n$. Pela versão unilateral da desigualdade de Chernoff (4.12), com $t = n/4$,

$$\mathbb{P}\left[S_n \geq \frac{3n}{4}\right] = \mathbb{P}\left[S_n - \frac{n}{2} \geq \frac{n}{4}\right] \leq e^{-2(n/4)^2/n} = e^{-n/8}.$$

Em resumo, os limitantes superiores para a probabilidade de $S_n \geq 1,5 \mathbb{E}S_n$ são

	Markov	Chebyshev	Chernoff
$\mathbb{P}[S_n \geq 3n/4]$	$\leq 2/3$	$\leq 4/n$	$\leq e^{-n/8}$

Embora a desigualdade de Chernoff seja muito mais poderosa, essas desigualdades assumem hipóteses diferentes: Markov só exige que a variável seja não negativa; Chebyshev, para uma soma, usa que as variâncias se somam (basta independência dois a dois); Chernoff usa a independência das X_i em conjunto.

4.4 A desigualdade de Hoeffding

O logaritmo da FGM,

$$K_X(s) := \ln M_X(s),$$

é chamado de *função geradora de cumulantes*. Sob a transformação logarítmica, a propriedade de produto vira soma:

$$K_{X_1+\dots+X_n}(s) = \sum_{i=1}^n K_{X_i}(s),$$

uma soma de n termos, mais simples de analisar que um produto de n fatores. Suas derivadas em $s = 0$ são os *cumulantes* de X : $K'_X(0) = \mathbb{E}X$ (o primeiro cumulante, igual ao primeiro momento) e $K''_X(0) = \text{Var}(X)$ (o segundo cumulante, que já não coincide com o segundo momento bruto, mas com a variância, justamente por causa da centralização implícita que o logaritmo introduz). É essa função, aplicada a $Z = X - \mathbb{E}X$, que aparece na prova do Lema de Hoeffding: $f(s) = K_{X-\mu}(s)$.

Combinando a FGM com a desigualdade de Markov aplicada a e^{sX} , como em (4.1), e escolhendo $s > 0$ para minimizar o lado direito, obtemos a cota mais forte possível por esse método. É o que faremos na prova do Teorema 4.4, com $s = 4t/n$. Diferentes escolhas de X e de s dão origem às várias variantes de “cotas de Chernoff” encontradas na literatura. A que provamos aqui (Lema de Hoeffding mais essa otimização) é uma das mais simples e vale para variáveis limitadas em $[0, 1]$.

Antes de enunciar o lema, vale explicar duas escolhas técnicas que tornam sua demonstração simples.

A primeira é trabalhar com o *logaritmo* da função geradora de momentos, $f(s) := \ln \mathbb{E}e^{sZ}$, em vez de $\mathbb{E}e^{sZ}$ diretamente. A função $\mathbb{E}e^{sZ}$ mistura somas e exponenciais de forma que suas derivadas de ordem superior ficam cada vez mais complicadas (a regra do produto se acumula a cada derivação). Tomando o logaritmo antes de derivar, essas derivadas assumem uma forma fechada e reconhecível: no caso de uma Bernoulli, a segunda derivada de f sai na forma $q_s(1 - q_s)$, um produto do tipo “ $p(1 - p)$ ”, fácil de limitar. Além disso, como $\ln$ é crescente, provar uma cota para $f(s)$ é equivalente a provar a mesma cota, exponenciada, para $\mathbb{E}e^{sZ}$, de modo que nada se perde ao passar para o logaritmo.

A segunda escolha é aplicar essa construção à variável *centralizada* $Z = X - \mu$, e não a X diretamente. Como $\mathbb{E}X - \mu = 0$, a variável Z tem média zero. Isso faz com que a expansão de Taylor de f em torno de $s = 0$ comece direto no termo quadrático: $f(0) = 0$ (pois $\mathbb{E}e^0 = 1$) e $f'(0) = \mathbb{E}Z = 0$, sem o termo linear, sobra apenas

$$f(s) = \frac{f''(\xi)}{2} s^2$$

para algum ξ entre 0 e s (teorema de Taylor com resto de Lagrange), e basta então limitar f'' uniformemente para obter uma cota do tipo

² Em geral, $\frac{d}{ds} \mathbb{E}e^{sZ} \big|_{s=0} = \mathbb{E}Z$; após compor com o logaritmo, $f'(0) = \mathbb{E}Z$ também, pois $\mathbb{E}e^0 = 1$.

$f(s) \leq cs^2$, válida para *todo* s , e não apenas para s pequeno, como daria uma expansão assintótica comum. Se não tivéssemos centralizado, $f'(0) = \mathbb{E}X = \mu \neq 0$ em geral, e um termo linear indesejado apareceria na cota final.

Lema 4.1: Lema de Hoeffding

Seja X uma variável aleatória com valores em $[0, 1]$ e $\mu := \mathbb{E}X$. Para todo $s \in \mathbb{R}$,

$$\mathbb{E}e^{s(X-\mu)} \leq \exp\left(\frac{s^2}{8}\right).$$

Demonstração. Se $\mu \in \{0, 1\}$, então $X = \mu$ com probabilidade 1 e o resultado é trivial; suponha $0 < \mu < 1$.

Redução ao caso Bernoulli. Para $x \in [0, 1]$, a convexidade de $x \mapsto e^{sx}$ dá $e^{sx} \leq (1-x) + xe^s$ (a corda entre $x = 0$ e $x = 1$). Tomando a esperança,

$$\mathbb{E}e^{sX} \leq 1 + \mu(e^s - 1),$$

que vale com igualdade quando $X \in \{0, 1\}$. Logo $\mathbb{E}e^{s(X-\mu)} \leq e^{f(s)}$, onde $f(s) := -s\mu + \ln(1 + \mu(e^s - 1))$.

Usando Taylor. Temos $f(0) = 0$, $f'(s) = -\mu + q_s$ com $q_s := \mu e^s / (1 + \mu e^s) \in (0, 1)$, logo $f'(0) = 0$ e, como $q'_s = q_s(1 - q_s)$,

$$f''(s) = q_s(1 - q_s) \leq \frac{1}{4} \quad \text{para todo } s.$$

Pelo teorema de Taylor com resto, existe ξ entre 0 e s tal que

$$\begin{aligned} f(s) &= f(0) + f'(0)s + \frac{f''(\xi)}{2}s^2 \\ &= \frac{f''(\xi)}{2}s^2 \leq \frac{1/4}{2}s^2 = \frac{s^2}{8}. \end{aligned}$$

Portanto $\mathbb{E}e^{s(X-\mu)} \leq e^{f(s)} \leq e^{s^2/8}$. □

Teorema 4.4: Desigualdade de Chernoff–Hoeffding

Sejam $X_1, \dots, X_n$ independentes, com valores em $[0, 1]$, $S := X_1 + \dots + X_n$ e $\mu := \mathbb{E}S$. Para todo $t > 0$,

$$\mathbb{P}[S \geq \mu + t] \leq e^{-2t^2/n},$$

e

$$\mathbb{P}[S \leq \mu - t] \leq e^{-2t^2/n}$$

e, portanto,

$$\mathbb{P}[|S - \mu| \geq t] \leq 2 \exp\left(-\frac{2t^2}{n}\right).$$

Demonstração. Para $s > 0$, pela desigualdade de Markov (3.5) aplicada à variável não negativa $e^{s(S-\mu)}$,

$$\begin{aligned}\mathbb{P}[S - \mu \geq t] &= \mathbb{P}\left[e^{s(S-\mu)} \geq e^{st}\right] \leq e^{-st} \mathbb{E}e^{s(S-\mu)} = \\ &= e^{-st} \prod_{i=1}^n \mathbb{E}e^{s(X_i - \mathbb{E}X_i)} \leq e^{-st} e^{(ns^2/8)},\end{aligned}$$

usando a independência dos X_i e o Lema 4.1 em cada fator. Otimizando em s , o mínimo de $-st + ns^2/8$ ocorre em $s = 4t/n$, dando o valor $-2t^2/n$, o que prova a primeira desigualdade. Para a segunda, aplicamos a primeira às variáveis $1 - X_i \in [0, 1]$, independentes, com soma $n - S$ e esperança $n - \mu$: $\mathbb{P}[S \leq \mu - t] = \mathbb{P}[n - S \geq (n - \mu) + t] \leq e^{-2t^2/n}$. A cota bilateral segue da subaditividade. $\square$

Observação 6. Os resultados da Seção 4.3 são casos particulares. Para $X_i \in_{\mathbb{R}} \{0, 1\}$ (binomial $(n, 1/2)$), o Teorema dá exatamente (4.12). Para Rademacher, $X = \sum_i X_i = 2S - n$ com $S = \sum_i (X_i + 1)/2$ e $\mu = n/2$, logo $\mathbb{P}[X \geq t] = \mathbb{P}[S \geq \mu + t/2] \leq e^{-t^2/2n}$, que é (4.11).

4.5 Soma de variáveis aleatórias Bernoulli não identicamente distribuídas

O Teorema 4.4 já dá a cota aditiva para qualquer soma de variáveis em $[0, 1]$. Para variáveis de Bernoulli com probabilidades p_i distintas obtemos, com as mesmas ideias, mais: a cota exata em função de $\hat{p}$ e a cota *multiplicativa*, bem melhor quando $\mathbb{E}X$ é pequeno, que é a usada nas aplicações a algoritmos.

A estratégia do método da função geradora de momentos (método de Chernoff: desigualdade de Markov aplicada a e^{sX}) pode ser usada na soma de variáveis aleatórias que são independentes mas não têm, necessariamente, a mesma distribuição. Sejam $X_i \sim \text{Bernoulli}(p_i)$, $1 \leq i \leq n$, independentes, $X = \sum_i X_i$ e

$$\hat{p} := \frac{1}{n} \sum_{i=1}^n p_i \quad \text{e} \quad \hat{q} := 1 - \hat{p}, \quad (4.14)$$

de modo que $\mathbb{E}X = n\hat{p}$. Se $\hat{p} \in \{0, 1\}$, então X é constante com probabilidade 1 e tudo o que segue é trivial; supomos $0 < \hat{p} < 1$.

Pela independência e pela desigualdade entre as médias aritmética e geométrica, para todo $s \in \mathbb{R}$,

$$\begin{aligned}\mathbb{E}e^{sX} &= \prod_{i=1}^n \mathbb{E}e^{sX_i} = \prod_{i=1}^n (p_i e^s + (1 - p_i)) \\ &\leq \left(\frac{1}{n} \sum_{i=1}^n (p_i e^s + (1 - p_i)) \right)^n = (\hat{p} e^s + \hat{q})^n.\end{aligned}$$

Para $s > 0$ e $t \geq 0$, a desigualdade de Markov aplicada à variável não negativa e^{sX} dá

$$\begin{aligned} \mathbb{P}[X \geq (\hat{p} + t)n] &= \mathbb{P}[e^{sX} \geq e^{s(\hat{p}+t)n}] \\ &\leq \frac{\mathbb{E}e^{sX}}{e^{s(\hat{p}+t)n}} \\ &\leq \left(\frac{\hat{p}e^s + \hat{q}}{e^{s(\hat{p}+t)}} \right)^n. \end{aligned} \quad (4.15)$$

Para $0 < t < \hat{q}$, minimizamos o lado direito em s , isto é, a função

$$g(s) = \frac{\hat{p}e^s + \hat{q}}{e^{s(\hat{p}+t)}} = \hat{p}e^{s(\hat{q}-t)} + \hat{q}e^{-s(\hat{p}+t)}.$$

Como g é soma de exponenciais, é convexa, e portanto um ponto crítico é mínimo global. A derivada é

$$g'(s) = \hat{p}(\hat{q} - t)e^{s(\hat{q}-t)} - \hat{q}(\hat{p} + t)e^{-s(\hat{p}+t)},$$

e $g'(s) = 0$ equivale, multiplicando por $e^{s(\hat{p}+t)}$, a $\hat{p}(\hat{q} - t)e^s = \hat{q}(\hat{p} + t)$, isto é,

$$s^* = \ln \left(\frac{\hat{q}(\hat{p} + t)}{\hat{p}(\hat{q} - t)} \right).$$

Esse ponto é positivo, pois $\hat{q}(\hat{p} + t) - \hat{p}(\hat{q} - t) = t(\hat{p} + \hat{q}) = t > 0$, de modo que s^* serve para a desigualdade (4.15).

Lema 4.2

Se X é a soma das variáveis aleatórias independentes

$X_i \sim \text{Bernoulli}(p_i)$, $1 \leq i \leq n$, $\hat{p} = \frac{1}{n} \sum_{i=1}^n p_i \in (0, 1)$ e $\hat{q} = 1 - \hat{p}$, então

$$\mathbb{P}[X \geq (\hat{p} + t)n] \leq \left(\left(\frac{\hat{p}}{\hat{p} + t} \right)^{\hat{p}+t} \left(\frac{\hat{q}}{\hat{q} - t} \right)^{\hat{q}-t} \right)^n \quad (0 \leq t < \hat{q}).$$

Demonstração. Para $t = 0$ o lado direito é 1 e não há o que provar.

Para $0 < t < \hat{q}$, substituímos $s = s^*$ em (4.15). Com $e^{s^*} = \hat{q}(\hat{p} + t) / (\hat{p}(\hat{q} - t))$,

$$\hat{p}e^{s^*} + \hat{q} = \frac{\hat{q}(\hat{p} + t)}{\hat{q} - t} + \hat{q} = \frac{\hat{q}}{\hat{q} - t}, \quad e^{-s^*(\hat{p}+t)} = \left(\frac{\hat{p}(\hat{q} - t)}{\hat{q}(\hat{p} + t)} \right)^{\hat{p}+t},$$

logo

$$g(s^*) = \frac{\hat{q}}{\hat{q} - t} \cdot \left(\frac{\hat{p}}{\hat{p} + t} \right)^{\hat{p}+t} \left(\frac{\hat{q} - t}{\hat{q}} \right)^{\hat{p}+t} = \left(\frac{\hat{p}}{\hat{p} + t} \right)^{\hat{p}+t} \left(\frac{\hat{q}}{\hat{q} - t} \right)^{1-\hat{p}-t},$$

e $1 - \hat{p} - t = \hat{q} - t$. □

Cota aditiva Reescrevendo o lado direito do Lema 4.2,

$$\mathbb{P}[X \geq (\hat{p} + t)n] \leq \exp(-f(t) \cdot n), \quad (4.16)$$

onde, para $-\hat{p} < t < \hat{q}$,

$$f(t) = (\hat{p} + t) \ln \frac{\hat{p} + t}{\hat{p}} + (\hat{q} - t) \ln \frac{\hat{q} - t}{\hat{q}}.$$

Vamos estudar essa função f . Sua primeira e segunda derivadas são

$$f'(t) = \ln \left(\frac{(\hat{p} + t)\hat{q}}{\hat{p}(\hat{q} - t)} \right) \quad \text{e} \quad f''(t) = \frac{1}{\hat{p} + t} + \frac{1}{\hat{q} - t} = \frac{1}{(\hat{p} + t)(\hat{q} - t)},$$

de modo que $f(0) = f'(0) = 0$. Para $0 \leq t < \hat{q}$, o denominador de f'' é o produto de dois reais positivos que somam 1, logo é no máximo $1/4$ e $f''(t) \geq 4$. Pela fórmula de Taylor com resto, com $a = 0$, existe $\xi \in (0, t)$ tal que

$$f(t) = f(0) + f'(0)t + \frac{f''(\xi)}{2} t^2 = \frac{f''(\xi)}{2} t^2 \geq 2t^2.$$

Substituindo em (4.16),

$$\mathbb{P}[X \geq (\hat{p} + t)n] \leq \exp(-2t^2n) \quad (0 \leq t < \hat{q}).$$

Essa cota vale para todo $t \geq 0$. Se $t > \hat{q}$, o evento é vazio, pois $(\hat{p} + t)n > n$. Se $t = \hat{q}$, o evento está contido em $[X \geq (\hat{p} + t')n]$ para todo $t' < \hat{q}$, e basta fazer $t' \rightarrow \hat{q}$.

Para a cauda inferior, as variáveis $Y_i := 1 - X_i \sim \text{Bernoulli}(1 - p_i)$ são independentes, com média amostral $\hat{q}$, e $\sum_i Y_i = n - X$. Portanto, pela cota anterior aplicada a (Y_i) , para todo $t \geq 0$,

$$\mathbb{P}[X \leq (\hat{p} - t)n] = \mathbb{P}\left[\sum_i Y_i \geq (\hat{q} + t)n\right] \leq \exp(-2t^2n).$$

Em particular, pelo Lema 4.2 aplicado a (Y_i) ,

$$\mathbb{P}[X \leq (\hat{p} - t)n] \leq \exp(-f(-t) \cdot n) \quad (0 \leq t < \hat{p}), \quad (4.17)$$

pois o expoente associado a (Y_i) é $(\hat{q} + t) \ln \frac{\hat{q} + t}{\hat{q}} + (\hat{p} - t) \ln \frac{\hat{p} - t}{\hat{p}} = f(-t)$.

Corolário 4.1

Com as hipóteses do Lema 4.2, $\mathbb{E}X = n\hat{p}$ e

$$\mathbb{P}[|X - \mathbb{E}X| \geq tn] \leq 2\exp(-2t^2n), \quad \text{para todo } t \geq 0.$$

□

Esse corolário também segue do Teorema 4.4 (com tn no lugar de t). A demonstração acima é uma segunda prova, que mostra a cota aditiva como consequência da cota exata do Lema e deixa disponível a função f , usada abaixo na cota inferior multiplicativa.

Cota multiplicativa Fazendo $s = \ln(1 + \varepsilon)$ e $t = \varepsilon \hat{p}$, para todo $\varepsilon > 0$, em (4.15), ao invés de tomarmos o ótimo como acima, obtemos uma desigualdade mais fraca, mas que pode ser mais fácil de aplicar. Com essa escolha, $\hat{p}e^s + \hat{q} = 1 + \varepsilon \hat{p}$ e $e^{s(\hat{p}+t)} = (1 + \varepsilon)^{(1+\varepsilon)\hat{p}}$, logo, usando $1 + x \leq e^x$,

$$\mathbb{P}[X \geq (1 + \varepsilon)\mathbb{E}X] \leq \left(\frac{1 + \varepsilon \hat{p}}{(1 + \varepsilon)^{(1+\varepsilon)\hat{p}}} \right)^n \leq \left(\frac{e^\varepsilon}{(1 + \varepsilon)^{(1+\varepsilon)}} \right)^{\mathbb{E}X}, \quad (4.18)$$

pois $n\hat{p} = \sum_i p_i = \mathbb{E}X$ e $(1 + \varepsilon)\mathbb{E}X = (\hat{p} + \varepsilon \hat{p})n$.

Exercício 23. Deduza que, para todo $\varepsilon \in (0, 1)$, vale

$$\mathbb{P}[X \leq (1 - \varepsilon)\mathbb{E}X] \leq \left(\frac{e^{-\varepsilon}}{(1 - \varepsilon)^{1-\varepsilon}} \right)^{\mathbb{E}X}.$$

(Dica: repita o argumento acima com $s < 0$, escolhendo $s = \ln(1 - \varepsilon)$, e use $1 + x \leq e^x$ em cada fator de $\mathbb{E}e^{sX} = \prod_i (1 + p_i(e^s - 1))$.)

Lema 4.3

Sejam $p_i \in [0, 1]$ e $X_i \sim \text{Bernoulli}(p_i)$, para $1 \leq i \leq n$, variáveis aleatórias independentes. Se $X = \sum_{i=1}^n X_i$, então

$$\begin{aligned} \mathbb{P}[X \geq (1 + \varepsilon)\mathbb{E}X] &\leq \left(\frac{e^\varepsilon}{(1 + \varepsilon)^{1+\varepsilon}} \right)^{\mathbb{E}X} && \text{para todo } \varepsilon > 0, \text{ e} \\ \mathbb{P}[X \leq (1 - \varepsilon)\mathbb{E}X] &\leq \left(\frac{e^{-\varepsilon}}{(1 - \varepsilon)^{1-\varepsilon}} \right)^{\mathbb{E}X} && \text{para todo } \varepsilon \in (0, 1). \end{aligned} \quad (4.19)$$

Demonstração. A primeira desigualdade é (4.18) e a segunda é o Exercício 23. □

A seguir vamos trabalhar os limitantes dos lemas acima para obtermos desigualdades mais fáceis de serem usadas. Usamos a seguinte desigualdade, cuja demonstração está no final desta seção.

Proposição 4.1

$$\text{Para todo } x > 0, (1 + x) \ln(1 + x) - x \geq \frac{3x^2}{6 + 2x} = \frac{x^2}{2(1 + x/3)}.$$

Como o limitante superior de (4.19) é igual a $\exp(-((1 + \varepsilon) \ln(1 + \varepsilon) - \varepsilon)\mathbb{E}X)$, a proposição dá

$$\mathbb{P}[X \geq (1 + \varepsilon)\mathbb{E}X] \leq \exp\left(-\frac{\varepsilon^2 \mathbb{E}X}{2(1 + \varepsilon/3)}\right) \leq \exp\left(-\frac{\varepsilon^2 \mathbb{E}X}{3}\right), \quad (4.20)$$

em que a segunda desigualdade vale se $2(1 + \varepsilon/3) \leq 3$, isto é, se $\varepsilon \leq 3/2$. Em particular, vale para $0 < \varepsilon \leq 1$.

Para o limitante inferior, seja $h(x) := f(-x\hat{p})$, com $0 \leq x < 1$.
Então $h(0) = 0$, $h'(x) = -\hat{p} f'(-x\hat{p})$, $h'(0) = 0$ e

$$h''(x) = \hat{p}^2 f''(-x\hat{p}) = \frac{\hat{p}^2}{(\hat{p} - x\hat{p})(\hat{q} + x\hat{p})} = \frac{\hat{p}}{(1-x)(\hat{q} + \hat{p}x)} \geq \frac{\hat{p}}{1-x} \geq \hat{p},$$

pois $\hat{q} + \hat{p}x \leq \hat{q} + \hat{p} = 1$. Portanto, pela fórmula de Taylor com resto,
 $h(x) \geq \hat{p}x^2/2$. Por (4.17) com $t = \varepsilon\hat{p} < \hat{p}$,

$$\begin{aligned} \mathbb{P}[X \leq (1-\varepsilon)\mathbb{E}X] &= \mathbb{P}[X \leq (\hat{p} - \varepsilon\hat{p})n] \\ &\leq \exp(-h(\varepsilon) \cdot n) \leq \exp\left(-\frac{\hat{p}\varepsilon^2 n}{2}\right) = \exp\left(-\frac{\varepsilon^2 \mathbb{E}X}{2}\right) \end{aligned}$$

para todo $\varepsilon \in (0, 1)$.

Reunindo os resultados acima, a partir do Corolário 4.1, de (4.20) e do limitante anterior, escrevemos o teorema a seguir.

Teorema 4.5: Chernoff para somas de Bernoulli

Se $X_i \sim \text{Bernoulli}(p_i)$ são independentes com $p_i \in [0, 1]$ e $X = \sum_{i=1}^n X_i$, então

1. para todo $t > 0$,

$$\mathbb{P}[|X - \mathbb{E}X| \geq t] \leq 2 \exp\left(\frac{-2t^2}{n}\right); \quad (4.21)$$

2. para todo $0 < \varepsilon \leq 1$,

$$\mathbb{P}[X \geq (1+\varepsilon)\mathbb{E}X] \leq \exp\left(-\frac{\varepsilon^2 \mathbb{E}X}{3}\right); \quad (4.22)$$

3. para todo $0 < \varepsilon < 1$,

$$\mathbb{P}[X \leq (1-\varepsilon)\mathbb{E}X] \leq \exp\left(-\frac{\varepsilon^2 \mathbb{E}X}{2}\right). \quad (4.23)$$

Além disso, para todo $\varepsilon > 0$,

$$\mathbb{P}[X \geq (1+\varepsilon)\mathbb{E}X] \leq \exp\left(-\frac{\varepsilon^2 \mathbb{E}X}{(2+\varepsilon)}\right).$$

O item 1 é o Corolário 4.1 com t/n no lugar de t . Os casos $\hat{p} \in \{0, 1\}$, excluídos acima, são triviais, pois X é constante. A última afirmação segue de (4.20), já que $2(1+\varepsilon/3) \leq 2+\varepsilon$.

Observação 7. Na prática podemos ter apenas uma estimativa $0 < \alpha \leq \mathbb{E}X \leq \beta$ para a esperança. Então, para todo $t \in (0, 1)$,

$$\mathbb{P}[X \geq (1+t)\beta] \leq \exp\left(-\frac{t^2\beta}{3}\right) \quad \text{e} \quad \mathbb{P}[X \leq (1-t)\alpha] \leq \exp\left(-\frac{t^2\alpha}{2}\right).$$

Para a primeira, acrescentamos a X novas variáveis de Bernoulli independentes ($k = \lceil \beta - \mathbb{E}X \rceil$ variáveis, cada uma com probabilidade $(\beta - \mathbb{E}X)/k$), de modo que a esperança total seja exatamente β , obtendo $X' \geq X$ com $\mathbb{E}X' = \beta$; então $\mathbb{P}[X \geq (1+t)\beta] \leq \mathbb{P}[X' \geq (1+t)\mathbb{E}X']$ e basta usar o item 2 do Teorema. Para a segunda, tomamos $c = \alpha/\mathbb{E}X \leq 1$ e $B_i \sim \text{Bernoulli}(c)$ independentes entre si e das X_i ; então $X'_i = X_i B_i \sim \text{Bernoulli}(cp_i)$ são independentes, $X'' = \sum_i X'_i \leq X$ e $\mathbb{E}X'' = \alpha$, logo $\mathbb{P}[X \leq (1-t)\alpha] \leq \mathbb{P}[X'' \leq (1-t)\mathbb{E}X'']$ e basta usar o item 3.

Demonstração da Proposição 4.1. Seja $\varphi(x) = (1+x)\ln(1+x) - x - \frac{3x^2}{6+2x}$, para $x \geq 0$. Então $\varphi(0) = 0$,

$$\varphi'(x) = \ln(1+x) - \frac{3x(6+x)}{2(3+x)^2}, \quad \varphi''(x) = \frac{1}{1+x} - \frac{27}{(3+x)^3},$$

e $\varphi'(0) = 0$. Como $(3+x)^3 = 27 + 27x + 9x^2 + x^3 \geq 27(1+x)$, temos $\varphi''(x) \geq 0$. Logo φ' é não decrescente, $\varphi' \geq \varphi'(0) = 0$, e portanto φ é não decrescente, $\varphi \geq \varphi(0) = 0$. $\square$

4.6 Soma de variáveis aleatórias geométricas

Vamos derivar uma desigualdade do tipo Chernoff para soma de variáveis aleatórias com distribuição geométrica. Diferentemente das seções anteriores, essas variáveis são ilimitadas, e a FGM só é finita para $s < \ln 2$ (Exemplo 4.2); como o método só usa $s > 0$, basta trabalhar com $0 < s < \ln 2$.

Sejam $X_i \sim \text{Geom}(1/2)$, para $1 \leq i \leq n$, variáveis aleatórias independentes, e $X := \sum_{i=1}^n X_i$. Pelo Exemplo 4.2 com $p = 1/2$, $\mathbb{E}X = 2n$ e, para $0 < s < \ln 2$,

$$\mathbb{E}e^{sX} = \prod_{i=1}^n \mathbb{E}e^{sX_i} = \left(\frac{e^s}{2 - e^s} \right)^n.$$

Usando a desigualdade (4.1) com $t = (2+a)n$, para qualquer $a > 0$, temos

$$\mathbb{P}[X \geq (2+a)n] \leq e^{-s(2+a)n} \left(\frac{e^s}{2 - e^s} \right)^n = \left(\frac{e^{-(1+a)s}}{2 - e^s} \right)^n.$$

Minimizamos o logaritmo da base, $-(1+a)s - \ln(2 - e^s)$, que é convexo em s (sua segunda derivada é $2e^s/(2 - e^s)^2 > 0$). Seu ponto crítico satisfaz $-(1+a) + e^s/(2 - e^s) = 0$, isto é, $e^s = 2(1+a)/(2+a) = 1 + a/(2+a) \in (1, 2)$, logo $s = \ln(1 + a/(2+a)) \in (0, \ln 2)$ é o mínimo, e nele, para todo $a > 0$

$$\mathbb{P}[X \geq (2+a)n] \leq \left(\left(1 + \frac{a}{2}\right) \left(1 - \frac{a}{2+2a}\right)^{1+a} \right)^n. \quad (4.24)$$

Usando que $1 - x \leq \exp(-x)$, para todo x ,

$$\left(1 - \frac{a}{2+2a}\right)^{1+a} \leq e^{-a/2},$$

e que $1 + a/2 \leq \exp(a/4)$ para $a \geq 6$ (a função $\varphi(a) = a/4 - \ln(1 + a/2)$ é não decrescente para $a \geq 2$, pois $\varphi'(a) = 1/4 - 1/(2+a) \geq 0$, e $\varphi(6) = 3/2 - \ln 4 > 0$),

$$\left(1 + \frac{a}{2}\right)^n \leq e^{an/4}.$$

Finalmente, para todo $a \geq 6$ vale que $\mathbb{P}[X \geq (2+a)n] \leq \exp(-an/4)$. Como $(2+a)n = (1+a/2)\mathbb{E}X$, fazendo $t = a/2$ obtemos o teorema a seguir.

Teorema 4.6: Chernoff para v.a. geométrica padrão

Sejam $X_i \sim \text{Geom}(1/2)$, para $1 \leq i \leq n$, variáveis aleatórias independentes e $X = \sum_{i=1}^n X_i$. Então

$$\mathbb{P}[X \geq (1+t)\mathbb{E}X] \leq \exp\left(-\frac{tn}{2}\right) \quad (4.25)$$

para todo $t \geq 3$. □

A cota exata (4.24) vale para todo $a > 0$; o enunciado simplificado exige $t \geq 3$ apenas por causa da passagem $1 + a/2 \leq \exp(a/4)$.

4.7 Amplificação de probabilidade em algoritmos de Monte Carlo

Um algoritmo de Monte Carlo A tem erro bilateral no máximo $\varepsilon < 1/2$ se, para toda entrada w ,

$$\mathbb{P}[A \text{ responde errado}] \leq \varepsilon < \frac{1}{2},$$

isto é, A pode responder *sim* quando a resposta correta é *não* e vice-versa. Queremos, dado $\delta \in (0, 1)$, um algoritmo com erro menor que δ .

Dada a entrada w , executamos k vezes o algoritmo A sobre w , cada uma com sorteios novos e independentes das anteriores, e respondemos a resposta que aparecer mais vezes (em caso de empate, qualquer uma).

Teorema 4.7: Amplificação por maioria

Se A tem erro bilateral no máximo $\varepsilon < 1/2$, então, para toda

entrada w e todo $k \geq 1$, em k rodadas independentes

$$\mathbb{P}[\text{resposta errada}] \leq \exp\left(-\frac{k(1-2\varepsilon)^2}{2}\right). \quad (4.26)$$

Em particular, para todo $\delta \in (0, 1)$, se

$$k > \frac{2}{(1-2\varepsilon)^2} \ln \frac{1}{\delta}, \quad (4.27)$$

então k rodadas de A erra com probabilidade menor que δ .

Demonstração. Fixe w e seja Z_j o indicador de que a j -ésima execução erra. As Z_j são independentes (sorteios novos a cada execução), com $Z_j \sim \text{Bernoulli}(q)$ e $q := \mathbb{P}[A(w) \text{ erra}] \leq \varepsilon$. Seja $Z = \sum_{j=1}^k Z_j$ o número de execuções erradas, de modo que $\mu := \mathbb{E}Z = qk$.

Se menos da metade das execuções erra, isto é, se $Z < k/2$, então a resposta correta aparece mais de $k/2$ vezes e vence a votação. Portanto,

$$[A(w) \text{ } k \text{ em rodadas, erra}] \subseteq [Z \geq k/2].$$

Escreva $k/2 = \mu + t$, com

$$t = \frac{k}{2} - qk = k\left(\frac{1}{2} - q\right) \geq k\left(\frac{1}{2} - \varepsilon\right) > 0.$$

Pela desigualdade de Chernoff–Hoeffding (Teorema 4.4), com as variáveis $Z_j \in [0, 1]$,

$$\mathbb{P}[Z \geq \mu + t] \leq \exp\left(-\frac{2t^2}{k}\right) \leq \exp\left(-2k\left(\frac{1}{2} - \varepsilon\right)^2\right) = \exp\left(-\frac{k(1-2\varepsilon)^2}{2}\right),$$

em que a segunda desigualdade usa $t \geq k(1/2 - \varepsilon)$. Isso prova (4.26).

Se vale (4.27), então o expoente é menor que $-\ln(1/\delta)$, e o erro é menor que δ . $\square$

Duas observações sobre o enunciado. Primeiro, o número de repetições é $k = O(\ln(1/\delta))$ quando ε é uma constante menor que $1/2$: o erro decai *exponencialmente* em k , e o custo cresce só com o *logaritmo* do erro desejado. O tempo total é k vezes o tempo de A . Segundo, a folga $\gamma := 1/2 - \varepsilon$ em relação a $1/2$ é essencial: o número de repetições é proporcional a $1/\gamma^2$, de modo que $\varepsilon = 1/2 - 1/\text{poly}(n)$ ainda pode ser amplificado com um número polinomial de repetições, enquanto com $\varepsilon = 1/2$ (o algoritmo não é melhor que uma moeda) não há como amplificar.

Exemplo 4.4: Monte Carlo com erro 1/3

Com $\varepsilon = 1/3$ temos $(1 - 2\varepsilon)^2 = 1/9$, e (4.27) pede $k > 18 \ln(1/\delta)$.

- Para $\delta = 2^{-100}$, $18 \ln(2^{100}) \approx 1247,7$, então $k = 1248$ repetições bastam.
- Para $\delta = n^{-c}$, o número de repetições é $k > 18c \ln n$, isto é, $O(\log n)$. Assim, um algoritmo com erro 1/3 vira um algoritmo com erro $1/\text{poly}(n)$ ao custo de um fator $O(\log n)$ no tempo. $\diamond$

A cota exata. Quando ε é pequeno, a cota (4.26) desperdiça muito, pois a desigualdade de Hoeffding não distingue erros pequenos de erros próximos de 1/2. A cota exata do Lema 4.2 (cuja prova é a mesma do método de Chernoff, sem as simplificações) dá mais. Com $\hat{p} = q$, $n = k$ e $t = 1/2 - q$, temos $\hat{p} + t = \hat{q} - t = 1/2$ e

$$\mathbb{P}[Z \geq k/2] \leq \left(\left(\frac{q}{1/2} \right)^{1/2} \left(\frac{1-q}{1/2} \right)^{1/2} \right)^k = (4q(1-q))^{k/2} \leq (4\varepsilon(1-\varepsilon))^{k/2},$$

pois $q \mapsto 4q(1-q)$ é crescente em $[0, 1/2]$ e $q \leq \varepsilon$ (para $q = 0$ o erro é nulo). Como $4\varepsilon(1-\varepsilon) = 1 - (1-2\varepsilon)^2 \leq \exp(-(1-2\varepsilon)^2)$, essa cota implica (4.26), e dá o número de repetições

$$k > \frac{2 \ln(1/\delta)}{\ln(1/(4\varepsilon(1-\varepsilon)))}.$$

Por exemplo, com $\varepsilon = 1/3$ a base é 8/9 e $k > 16,98 \ln(1/\delta)$ (em vez de 18); com $\varepsilon = 0,01$, a cota exata pede $k > 0,62 \ln(1/\delta)$, contra $2,08 \ln(1/\delta)$ de (4.27).

Observação 8. • A votação só usa que a resposta correta é única. Para problemas com mais de duas respostas possíveis vale o mesmo argumento: se $Z < k/2$, a resposta correta aparece mais de $k/2$ vezes e é a mais frequente.

- Se o algoritmo devolve um número $\tilde{x}$ com $\mathbb{P}[|\tilde{x} - x| \leq \eta] \geq 1 - \varepsilon$, devolva a mediana das k execuções. Se menos da metade das execuções está fora de $[x - \eta, x + \eta]$, a mediana está dentro, e a análise é a mesma, com o mesmo número de repetições. É o chamado “truque da mediana”.
- Em termos de classes de complexidade, o teorema mostra que a constante 1/3 na definição de BPP é arbitrária: qualquer constante em $(0, 1/2)$ define a mesma classe, e o erro pode ser reduzido até $2^{-\text{poly}(n)}$.

4.8 Quicksort

Vimos duas estratégias de que o *quicksort* aleatorizado executa $O(n \ln n)$ comparações com alta probabilidade, usando propriedades de distribuições conhecidas e usando desigualdades para desvios da média (Markov e Chebyshev). Nessas últimas provas a probabilidade de falha obtida é fraca: apenas $O(1/n)$ com a desigualdade de Markov, que é a melhor delas. Nesta seção obtemos uma cota de falha muito mais forte — polinomialmente pequena em qualquer grau desejado — usando a desigualdade de Chernoff.

Preliminares. Relembramos a montagem já estabelecida. Um particionamento de S é um *sucesso* se $\min\{|S_E|, |S_D|\} \geq |S|/10$; a probabilidade de sucesso é $p > 0,76$, qualquer que seja o histórico anterior. um elemento fixo x_i participa de no máximo $\ell := \lfloor \log_{10/9} n \rfloor$ particionamentos; temos $\log_{10/9} n \approx 9,49 \ln n$, logo $\ell < 10 \ln n$.

A sequência de particionamentos de x_i é completada com particionamentos *fictícios* após o fim de sua participação real, cada um com sucesso de probabilidade exatamente 0,76, independentemente do passado. Isso produz uma sequência infinita em que, a cada posição, a probabilidade condicional de sucesso é sempre pelo menos 0,76.

Como antes, se M_i denota o número de particionamentos reais de que x_i participa, vale $X_i \leq M_i$, pois x_i é comparado com o pivô uma única vez por particionamento real do qual participa sem ser o pivô.

Dominação estocástica. Fixe uma constante $c > 10$, a ser escolhida mais adiante, e defina

$$L := c \ln n$$

(mais precisamente $\lceil c \ln n \rceil$, o que altera apenas constantes aditivas que são irrelevantes na análise). Seja B o número de sucessos entre os L primeiros particionamentos da sequência completada de x_i . Pelo Lema 3.1(a), com $\alpha = 0,76$ e $m = L$ tentativas,

$$B \succeq \text{Binomial}(L, 0,76).$$

Denotando por $F := L - B$ o número de *fracassos* entre esses L particionamentos, para todo t ,

$$\begin{aligned} \mathbb{P}[F \geq t] &= \mathbb{P}[B \leq L - t] \leq \mathbb{P}[\text{Binomial}(L, 0,76) \leq L - t] \\ &= \mathbb{P}[\text{Binomial}(L, 0,24) \geq t]. \end{aligned}$$

Tome $G \sim \text{Binomial}(L, 0,24)$, o número de fracassos de uma binomial com parâmetro de sucesso 0,76 (ou 0,24, trocando os papéis). Note que $\mathbb{E}G = 0,24 L = 0,24 c \ln n$.

O evento “muitos particionamentos”. Suponha $M_i > L$. Então os L primeiros particionamentos da sequência completada de x_i são todos reais (pois x_i ainda não saiu do processo), e, pelo Exercício 13, contêm no máximo $\ell < 10 \ln n$ sucessos. Logo, supondo $c > 10$, o número de fracassos é

$$F = L - B \geq L - \ell > c \ln n - 10 \ln n = (c - 10) \ln n.$$

Combinando essa implicação com a dominação estocástica da seção anterior, obtemos a cadeia

$$\mathbb{P}[M_i > L] \leq \mathbb{P}[F \geq (c - 10) \ln n] \leq \mathbb{P}[G \geq (c - 10) \ln n],$$

onde o primeiro “ $\leq$ ” é a implicação determinística recém-obtida e o segundo vem da dominação estocástica de B .

Cota de Chernoff. Usamos a seguinte forma da desigualdade de Chernoff para a cauda superior de uma soma de Bernoulli independentes.

Teorema 4.8: Desigualdade de Chernoff

Se G é soma de variáveis de Bernoulli independentes, $\mu = \mathbb{E}G$ e $\delta > 0$, então

$$\mathbb{P}[G \geq (1 + \delta)\mu] \leq \exp\left(\frac{-\delta^2\mu}{2 + \delta}\right).$$

No nosso caso, $G \sim \text{Binomial}(L, 0,24)$ é soma de L Bernoulli independentes, com $\mu = 0,24 c \ln n$. Queremos aplicar o teorema com $(1 + \delta)\mu = (c - 10) \ln n$, isto é,

$$1 + \delta = \frac{c - 10}{0,24 c}, \quad \delta = \frac{0,76 c - 10}{0,24 c}.$$

Para que $\delta > 0$ (hipótese do teorema), precisamos $c > 10/0,76 \approx 13,16$; assumimos isso daqui em diante (condição mais restritiva que $c > 10$, já suposta acima).

Substituindo $\mu = 0,24 c \ln n$ e o δ no limitantes exponencial do teorema,

$$\delta^2\mu = \frac{(0,76 c - 10)^2}{(0,24 c)^2} \cdot 0,24 c \ln n = \frac{(0,76 c - 10)^2}{0,24 c} \ln n,$$

e

$$2 + \delta = \frac{2 \cdot 0,24 c + (0,76 c - 10)}{0,24 c} = \frac{1,24 c - 10}{0,24 c}.$$

Dividindo,

$$\frac{\delta^2\mu}{2 + \delta} = \frac{(0,76 c - 10)^2}{0,24 c} \cdot \frac{0,24 c}{1,24 c - 10} \ln n = \frac{(0,76 c - 10)^2}{1,24 c - 10} \ln n.$$

Definindo

$$b := \frac{(0,76c - 10)^2}{1,24c - 10}$$

a desigualdade de Chernoff dá

$$\mathbb{P}[G \geq (c - 10) \ln n] \leq n^{-b},$$

e, pela cadeia de implicações da seção anterior,

$$\mathbb{P}[M_i > c \ln n] \leq n^{-b} \quad \text{para cada } i.$$

Observação 9 (Dependência de δ, μ, b em c). Note que $\delta = \delta(c)$ satura: quando $c \rightarrow \infty$, temos $\delta(c) \rightarrow 19/6$. Também, $2 + \delta \rightarrow 31/6$, logo para $b = b(c)$

$$\frac{\delta^2 \mu}{(2 + \delta) \ln n} \sim \frac{(19/6)^2}{31/6} \cdot 0,24c = \frac{361}{186} \cdot 0,24c \approx 0,4658c \xrightarrow{c \rightarrow \infty} \infty.$$

Alguns valores, para ilustrar o crescimento:

$$b(20) \approx 1,83, \quad b(30) \approx 6,02, \quad b(50) \approx 15,08, \quad b(100) \approx 38,21.$$

Pela união sobre os n elementos de S ,

$$\mathbb{P}[\exists i : M_i > c \ln n] \leq n \cdot n^{-b} = n^{1-b}.$$

Em particular, $\mathbb{P}[\exists i : M_i > 30 \ln n] \leq n \cdot n^{-b} < n^5$.

Dado qualquer $a > 0$ desejado para o expoente final da probabilidade de falha, basta escolher c de modo que $b(c) \geq a + 1$. Escrevendo $K := a + 1$ e expandindo $b(c) = K$,

$$(0,76c - 10)^2 = K(1,24c - 10) \iff 0,5776c^2 - (15,2 + 1,24K)c + (100 + 10K) = 0,$$

cuja raiz positiva relevante (a maior das duas) é

$$c = \frac{(15,2 + 1,24K) + \sqrt{(15,2 + 1,24K)^2 - 4 \cdot 0,5776(100 + 10K)}}{2 \cdot 0,5776}.$$

Como $b(c) \rightarrow \infty$ quando $c \rightarrow \infty$, essa equação sempre admite solução real para qualquer $K > 0$, isto é, para qualquer $a > 0$ desejado. Por exemplo, $a = 6$ (logo $K = 7$) dá $c \approx 32,2$; conferindo, $b(32,2) \approx 7,00 = K$, como esperado. Com essa escolha,

$$\mathbb{P}[\exists i : M_i > c \ln n] < n^{-a}.$$

Concluindo, fixada a constante c (e, portanto, a) como acima, com probabilidade pelo menos $1 - n^{-a}$ vale $X_i \leq M_i \leq c \ln n$ para todo $i \in \{1, \dots, n\}$. Como cada comparação com um pivô é contabilizada uma única vez, pelo elemento não-pivô envolvido,

$$T = \sum_{i=1}^n X_i \leq c \cdot n \cdot \ln n = O(n \ln n).$$

Somando as $O(n)$ comparações realizadas pela ordenação por força bruta nas folhas da recursão, concluímos que o número total de comparações do *quicksort* aleatorizado é

$$T = O(n \ln n) \quad \text{com probabilidade } 1 - O(n^{-a}),$$

onde $a > 0$ é uma constante que pode ser escolhida livremente, ao custo de uma constante multiplicativa maior (via c) escondida no $O(n \ln n)$.

4.9 Exercícios

Exercício 24. Reescreva a prova do Teorema 4.7 usando, no lugar do Teorema 4.4, o item 2 do Teorema 4.5 (cota multiplicativa) com $\mathbb{E}Z \leq \varepsilon k$. Que cota você obtém, e por que ela é pior quando ε está próximo de $1/2$?

Exercício 25. Seja X uma variável aleatória com $\text{Var}(X) = 0$ (em particular, quadrado integrável). Prove que $\mathbb{P}[X = \mathbb{E}X] = 1$. (Dica: use a desigualdade de Chebyshev para mostrar que $\mathbb{P}[|X - \mathbb{E}X| \geq 1/k] = 0$ para todo inteiro $k \geq 1$, e a subaditividade para a união enumerável sobre k .)

Exercício 26. Seja X uma variável aleatória quadrado integrável com $\text{Var}(X) > 0$. Calcule a esperança e a variância da variável aleatória

$$Y := \frac{X - \mathbb{E}X}{\sqrt{\text{Var}(X)}}.$$

Exercício 27. Prove que, se X e Y são variáveis aleatórias simples e $M_X(s) = M_Y(s)$ para todo $s \in \mathbb{R}$, então X e Y têm a mesma distribuição.

(Dica: sejam $a_1 < \dots < a_m$ os valores possíveis de X ou de Y e $c_j = \mathbb{P}[X = a_j] - \mathbb{P}[Y = a_j]$. Então $\sum_{j=1}^m c_j e^{a_j s} = 0$ para todo s . Se algum $c_j \neq 0$, tome o maior j com essa propriedade, divida por $e^{a_j s}$ e faça $s \rightarrow \infty$.)

Observação. O resultado vale, mais geralmente, para variáveis cuja FGM é finita em algum intervalo $(-x_0, x_0)$ com $x_0 > 0$ (veja, por exemplo, Billingsley 1995); essa hipótese não pode ser retirada: se X tem densidade $\frac{1}{2}|x|^{-3}$ em $|x| \geq 1$, então X e $2X$ têm FGM igual a $+\infty$ para todo $s \neq 0$, mas distribuições diferentes.

Exercício 28. Prove que se $X_1, \dots, X_n$ são variáveis aleatórias independentes com distribuição de Rademacher e $t \in (0, 1)$, então

$$\mathbb{P}\left[\frac{1}{n} \sum_{i=1}^n X_i \geq t\right] \leq \exp\left(-\frac{n}{2}((1+t) \ln(1+t) + (1-t) \ln(1-t))\right). \quad (4.28)$$

(Dica: para $s > 0$, aplique a desigualdade de Markov a $e^{s \sum_i X_i}$ e use $\mathbb{E}e^{sX_i} = \cosh s$ para obter $\mathbb{P}[\sum_i X_i \geq nt] \leq (\cosh(s) e^{-st})^n$. Depois minimize $f(s) = \cosh(s) e^{-st}$ em $s > 0$ usando técnicas de Cálculo Diferencial: mostre que o ponto crítico satisfaz $\tanh s = t$ e que então $\cosh s = (1 - t^2)^{-1/2}$.)

Exercício 29. Seja $g(t) = (1+t) \ln(1+t) + (1-t) \ln(1-t)$ para $t \in [0, 1)$. Mostre que $g(t) \geq t^2$ (dica: $g(0) = g'(0) = 0$ e $g''(t) = 2/(1-t^2)$) e conclua que o lado direito de (4.28) é no máximo $e^{-nt^2/2}$. Compare com o Teorema 4.3.

Exercício 30. Dizemos que X é uma (ε, δ) -aproximação para a quantidade V se $\mathbb{P}[|X - V| \leq \varepsilon V] \geq 1 - \delta$. Sejam $X_1, \dots, X_m$ variáveis aleatórias independentes com valores em $[0, 1]$ e $\mathbb{E}X_i = \mu > 0$ para todo i . Denotemos por $\bar{X}_m$ a média amostral, $\bar{X}_m = (1/m) \sum_{i=1}^m X_i$. Prove que, para $0 < \varepsilon \leq 1$, se $m \geq 3 \ln(2/\delta) / (\varepsilon^2 \mu)$ então

$$\mathbb{P}[|\bar{X}_m - \mu| \geq \varepsilon \mu] \leq \delta \quad (4.29)$$

e conclua, passando ao evento complementar, que a média amostral é uma (ε, δ) -aproximação para μ .

Exercício 31. (Karp e Luby, 1983) Suponha que sejam dados conjuntos finitos $S_1, S_2, \dots, S_n$ com cardinalidades conhecidas e tais que seja possível sortear elementos uniformemente de cada S_i e testar em tempo constante se $x \in S_i$. O algoritmo a seguir estima a cardinalidade da união desses conjuntos. Defina $\text{cob}(x) := |\{i : x \in S_i\}|$ e $s := \sum_{i=1}^n |S_i|$.

Instância: conjuntos $S_1, S_2, \dots, S_n$.

Resposta: uma estimativa para $|S_1 \cup S_2 \cup \dots \cup S_n|$.

1 escolha $T \in_{\mathcal{D}} \{S_1, S_2, \dots, S_n\}$ de acordo com a lei

$$\mathcal{D}(S_i) = |S_i|/s$$

2 $x \leftarrow_R T$

3 compute $\text{cob}(x)$

4 $X \leftarrow \frac{s}{\text{cob}(x)}$

5 **responda** X .

Algoritmo 1: Algoritmo de Karp–Luby

Prove que $\mathbb{E}X = |\bigcup_{i=1}^n S_i|$ e que $\text{Var}(X) \leq (n-1)\mathbb{E}(X)^2$.

Exercício 32. Sejam $X_1, X_2, \dots, X_m$ as respostas de m rodadas independentes do Algoritmo 1 com a mesma entrada, $\bar{X}_m$ a média amostral dessas rodadas e $V = |\bigcup_{i=1}^n S_i|$. Seja $0 < \varepsilon \leq 1$.

(a) Prove que, se $n \geq 3$ e $m \geq (9/2)(n-1)(1/\varepsilon^2) \ln(2/\delta)$, então $\bar{X}_m$

é uma (ε, δ) -aproximação para V . *Dica:* aplique o Exercício 1 às variáveis X_i/s e use que $s \leq nV$.

- (b) Usando a desigualdade de Chebyshev e o Exercício 2, prove que se $m \geq (n-1)/(\varepsilon^2\delta)$ então $\bar{X}_m$ é uma (ε, δ) -aproximação para V . Note que essa cota vale para todo $n \geq 2$, mas depende de $1/\delta$ e não de $\ln(1/\delta)$.

Exercício 33 (Truque da mediana). Para recuperar a dependência logarítmica em δ no Exercício 32 item (b), proceda assim:

- (a) Tome $m_0 = \lceil 4(n-1)/\varepsilon^2 \rceil$ e mostre, por (b) com $\delta = 1/4$, que a média de m_0 rodadas é uma $(\varepsilon, 1/4)$ -aproximação para V .
- (b) Repita o procedimento de (i) de forma independente k vezes, obtendo $Y_1, \dots, Y_k$, e seja Y a mediana desses valores. Chame Y_j de *ruim* se $|Y_j - V| > \varepsilon V$ e seja N o número de Y_j ruins. Mostre que $N < k/2$ implica $|Y - V| \leq \varepsilon V$.
- (c) Use o limitante de Chernoff (cauda superior, com $\mathbb{E}N \leq k/4$) para mostrar que $\mathbb{P}[N \geq k/2] \leq e^{-k/12}$ e conclua que, para $k \geq 12 \ln(1/\delta)$, Y é uma (ε, δ) -aproximação para V usando $O((n/\varepsilon^2) \ln(1/\delta))$ rodadas do Algoritmo 1.