6.4 *Hashing 2-independente*

Vimos (Seção 6.2) que, numa *família universal*, dois elementos distintos colidem com probabilidade no máximo $1/|N|$. Isso basta para as estatísticas que dependem apenas de colisões aos pares: os limites esperados são os mesmos de uma função de *hash* totalmente aleatória. Vimos também que essas famílias podem ser pequenas, com funções fáceis de calcular e de descrever (Exemplo 6.2).

Obter famílias assim, pequenas e eficientes, mas com o comportamento aleatório de que precisamos, é um problema recorrente na teoria da computação e central no estudo da desaleatorização.

Neste capítulo, usaremos a ***independência par a par*** para dizer o que significa "comportar-se como uma função aleatória". Trata-se de uma propriedade da família, e não de uma função isolada.

Para uma família $\mathcal{H} = \{ h_\lambda \in N^U : \lambda \in \Lambda \}$, pedimos que cada h_λ seja eficiente de calcular e de descrever, que $|\Lambda|$ seja pequeno e que as variáveis aleatórias

$$H_x(\lambda) \coloneqq h_\lambda(x) \qquad (x \in U)$$

satisfaçam a propriedade de independência definida a seguir. A exigência sobre $|\Lambda|$ tem um motivo concreto: sortear $\lambda \in_R \Lambda$ custa $\log |\Lambda|$ bits aleatórios, contra cerca de $|U| \log |N|$ para uma função totalmente aleatória.

Definição 6.1: família 2-independente de funções

Uma família $\mathcal{H} = \{ h_\lambda \in N^U : \lambda \in \Lambda \}$, com $|U| \geqslant |N| \geqslant 2$, munida da distribuição uniforme em Λ, é dita ***2-independente*** se

$$\mathop{\mathbb{P}}_{\lambda \in \Lambda} ([h_\lambda(x) = i] \cap [h_\lambda(y) = j]) = \frac{1}{|N|^2}, \tag{6.13}$$

para quaisquer $x, y \in U$ distintos e quaisquer $i, j \in N$.

Dado $x \in U$ e $i \in N$, tome qualquer $y \in U$ com $y \neq x$ (que existe pois $|U| \geqslant |N| \geqslant 2$). Como os eventos $[h_\lambda(y) = j]$, para $j \in N$, particionam Λ,

$$\begin{aligned} \mathbb{P}_{H_x}(i) &= \mathop{\mathbb{P}}_{\lambda \in \Lambda} [\, h_\lambda(x) = i \,] \\ &= \sum_{j \in N} \mathop{\mathbb{P}}_{\lambda \in \Lambda} ([h_\lambda(x) = i] \cap [h_\lambda(y) = j]) \\ &= \sum_{j \in N} \frac{1}{|N|^2} = \frac{1}{|N|} \end{aligned} \tag{6.14}$$

donde concluímos que cada H_x é uniforme em N. Logo, para $x \neq y$,

$$\mathop{\mathbb{P}}_{\lambda\in\Lambda}\big([H_x = i]\cap[H_y = j]\big) = \frac{1}{|N|}\cdot\frac{1}{|N|} = \mathbb{P}_{H_x}(i)\,\mathbb{P}_{H_y}(j),$$

isto é, $[H_x = i]$ e $[H_y = j]$ são eventos independentes em Λ. Assim, as variáveis H_x são independentes *par a par*. A definição não garante independência conjunta de três ou mais delas. Em particular, a probabilidade de colisão é *exatamente* a da função aleatória

$$\mathop{\mathbb{P}}_{\lambda\in\Lambda}[\,h_\lambda(x) = h_\lambda(y)\,] = \sum_{i\in N}\frac{1}{|N|^2} = \frac{1}{|N|}.$$

Como $\mathbb{P}[\,h(x) = h(y)\,] = 1/|N|$, toda família 2-independente é universal e, portanto, vale para ela tudo o que foi provado na seção anterior a partir apenas da linearidade da esperança e das probabilidades de colisão aos pares (tempo esperado de busca, número esperado de colisões, cota de Markov).

Quanto a terminologia

Na literatura, o termo "universal" (no sentido de Carter e Wegman (1979)) costuma significar $\mathbb{P}[\,h(x) = h(y)\,] \leqslant 1/|N|$ para $x \neq y$ ou, mais geralmente, $\mathbb{P}[\,h(x_1) = \cdots = h(x_k)\,] \leqslant 1/|N|^{k-1}$ para x_i's distintos.

A independência de pares da definição acima também é chamada de ***fortemente 2-universal***, e se generaliza para a k-independência: $\mathbb{P}\Big(\bigcap_{i=1}^{k}[h(x_i) = y_i]\Big) = 1/|N|^k$, para $x_1, \ldots, x_k \in U$ distintos e $y_1, \ldots, y_k \in N$ quaisquer.

A condição forte implica a simples, mas não vale a recíproca: o Exemplo 6.4 e a família linear $h(\mathsf{x}) = \mathsf{Ax}$ do exemplo da seção anterior (Exemplo 6.1) são universais, mas, como $h(\mathsf{0}) = \mathsf{0}$ sempre, não são 2-independentes.

Exemplo 6.4: uma família universal que não é 2-independente

Para $U = N = \{0, 1, \ldots, p-1\}$ com p primo, a família $\{\,h_a \in N^U : a \in U\,\}$ das funções dadas por

$$h_a(x) = (ax) \bmod p$$

onde uma escolha aleatória $a \in_{\mathrm{R}} U$ define unicamente uma função.

Dados $x \neq y$, temos $h_a(x) = h_a(y)$ se, e somente se, $a(x-y) \equiv 0 \pmod p$, o que, como p é primo, só ocorre para $a = 0$. Logo x e y colidem com probabilidade $1/p = 1/|N|$ e a família é *universal*. Essa família, porém, *não* é 2-independente: $h_a(0) = 0$ para todo a, de modo que H_0 não é uniforme, e, como há apenas p funções para p^2 pares (i, j), a probabilidade de $[H_x = i]\cap[H_y = j]$ nunca é $1/p^2$.

Exemplo 6.5: funções afins no $\mathbb{Z}_p$ formam família 2-independente

Para $U=N=\{0,1,\ldots,p-1\}$ com p primo, a família dada pelas funções afins $h_{a,b}(x)=(ax+b) \bmod p$, com $(a,b)\in U^2$, tem p^2 funções, cada uma descrita por $2\lceil \log p \rceil$ bits.
Dados $x\neq y$ e $i,j\in N$, o sistema

$$\begin{pmatrix} x & 1 \\ y & 1 \end{pmatrix} \begin{pmatrix} a \\ b \end{pmatrix} \begin{pmatrix} i \\ j \end{pmatrix} \pmod p$$

tem exatamente uma solução $(a,b)\in U^2$. Assim,

$$\mathbb{P}(\,[h_{a,b}(x)=i]\cap[h_{a,b}(y)=j]\,)=\frac{1}{p^2},$$

e a família é 2-independente.
Aqui $a=0$ é permitido, e isso a distingue da família $\mathcal{H}_{p,n}$ do Exemplo 6.2, onde $a\neq 0$ exclui os pares (i,i) e o resto módulo n destrói a uniformidade. Por outro lado, a independência é só de pares: há apenas p^2 funções para p^3 triplas de valores.

6.4.1 *Exemplo de uma família 2-independente*

Seja $\mathbb{F}$ um corpo finito[4] com q elementos e $d \geqslant 1$ um inteiro. Tomemos $U = \mathbb{F}^d$, $N = \mathbb{F}$ (de modo que $|N| = q$) e a família de funções de $\mathbb{F}^d$ em $\mathbb{F}$

$$\mathcal{H} := \left\{ h_{(\mathsf{a},b)}(\mathsf{x}) = \langle \mathsf{a},\mathsf{x}\rangle + b \colon \mathsf{a}\in\mathbb{F}^d,\ b\in\mathbb{F} \right\},$$

onde $\langle \mathsf{u},\mathsf{v}\rangle = \sum_{k=1}^{d} u_k v_k$ denota o produto escalar usual. Note que $\mathsf{a}=0$ é permitido.

Aqui $\Lambda = \mathbb{F}^d \times \mathbb{F}$, e uma escolha aleatória de função é dada por $(\mathsf{a},b)\in_{\mathrm{R}} \mathbb{F}^d\times\mathbb{F}$, isto é, sorteando $a_1,\ldots,a_d,b$ independentemente e uniformemente em $\mathbb{F}$.

Se $\mathsf{z}\neq 0$ então, para $\mathsf{a}\in_{\mathrm{R}}\mathbb{F}^d$ e qualquer $t\in\mathbb{F}$,

$$\mathbb{P}[\,\langle \mathsf{a},\mathsf{z}\rangle = t\,] = \frac{1}{q}, \tag{6.15}$$

pelo princípio da decisão adiada: tome k com $z_k\neq 0$ e sorteie primeiro os a_l com $l\neq k$. Então $\langle \mathsf{a},\mathsf{z}\rangle = t$ se, e somente se, $a_k = z_k^{-1}\big(t - \sum_{l\neq k} a_l z_l\big)$, que é um único valor de $\mathbb{F}$ e é sorteado com probabilidade $1/q$. Em particular, exatamente $q^d/q = q^{d-1}$ vetores $\mathsf{a}\in\mathbb{F}^d$ satisfazem $\langle \mathsf{a},\mathsf{z}\rangle = t$, pois a é uniforme nos q^d vetores de $\mathbb{F}^d$.

Dados $\mathsf{x}\neq\mathsf{y}$ em $\mathbb{F}^d$ e $i,j\in\mathbb{F}$, o evento

$$[\langle \mathsf{a},\mathsf{x}\rangle + b = i]\cap[\langle \mathsf{a},\mathsf{y}\rangle + b = j]$$

[4] Existe um corpo finito com q elementos se, e somente se, $q = p^n$, para algum primo p e algum inteiro $n \geqslant 1$. Além disso, esse corpo é único a menos de isomorfismo.

Em um corpo finito $\mathbb{F}$ a soma $1+1+\cdots+1$ precisa se anular em algum momento, e o menor número de parcelas para isso ocorrer é primo, senão haveria divisores de zero. Então $\mathbb{F}$ contém uma cópia de $\mathbb{Z}_p := \mathbb{Z}/p\mathbb{Z}$, e $\mathbb{F}$ é um espaço vetorial sobre $\mathbb{Z}_p$. Como $\mathbb{F}$ é finito, sua dimensão n sobre $\mathbb{Z}_p$ é finita, e portanto $|\,\mathbb{F}\,| = p^n$.

coincide com

$$[\langle \mathsf{a}, \mathsf{x}-\mathsf{y}\rangle = i-j] \cap [b = i - \langle \mathsf{a}, \mathsf{x}\rangle].$$

Como $\mathsf{x}-\mathsf{y} \neq 0$, pela equação (6.15) o primeiro evento tem probabilidade $1/q$. Fixado qualquer a, o segundo evento pede um valor determinado para b, que é independente de a e uniforme, logo com probabilidade $1/q$. Condicionando em a,

$$\mathbb{P}(\,[\langle \mathsf{a}, \mathsf{x}\rangle + b = i] \cap [\langle \mathsf{a}, \mathsf{y}\rangle + b = j]\,) = \sum_{\substack{\mathsf{a}: \\ \langle \mathsf{a}, \mathsf{x}-\mathsf{y}\rangle = i-j}} \frac{1}{q^d} \cdot \frac{1}{q} = q^{d-1} \cdot \frac{1}{q^{d+1}} = \frac{1}{q^2},$$

pois, como vimos acima, a soma tem q^{d-1} termos. Concluímos que $\mathcal{H}$ é 2-independente. Ela tem q^{d+1} funções, cada uma descrita por $(d+1)\lceil \log q \rceil$ bits, contra os q^d valores de uma função arbitrária de $\mathbb{F}^d$ em $\mathbb{F}$.

Para $d = 1$ e $\mathbb{F} = \mathbb{F}_p$ obtemos a família $h_{a,b}(x) = (ax + b) \bmod p$ do Exemplo 6.5.

No caso particular do exemplo acima com $\mathbb{F} = \mathbb{F}_2$ e $d = 2$, $\mathcal{H}$ é o conjunto das $2^3 = 8$ funções afins de $\{0,1\}^2$ em $\{0,1\}$, entre as $2^4 = 16$ funções possíveis. Cada função é dada por 3 bits, dos quais 2 são do parâmetro a e 1 do parâmetro b. Assim, sorteando 3 bits obtemos uma sequência de 4 bits, $h_{(\mathsf{a},b)}(00)$, $h_{(\mathsf{a},b)}(01)$, $h_{(\mathsf{a},b)}(10)$ e $h_{(\mathsf{a},b)}(11)$, cada bit com distribuição uniforme e dois a dois independentes (mas não mutuamente independentes: há só 8 sequências possíveis em 16). De fato, em $\mathbb{F}_2$ vale $h_{(\mathsf{a},b)}(11) = h_{(\mathsf{a},b)}(00) + h_{(\mathsf{a},b)}(01) + h_{(\mathsf{a},b)}(10)$, isto é, as sequências possíveis são exatamente as que têm soma par.

No caso $\mathbb{F} = \mathbb{F}_2$, com d qualquer, sorteando $d+1$ bits obtemos uma sequência de 2^d bits $h_{(\mathsf{a},b)}(\mathsf{x})$, para $\mathsf{x} \in \{0,1\}^d$, em que cada bit tem distribuição uniforme e os bits são dois a dois independentes. Essa sequência pode ser usada para a desaleatorização de algoritmos que usam bits aleatórios com independência dois a dois, como é o caso do algoritmo para achar cortes grandes em grafos (Algoritmo 6.1, página 163). Como há apenas 2^{d+1} sequências possíveis, basta testá-las todas: para um grafo com n vértices, tomando $d = \lceil \log_2 n \rceil$, são no máximo $4n$ sequências.

Concentração via Chebyshev Para $S \subseteq U$ fixo, de cardinalidade m, e $y \in N$, com $n := |N|$ e $c := m/n$, seja $Z := \sum_{x \in S} \mathbb{1}_{[H_x = y]} = |S \cap h_\lambda^{-1}(y)|$. Pela 2-independência, cada H_x é uniforme em N e os H_x são independentes dois a dois. Logo os indicadores $\mathbb{1}_{[H_x=y]}$ são Bernoulli de parâmetro $1/n$ e independentes dois a dois, de modo que $\mathbb{E}Z = m/n = c$ e, como só aparecem covariâncias de pares, a variância da soma é a soma das variâncias: $\mathrm{Var}(Z) = m \cdot \frac{1}{n}\left(1 - \frac{1}{n}\right) = c(1 - 1/n)$

(como em (6.8)). Pela desigualdade de Chebyshev, para todo $\varepsilon > 0$,

$$\mathbb{P}[\ |Z - c| > \varepsilon m\ ] \leqslant \frac{\mathrm{Var}(\,Z\,)}{\varepsilon^2 m^2} = \frac{(1/n)(1-1/n)}{\varepsilon^2 m},$$

e, pela cota da união sobre os n valores de y,

$$\mathbb{P}\big[\ \exists y \in N : |S \cap h_\lambda^{-1}(y)| > (\varepsilon + 1/n)m\ \big] \leqslant \frac{1-1/n}{\varepsilon^2 m} \leqslant \frac{1}{\varepsilon^2 m}.$$

Essa cota só é não trivial quando $\varepsilon^2 m > 1$, isto é, para $\varepsilon > 1/\sqrt{m}$, o que corresponde a desvios εm maiores que $\sqrt{m}$ em torno de c.

6.4.2 *Desaleatorização de corte grande em grafos*

Muitos problemas de otimização são NP-difíceis, o que quer dizer que, a menos que P = NP, não têm algoritmo eficiente que os resolva exatamente no pior caso. Há casos, no entanto, em que soluções próximas da ótima são razoavelmente boas.

Algoritmos aproximativos Para problemas de maximização, um ***algoritmo aproximativo*** é um algoritmo que encontra soluções próximas da ótima, para uma garantia $0 < \alpha \leqslant 1$ fixada: o valor devolvido pelo algoritmo é no máximo o valor ótimo OPT e pelo menos $\alpha \cdot \mathrm{OPT}$. Nesse caso dizemos que é uma ***α-aproximação***. Uma questão central é para quais valores de α podemos esperar um algoritmo de aproximação de tempo polinomial.

Os algoritmos aproximativos são muito estudados em teoria da computação pois, dentre outros fatos, podem levar a resultados surpreendentes. O problema MAX-CUT[5] é NP-difícil. O algoritmo abaixo é uma 1/2-aproximação aleatorizada, responde com um corte com pelo menos $m/2$ arestas em tempo esperado polinomial. Existem aproximações melhores. Entre elas, o algoritmo de Goemans e Williamson (1995) é um marco teórico: usa relaxação semidefinida e arredondamento por hiperplano aleatório para garantir uma razão de aproximação de pelo menos 87,8% do valor ótimo. Há, porém, limites teóricos: uma $(16/17 + \varepsilon)$-aproximação em tempo polinomial para MAX-CUT, para qualquer $\varepsilon > 0$, implica P = NP (Håstad, 2001).

[5] O problema computacional do corte máximo em grafos é o problema de otimização: dado um grafo G, determine um corte de cardinalidade $\max_S |\nabla(S)|$. A versão de decisão é NP-completa: dados um grafo G e um inteiro positivo k, existe S tal que $|\nabla(S)| \geqslant k$?

Corte grande em grafos Dado um grafo $G = (V, E)$, queremos determinar um corte com muitas arestas em G. Recordemos que o corte definido por $S \subseteq V$ em G é o conjunto das arestas com exatamente uma extremidade em S,

$$\nabla(S) = \{\, \{\, i, j \,\} \in E : i \in S \text{ e } j \in \overline{S} \,\}.$$

Assumimos, sem perda de generalidade, que $V = \{\, 1, 2, \ldots, n \,\}$ e escrevemos $m = |E|$.

Consideramos o espaço amostral $\Omega := \{0,1\}^n$ munido da medida uniforme, de modo que um subconjunto aleatório $S \subseteq V$ é identificado pelo ponto amostral $(x_1, \ldots, x_n) \in \Omega$: para cada vértice $i \in V$, se $x_i = 1$ então $i \in S$, senão $i \in \overline{S}$. O número de arestas no corte é a variável aleatória

$$|\nabla(S)| = \sum_{\{i,j\} \in E} \mathbb{1}_{[\{i,j\} \in \nabla(S)]}.$$

Temos $\{i,j\} \in \nabla(S)$ se, e somente se, $x_i \neq x_j$, o que ocorre com probabilidade $1/2$ para cada aresta. Pela linearidade da esperança,

$$\mathbb{E}|\nabla(S)| = \sum_{\{i,j\} \in E} \mathbb{P}\left[x_i \neq x_j \right] = \frac{m}{2}.$$

Se o valor médio do tamanho de um corte em G é $m/2$, então G deve conter um corte com pelo menos $m/2$ arestas.

Observe que a probabilidade $\mathbb{P}\left[x_i \neq x_j \right] = 1/2$ depende apenas da distribuição conjunta de *dois* bits: bastam bits uniformes e dois a dois independentes, um fato que usaremos mais adiante.

Podemos transformar esse resultado num algoritmo aleatorizado que determina um corte grande em G, isto é, um corte com pelo menos metade das arestas.

Algoritmo 6.1: $1/2$**-aproximação probabilística para MAX-CUT**

Instância: grafo G sobre os vértices $V = \{1, \ldots, n\}$ e com m arestas.
Resposta: $S \subseteq V$ tal que $\nabla(S)$ tem $\geqslant \frac{m}{2}$ arestas.

```
1 repita
2     para cada i ∈ {1,...,n} faça x_i ←R {0,1};
3     S ← {i : x_i = 1};
4     calcule |∇(S)|;
5 até que |∇(S)| ⩾ m/2
6 responda S.
```

As linhas 2 a 4 têm custo proporcional ao tamanho do grafo, $O(n+m)$. O número total de instruções executadas é uma variável aleatória que depende do número de rodadas do laço. Seja p a probabilidade de sucesso ($|\nabla(S)| \geqslant \frac{m}{2}$) em uma rodada. Como as rodadas são independentes, o número de rodadas até que ocorra um sucesso é uma variável aleatória $Z \sim \text{Geom}(p)$, cuja esperança é $\mathbb{E}Z = 1/p$.

Proposição 6.5: probabilidade de sucesso para o corte

Seja G um grafo com $m \geqslant 1$ arestas e seja p a probabilidade com que um subconjunto aleatório $S \subseteq V$ define um corte com pelo

menos $m/2$ arestas. Então

$$p \geqslant \frac{1}{m+2}.$$

Demonstração. Seja $X = |\nabla(S)|$ o número de arestas no corte e seja p_j a probabilidade de que $X = j$, de modo que $\sum_{j=0}^{m} p_j = 1$. Como visto acima, $\mathbb{E}X = m/2$, ou seja,

$$\frac{m}{2} = \mathbb{E}X = \sum_{j=0}^{m} j\, p_j. \tag{6.16}$$

Seja $M := \lceil m/2 \rceil - 1$, o maior inteiro estritamente menor que $m/2$; como $m \geqslant 1$, temos $0 \leqslant M < m/2 \leqslant m$. Como X é inteiro, $X \geqslant m/2$ se, e somente se, $X \geqslant M+1$: de fato, $X \geqslant m/2 > M$ implica $X \geqslant M+1$ e, reciprocamente, $X \geqslant M+1 \geqslant m/2$ pela maximalidade de M. Portanto

$$\sum_{j=0}^{M} p_j = 1 - p \qquad \text{e} \qquad \sum_{j=M+1}^{m} p_j = p. \tag{6.17}$$

Majorando j por M na primeira soma e por m na segunda,

$$\sum_{j=0}^{m} j\, p_j \leqslant M \sum_{j=0}^{M} p_j + m \sum_{j=M+1}^{m} p_j = M(1-p) + mp. \tag{6.18}$$

De (6.16), (6.17) e (6.18) deduzimos que

$$\frac{m}{2} \leqslant M(1-p) + mp, \qquad \text{isto é,} \qquad p\,(m-M) \geqslant \frac{m}{2} - M.$$

Como $m - M > 0$, segue que

$$p \geqslant \frac{m/2 - M}{m - M} = \frac{m - 2M}{2m - 2M}.$$

Como m e $2M$ são inteiros e $2M < m$, temos $m - 2M \geqslant 1$. Além disso, de $m/2 \leqslant M + 1$ deduzimos que $0 < 2m - 2M \leqslant m + 2$. Logo

$$p \geqslant \frac{m-2M}{2m-2M} \geqslant \frac{1}{2m-2M} \geqslant \frac{1}{m+2}. \qquad \square$$

Pela Proposição 6.5, a probabilidade p de que uma rodada tenha sucesso satisfaz

$$p \geqslant \frac{1}{m+2}$$

(a prova usa apenas $\mathbb{E}|\nabla(S)| = m/2$, $|\nabla(S)| \leqslant m$ e o fato de $|\nabla(S)|$ ser inteiro). Portanto, o número esperado de rodadas do laço é $\mathbb{E}Z \leqslant m+2$ e o custo esperado de uma execução do algoritmo é $O(m(m+n))$ para um grafo com n vértices e m arestas. (Se $m = 0$, qualquer corte serve e o algoritmo para na primeira rodada.)

A probabilidade de que o algoritmo realize pelo menos km rodadas até parar é

$$\mathbb{P}[\, Z \geqslant km \,] = (1-p)^{km-1} \leqslant \left(1 - \frac{1}{m+2}\right)^{km-1}$$

para todo inteiro $k \geqslant 1$. Para $k = m$ essa cota é menor que 0,00019 para todo grafo com $m \geqslant 10$ arestas e, para $m \geqslant 90$, é menor que 5×10^{-39}.

6.4.3 *Desaleatorização usando 2-independência*

O Algoritmo 6.1 sorteia n bits independentes, um por vértice. Mostramos que bastam $O(\log n)$ bits aleatórios e que, como o espaço amostral resultante é pequeno, podemos percorrê-lo inteiro, o que dá um algoritmo determinístico.

Retomemos o problema: dado $G = (V, E)$ com $V = \{1, \ldots, n\}$, $n \geqslant 2$, e $m = |E|$ arestas, queremos um corte com pelo menos $m/2$ arestas. Para $S \subseteq V$ definido por $(x_1, \ldots, x_n) \in \{0,1\}^n$, o número esperado de arestas no corte é

$$\mathbb{E}|\nabla(S)| = \sum_{\{i,j\} \in E} \mathbb{P}\big[\, x_i \neq x_j \,\big].$$

Cada parcela depende apenas da distribuição conjunta de *dois* bits. Se x_i e x_j são uniformes e independentes, então

$$\mathbb{P}\big[\, x_i \neq x_j \,\big] = \mathbb{P}\big[\, x_i = 0, x_j = 1 \,\big] + \mathbb{P}\big[\, x_i = 1, x_j = 0 \,\big] = \frac{1}{2}$$

e $\mathbb{E}|\nabla(S)| = m/2$. Não é preciso que os n bits sejam mutuamente independentes: basta independência dois a dois.

Bits dois a dois independentes com poucos bits aleatórios Seja $d := \lceil \log_2 n \rceil$, de modo que $n \leqslant 2^d < 2n$. Associamos a cada vértice i um vetor $\mathsf{v}_i \in \mathbb{F}_2^d$, a representação binária de $i-1$ com d bits; vértices distintos recebem vetores distintos. Usamos a família 2-independente da Seção 6.4.1 com $\mathbb{F} = \mathbb{F}_2$,

$$h_{(\mathsf{a},b)}(\mathsf{v}) = \langle \mathsf{a}, \mathsf{v} \rangle + b, \qquad (\mathsf{a}, b) \in \mathbb{F}_2^d \times \mathbb{F}_2,$$

e definimos, para (a, b) sorteado uniformemente,

$$x_i := h_{(\mathsf{a},b)}(\mathsf{v}_i), \qquad 1 \leqslant i \leqslant n.$$

Para $i \neq j$ temos $\mathsf{v}_i \neq \mathsf{v}_j$ e, pela 2-independência, o par (x_i, x_j) tem distribuição uniforme em $\{0,1\}^2$, isto é, x_i e x_j são uniformes e independentes. Logo, pelo parágrafo anterior, para essa distribuição vale ainda

$$\mathbb{E}|\nabla(S)| = \frac{m}{2},$$

mas agora o sorteio usa apenas $d + 1 = O(\log n)$ bits.

Enumeração O espaço amostral é $\mathbb{F}_2^d \times \mathbb{F}_2$, com $2^{d+1} < 4n$ pontos equiprováveis. Como a média do tamanho do corte sobre esses pontos é $m/2$, existe um ponto (a, b) para o qual $|\nabla(S)| \geqslant m/2$. O algoritmo determinístico percorre todos os $2^{d+1} < 4n$ pontos, calcula o corte $S_{(\mathsf{a},b)} = \{\, i \colon x_i = 1 \,\}$ de cada um em tempo $O(n+m)$ (supondo que o produto interno de vetores de d bits custa $O(1)$; sem essa hipótese, $O(n \log n + m)$) e devolve o melhor. O tempo total é $O(n(n+m))$ e a resposta tem pelo menos $m/2$ arestas.

Observação 19. O ganho está na troca de n bits independentes, que levariam à enumeração de 2^n pontos, por $d+1 = O(\log n)$ bits dois a dois independentes, que levam a $O(n)$ pontos.

Isso só foi possível porque a quantidade que nos interessa, $\mathbb{E}|\nabla(S)|$, depende apenas de probabilidades de pares. Para análises que usem a independência de três ou mais variáveis (como a cota de Chernoff para o tamanho da maior lista), essa técnica não se aplica diretamente: com apenas 2-independência dispomos da cota de Chebyshev, mais fraca.

Observe também que a análise do Algoritmo 6.1 usa só $\mathbb{E}|\nabla(S)| = m/2$ e $|\nabla(S)| \leqslant m$ (Proposição 6.5), e portanto vale também com bits dois a dois independentes: poderíamos repetir sorteios de $d+1$ bits e obter a mesma cota $p \geqslant 1/(m+2)$. Na versão desta seção não sorteamos nada: percorremos todos os pontos, e o argumento da média garante que há um bom. ◊

Existe também um algoritmo determinístico eficiente de 1/2-aproximação para esse problema. Começamos com uma partição arbitrária dos vértices do grafo dado $G = (V, E)$ e movemos um vértice de cada vez de um lado da partição para o outro se isso melhora a solução, até que não haja mais movimentos que melhorem a solução. O número de iterações é no máximo m, porque cada movimento melhora o corte em pelo menos uma aresta e o corte nunca excede m. Para encontrar um vértice que melhora o corte basta contar, para cada vértice, quantos vizinhos estão de cada lado, o que custa $O(n+m)$, de modo que o tempo total é $O(m(n+m))$. Ao final, cada vértice tem pelo menos metade de seus vizinhos do lado oposto, pois senão movê-lo melhoraria o corte. Somando sobre os vértices, $2|\nabla(S)| \geqslant \sum_v \deg(v)/2 = m$, isto é, $|\nabla(S)| \geqslant m/2$.

6.5 Exercícios

Exercício 52. Sejam $n \geqslant k > 0$ inteiros. Identifique $\{0,1\}$ com o corpo $\mathbb{F}_2$, tome $\mathsf{A} \in {\mathbb{F}_2}^{k \times n}$ e $\mathsf{b} \in {\mathbb{F}_2}^k$. Prove que a família de funções $h_{\mathsf{A},\mathsf{b}} \colon {\mathbb{F}_2}^n \to {\mathbb{F}_2}^k$ dadas por $h_{\mathsf{A},\mathsf{b}}(\mathsf{x}) = \mathsf{Ax} + \mathsf{b}$, com (A, b) sorteado uniformemente, é 2-universal. (Dica: argumente linha a linha como na

seção 6.4.1; as k linhas de (A, b) são independentes.)

Exercício 53. Considere a família $\mathcal{H}$ de funções de *hashing* da seção 6.4.1 e fixe $S \subset \mathbb{F}^n$. Prove que se $|S| \leqslant \sqrt{|\mathbb{F}|}$ então para uma escolha aleatória de $h \in \mathcal{H}$ a probabilidade de não ocorrer colisão para os elementos de S é pelo menos $1/2$.

Exercício 54. Suponha que $\mathcal{H}$ seja uma família 2-universal de funções $\{0,1\}^n \to \{0,1\}^n$. Para $m < n$ podemos definir uma família $\mathcal{H}'$ de funções $\{0,1\}^n \to \{0,1\}^m$ fazendo para cada $h \in \mathcal{H}$

$$h'(x) \coloneqq h(x) \restriction_m$$

em que $h(x) \restriction_m$ denota a restrição de $h(x)$ aos primeiros m bits. $\mathcal{H}'$ é uma família 2-universal?

Exercício 55. A família de funções $h \colon \{0,1\}^n \to \{0,1\}^m$ indexada pelas matriz binárias $\mathsf{M} \in \{0,1\}^{(n+1)\times m}$ definida para todo $\mathsf{x} \in \{0,1\}^n$ por

$$h_M(\mathsf{x}) \coloneqq (\mathsf{x}, 1) \cdot \mathsf{M}$$

Mostre que essa família é 2-universal.

Exercício 56. Uma família $\mathcal{H} \subset M^U$ de funções de *hash* é ε-universal para $S \subset U$ se $\mathbb{P}[\, h(u) = h(s) \,] \leqslant \varepsilon$ para todos $u \neq s \in S$. Prove que nesse caso deve valer $\varepsilon \geqslant \frac{1}{|M|} - \frac{1}{|U|}$.

Exercício 57. Uma família de funções $\mathcal{H} = \{\, h_\lambda \in N^U : \lambda \in \Lambda \,\}$ tais que para quaisquer $x \neq y$

$$\mathop{\mathbb{P}}_{\lambda \in \Lambda} [\, h_\lambda(x) = h_\lambda(y) \,] \leqslant \frac{1}{|N|}.$$

é chamada de *hash fracamente* 2*-universal*. Verifique que a família de funções de Carter e Wegman (1979), dada no Exemplo 6.2, página 146 não é 2-universal, mas é fracamente 2-universal.

Exercício 58. Vamos repetir para MAX-E3SAT a desaleatorização do corte grande.

Uma instância de MAX-E3SAT consiste em uma fórmula booleana $\varphi = \bigwedge_{j=1}^{m} C_j$, em que cada cláusula tem a forma

$$C_j = \ell_{j,1} \vee \ell_{j,2} \vee \ell_{j,3},$$

e cada literal $\ell_{j,k}$ é uma variável booleana v_i ou sua negação $\neg v_i$. O objetivo é encontrar uma atribuição $a \in \{0,1\}^n$ que maximize o número de cláusulas satisfeitas.

Seja $C = \{\, C_1, \ldots, C_m \,\}$ uma instância de MAX-E3SAT sobre as variáveis $V = \{\, v_1, \ldots, v_n \,\}$, em que cada cláusula tem exatamente três

literais, sobre variáveis distintas. Seja $d = \lceil \log_2 n \rceil$ e identifique as variáveis com elementos distintos de $\mathbb{F}_{2^d}$ (ou de $\mathbb{F}_2^d$)

$$V \ni v_i \leftrightarrow x_i \in \mathbb{F}_{2^d}.$$

Para uma distribuição sobre valorações $(x_1, \ldots, x_n)$, seja X o número de cláusulas satisfeitas.

1. *Usando independência de par a par.* Suponha que $x_1, \ldots, x_n$ são uniformes e independentes *dois a dois*. Seja $C = \ell_1 \vee \ell_2 \vee \ell_3$ uma cláusula e A_k o evento "o literal ℓ_k vale 1".
   (a) Mostre que $\mathbb{P}(A_k) = 1/2$ e $\mathbb{P}(A_j \cap A_k) = 1/4$ para $j \neq k$.
   (b) Prove, por inclusão e exclusão, que $\mathbb{P}(A_1 \cup A_2 \cup A_3) \geqslant \sum_k \mathbb{P}(A_k) - \sum_{j<k} \mathbb{P}(A_j \cap A_k)$ e conclua que $\mathbb{P}[\, C \text{ é satisfeita} \,] \geqslant 3/4$.
   (c) Conclua que $\mathbb{E}X \geqslant 3m/4$.
2. *A cota* $3/4$ *é justa para pares.* Considere a cláusula $v_1 \vee v_2 \vee v_3$ e bits x_1, x_2 uniformes e independentes com $x_3 := x_1 \oplus x_2$. Mostre que x_1, x_2, x_3 são uniformes e independentes dois a dois e que a cláusula é satisfeita com probabilidade exatamente $3/4$.
3. *Desaleatorização com pares.* Use a família da seção 6.4.1 com $\mathbb{F} = \mathbb{F}_2$ para obter um algoritmo determinístico que devolve uma valoração satisfazendo pelo menos $3m/4$ cláusulas. Quantas valorações ele examina e qual o seu tempo?

Exercício 59. Nesse exercício vamos estender a análise do MAX-E3SAT.

1. Imite a demonstração da Proposição 6.5 e demonstre: *Seja φ uma instância de* MAX-E3SAT *e p a probabilidade com que uma valoração satisfaz pelo menos $7/8$ de todas as cláusulas. Então*
$$p \geqslant \frac{1}{m+8}.$$
2. Escreva um algoritmo Las Vegas que determina tal valoração e determine o seu tempo médio de execução.
3. *Independência de três a três.* Seja $\mathbb{F} = \mathbb{F}_{2^d}$ e, para $(\alpha_0, \alpha_1, \alpha_2) \in \mathbb{F}^3$,
$$g_\alpha(y) := \alpha_0 + \alpha_1 y + \alpha_2 y^2.$$
   (a) Mostre que, para $y_1, y_2, y_3 \in \mathbb{F}$ distintos e quaisquer $z_1, z_2, z_3 \in \mathbb{F}$, existe exatamente um $\alpha \in \mathbb{F}^3$ com $g_\alpha(y_k) = z_k$ para $k = 1, 2, 3$. (Dica: matriz de Vandermonde.) Conclua que, para α uniforme, $g_\alpha(y_1), g_\alpha(y_2), g_\alpha(y_3)$ são uniformes e independentes em $\mathbb{F}$.

(b) Seja $\lambda : \mathbb{F} \to \mathbb{F}_2$ uma função linear sobrejetora (por exemplo, a primeira coordenada de $\mathbb{F} \cong \mathbb{F}_2^d$). Mostre que cada valor de $\mathbb{F}_2$ tem exatamente $q/2$ preimagens e conclua que os bits $x_i := \lambda(g_\alpha(y_i))$, onde y_i é o elemento de $\mathbb{F}$ associado à variável v_i, são uniformes e *independentes três a três*.

(c) Mostre que, para essa distribuição, cada cláusula é satisfeita com probabilidade exatamente $7/8$ e que $\mathbb{E}X = 7m/8$.

4. *O algoritmo.* Descreva um algoritmo determinístico que enumera todos os $\alpha \in \mathbb{F}^3$, avalia a valoração correspondente e devolve a melhor, e prove que ele satisfaz pelo menos $7m/8$ cláusulas. Mostre que o número de valorações examinadas é $q^3 < 8n^3$ e que o tempo total é $O(n^3(n+m))$, supondo operações em $\mathbb{F}$ de custo constante. Compare com a enumeração de todas as 2^n valorações e com a versão do item 3.

5. *Versão aleatorizada com poucos bits.* Mostre que a prova da proposição que dá $p \geqslant 1/(m+8)$ usa apenas $\mathbb{E}X = 7m/8$ e $X \leqslant m$. Conclua que o algoritmo com o sorteio de α em $\mathbb{F}^3$ (isto é, $3d = O(\log n)$ bits por rodada), tem a mesma garantia $\mathbb{E}Z \leqslant m + 8$ para o número de rodadas que o algoritmo desenvolvido no item 2.