Algoritmos de *streaming* e o contador de Morris

Algoritmos Probabilísticos

J.D.

UFABC

Fluxos de dados

Um fluxo é uma sequência extremamente longa de itens de um universo, lida uma única vez, em ordem. Há dados demais para armazenar e eles chegam rápido demais.

- **Roteador de rede:** quantos endereços de origem distintos aparecem? Quais enviam mais tráfego?
- **Servidor web / busca:** quantos visitantes únicos? Quais os termos mais buscados?
- **Sensores:** leituras contínuas, em dispositivos com memória muito limitada.

O modelo de *streaming*

Os dados chegam um a um:

$$\sigma = (x_1, x_2, \ldots, x_m), \qquad x_i \in \{1, \ldots, n\},$$

com m muito grande e possivelmente desconhecido.

- Memória muito menor que m, idealmente polilogarítmica: $(\log m + \log n)^{O(1)}$ bits.
- Resultados exatos costumam ser impossíveis. Recorremos a aleatoriedade e a aproximações (ε, δ): com probabilidade $\geq 1 - \delta$, o erro relativo é $\leq \varepsilon$.

Para comparação, memorizar o fluxo inteiro custaria $m \log n$ bits, e manter um vetor com um bit para cada elemento do universo, marcando os que já apareceram, custaria n bits.

Problemas básicos

a) **Elementos distintos:** quantos valores diferentes aparecem?

b) **Estimativa de frequências:** quantas vezes i apareceu, sem um contador por elemento (*heavy hitters*).

c) **Momentos de frequência:** $F_k = \sum_i f_i^k$. Aqui $F_0 =$ distintos, $F_1 = m$, F_2 mede a não uniformidade.

d) **Amostragem em fluxo:** amostra uniforme de ℓ elementos de um fluxo de tamanho desconhecido.

e) **Contagem aproximada:** contar m itens com muito menos que $\log_2 m$ bits.

Hoje: o item e), o mais simples, devido a Morris (1978).

Contagem exata

Fluxo de comprimento em $\{1, \ldots, m\}$, com m conhecido.

- Mantemos um contador c, incrementado a cada item.
- Basta guardar c mod m: são m valores, ou seja, $\lceil \log_2 m \rceil$ bits. O resto 0 é lido como m.

É possível usar bem menos? Para algoritmos determinísticos exatos, não.

Limite inferior para contagem exata

Proposição

Seja $m \geq 2$. Nenhum algoritmo determinístico com no máximo $\lceil \log_2 m \rceil - 1$ bits devolve o comprimento exato de toda sequência de comprimento em $\{1, \ldots, m\}$. O mesmo vale para algoritmos aleatorizados que nunca erram.

Ideia da prova.

- Com $b = \lceil \log_2 m \rceil - 1$ bits há $2^b < m$ estados.
- Seja S_i o estado após ler $(1, \ldots, 1)$ de comprimento i, $i = 1, \ldots, m$. Pelo princípio da casa dos pombos, $S_i = S_j$ para algum $i \neq j$.
- A saída é função do estado final: mesma resposta, mas as corretas (i e j) diferem.
- Aleatorizado que nunca erra: fixada a semente, torna-se determinístico.

O limite é justo: o contador módulo m usa $\lceil \log_2 m \rceil$ bits.

(ε, δ)-aproximação

Definição

Dados $\varepsilon, \delta \in (0, 1)$, um algoritmo aleatorizado é uma (ε, δ)-aproximação se, para todo fluxo de comprimento m, calcula $\widehat{m}$ tal que

$$\Pr[|\widehat{m} - m| \leq \varepsilon m] \geq 1 - \delta,$$

com a probabilidade sobre as escolhas aleatórias do algoritmo.

- ε é a precisão; $1 - \delta$ é a confiança.
- Quanto menores ε e δ, melhor a garantia e maior a memória.

O algoritmo de Morris

Algoritmo

Entrada: fluxo $(x_1, \ldots, x_m)$ (os valores x_i são ignorados).
Saída: estimativa $\widehat{m}$ de m.

$X \leftarrow 0$
para cada item lido:
    com probabilidade 2^{-X}, faça $X \leftarrow X + 1$
devolva $2^X - 1$

O algoritmo de Morris

Algoritmo

Entrada: fluxo $(x_1, \ldots, x_m)$ (os valores x_i são ignorados).
Saída: estimativa $\widehat{m}$ de m.

$X \leftarrow 0$
para cada item lido:
    com probabilidade 2^{-X}, faça $X \leftarrow X + 1$
devolva $2^X - 1$

Intuição.

- Com $X = j$, o número de itens até o incremento é geométrico, de média 2^j.
- Chegar a $X = j$ leva em média $1 + 2 + \cdots + 2^{j-1} = 2^j - 1$ itens: daí a saída $2^X - 1$.
- Só guardamos $X \approx \log_2 m$, ou seja, $O(\log \log m)$ bits (com alta probabilidade).

Recorrência do contador

Seja X_i o valor de X após i itens, $X_0 = 0$. Dado $X_{i-1} = j$:

$$X_i = \begin{cases} j+1 & \text{com probabilidade } 2^{-j}, \\ j & \text{com probabilidade } 1 - 2^{-j}. \end{cases}$$

Para $f : \mathbb{N} \to \mathbb{N}$, defina $g_f(j) := (1 - 2^{-j}) f(j) + 2^{-j} f(j+1)$. Pela lei da esperança total,

$$\mathbb{E}[f(X_i)] = \sum_j \Pr[X_{i-1} = j]\, g_f(j) = \mathbb{E}[g_f(X_{i-1})]\,. \qquad (*)$$

A soma é finita, pois $X_i \in \{0, \ldots, i\}$.

O estimador é não viesado

Teorema 1

Para toda entrada de comprimento $m \geq 0$, $\mathbb{E}\left[2^{X_m}\right] = m + 1$. *Logo* $\widehat{m} = 2^{X_m} - 1$ *satisfaz* $\mathbb{E}[\widehat{m}] = m$.

O estimador é não viesado

Teorema 1

Para toda entrada de comprimento $m \geq 0$, $\mathbb{E}\left[2^{X_m}\right] = m + 1$. Logo $\widehat{m} = 2^{X_m} - 1$ satisfaz $\mathbb{E}[\widehat{m}] = m$.

Prova. Indução em m. Para $f(j) = 2^j$,

$$g_f(j) = (1 - 2^{-j})2^j + 2^{-j}2^{j+1} = 2^j + 1.$$

O estimador é não viesado

Teorema 1

Para toda entrada de comprimento $m \geq 0$, $\mathbb{E}\left[2^{X_m}\right] = m + 1$. Logo $\widehat{m} = 2^{X_m} - 1$ satisfaz $\mathbb{E}[\widehat{m}] = m$.

Prova. Indução em m. Para $f(j) = 2^j$,

$$g_f(j) = (1 - 2^{-j})2^j + 2^{-j}2^{j+1} = 2^j + 1.$$

Por $(*)$ e pela hipótese de indução,

$$\mathbb{E}\left[2^{X_m}\right] = \mathbb{E}\left[2^{X_{m-\mathbf{1}}}\right] + 1 = m + 1. \qquad \square$$

Segundo momento e variância

Lema 1
$\mathbb{E}\left[(2^{X_m})^2\right] = \mathbb{E}\left[4^{X_m}\right] = \frac{3}{2}m^2 + \frac{3}{2}m + 1.$

Segundo momento e variância

Lema 1

$\mathbb{E}\big[(2^{X_m})^2\big] = \mathbb{E}\big[4^{X_m}\big] = \frac{3}{2}m^2 + \frac{3}{2}m + 1.$

Prova. Para $f(j) = 4^j$: $g_f(j) = 4^j + 3 \cdot 2^j$. Por $(*)$ e pelo teorema anterior,

$$\mathbb{E}\big[4^{X_i}\big] = \mathbb{E}\big[4^{X_{i-1}}\big] + 3\mathbb{E}\big[2^{X_{i-1}}\big] = \mathbb{E}\big[4^{X_{i-1}}\big] + 3i \;\Rightarrow\; \mathbb{E}\big[4^{X_m}\big] = 1 + 3\sum_{i=1}^{m} i = \frac{3}{2}m^2 + \frac{3}{2}m + 1.$$

Segundo momento e variância

Lema 1

$\mathbb{E}\big[(2^{X_m})^2\big] = \mathbb{E}\big[4^{X_m}\big] = \frac{3}{2}m^2 + \frac{3}{2}m + 1.$

Prova. Para $f(j) = 4^j$: $g_f(j) = 4^j + 3 \cdot 2^j$. Por $(*)$ e pelo teorema anterior,

$$\mathbb{E}\big[4^{X_i}\big] = \mathbb{E}\big[4^{X_{i-1}}\big] + 3\mathbb{E}\big[2^{X_{i-1}}\big] = \mathbb{E}\big[4^{X_{i-1}}\big] + 3i \;\Rightarrow\; \mathbb{E}\big[4^{X_m}\big] = 1 + 3\sum_{i=1}^{m} i = \frac{3}{2}m^2 + \frac{3}{2}m + 1.$$

Corolário 1

$\mathrm{Var}[\widehat{m}] = \mathbb{E}\big[(2^{X_m})^2\big] - (\mathbb{E}\big[2^{X_m}\big])^2 = \dfrac{m(m-1)}{2}.$

Um único contador não basta

Para $m \geq 1$, $\mathrm{Var}[\widehat{m}] \leq m^2/2$: o desvio padrão é da ordem de $m/\sqrt{2}$, comparável a m. Por Chebyshev,

$$\Pr[|\widehat{m} - m| \geq \varepsilon m] \leq \frac{\mathrm{Var}[\widehat{m}]}{\varepsilon^2 m^2} \leq \frac{1}{2\varepsilon^2}.$$

- Só é não trivial para $\varepsilon > 1/\sqrt{2}$.
- Com $\varepsilon \in (0, 1)$, o limite é sempre $> 1/2$: nunca dá $\delta < 1/2$.

Um único contador não basta

Para $m \geq 1$, $\mathrm{Var}[\widehat{m}] \leq m^2/2$: o desvio padrão é da ordem de $m/\sqrt{2}$, comparável a m. Por Chebyshev,

$$\Pr[|\widehat{m} - m| \geq \varepsilon m] \leq \frac{\mathrm{Var}[\widehat{m}]}{\varepsilon^2 m^2} \leq \frac{1}{2\varepsilon^2}.$$

- Só é não trivial para $\varepsilon > 1/\sqrt{2}$.
- Com $\varepsilon \in (0, 1)$, o limite é sempre $> 1/2$: nunca dá $\delta < 1/2$.

Precisamos melhorar a concentração: dois truques.

1. **Média** de cópias independentes: divide a variância.
2. **Mediana** de várias médias: amplifica a confiança.

O truque da média

Executamos t cópias independentes do algoritmo sobre o mesmo fluxo e devolvemos

$$\widehat{m}^* = \frac{1}{t}\sum_{i=1}^{t} \widehat{m}_i.$$

- $\mathbb{E}[\widehat{m}^*] = m$ e, pela independência, $\mathrm{Var}[\widehat{m}^*] = \dfrac{\mathrm{Var}[\widehat{m}_1]}{t} \le \dfrac{m^2}{2t}$.
- Chebyshev: $\Pr[|\widehat{m}^* - m| \ge \varepsilon m] \le \dfrac{1}{2t\varepsilon^2}$.
- Com $t = \lceil 1/(2\varepsilon^2\delta) \rceil$, obtém-se uma (ε, δ)-aproximação.

Problema: o custo cresce com $1/\delta$.

O truque da mediana

- $t = \lceil 3/(2\varepsilon^2) \rceil$: cada média erra com probabilidade $\leq 1/3$ (Chebyshev).
- Repetimos s vezes (com s ímpar) e devolvemos a mediana $\widehat{m}^{**}$ das s médias.
- Y_i: indicador de que a i-ésima média é boa. Independentes, $\Pr[Y_i = 1] \geq 2/3$, logo $\mathbb{E}[Y] \geq 2s/3$ para $Y = \sum Y_i$.
- Mediana ruim $\Rightarrow$ pelo menos $(s+1)/2$ médias ruins $\Rightarrow$ $Y - \mathbb{E}[Y] < -s/6$.
- Chernoff–Hoeffding:

$$\Pr[|\widehat{m}^{**} - m| \geq \varepsilon m] \leq \exp\left(-\frac{2(s/6)^2}{s}\right) = e^{-s/18}.$$

Basta $s \geq 18 \ln(2/\delta)$ para erro $\leq \delta/2$.

Por que Chebyshev na média e Chernoff na mediana?

- As saídas $\widehat{m}_i = 2^{X_m} - 1$ são ilimitadas; só controlamos bem a variância $\Rightarrow$ Chebyshev.
- Os indicadores $Y_i \in \{0, 1\}$ são limitados e independentes $\Rightarrow$ Chernoff–Hoeffding.
- Só com Chebyshev na mediana, precisaríamos de $s = \Omega(1/\delta)$. Com Chernoff, $s = O(\log(1/\delta))$.

Memória fixa: reservar e abortar

- O espaço usado é aleatório: X pode, raramente, passar do limiar.
- O algoritmo reserva o espaço do limiar e aborta se algum contador o exceder (probabilidade $\leq \eta$).
- Com $\eta = \delta/2$: metade de δ para o erro de precisão, metade para o aborto.

Exemplo. $m = 10^9$, $N = 1$, $\eta = 10^{-3}$: o limiar é 10^{12} e $\log_2 10^{12} \approx 39{,}9$. Com probabilidade $\geq 99{,}9\%$, $X < 40$, que cabe em 6 bits; o contador exato precisaria de 30 bits.

Garantias finais

Para $\varepsilon, \delta \in (0,1)$ com $1/(\varepsilon\delta) \leq m^{O(1)}$, existem (ε, δ)-aproximações de m com memória:

Variante	Contadores	Bits
Média	$\lceil 1/(\varepsilon^2\delta) \rceil$	$O\left(\frac{\log\log m}{\varepsilon^2\delta}\right)$
Mediana de médias	ts, $t = \lceil \frac{3}{2\varepsilon^2} \rceil$, $s \geq 18 \ln \frac{2}{\delta}$	$O\left(\frac{\ln(2/\delta)\ \log\log m}{\varepsilon^2}\right)$

A mediana troca $1/\delta$ por $\ln(2/\delta)$: preferível quando δ é pequeno.

Resumo

- Fluxos: leitura única, memória polilogarítmica, aproximação aleatorizada (ε, δ).
- Contagem exata exige $\lceil \log_2 m \rceil$ bits (limite inferior justo).
- Contador de Morris: $\mathbb{E}\left[2^{X_m} - 1\right] = m$ e $\mathrm{Var}\left[2^{X_m} - 1\right] = m(m-1)/2$, com $O(\log \log m)$ bits.
- **Média** reduz a variância; **mediana** amplifica a confiança.

R. Morris, *Counting large numbers of events in small registers*, Communications of the ACM 21(10), 840–842, 1978.